https://hjfy.top/arxiv/2408.03464

遥感领域的视觉基础模型：综述

Siqi Lu[1], Junlin Guo[1], James R Zimmer-Dauphinee[2],
Jordan M Nieusma[4], Xiao Wang[3], Parker VanValkenburgh[5],
Steven A Wernke[2], Yuankai Huo[1,6]
[1]Department of Electrical and Computer Engineering, Vanderbilt University,
[2]Department of Anthropology, Vanderbilt University,
[3]Oak Ridge National Laboratory,
[4]Data Science Institute, Vanderbilt University,
[5]Department of Anthropology, Brown University
[6]Department of Computer Science, Vanderbilt University,

摘要—人工智能（AI）技术已深刻变革遥感领域，彻底改变了数据采集、处理与分析的方式。传统上依赖人工解译和特定任务模型的遥感研究，因基础模型的出现而得到显著提升——这些大规模预训练的人工智能模型能够以前所未有的准确率和效率完成多种任务。本文对遥感领域的基础模型进行了全面综述。我们根据模型架构、预训练数据集及方法论对这些模型进行分类。通过详细的性能对比，我们揭示了新兴趋势以及基础模型所取得的重大进展。此外，我们还探讨了技术挑战、实际应用意义及未来研究方向，强调了高质量数据、计算资源以及模型泛化能力提升的重要性。我们的研究还发现，预训练方法，尤其是自监督学习技术如对比学习和掩码自编码器，显著提升了基础模型的性能与鲁棒性。本综述旨在为研究人员和从业者提供一个全景式的参考，展示基础模型在遥感领域中的最新进展与充满前景的发展路径。

***Index Terms*—遥感，机器学习，人工智能，图像处理，计算机视觉，Transformer**

I. 引言

工智能（AI）技术深刻改变了遥感领域，彻底人革新了数据的采集、处理与分析方式。传统上，遥感项目严重依赖人工解译以及需要大量标注数据集和大量计算资源的任务特定模型。然而，人工智能与深度学习（DL）的出现开启了一个新时代，在此时代中，大规模预训练模型——即基础模型——能够以前所未有的准确率和效率完成多种任务。这些进步不仅拓展了遥感的潜在应用范围，还为其在各个领域的使用开辟了新的途径。

近年来，众多视觉基础模型相继涌现，在处理多样化的遥感任务方面表现出卓越性能。这些模型在场景分类、语义分割、目标检测等多个下游任务上展现出显著提升性能的潜力。通过利用海量的预训练数据和复杂的架构，这些基础模型在该领域树立了新的基准，已成为研究人员和工程师不可或缺的工具。

本文旨在对遥感领域中的视觉基础模型进行全面综述，且仅限于 2021 年 6 月至 2024 年 6 月期间发布的基础模型。这一时间段标志着现代基础模型（包括视觉 Transformer 和先进的自监督学习技术）发展的迅猛增长。尽管早期的模型如 Tile2Vec [47] 等为遥感领域的表示学习奠定了基础，但它们通常在规模和泛化能力方面存在局限性。此外，已有大量综述论文对 2021 年前的模型进行了全面概述。因此，我们的综述聚焦于近期的发展，以突出过去几年中涌现的独特贡献与创新。

在图 1 中，按时间顺序列出了 **58** 个视觉基础模型。为了便于导航并提升对研究人员的实用性，我们根据模型的感知层级（例如，图像级、区域级、像素级）对现有模型进行了分类。这种组织方式有助于明确哪些模型已被测试用于通用图像挑战，或特定应用，如环境监测、土地覆盖制图、

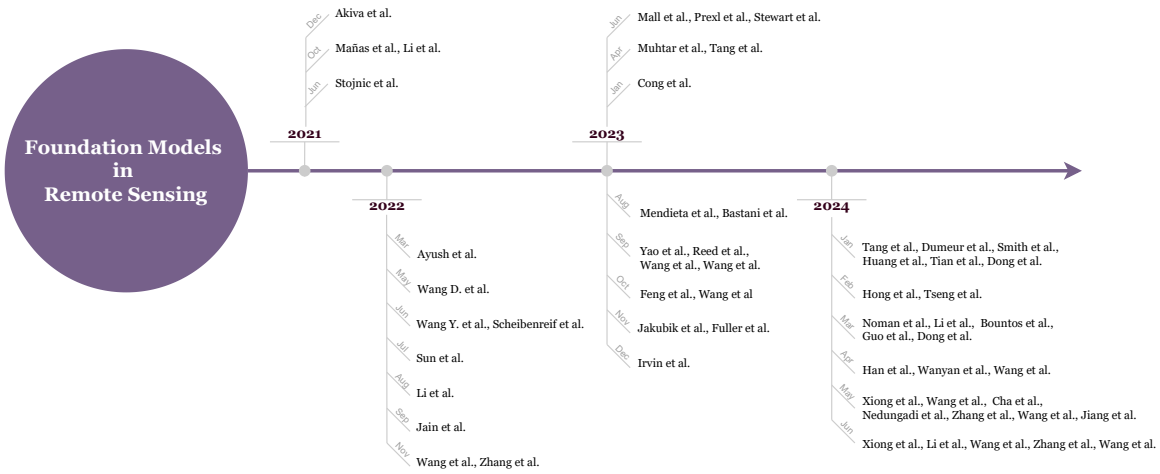

图 1: 2021 年 6 月至 2024 年 6 月期间一些知名遥感基础模型概览。

考古探索、灾害管理等。区分模型已被明确测试的应用与可能具有潜力的应用至关重要。在本综述中，某一模型未在特定应用上进行测试，并不意味着其表现不佳。基础模型，尤其是卷积神经网络（CNN）主干，如残差网络（ResNet）[36] 和视觉变换器（ViT）[25]，即使先前的研究尚未证明其有效性，仍可能适用于各种下游任务。

我们的贡献包括：

1) 对遥感领域中提出的视觉基础模型的现状进行详尽综述，从这些模型的背景和方法论出发，以层次化和结构化的方式，涵盖其在不同领域和任务中的具体应用。
2) 根据模型在图像分析（表 I）和实际应用（表 VI-B）中的应用进行分类与分析。我们讨论了每个模型的架构、预训练数据集、预训练方法及性能。
3) 讨论基础模型在遥感领域面临的挑战及尚未解决的问题。我们指出了新的趋势，提出了重要问题，并为未来的探索方向提出了建议。

II. 背景

A. 遥感

遥感（RS）是指通过卫星或机载传感器从远处获取物体或区域信息的过程。这些技术和方法在多个领域中发挥着重要作用，能够在不进行物理接触的情况下对地理区域进行数据采集。遥感的应用包括地球观测、数字考古学、城市规划与发展以及灾害管理。自 20 世纪中期以来，遥感领域发展迅速。最初，遥感主要由航空和卫星平台上的模拟摄影技术构成，其光谱和空间分辨率有限。1967 年启动的早期地球观测卫星项目，如陆地卫星计划（Landsat program）[112]，标志着重大进展，实现了环境监测所需的一致性和广泛的数据采集。

现代遥感采用多种传感器，适用于特定类型的数据采集，包括光学、热红外和雷达传感器。光学传感器可捕捉广泛的光谱波段，包括可见光和近红外光，从而实现对地表覆盖和植被健康状况的详细成像。热传感器可检测地球表面发射或反射的热量，有助于监测火山活动、森林火灾以及气候变化。雷达传感器能够穿透云层和植被，在全天候条件下提供关键信息，适用于土壤湿度估算和城市基础设施测绘等应用 [17], [71]。

近年来，遥感技术已广泛应用于多个领域。在环境监测方面，它被用于追踪森林砍伐、监测空气质量与水质，以及评估气候变化的影响 [30], [39]。在农业领域，遥感有助于作物健康监测、产量估算和资源的高效管理 [71]。城市规划与发展得益于遥感技术在城市扩张监测、基础设施建设及土地利用规划方面的应用 [17], [48]。此外，在灾害管理

Year-Month	Architecture	Model Name	Image-Level	Pixel-Level	Region-Level	Spatial-Temporal	Contrastive Learning	Predictive Coding
2021 Jun	ResNet-50	CMC-RSSR [84]	✓				✓	
2021 Oct	ResNet-50	SeCo [66]	✓			✓		
2021 Oct	ResNet-50	GeoKR [56]	✓	✓	✓			
2021 Dec	ResNet-34	MATTER [2]	✓	✓		✓		✓
2022 Mar	ResNet-50	GASSL [6]	✓	✓	✓		✓	
2022 May	ViTAEv2-S	RSP [96]	✓	✓	✓	✓		
2022 Jun	ViT-S/8	DINO-MM [105]	✓				✓	
2022 Jun	Swin Transformer	Scheibenreif, et al. [79]	✓	✓			✓	
2022 Jul	ViT/Swin Transformer	RingMo [87]	✓	✓	✓	✓		✓
2022 Aug	ResNet-50	GeCO [57]	✓	✓	✓			✓
2022 Sep	BYOL	RS-BYOL [45]	✓	✓			✓	
2022 Nov	ViT-B	CSPT [124]	✓		✓			✓
2022 Nov	ViT	RVSA [100]	✓	✓	✓			✓
2023 Jan	MAE-based Framework	SatMAE [16]	✓	✓				✓
2023 Apr	TOV	TOV [89]	✓	✓	✓			✓
2023 Apr	Teacher-student Self-distillation	CMID [70]	✓	✓	✓	✓		
2023 Jun	CACo	CACo [67]	✓	✓		✓	✓	
2023 Jun	ResNet-18	IaI-SimCLR [77]	✓				✓	
2023 Jun	ResNet	SSL4EO-L [83]		✓			✓	
2023 Aug	Teacher-Student	GFM [69]	✓	✓		✓		✓
2023 Aug	Swim Transformer	SatLasPretrain [7]	✓	✓				
2023 Sep	Multi-Branch	RingMo-Sense [119]		✓				✓
2023 Sep	ViT	Scale-MAE [78]	✓	✓				✓
2023 Sep	CNN-Transformer	RingMo-lite [109]	✓	✓	✓	✓		✓
2023 Sep	Multimodel SSL	DeCUR [102]	✓	✓				✓
2023 Oct	MSFE+MMFH	Feng et al. [27]	✓	✓	✓	✓		✓
2023 Oct	ViT	FG-MAE [108]	✓	✓				✓
2023 Nov	ViT	Prithvi [46]		✓				✓
2023 Nov	Multimodal Encoder	CROMA [28]	✓	✓			✓	✓
2023 Dec	ViT	USat [44]	✓					✓
2024 Jan	ViT-B	Cross-Scale MAE [88]	✓	✓				✓
2024 Jan	Unet+Transformer	U-BARN [26]	✓	✓				
2024 Jan	Autoregressive Transformer	EarthPT [82]	✓					✓
2024 Jan	Teacher-Student Network	GeRSP [42]	✓	✓	✓		✓	✓
2024 Jan	Dual-Branch	SwiMDiff [91]	✓					
2024 Jan	Generative ConvNet	SMLFR [22]		✓	✓			✓
2024 Feb	3D GPT	SpectralGPT [40]	✓	✓		✓		✓
2024 Feb	MAE-based Framework	Presto [92]		✓			✓	✓
2024 Mar	SatMAE	SatMAE++ [73]	✓					✓
2024 Mar	Joint-Embedding Predictive Architecture	SAR-JEPA [58]	✓					✓
2024 Mar	ViT	FoMo-Bench [8]	✓	✓	✓			✓
2024 Mar	Factorized Multi-Modal Spatiotemporal Encoder	SkySense [32]	✓	✓	✓	✓		✓
2024 Mar	Multi-Modules	UPetu [24]	✓	✓		✓		✓
2024 Apr	Swim Transformer	msGFM [33]	✓	✓				✓
2024 Apr	DINO	DINO-MC [111]	✓			✓	✓	
2024 May	OFA-Net	OFA-Net [118]	✓	✓				✓
2024 May	Shared Encoder, Task-Specific Decoders	MTP [99]	✓	✓	✓	✓		
2024 May	ViT	BFM [11]		✓	✓			✓
2024 May	MP-MAE	MMEarth [72]	✓	✓				✓
2024 May	ViT	CtxMIM [123]	✓	✓	✓			✓
2024 May	HiViT	SARATR-X [54]	✓		✓			✓
2024 May	Transformer	SoftCon [106]	✓	✓		✓	✓	
2024 May	ViT	LeMeViT [49]		✓	✓	✓		
2024 Jun	Masked Autoencoder	S2MAE [59]	✓			✓		✓
2024 Jun	CNN - Transformer	RS-DFM [110]		✓	✓			
2024 Jun	MAE-based	A2-MAE [122]	✓	✓		✓		
2024 Jun	ViT	HyperSIGMA [95]	✓	✓	✓	✓		✓
2024 Jun	Dynamic OFA	DOFA [117]	✓	✓				✓

表 I: 不同模型所采用的预训练方法及评估的图像分析任务总结。图像级、像素级、区域级和时空级对图像分析任务进行分类，而对比学习和预测编码则表明各研究使用的不同自监督预训练策略。

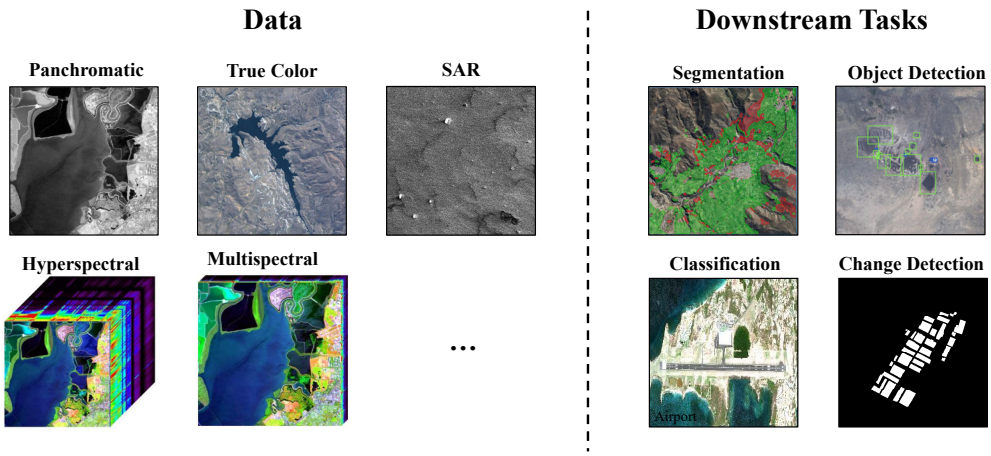

图 2: 基础模型中使用的一些数据类型以及基础模型可完成的下游任务示例。数据：(1) 全色 [4]，(2) 真彩色，(3) SAR [94]，(4) 超光谱 [4]，(5) 多光谱 [4]。下游任务：(1) 分割，(2) 目标检测，(3) 分类 [15]，(4) 变化检测 [76]。[1]

中，遥感对于评估自然灾害造成的损害至关重要，有助于救援行动的规划与实施 [1], [30]。

遥感数据与地理信息系统（GIS）的融合进一步提升了其应用价值。GIS 为捕捉、存储、分析和可视化空间及地理数据提供了框架。当与遥感数据结合时，GIS 可用于创建详细且动态的地图和模型，以应用于多种场景。这种协同作用在资源管理、城市规划和灾害应对等领域尤为宝贵，因为这些领域需要准确及时的信息 [17], [30], [71]。

B. 遥感领域的基础模型

基础模型（FMs）指的是大规模预训练模型，它们为不同领域中的各种下游任务提供了强有力的起点 [50]。这些模型利用海量数据集和先进的架构，能够捕捉复杂的模式与特征，通过少量额外训练即可微调以适应特定应用。在遥感领域，由于数据具有多样性和复杂性，包括多光谱和多时相影像，基础模型尤为有价值。自监督学习（SSL）[51] 和 Transformer [93] 等技术显著提升了图像分类、目标检测和变化检测等任务的性能与效率，有效应对了遥感数据带来的独特挑战 [19]。

[1]真彩色图像、分割图像和目标检测图像 © MAXAR 2024，通过 NextView 许可协议提供。

这些模型的一个主要优势在于它们能够利用自监督学习（SSL）从大量未标记数据中学习有效的表示，而这类数据在遥感场景中通常十分丰富 [126]。通过集成如 Transformer 等先进架构 [93]，遥感领域的表示学习模型可以处理地理空间数据的独特特性，例如变化的空间分辨率和时间动态性，而无需依赖分离的任务特定模型。

FMs 的演化得益于深度学习的进步以及大规模数据集的可用性。最初，如残差网络（Resnet）[37] 这样的卷积神经网络（CNNs）为改进图像识别和分类任务铺平了道路 [65]。Transformer 的引入，利用自注意力机制来建模长程依赖关系，进一步提升了 FMs 在处理大规模图像数据方面的能力 [16]。视觉 Transformer（ViTs）[25] 将 Transformer 架构扩展至图像数据处理，将图像块视为 token 序列，使模型能够学习局部与全局关系。这一能力使得 Transformer 在语义分割和变化检测任务中尤为有效，因为在这些任务中捕捉长程依赖关系至关重要，尤其是在高分辨率卫星影像中。

遥感领域中重要的基础模型包括 SatMAE [16]，其针对时序和多光谱卫星影像预训练 Transformer；Scale-MAE [78]，一种用于多尺度地理空间

表示学习的尺度感知掩码自编码器；以及 DINO-MC [111]，通过扩展全局-局部视图对齐实现遥感影像的自监督学习。这些模型在场景分类、目标检测和变化检测等多种遥感任务中表现出色。

尽管取得了成功，特征模型（FMs）仍面临诸多挑战，包括对高质量且多样化的训练数据的需求、巨大的计算资源消耗，以及针对特定遥感任务的有效领域自适应 [73]。解决这些挑战对于特征模型在遥感领域的持续发展至关重要。

III. 相关综述论文

人工智能在遥感领域的应用已成为一个日益增长的研究方向，众多综述论文深入探讨了人工智能的发展及其应用。本节将总结遥感领域基础模型方面最具影响力的几篇综述。

Zhang 等人（2016）在其基础性综述"*Deep Learning for Remote Sensing Data: A Technical Tutorial on the State of the Art*" [121] 中，将深度学习技术引入遥感（RS），重点介绍了卷积神经网络（CNNs）在图像分类和目标检测等任务中的应用。这项工作突出了早期人工智能在遥感中集成的潜力与挑战，为后续的发展奠定了基础。

2017 年，朱等人的"*深度学习在遥感中的综合回顾与资源列表*" [129] 深入探讨了多种人工智能应用，包括高光谱分析和合成孔径雷达（SAR）解读。该文献还提供了一份详尽的资源列表，反映了深度学习在解决复杂遥感挑战方面的快速应用，为后续几年更先进的人工智能模型的发展铺平了道路。

更近期的综述聚焦于先进的人工智能模型与方法。Wang 等人 2022 年的综述《*遥感中的自监督学习*》[103]，强调了自监督学习（SSL）方法能够利用大量未标记数据，显著降低对标注数据集的依赖，同时在遥感（RS）任务中保持高性能。该综述还指出了关键挑战与未来方向，强调了 SSL 在处理大规模遥感数据复杂性方面的潜力。

Zhang 等人（2022）在《人工智能在遥感数据分析中的应用：挑战与机遇综述》[120] 中，全面概述了人工智能算法，整合了超过 270 项研究的成果。文章强调了可解释性、安全性以及将人工智能与其他计算技术相结合等方面的持续挑战，为人工智能驱动的遥感领域未来创新提供了路线图。

Aleissaee 等人 2023 年的综述《遥感中的 Transformer》[3]，探讨了基于 Transformer 的模型在各类遥感（RS）任务中的影响，并将其与卷积神经网络（CNNs）进行了比较。该研究识别出其优势与局限性，以及尚未解决的挑战，为未来研究 Transformer 在遥感中作用提供了详细的路线图。

Li 等人 2024 年的综述《遥感中的视觉-语言模型》[60]，探讨了视觉-语言模型（VLMs）日益重要的作用，这些模型结合了视觉和文本数据。该综述强调了 VLMs 在图像描述生成和视觉问答等应用中的潜力，突出了遥感任务中向更丰富的语义理解转变的趋势。

此外，最近的工作《*关于地球与气候基础模型的根基*》[130] 对现有的基础模型进行了全面回顾，提出了地理定位嵌入和多感官能力等特征。它概述了未来地球与气候模型的关键特性，推动了地理空间人工智能基础进展的更广泛讨论。

在这些综述的基础上，本研究对 2021 年 6 月至 2024 年 6 月期间开发的基础模型进行了全面分析，重点关注自监督学习和基于 Transformer 架构的进展。与以往主要聚焦于单一技术的综述不同，我们探讨了这些技术在遥感任务中的联合潜力，例如语义分割、多光谱分析和变化检测。例如，SatMAE [16] 展示了自监督学习在预训练 Transformer 中的有效应用，从而提升了复杂多光谱图像中的分割性能；而 Scale-MAE 则采用尺度感知的掩码自编码器，更好地处理了遥感数据中不同的空间分辨率问题。

我们的研究还突出了 DINO-MC [111] 等新模型，该模型整合了全局-局部视图对齐用于自监督学习（SSL），在识别高分辨率卫星影像中的变化方面尤为有效。通过系统性地考察这些创新，我们展示了近期模型如何应对领域自适应和计算效率等长期挑战。例如，Scale-MAE [78] 中的高效自注意力机制有助于降低计算代价，而诸如 SatMAE 等模型中增强的地理定位嵌入则提升了在地理空间特征抽取方面的性能。

与早期的综述不同，这些综述往往停留在理论层面，我们强调了近期模型在理论进步和实际应用两方面的进展。例如，DINO-MC [111] 和 ORBIT 的 [101] 在环境监测和灾害响应中的实际应用突显了其实际影响，展示了如何有效利用新型 FMs 来应对地理空间分析中的紧迫挑战。

IV. 预训练方法

预训练是构建基础模型（FM）的关键步骤，使其能够从大规模数据集中学习可迁移且具备泛化能力的表示。该过程利用自监督或监督学习方法，提取与领域无关的特征，这些特征可适应多种下游任务。在本节中，我们探讨了基础模型在遥感领域常用的关键预训练方法，解释这些方法的机制及其在提升模型性能和应对该领域挑战中的作用。

A. 自监督学习

自监督学习已成为预训练基础模型的核心，其范式是通过从输入数据的某部分预测另一部分来学习表示。这种方法减少了对昂贵且耗时的标注数据集的依赖，在遥感等领域尤为有利，因为这些领域中的标注数据往往稀缺或难以获取。

自监督学习（SSL）使模型能够利用大量未标记数据，学习到丰富且可泛化的表示，这些表示在下游任务中表现良好，例如场景分类、语义分割、目标检测和变化检测。通过揭示数据的潜在结构和模式，SSL 不仅增强了模型的鲁棒性，还提升了其在不同领域和分辨率的遥感影像中的适应能力 [104]。图 3 展示了自监督学习的一般流水线。

在遥感视觉基础模型中，两种常用的自监督学习方法是对比学习和预测编码，它们各自提供了独特的机制来利用未标记数据中的信息。

1) 预测编码: 预测编码利用生成方法，使模型能够基于可见部分预测图像中缺失或被遮挡的部分。该策略有助于捕捉遥感影像中的空间和上下文关系，而遥感影像通常包含多样的纹理、复杂的场景以及不同的分辨率。

[2]目标检测与分割 © MAXAR 2024，根据 NextView 许可协议提供。

在遥感中，预测编码可应用于卫星影像中的缺损填补任务，其中模型学习推断由传感器限制或遮挡（如云层覆盖）导致的缺失数据。预测编码框架的流行实现包括基于自编码器的架构、如 MAE（掩码自编码器）[34] 所使用的掩码图像建模技术以及自回归模型。这些方法在学习高分辨率影像和特定任务中至关重要的细粒度细节方面尤为有效。

2) 对比学习: 对比学习是另一种强大的自监督学习技术，其重点在于区分数据中相似样本与不相似样本。其核心思想是将相似（正例）样本的表示拉近，同时将不相似（负例）样本的表示推远。这促使模型学习到对遥感任务至关重要的判别性和不变特征。

对比学习框架如 SimCLR [13]、MoCo [35]、DINO [9] 和 BYOL [29] 在遥感应用中展现出巨大潜力。它们利用随机裁剪、旋转或光谱波段丢弃等增强手段生成正样本对，使模型能够学习到对这些变换不变的鲁棒表示。例如，在多光谱或高光谱影像中，对比学习有助于模型在不同条件下捕捉光谱特征，从而提升作物分类或土地覆盖制图等任务的性能 [104]。

对比学习在遥感领域尤其重要，当标注数据集高度不平衡时，该方法使模型能够在没有显式标签的情况下从代表性不足的类别或区域中学习。

通过结合预测编码和对比学习等方法，自监督学习在遥感视觉基础模型的发展中取得了显著进展。这些方法使模型能够在利用海量未标记数据的同时，保持对不同空间分辨率、光谱波段和应用情景的适应性。另一方面，值得注意的是，还有许多其他自监督学习（SSL）方法可应用于此类任务。此外，诸如教师-学生自蒸馏框架等创新方法也在遥感应用中展现出潜力。例如，CMID [70] 通过在教师-学生自蒸馏框架中结合对比学习与掩码图像建模，取得了令人瞩目的性能。该结构使其能够捕捉全局与局部特征，从而在多种遥感任务中表现出色。自监督学习技术的多样性凸显了其灵活性与不断演进的特性，突显了其在充分挖掘遥感影像潜力方面的重要作用。

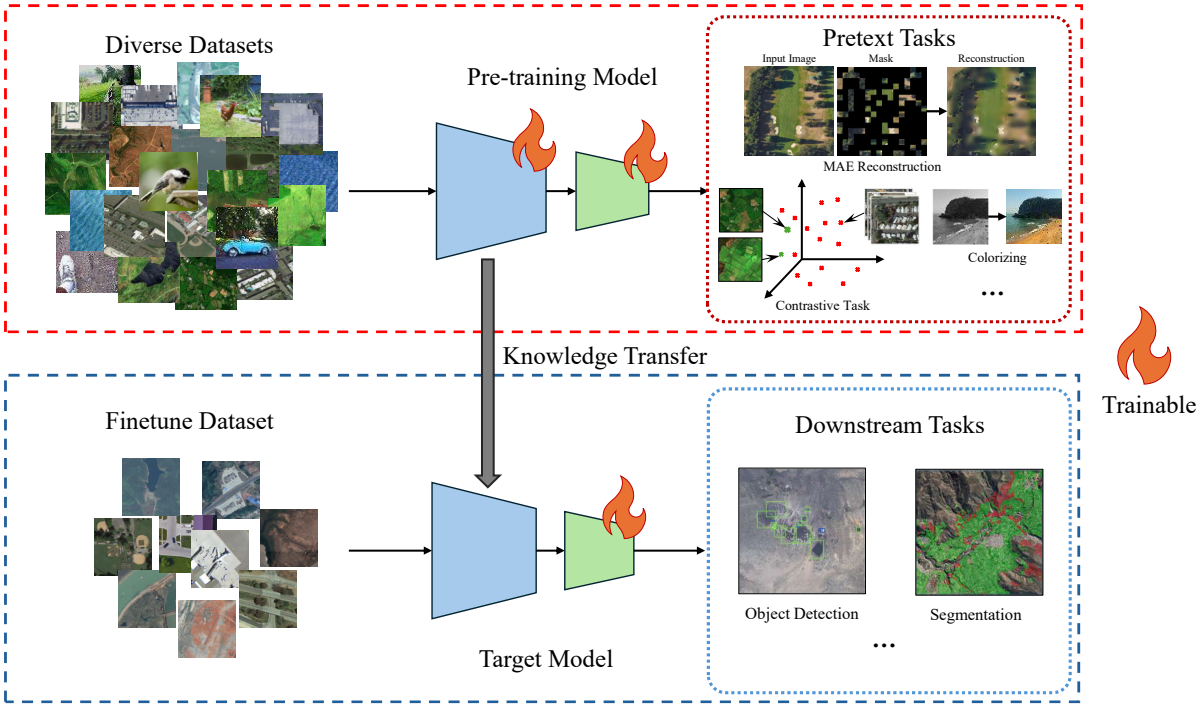

图 3: SSL [51] 的通用流水线。多样化的数据集图像和预训练任务图像来自 ImageNet [18]、BigEarthNet [85] 和 MillionAID [64]。微调数据集包括来自 DIOR [55] 的图像。[2]

B. 监督预训练

监督预训练是深度学习中的一个基础方法，其中模型使用标注数据集进行训练，以最小化特定任务（如图像分类）的预测误差。该方法使模型能够学习输入特征与目标标签之间的直接映射，促进详细、任务相关的表示的发展。例如，像残差网络 [36] 和 VGGNet（视觉几何组网络）[81] 这样的模型，在 ImageNet [18] 等大规模数据集上进行训练后，展示了监督预训练如何捕捉到对相关任务（包括语义分割或目标检测）具有高度可迁移性的稳健特征层次结构。

在遥感领域，监督预训练在利用高分辨率卫星影像进行土地覆盖分类和目标检测等任务中展现出巨大潜力 [97]。然而，其对大规模标注数据集的依赖构成了主要限制。为遥感任务创建标注数据集，尤其是涉及多光谱或高光谱数据时，资源消耗巨大，通常需要领域专业知识进行标注。例如，对土地覆盖分类的像素级数据进行标注，或在复杂城市环境中勾画物体边界，可能耗时过长，难以承受。此外，遥感领域的标注数据往往具有领域特异性，导致在某一数据集上训练的模型难以泛化到其他应用场景或区域 [129]。

这些挑战凸显了开发创新策略以减少对标注数据依赖的必要性。此类局限性推动了替代方法的发展，包括自监督预训练方法，该方法利用大量未标记数据，在无需人工标注的情况下学习通用表示。

V. 图像分析方法

A. 不同层次的图像感知

遥感领域的基础模型使图像分析在三个主要层次上成为可能：图像级、区域级和像素级。这些层次分别满足不同的空间、上下文和应用需求，为环境监测、城市规划、灾害响应等一系列任务奠定了基础。下文小节将概述每个层次的独特目标与应用。针对这些任务所评估的模型的详细总结

见表II。下文小节将概述每个层次的独特目标与应用。

1) 图像级: 图像级分析专注于分类任务，将整个图像或大图像区域归类到预定义类别中，例如城市、森林、水体或农业区。该方法为地理区域提供了宏观的高层次洞察，对于土地利用制图、土地覆盖分类和资源管理等大规模应用具有重要意义。通过分类整个场景，这一层级的分析能够高效监测广阔区域，支持环境管理和政策规划中的决策制定。

2) 区域级: 区域级分析能够识别并定位图像中的特定对象，例如建筑物、车辆、船只或其他结构。与提供整体分类的图像级分析不同，区域级任务专注于目标检测，即检测个体实体及其空间位置。这种分析对于城市规划等针对性应用至关重要，在这些应用中，基础设施的检测尤为关键；同时在灾害响应和安全领域，识别受损建筑或脆弱区域可显著促进及时干预。

表 II: 近年来遥感领域基础模型的概览，按架构、模型名称、预训练数据集、分辨率、地理覆盖范围、图像分析标签、视觉编码器、预训练方法以及参数量进行分类。**预训练方法的缩写如原作所述：** SSL 指自监督学习，CL 代表对比学习，MIM 为掩码图像建模，MAE 为掩码自编码器，FD-MIM 为特征蒸馏掩码图像建模。

Model Name	Architecture	Pre-training Dataset	Resolution (m)	Geographic Coverage	Image Analysis Levels	Pretrain methods	# of Par
CMC-RSSR [84]	ResNet-50	NWPU-DOTA [114], BigEarthNet [85], ImageNet [18]	0.2 to 60	Global	Image-level	Contrastive Multiview Coding	23M
SeCo [66]	ResNet-50	Sentinel-2 Imagery	10, 20, 60	200k Locations Worldwide	Image-level, Spacial-temporal	CL	23.5
GeoKR [56]	ResNet-50	Levir-KR [56]	0.8 to 16	Global	Image-level, Pixel-level, Region-level	Geographical Knowledge Supervision	23.5M/
MATTER [2]	ResNet-34	Sentinel-2 Imagery	-	Rural and Remote Regions with Little Changes	Image-level, Pixel-level	SSL	21.3
GASSL [6]	ResNet-50	fMoW [15], GeoImageNet [18]	-	7 Continents	Image-level, Pixel-level Region-level	CL	23.5
RSP [96]	ViTAEv2-S	MillionAID [63], [64]	0.5 to 153	Global	Image-level, Pixel-level, Region-level, Spacial-temporal	Supervised Learning	24.8M/23.5
DINO-MM [105]	ViT-S/8	BigEarthNet-MM [86]	10	Global	Image-level	SSL	22M
cheibenreif, et al. [79]	Swin Transformer	SEN12MS [80]	10	Global	Image-level, Pixel-level	CL	-
RingMo [87]	ViT/Swin Transformer	2 million RS images	0.3 to 30	6 Continents	Image-level, Pixel-level, Region-level, Spacial-temporal	MIM	-
GeCO [57]	ResNet-50	Levir-KR [56]	0.8 to 16	Global	Image-level, Pixel-level, Region-level	SSL	23.5
RS-BYOL [45]	BYOL	Sen12MS [80]	10 to 20	Global	Image-level, Pixel-level	SSL	23.5
CSPT [124]	ViT-B	ImageNet-1K [18]	-	Global	Image-level, Region-level	SSL	86M
RVSA [100]	ViT	MillionAID [63], [64]	0.5 to 153	Global	Image-level, Pixel-level, Region-level	MAE	100M
SatMAE [16]	MAE-based Framework	fMoW Sentinel-2 [15]	10, 20, 60	Global	Image-level, Pixel-level	MAE	307M

Continued on ne

表 II – continued from previous page

Model Name	Architecture	Pre-training Dataset	Resolution (m)	Geographic Coverage	Image Analysis Levels	Pretrain methods	# of Par
TOV [89]	TOV	TOV-NI, TOV-RS	-	Global	Image-level, Pixel-level, Region-level	SSL	-
CMID [70]	Teacher-student Self-distillation	MillionAID [63], [64]	Varied	Global	Image-level, Pixel-level, Region-level, Spacial-temporal	SSL	25.6M/8
CACo [67]	ResNet-18/50	Sentinel-2 Imagery	10	Global	Image-level, Pixel-level, Spacial-temporal	SSL	11.7M/2
IaI-SimCLR [77]	ResNet-18	SEN12MS	-	Global	Image-level	CL	11.7
SSL4EO-L [83]	ResNet/ViT	ImageNet [18], MoCo [35], SimCLR [13]	30	Global	Pixel-level	SSL	11.7M/23.5
GFM [69]	Teacher-Student	GeoPile [69]	-	Global	Image-level, Pixel-level	Continual Pretraining	-
SatlasPretrain [7]	SatlasNet	GeoPile [69]	1, 10	Global	Image-level, Pixel-level	Multi-task Learning	88M
RingMo-Sense [119]	Multi-Branch	RS Spatiotemporal Dataset	-	Global	Pixel-level	SSL	-
Scale-MAE [78]	ViT-Large	FMoW [15]	-	Global	Image-level, Pixel-level	MAE	322.9
RingMo-lite [109]	CNN-Transformer	AID [115]	0.3 to 30	Global	Image-level, Pixel-level, Region-level, Spacial-temporal	FD-MIM	60% less than
DeCUR [102]	Multimodel SSL	SSL4EO-S12 [107], RGB-DEM/depth	Varied	Global	Image-level, Pixel-level	SSL	23.5
Feng et al. [27]	MSFE+MMFH	Multi-modal Dataset	Varied	Global	Image-level, Pixel-level, Region-level, Spacial-temporal	SSL	-
FG-MAE [108]	ViT	SSL4EO-S12 [107]	10	Global	Image-level, Pixel-level	MAE	-
Prithvi [46]	ViT	Harmonized Landsat Sentinel 2	30	Contiguous U.S.	Pixel-level	MAE	100M
CROMA [28]	Multimodal Encoder	SSL4EO [107]	10	Areas Surrounding Human Settlements	Image-level, Pixel-level	CL, MAE	86M
USat [44]	ViT	Satlas [7]	Varied	Global	Pixel-level	MAE	-

Continued on ne

表 II – continued from previous page

Model Name	Architecture	Pre-training Dataset	Resolution (m)	Geographic Coverage	Image Analysis Levels	Pretrain methods	# of Par
Cross-Scale MAE [88]	ViT-B	fMoW [15]	-	Global	Image-level, Pixel-level	MAE	86M
U-BARN [26]	Unet+Transformer	Sentinel-2 Imagery	Varied	France	Image-level, Pixel-level	SSL	-
EarthPT [82]	Transformer	Sentinel-2 Imagery	10	UK	Image-level	Autoregressive SSL	700M
GeRSP [42]	Teacher-Student Network	ImageNet [18], MillionAID [63], [64]	0.5 to 153	Global	Image-level, Pixel-level, Region-level	SSL, SL	-
SwiMDiff [91]	Dual-Branch	Sen12MS [80]	Varied	Global	Image-level, Spacial-temporal	SSL	11.7
SMLFR [22]	Generative ConvNet	GeoSense [23]	0.05 to 150	Multiple Continents	Pixel-level, Region-level	SSL	88M/1
SpectralGPT [40]	3D GPT	Sentinel-2 Imagery	Varied	Global	Image-level, Pixel-level, Spacial-temporal	MAE	100M/300M
Presto [92]	MAE-based Framework	Presto-21.5M [92]	10	Global	Crop Type Segmentation	MAE	402
SatMAE++ [73]	SatMAE	fMoW [15]	Varied	Global	Image-level	Multi-Scale Pre-training	-
SAR-JEPA [58]	Joint-Embedding Predictive Architecture	100K SAR Images	Varied	Global	Image-level	SSL	-
FoMo-Bench [8]	ViT	Multiple	Varied	Global	Image-level, Pixel-level, Region-level	MAE	101M/1
SkySense [32]	Factorized Multi-Modal Spatiotemporal Encoder	Multiple	Varied	Global	Image-level, Pixel-level, Region-level, Spacial-temporal	CL	2.06
UPetu [24]	Multi-Modules	GeoSense [23]	-	Global	Image-level, Pixel-level, Spacial-temporal	SSL	0.65
msGFM [33]	Swin Transformer	GeoPile-2 [69]	0.1 to 153	Global	Image-level, Pixel-level	MIM	89M
DINO-MC [111]	DINO	SeCo-100K [66]	10 to 60	Global	Image-level, Spacial-temporal	SSL	-
OFA-Net [118]	OFA-Net	Multi-modal Dataset	Varied	Global	Image-level, Pixel-level	MIM	-
MTP [99]	Shared Encoder Task-Specific Decoders	SAMRS [98]	Varied	Global	Image-level, Pixel-level, Region-level, Spacial-temporal	Multi-Task Pretraining	over 30

Continued on ne

表 II – continued from previous page

Model Name	Architecture	Pre-training Dataset	Resolution (m)	Geographic Coverage	Image Analysis Levels	Pretrain methods	# of Par
BFM [11]	ViT	MillionAID [63], [64]	0.5 to 153	Global	Pixel-level, Region-level	MAE	86M/605 1.36B/2
MMEarth [72]	MP-MAE	Multi-modal, Geospatial Data	-	Global	Image-level, Pixel-level	MP-MAE	3.7M to
CtxMIM [123]	ViT	WorldView-3 Imagery	Varied	Asia	Image-level, Pixel-level, Region-level	MIM	88M
SARATR-X [54]	HiViT	SAR Datasets	0.1 to 3	Global	Image-level, Region-level	MIM	66M
SoftCon [106]	Siamese Network with ResNet and ViT Backbones	SSL4EO-S12-ML [107]	-	Global	Image-level, Pixel-level, Spacial-temporal	Multi-label Soft Contrastive Learning	23M, 23M
LeMeViT [49]	Hierarchical ViT	MillionAID [63], [64]	-	-	Image-level, Pixel-level, Region-level , Spacial-temporal	Dual Cross-Attention with Learnable Meta Token Adaptation	8.33M to
S2MAE [59]	3D Transformer-based MAE	fMoW-Sentinel [15], BigEarthNet [85]	-	Global	Image-level, Spacial-temporal	3D MAE	-
RS-DFM [110]	Multi-platform Inference Framework	AirCo-MultiTasks [110]	-	-	3D Region-level, Pixel-level	Generalized Feature Mapping with Relative Depth Estimation	-
A2-MAE [122]	ViT-Large	STSSD (Spatial-Temporal-Spectral Structured Dataset)	0.8 - 30m	Global	Image-level, Pixel-level, Spacial-temporal	Anchor-aware Masking Strategy and Geographic Encoding Module	304M
HyperSIGMA [95]	ViT-based	HyperGlobal-450K [95]	30m	Global	Image-level, Region-level, Anomaly Detection, Spacial-temporal	MAE	over
DOFA [117]	Dynamic OFA	Multiple	1 to 30	Global	Image-level, Pixel-level	MIM	111M/3

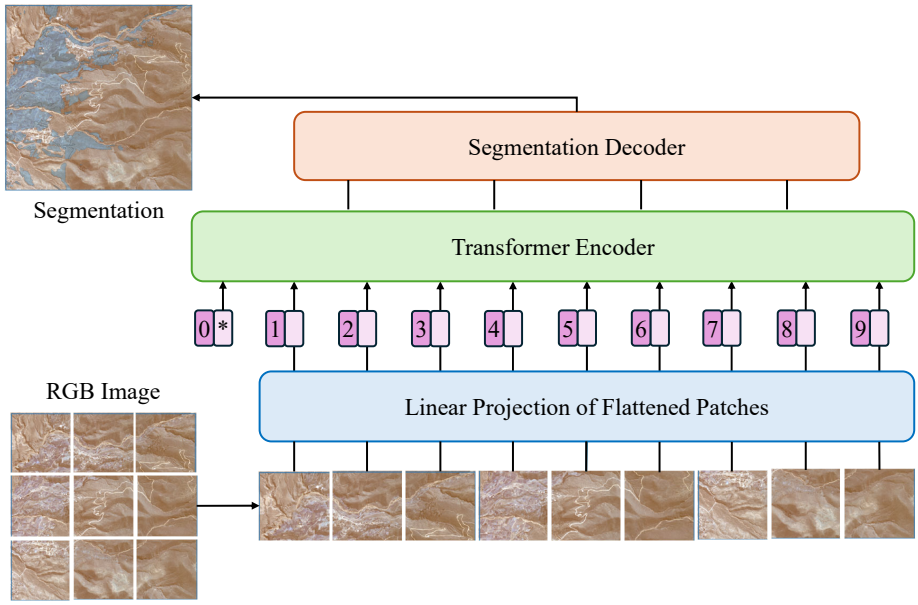

图 4: 视觉 Transformer 架构。[3]

3) 像素级: 像素级分析提供了最精细的图像感知方式，为图像中的每个像素分配一个标签。这包括语义分割等任务，其中每个像素被分类到植被、水体或建筑物等类别中；还包括变化检测，用于识别在不同时间拍摄的图像之间的时序差异。像素级分析对于创建高精度地图至关重要，这些地图广泛应用于精准农业、森林砍伐监测和灾害管理等领域。能够分析细微细节，使这些关键领域获得更准确的评估结果和可执行的洞察。

B. 骨架

1) 卷积神经网络（CNN）: 卷积神经网络 [74] 是深度学习中的基本架构，通过卷积层从图像中提取分层的空间特征。每个卷积层对输入数据应用滤波器，以在不同抽象层次上检测边缘、纹理和形状等模式。这使得卷积神经网络非常适合处理遥感中的复杂视觉任务，如图像分类、分割和目标检测。

残差神经网络（ResNet）[36]，一种卷积神经网络（CNN），通过引入残差连接来解决深度神经网络中的性能退化问题，使梯度能够绕过某些层，从而有助于训练非常深的网络。这一特性在遥感领域尤为有益，因为深度模型通常需要捕捉卫星图像中复杂的细节和变化。以残差网络（ResNet）为例，其特征是包含直连边的残差块，这些直连边可绕过一个或多个层。残差块可由如下公式描述：

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x}$$

其中 $\mathbf{y}$ 为输出，$\mathcal{F}$ 表示需要学习的残差映射，$\mathbf{x}$ 为输入，$\{W_i\}$ 为层权重 [37]。

残差网络（ResNet）具有多种架构，如 ResNet-50、ResNet-101 和 ResNet-152，其中数字表示网络的总层数。由于能够训练更深的网络而不会出现性能退化，这些网络在各种视觉任务中表现出色。在遥感领域，残差网络被广泛用于图像分类、目标检测和变化检测任务 [31]。例如，基于残差网络的模型可以对不同的地表覆盖类型进行分类 [125], [128]，检测建筑物和车辆等目标 [31]，并通过对比不同时相的卫星影像序列来监测景观随时间的变化 [75], [128]。

2) Transformer 与视觉 Transformer（ViT）: Transformer 在计算机视觉（CV）领域被 adapted

[3]RGB 图像与分割 © MAXAR 2024，根据 NextView 许可协议提供。

为视觉 Transformer（ViT），通过自注意力机制建模长距离依赖关系，使其在处理复杂的地理空间数据时表现出色。图4展示了 ViT 的架构。ViT 将图像视为补丁序列，能够捕捉全局和局部模式，这在分割和变化检测任务中非常有用。自注意力机制计算：

$$\text{Attention}(Q, K, V) = \text{softmax}\left[\frac{QK^T}{\sqrt{d_k}}\right[V$$

其中 Q（查询）、K（键）和 V（值）是输入矩阵，d_k 是键向量的维度 [93]。

通过整合这些方法，遥感领域的基础模型能够利用海量数据，处理复杂结构，并在各种应用中实现先进的性能。这些方法使模型能够有效应对遥感的独特挑战，例如大尺寸图像、多样的数据源以及环境监测与分析对高准确率的需求。

在接下来的章节中，我们将探讨这些方法在不同遥感任务中的具体应用，分析其性能，并讨论用于训练和评估这些模型的数据集。

VI. 数据与任务

A. 数据

数据集在遥感中起着至关重要的作用，为模型的训练和评估提供了基础。高质量的数据集使模型能够学习地球表面的准确表示，从而提升其在各种遥感任务中的表现。在图 2 中，我们展示了用于训练基础模型及其下游任务的一些数据示例。在本节中，我们在表 VIII 中概述了遥感领域常用的数据集，讨论了它们的特征、应用以及与基础模型的相关性。这些数据集具有不同的分辨率、类别和地理覆盖范围，为推进遥感研究和应用提供了丰富的资源。它们促进了鲁棒模型的发展，使模型能够应对通过遥感技术理解与解析地球表面时面临的多样化挑战。

遥感中使用的数据集在大小上差异显著，从 RSD46-WHU [62], [116] 中的数十万个样本到 MillionAID [63], [64] 中超过一百万个样本不等。通常情况下，更大的数据集通过涵盖多样化的地理区域、季节变化和环境条件，有助于提升模型的泛化能力。数据集的分辨率范围也从高分辨率（亚米级），适用于需要详细空间分析的任务，到中等分辨率（10-60 米），如 SEN12MS [80] 和 SSL4EO-S12 [107]，支持更广泛的模式识别应用。

这些数据集利用了多种传感器类型，包括 RGB、多光谱、高光谱以及合成孔径雷达（SAR）。例如，SEN12MS [80] 同时整合了 SAR 和多光谱影像，使模型能够从不同的数据模态中学习。传感器类型的多样性对于模型的稳健开发至关重要，因为每种传感器类型都能捕捉到独特的地表特征，从而支持受益于跨模态信息的任务。

基础模型尤其受益于这种大规模多模态数据集，它们支持在场景分类、分割和目标检测等任务中采用自监督和监督训练方法。为获得更深入的理解，附录详细描述了每个数据集的结构、独特特征及其应用角色，有助于加深对它们在遥感技术进步中作用的认识。

B. 任务

遥感中的不同应用通过利用基础模型的能力来解决特定的现实世界挑战。这些任务包括环境监测、考古学、农业、城市规划与发展以及灾害管理。为了突出基础模型在遥感中的多功能性，我们展示了表格 VI-B，该表根据模型在各种应用中的适用性以及所使用的不同图像分析方法对模型进行了分类。此图表可作为研究人员快速查找适合其特定需求模型的参考。

1) **环境监测**: 根据 Himeur 等人（2022）的研究，环境监测利用遥感模型来观测和追踪环境变化，包括森林砍伐、荒漠化和污染。这些模型在分析人类活动和自然现象对环境的影响方面发挥着至关重要的作用 [39]。

2) **农业**: 在农业中，遥感模型被用于监测作物健康状况、估算产量以及管理农业实践。根据 Kamilaris 等（2018）的研究，这些模型有助于优化资源利用并提高农业生产效率 [52]。

3) **考古学**: 在考古学中，遥感模型已被用于识别和分析考古特征与遗址。根据 Argyrou 等人（2022）的研究，这些模型有助于从卫星图像中检测废墟、文物和古代结构等特征，利用卷积神经网络（CNNs）和视觉 Transformer（ViTs）等技术

Tasks		Image Analysis by Levels				Related Work
		Image-Level	Pixel-Level	Region-Level	Spatial-Temporal	
Environmental Monitoring	Land Cover Change Detection				✓	[2], [40], [66], [67], [69], [70], [87], [91], [96], [109] [24], [32], [49], [59], [95], [99], [106], [111], [122]
	Deforestation Monitoring		✓			[2], [6], [16], [45], [56], [57], [79], [87], [89], [96], [100] [7], [27], [67], [69], [70], [78], [102], [109], [119] [22], [24], [26], [28], [32], [40], [42], [88], [92], [108] [33], [49], [95], [99], [106], [110], [117], [118], [122], [123]
	Water Body Analysis		✓	✓	✓	[27], [32], [49], [70], [87], [95], [96], [99]
	Forest Cover mapping		✓		✓	[27], [40], [49], [67], [69], [87], [96], [106], [109] [59], [95], [122]
	Biomass Estimation					[77]
	Weather/Climate Prediction	✓				[82], [101], [119]
	Cloud Removal					[33]
	Moisture Content Measurement					[92]
Agriculture	Crop Type Mapping	✓	✓	✓	✓	[27], [32], [49], [70], [83], [87], [95], [96], [99]
	Weed Detection			✓		[6], [27], [56], [57], [70], [87], [89], [96], [100], [124] [8], [22], [32], [49], [95], [99], [110], [123]
	Disease Monitoring	✓	✓		✓	[6], [27], [56], [57], [70], [87], [89], [96], [100] [22], [32], [49], [95], [99], [110], [123]
	Forecasting					[82], [119]
	Soil Parameter Estimation					[117]
	Yield Estimation	✓	✓			[2], [6], [16], [45], [56], [57], [79], [87], [89], [96], [100] [7], [27], [67], [69], [70], [78], [102], [109] [24], [26], [32], [33], [40], [42], [88], [108], [118] [95], [99], [106], [117], [122], [123]
	Agricultural Pattern Segmentation		✓			[66]
Archaeology	Artifact Classification and Recognition	✓		✓		[2], [6], [56], [66], [79], [84], [87], [96], [105] [7], [16], [67], [69], [70], [77], [78], [89], [100], [109], [124] [26], [27], [42], [44], [58], [82], [88], [91], [108] [8], [24], [32], [33], [72], [99], [106], [111], [118], [123] [40], [45], [57], [59], [95], [102], [117], [122]
	Detection of Archaeological Structures			✓		[6], [27], [56], [57], [70], [87], [89], [96], [100], [124] [8], [22], [32], [49], [95], [99], [110], [123]
	Semantic Segmentation		✓			[2], [6], [16], [45], [56], [57], [79], [87], [89], [96], [100] [7], [27], [67], [69], [70], [78], [102], [109], [119] [22], [24], [26], [28], [32], [40], [42], [88], [92], [108] [33], [49], [95], [99], [106], [110], [117], [118], [122], [123]
	Texture/Structural Analysis					[2]
	Pattern Recognition		✓	✓		[6], [27], [56], [57], [70], [87], [89], [96], [100] [22], [32], [49], [95], [99], [110], [123]
Urban Planning & Development	Traffic Monitoring	✓		✓	✓	[27], [32], [49], [70], [87], [95], [96], [99]
	Land Cover/Use Classification	✓				[2], [6], [56], [66], [79], [84], [87], [96], [105] [7], [16], [67], [69], [70], [77], [78], [89], [100], [109], [124] [26], [27], [42], [44], [58], [82], [88], [91], [108] [8], [24], [32], [33], [72], [99], [106], [111], [118], [123] [40], [45], [57], [59], [83], [95], [102], [117], [122]
	Road Crack Detection			✓		[6], [27], [56], [57], [70], [87], [89], [96], [100], [124] [8], [22], [32], [49], [95], [99], [110], [123]
	Air Quality Monitoring	✓		✓		[6], [27], [33], [56], [57], [70], [87], [89], [96], [100] [22], [32], [49], [95], [99], [110], [123]
	Building Extraction	✓	✓			[27]
	Object/Video Tracking			✓	✓	[119]
	Infrastructure Monitoring					[44], [119]
Disaster Management	Landslide Risk Monitoring	✓	✓	✓	✓	[27], [32], [49], [70], [87], [95], [96], [99]
	Disaster Response					[117]
	Real-Time Detection and Mapping		✓	✓	✓	[27], [32], [49], [70], [87], [95], [96], [99]
	Building Damage Assessment	✓	✓	✓		[27], [32], [49], [70], [87], [95], [96], [99]
	Critical Infrastructure Detection	✓		✓		[6], [27], [56], [57], [70], [87], [89], [96], [100], [124] [8], [22], [32], [49], [95], [99], [110], [123]
	Flood/Fire Mapping and Prediction	✓	✓		✓	[27], [40], [67], [69], [87], [96], [109] [49], [95], [106], [122]
	Crowd and Vehicle Detection			✓	✓	[2], [40], [66], [67], [69], [70], [87], [91], [96], [109] [24], [32], [49], [59], [95], [99], [106], [111], [122]

表 III: 该图展示了遥感在不同应用中的各类任务。主要领域包括环境监测、农业、城市规划与发展、灾害管理以及考古学。每个领域包含不同图像分析层级（如图像级、像素级、区域级和时空级）的具体任务。这些任务与其应用之间的关系通过勾号表示，突出了不同领域间图像分析方法的相互关联性。

处理高分辨率图像并捕捉细微细节 [5]。Mantovan 等人（2020）也强调了人工智能模型，特别是卷积神经网络（CNNs），在定位具有挑战性的陆地考古遗址以及处理多光谱数据方面的有效性 [68]。

4) **城市规划与发展***:* 在城市规划与发展方面，遥感模型被用于监测和分析城市扩张、基础设施建设和土地利用变化。根据 Jha 等人（2021 年）的研究，这些模型在管理城市增长、规划新开发项目以及评估城市化影响方面发挥着关键作用，为智慧城市建设与可持续发展提供了必要的数据支持 [48]。

5) **灾害管理***:* 遥感模型在灾害管理中发挥着至关重要的作用，能够提供受灾区域的及时信息。根据 Abid 等人（2021）的研究，这些模型用于探测和评估地震、飓风和洪水等自然灾害造成的损害，从而实现快速响应和恢复工作 [1]。

VII. 讨论

遥感基础模型的快速发展凸显了其在各类应用中的变革潜力。随着该领域持续演进，综合研究成果、解决技术挑战、理解实际应用意义并明确未来研究方向至关重要。在本节中，我们对这些方面进行了全面分析，旨在为遥感基础模型的未来发展与应用提供洞察与指导。

A. 研究结果综合

在我们对遥感领域基础模型的调研中，发现了显著的进步和趋势，凸显了这些模型能力与应用的不断发展。各类模型在不同下游任务（如场景分类、语义分割、目标检测和变化检测）中的性能指标揭示了以下关键发现：

1) 模型性能: 在本节中，我们根据原始论文中报告的结果，展示了近期遥感基础模型的性能指标。**此处提到的所有性能数据均直接来源于原始研究，以确保评估这些模型时的准确性和一致性**。这些指标提供了模型在语义分割、目标检测和变化检测等任务中的有效性洞察，突出了它们在不同实验设置下的优势与局限性。

- **图像级**基础模型在 BigEarthNet 数据集 [85] 上的分类任务性能表现存在差异，如表 IV 所示。总体而言，msGFM [33] 的准确率最高，达到 92.90%（mAP），紧随其后的是 SkySense [32]，其性能为 92.09%。其他表现突出的模型包括 DeCUR [102]，其 mAP 为 89.70%，以及 DINO-MC [111]，其 mAP 为 88.75%。SeCo [66] 也表现出较强性能，mAP 为 87.81%，而 DINO-MM [105] 的 mAP 为 87.10%。另一方面，CACo [67] 和 FoMo-Bench [8] 的 mAP 分别为 74.98% 和 F1-Score 为 68.33%，显示出一定的竞争力，但仍存在提升空间。

msGFM [33] 和 SkySense [32] 的高 mAP 得分突显了它们在分类任务中的高效性，使其适用于对准确率要求较高的应用场景。其他基础模型，如 DINO-MM [105] 和 DeCUR [102]，也表现出强劲性能，并具备进一步最优化的潜力。性能指标的多样性凸显了基础模型在处理 BigEarthNet [85] 等数据集中的复杂分类任务时，不断演进的能力与特化趋势。

遥感模型中的分类进展源于复杂的预训练技术，这些技术能够捕捉大规模数据集中的空间与光谱复杂性。例如，SkySense 通过在包含 2150 万条光学和 SAR 序列的多样化数据集上实施多粒度对比学习，相较于近期模型平均提升了 2.76% [32]。该方法使 SkySense 能够学习跨模态的细微空间与时间关系，从而在不同环境条件下增强泛化能力。这种多粒度表示在遥感中至关重要，因为场景分类往往依赖于细微的光谱差异，而简单模型可能忽略这些细节。同样，HyperSIGMA [95] 在庞大的 HyperGlobal-450K 高光谱数据集 [95] 上进行预训练，利用其稀疏采样注意力机制优化高维高光谱数据中的光谱-空间特征提取。通过选择性地关注关键光谱波段并减少冗余，HyperSIGMA 在高光谱场景中实现了高分类准确率，相较以往难以应对高光谱数据复杂性的模型有显著提升。

这些模型突显了设计能够捕捉多模态特征并有效利用数据集多样性的预训练策略的重要性，因为这些要素直接影响遥感应用中分类的

鲁棒性和准确率。

- **像素级**在分割任务中，我们对比了 12 个已在 ISPRS Potsdam 数据集上测试的基础模型。如表V所示，SkySense [32] 在所有 12 个模型中表现最佳，其 mF1 得分达到 93.99%。CMID [70] 在各项指标中表现出最高的 mIoU（87.04%），展现了其在准确分割数据集中不同区域方面的卓越能力。在总体准确率方面，BFM [11] 的 OA 得分最高，达到 91.82%。Cross-Scale MAE [88]、UPetu [24] 和 RSP [96] 的 mIoU 得分分别为 76.17%、83.17% 和 65.30%，显示出具有竞争力的分割能力。GeoKR [56] 的 mIoU 为 70.48%，表明其具备稳健的分割性能，但相较于 CMID [70] 仍有提升空间。TOV 的 mIoU 最低，仅为 60.34%，表明其在细粒度分割任务上可能面临挑战，与其他模型相比表现较弱。

  在应用于 ISPRS Potsdam 数据集的模型性能指标中，其在分割任务中的有效性表现出显著差异。SkySense [32] 在 mF1 得分上表现最佳，而 CMID [70] 在 mIoU 上表现最优，此外，SMLFR [22]、RingMo [87] 和 RingMo-lite [109] 展现出较强的总体准确率。这些洞察有助于指导特定遥感应用中模型的选择与最优化，确保针对具体任务实现最佳性能。

  在变化检测任务中，我们对比了基础模型在 OSCD 和 LEVIR-CD 数据集上的表现。模型的评估基于 F1 得分，该得分提供了准确率和召回率之间的平衡度量。如表所示，不同模型在不同数据集上的表现存在显著差异。

  SkySense [32] 在 OSCD 数据集上取得了最高的 F1 得分 60.06%，展现出其在准确检测变化方面的优越能力。GFM [69] 紧随其后，F1 得分为 59.82%，表明其在变化检测任务中表现强劲。SpectralGPT [40] 的 F1 得分也达到了 54.29%。其他表现突出的模型包括 DINO-MC [111]，F1 得分为 52.71%，以及 CACo [67]，F1 得分为 52.11%。SeCo [66] 的 F1 得分最低，为 46.94%，表明其可能需要进一步的最优化以提升其变化检测能力。

  相比之下，LEVIR-CD 数据集显示各模型具有更高的性能指标。MTP [99] 在该数据集上取得了最高的 F1 得分 92.67%，SkySense [32] 紧随其后，F1 得分为 92.58%，展现出其出色的鲁棒性。尽管 SWiMDiff 的 F1 得分（80.90%）低于其他模型，但在 LEVIR-CD [12] 数据集上仍表现出有效的性能。

- **区域级**在表 VI 中，基于平均精度（mAP）和 50% 的平均精度（AP50），评估了基础模型在 DOTA、DIOR 和 DIOR-R 数据集上的目标检测性能。

  在 DOTA 数据集上，RVSA [100] 在准确检测目标方面取得了最高的 mAP 值 81.24%，其次是 SMLFR [22] 和 RSP [96]，其 mAP 分别为 79.33% 和 77.72%。CMID [70]、GeRSP [42] 和 BFM [11] 也表现出中等性能，其 mAP 分别为 72.12%、67.40% 和 58.69%。在 DIOR 和 DIOR-R 数据集上，MTP [99] 和 SkySense [32] 表现最佳，其 AP50 分别为 78%，mAP 分别为 78.73%，展现出优越的目标检测能力。这些见解可指导模型的选择与最优化，以确保在特定遥感应用中实现最佳性能。

- **预训练方法的影响**。各种预训练方法对基础模型在遥感中的性能具有显著影响。使用自监督学习（SSL）技术进行预训练的模型，例如对比学习（CL）和掩码自编码器（MAE），其性能始终优于传统监督学习预训练的模型。例如，采用多粒度对比学习方法的 SkySense，在场景分类和目标检测任务中比其他模型性能高出约 3.6% [32]。同样，基于季节性对比学习的 Seco 在土地覆盖分类任务中表现更优，其指标较 ImageNet 预训练模型最高提升 7% [66]。在处理多时相和多光谱数据方面，采用掩码自编码技术的模型如 SatMAE [16] 和 Scale-MAE [78]，在变化检测任务中均取得改进，其中 SatMAE 在土地覆盖分类任务中性能提升高达 14% [16]，Scale-MAE 则在不同分辨率下的分割任务中实现了 1.7% 的 mIoU

Dataset	Model	Performance (%)	Metrics
BigEarthNet [85]	SeCo [66]	87.81	mAP
	CMC-RSSR [84]	82.90	mAP
	DINO-MM [105]	87.10	mAP
	CACo [67]	74.98	mAP
	GFM [69]	86.30	mAP
	DINO-MC [111]	88.75	mAP
	CROMA [28]	86.46	mAP
	DeCUR [102]	89.70	mAP
	CtxMIM [123]	86.88	mAP
	FG-MAE [108]	78.00	mAP
	USat [44]	85.82	mAP
	FoMo-Bench [8]	69.33	F1 Score
	SwiMDiff [91]	81.10	mAP
	SpectralGPT [40]	88.22	mAP
	SatMAE++ [73]	85.11	mAP
	msGFM [33]	**92.90**	mAP
	SkySense [32]	92.09	mAP
	MMEarth [72]	78.6	mAP
	Shallow CNN* [85]	**70.98**	**F1-Score**

表 IV: This table provides an overview of the performance metrics for various models applied to the BigEarthNet dataset [85] for **image-level** tasks. The performance is measured using mAP (Mean Average Precision) and F1 Score. *Performance for the shallow CNN model are sourced from the original BigEarthNet [85] paper.

Dataset	Model	Performance (%)	Metrics
ISPRS Potsdam	GeoKR [56]	70.48	mIoU
	RSP [96]	65.30	mIoU
	RingMo [87]	91.74	OA
	RVSA [100]	91.22	OA
	TOV [89]	60.34	mIoU
	CMID [70]	**87.04**	mIoU
	RingMo-lite [109]	90.96	OA
	Cross-Scale MAE [88]	76.17	mIoU
	SMLFR [22]	**91.82**	OA
	SkySense [32]	**93.99**	mF1
	UPetu [24]	83.17	mIoU
	BFM [11]	92.58	OA
	R-SegNet* [127]	**91.37**	**OA**

表 V: This table provides an overview of the performance metrics for various models applied to the ISPRS Potsdam [43] dataset for **pixel-level** tasks. The performance is measured using Mean Intersection over Union (mIoU) and Overall Accuracy (OA). *Non-FM

提升 [78]。这些发现凸显了创新性预训练方法在最大化基础模型效能中的关键作用，表明持续探索与优化这些技术对于推动遥感能力发展至关重要。

像 SatMAE、RingMo、A2-MAE 和 ORBIT 这样的基础模型各自表现出色，但在实际应用中必须考虑必要的权衡，特别是针对特定应用场景的约束条件 [16], [87], [101], [122]。SatMAE 基于 Transformer 架构，能够有效利用时间序列和多光谱嵌入，捕捉卫星图像中的复杂时空模式。然而，这种优势伴随着显著的计算需求，可能在资源受限环境下的实时监控应用中不可行。

相比之下，RingMo 提供了一种更轻量级的视觉 Transformer 架构，能够在性能和计算需求之间取得平衡，从而实现高效的模型推理。这使得 RingMo 特别适用于灾难响应监测等需要快速推理的任务，其中实时处理至关重要。[87] A2-MAE 引入了一种锚点感知的掩码策略，优化了时空谱表示，并允许有效整合多源数据。这种设计增强了其对不同数据分辨率和模态的适应性，但模型复杂的编码技术增加了计算负担，表明其更适合对精度要求高于效率的应用场景。[122]

最后，ORBIT 是一个设计有 1130 亿参数的模型，具有出色的可扩展性，能够在地球系统预测任务中实现高通量性能。尽管它在大规模预测任务中表现出色，但该模型显著的资源需求限制了其仅能在特定的高性能计算环境中部署。[101] 这些权衡突显了选择与特定操作目标相匹配的模型的重要性，无论是为了最大化准确率还是最小化计算开销。

此外，最近对比自监督学习（SSL）方法的研究突显了生成式方法（如掩码自编码器（MAE））相较于对比方法在时间序列数据上的显著优势，尤其是在标注数据有限的情况下 [61]。与强调区分相似和不相似样本对的对比方法不同，生成式方法（如 MAE）通过从掩码片段

Dataset	Model	Performance (%)	Metrics
DOTA	RSP [96]	77.72	mAP
	RVSA [100]	**81.24**	mAP
	TOV [89]	26.10	mAP50
	CMID [70]	72.12	mAP
	GeRSP [42]	67.40	mAP
	SMLFR [22]	79.33	mAP
	BFM [11]	58.69	mAP
	YOLOv2-D* [21]	**60.51**	**AP**
DIOR	RingMo [87]	75.80	mAP
	CSPT [124]	69.80	mAP
	RingMo-lite [109]	73.40	mAP
	GeRSP [42]	72.20	mAP
	MTP [99]	**78.00**	AP50
	Faster R-CNN* [55]	**74.05**	**mAP**
DIOR-R	RVSA [100]	71.05	mAP
	SMLFR [22]	72.33	mAP
	SkySense [32]	**78.73**	mAP
	MTP [99]	74.54	mAP
	BFM [11]	73.62	mAP
	AOPG* [14]	**64.41**	**mAP**

表 VI: This table provides an overview of the performance metrics for various models applied to the DOTA [20], [21], [113] dataset, DIOR [55] and DIOR-R [14] dataset for **region-level** task. The performance is mainly measured using Mean Average Precision (mAP). *Model performance are aquired from original dataset papers. AOPG is Anchor-free Oriented Proposal Generator.

Dataset	Model	F1 Score
OSCD [10]	SeCo [66]	46.94
	MATTER [2]	49.48
	CACo [67]	52.11
	GFM [69]	59.82
	SWiMDiff [91]	49.60
	SpectralGPT [40]	54.29
	SkySense [32]	**60.06**
	DINO-MC [111]	52.71
	HyperSIGMA [95]	59.28
	MTP [99]	53.36
	CNNs* [10]	**89.66 (OA)**
LEVIR-CD [12]	RSP [96]	90.93
	RingMo [87]	91.86
	RIngMo-lite [109]	91.56
	SwiMDiff [91]	80.90
	SkySense [32]	92.58
	UPetu [24]	88.50
	STANet* [12]	**85.4**

表 VII: This table provides an overview of the F1 Score for various models applied to the Onera Satellite Change Detection (OSCD) dataset [10] and the LEVIR-CD dataset [12] for **spacial-temporal** downstream tasks. *Performance for the models are sourced from the original dataset papers. STANet is Spatial-Temporal Attention Network.

中重构数据，能够捕捉数据中的复杂潜在结构和关系。这种基于重构的学习方式在遥感的时间序列和多光谱应用中尤为有利，因为这些场景中时间和光谱依赖性至关重要。因此，在标注稀疏的条件下，基于 MAE 的模型可以实现更强的数据表示，使其成为需要精细时间分析的遥感任务中的强大工具。

2) 实际意义: 基础模型通过建立在多光谱和时序数据分析等成熟应用之上，在遥感领域展现出变革性能力。尽管这些应用传统上依赖机器学习和深度学习，但基础模型减少了对标注数据的需求，并能够快速适应新任务，为此前受限于数据约束和任务特定架构的领域提供了稳健的解决方案。因此，基础模型的进展在多个领域具有重要的实际意义：

- **环境监测.** 如 GASSL [6] 和 SatMAE [16] 等模型能够对环境变化提供详细的评估，有助于保护工作和政策制定。这些模型在监测森林砍伐、荒漠化和污染水平方面表现优异，为环境管理提供了可操作的洞察。通过整合多光谱和时间序列数据，这些模型能够追踪随时间的变化，实现对环境退化的早期检测，并制定及时的干预措施。这一能力对于自然资源的可持续管理以及减轻气候变化的影响尤为重要。
- **农业与林业**。基础模型如 EarthPT [82] 和 GeCo [57] 为作物健康、产量预测和土地利用管理提供了有价值的见解，优化了农业实践和资源分配。例如，RSP [96] 利用多光谱数

据，通过精确监测作物状况和预测产量，提升了精准农业的水平。这些模型能够检测作物早期应激、病害和虫害侵袭的迹象，使农民能够采取主动措施。此外，它们还通过提供森林覆盖的详细地图、生物量估算以及毁林活动的监测，助力林业管理，从而支持保护工作和可持续林业实践。

- **考古学**。基础模型在考古学中的应用彻底改变了考古特征和遗址的发现、测绘与分析方式。例如 GeoKR [56]、RingMo [87] 等模型能够处理高分辨率卫星图像和多光谱数据，从而增强对肉眼难以辨别的考古特征的检测与制图能力。而 MATTE [2] 等模型则可完成纹理与材质分析，帮助识别不同地表类型。这些模型使大范围调查成为可能，使考古学家能够高效地在广阔区域内识别潜在的兴趣点。尽管全面探索仍需实地考察、发掘或其他陆地调查手段，但这些技术显著提升了初始识别与制图的效率。此外，这些模型还能追踪随时间的变化，帮助考古学家监测环境与人类活动的影响，为保护与修复提供关键信息。这不仅提高了调查的效率与准确率，还为发现未知遗址开辟了新途径。
- **城市规划与发展**。遥感模型如 CMID [70] 和 SkySense [32] 在监测城市扩张、基础设施建设和土地利用变化方面起着关键作用。这些模型通过提供高分辨率的数据分析和趋势预测，促进了可持续的城市增长和发展规划。它们使城市规划者能够评估城市化对自然栖息地的影响，优化土地利用，并更有效地规划基础设施项目。
- **灾害管理**。如 OFA-Net [118]、DOFA [117] 和 Prithvi [46] 等模型在洪水制图和火灾探测中发挥着重要作用。这些模型提供关键的实时数据，有助于快速识别受灾区域，从而实现及时有效的应对措施。这一能力支持应急响应人员优先分配资源并实施疏散计划，进而减轻自然灾害的影响。此外，这些模型在灾后恢复过程中也起到辅助作用，能够评估损毁情况并持续监测恢复进程。通过整合多种数据源，它们提升了决策的科学性，增强了响应行动的协调性，并为未来的灾害减缓策略规划提供了支持。

这些模型在准确率上的提升对实际遥感应用具有深远意义。例如，在森林砍伐监测中，GFM 等模型在语义分割中实现了高像素级准确率，相较于基准模型最高提升了 4.5%，从而提高了森林覆盖变化制图的精确度，有力支持了保护工作 [101]。同样，HyperSIGMA 在高光谱植被监测中实现了惊人的 6.2% 准确率提升，为评估森林健康状况和生物多样性提供了宝贵数据 [95]。

在城市规划中，像 UPetu 这样的模型通过整合光学和雷达影像等多模态数据，在基础设施制图方面表现出色，相比单模态模型准确率提升超过 5%，使城市规划者能够做出更明智的土地利用决策 [24]。此外，RingMo 相较于传统监督模型，将目标检测准确率提升了 3.7%，有效识别出对灾害管理和城市基础设施评估至关重要的稠密城市特征 [87]。

最后，ORBIT 展现出卓越的可扩展性，能够以高达 85% 的缩放效率处理大型气候数据集，支持长期环境监测应用，如气候变化预测和季节性预报。这种可扩展性不仅推动了传统遥感工作流的发展，还使得以往采用常规方法难以实现的复杂多时相分析与预测建模成为可能 [101]。

尽管遥感技术长期以来受益于多光谱和时间序列数据，但基础模型的适应性、可扩展性和高效性在这些应用中实现了更高水平的准确率和可及性。这一进展为应对跨领域（从环境保护到城市规划）日益复杂且不断演变的挑战创造了机遇，而传统模型在大规模应用中一直难以解决这些问题。

B. 未来方向

未来的研究应优先关注几个关键领域：

- **高效模型开发：**探索模型蒸馏、剪枝和量化等技术以在不牺牲性能的前提下降低计算需求至关重要。此外，开发能够高效处理超高分辨率图像的可扩展架构也十分关键。例如，将

剪枝技术应用于 SatMAE [16] 等模型，可以在保持性能的同时降低计算负载。低秩适应（LoRA）[41] 等模型适配技术已作为在小计算开销下微调大规模模型的有效方法脱颖而出。通过将权重更新分解为低秩矩阵，LoRA [41] 能够在无需修改全部模型参数的情况下实现高效适配，使其适用于资源受限环境或需要频繁重新训练的场景。融入如 LoRA [41] 等方法可进一步提升基础模型在多样化任务和领域中的适用性。

- **多模态数据融合：** 提升多模态数据（例如光学与雷达影像的结合）的集成与处理方法，将提供更全面的洞察。有必要开展针对能够利用多模态数据的先进自监督学习（SSL）技术的研究。OFA-Net [118] 框架通过整合多模态数据，为未来模型提供了值得借鉴和改进的有前景方向。
- **跨学科协作：** 促进遥感专家、人工智能研究人员与领域专家之间的合作，可以应对复杂挑战并推动创新。例如，人工智能研究人员与环境科学家之间的合作可以优化如 GASSL [6] 这类模型，以提升环境监测和保护工作的效果。

展望未来，自监督学习方法在基础模型中持续取得的成功，标志着未来研究的一个令人振奋的前沿。这些模型能够从未标记数据中学习，并通过极少的微调即可适应多种遥感任务，这表明无监督学习技术的进步有望大幅减少对大规模标注数据集的依赖，而这类数据集在许多遥感应用中仍是主要瓶颈。然而，随着这些模型规模和复杂性的增加，如何在计算需求与效率之间取得平衡将变得越来越关键。未来的研究可能聚焦于开发更节省资源的基础模型版本，同时保持高性能，尤其适用于实时监测系统或计算资源有限的环境。

C. 局限性

本次调查存在若干局限性：

- **范围与覆盖**. 本综述聚焦于 2021 年 6 月至 2024 年 6 月间发布的基础模型。尽管本综述的范围广泛，涵盖了众多重要进展，但并非全面详尽。由于发布时机或撰写时缺乏足够的评估指标，部分近期的进展与创新可能未被包含在内。因此，某些在该时期后期出现或尚未得到充分评估的前沿模型可能会被遗漏。这一局限性凸显了读者需超越本综述范围，主动获取最新研究成果和更新的重要性。此外，尽管基础模型已在特定下游应用上进行了实证测试，但其稳健的架构和通用训练范式（如卷积网络，例如残差网络，以及视觉变换器，例如 ViT）表明它们在更广泛的任务中也具备出色表现的潜力。当前文献中观察到的有限测试不应被视为其适用性的限制，而应理解为现有研究重点的体现。鉴于其设计特性，这些模型有望在多种遥感任务中实现有效泛化，甚至超出已明确测试的任务范围。未来工作应致力于探索并验证其在更多样化应用中的性能，以充分释放其潜力。
- **动态领域**。人工智能与遥感领域正在迅速发展，不断出现快速进展和突破。这种动态特性要求持续进行综述和更新，以确保综述的相关性和全面性。新技术、新方法和新模型不断涌现，可能对当前技术水平产生重大影响。因此，必须认识到本综述仅反映了某一时间点的状况，需要持续跟踪文献，以捕捉最新进展和新兴趋势。这种方法有助于保持对该领域的最新理解，并在新成果出现时及时纳入。

VIII. 结论

在本篇综合调查中，我们回顾了遥感领域基础模型的最新进展。我们根据其预训练方法、图像分析技术以及在不同领域的应用对这些模型进行了分类，重点突出了它们独特的研究方法和能力。

我们的分析涵盖了多种先进技术，包括自监督学习、视觉 Transformer 和残差神经网络。这些模型在区域级、像素级和图像级等不同图像感知层次上均显著提升了性能，并在环境监测、数字考古学、农业、城市规划及灾害管理等应用中表现出色。

尽管取得了显著进展，但仍存在一些挑战，例如需要更多样化和高质量的数据集、较高的计算

需求，以及在不同应用中的困难。解决这些挑战需要跨学科的进一步研究与合作。

综上所述，本调查详细概述了遥感领域基础模型的当前状态，提供了宝贵见解并指明了未来的研究方向。我们建议持续致力于开发高效模型架构、增强多模态数据融合以及扩展数据集多样性，以充分实现这些模型在遥感领域的潜力。

致谢

本工作得到了范德比尔特大学种子成功基金、范德比尔特大学发现基金以及 VISR 种子基金的支持。我们感谢英伟达公司通过英伟达硬件资助提供的支持。本工作还得到了美国国家科学基金会 NAIRR 试点奖项 NAIRR240055 的支持。本文由橡树岭国家实验室（ORNL）共同撰写，该实验室由 UT-Battelle, LLC 根据与美国能源部签订的合同号 DE-AC05-00OR22725 运营。本文中可能表达的任何主观观点或意见并不一定代表美国能源部或美国政府的观点。

附录
遥感常用预训练数据集

RSD46-WHU [62], [116] 数据集于 2017 年提出，数据来源于 Google Earth 和天地图。该数据集包含 117,000 张图像，图像块大小为 256 像素，空间分辨率在每像素 0.5 至 2 米之间。涵盖全球 46 个类别，主要用于场景分类。类似地，世界功能地图（fMoW）[15] 于 2018 年 4 月发布，包含来自 Digital Globe 的超过 100 万张图像。覆盖 207 个国家的 63 个类别，包含多光谱图像，用于场景分类和目标检测。

2019 年 5 月，提出了 DOTA [114] 数据集，以其大规模的航空影像目标检测能力而闻名。该数据集包含来自 Google Earth、GF-2 卫星和航空来源的 11,268 张不同分辨率的图像，覆盖全球 18 个类别。另一个重要数据集 SEN12MS [80] 于 2019 年 6 月发布，包含来自哨兵-1、哨兵-2 和 MODIS 地表覆盖的 541,986 张图像。其图像块大小为 256x256 像素，支持地表覆盖分类和变化检测任务。

BigEarthNet [85]，同样发布于 2019 年 6 月，包含 590,326 张图像，大小从 20×20 到 120×120 像素不等，数据来源于 Sentinel-2。该数据集覆盖欧洲的 43 个类别，用于场景分类和目标检测。SeCo [66] 数据集是另一项 2019 年 6 月发布的数据集，包含约 100 万张图像，分辨率为 2.65×2.65 公里，数据来自 Sentinel-2。该数据集旨在用于季节变化检测以及季节性土地覆盖分类。

MillionAID 数据集 [63], [64]，于 2021 年 3 月发布，包含来自 Google Earth 的超过一百万张不同大小的图像。覆盖全球 51 个类别，用于场景分类。Levir-KR 数据集于 2021 年 7 月发布，包含来自高分一号、高分二号和高分六号卫星的 1,431,950 张图像，支持变化检测和场景分类应用。

SoundingEarth [38]，于 2021 年 8 月推出，包含来自 Google Earth 的 50,545 张 1024 像素大小的图像，结合了 RGB 和音频数据，用于遥感。TOV-RS-Balanced 数据集 [90]，于 2022 年 4 月发布，包含 500,000 张 600 像素大小的图像，来自 Google Earth，覆盖全球 31 个类别，用于场景分类、目标检测和语义分割。

SeasoNet [53]，于 2022 年 7 月发布，包含来自哨兵-2 的 1,759,830 张图像，图像块大小为 20 至 120 像素，支持对德国区域的季节性场景分类、分割和检索。最后，2022 年 11 月发布的 SSL4EO-S12 数据集 [107] 包含超过 300 万张来自哨兵-1 和哨兵-2 的图像，图像块大小为 264x264 像素。由于该数据集不包含任何标签，因此常用于自监督学习。

近年来，额外的数据集进一步丰富了遥感研究可用的资源。2023 年 10 月发布的 SAMRS 数据集 [98]，提供了来自 HRSC2016 和 FAIR1M-2.0 等数据集的高分辨率图像集合，专为高级分割任务设计。该数据集包含超过 105,000 张图像，分辨率高达 1024x1024 像素，支持语义分割和实例分割以及目标检测，有助于推动遥感领域可扩展分割模型的发展。

聚焦于变化感知学习，CACo [67] 于 2023 年 6 月发布，提供了一个来自哨兵-2 的可变块大小

数据集。该数据集专为变化检测和对比学习优化，特别针对城市与乡村景观。通过优先考虑对比学习和自监督任务，CACo 有助于开发能够适应不同环境卫星影像变化的模型。

SatlasPretrain [7] 数据集于 2023 年 10 月推出，是一个大规模数据集，包含超过 856,000 张图像，融合了哨兵-2（Sentinel-2）和 NAIP 高分辨率影像源。该数据集提供多光谱和高分辨率影像，支持土地覆盖分类、分割和变化检测等应用，进一步推动了高分辨率卫星影像分析领域的研究进展。

SSL4EO-L [83] 数据集于 2023 年 10 月发布，是一个庞大的资源，包含来自 Landsat 的超过 500 万张图像，专为云检测和地表覆盖分类中的自监督学习设计。通过聚焦多年份的 Landsat 影像，SSL4EO-L 使得能够针对需要长期时间覆盖和抗云分类的应用进行稳健训练。

最后，2024 年 7 月推出的 MMEarth [72]，融合了 Sentinel-1、Sentinel-2 和 Aster DEM 的数据，为多模态应用提供了超过 120 万张图像。该数据集支持地表覆盖分类和语义分割，使研究人员能够利用多种传感器类型和气候数据，以提升地理空间表示学习的效果。

这些数据集具有不同的分辨率、类别和地理覆盖范围，为推进遥感研究与应用提供了丰富的资源。它们有助于开发出能够应对多种挑战的稳健模型，从而更好地通过遥感技术理解与解析地球表面。

参考文献

[1] Sheikh Kamran Abid, Noralfishah Sulaiman, Shiau Wei Chan, Umber Nazir, Muhammad Abid, Heesup Han, Antonio Ariza-Montes, and Alejandro Vega-Muñoz. Toward an integrated disaster management approach: How artificial intelligence can boost disaster management. *Sustainability*, 13(22), 2021. 4, 16

[2] Peri Akiva, Matthew Purri, and Matthew Leotta. Self-supervised material and texture representation learning for remote sensing tasks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 8203–8215, June 2022. 3, 9, 15, 19, 20

[3] Abdulaziz Amer Aleissaee, Amandeep Kumar, Rao Muhammad Anwer, Salman Khan, Hisham Cholakkal, Gui-Song Xia, and Fahad Shahbaz khan. Transformers in remote sensing: A survey, 2022. 5

[4] Arbeck. English: Mono, Multi and Hyperspectral Cube and corresponding Spectral Signatures, Mar. 2013. 4

[5] Argyro Argyrou and Athos Agapiou. A review of artificial intelligence and remote sensing for archaeological research. *Remote Sensing*, 14(23), 2022. 16

[6] Kumar Ayush, Burak Uzkent, Chenlin Meng, Kumar Tanmay, Marshall Burke, David Lobell, and Stefano Ermon. Geography-aware self-supervised learning. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 10181–10190, October 2021. 3, 9, 15, 19, 21

[7] Favyen Bastani, Piper Wolters, Ritwik Gupta, Joe Ferdinando, and Aniruddha Kembhavi. Satlaspretrain: A large-scale dataset for remote sensing image understanding, 2023. 3, 10, 15, 23, 24

[8] Nikolaos Ioannis Bountos, Arthur Ouaknine, and David Rolnick. Fomo-bench: a multi-modal, multi-scale and multi-task forest monitoring benchmark for remote sensing foundation models, 2024. 3, 11, 15, 16, 18

[9] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers, 2021. 6

[10] Rodrigo Caye Daudt, Bertrand Le Saux, Alexandre Boulch, and Yann Gousseau. Oscd - onera satellite change detection, 2019. 19

[11] Keumgang Cha, Junghoon Seo, and Taekyung Lee. A billion-scale foundation model for remote sensing images, 2024. 3, 12, 17, 18, 19

[12] Hao Chen and Zhenwei Shi. A spatial-temporal attention-based method and a new dataset for remote sensing image change detection. *Remote Sensing*, 12(10), 2020. 17, 19

[13] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations, 2020. 6, 10

[14] Gong Cheng, Jiabao Wang, Ke Li, Xingxing Xie, Chunbo Lang, Yanqing Yao, and Junwei Han. Anchor-free oriented proposal generator for object detection. *IEEE Transactions on Geoscience and Remote Sensing*, 60:1–11, 2022. 19

[15] Gordon Christie, Neil Fendley, James Wilson, and Ryan Mukherjee. Functional map of the world. In *CVPR*, 2018. 4, 9, 10, 11, 12, 22, 24

[16] Yezhen Cong, Samar Khanna, Chenlin Meng, Patrick Liu, Erik Rozi, Yutong He, Marshall Burke, David Lobell, and Stefano Ermon. Satmae: Pre-training transformers for temporal and multi-spectral satellite imagery. In S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, editors, *Advances in Neural Information Processing Systems*, volume 35, pages 197–211. Curran Associates, Inc., 2022. 3, 4, 5, 9, 15, 17, 18, 19, 20

[17] Russell G. Congalton. Remote sensing: An overview. *GIScience & Remote Sensing*, 47(4):443–459, 2010. 2, 4

[18] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image

Month, Year	Dataset	Title	Patch Size	Size	Resolution (m)	Sensor	Categories	Geographic Coverage	Image Type	Application
2017	RSD46-WHU [62], [116]	-	256 x 256	117,000	0.5 - 2	Google Earth, Tianditu	46	Global	RGB	Scene Classification
Apr, 2018	fMoW [15]	Functional Map of the World	-	1,047,691	-	Digital Globe	63	207 of 247 countries	Multispectral	Scene Classification, Object Detection
May, 2019	DOTA [114]	DOTA: A Large-scale Dataset for Object Detection in Aerial Images	800 × 800 to 20,000 × 20,000	11,268	Various	Google Earth, GF-2 Satellite, and aerial images	18	Global	RGB	Object Detection
Jun, 2019	SEN12MS [80]	SEN12MS – A Curated Dataset of Georeferenced Multi-Spectral Sentinel-1/2 Imagery for Deep Learning and Data Fusion	256 x 256	541,986	10	Sentinel-1, Sentinel-2, MODIS Land Cover	33	Globally distributed	SAR/Multispectral	Land Cover Classification, Change Detection
Jun, 2019	BigEarthNet [85]	BigEarthNet: A Large-Scale Benchmark Archive For Remote Sensing Image Understanding	20 x 20 to 120 x 120	590,326	Various	Sentinel-2	43	Europe	Multispectral	Scene Classification, Object Detection
Jun, 2019	SeCo [66]	Seasonal Contrast: Unsupervised Pre-Training from Uncurated Remote Sensing Data	264 x 264	~1M	10 - 60	Sentinel-2	-	Global	Multispectral	Seasonal Change Detection, Land Cover Classification over Seasons
Mar, 2021	MillionAID [63], [64]	Million-AID	110 - 31,672	1,000,848	Various	Google Earth	51	Global	RGB	Scene Classification
Jul, 2021	Levir-KR [56]	Geographical Knowledge-driven Representation Learning for Remote Sensing Images	-	1,431,950	Various	Gaofen1, Gaofen-2, Gaofen-6	8	Global	Multispectral	Change Detection, Scene Classification
Apr, 2022	TOV-RS-Balanced [90]	TOV: The Original Vision Model for Optical Remote Sensing Image Understanding via Self-supervised Learning	600 x 600	500,000	1 - 20	Google Earth	31	Global	RGB	Scene Classification, Object Detection, Semantic Segmentation
Jul, 2022	SeasoNet [53]	SeasoNet: A Seasonal Scene Classification, Segmentation and Retrieval dataset for satellite Imagery over Germany	up to 120 x 120	1,759,830	10 - 60	Sentinel-2	33	Germany	Multispectral	Scene Classification, Scene Segmentation
Nov, 2022	SSL4EO-S12 [107]	SSL4EO-S12: A Large-Scale Multi-Modal, Multi-Temporal Dataset for Self-Supervised Learning in Earth Observation	264 x 264	3,012,948	10 - 60	Sentinel-1, Sentinel-2	-	Global	SAR/Multispectral	Self-Supervised Learning
Oct, 2023	SAMRS [98]	SAMRS: Scaling-up Remote Sensing Segmentation Dataset with Segment Anything Model	600 x 600 to 1024 x 1024	105,090	Various	HRSC2016, DOTA-V2.0, DIOR, FAIR1M-2.0	37	Global	High-resolution	Semantic Segmentation, Instance Segmentation, Object Detection
Jun, 2023	CACo [67]	Change-Aware Sampling and Contrastive Learning for Satellite Images	Variable	-	10	Sentinel-2	-	Urban and Rural Areas	Multispectral	Semantic Segmentation, Change Detection, Self-Supervised Learning
Oct, 2023	SatlasPretrain [7]	SatlasPretrain: A Large-Scale Dataset for Remote Sensing Image Understanding	512 x 512	856,000	1 - 10 (Sentinel-2), 0.5 - 2 (NAIP)	Sentinel-1, Sentinel-2, Landset, and NAIP	137	Global	Multispectral, High-resolution	Land Cover Classification, Segmentation, Change Detection
Oct, 2023	SSL4EO-L [83]	SSL4EO-L: Datasets and Foundation Models for Landsat Imagery	264 x 264	5,000,000	30	Landsat 4–5 TM, Landsat 7 ETM+, Landsat 8–9 OLI/TIRS	-	Global	Multispectral	Cloud Detection, Land Cover Classification, Semantic Segmentation
Jul, 2024	MMEarth [72]	MMEarth: Exploring Multi-Modal Pretext Tasks For Geospatial Representation Learning	128 x 128	1,200,000	10	Sentinel-2, Sentinel-1, Aster DEM	46	Global	Multispectral, SAR, Climate	Land Cover Classification, Semantic Segmentation

表 VIII: 该表格总结了遥感领域常用的一组预训练数据集，包括数据集名称、传感器类型、地理覆盖范围及相关应用。

database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255, 2009. 7, 9, 10, 11

[19] Philipe Dias, Abhishek Potnis, Sreelekha Guggilam, Lexie Yang, Aristeidis Tsaris, Henry Medeiros, and Dalton Lunga. An agenda for multimodal foundation models for earth observation. In *IGARSS 2023 - 2023 IEEE International Geoscience and Remote Sensing Symposium*, pages 1237–1240, 2023. 4

[20] Jian Ding, Nan Xue, Yang Long, Gui-Song Xia, and Qikai Lu. Learning roi transformer for detecting oriented objects in aerial images. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2019. 19

[21] Jian Ding, Nan Xue, Gui-Song Xia, Xiang Bai, Wen Yang, Michael Yang, Serge Belongie, Jiebo Luo, Mihai Datcu, Marcello Pelillo, and Liangpei Zhang. Object detection in aerial images: A large-scale benchmark and challenges. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pages 1–1, 2021. 19

[22] Zhe Dong, Yanfeng Gu, and Tianzhu Liu. Generative convnet foundation model with sparse modeling and low-frequency reconstruction for remote sensing image interpretation. *IEEE Transactions on Geoscience and Remote Sensing*, 62:1–16, 2024. 3, 11, 15, 17, 18, 19

[23] Zhe Dong, Yanfeng Gu, and Tianzhu Liu. Generative convnet foundation model with sparse modeling and low-frequency reconstruction for remote sensing image interpretation. *IEEE Transactions on Geoscience and Remote Sensing*, 62:1–16, 2024. 11

[24] Zhe Dong, Yanfeng Gu, and Tianzhu Liu. Upetu: A unified parameter-efficient fine-tuning framework for remote sensing foundation model. *IEEE Transactions on Geoscience and Remote Sensing*, 62:1–13, 2024. 3, 11, 15, 17, 18, 19, 20

[25] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale, 2021. 2, 4

[26] Iris Dumeur, Silvia Valero, and Jordi Inglada. Self-supervised spatio-temporal representation learning of satellite image time series. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 17:4350–4367, 2024. 3, 11, 15

[27] Yingchao Feng, Peijin Wang, Wenhui Diao, Qibin He, Huiyang Hu, Hanbo Bi, Xian Sun, and Kun Fu. A self-supervised cross-modal remote sensing foundation model with multi-domain representation and cross-domain fusion. In *IGARSS 2023 - 2023 IEEE International Geoscience and Remote Sensing Symposium*, pages 2239–2242, 2023. 3, 10, 15

[28] Anthony Fuller, Koreen Millard, and James R. Green. Croma: Remote sensing representations with contrastive radar-optical masked autoencoders, 2023. 3, 10, 15, 18

[29] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre H. Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Daniel Guo, Mohammad Gheshlaghi Azar, Bilal Piot, Koray Kavukcuoglu, Rémi Munos, and Michal Valko. Bootstrap your own latent: A new approach to self-supervised learning, 2020. 6

[30] Shengxi Gui, Shuang Song, Rongjun Qin, and Yang Tang. Remote sensing object detection in the deep learning era—a review. *Remote Sensing*, 16(2), 2024. 2, 4

[31] Shengxi Gui, Shuang Song, Rongjun Qin, and Yang Tang. Remote sensing object detection in the deep learning era—a review. *Remote Sensing*, 16(2), 2024. 13

[32] Xin Guo, Jiangwei Lao, Bo Dang, Yingying Zhang, Lei Yu, Lixiang Ru, Liheng Zhong, Ziyuan Huang, Kang Wu, Dingxiang Hu, Huimei He, Jian Wang, Jingdong Chen, Ming Yang, Yongjun Zhang, and Yansheng Li. Skysense: A multimodal remote sensing foundation model towards universal interpretation for earth observation imagery, 2024. 3, 11, 15, 16, 17, 18, 19, 20

[33] Boran Han, Shuai Zhang, Xingjian Shi, and Markus Reichstein. Bridging remote sensors with multisensor geospatial foundation models, 2024. 3, 11, 15, 16, 18

[34] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners, 2021. 6

[35] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning, 2020. 6, 10

[36] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition, 2015. 2, 7, 13

[37] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition, 2015. 4, 13

[38] Konrad Heidler, Lichao Mou, Di Hu, Pu Jin, Guangyao Li, Chuang Gan, Ji-Rong Wen, and Xiao Xiang Zhu. Self-supervised audiovisual representation learning for remote sensing data, 2021. 22

[39] Yassine Himeur, Bhagawat Rimal, Abhishek Tiwary, and Abbes Amira. Using artificial intelligence and data fusion for environmental monitoring: A review and future perspectives. *Information Fusion*, 86-87:44–75, 2022. 2, 14

[40] Danfeng Hong, Bing Zhang, Xuyang Li, Yuxuan Li, Chenyu Li, Jing Yao, Naoto Yokoya, Hao Li, Pedram Ghamisi, Xiuping Jia, Antonio Plaza, Paolo Gamba, Jon Atli Benediktsson, and Jocelyn Chanussot. Spectralgpt: Spectral remote sensing foundation model. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, page 1–18, 2024. 3, 11, 15, 17, 18, 19

[41] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models, 2021. 21

[42] Ziyue Huang, Mingming Zhang, Yuan Gong, Qingjie Liu, and Yunhong Wang. Generic knowledge boosted pre-training for remote sensing images, 2024. 3, 11, 15, 17, 19

[43] International Society for Photogrammetry and Remote Sensing (ISPRS). 2d semantic labeling contest –potsdam, 2024. Accessed: 2024-07-08. 18

[44] Jeremy Irvin, Lucas Tao, Joanne Zhou, Yuntao Ma, Langston Nashold, Benjamin Liu, and Andrew Y. Ng. Usat: A unified self-supervised encoder for multi-sensor satellite imagery, 2023. 3, 10, 15, 18

[45] Pallavi Jain, Bianca Schoen-Phelan, and Robert Ross. Self-supervised learning for invariant representations from multi-spectral and sar images. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 15:7797–7808, 2022. 3, 9, 15

[46] Johannes Jakubik, Sujit Roy, C. E. Phillips, Paolo Fraccaro, Denys Godwin, Bianca Zadrozny, Daniela Szwarcman, Carlos Gomes, Gabby Nyirjesy, Blair Edwards, Daiki Kimura, Naomi Simumba, Linsong Chu, S. Karthik Mukkavilli, Devyani Lambhate, Kamal Das, Ranjini Bangalore, Dario Oliveira, Michal Muszynski, Kumar Ankur, Muthukumaran Ramasubramanian, Iksha Gurung, Sam Khallaghi, Hanxi, Li, Michael Cecil, Maryam Ahmadi, Fatemeh Kordi, Hamed Alemohammad, Manil Maskey, Raghu Ganti, Kommy Weldemariam, and Rahul Ramachandran. Foundation models for generalist geospatial artificial intelligence, 2023. 3, 10, 20

[47] Neal Jean, Sherrie Wang, Anshul Samar, George Azzari, David Lobell, and Stefano Ermon. Tile2vec: Unsupervised representation learning for spatially distributed data, 2018. 1

[48] Avinash Kumar Jha, Awishkar Ghimire, Surendrabikram Thapa, Aryan Mani Jha, and Ritu Raj. A review of ai for urban planning: Towards building sustainable smart cities. In *2021 6th International Conference on Inventive Computation Technologies (ICICT)*, pages 937–944, 2021. 2, 16

[49] Wentao Jiang, Jing Zhang, Di Wang, Qiming Zhang, Zengmao Wang, and Bo Du. Lemevit: Efficient vision transformer with learnable meta tokens for remote sensing image interpretation, 2024. 3, 12, 15

[50] Licheng Jiao, Zhongjian Huang, Xiaoqiang Lu, Xu Liu, Yuting Yang, Jiaxuan Zhao, Jinyue Zhang, Biao Hou, Shuyuan Yang, Fang Liu, Wenping Ma, Lingling Li, Xiangrong Zhang, Puhua Chen, Zhixi Feng, Xu Tang, Yuwei Guo, Dou Quan, Shuang Wang, Weibin Li, Jing Bai, Yangyang Li, Ronghua Shang, and Jie Feng. Brain-inspired remote sensing foundation models and open problems: A comprehensive survey. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 16:10084–10120, 2023. 4

[51] Longlong Jing and Yingli Tian. Self-supervised visual feature learning with deep neural networks: A survey, 2019. 4, 7

[52] Andreas Kamilaris and Francesc X. Prenafeta-Boldú. Deep learning in agriculture: A survey. *Computers and Electronics in Agriculture*, 147:70–90, 2018. 14

[53] Dominik Koßmann, Viktor Brack, and Thorsten Wilhelm. Seasonet: A seasonal scene classification, segmentation and retrieval dataset for satellite imagery over germany, 2022. 22, 24

[54] Weijie L, Wei Yang, Yuenan Hou, Li Liu, Yongxiang Liu, and Xiang Li. Saratr-x: A foundation model for synthetic aperture radar images target recognition, 2024. 3, 12

[55] Ke Li, Gang Wan, Gong Cheng, Liqiu Meng, and Junwei Han. Object detection in optical remote sensing images: A survey and a new benchmark. *ISPRS Journal of Photogrammetry and Remote Sensing*, 159:296–307, Jan. 2020. 7, 19

[56] Wenyuan Li, Keyan Chen, Hao Chen, and Zhenwei Shi. Geographical knowledge-driven representation learning for remote sensing images. *IEEE Transactions on Geoscience and Remote Sensing*, 60:1–16, 2022. 3, 9, 15, 17, 18, 20, 24

[57] Wenyuan Li, Keyan Chen, and Zhenwei Shi. Geographical supervision correction for remote sensing representation learning. *IEEE Transactions on Geoscience and Remote Sensing*, 60:1–20, 2022. 3, 9, 15, 19

[58] Weijie Li, Yang Wei, Tianpeng Liu, Yuenan Hou, Yuxuan Li, Zhen Liu, Yongxiang Liu, and Li Liu. Predicting gradient is better: Exploring self-supervised learning for sar atr with a joint-embedding predictive architecture, 2024. 3, 11, 15

[59] Xuyang Li, Danfeng Hong, and Jocelyn Chanussot. S2mae: A spatial-spectral pretraining foundation model for spectral remote sensing data. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 24088–24097, June 2024. 3, 12, 15

[60] Xiang Li, Congcong Wen, Yuan Hu, Zhenghang Yuan, and Xiao Xiang Zhu. Vision-language models in remote sensing: Current progress and future trends. *IEEE Geoscience and Remote Sensing Magazine*, 12(2):32–66, 2024. 5

[61] Ziyu Liu, Azadeh Alavi, Minyi Li, and Xiang Zhang. Self-supervised learning for time series: Contrastive or generative?, 2024. 18

[62] Yang Long, Yiping Gong, Zhifeng Xiao, and Qing Liu. Accurate object localization in remote sensing images based on convolutional neural networks. *IEEE Transactions on Geoscience and Remote Sensing*, PP:1–13, 01 2017. 14, 22, 24

[63] Yang Long, Gui-Song Xia, Shengyang Li, Wen Yang, Michael Ying Yang, Xiao Xiang Zhu, Liangpei Zhang, and Deren Li. On creating benchmark dataset for aerial image interpretation: Reviews, guidances and million-aid. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 14:4205–4230, 2021. 9, 10, 11, 12, 14, 22, 24

[64] Yang Long, Gui-Song Xia, Liangpei Zhang, Gong Cheng, and Deren Li. Aerial scene parsing: From tile-level scene classification to pixel-wise semantic labeling, 2022. 7, 9, 10, 11, 12, 14, 22, 24

[65] Yuchi Ma, Shuo Chen, Stefano Ermon, and David B. Lobell. Transfer learning in environmental remote sensing. *Remote Sensing of Environment*, 301:113924, 2024. 4

[66] Oscar Mañas, Alexandre Lacoste, Xavier Giró-i Nieto, David Vazquez, and Pau Rodríguez. Seasonal contrast: Unsupervised pre-training from uncurated remote sensing data. In

Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pages 9414–9423, October 2021. 3, 9, 11, 15, 16, 17, 18, 19, 22, 24

[67] Utkarsh Mall, Bharath Hariharan, and Kavita Bala. Change-aware sampling and contrastive learning for satellite images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5261–5270, June 2023. 3, 10, 15, 16, 17, 18, 19, 22, 24

[68] Lorenzo Mantovan and Loris Nanni. The computerization of archaeology: Survey on artificial intelligence techniques. *SN Computer Science*, 1(5), Aug. 2020. 16

[69] Matias Mendieta, Boran Han, Xingjian Shi, Yi Zhu, and Chen Chen. Towards geospatial foundation models via continual pretraining, 2023. 3, 10, 11, 15, 17, 18, 19

[70] Dilxat Muhtar, Xueliang Zhang, Pengfeng Xiao, Zhenshi Li, and Feng Gu. Cmid: A unified self-supervised learning framework for remote sensing image understanding. *IEEE Transactions on Geoscience and Remote Sensing*, 61:1–17, 2023. 3, 6, 10, 15, 17, 18, 19, 20

[71] Ranganath Navalgund, Jayaraman V, and Parth Roy. Remote sensing applications: An overview. *Current science*, Vol. 93, 12 2007. 2, 4

[72] Vishal Nedungadi, Ankit Kariryaa, Stefan Oehmcke, Serge Belongie, Christian Igel, and Nico Lang. Mmearth: Exploring multi-modal pretext tasks for geospatial representation learning, 2024. 3, 12, 15, 18, 23, 24

[73] Mubashir Noman, Muzammal Naseer, Hisham Cholakkal, Rao Muhammad Anwar, Salman Khan, and Fahad Shahbaz Khan. Rethinking transformers pre-training for multi-spectral satellite imagery, 2024. 3, 5, 11, 18

[74] Keiron O'Shea and Ryan Nash. An introduction to convolutional neural networks, 2015. 13

[75] Eleonora Jonasova Parelius. A review of deep-learning methods for change detection in multispectral remote sensing images. *Remote Sensing*, 15(8), 2023. 13

[76] Daifeng Peng, Lorenzo Bruzzone, Yongjun Zhang, Haiyan Guan, Haiyong Ding, and Xu Huang. Semicdnet: A semisupervised convolutional neural network for change detection in high resolution remote-sensing images. *IEEE Transactions on Geoscience and Remote Sensing*, 59(7):5891–5906, 2021. 4

[77] Jonathan Prexl and Michael Schmitt. Multi-modal multi-objective contrastive learning for sentinel-1/2 imagery. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, pages 2136–2144, June 2023. 3, 10, 15

[78] Colorado J. Reed, Ritwik Gupta, Shufan Li, Sarah Brockman, Christopher Funk, Brian Clipp, Kurt Keutzer, Salvatore Candido, Matt Uyttendaele, and Trevor Darrell. Scale-mae: A scale-aware masked autoencoder for multiscale geospatial representation learning, 2023. 3, 4, 5, 10, 15, 17

[79] Linus Scheibenreif, Joëlle Hanna, Michael Mommert, and Damian Borth. Self-supervised vision transformers for land-cover segmentation and classification. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, pages 1422–1431, June 2022. 3, 9, 15

[80] Michael Schmitt, Lloyd Haydn Hughes, Chunping Qiu, and Xiao Xiang Zhu. Sen12ms – a curated dataset of georeferenced multi-spectral sentinel-1/2 imagery for deep learning and data fusion, 2019. 9, 11, 14, 22, 24

[81] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition, 2015. 7

[82] Michael J. Smith, Luke Fleming, and James E. Geach. Earthpt: a time series foundation model for earth observation, 2024. 3, 11, 15, 19

[83] Adam J. Stewart, Nils Lehmann, Isaac A. Corley, Yi Wang, Yi-Chia Chang, Nassim Ait Ali Braham, Shradha Sehgal, Caleb Robinson, and Arindam Banerjee. Ssl4eo-l: Datasets and foundation models for landsat imagery, 2023. 3, 10, 15, 23, 24

[84] Vladan Stojnic and Vladimir Risojevic. Self-supervised learning of remote sensing scene representations using contrastive multiview coding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, pages 1182–1191, June 2021. 3, 9, 15, 18

[85] Gencer Sumbul, Marcela Charfuelan, Begum Demir, and Volker Markl. Bigearthnet: A large-scale benchmark archive for remote sensing image understanding. In *IGARSS 2019 - 2019 IEEE International Geoscience and Remote Sensing Symposium*. IEEE, July 2019. 7, 9, 12, 16, 18, 22, 24

[86] Gencer Sumbul, Arne de Wall, Tristan Kreuziger, Filipe Marcelino, Hugo Costa, Pedro Benevides, Mario Caetano, Begum Demir, and Volker Markl. Bigearthnet-mm: A large-scale, multimodal, multilabel benchmark archive for remote sensing image classification and retrieval [software and data sets]. *IEEE Geoscience and Remote Sensing Magazine*, 9(3):174–180, Sept. 2021. 9

[87] Xian Sun, Peijin Wang, Wanxuan Lu, Zicong Zhu, Xiaonan Lu, Qibin He, Junxi Li, Xuee Rong, Zhujun Yang, Hao Chang, Qinglin He, Guang Yang, Ruiping Wang, Jiwen Lu, and Kun Fu. Ringmo: A remote sensing foundation model with masked image modeling. *IEEE Transactions on Geoscience and Remote Sensing*, 61:1–22, 2023. 3, 9, 15, 17, 18, 19, 20

[88] Maofeng Tang, Andrei Cozma, Konstantinos Georgiou, and Hairong Qi. Cross-scale mae: A tale of multi-scale exploitation in remote sensing, 2024. 3, 11, 15, 17, 18

[89] Chao Tao, Ji Qi, Guo Zhang, Qing Zhu, Weipeng Lu, and Haifeng Li. Tov: The original vision model for optical remote sensing image understanding via self-supervised learning. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 16:4916–4930, 2023. 3, 10, 15, 18, 19

[90] Chao Tao, Ji Qia, Guo Zhang, Qing Zhu, Weipeng Lu, and Haifeng Li. Tov: The original vision model for optical remote

sensing image understanding via self-supervised learning, 2022. 22, 24

[91] Jiayuan Tian, Jie Lei, Jiaqing Zhang, Weiying Xie, and Yunsong Li. Swimdiff: Scene-wide matching contrastive learning with diffusion constraint for remote sensing image, 2024. 3, 11, 15, 18, 19

[92] Gabriel Tseng, Ruben Cartuyvels, Ivan Zvonkov, Mirali Purohit, David Rolnick, and Hannah Kerner. Lightweight, pre-trained transformers for remote sensing timeseries, 2024. 3, 11, 15

[93] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2023. 4, 14

[94] Chen Wang, Alexis Mouche, Pierre Tandeo, Justin Stopa, Nicolas Longépé, Guillaume Erhard, Ralph Foster, Douglas Vandemark, and Bertrand Chapron. A labelled ocean sar imagery dataset of ten geophysical phenomena from sentinel-1 wave mode. *Geoscience Data Journal*, 6, 07 2019. 4

[95] Di Wang, Meiqi Hu, Yao Jin, Yuchun Miao, Jiaqi Yang, Yichu Xu, Xiaolei Qin, Jiaqi Ma, Lingyu Sun, Chenxing Li, Chuan Fu, Hongruixuan Chen, Chengxi Han, Naoto Yokoya, Jing Zhang, Minqiang Xu, Lin Liu, Lefei Zhang, Chen Wu, Bo Du, Dacheng Tao, and Liangpei Zhang. Hypersigma: Hyperspectral intelligence comprehension foundation model, 2024. 3, 12, 15, 16, 19, 20

[96] Di Wang, Jing Zhang, Bo Du, Gui-Song Xia, and Dacheng Tao. An empirical study of remote sensing pretraining. *IEEE Transactions on Geoscience and Remote Sensing*, 61:1–20, 2023. 3, 9, 15, 17, 18, 19

[97] Di Wang, Jing Zhang, Bo Du, Gui-Song Xia, and Dacheng Tao. An empirical study of remote sensing pretraining. *IEEE Transactions on Geoscience and Remote Sensing*, 61:1–20, 2023. 7

[98] Di Wang, Jing Zhang, Bo Du, Minqiang Xu, Lin Liu, Dacheng Tao, and Liangpei Zhang. Samrs: Scaling-up remote sensing segmentation dataset with segment anything model, 2023. 11, 22, 24

[99] Di Wang, Jing Zhang, Minqiang Xu, Lin Liu, Dongsheng Wang, Erzhong Gao, Chengxi Han, Haonan Guo, Bo Du, Dacheng Tao, and Liangpei Zhang. Mtp: Advancing remote sensing foundation model via multi-task pretraining, 2024. 3, 11, 15, 17, 19

[100] Di Wang, Qiming Zhang, Yufei Xu, Jing Zhang, Bo Du, Dacheng Tao, and Liangpei Zhang. Advancing plain vision transformer toward remote sensing foundation model. *IEEE Transactions on Geoscience and Remote Sensing*, 61:1–15, 2023. 3, 9, 15, 17, 18, 19

[101] Xiao Wang, Siyan Liu, Aristeidis Tsaris, Jong-Youl Choi, Ashwin Aji, Ming Fan, Wei Zhang, Junqi Yin, Moetasim Ashfaq, Dan Lu, and Prasanna Balaprakash. Orbit: Oak ridge base foundation model for earth system predictability, 2024. 6, 15, 18, 20

[102] Yi Wang, Conrad M Albrecht, Nassim Ait Ali Braham, Chenying Liu, Zhitong Xiong, and Xiao Xiang Zhu. Decur: decoupling common & unique representations for multimodal self-supervision, 2023. 3, 10, 15, 16, 18

[103] Yi Wang, Conrad M. Albrecht, Nassim Ait Ali Braham, Lichao Mou, and Xiao Xiang Zhu. Self-supervised learning in remote sensing: A review. *IEEE Geoscience and Remote Sensing Magazine*, 10(4):213–247, 2022. 5

[104] Yi Wang, Conrad M Albrecht, Nassim Ait Ali Braham, Lichao Mou, and Xiao Xiang Zhu. Self-supervised learning in remote sensing: A review, 2022. 6

[105] Yi Wang, Conrad M Albrecht, and Xiao Xiang Zhu. Self-supervised vision transformers for joint sar-optical representation learning, 2022. 3, 9, 15, 16, 18

[106] Yi Wang, Conrad M Albrecht, and Xiao Xiang Zhu. Multilabel guided soft contrastive learning for efficient earth observation pretraining, 2024. 3, 12, 15

[107] Yi Wang, Nassim Ait Ali Braham, Zhitong Xiong, Chenying Liu, Conrad M Albrecht, and Xiao Xiang Zhu. Ssl4eo-s12: A large-scale multi-modal, multi-temporal dataset for self-supervised learning in earth observation, 2023. 10, 12, 14, 22, 24

[108] Yi Wang, Hugo Hernández Hernández, Conrad M Albrecht, and Xiao Xiang Zhu. Feature guided masked autoencoder for self-supervised learning in remote sensing, 2023. 3, 10, 15, 18

[109] Yuelei Wang, Ting Zhang, Liangjin Zhao, Lin Hu, Zhechao Wang, Ziqing Niu, Peirui Cheng, Kaiqiang Chen, Xuan Zeng, Zhirui Wang, Hongqi Wang, and Xian Sun. Ringmolite: A remote sensing multi-task lightweight network with cnn-transformer hybrid framework, 2023. 3, 10, 15, 17, 18, 19

[110] Zhechao Wang, Peirui Cheng, Pengju Tian, Yuchao Wang, Mingxin Chen, Shujing Duan, Zhirui Wang, Xinming Li, and Xian Sun. Rs-dfm: A remote sensing distributed foundation model for diverse downstream tasks, 2024. 3, 12, 15

[111] Xinye Wanyan, Sachith Seneviratne, Shuchang Shen, and Michael Kirley. Extending global-local view alignment for self-supervised learning with remote sensing imagery, 2024. 3, 5, 6, 11, 15, 16, 17, 18, 19

[112] Michael Wulder, Thomas Loveland, David Roy, Christopher Crawford, Jeffrey Masek, Curtis Woodcock, Richard Allen, Martha Anderson, Alan Belward, Warren Cohen, John Dwyer, Angela Erb, Feng Gao, Patrick Griffiths, Dennis Helder, Txomin Hermosilla, James Hipple, Patrick Hostert, M. Hughes, and Zhe Zhu. Current status of landsat program, science, and applications. *Remote Sensing of Environment*, 225:127–147, 03 2019. 2

[113] Gui-Song Xia, Xiang Bai, Jian Ding, Zhen Zhu, Serge Belongie, Jiebo Luo, Mihai Datcu, Marcello Pelillo, and Liangpei Zhang. Dota: A large-scale dataset for object detection in aerial images. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2018. 19

[114] Gui-Song Xia, Xiang Bai, Jian Ding, Zhen Zhu, Serge Belongie, Jiebo Luo, Mihai Datcu, Marcello Pelillo, and Liangpei Zhang. Dota: A large-scale dataset for object detection in aerial images, 2019. 9, 22, 24

[115] Gui-Song Xia, Jingwen Hu, Fan Hu, Baoguang Shi, Xiang Bai, Yanfei Zhong, Liangpei Zhang, and Xiaoqiang Lu. Aid: A benchmark data set for performance evaluation of aerial scene classification. *IEEE Transactions on Geoscience and Remote Sensing*, 55(7):3965–3981, July 2017. 10

[116] Zhifeng Xiao, Yang Long, Deren Li, Chunshan Wei, Gefu Tang, and Junyi Liu. High-resolution remote sensing image retrieval based on cnns from a dimensional perspective. *Remote Sensing*, 9(7), 2017. 14, 22, 24

[117] Zhitong Xiong, Yi Wang, Fahong Zhang, Adam J. Stewart, Joëlle Hanna, Damian Borth, Ioannis Papoutsis, Bertrand Le Saux, Gustau Camps-Valls, and Xiao Xiang Zhu. Neural plasticity-inspired multimodal foundation model for earth observation, 2024. 3, 12, 15, 20

[118] Zhitong Xiong, Yi Wang, Fahong Zhang, and Xiao Xiang Zhu. One for all: Toward unified foundation models for earth vision, 2024. 3, 11, 15, 20, 21

[119] Fanglong Yao, Wanxuan Lu, Heming Yang, Liangyu Xu, Chenglong Liu, Leiyi Hu, Hongfeng Yu, Nayu Liu, Chubo Deng, Deke Tang, Changshuo Chen, Jiaqi Yu, Xian Sun, and Kun Fu. Ringmo-sense: Remote sensing foundation model for spatiotemporal prediction via spatiotemporal evolution disentangling. *IEEE Transactions on Geoscience and Remote Sensing*, 61:1–21, 2023. 3, 10, 15

[120] Lefei Zhang and Liangpei Zhang. Artificial intelligence for remote sensing data analysis: A review of challenges and opportunities. *IEEE Geoscience and Remote Sensing Magazine*, 10(2):270–294, 2022. 5

[121] Liangpei Zhang, Lefei Zhang, and Bo Du. Deep learning for remote sensing data: A technical tutorial on the state of the art. *IEEE Geoscience and Remote Sensing Magazine*, 4(2):22–40, 2016. 5

[122] Lixian Zhang, Yi Zhao, Runmin Dong, Jinxiao Zhang, Shuai Yuan, Shilei Cao, Mengxuan Chen, Juepeng Zheng, Weijia Li, Wei Liu, Wayne Zhang, Litong Feng, and Haohuan Fu. A^2-mae: A spatial-temporal-spectral unified remote sensing pre-training method based on anchor-aware masked autoencoder, 2024. 3, 12, 15, 18

[123] Mingming Zhang, Qingjie Liu, and Yunhong Wang. Ctxmim: Context-enhanced masked image modeling for remote sensing image understanding, 2024. 3, 12, 15, 18

[124] Tong Zhang, Peng Gao, Hao Dong, Yin Zhuang, Guanqun Wang, Wei Zhang, and He Chen. Consecutive pre-training: A knowledge transfer learning strategy with relevant unlabeled data for remote sensing domain. *Remote Sensing*, 14(22), 2022. 3, 9, 15, 19

[125] Yi Zhao, Xinchang Zhang, Weiming Feng, and Jianhui Xu. Deep learning classification by resnet-18 based on the real spectral dataset from multispectral remote sensing images. *Remote Sensing*, 14(19), 2022. 13

[126] Ce Zhou, Qian Li, Chen Li, Jun Yu, Yixin Liu, Guangjing Wang, Kai Zhang, Cheng Ji, Qiben Yan, Lifang He, Hao Peng, Jianxin Li, Jia Wu, Ziwei Liu, Pengtao Xie, Caiming Xiong, Jian Pei, Philip S. Yu, and Lichao Sun. A comprehensive survey on pretrained foundation models: A history from bert to chatgpt, 2023. 4

[127] Huming Zhu, Chendi Liu, Qiuming Li, et al. Deep convolutional encoder–decoder networks based on ensemble learning for semantic segmentation of high-resolution aerial imagery. *CCF Transactions on High Performance Computing*, 6:408–424, August 2024. 18

[128] Hao Zhu, Mengru Ma, Wenping Ma, Licheng Jiao, Shikuan Hong, Jianchao Shen, and Biao Hou. A spatial-channel progressive fusion resnet for remote sensing classification. *Information Fusion*, 70:72–87, 2021. 13

[129] Xiao Xiang Zhu, Devis Tuia, Lichao Mou, Gui-Song Xia, Liangpei Zhang, Feng Xu, and Friedrich Fraundorfer. Deep learning in remote sensing: A comprehensive review and list of resources. *IEEE Geoscience and Remote Sensing Magazine*, 5(4):8–36, 2017. 5, 7

[130] Xiao Xiang Zhu, Zhitong Xiong, Yi Wang, Adam J. Stewart, Konrad Heidler, Yuanyuan Wang, Zhenghang Yuan, Thomas Dujardin, Qingsong Xu, and Yilei Shi. On the foundations of earth and climate foundation models, 2024. 5

传记部分

Lu Siqi（学生会员，IEEE）现为范德堡大学电子与计算机工程系的二年级硕士研究生，导师为胡远开博士和米切尔 · M · 威尔克斯博士。她的研究兴趣包括深度学习、医学图像分析以及软件工程。她于 2023 年获得伊利诺伊大学厄本那-香槟分校电气工程学士学位。

Guo Junlin 目前正于范德堡大学电子与计算机工程系攻读博士学位。他的研究兴趣包括医学图像分析、深度学习、计算机视觉以及脑科学。在加入范德堡大学之前，他于 2017 年获得东北大学通信工程学士学位，并于 2020 年在范德堡大学电子与计算机工程系获得硕士学位，研究方向为功能性磁共振成像脑活性值研究。

詹姆斯 · R · 齐默-道芬尼 2011 年于佐治亚南方大学获得人类学文学学士学位和数学理学学士学位，2014 年于阿肯色大学获得人类学硕士学位，2023 年于范德比尔特大学获得人类学博士学位。目前他是范德比尔特大学空间分析研究中心（SARL）的博士后研究员，研究经费来自人文基金会的 GeoPACHA 2.0 项目资助。他的研究兴趣包括开发用于大规模自主考古卫星图像调查的深度学习模型、地球物理方法以及空间建模，以理解殖民化对土著人民的影响。

乔丹 · M · 尼厄斯马 是范德比尔特大学空间分析研究中心的研究助理。她于 2024 年 5 月获得范德比尔特大学数据科学硕士学位，并拥有哈弗福德学院英语文学学士学位及法语辅修学位。

王晓 2012 年获得明尼苏达州圣约翰大学数学与计算机科学学士学位，2016 年获得印第安纳州西拉法叶普渡大学电气与计算机工程硕士学位，2017 年获得普渡大学电气与计算机工程博士学位。他曾在哈佛医学院和波士顿儿童医院从事博士后研究，直至 2021 年。目前，他是橡树岭国家实验室的研究人员。他的研究兴趣包括将机器学习、医学物理、图像处理以及高性能计算应用于各类成像问题，如 CT 重构、电子断层成像以及磁共振成像。他曾荣获 2022 年美国医学物理师协会（AAPM）真实 CT 重构挑战赛冠军，并于 2017 年入围 ACM 戈登 · 贝尔奖决赛。

帕克 · 范瓦尔肯伯格 是布朗大学人类学副教授，以及拉丁美洲与加勒比研究项目的临时主任。他的研究重点在于殖民主义和帝国主义对秘鲁安第斯地区原住民及其环境的影响。他运用多种材料和数字方法，包括地理信息系统（GIS），以理解帝国历史中关系的变迁。他共同领导“查查波亚斯考古景观”（PACha）项目和 GeoPACHA（安第斯文化、历史与考古的地理空间平台）。范瓦尔肯伯格博士毕业于哈佛大学。

Steven A Wernke 是范德比尔特大学人类学系的副教授及系主任，空间分析研究实验室主任，以及范德比尔特大学空间研究所主任。韦恩克教授是南美洲安第斯地区考古学家和历史人类学家。他的研究位于多个学科的交叉点：考古学与历史学、前西班牙时期与殖民时期研究、人类学与文化地理学。韦恩克教授的研究兴趣集中于在西班牙入侵安第斯地区过程中原住民社区的生活体验——特别是印加人和西班牙人接连试图使安第斯社会臣服并按照自身形象重塑的过程中，新型社区、景观和宗教实践如何涌现。在方法论上，他的工作将考古学和文献数据集的分析融入地理空间框架中。

郭远凯 是美国田纳西州范德堡大学计算机科学系的助理教授。他于 2008 年获得南京邮电大学电气工程学士学位，2011 年获得东南大学电气工程硕士学位。毕业后，他于 2011 年至 2014 年在哥伦比亚大学及纽约州精神病研究所担任工程师和研究官员。2014 年，他在哥伦比亚大学获得计算机科学硕士学位，2018 年在范德堡大学获得电气工程博士学位。此后，他曾在范德堡大学担任研究助理教授，并随后在 PAII 实验室担任高级研究科学家。自 2020 年起，他成为范德堡大学电子工程与计算机科学系及数据科学研究所的教职成员。