https://hjfy.top/arxiv/2507.13812

SkySense V2：面向多模态遥感的统一基础模型

Yingying Zhang[1] Lixiang Ru[1] Kang Wu[2] Lei Yu[1] Lei Liang[1] Yansheng Li[2] Jingdong Chen[1]
[1]Ant Group [2] Wuhan University
qichu.zyy@antgroup.com

Abstract

多模态遥感基础模型（MM-RSFM）在城市规划、环境监测和自然灾害管理等地球观测任务中取得了显著进展。然而，现有大多数方法通常需要为每种数据模态分别训练独立的骨干网络，导致冗余并造成参数利用效率低下。此外，主流的预训练方法通常采用自然图像中的自监督学习（SSL）技术，未能充分考虑遥感（RS）图像的特性，例如单幅遥感图像中复杂的语义分布。本文提出 SkySense V2，一种统一的多模态遥感基础模型，采用单一 Transformer 骨干网络处理多种模态。该骨干网络通过一种针对遥感数据独特特性的新型自监督学习策略进行预训练。特别地，SkySense V2 引入了一种创新的自适应补丁合并模块和可学习的模态提示 token，以应对不同分辨率及模态间特征多样性有限的挑战。此外，我们还引入了混合专家（MoE）模块，进一步提升基础模型的性能。通过覆盖 7 项任务的 16 个数据集的广泛评估，SkySense V2 展现出出色的泛化能力，平均性能优于 SkySense 1.8 分。

1. 引言

多模态遥感基础模型（MM-RSFM）的进展显著增强了遥感（RS）数据在众多地球观测（EO）应用中的利用 [5, 12, 47, 83]，例如环境监测、农业管理、自然灾害应对、土地覆盖（或利用）制图 etc. 。最近，Guo et al. 提出了 SkySense [24]，这是迄今为止最大的 MM-RSFM。SkySense 通过在众多不同任务上的广泛评估，展现了出色的泛化能力。其成功的关键因素是对地理对齐的多模态和多时相遥感数据进行同步训练。为适应不同模态的不同分辨率，SkySense 采用 Swin Transformer [41] 处理高分辨率（HR）光学图像，同时

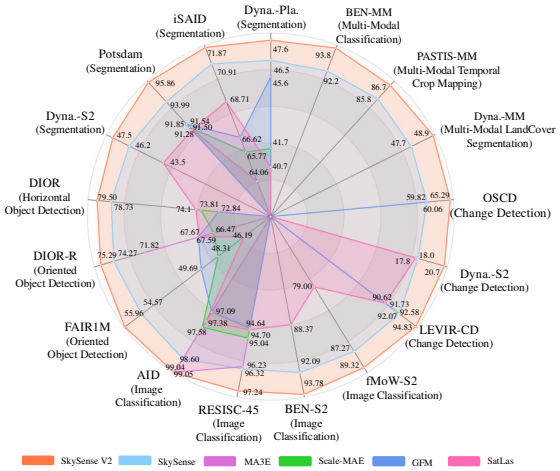

图 1. SkySense V2 在 7 个不同任务的 16 个数据集上相较于其前代 SkySense 实现了更优的性能，并支持更广泛的任务范围。

使用视觉 Transformer（ViT）[18] 处理中分辨率多光谱（MS）数据和合成孔径雷达（SAR）数据。然而，这种分离的骨干网络设计导致了冗余和参数利用效率低下。另一方面，SkySense 的预训练方法主要基于 DINOv2 [53]，DINOv2 以其在自监督学习（SSL）中的高效性而著称。尽管它在遥感图像上展现了优异性能，但通过充分适应单张遥感图像中涉及的语义分布，仍有较大的改进空间。

在本文中，我们介绍了 SkySense V2，这是一种通过针对遥感数据独特属性量身定制的新型自监督学习方法预训练的先进多模态遥感特征建模模型。具体而言，SkySense V2 采用统一的 Transformer 骨干网络，能够处理不同模态和分辨率的数据。其通过一种新的自监督学习策略进行预训练，该策略利用基于查询的注意力机制，从遥感图像的不同区域中聚合具有相似

语义的特征。

为地理对齐的多模态数据设计统一主干网络面临两个主要挑战。第一个挑战是在多个模态同时进行预训练时，处理具有不同地面采样距离（GSD）的数据之间的特征分辨率差异。为解决这一问题，我们引入了一种创新的自适应补丁合并（APM）模块，该模块被集成在统一主干网络的每个阶段之后。该模块根据各模态的具体特征分辨率需求，决定是否降低特征分辨率。例如，在处理高分辨率光学图像时，APM 模块会在每个阶段激活分辨率降低；而对于中等分辨率数据（如多光谱和合成孔径雷达数据），特征分辨率在整个阶段中得以保持。这种设计使主干网络能够高效处理不同分辨率的数据，并根据实际需求自适应地调整输出特征分辨率，这对于多模态特征的联合训练与融合至关重要。

第二个挑战在于，跨不同模态完全共享参数会降低特征多样性。为解决这一问题，我们受到 [16] 和 [35] 工作的启发，为每种模态引入可学习的模态提示 token。通过注意力机制与这些独立的模态提示 token 进行交互，预训练模型能够更好地捕捉每种模态的独特特征。与 SkySense 相比，我们的统一设计显著提升了参数利用效率。具体而言，SkySense 使用三个分离的骨干网络：Swin-H 用于高分辨率光学数据，ViT-L 用于中分辨率数据，以及 ViT-L 用于 SAR 数据，总参数量达到 12.6 亿。相比之下，SkySense V2 的统一 Transformer 骨干网络能够同时处理三种模态，且仅使用 6.65 亿参数。这种高效的参数利用不仅优化了架构，还为模型缩放提供了可能，以进一步提升性能。因此，我们集成了混合专家模块 [33]，这一技术在各类大型语言模型 [19, 59, 86] 中被广泛使用，以进一步增强基础模型的性能。

为了有效将自然图像上开发的自监督学习（SSL）技术应用于遥感特征记忆（RSFM）的预训练，必须考虑数据特性的显著差异。自然图像通常具有单一且明确的主题，例如猫、狗或人。相比之下，遥感（RS）图像包含分布在图像各个区域的多个主题。例如，如图2所示，遥感图像的一个部分可能显示建筑物，而其他区域可能显示森林、池塘或土地。当前的 SSL 方法直接在不同视图之间进行对比学习，使用各种增强裁剪，这在自然图像上由于其单一焦点而表现良好。然而，当应用于遥感图像时，这种方法可能导致语义不准确，因为不同的视图可能捕捉到不同的主题。例如，在图2b中，遥感图像的视图 1 主要包含建筑物，而视图 2 则显示森林和池塘。

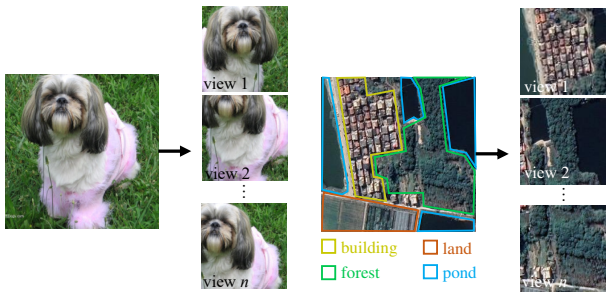

(a) 自然图像的视角　　(b) 遥感图像的视角

图 2. 在自监督学习中，自然图像和遥感图像的不同增强视图的对比。自然图像的视图通常集中在单一主题上，例如“狗”。而遥感图像的视图则包含多种主题，包括建筑、森林、池塘和土地。

为应对这一挑战，我们提出了一种名为基于查询的语义聚合对比学习（QSACL）的新方法。该方法采用多个可学习的查询，与不同视图的特征进行交叉注意力操作，生成语义聚合特征。随后，我们对来自同一查询的聚合特征对应用对比学习。如我们的消融研究中图9所示，使用不同的查询可以在多个视图间聚合一致的语义特征，从而提升对比学习的准确率。

我们在一组多样化的 16 个数据集 [9, 13–15, 17, 21, 36, 62, 65, 67, 76, 79] 上评估了 SkySense V2，这些数据集涵盖了多种任务类型、模态和空间尺度。如图 1 所示，SkySense V2 相较于其前身 SkySense 在性能上表现出显著提升，在各类遥感地球观测（EO）任务的多种模态下均达到了当前最优（SOTA）结果。所有测试场景的实验结果突显了其在广泛多样的 EO 解释任务中相较于现有遥感特征模型（RSFM）的竞争力。

2. 相关工作

2.1. 遥感基础模型

RSFMs 以其能够通过自监督学习（SSL）技术利用海量数据的能力为特征，使其能够在无需大量标注的情况下学习鲁棒的特征表示。主流的 RSFMs 采用对比学习（CL）或掩码图像建模（MIM）。典型的 CL 研究包括 RS-BYOL [34]、GASSL [82]、DINO-MC [75]、SeCo [49] 和 CACo [48]。其他研究则聚焦于增强 MIM 框架，例如 RingMo [64]、S2MAE [38]、MA3E [39]、SatMAE [15] 以及 SatMAE++ [52]。此外，CMID [51] 和 GFM

[50] 等研究通过自蒸馏方法探索了 CL 与 MIM 的交叉融合。

最近，Guo et al. 提出了一种全面的多模态遥感自监督模型（MM-RSFM）——SkySense [24]，其具有分解的多模态时空编码器架构。该架构实现了独立的空间特征抽取与多模态时间融合。作为迄今为止规模最大的 MM-RSFM，SkySense 在广泛的遥感数据集上展现出卓越的泛化能力。然而，它也面临一个挑战：由于不同模态采用独立的主干网络设计，导致参数利用效率低下。在本工作中，我们提出 SkySense V2，通过采用统一的 Transformer 主干设计来解决这一问题。

2.2. 多模态学习的统一框架

多模态学习旨在训练能够有效处理和关联来自不同模态信息的模型。该领域已取得显著进展，涌现出大量专注于构建统一网络以整合和处理多种模态的研究工作。主要成果包括 VLMO [60]、Meta-Transformer [84]、Uni-Perceiver [85] 和 UniTR [25]，etc. 。已有若干方法采用统一的骨干网络设计来处理多模态遥感数据。例如，OFA-Net [81] 在精心构建的多模态数据集上使用 MIM 对单一 Transformer 骨干网络进行预训练。Han et al. 提出了一种名为 msGFM[26] 的遥感特征融合模型，其采用共享的 Transformer 编码器，同时为每种模态使用不同的解码器。与我们的方法不同，OFA-Net 和 msGFM 仅共享骨干网络的所有参数，并分别学习多模态数据的特征表示，导致不同模态间的特征缺乏地理对齐和融合。AnySat [2] 采用联合嵌入预测架构构建多模态模型，以自监督学习（SSL）方式在异构数据上训练单一模型。然而，我们的 SkySense V2 在骨干网络设计和自监督预训练方法上与 AnySat 存在显著差异。

3. SkySense V2

3.1. 模型架构

3.1.1. 统一的 Transformer 主干网络

如图3所示，我们的统一 Transformer 主干网络是一个具有四个阶段的分层编码器结构。在前两个阶段中，我们采用 Swin Transformer V2 块（SwinV2B）[42]，以融入局部性与平移不变性等关键视觉先验。SwinV2B 中的基于窗口的自注意力机制相较于全局自注意力，有助于降低计算复杂度，尤其是在这些初始阶段特征具

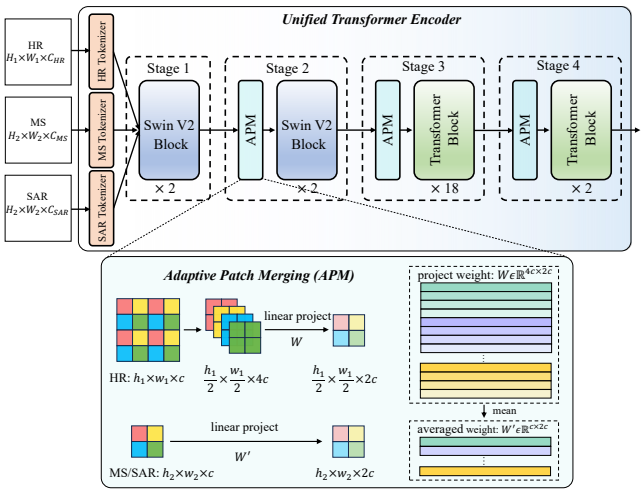

图 3. SkySense V2 中统一 Transformer 主干模型的概览：整个主干在不同模态间共享所有参数，仅分立的标记器除外。

有较高空间分辨率的情况下。在最后两个阶段中，我们使用原始 Transformer 块（TB）[18]，主要原因有两点：首先，这些阶段的特征空间分辨率相对较低，使得全局自注意力的计算成本更加可控；其次，我们的消融实验表明，全局自注意力可与基于窗口的自注意力相辅相成，使模型能够获得更强的表示能力。

给定一组多模态输入，包括高分辨率光学图像 x_{HR}、多光谱数据 x_{MS} 和合成孔径雷达数据 x_{SAR}，其中不同模态中的每个“像素”通过地理定位自然对齐，我们采用三种不同的 tokenizer 来将这些输入处理为 token。在每个 tokenizer 中，输入数据首先被划分为非重叠的 4×4 块。随后，对这些原始块状数据应用线性嵌入层，将其投影到块 token。接着，对这些块 token 应用四个阶段的 SwinV2B 或 TB，且跨模态共享参数。

由于不同模态的卫星传感器具有不同的地面采样距离（GSD），在联合对齐训练过程中，同一地理区域的输入数据在特定地理位置上表现出不同的空间分辨率。为了统一来自不同模态的 token 的空间分辨率，我们提出自适应补丁合并（APM），并在每一阶段（除第 1 阶段外）使用该方法有选择地降低空间分辨率。具体而言，对于具有高空间分辨率的光学图像数据的 token，APM 将 2×2 个相邻补丁的特征进行连结，并对 $4c$ 维的连结特征应用线性层。该过程将 token 数量减少为原数量的 $2 \times 2 = 4$ 倍，即实现了 $2 \times 2 = 4$ 倍的空间分辨率下采样，同时输出维度设置为 $2c$。相比之下，

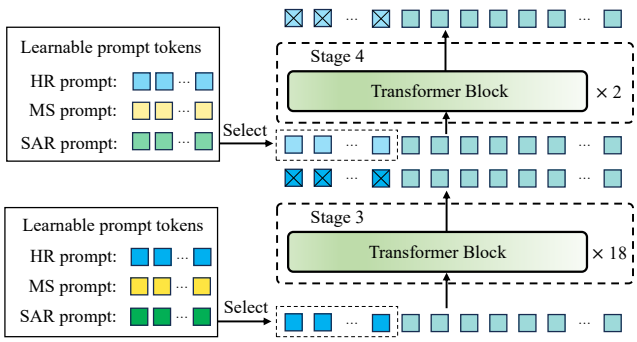

图 4. 模态特定提示 token 添加到统一主干网络的示意图。

对于空间分辨率较低的多光谱（MS）和合成孔径雷达（SAR）数据的 token，APM 通过在输入维度上平均权重的线性投影来保持分辨率。通过集成 APM 模块，我们的统一骨干网络能够高效处理具有不同分辨率的多模态数据，同时保持各模态间特征的空间对齐。

3.1.2. 模态特定的提示 token

我们的统一 Transformer 主干网络在不同模态间使用完全共享的参数。为了增强特征多样性，我们为每种模态引入可学习的模态特定提示 token。通过注意力机制与这些独立的模态提示 token 进行交互，预训练模型能够更好地捕捉每种模态的独特特性。如图4所示，我们在最后两个阶段中为每种模态引入 N 个可学习的提示 token。我们将每一阶段的输入 token 表示为 $E_i^j \in \mathbb{R}^{h_j w_j \times c_j}, i \in \{HR, MS, SAR\}, j \in \{3, 4\}$，其中 h_j 和 w_j 分别表示第 j 阶段的空间分辨率的高度和宽度，而 c_j 表示 token 的维度。对于每种模态 i，我们将模态特定的可学习提示 token$P_i^j \in \mathbb{R}^{N \times c_j}$ 插入到第 j 阶段的第一个块的输入中 $\mathcal{F}_j$。在每个阶段的最后一个块中，这些提示 token 被丢弃。整个过程可表述为：

$$\begin{aligned} [E_{drop}, E_i^4] &= \mathcal{F}_3([P_i^3, E_i^3]), \\ [E_{drop}, E_i^{out}] &= \mathcal{F}_4([P_i^4, E_i^4]). \end{aligned} \tag{1}$$

此处，E_{drop} 表示被丢弃的 token，E_i^{out} 表示主干网络的最终输出 token。我们设计的模态特定 prompt 在仅引入少量模态特定参数的情况下，增强了特征多样性，同时保持了完整的参数共享。

3.1.3. 扩大模型容量

我们跨多种模态的统一骨干网络设计显著提升了参数利用效率。为了进一步增强模型能力，我们在骨干网络中集成混合专家模型（Mixture of Experts, MoE）[33]。我们选择使用 MoE 而非简单增加骨干网络的宽度和深度，是因为 MoE 能够通过为每个 token 利用稀疏的前馈层（即专家）来大幅减少预训练所需的计算量。遵循常见方法 [43, 78]，我们将 MoE 模块插入到最后 L 个 Transformer 块中，替代原有的前馈网络（FFN）层。每个 MoE 模块包含 M 个专家（记为 $\mathcal{E}_i(\cdot), i = 1, 2, ..., M$），其结构与 FFN 相同，并作为独立网络运行。对于 MoE 中的门控网络，我们采用一个可学习的线性层后接 Softmax 函数，$\mathcal{G}(x) = Softmax(Wx)$，其中 W 为门控参数。最终，MoE 的输出是所选专家输出的线性组合，权重由对应的门控值决定。该过程可表示如下：

$$MOE(x) = \sum_{i \in \mathcal{T}} \mathcal{G}_i(x) \cdot \mathcal{E}_i(x), \tag{2}$$

$\mathcal{T}$ 表示前-k 个索引的集合。在我们的 SkySense V2 主干网络中，我们设置 $L = 6, M = 8$ ，以及 $k = 1$ 。

3.2. 整体预训练流水线

图 5 展示了我们预训练过程的概览。SkySense V2 的预训练框架主要采用 SkySense [24] 中的教师-学生架构，其中教师网络的参数通过学生网络参数的指数移动平均（EMA）[53] 进行更新。为了训练 SkySense V2，我们采用如 SkySense 所提出的多粒度对比学习（MGCL）损失 $\mathcal{L}_{MGCL}$。对于每种模态，MGCL 分别在像素级、目标级和图像级粒度上利用对比损失 [53] 来对齐教师网络与学生网络的表示。此外，我们还引入了无监督地理上下文原型学习（GCPL），如 SkySense 中所验证，以增强互补区域上下文线索的学习，从而帮助下游任务。为进一步提升稠密解读能力，我们引入辅助监督损失 $\mathcal{L}_{ITA}$，根据开放街道地图（OSM）标签实现稠密的图文对齐（ITA）。[1]. MGCL、GCPL 和 ITA 的详细实现见附录 A。在接下来的段落中，我们将重点介绍所提出的基于查询的语义聚合对比学习（QSACL）。

基于查询的语义聚合对比学习。 QSACL 利用可学习的查询来聚合图像不同区域中的相似语义，从而实现更精确的对比学习。给定来自两个全局视图的特征 g_1, g_2 以及来自 n 个局部视图的特征 $l_1, l_2, ...l_n$ ，其中 g 和 l 表示来自全局和局部视图的融合特征 F_{fus} ，我们采用

[1] https://www.openstreetmap.org/

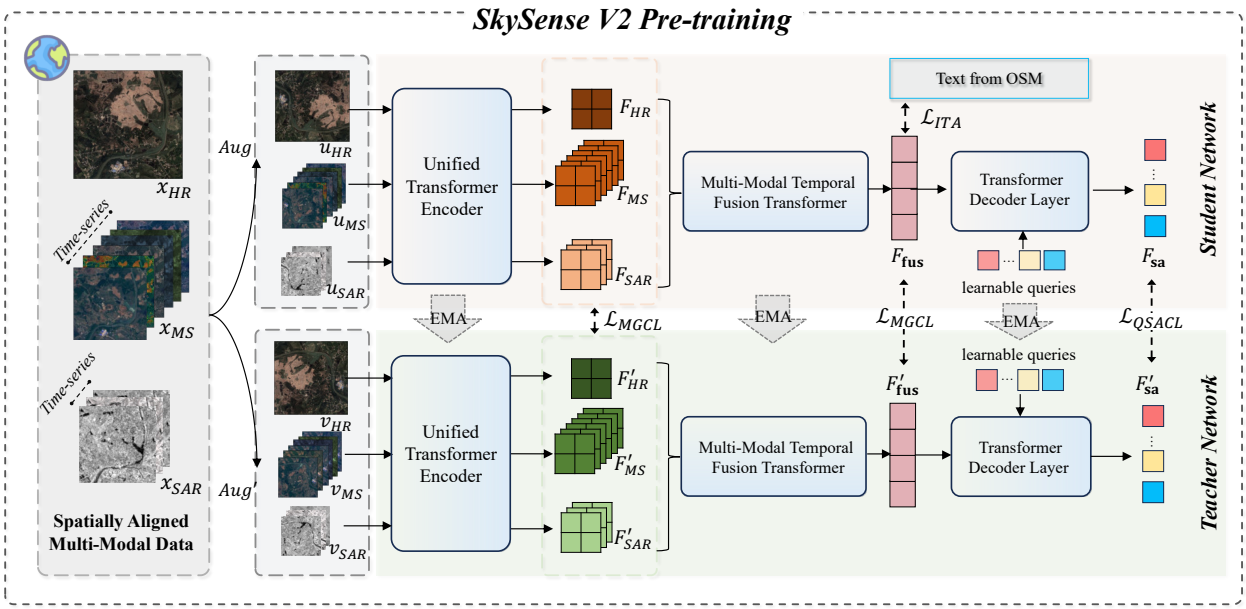

图 5. SkySense V2 预训练流水线概览。SkySense V2 对多模态输入进行数据增强，随后将其输入学生网络和教师网络。预训练过程结合了多粒度对比学习、稠密图像-文本对齐以及基于查询的语义聚合对比学习，以有效训练网络。预训练完成后，将使用教师分支的参数用于下游应用。

Transformer 解码器层对 m 个可学习查询 $q_1, q_2, ..., q_m$ 与特征集 g 和 l 进行交叉注意力操作。该过程为每个 $i = 1, 2, ...m$ 生成一组全局聚合特征集 z_i^g 和一组局部聚合特征集 z_i^l 。如图 6 所示，我们使用上标 $\prime$ 表示来自教师网络的特征，QSACL 损失 $\mathcal{L}_{QSACL}$ 通过平均每个查询在局部视图与全局视图之间聚合特征的损失 $\mathcal{L}_{CL}$ 得到：

$$\mathcal{L}_{QSACL} = \frac{1}{2m}\sum_{i=1}^{m}(\mathcal{L}_{CL}(z_i^g, z_i^{l\prime}) + \mathcal{L}_{CL}(z_i^l, z_i^{g\prime})), \quad (3)$$

$$\mathcal{L}_{CL}(x, x') = -\mathcal{H}(x)\log(\mathcal{H}'(x')). \quad (4)$$

其中，$\mathcal{H}$ 和 $\mathcal{H}'$ 分别表示学习头及其对应的 EMA 部分，如 [7] 所定义。整体训练目标是 $\mathcal{L}_{MGCL}$、$\mathcal{L}_{ITA}$ 和 $\mathcal{L}_{QSACL}$ 的加权和，即

$$\mathcal{L} = \lambda_1\mathcal{L}_{MGCL} + \lambda_2\mathcal{L}_{ITA} + \lambda_3\mathcal{L}_{QSACL}. \quad (5)$$

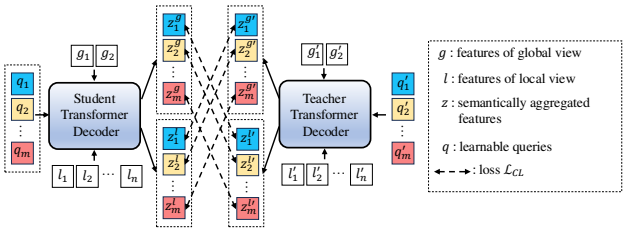

图 6. QSACL 的计算流水线，采用多裁剪增强（2 个全局视图和 n 个局部视图）。

4. 实验

遵循 SkySense [24]，我们在 16 个跨多种模态和任务的数据集上进行了实验，以全面评估 SkySense V2。预训练的 SkySense V2 在各类任务中的应用详见附录 B。每个模块均可单独或联合使用，可根据需要选择冻结或微调。

4.1. 预训练实现

训练数据集 我们使用与 SkySense [24] 相同的训练数据集来训练 SkySense V2。该大规模数据集包含约 2100 万组多模态遥感影像。每组数据包含三个部分：空间维度为 2048×2048 的高分辨率光学 RGB 图像、一组包含 10 个光谱波段且空间维度为 64×64 的 Sentinel-2

(S2) 多光谱 (MS) 图像序列 (平均序列长度为 65 幅图像)，以及一组包含 2 个波段且空间维度同样为 64×64 的 Sentinel-1 (S1) 合成孔径雷达 (SAR) 图像序列 (平均序列长度为 10 幅图像)。在每次训练迭代中，我们随机采样 10 幅不同时相的 S2 图像和 5 幅不同时相的 S1 图像，以适应 GPU 显存约束。

统一骨干的设定。 我们最初将 token 维度设置为 $C = 352$。在前两个阶段中，Swin Transformer V2 块 (SwinV2B) 的窗口大小配置为 8。每个头的查询维度为 32，每个 MLP 层由两个全连接层组成，其维度在统一骨干网络的所有块中始终按因子 4 扩展。在最后两个阶段中引入提示 token，每种模态的提示 token 数量相同。我们为第 3 阶段和第 4 阶段各分配 4 个提示 token。

预训练情景 SkySense V2 使用批量大小为 1024 的设置，在 128 块 H20 GPU 上进行训练。模型总共进行 600k 次迭代，采用 AdamW 优化器 [46]。学习率初始设置为 2×10^{-4}，并按照余弦退火调度方式衰减至 1×10^{-6} [45]。更多实现细节见附录 C。

4.2. 单模态任务

我们在四个常见的单模态遥感图像理解任务上评估了 SkySense V2，包括场景分类、目标检测、语义分割和变化检测。实验通过微调预训练的 SkySense V2 主干网络并搭配特定任务的头部来完成。更多实现细节见附录 D。

场景分类 在表 1 中，我们报告了在四个广泛使用的数据集上的场景分类性能：AID [79] 和 RESISC-45 [13]，二者均包含静态的 RGB 光学图像；BEN-S2 [62]，包含静态的多光谱 (MS) 图像；以及 fMoW-S2 [15]，包含时序多光谱 (MS) 图像。对于每个数据集，性能评估采用不同的训练比例 (TR)，遵循方法 [15, 49]。在我们的实验中，采用简单的线性分类器作为分类头。对于多标签数据集，使用平均精度均值 (mAP) 作为评估指标；而对于单标签数据集，则报告整体准确率 (OA)。如表 1 所示，SkySense V2 在各种数据集和训练配置下始终优于之前的遥感图像模型 (RSFMs)，尤其在低训练比例 (TR) 设置下表现更为突出。这表明 SkySense V2 相较于其他 RSFMs (包括其前身 SkySense [24]) 具有更强的表示能力。

Models	Single-label		Multi-label	Temporal
	AID (TR=20%/50%)	RESISC-45 (TR=10%/20%)	BEN-S2 (TR=10%/100%)	fMoW-S2 (TR=100%)
	OA	OA	mAP	Top-1/5 Acc
GASSL [3]	93.55/95.92	90.86/93.06	79.24/87.40	50.69/77.99
SeCo [49]	93.47/95.99	89.64/92.91	82.62/87.81	51.65/77.40
SatMAE [15]	95.02/96.94	91.72/94.10	86.18/89.50	63.84/-
RingMo [64]	96.90/98.34	94.25/95.67	-	-
RVSA [70]	97.03/98.50	93.93/95.69	-	-
DINO-MC [75]	-	-	84.20/88.75	60.16/83.49
TOV [66]	95.16/97.09	90.97/93.79	-	-
SSL4EO [73]	91.06/94.74	87.60/91.27	87.10/91.80	51.70/76.77
CMID [51]	96.11/97.79	94.05/95.53	-	-
CACo [48]	90.88/95.05	88.28/91.94	81.30/87.00	50.72/76.31
CROMA [20]	-	-	88.29/-	63.59/-
SatLas [4]	94.96/97.38	92.16/94.70	82.80/88.37	57.95/79.00
GFM [50]	95.47/97.09	92.73/94.64	86.30/-	-
Scale-MAE [55]	96.44/97.58	92.63/95.04	-	-
MA3E [39]	- /99.04	- /96.23	-	-
SatMAE++ [52]	-	- /97.48	85.11/-	63.23/-
SkySense [24]	97.68/98.60	94.85/96.32	88.67/92.09	64.38/87.27
SkySense V2	98.34/99.05	96.42/97.24	89.13/93.78	66.65/89.32

表 1. 场景分类结果。—表示该任务不被支持或论文中无法获取该数值。

语义分割 在表 2a 中，我们报告了四个具有代表性的语义分割数据集的分割结果：iSAID [76] 和 Potsdam [61] 用于高分辨率光学图像分割，Dyna.-Pla [67] 和 Dyna.-S2 [67] 用于多光谱和多时相图像分割。遵循先前的工作，我们使用平均 F1 得分 (mF1) 作为 Potsdam 数据集的评估指标。而对于其他数据集，则报告平均交并比 (mIoU)。所有分割实验均采用 UperNet [80] 作为解码器头。如表 2a 所示，我们的 SkySense V2 在所有四个数据集上均优于近期的 RSFM。具体而言，与之前的 SOTA 方法 SkySense [24] 相比，SkySense V2 在平均性能上提升了 1.5%。

水平与方向性目标检测。 我们利用 DIOR 数据集 [36] 评估 SkySense V2 在水平目标检测中的性能，同时使用 DIOR-R [14] 和 FAIR1M [65] 数据集进行定向目标检测。这些数据集仅包含 RGB 遥感影像。与先前的研究 [24] 一致，我们分别采用 Faster R-CNN [56] 和 Oriented R-CNN [37] 作为水平目标检测和定向目标检测的基本检测器。如表 2b 所示，我们的 SkySense

Models	Publication	Dyna.-Pla.	iSAID	Potsdam	Dyna.-S2
		mIoU	mIoU	mF1	mIoU
GASSL [3]	ICCV'21	34.0/40.8	65.95	91.27	28.1/41.0
SeCo [49]	ICCV'21	-	57.20	89.03	29.4/39.8
SatMAE [15]	NIPS'22	32.8/39.9	62.97	90.63	30.1/38.7
RingMo [64]	TGRS'22	-	67.20	91.27	-
RVSA [70]	TGRS'22	34.3/44.4	64.49	-	-
BFM [8]	Arxiv'23	-	-	92.12	-
TOV [66]	JSTARS'23	32.1/37.8	66.24	92.03	-
SSL4EO [73]	GRSM'23	35.3/42.1	64.01	91.54	31.8/42.7
CMID [51]	TGRS'23	36.4/43.5	66.21	91.86	-
CACo [48]	CVPR'23	35.4/42.7	64.32	91.35	30.2/42.5
SAMRS [71]	NIPS'23	-	66.26	91.43	-
SatLas [4]	ICCV'23	37.4/40.7	68.71	91.28	31.9/43.5
GFM [50]	ICCV'23	36.7/45.6	66.62	91.85	-
Scale-MAE [55]	ICCV'23	34.0/41.7	65.77	91.54	-
MA3E [39]	ECCV'24	-	64.06	91.50	-
SkySense [24]	CVPR'24	39.7/46.5	70.91	93.99	33.1/46.2
SkySense V2	-	41.2/47.6	71.87	95.86	35.2/47.5

(a) 语义分割结果。

Models	Horizontal	Oriented	
	DIOR	DIOR-R	FAIR1M
	mAP_{50}	mAP	mAP
GASSL [3]	67.40	65.65	48.17
SatMAE [15]	70.89	65.66	46.55
RingMo [64]	75.90	-	46.21
RVSA [70]	73.22	71.05	47.03
BFM [8]	-	73.62	-
TOV [66]	70.16	66.33	49.62
SSL4EO [73]	64.82	61.23	49.37
CMID [51]	75.11	66.37	50.58
CACo [48]	66.91	64.10	47.83
SatLas [4]	74.10	67.59	46.19
GFM [50]	72.84	67.67	49.69
Scale-MAE [55]	73.81	66.47	48.31
MA3E [39]	-	71.82	-
SkySense [24]	78.73	74.27	54.57
SkySense V2	79.50	75.29	55.96

(b) 目标检测结果。

Models	LEVIR-CD	OSCD	Dyna.-S2
	F1	F1	SCS
GASSL [3]	78.19	46.26	13.6/16.7
SeCo [49]	90.14	47.67	13.9/16.0
SatMAE [15]	87.65	52.76	14.8/16.2
RingMo [64]	91.86	-	-
RVSA [70]	90.86	-	-
SpectralGPT [28]	-	54.29	-
MATTER [1]	-	59.37	-
DINO-MC [75]	-	52.70	14.5/15.6
SSL4EO [73]	89.05	35.08	12.3/17.5
CMID [51]	91.72	-	-
CACo [48]	81.04	52.11	15.3/15.8
SatLas [4]	90.62	-	13.3/17.8
GFM [50]	91.73	59.82	-
Scale-MAE [55]	92.07	-	-
SkySense [24]	92.58	60.06	15.4/18.0
SkySense V2	94.83	65.29	16.0/20.7

(c) 变化检测结果。

表 2. 语义分割、目标检测和变化检测的结果。

V2 在性能上显著优于以往的遥感图像模型。具体而言，SkySense V2 相较于之前的最先进模型 SkySense [24]，平均 mAP 提升了 1.1%。

变化检测 对于变化检测，我们在 LEVIR-CD [9]、OSCD [17] 和 Dyna.-S2 [67] 数据集上进行了实验。由于 LEVIR-CD 和 OSCD 数据集仅包含二值变化检测结果，我们采用 [10] 中的基本变化检测器，并以 F1 得分作为评估指标。而 Dyna.-S2 关注语义变化检测，我们使用 UperNet [80] 作为分割网络，并按照 [24] 的方法在验证集和测试集上计算语义变化检测得分（SCS）。如表 2c 所示，SkySense V2 在所有 3 个数据集上均持续优于之前的 SOTA 方法 SkySense，平均超出 2.7%。尤其在 OSCD 数据集上，我们的 SkySense V2 在 F1 得分上显著优于 SkySense，高出 5.2%。

4.3. 多模态任务

在本节中，我们针对两种具有代表性的多模态任务——多模态分割和多模态场景分类——对 SkySense V2 进行评估，以展示其在不同模态数据上的泛化能力。

多模态分割 在表 3 (a) 和 (b) 中，我们分别展示了 Dyna.-MM [67] 与 PASTIS-MM [21] 的性能结果。Dyna.-MM 包含来自 PlanetFusion (Planet.) 的高分辨率光学影像、来自 Sentinel-2（S2）的多光谱影像以及来自 Sentinel-1 (S1) 的 SAR 影像。针对在 Dyna.-MM 上进行的实验，我们采用基础的 UperNet [80] 作为解码器头部，并使用 mIoU 作为评估指标。如表 3 (a) 所示，SkySense V2 在各种模态下均持续优于 SkySense，展现出更强的表示能力。此外，融合多种模态的表现优于单一模态，这一结果证实了所提出的 SkySense V2 能够通过统一的骨干网络有效从多样化模态中提取表示。

Task & Dataset	Data Source	SkySense[24]	SkySense V2
(a) Multi-modal Seg: Dyna.-MM	(i) Planet.	46.5	47.6
	(ii) S2	46.2	47.5
	(iii) Planet. + S2	47.3	48.7
	(iv) Planet. + S2 + S1	47.7	48.9
(b) Multi-modal Seg: PASTIS-MM	(i) S2	73.5	75.0
	(ii) S2-Ts	84.6	85.5
	(iii) S2-Ts + S1-Ts	84.8	85.6
	(iv) S2-Ts + GEP	85.8	86.7
(c) Multi-modal Cls: BEN-MM	(i) S1	86.2	86.5
	(ii) S2 + S1	92.2	93.8

表 3. 多模态任务上的微调结果。

PASTIS-MM 是一个作物制图数据集，包含来自 Google Earth Pro (GEP) 的高分辨率光学影像、来自 Sentinel-2 (S2-Ts) 的多时相多光谱影像以及来自 Sentinel-1 (S1-Ts) 的多光谱 SAR 影像。我们采用一个

简单的全连接网络（FCN）头来解码语义分割结果，并在表 3 (b) 中以整体准确率作为评估指标。结果显示，SkySense V2 相较于之前的 SOTA 方法 SkySense 平均提升了 1.0%。此外值得注意的是，与仅使用 S2 影像相比，S2-Ts 显著提高了分割准确率，凸显了时间信息在作物制图中的重要性。

多模态场景分类 我们在 BEN-MM 数据集上进行了多模态场景分类实验 [63]。如表 3 (c) 所示，所提出的 SkySense V2 优于 SkySense，展现出更强的表示能力。此外，通过融合 S1 和 S2 影像，SkySense V2 取得了更高的提升，凸显了其相较于 SkySense 在从不同模态中提取更优表示方面具有更强的能力。

4.4. 消融与讨论

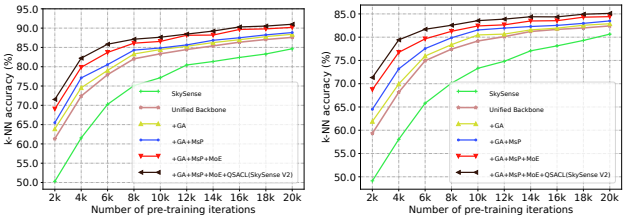

(a) AID 数据集 (b) RESISC-45 数据集

图 7. 在 AID 和 RESISC-45 数据集上，采用 k-NN 分类进行了消融实验。在此背景下，各缩写含义如下：GA 指在最后两个阶段用全局自注意力替换基于窗口的自注意力；MsP 表示添加模态特定的提示 token；MoE 表示通过混合专家模型方法扩大模型规模；QSACL 意为增加基于查询的语义聚合对比学习。

组件消融研究。 为了理解各个组件的贡献，我们在 AID 和 RESISC-45 数据集上进行了 K 近邻（k-NN）评估。图7展示了不同组件组合在各种预训练迭代下的性能表现。值得注意的是，统一的主干网络设计显著加速了表示学习。这主要是因为不同模态间共享参数，使得梯度能够聚合，从而加快收敛速度。此外，统一的设计允许主干网络使用来自不同模态的数据进行训练，从而增强了模型的泛化能力（详见附录 F.3）。结果还表明，全局自注意力与基于窗口的自注意力相互补充，有助于生成更优的表示。同时，模态特定的提示 token 和 MoE 缩放分别通过增加特征多样性与模型容量来提升表示学习效果。QSACL 通过提高对比学习中特征的语义准确率，进一步提升了模型性能。

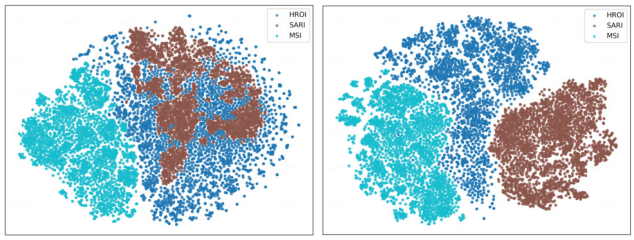

(a) 无特定模态提示 (b) 带模态特定提示

图 8. 统一 Transformer 主干网络最后一块输出特征表示的 t-SNE 可视化。HROI、SARI 和 MSI 分别代表高分辨率光学遥感影像、合成孔径雷达影像和多光谱影像的特征。

模态特定提示 token 如何促进预训练？ 为了探究模态特定提示（MsP）token 对统一骨干网络中多模态预训练过程的影响，我们采用 t-SNE [69] 对不同模态对应的特征进行可视化。这些特征从统一 Transformer 骨干网络的最后一块中提取，对比结果如图 8 所示。在未使用 MsP 的情况下，高分辨率光学影像（HROI）与合成孔径雷达影像（SARI）的特征呈现出紧密聚集的状态，导致特征分布重叠。然而，在引入 MsP 后，HROI 与 SARI 的特征变得明显可分离。这些可视化结果清晰地表明，MsP 有效增强了特征多样性，并赋予了模态特定的特征。

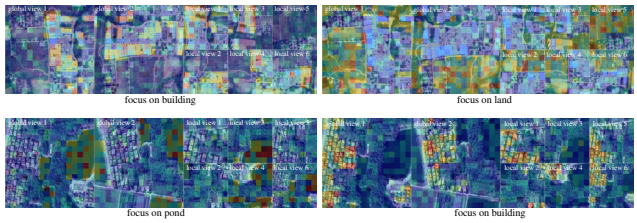

图 9. QSACL 中不同查询对应特征块的交叉注意力权重可视化。查询能够有效聚合具有特定语义的特征。

基于查询的语义聚合对比学习捕捉哪些类型的特征？ 为了更清晰地理解我们提出的 QSACL，我们可视化了在与特定查询交互时不同特征所分配的注意力权重，如图9所示。在预训练阶段，我们使用两个全局增强图像块和六个局部增强图像块。这里，我们展示了两个不同的查询，每个查询都关注图像块的不同语义特征。例如，一个查询关注具有建筑语义的特征（图9第一行左侧部分），而另一个查询关注具有土地语义的特征（图9第一行右侧部分）。不同查询的注意力权重将每个图像块的

特征聚合为不同的特征表示。随后，我们在教师模型和学生模型中对同一查询的聚合特征进行对比学习。相比传统对比学习应用于整个图像特征的方法，该方法显著提升了语义准确率。

5. 结论

本文介绍了 SkySense V2，一种采用统一主干网络以适应多种模态的多模态遥感特征提取模型（MM-RSFM）。该统一方法提升了参数利用效率，并增强了模型的泛化能力。SkySense V2 采用创新的 QSACL 策略进行预训练，专门针对遥感图像的独特特性进行了优化。因此，SkySense V2 在保持前代模型 SkySense 多模态灵活性优势的同时，显著提升了性能。展望未来，我们的工作将聚焦于融合语言模态，并引入地理知识图谱，以构建更强大且通用的多模态遥感特征提取模型。

A. 预训练模块 & 损失

A.1. 多粒度对比学习

我们实现了 SkySense[24] 提出的多粒度对比学习方法，用于跨多个模态和空间粒度的自监督学习。给定输入集 $\{x_{HR}, x_{MS}, x_{SAR}\}$ ，通过随机增强生成两组独立的增强视图，分别表示为 $\{u_i\}$ 和 $\{v_i\}$ ，其中 $i \in \{HR, MS, SAR\}$ 。这些视图 u_i 和 v_i 分别输入到学生分支和教师分支中。在学生分支中，令 $\mathcal{T}_i$ 表示各模态的 tokenizer，$\mathcal{U}$ 为 SkySense V2 的统一 Transformer 主干网络。教师分支的权重由学生分支权重的指数移动平均（EMA）计算得到：$\mathcal{T}_i' = EMA(\mathcal{T}_i)$ ，$\mathcal{U}' = EMA(\mathcal{U})$ s。该过程生成如公式 6 所述的空间特征：

$$F_i = \mathcal{U}(\mathcal{T}_i(u_i)), F_i' = \mathcal{U}'(\mathcal{T}_i'(v_i)) \;\; i \in \{HR, MS, SAR\}. \tag{6}$$

通过应用多模态时间融合与地理上下文集成 [24] 到 F_i 和 F_i'，我们获得了最终的特征 F_{fus} 和 F_{fus}'。随后，我们启动像素级、对象级和图像级对比学习，以逐步获取从粗到细的空间特征，适用于各种任务。

像素级损失。 每个空间特征的时序切片 F_i 可以看作是一个像素级特征 $F_i^{\text{pix}} \in \mathbb{R}^{N_S \times d}$。像素级对比学习损失，记为 $\mathcal{L}_{\text{pix}}$，通过对所有 $\mathcal{L}_{CL}$ 在空间（s）和时间（t）维度上的平均来计算，如公式 7 所示。其中，$f_i^{\text{pix}} \in \mathbb{R}^d$ 表示特定位置处来自 F_i^{pix} 的特征向量，$f_i^{\text{pix}\prime}$ 为其在同一地理位置的对应特征。$\mathcal{L}_{CL}$ 表示 f_i^{pix} 与 $f_i^{\text{pix}\prime}$ 之间的学习损失 [7]：

$$\mathcal{L}_{\text{pix}}(F_i, F_i') = \frac{1}{N_S T_i} \sum_s \sum_t \mathcal{L}_{CL}(f_i^{\text{pix}}, f_i^{\text{pix}\prime}). \tag{7}$$

对象级别的损失。 对象级特征 $F_i^{\text{obj}} \in \mathbb{R}^{N_C \times d}$ 从单幅 RSI 的像素级特征向量 f_i^{pix} 的无监督聚类中生成，其中 N_C 为簇的数量。为了进行聚类，我们采用 Sinkhorn-Knopp 算法 [6]，如文献 [24] 中所述。每个簇中心记作 $f_i^{\text{obj}} \in \mathbb{R}^d$ ，作为一组 f_i^{pix} 的泛化表示。该簇中心通常对应于特定的地物对象或语义概念。我们按如下方式计算对象级对比学习损失：

$$\mathcal{L}_{\text{obj}}(F_i, F_i') = \frac{1}{N_C T_i} \sum_s \sum_t \mathcal{L}_{CL}(f_i^{\text{obj}}, f_i^{\text{obj}\prime}). \tag{8}$$

图像级别损失。 图像级特征 $F_i^{\text{img}} \in \mathbb{R}^d$ 仅是来自 F_i^{pix} 的平均池化结果。图像级对比学习损失定义如下：

$$\mathcal{L}_{\text{img}}(F_i, F_i') = \frac{1}{T_i} \sum_t \mathcal{L}_{CL}(F_i^{\text{img}}, F_i^{\text{img}\prime}). \tag{9}$$

最后，细粒度对比学习损失 $\mathcal{L}_{FGCL}$ 是像素级、对象级和图像级对比学习损失的总和，如公式 10 所述。随后，我们如公式 11 所示提出了多模态损失 $\mathcal{L}_{MGCL}$。多粒度概念体现在两个主要维度：空间和模态。从空间角度来看，对比学习在像素、对象和图像级别上执行，从而实现全面捕捉不同空间维度的表示学习。从模态角度来看，我们在单个模态的特征上进行对比学习，记为 F_i，以及在融合的多模态特征上进行对比学习，表示为 F_{fus}。

$$\mathcal{L}_{FGCL}(F_i, F_i') = \sum_{n \in \{\text{pix,obj,img}\}} \mathcal{L}_n(F_i, F_i'), \tag{10}$$

$$\begin{aligned} \mathcal{L}_{MGCL} = & \sum_{i \in \{HR, MS, SAR\}} \mathcal{L}_{FGCL}(F_i, F_i') \\ & + \mathcal{L}_{FGCL}(F_{\text{fus}}, F_{\text{fus}}'). \end{aligned} \tag{11}$$

A.2. 稠密图像-文本对齐

除了 $\mathcal{L}_{MGCL}$ 和 $\mathcal{L}_{QSACL}$ 损失之外，我们引入了一种使用开放街图（OpenStreetMap，OSM）的辅助监督策略[2] 以增强稠密解释能力。OSM 是一个开源的全

[2]https://www.openstreetmap.org/

球尺度数据库，提供像素级的地表覆盖和用地类别。对于多模态输入图像，我们首先收集相应的像素级 OSM 标签。每个像素的类别名称通过 CLIP [54] 文本编码器转换为文本表示，并将其视觉表示与该文本表示对齐。我们的实验表明，这种稠密的图像-文本对齐能够促使 SkySense V2 学习到稠密且具备语义感知能力的表示。

具体而言，假设 OSM 的类别集包含 K 个类别，我们首先使用 CLIP 文本编码器将所有类别名称编码为文本表示 $F^{text} \in \mathbb{R}^{K\times D}$ ，其中 D 表示特征维度数。给定由 SkySense V2 主干网络提取的视觉特征 $F \in \mathbb{R}^{N\times D}$ ，我们最大化每个像素的视觉特征与其对应文本特征之间的相似度，同时最小化与不匹配文本特征之间的相似度。稠密的图像-文本对齐损失 $\mathcal{L}_{ITA}$ 因此被表述为

$$\mathcal{L}_{ITA} = -\frac{1}{n}\log(\sum_{i\in n}\frac{\exp(F_i * F_j^{text}/\tau)}{\sum_{k=1}^{K}\exp(F_i * F_k^{text}/\tau)}), \quad (12)$$

其中 j 表示第 i 个视觉特征的标签索引，τ 是控制 Logit 平滑度的温度参数。通过如公式 Eq. 12 所述，对每个像素的视觉和文本表示进行对齐，SkySense V2 能够生成对输入图像更细粒度的解释。

A.3. 无监督地理上下文原型学习

不同区域具有独特的地理景观特征 [29, 30]，这些特征受文化、地形和气候差异的影响。SkySense [24] 已证明，这种区域地理上下文有助于遥感影像的解释 [11, 23, 30, 40]。沿用 SkySense [24] 的方法，我们采用无监督地理上下文原型学习（GCPL）来对相似的 $F_{\text{fus}}^{\text{mm}}$ 进行分组。这些特征被整合为广泛地理空间范围内的隐式地理知识，以增强预训练阶段的原始特征。具体而言，我们将全球划分为 N_R 个区域，并初始化一个区域特定的原型集 $\mathcal{P} \in \mathbb{R}^{N_R\times N_p\times d}$。每个原型基于 $F_{\text{fus}}^{\text{mm}}$ 学成。我们利用遥感影像的地理定位信息，从 $\mathcal{P}$ 中检索出对应的区域子集 $\mathcal{P}_r \in \mathbb{R}^{N_p\times d}$。然后，我们计算 $F_{\text{fus}}^{\text{mm}}$ 与 $\mathcal{P}_r$ 之间的余弦相似度矩阵 $\mathrm{M} \in \mathbb{R}^{N_S\times N_p}$：

$$\mathrm{M} = \frac{F_{\text{fus}}^{\text{mm}} \cdot \mathcal{P}_r^{\mathrm{T}}}{\|F_{\text{fus}}^{\text{mm}}\|\|\mathcal{P}_r\|}. \quad (13)$$

Sinkhorn-Knopp (SK) 算法 [6] 在 M 上被用于寻找 $F_{\text{fus}}^{\text{mm}}$ 与原型之间的最优分配矩阵 $\mathrm{S} \in \mathbb{R}^{N_S\times N_p}$。SK 算法引入了均匀分布约束，以避免平凡解，同时力求实现尽可能高的相似度。随后，我们利用 S 来生成当前样本对应 $\mathcal{P}_r$ 的更新值，记为 $\overline{\mathcal{P}_r}$。该过程详细如下：

$$\overline{\mathcal{P}_r} = \mathrm{S}^{\mathrm{T}} F_{\text{fus}}^{\text{mm}}. \quad (14)$$

之后，我们通过指数移动平均（EMA） [27] 更新 $\mathcal{P}_r$，如公式 15 所示，其中 $m \in [0, 1)$ 为动量系数。

$$\mathcal{P}_r \leftarrow m\mathcal{P}_r + (1-m)\overline{\mathcal{P}_r}. \quad (15)$$

每个 $\mathcal{P}_r$ 在预训练期间被更新，并在下游任务中作为固定的地理上下文。GCPL 仅应用于学生分支，从同一区域内的大量 RSI 中提取泛化的区域感知表示。这为增强单个 RSI 的特征提供了互补信息。

B. SkySense V2 的下游应用

预训练完成后，我们使用教师分支的参数进行下游任务，如图 10 所示。每个预训练模块可独立使用或与其他模块组合使用，所选模块可被冻结或微调。对于单模态静态下游任务，我们保留统一的 Transformer 主干网络，并激活特定的分词器。此外，我们添加一个针对特定任务设计的任务专用头部。在单模态时间下游任务中，我们引入预训练的融合 Transformer 来处理来自单一模态的时间序列特征数据。该融合 Transformer 能够整合时间信息，使模型能够捕捉随时间变化的动态模式与趋势，这对于作物识别或变化检测等应用至关重要。对于多模态下游任务，融合 Transformer 被用于整合不同模态的特征。这种整合同时考虑了模态特异性与时间特性，使模型能够利用来自多种数据源的互补信息。通过融合多模态数据，SkySense V2 提升了执行需要综合多样化信息的复杂任务的能力。这种灵活性确保 SkySense V2 可有效应用于广泛的下游应用场景，在保持高性能的同时适应不同的任务需求。

C. 预训练实现细节

SkySense V2 采用批量大小为 1024 的预训练，分布在 128 块 H20 GPU 上。模型总共进行 600k 迭代，使用 AdamW 优化器 [46]，其中 $\beta_1 = 0.9, \beta_2 = 0.999$。学习率初始设置为 2×10^{-4}，按照余弦退火调度 [45] 降低至 1×10^{-6}。同样，权重衰减也遵循余弦调度，从 0.04 开始增加至 0.2。此外，为保持训练稳定，所有参数的梯度被裁剪至 L_2 范数 3.0。教师网络在 EMA 更新中的动量初始值为 0.996，并按余弦调度衰减至 1.0。损失 $\mathcal{L}_{MGCL}, \mathcal{L}_{QSACL}, \mathcal{L}_{ITA}$ 的损失权重设置为：

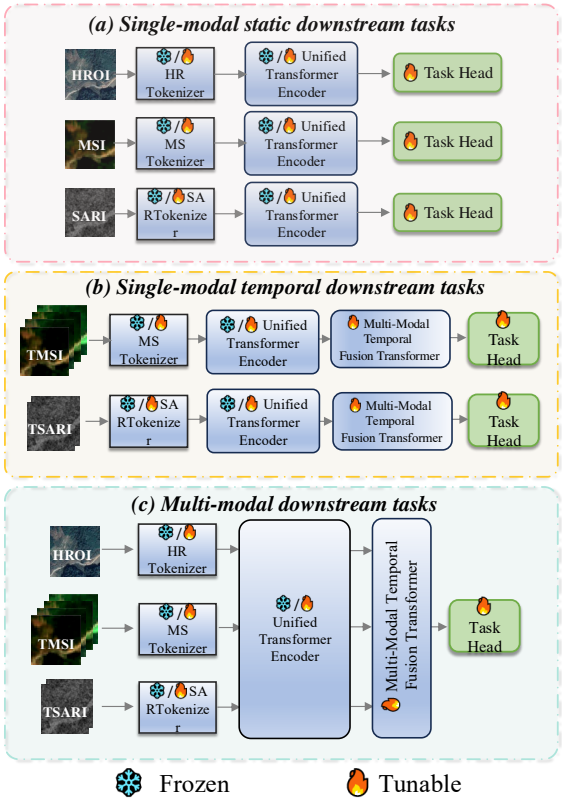

图 10. SkySense V2 下游应用概览。每个预训练模块可独立使用或组合使用，并可根据具体下游任务需求选择冻结或微调选定的模块。

$\lambda_1 = 1.0, \lambda_2 = 1.0, \lambda_3 = 1.0$。MoE 辅助损失的权重设置为 0.01。QSACL 的查询数量设置为 16。整个预训练过程耗时 44500 小时的 H20 GPU，其计算复杂度为 8109.52 GFLOPs。

对于高分辨率光学影像（HROI），我们应用包括高斯模糊、太阳化 [22]、随机颜色抖动、随机翻转和随机旋转在内的数据增强。对于多光谱影像（MSI）和合成孔径雷达影像（SARI）时序数据，我们从原始序列中随机选取固定大小的片段（MSI 为 20 个，SARI 为 10 个），并对 RSI 获取日期施加随机扰动。我们遵循 [6, 24] 中的全局与局部多视角裁剪策略，分别使用 2 个全局视图和 6 个局部视图。

在 SkySense[24] 的基础上，多模态时间融合 Transformer 模块包含 24 个基本 Transformer 编码器层。此外，采用单个基本 Transformer 解码器层进行基于查询的语义聚合对比学习。对于 GCPL，地球被划分为 4096 个区域，每个区域覆盖约 4294 平方公里，包含 100 个原型。

Dataset	Dyna.-Pla.	iSAID	Potsdam	Dyna.-S2
Activated modality	HR	HR	HR	MS
Optimizer	AdamW	AdamW	AdamW	AdamW
Input size	1024×1024	896×896	512×512	256×256
Input channel	RGBNIR	RGB	NIRRG	B02-08, B8A, B11-12
Base lr.	1e-4	1e-4	1e-4	1e-4
Lr. scheduler	poly	poly	poly	poly
Weight decay	0.01	0.01	0.01	0.01
Layer-wise lr decay	0.8	0.8	0.8	0.8
Max iters.	80k	80k	80k	80k
Warmup	linear	linear	linear	linear
Warmup iters.	1.5k	1.5k	1.5k	1.5k
Warmup ratio	1e-6	1e-6	1e-6	1e-6
Drop path rate	0.2	0.2	0.2	0.2
Augmentations				
RandomScaling		✓	✓	
RandomCrop	✓	✓	✓	✓
RandomFlip	✓	✓	✓	✓

表 4. 单模态语义分割任务中的微调情景。随机缩放的极小值和极大值分别为 0.5 和 2.0，随机翻转的概率为 0.5。

D. 下游任务训练实施细节

D.1. 语义分割

语义分割在遥感中被广泛用于自动提取土地利用类别和地面实例。考虑到空间分辨率、光谱特征以及类别数量等因素，我们选取了四个流行的语义分割数据集：DynamicEarthNet-PlanetFusion（Dyna.-Pla.）[67]、iSAID [76]、Potsdam [61] 以及 DynamicEarthNet-Sentinel2（Dyna.-S2）。我们采用 UperNet [80] 作为统一的分割头，其基于 MMSegmentation 实现。[3]，与 [8, 64, 70] 的方法一致。详细的微调设置见表 4。

D.2. 水平 & 方向性目标检测

遥感图像包含多种多样的目标，包括建筑物、车辆、桥梁等。这些目标分布稠密，且在大小、尺度和方

[3] https://github.com/open-mmlab/mmsegmentation

Dataset	DIOR	DIOR-R	FAIR1M
Activated modality	HR	HR	HR
Optimizer	AdamW	AdamW	AdamW
Input size	800×800	800 ×800	512×512
Input channel	RGB	RGB	RGB
Base lr.	8e-5	8e-5	8e-5
Lr. scheduler	multistep	multistep	multistep
Layer-wise lr decay	0.85	0.85	0.85
Weight decay	0.05	0.05	0.05
Max epoch	12	12	8
Warmup	linear	linear	linear
Warmup iters.	1k	1k	0.5k
Warmup ratio	1e-3	1e-3	1e-3
Drop path rate	0.2	0.2	0.2
Augmentations			
RandomFlip	✓	✓	✓
RadnomRotate			✓
Head	Faster RCNN	Oriented RCNN	Oriented RCNN

表 5. 目标检测任务中的微调情景。随机翻转的概率为 0.5。

Dataset	LEVIR-CD	OSCD	Dyna.-S2
Activated modality	HR	MS	MS
Optimizer	AdamW	AdamW	AdamW
Input size	256×256	96 ×96	256×256
Input channel	RGB	B02-08, B8A, B11-12	B02-08, B8A, B11-12
Base lr.	6e-5	6e-4	1e-4
Lr. scheduler	LambdaLR	ExponentialLR	poly
Layer-wise lr decay	0.9	0.9	0.8
Weight decay	0.01	1e-4	0.05
Max iters./epoch	200 epochs	100 epochs	80k iters
Warmup	-	-	linear
Warmup iters.	-	-	1.5k
Warmup ratio	-	-	1e-6
Drop path rate	0.2	0.2	0.2
Augmentations			
RandomCrop	✓		✓
RandomFlip	✓	✓	✓
Head/Detector	BIT	U-Net	UperNet
Loss	CrossEntropy	BCE	CrossEntropy

表 6. 变化检测任务中的微调情景。随机翻转的概率为 0.5。

向上差异显著，使得其检测与识别成为一项具有挑战性的任务 [77]。为了评估 RSFMs 在定向目标检测中的有效性，我们采用 DIOR-R 和 FAIR1M 数据集，并以定向 RCNN [37] 作为检测算法，与先前的研究保持一致 [8, 24, 64, 70]。为评估 SkySense V2 在水平目标检测方面的能力，我们使用 DIOR 数据集。按照 [24, 64] 的方法，我们采用 Faster RCNN [56] 作为检测器。更多细节见表 5。

D.3. 变化检测

变化检测专注于利用双时相或多时相影像识别像素级区域变化。在 Sun 等人的工作 [64] 基础上，我们将多种 RSFM 的主干网络引入到 BIT 框架 [10] 中，以评估其在 LEVIR-CD 数据集上的模型性能。遵循先前的方法 [24, 48, 49]，我们采用 U-Net[58] 作为分割头，利用多光谱影像的 OSCD 数据集来评估 RSFM 在双时相变化检测任务中的有效性。此外，我们使用 DynamicEarthNet-Sentinel2 数据集评估模型在语义变化检测任务中的表现，保持与分割任务相同的配置。更多情景详见第6节。

D.4. 场景分类

我们选择了两个广泛使用的单标签场景分类数据集：AID 和 NWPU-RESISC45。此外，我们还利用了一个多标签多光谱场景分类数据集 BigEarthNet-Sentinel2，以及一个时序多光谱场景分类数据集 fMoW-Sentinel2。AID 和 NWPU-RESISC45（RESISC-45）数据集包含高分辨率光学图像，而 BigEarthNet-Sentinel2（BEN-S2）和 fMoW-Sentinel2（fMoW-S2）则是大规模多光谱图像数据集。我们的场景分类实验采用标准的线性分类器进行。详细的实现设置见表 7。

D.5. 多模态语义分割

通过整合来自多种传感器、成像技术、分辨率和光谱波段的多源数据，我们可以提取出更丰富且更具区分性的特征。这些特征有助于更好地理解地表物体的形状、大小及其相互关系。为评估时间无关的土地覆盖制图任务和时间相关的作物制图任务，我们分别使用 DynamicEarthNet-MM（Dyna.-MM）数据集和

Dataset	AID	RESISC-45	BEN-S2	fMoW-S2
Activated modality	HR	HR	MS	MS
Optimizer	AdamW	AdamW	AdamW	AdamW
Input size	320×320	320×320	128×128	96×96
Input channel	RGB	RGB	B02-08, B8A, B11-12	B02-08, B8A, B11-12
Base lr.	6e-5	6e-5	5e-5	8e-4
Lr. scheduler	cosine	cosine	multistep	cosine
Weight decay	0.05	0.05	0.01	0.05
Layer-wise lr decay	0.9	0.9	0.9	0.9
Max epoch	200	200	100	30
Warmup	linear	linear	-	linear
Warmup epoch	5	5	-	5
Warmup ratio	0.01	0.01	-	0.2
Drop path rate	0.2	0.2	0.2	0.2
Augmentations				
RandomErasing	✓	✓		
RandomCrop	✓	✓		✓
Mixup				✓
RandomFlip	✓	✓	✓	✓

表 7. 单模态语义分割任务中的微调情景。随机擦除的最小和最大面积比分别为 0.03 和 0.333，随机擦除的概率为 0.3。Mixup 比例和概率分别为 0.8 和 1.0。随机翻转的概率为 0.5。

PASTIS-MM 数据集。

Dyna.-MM　包含空间和时间对齐的多模态数据，其中包括来自 DynamicEarthNet-PlanetFusion 数据集的 PlanetFusion 影像、来自 DynamicEarthNet-Sentinel2 数据集的 Sentinel-2 多光谱影像以及 Sentinel-1 SAR 影像。对于 SAR 数据，我们使用经过标准校准的 Sentinel-1 GRD 数据，包含 VV 和 VH 极化信息，并根据光学影像的地理坐标进行选取。这一方法与 SkySense [24] 一致，确保了多模态实验的有效性。在分割任务中，采用 UperNet 作为分割头，并报告平均交并比（mIoU）指标。更多实现细节可参见表 8 (i)。

PASTIS-MM　[21, 24] 是一个源自 SkySense[24] 的数据集，专为细粒度、时间敏感的作物制图而设计。该数据集在 PASTIS-R 数据集 [21] 的基础上，增加了空间对齐的高分辨率 RGB 图像。PASTIS-MM 旨在探讨高分辨率光学影像、中等分辨率时序多光谱数据以及时序合成孔径雷达（SAR）数据在时间敏感作物制图中的综合影响。该数据集基于原始 PASTIS-R 数据集图像块的地理坐标和获取日期进行采集，数据来源为 [24]。PASTIS-MM 包含 2433 个 Sentinel-2 图像块，每个图像块的尺寸为 128×128 像素，具有 10 个光谱波段，地面采样距离（GSD）为 10 米。对于每个图像块，数据集包含 2018 年 9 月至 2019 年 11 月期间所有可用的 Sentinel-2 和 Sentinel-1 获取数据，以及额外的高分辨率可见光影像。在分割任务中，我们采用简单的全卷积网络（FCN）头 [44]，并基于数据集官方的五折交叉验证报告总体准确率（OA）。更多实现细节可参见表 8 (ii)。

D.6. 多模态场景分类

遵循 SkySense [24]，我们采用具有代表性的 BigEarthNet-MM (BEN-MM) 数据集来评估 SkySense V2 在大规模场景分类任务中的性能，重点关注光学数据与 SAR 数据的融合。该数据集在 BigEarthNet-Sentinel2 数据集的基础上增加了对应的 Sentinel-1 SAR 数据，从而能够利用多光谱（MS）和 SAR 模态对多标签场景分类进行评估。BEN-MM 为 BigEarthNet-Sentinel2 数据集中的每个 Sentinel-2 图像块补充了在同一时间附近获取的预处理 Sentinel-1 图像块。每个 Sentinel-1 图像块保留其对应 Sentinel-2 图像块的标注信息，并具有 10 米的地面采样距离（GSD）。这些图像块提供双极化信息通道（VV 和 VH），并以干涉宽幅模式（interferometric wide-swath mode）采集。与先前研究 [20, 24, 72, 73] 保持一致，我们沿用 BigEarthNet-Sentinel2 数据集中所采用的数据划分方式。更多实现细节见表 8 (iii)。

Task	(i) Multi-Modal Segmentation: Time-insensitive LandCover Mapping	(ii) Multi-Modal Segmentation: Time-sensitive Crop Mapping	(iii) Multi-Modal Classification
Dataset	Dyna.-MM	PASTIS-MM	BEN-MM
Optimizer	AdamW	AdamW	AdamW
Input Size	planet: 1024×1024 sentinel2: 1024×1024 sentinel1: 1024×1024	gep: 4096×4096 sentinel2: 128×128 sentinel1: 128×128	sentinel2: 128×128 sentinel1: 128×128
Input channel	planet: RGBNIR sentinel2: B02-08, B8A, B11-12 sentinel1: VV, VH	gep: RGB sentinel2: B02-08, B8A, B11-12 sentinel1: VV, VH	sentinel2: B02-08, B8A, B11-12 sentinel1: VV, VH
Base learning rate	6e-05	6e-05	5e-05
Learning rate scheduler	linear	linear	MultiStepLR
Weight decay	0.01	0.01	0.01
Batch size	8	8	256
Max iteration/epoch	6k iters	20k iters	100 epoch
Warmup	linear	linear	-
Warmup iteration/epoch	150 iters	1500 iters	-
Warmup ratio	1e-6	1e-6	-
Drop path rate	0.2	0.2	0.2
Augmentation	RandomFlip	RandomFlip	RandomFlip
Head/Detector	UperNet	FCN	Linear Classifier
Loss function	CrossEntropy	CrossEntropy	MultiLabel SoftMargin

表 8. 多模态下游任务中的微调情景。

E. 与 SkySense 的参数数量对比

Model Name	SkySense	SkySense V2 w/o MoE	SkySense V2
Tokenizer	0.21M HR: 0.02 MS: 0.16 SAR: 0.03	0.09M HR: 0.02 MS: 0.06 SAR: 0.01	0.09M HR: 0.02 MS: 0.06 SAR: 0.01
Backbone	1260.31M HR: 655.17 MS: 302.57 SAR: 302.57	661.40M	1994.10M
Modality prompt	-	9.94M	9.94M
Fusion module	398.20M	347.01M	347.01M
Others	404.13M	490.49M	490.49M
Total	2062.85M	1508.93M	2841.63M

表 9. SkySense V2 与 SkySense 不同模块参数数量的对比。

SkySense [24] 采用了三种不同的主干网络：Swin-H 用于高分辨率（HR）光学数据，ViT-L 用于多光谱（MS）数据，以及 ViT-L 用于合成孔径雷达（SAR）数据。在 SkySense V2 中，主干网络的参数在不同模态间共享，仅保留少量分离的参数用于模态特定的 tokenizers 和 prompts。详细对比见表 9。通过采用这一统一设计，三种模态的主干网络参数总数从 1,260 百万减少至 661 百万。此外，我们引入了混合专家模型（MoE）方法 [33]，使得参数总量可扩展至 1,994 百万（其中激活参数为 661 百万）。总而言之，我们的统一 Transformer 主干网络在不同模态间实现了完整的参数共享，具有以下几项关键优势：1）如论文消融部分所述，这种参数共享能够聚合来自所有模态的梯度，从而加速收敛过程。2）显著提升了参数利用效率，为通过引入 MoE 模块增加额外容量提供了充足空间，进一步增强了表示学习能力。3）我们的统一模型架构与完全的参数共享简化了不同模态间特征对齐的过程。

F. 实验

F.1. 图像-文本对齐在 OSM 中的影响

OpenStreetMap 是一个全球性的开源数据源，提供了丰富的语义类别。我们利用 CLIP 文本编码器 [54] 将类别转换为文本表示，并进一步应用稠密图像-文本对齐（ITA）以增强预训练模型在稠密理解任务中的能力。为了验证该方法的有效性，我们在分割数据集 iSAID 和 Potsdam 上进行了消融实验。由于整个预训练过程资源消耗较大，我们通过将迭代次数限制在 20,000 次来确保对比的公平性。微调过程与第 D.1 节中所述方法保持一致。实验结果如表 10 所示，表明图像-文本对齐能够有效提升稠密任务的性能。

Dataset	iSAID	Potsdam
w/o ITA	67.45	88.77
w/ ITA	68.24	90.05

表 10. SkySense V2 中图像-文本对齐的消融实验结果。

F.2. 自适应块合并所得不同分辨率的特征

我们的自适应块合并（APM）模块集成在统一主干网络的每个阶段之后，能够根据具体需求灵活生成不同分辨率的特征。为了评估 APM 中不同下采样活性条件的影响，我们在 iSAID 和 Potsdam 分割数据集上进行了消融实验。微调过程与第D.1节所述方法保持一致，所有模型均使用同一预训练模型的参数。如表 11所示，通过 APM 生成更高分辨率的特征能够提升模型性能。这一改进使得模型在具备充足计算资源的环境中部署时尤为有利。

Sub-sampling activation of APM			downscale	Dataset	
Stage 2	Stage 3	Stage 4		iSAID	Potsdam
✓	✓	✓	1/8	71.87	95.86
✓	✓		1/4	71.92	95.85
✓			1/2	72.55	96.76
			–	72.88	97.03

表 11. APM 内不同下采样激活条件的实验结果。所有模型均使用相同的参数初始化，仅在 APM 中的下采样激活策略上有所不同。

F.3. 训练以外的传感器数据表现

为了进一步验证预训练模型的泛化能力，我们在三个来自不同传感器的数据集上进行了实验：来自高分二号卫星的五亿像素（FBP）[68]、来自陆地卫星八号的 SPARCS [31]，以及来自高分三号卫星的 AIR-PolSAR-Seg（APS）[74]。所有这些数据集所使用的传感器均与训练数据中的传感器不同。FBP 包含超过 50 亿个标注像素，分布在 150 张高分辨率图像中，被标注为 24 个类别，涵盖人工构造、农业和自然类。SPARCS 包含 80 张图像，分辨率为 1000×1000 像素，标注为 7 个类别。APS 包含一幅极化合成孔径雷达（PolSAR）图像，其区域大小为 9082×9805 像素，并包含 2000 个图像块，每个图像块大小为 512×512 像素。这三组数据集上的实验结果如表 12所示。SkySense V2 在 mIoU 上平均比 SkySense 高出 1.8%，表明 SkySense V2 具有更强的泛化能力。我们将其归因于统一的设计，该设计使得主干网络参数能够利用不同模态的数据进行训练，从而有效提升了模型的泛化能力。

Dataset	Sensor	SkySense	SkySense V2
Five-Billion-Pixels	Gaofen-2	65.31	66.82
SPARCS	Landsat-8	72.57	74.32
AIR-PolSAR-Seg	Gaofen-3(SAR)	53.21	55.32

表 12. 来自不同传感器构建的数据集上的结果。评估指标为 mIoU。

F.4. 下游任务中模态特异性提示 token 的消融实验

在对模型进行预训练后，下游微调过程中处理模态特定提示 token（MSPT）有两种选择：1）保留 MSPT，或 2）完全移除 MSPT。我们在这两种不同情景下评估了 MSPT 的影响：1）单模态任务，其中仅激活一种模态；2）多模态任务，其中至少激活两种模态。对于单模态情景，我们使用 RESISC-45 和 BEN-S2 数据集进行了实验。对于多模态情景，我们采用了 BEN-MM 数据集。如表 13 所示，我们的研究结果表明，MSPT 能够显著提升多模态任务的性能，这主要归因于其能够增加不同模态特征的多样性。

F.5. 预训练中关于 MoE 的消融研究

为了快速评估 MoE 相关配置的影响，我们对每种配置均进行了 20,000 次迭代的预训练。预训练完成后，

Dataset	RESISC-45 (TR=10%)	BEN-S2 (TR=10%)	BEN-MM
Activated modality	HR	MS	MS,SAR
w/o MSPT	96.15	88.97	92.64
w/ MSPT	96.42	89.13	93.81

表 13. 模态特定提示 token 在下游任务中的消融实验结果。“TR”表示训练比例，代表训练数据占整个数据集的比例。

我们使用 k-NN 准确率在 AID 和 RESISC-45 数据集上对模型进行了评估。

专家人数的变化。 我们配置了具有不同专家数量的统一主干网络，以评估性能与参数大小的关系。如表 14 所示，随着专家数量的增加，模型的表示容量得到提升。尽管包含 16 个专家的配置优于 8 个专家的配置，但其额外增加了 16 亿参数。这一参数增长并未匹配性能的边际提升。因此，我们在 SkySense V2 模型中将专家数量设定为 8。

#experts	#parameters	AID	RESISC-45
4	1232.61M	89.05	82.57
8	1994.10M	91.00	85.11
16	3517.08M	91.23	85.97

表 14. MoE 中专家数量变化的消融实验结果。我们在 AID 和 RESISC-45 数据集上报告了 k-NN 分类准确率。

调整 MoE 块的数量。 遵循先前利用混合专家模型（MoE）[43, 78] 的方法，我们将 MoE 模块集成到最后的 L 个 Transformer 块中，替代原有的前馈网络（FFN）层。每个 MoE 模块包含 8 个专家，它们均保持 FFN 的结构设计，但作为独立网络运行。我们进行了消融实验，探究了在主干网络中不同数量的 MoE 块（$L = 2, 4, 6, 8$）的各种配置。如表 15 所示，结果表明性能在 6 个 MoE 块时趋于饱和。

探索骨干网络中 MoE 块的不同分布。 先前的研究 [43, 78] 通常将混合专家模型（Mixture of Experts, MoE）融入网络的最后几层。这种做法主要受到两个因素的驱动：1）更深层的路由决策与图像类别关联更

L	#parameters	AID	RESISC-45
2	1486.37M	89.63	83.45
4	1740.23M	90.14	84.37
6	1994.10M	91.00	85.11
8	2247.97M	91.11	85.43

表 15. 骨干网络中不同数量 MoE 块的消融实验结果。

为紧密，并包含更丰富的语义信息 [57]，以及 2）最后一层对分类性能的影响最为显著。然而，Swin-MoE 的官方实现 [32][4] 提出了一种替代策略，即在整个主干网络的所有层中均匀分布 MoE 块。我们在 SkySense V2 的主干网络中测试了这两种分布策略。我们的研究结果表明，尽管两种方法之间的性能差异微乎其微，但在最后几层中引入 MoE 块仍具有轻微优势，具体详见表 16。

MoE block(layer) index Total: 24	AID	RESISC-45
3,7,11, 15,19,23	90.93	84.87
18,19,20, 21,22,23	91.00	85.11

表 16. SkySense V2 主干中不同 MoE 分布策略的比较。

F.6. 关于 MoE 在下游任务中的消融研究

为了进一步探究 MoE，我们在预训练的 MoE 主干网络的下游微调阶段进行了消融实验。我们选取了 RESISC-45、BEN-S2 和 BEN-MM 数据集，这些数据集涵盖了三种模态：高分辨率（HR）、多光谱（MS）和合成孔径雷达（SAR）。首先，我们考察了在下游微调过程中是否固定路由门。如表 17 所示，尽管路由门在预训练阶段已使用大量数据进行训练，但针对特定任务的微调仍然是必要的。其次，我们通过随机保留 MoE 块中的一个专家而移除其余专家进行了实验，从而将 MoE 前馈网络（FFN）简化为普通的 FFN。该修改后模型的性能与未使用 MoE 的完整预训练主干网络相当，表明每个专家均已充分训练，并具备独立的表示能力。

[4] https://github.com/microsoft/Swin-Transformer

Dataset Activated modality	RESISC-45 (TR=10%) HR	BEN-S2 (TR=10%) MS	BEN-MM MS,SAR
SkySense V2	96.42	89.13	93.81
SkySense V2 w/o MoE	95.61	88.76	92.95
SkySense V2 fixed routing gate	95.73	88.65	92.80
SkySense V2 random 1 expert	95.47	88.69	92.81

表 17. MoE 在下游任务中的消融实验结果。“TR” 表示训练比例，代表训练数据占整个数据集的比例。

F.7. 基于查询的语义聚合对比学习中关于查询数量的消融研究

在基于查询的语义聚合对比学习（QSACL）的消融实验中，我们探究了不同 m 可学习查询的影响，这些查询用于聚合图像在多个增强视图下的不同语义特征。我们使用 20,000 次迭代进行模型预训练，并尝试了不同数量的查询。预训练完成后，我们使用 k-NN 准确率在 AID 和 RESISC-45 数据集上评估了模型性能。如表 18 所示，当查询数量较少时，例如 4 或 8 个，性能显著下降。这种下降是由于查询数量不足，无法充分捕捉图像内部的多样化语义类别，导致预训练效果不佳。相反，当 $m = 8$ 时，性能与 $m = 16$ 时相近，表明 16 个查询已足够捕捉图像中的不同语义，而增加更多查询对性能提升无明显帮助。

m	AID	RESISC-45
4	90.21	84.32
8	90.68	84.87
16	91.00	85.11
24	91.05	85.07

表 18. QSACL 中不同数量 MoE 可学习查询的消融实验结果。

F.8. 与随机初始化的比较。

在本节中，我们使用 SkySense 预训练权重和随机初始化权重，在三个数据集上对同一骨干网络进行微调，每个数据集对应一个不同的任务。这些任务包括使用 AID 数据集 [79] 进行场景分类、使用 DIOR 数据集 [36] 进行目标检测，以及使用 iSAID 数据集 [76] 进行语义分割。实验结果如表 19 所示，表明我们的预训练模型在所有三个数据集上均显著优于从零开始训练的模型。

Model	AID	DIOR	iSAID
	OA(TR=20/50%)	mAP_{50}	mIoU
Randm Init	66.82/90.78	56.36	48.34
SkySense V2	98.34/99.05	79.50	71.87

表 19. SkySense V2 与随机初始化的对比，以及 SkySense V2 与预训练的对比。

参考文献

[1] Peri Akiva, Matthew Purri, and Matthew Leotta. Self-supervised material and texture representation learning for remote sensing tasks. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 8203–8215, 2022.

[2] Guillaume Astruc, Nicolas Gonthier, Clement Mallet, and Loic Landrieu. AnySat: An Earth observation model for any resolutions, scales, and modalities. arXiv preprint arXiv:2412.14123, 2024.

[3] Kumar Ayush, Burak Uzkent, Chenlin Meng, Kumar Tanmay, Marshall Burke, David Lobell, and Stefano Ermon. Geography-aware self-supervised learning. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 10181–10190, 2021.

[4] Favyen Bastani, Piper Wolters, Ritwik Gupta, Joe Ferdinando, and Aniruddha Kembhavi. Satlaspretrain: A large-scale dataset for remote sensing image understanding. Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 16772–16782, 2023.

[5] Yinxia Cao, Xin Huang, and Qihao Weng. A multi-scale weakly supervised learning method with adaptive online noise correction for high-resolution change detection of built-up areas. Remote Sensing of Environment, 297:113779, 2023.

[6] Mathilde Caron, Ishan Misra, Julien Mairal, Priya Goyal, Piotr Bojanowski, and Armand Joulin. Unsupervised learning of visual features by contrasting

cluster assignments. Advances in neural information processing systems, 33:9912–9924, 2020.

[7] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In Proceedings of the IEEE/CVF international conference on computer vision, pages 9650–9660, 2021.

[8] Keumgang Cha, Junghoon Seo, and Taekyung Lee. A billion-scale foundation model for remote sensing images. arXiv preprint arXiv:2304.05215, 2023.

[9] Hao Chen and Zhenwei Shi. A spatial-temporal attention-based method and a new dataset for remote sensing image change detection. Remote Sensing, 12 (10):1662, 2020.

[10] Hao Chen, Zipeng Qi, and Zhenwei Shi. Remote sensing image change detection with transformers. IEEE Transactions on Geoscience and Remote Sensing, 60: 1–14, 2021.

[11] Wuyang Chen, Ziyu Jiang, Zhangyang Wang, Kexin Cui, and Xiaoning Qian. Collaborative global-local networks for memory-efficient segmentation of ultra-high resolution images. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 8924–8933, 2019.

[12] Gong Cheng and Junwei Han. A survey on object detection in optical remote sensing images. ISPRS journal of photogrammetry and remote sensing, 117:11–28, 2016.

[13] Gong Cheng, Junwei Han, and Xiaoqiang Lu. Remote sensing image scene classification: Benchmark and state of the art. Proceedings of the IEEE, 105 (10):1865–1883, 2017.

[14] Gong Cheng, Jiabao Wang, Ke Li, Xingxing Xie, Chunbo Lang, Yanqing Yao, and Junwei Han. Anchor-free oriented proposal generator for object detection. IEEE Transactions on Geoscience and Remote Sensing, 60:1–11, 2022.

[15] Yezhen Cong, Samar Khanna, Chenlin Meng, Patrick Liu, Erik Rozi, Yutong He, Marshall Burke, David Lobell, and Stefano Ermon. Satmae: Pre-training transformers for temporal and multi-spectral satellite imagery. Advances in Neural Information Processing Systems, 35:197–211, 2022.

[16] Timothée Darcet, Maxime Oquab, Julien Mairal, and Piotr Bojanowski. Vision transformers need registers. In The Twelfth International Conference on Learning Representations, 2024.

[17] Rodrigo Caye Daudt, Bertr Le Saux, Alexandre Boulch, and Yann Gousseau. Urban change detection for multispectral earth observation using convolutional neural networks. In IGARSS 2018-2018 IEEE International Geoscience and Remote Sensing Symposium, pages 2115–2118. Ieee, 2018.

[18] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929, 2020.

[19] William Fedus, Barret Zoph, and Noam M. Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. ArXiv, abs/2101.03961, 2021.

[20] Anthony Fuller, Koreen Millard, and James R. Green. Croma: Remote sensing representations with contrastive radar-optical masked autoencoders. Advances in Neural Information Processing Systems, 2023.

[21] Vivien Sainte Fare Garnot, Loic Landrieu, and Nesrine Chehata. Multi-modal temporal attention models for crop mapping from satellite time series. ISPRS Journal of Photogrammetry and Remote Sensing, 187:294–305, 2022.

[22] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Guo, Mohammad Gheshlaghi Azar, et al. Bootstrap your own latent-a new approach to self-supervised learning. Advances in neural information processing systems, 33:21271–21284, 2020.

[23] Shaohua Guo, Liang Liu, Zhenye Gan, Yabiao Wang, Wuhao Zhang, Chengjie Wang, Guannan Jiang, Wei Zhang, Ran Yi, Lizhuang Ma, et al. Isdnet: Integrating shallow and deep networks for efficient ultra-high resolution segmentation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 4361–4370, 2022.

[24] Xin Guo, Jiangwei Lao, Bo Dang, Yingying Zhang, Lei Yu, Lixiang Ru, Liheng Zhong, Ziyuan Huang, Kang

Wu, Dingxiang Hu, Huimei He, Jian Wang, Jingdong Chen, Ming Yang, Yongjun Zhang, and Yansheng Li. Skysense: A multi-modal remote sensing foundation model towards universal interpretation for earth observation imagery. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 27672–27683, 2024.

[25] Wang Haiyang, Tang Hao, Shi Shaoshuai, Li Aoxue, Li Zhenguo, Schiele Bernt, and Liwei Wang. Unitr: A unified and efficient multi-modal transformer for bird's-eye-view representation. In ICCV, 2023.

[26] Boran Han, Shuai Zhang, Xingjian Shi, and Markus Reichstein. Bridging remote sensors with multisensor geospatial foundation models. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 27852–27862, 2024.

[27] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 9729–9738, 2020.

[28] Danfeng Hong, Bing Zhang, Xuyang Li, Yuxuan Li, Chenyu Li, Jing Yao, Pedram Ghamisi, Naoto Yokoya, Hao Li, Xiuping Jia, Antonio Plaza, Paolo Gamba, Jon Atli Benediktsson, and Jocelyn Chanussot. Spectralgpt: Spectral remote sensing foundation model. IEEE Transactions on Pattern Analysis and Machine Intelligence, (8):5227–5244, 2024.

[29] Jingliang Hu, Lichao Mou, and Xiao Xiang Zhu. Unsupervised domain adaptation using a teacher-student network for cross-city classification of sentinel-2 images. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, 43:1569–1574, 2020.

[30] Xin Huang, Yihong Song, Jie Yang, Wenrui Wang, Huiqun Ren, Mengjie Dong, Yujin Feng, Haidan Yin, and Jiayi Li. Toward accurate mapping of 30-m time-series global impervious surface area (gisa). International Journal of Applied Earth Observation and Geoinformation, 109:102787, 2022.

[31] M. Joseph Hughes and Robert H. Kennedy. High-quality cloud masking of landsat 8 imagery using convolutional neural networks. Remote. Sens., 11:2591, 2019.

[32] Changho Hwang, Wei Cui, Yifan Xiong, Ziyue Yang, Ze Liu, Han Hu, Zilong Wang, Rafael Salas, Jithin Jose, Prabhat Ram, Joe Chau, Peng Cheng, Fan Yang, Mao Yang, and Yongqiang Xiong. Tutel: Adaptive mixture-of-experts at scale, 2022.

[33] Robert A. Jacobs, Michael I. Jordan, Steven J. Nowlan, and Geoffrey E. Hinton. Adaptive mixtures of local experts. Neural Computation, 3:79–87, 1991.

[34] Pallavi Jain, Bianca Schoen-Phelan, and Robert J. Ross. Self-supervised learning for invariant representations from multi-spectral and sar images. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 15:7797–7808, 2022.

[35] Menglin Jia, Luming Tang, Bor-Chun Chen, Claire Cardie, Serge Belongie, Bharath Hariharan, and Ser-Nam Lim. Visual prompt tuning. In European Conference on Computer Vision (ECCV), 2022.

[36] Ke Li, Gang Wan, Gong Cheng, Liqiu Meng, and Junwei Han. Object detection in optical remote sensing images: A survey and a new benchmark. ISPRS journal of photogrammetry and remote sensing, 159:296–307, 2020.

[37] Wentong Li, Yijie Chen, Kaixuan Hu, and Jianke Zhu. Oriented reppoints for aerial object detection. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 1829–1838, 2022.

[38] Xuyang Li, Danfeng Hong, and Jocelyn Chanussot. S2mae: A spatial-spectral pretraining foundation model for spectral remote sensing data. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 24088–24097, 2024.

[39] Zhihao Li, Biao Hou, Siteng Ma, Zitong Wu, Xianpeng Guo, Bo Ren, and Licheng Jiao. Masked angle-aware autoencoder for remote sensing images. In European Conference on Computer Vision, pages 260–278. Springer, 2024.

[40] Yinhe Liu, Sunan Shi, Junjue Wang, and Yanfei Zhong. Seeing beyond the patch: Scale-adaptive semantic segmentation of high-resolution remote sensing imagery based on reinforcement learning. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 16868–16878, 2023.

[41] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using

shifted windows. In Proceedings of the IEEE/CVF international conference on computer vision, pages 10012–10022, 2021.

[42] Ze Liu, Han Hu, Yutong Lin, Zhuliang Yao, Zhenda Xie, Yixuan Wei, Jia Ning, Yue Cao, Zheng Zhang, Li Dong, Furu Wei, and Baining Guo. Swin transformer v2: Scaling up capacity and resolution. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 12009–12019, 2022.

[43] Zhili Liu, Kai Chen, Jianhua Han, Lanqing Hong, Hang Xu, Zhenguo Li, and James Tin-Yau Kwok. Task-customized masked autoencoder via mixture of cluster-conditional experts. ArXiv, abs/2402.05382, 2024.

[44] Jonathan Long, Evan Shelhamer, and Trevor Darrell. Fully convolutional networks for semantic segmentation. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 3431–3440, 2015.

[45] Ilya Loshchilov and Frank Hutter. Sgdr: Stochastic gradient descent with warm restarts. arXiv: Learning, 2016.

[46] Ilya Loshchilov and Frank Hutter. Fixing weight decay regularization in adam. CoRR, abs/1711.05101, 2017.

[47] ZhiYong Lv, HaiTao Huang, Xinghua Li, MingHua Zhao, Jon Atli Benediktsson, WeiWei Sun, and Nicola Falco. Land cover change detection with heterogeneous remote sensing images: Review, progress, and perspective. Proceedings of the IEEE, 2022.

[48] Utkarsh Mall, Bharath Hariharan, and Kavita Bala. Change-aware sampling and contrastive learning for satellite images. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 5261–5270, 2023.

[49] Oscar Manas, Alexandre Lacoste, Xavier Giró-i Nieto, David Vazquez, and Pau Rodriguez. Seasonal contrast: Unsupervised pre-training from uncurated remote sensing data. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 9414–9423, 2021.

[50] Matías Mendieta, Boran Han, Xingjian Shi, Yi Zhu, Chen Chen, and Mu Li. Towards geospatial foundation models via continual pretraining. Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 16806–16816, 2023.

[51] Dilxat Muhtar, Xueliang Zhang, Pengfeng Xiao, Zhenshi Li, and Feng Gu. Cmid: A unified self-supervised learning framework for remote sensing image understanding. IEEE Transactions on Geoscience and Remote Sensing, 2023.

[52] Mubashir Noman, Muzammal Naseer, Hisham Cholakkal, Rao Muhammad Anwer, Salman Khan, and Fahad Shahbaz Khan. Rethinking transformers pre-training for multi-spectral satellite imagery. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 27811–27819, 2024.

[53] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. Dinov2: Learning robust visual features without supervision. arXiv preprint arXiv:2304.07193, 2023.

[54] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In International conference on machine learning, pages 8748–8763. PMLR, 2021.

[55] Colorado J Reed, Ritwik Gupta, Shufan Li, Sarah Brockman, Christopher Funk, Brian Clipp, Kurt Keutzer, Salvatore Candido, Matt Uyttendaele, and Trevor Darrell. Scale-mae: A scale-aware masked autoencoder for multiscale geospatial representation learning. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 4088–4099, 2023.

[56] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster r-cnn: Towards real-time object detection with region proposal networks. Advances in neural information processing systems, 28, 2015.

[57] Carlos Riquelme, Joan Puigcerver, Basil Mustafa, Maxim Neumann, Rodolphe Jenatton, André Susano Pinto, Daniel Keysers, and Neil Houlsby. Scaling vision with sparse mixture of experts. In Neural Information Processing Systems, 2021.

[58] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical im-

age segmentation. In Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III 18, pages 234–241. Springer, 2015.

[59] Sheng Shen, Le Hou, Yan-Quan Zhou, Nan Du, S. Longpre, Jason Wei, Hyung Won Chung, Barret Zoph, William Fedus, Xinyun Chen, Tu Vu, Yuexin Wu, Wuyang Chen, Albert Webson, Yunxuan Li, Vincent Zhao, Hongkun Yu, Kurt Keutzer, Trevor Darrell, and Denny Zhou. Mixture-of-experts meets instruction tuning: A winning combination for large language models. In International Conference on Learning Representations, 2023.

[60] Sheng Shen, Le Hou, Yanqi Zhou, Nan Du, Shayne Longpre, Jason Wei, Hyung Won Chung, Barret Zoph, William Fedus, Xinyun Chen, Tu Vu, Yuexin Wu, Wuyang Chen, Albert Webson, Yunxuan Li, Vincent Y Zhao, Hongkun Yu, Kurt Keutzer, Trevor Darrell, and Denny Zhou. Mixture-of-experts meets instruction tuning: A winning combination for large language models. In The Twelfth International Conference on Learning Representations, 2024.

[61] Jamie Sherrah. Fully convolutional networks for dense semantic labelling of high-resolution aerial imagery. arXiv preprint arXiv:1606.02585, 2016.

[62] Gencer Sumbul, Jian Kang, Tristan Kreuziger, Filipe Marcelino, Hugo Costa, Pedro Benevides, Mario Caetano, and Begüm Demir. Bigearthnet: A large-scale benchmark archive for remote sensing image understanding. In IEEE International Geoscience and Remote Sensing Symposium, pages 5901–5904, 2019.

[63] Gencer Sumbul, Arne de Wall, Tristan Kreuziger, Filipe Marcelino, Hugo Costa, Pedro Benevides, Mario Caetano, Begüm Demir, and Volkerl Mark. BigEarthNet-MM: A large-scale, multimodal, multilabel benchmark archive for remote sensing image classification and retrieval. IEEE Geoscience and Remote Sensing Magazine, 9(3):174–180, 2021.

[64] Xian Sun, Peijin Wang, Wanxuan Lu, Zicong Zhu, Xiaonan Lu, Qibin He, Junxi Li, Xuee Rong, Zhujun Yang, Hao Chang, et al. Ringmo: A remote sensing foundation model with masked image modeling. IEEE Transactions on Geoscience and Remote Sensing, 2022.

[65] Xian Sun, Peijin Wang, Zhiyuan Yan, Feng Xu, Ruiping Wang, Wenhui Diao, Jin Chen, Jihao Li, Yingchao Feng, Tao Xu, et al. Fair1m: A benchmark dataset for fine-grained object recognition in high-resolution remote sensing imagery. ISPRS Journal of Photogrammetry and Remote Sensing, 184:116–130, 2022.

[66] Chao Tao, Ji Qi, Guo Zhang, Qing Zhu, Weipeng Lu, and Haifeng Li. Tov: The original vision model for optical remote sensing image understanding via self-supervised learning. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023.

[67] Aysim Toker, Lukas Kondmann, Mark Weber, Marvin Eisenberger, Andrés Camero, Jingliang Hu, Ariadna Pregel Hoderlein, Çağlar Şenaras, Timothy Davis, Daniel Cremers, et al. Dynamicearthnet: Daily multi-spectral satellite dataset for semantic change segmentation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 21158–21167, 2022.

[68] Xin-Yi Tong, Guisong Xia, and Xiaoxiang Zhu. Enabling country-scale land cover mapping with meter-resolution satellite imagery. Isprs Journal of Photogrammetry and Remote Sensing, 196:178 – 196, 2022.

[69] Laurens van der Maaten and Geoffrey E. Hinton. Visualizing data using t-sne. Journal of Machine Learning Research, 9:2579–2605, 2008.

[70] Di Wang, Qiming Zhang, Yufei Xu, Jing Zhang, Bo Du, Dacheng Tao, and Liangpei Zhang. Advancing plain vision transformer toward remote sensing foundation model. IEEE Transactions on Geoscience and Remote Sensing, 61:1–15, 2022.

[71] Di Wang, Jing Zhang, Bo Du, Dacheng Tao, and Liangpei Zhang. Scaling-up remote sensing segmentation dataset with segment anything model. Advances in Neural Information Processing Systems, 2023.

[72] Yi Wang, Conrad M Albrecht, Nassim Ait Ali Braham, Chenying Liu, Zhitong Xiong, and Xiao Xiang Zhu. Decur: decoupling common & unique representations for multimodal self-supervision. arXiv preprint arXiv:2309.05300, 2023.

[73] Yi Wang, Nassim Ait Ali Braham, Zhitong Xiong, Chenying Liu, Conrad M Albrecht, and Xiao Xiang

Zhu. Ssl4eo-s12: A large-scale multi-modal, multi-temporal dataset for self-supervised learning in earth observation. IEEE Geoscience and Remote Sensing Magazine, 11(3):98–106, 2023.

[74] Zhirui Wang, X.-M. Zeng, Zhiyuan Yan, Jian Kang, and Xian Sun. Air-polsar-seg: A large-scale data set for terrain segmentation in complex-scene polsar images. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 15:3830–3841, 2022.

[75] Xinye Wanyan, Sachith Seneviratne, Shuchang Shen, and Michael Kirley. Dino-mc: Self-supervised contrastive learning for remote sensing imagery with multi-sized local crops. arXiv preprint arXiv:2303.06670, 2023.

[76] Syed Waqas Zamir, Aditya Arora, Akshita Gupta, Salman Khan, Guolei Sun, Fahad Shahbaz Khan, Fan Zhu, Ling Shao, Gui-Song Xia, and Xiang Bai. isaid: A large-scale dataset for instance segmentation in aerial images. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, pages 28–37, 2019.

[77] Long Wen, Yu Cheng, Yi Fang, and Xinyu Li. A comprehensive survey of oriented object detection in remote sensing images. Expert Systems with Applications, page 119960, 2023.

[78] Lemeng Wu, Mengchen Liu, Yinpeng Chen, Dongdong Chen, Xiyang Dai, and Lu Yuan. Residual mixture of experts. ArXiv, abs/2204.09636, 2022.

[79] Gui-Song Xia, Jingwen Hu, Fan Hu, Baoguang Shi, Xiang Bai, Yanfei Zhong, Liangpei Zhang, and Xiaoqiang Lu. Aid: A benchmark data set for performance evaluation of aerial scene classification. IEEE Transactions on Geoscience and Remote Sensing, 55(7):3965–3981, 2017.

[80] Tete Xiao, Yingcheng Liu, Bolei Zhou, Yuning Jiang, and Jian Sun. Unified perceptual parsing for scene understanding. In Proceedings of the European conference on computer vision (ECCV), pages 418–434, 2018.

[81] Zhitong Xiong, Yi Wang, Fahong Zhang, and Xiao Xiang Zhu. One for all: Toward unified foundation models for earth vision. IGARSS 2024 - 2024 IEEE International Geoscience and Remote Sensing Symposium, pages 2734–2738, 2024.

[82] Longqi Yang, Liangliang Zhang, and Wenjing Yang. Graph adversarial self-supervised learning. In Advances in Neural Information Processing Systems, 2021.

[83] Xiaohui Yuan, Jianfang Shi, and Lichuan Gu. A review of deep learning methods for semantic segmentation of remote sensing imagery. Expert Systems with Applications, 169:114417, 2021.

[84] Yiyuan Zhang, Kaixiong Gong, Kaipeng Zhang, Hongsheng Li, Yu Qiao, Wanli Ouyang, and Xiangyu Yue. Meta-transformer: A unified framework for multimodal learning. arXiv preprint arXiv:2307.10802, 2023.

[85] Xizhou Zhu, Jinguo Zhu, Hao Li, Xiaoshi Wu, Xiaogang Wang, Hongsheng Li, Xiaohua Wang, and Jifeng Dai. Uni-perceiver: Pre-training unified architecture for generic perception for zero-shot and few-shot tasks. 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 16783–16794, 2021.

[86] Barret Zoph, Irwan Bello, Sameer Kumar, Nan Du, Yanping Huang, Jeff Dean, Noam M. Shazeer, and William Fedus. St-moe: Designing stable and transferable sparse expert models. 2022.