https://hjfy.top/arxiv/2311.00566

CROMA：基于对比雷达-光学掩码自编码器的遥感表示

Anthony Fuller[1,*], Koreen Millard[2], James R. Green[1]
[1]Department of Systems and Computer Engineering
[2]Department of Geography and Environmental Studies
Carleton University, Ottawa, Canada

Abstract

一种重要且迅速发展的应用——遥感，提供了海量但标注稀疏、空间对齐的多模态数据；这使得自监督学习算法变得至关重要。我们提出 CROMA：一个结合对比与重构自监督目标的框架，用于学习丰富的单峰值和多模态表示。我们的方法分别编码被掩码的多光谱光学与合成孔径雷达样本——这些样本在空间和时间上对齐——并执行跨模态对比学习。另一个编码器融合这些传感器，生成联合的多模态编码，通过轻量级解码器预测被掩码的图像块。我们证明，在空间对齐的多模态数据上，这些目标具有互补性。我们还引入 X- 和 2D-ALiBi，它们对跨注意力与自注意力矩阵施加空间偏置。这些策略提升了表示能力，并使我们的模型能够有效外推至测试时尺寸高达 17.6× 的图像。CROMA 在多个基准上超越了当前最先进的多光谱模型，包括：四个分类基准——微调（平均↑ 1.8%）、线性（平均↑ 2.4%）和非线性（平均↑ 1.4%）探测，k NN 分类（平均↑ 3.5%），以及 K -均值聚类（平均↑ 8.4%）；以及三个分割基准（平均↑ 6.4%）。CROMA 丰富的、可选多模态的表示可广泛应用于遥感领域。

1 引言

深度学习推动了遥感领域的快速发展，增强了我们理解与监测地球的能力。遥感领域已开发出许多针对特定应用的深度学习模型，尤其适用于卫星影像：识别重度污染的砖窑 [1, 2] 或非法跑道 [3]；监测森林砍伐 [4, 5, 6, 7] 或农作物 [8, 9, 10]；检测洪水 [11, 12] 或野火 [13, 14, 15]；甚至估算家庭收入 [16, 17] 或贫困状况 [18, 19, 20]。基于深度学习的遥感在应对气候危机方面正发挥着日益重要的作用 [21, 22, 23]。最近，研究人员利用自监督学习预训练遥感模型，使其能够应用于这些任务以及其他更多场景 [24, 25, 26, 27]。自监督方法对遥感至关重要，因为存在海量公开的原始数据可供学习通用表示，而下游应用所需的标注数据却十分有限。

自监督表示通常通过对比方法 [28, 29, 30] 或重构方法 [31, 32, 33] 学成。对比方法鼓励正样本对的表示——这些正样本对通过生成样本的另一视图构建，例如来自另一个传感器 [34] 或时间 [35]，或通过数据增强 [30]——彼此相似，而负样本对的表示则应不同；这一过程可

[*]All correspondence should be addressed to Anthony Fuller: `anthony.fuller@carleton.ca`

37th Conference on Neural Information Processing Systems (NeurIPS 2023).

以学成描述性强、以对象为中心的表示。采用对比目标训练的模型学会丢弃各视图之间不共享的信息 [36, 37]，无论这些信息在下游任务中是否实用；这使得它们学成的表示对正样本对的构建方式非常敏感 [30, 38, 39, 40]。相反，采用重构或自编码目标训练的模型——例如预测被隐藏的像素 [31, 41]——则会尽可能捕捉所有信息 [42, 43, 44]。重构方法无需依赖多视图，且可扩展性极强 [31, 45, 46]，但其学成的表示在用于下游任务时通常需要大量的微调 [43, 45]。Park 等人 [47] 表明，通过对比学习训练的视觉 Transformer（ViTs [48]）更关注形状和低频信息，而通过重构方法训练的 ViTs 则更关注纹理和高频信息。他们还表明，结合两种目标可能达到一个最佳平衡点，从而学成比单独使用任一目标更优的表示。已有多种框架被开发出来，利用这两种目标来学成最先进的表示 [49, 50, 51, 52]；然而，目前尚无任何框架专为空间对齐的多模态数据设计。

致力于遥感领域基础模型的研究人员尚未充分利用遥感中普遍存在的多模态数据。例如，自 2015 年以来，哨兵（Sentinel）任务多次每月对地球陆地进行成像，其包含由哨兵-2 获取的多光谱光学影像以及由哨兵-1 获取的合成孔径雷达（SAR）数据。通过利用电磁辐射与地球表面物质相互作用的差异，并在多个波长范围（从440 到2,200 nm）测量辐射，哨兵-2 的多光谱光学影像可用于表征物体的物质组成 [53]。通过主动发射并接收较长波长（5.5 cm）的电磁脉冲，哨兵-1 SAR 可用于表征物体的几何形态、粗糙度及电学特性 [54]。这些模态在遥感应用中已被证明具有互补性 [55, 56, 57]。对于我们的研究而言尤为重要的是，它们在空间上对齐，能够提供同一地表特征的多个视角。此外，由于哨兵任务的数据免费开放，已成为科研中最广泛使用的卫星影像来源；因此，能够对哨兵-1 与哨兵-2 影像产生有效表示的模型可立即应用于科学研究，从而提升我们对地球的理解能力。

这些观察结果激发了 <u>C</u> 对比 <u>R</u> 雷达- <u>O</u> 光学 <u>M</u> 掩码 <u>A</u> 自编码器（**CROMA**）：一种用于学习多模态、空间对齐的二维数据丰富表示的框架；我们利用该框架在哨兵-1 与 2 数据上对 ViT 模型进行预训练，为地球观测提供了迄今为止最有价值的基础模型。我们强调三个贡献：❶ CROMA 在广泛评估下显著优于当前最先进（SoTA）的多光谱模型 SatMAE [26]。❷ CROMA 学成的表示具有 可选多模态性（即当任一或两个模态可用时均可有效利用），并且能在测试时 外推到更大图像（即可在大于训练时所用图像尺寸的图像上有效利用）。❸ CROMA 的有效性源于两项创新：我们互补的预训练目标以及我们新颖的相对位置编码（RPE）策略，这些策略有助于提升学成表示的质量。

2 方法

在本节中，“光学”指由哨兵-2 获取的 12-通道多光谱光学影像，“雷达”指由哨兵-1 获取的 2-通道 SAR 后向散射数据。

架构背景。大多数将对比学习与重构目标相结合以学习联合多模态表示的工作集中在图像-文本领域 [51, 58, 59, 60, 61, 62, 63, 64, 65]；这极大地启发了我们的架构，对比性描述（CoCa [49]）学习了当前最优的图像-文本表示，这些表示可选地为多模态。CoCa 框架由两个单峰值编码器组成——一个用于图像，一个用于文本——以及一个接收文本编码并交叉注意力于图像编码的多模态解码器。CoCa 通过两个目标进行训练：在单峰值编码器之间进行图像 $\leftrightarrow$ 文本对比目标，以及在多模态解码器输出处的图像描述生成目标。我们的框架通过对 CoCa 进行显著改进，以适应对齐的多模态二维数据，包括对两种模态均引入掩码，引入多模态编码器，采用轻量级解码器（仅在预训练期间使用，受掩码自编码器 [31] 启发），并提出新颖的交叉注意力和自注意力位置偏置。

模型架构. CROMA 包含三个编码器（图 1）。❶ 一个单峰值雷达 ViT f_{R}，将雷达输入 $I_{\mathrm{R}} \in \mathbb{R}^{2\times H\times W}$ 编码为 L 个补丁表示 $\mathcal{E}_{\mathrm{R}} \in \mathbb{R}^{L\times D}$，即 $\mathcal{E}_{\mathrm{R}} = f_{\mathrm{R}}(I_{\mathrm{R}})$。❷ 一个单峰值光学 ViT f_{O}，将光学输入 $I_{\mathrm{O}} \in \mathbb{R}^{12\times H\times W}$ 编码为 L 个补丁表示 $\mathcal{E}_{\mathrm{O}} \in \mathbb{R}^{L\times D}$，即 $\mathcal{E}_{\mathrm{O}} = f_{\mathrm{O}}(I_{\mathrm{O}})$。❸ 一

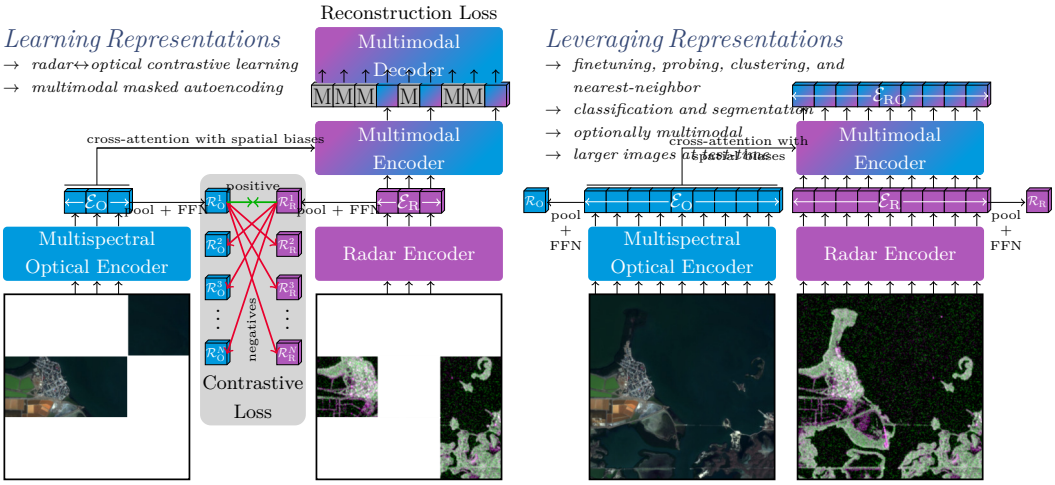

图 1: **(左)** 我们的 CROMA 框架联合利用雷达 ↔ 光学对比学习和掩码自编码来学习丰富的自监督表示。**(右)** 利用表示于：单峰值或多模态数据、测试时更大的图像，以及多样化的任务和方法。

个多模态雷达-光学 Transformer f_{RO}，将 L 个雷达-光学补丁编码为 $\mathcal{E}_{\text{RO}} \in \mathbb{R}^{L\times D}$，即 $\mathcal{E}_{\text{RO}} = f_{\text{RO}}(\mathcal{E}_{\text{R}}, \mathcal{E}_{\text{O}})$。对于每组单峰值编码，我们通过将平均池化后的补丁编码送入前馈网络（FFN）构建全图像表示 $\mathcal{R} \in \mathbb{R}^{D}$，即 $\mathcal{R}_{\text{R}} = \text{FFN}_{\text{R}}(\text{MeanPool}(\mathcal{E}_{\text{R}}))$ 和 $\mathcal{R}_{\text{O}} = \text{FFN}_{\text{O}}(\text{MeanPool}(\mathcal{E}_{\text{O}}))$。我们的补丁大小在两种模态下均为 8×8 像素，默认图像大小为 120×120 像素。我们的雷达编码器包含 $N/2$ 层 Transformer，光学编码器包含 N 层 Transformer（N 对应 ViT-B 为 12，对应 ViT-L 骨干为 24）。所有单峰值编码器层均由自注意力和 FFN 子层组成。我们的多模态 $N/2$ -层编码器——由自注意力、交叉注意力和 FFN 子层构成——将两种模态编码为一个 *单一*序列的 L 个补丁表示；该编码器在网络底部接收雷达补丁编码，并通过交叉注意力关注光学补丁编码来学习多模态表示。多模态表示可通过池化多模态补丁编码获得，即 $\mathcal{R}_{\text{RO}} = \text{MeanPool}(\mathcal{E}_{\text{RO}})$。我们的 ViT 骨干不使用正弦位置嵌入；相反，我们通过对自注意力和交叉注意力矩阵施加补丁之间的距离进行偏置。

ALiBi 背景. ALiBi [66] 是一种简单直观的 RPE 方法，用于 Transformer，它根据一维序列中 token 之间的距离对自注意力矩阵进行偏差调整。每个自注意力头接收具有不同强度的位置偏差，称为斜率 m，与 16 个注意力头对应。这些标量斜率由几何序列定义，从 $\frac{1}{\sqrt{2}}$ 开始，即 $\frac{1}{2^{0.5}}, \frac{1}{2^{1}}, \frac{1}{2^{1.5}}, \ldots, \frac{1}{2^{8}}$。在 Softmax 计算之前，将这些偏差从注意力矩阵中减去。具体而言，预 Softmax 注意力矩阵 $A \in \mathbb{R}^{h\times L\times L}$（$h$ 为头数，L 为序列长度）用注意力得分 a_{hij} 填充，对应第 i 个查询 $q_{hi} \in \mathbb{R}^{d}$ 和第 j 个键 $k_{hj} \in \mathbb{R}^{d}$（$d$ 为头维度）：$a_{hij} = \sqrt{d}\cdot q_{hi}\cdot k_{hj}$，无 ALiBi；以及 $a_{hij} = \sqrt{d}\cdot q_{hi}\cdot k_{hj} - \text{distance}(i,j)\cdot m(h)$，含 ALiBi。关键的是，ALiBi 不在网络底部添加位置嵌入；相反，token 之间的相对位置直接编码在注意力矩阵本身中。迄今为止，ALiBi 是唯一一种已被证明能够在测试时外推至远长于训练序列长度的 Transformer 位置编码方法。

2D-ALiBi 和 X-ALiBi。我们将 ALiBi 扩展至二维输入，通过基于视觉变换器（ViT）中查询-键对之间的欧氏距离来偏置自注意力矩阵——我们称之为 2D-ALiBi（图 2）。我们还将 ALiBi 扩展至交叉注意力，通过基于跨模态查询-键对之间的欧氏距离来偏置交叉注意力矩阵——我们称之为 X-ALiBi。（在交叉注意力 [67] 中，查询由前

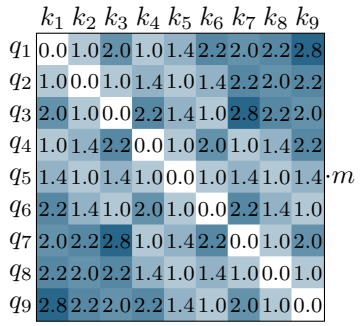

图 2: 二维 ALiBi 矩阵，用于一个包含 9 个图像块的图像（3^2 在展平之前）；q 用于查询，k 用

一层构建，而键和值则由光学编码构建。）对于 2D-ALiBi 和 X-ALiBi，我们使用与 ALiBi 相同的几何序列计算注意力头斜率。由于我们的两种模态均为对齐的二维传感器数据，因此 2D-ALiBi 和 X-ALiBi 矩阵是相同的。2D-ALiBi 的主要动机是学习能够泛化至不同图像大小的表示；这在遥感领域尤其有用，且可能在其他领域也具有价值。X-ALiBi 的主要动机是通过在多模态编码器的交叉注意力子层中引入位置信息，从而提升传感器融合效果，f_{RO}。这些位置编码技术具有旋转和平移不变性，这对地球观测中的俯视影像而言是理想的特性。

平均绝对误差背景。一种掩码自编码器（MAE [31]）将图像重新排列为一系列不重叠的块，然后随机采样大部分块进行隐藏。未被隐藏的“可见”块由一个 ViT 进行编码。这种类似 MAE 的掩码策略非常巧妙：它利用了稀疏计算，同时仅需稠密操作，能够在现代硬件上高效运行。MAE 引入了一个轻量级解码器，接收可见块编码和隐藏掩码嵌入，两者均与二维正弦位置嵌入相加。解码器输出对被隐藏块的像素值预测。编码器和解码器均通过端到端预训练，以最小化块预测值与原始被隐藏块之间的均方误差。预训练的编码器随后可应用于下游任务。

重构目标. 我们独立地对雷达和光学块中的 75% 进行掩码，并使用我们的三个编码器（即 $\mathcal{E}_{\mathrm{R}}^{um} = f_{\mathrm{R}}(\mathrm{I}_{\mathrm{R}}^{um})$ 、$\mathcal{E}_{\mathrm{O}}^{um} = f_{\mathrm{O}}(\mathrm{I}_{\mathrm{O}}^{um})$ 和 $\mathcal{E}_{\mathrm{RO}}^{um} = f_{\mathrm{RO}}(\mathcal{E}_{\mathrm{R}}^{um}, \mathcal{E}_{\mathrm{O}}^{um})$）对未掩码的块进行编码；其中 um 表示未掩码。我们引入一个轻量级的 1 层 Transformer 解码器 f_{DEC}，该解码器在添加二维正弦位置嵌入后接收多模态块编码和掩码嵌入，并预测目标图像（即 $\hat{\mathrm{I}} = f_{\mathrm{DEC}}(\mathrm{CONCAT}[\mathcal{E}_{\mathrm{RO}}^{um}, \mathrm{Emb}^{\mathrm{mask}}] + \mathrm{Emb}^{\mathrm{positions}})$ ）。我们分割 $\hat{\mathrm{I}}$ 的通道以形成针对每个传感器（$\hat{\mathrm{I}}_{\mathrm{O}}$ 和 $\hat{\mathrm{I}}_{\mathrm{R}}$）的预测；损失仅应用于被掩码的块的位置：

$$\mathcal{L}_{\mathrm{MAE}} = \frac{1}{N}\sum_{i}^{N}\left(\underbrace{\frac{\sum_{j}^{M}\left(\hat{\mathrm{I}}_{\mathrm{O}}^{ij} - \mathrm{Norm}(\mathrm{I}^{ij})_{\mathrm{O}}\right)^{2}}{M}}_{\text{optical reconstruction}} + \underbrace{\frac{\sum_{j}^{M}\left(\hat{\mathrm{I}}_{\mathrm{R}}^{ij} - \mathrm{Norm}(\mathrm{I}^{ij})_{\mathrm{R}}\right)^{2}}{M}}_{\text{radar reconstruction}}\right)$$

其中 N 为批量大小，M 为被掩码的图像块数量，Norm 将目标图像块的均值设为 0，标准差设为 1（遵循 MAE）。除了学习单峰值表示外，该目标还实现了两个传感器的空间融合，即构建了多模态图像块编码，使每个图像块能够表示来自 两个传感器的信息，对应地表上一个 $80\,\mathrm{m} \times 80\,\mathrm{m}$ 的方阵（在 10 m 分辨率下共 8×8 个图像块）。最后，2D 和 X-ALiBi 可通过从偏置矩阵中移除被掩码的行和列，轻松适配到 MAE 风格的掩码机制。

对比学习背景。对比学习旨在对从批量中提取的样本配对进行正确分类。通过测量样本投影表示之间的相似度来形成 Logit。因此，正样本对的表示被拉近，而负样本对的表示被推开。最近，FLIP [68] 通过类似 MAE 的掩码方式对掩码掉的表示进行对比学习。这加快了预训练速度，并由于每个样本所需的内存减少而支持更大的批量。FLIP 的性能与 CLIP [69] 相当——后者是通过图像 ↔ 文本对比学习来学习丰富表示的基础性工作——但其预训练成本仅为一半。

对比目标。我们在掩码传感器数据的单峰值表示上，使用 InfoNCE 损失 [28] 执行雷达 ↔ 光学对比学习。对于一个光学锚点图像，正例是地理和时间上匹配的雷达样本，负例是批量中所有其他雷达样本；同样地，我们的雷达表示被拉向（正例）或推开（负例）光学表示：

$$\mathcal{L}_{\text{Con}} = -\frac{1}{2N}\left(\underbrace{\sum_{i}^{N}\log\frac{\exp\left(z_{\text{R}}^{i\top}z_{\text{O}}^{i}/\sigma\right)}{\sum_{j}^{N}\exp\left(z_{\text{R}}^{i\top}z_{\text{O}}^{j}/\sigma\right)}}_{\text{radar-to-optical}} + \underbrace{\sum_{i}^{N}\log\frac{\exp\left(z_{\text{O}}^{i\top}z_{\text{R}}^{i}/\sigma\right)}{\sum_{j}^{N}\exp\left(z_{\text{O}}^{i\top}z_{\text{R}}^{j}/\sigma\right)}}_{\text{optical-to-radar}}\right)$$

其中，z_{R} 和 z_{O} 分别是雷达和光学表示的 ℓ_2 规范化的线性投影，即 $z_{\text{R}} = \text{Norm}(\text{Linear}_{\text{R}}(\mathcal{R}_{\text{R}}))$ 和 $z_{\text{O}} = \text{Norm}(\text{Linear}_{\text{O}}(\mathcal{R}_{\text{O}}))$。$\sigma$ 是 Softmax 温度，N 是批量大小。关键的是，我们仅对输入图像块的一小部分进行编码，这些图像块构成了我们的表示。这种掩码机制具有诸多优势：它能够支持更大的批量、加快预训练速度，并在相同的计算图中实现多模态重构目标。该雷达 ↔ 光学对比目标促使表示具备传感器不变性，即捕捉传感器之间的共享信息。

联合预训练目标。我们结合了对比学习和掩码传感器建模预训练目标：$\mathcal{L} = \lambda_{\text{Con}}\mathcal{L}_{\text{Con}} + \lambda_{\text{MAE}}\mathcal{L}_{\text{MAE}}$ 。我们将两个任务权重（即 λ_{Con} 和 λ_{MAE} ）均设为 1，并在附录 §A.1 中对其进行消融实验。

3 实验

预训练. 我们在 SSL4EO 数据集 [70]—一个地理和季节多样性强的大型未标记数据集上预训练 CROMA 模型。SSL4EO 由 1 百万对 Sentinel-1 GRD 和 Sentinel-2 L2A 样本组成，每个样本包含 264×264 像素。Sentinel-1 通道包含 VV 和 VH 后向散射。Sentinel-2 通道包含 12 地表反射率多光谱波段（去除了卷云波段）。我们对 CROMA-B（ViT-B 主干）预训练 300 轮次，对 CROMA-L（ViT-L 主干）预训练 600 轮次。关键的是，单次预训练过程端到端地训练三个编码器（光学、雷达以及雷达-光学联合编码器）；用户随后可根据任务和数据可用性微调一个或多个编码器。我们在 NVIDIA DGX 服务器（8× A100–80 GB）上进行所有预训练实验，包括消融实验。请参阅附录 §A.3 获取更多细节。

对比. 我们将 CROMA 与所有可用的多光谱光学基础模型进行比较，其中包括两个由 [71] 通过雷达 ↔ 光学对比学习预训练的模型；两个由 [70] 使用 MAE [31] 和 DINO [72] 框架预训练的模型；以及两个由 [26] 使用其多光谱表示学习框架 SatMAE 预训练的模型。我们还将 CROMA 与一种用于学习自然图像视觉表示的最先进方法——图像联合嵌入预测架构（I-JEPA, [73]）——进行比较，该方法被我们用于在 SSL4EO 的光学影像上对 ViT-B 模型进行 300 轮次的自监督学习预训练。为了确保模型间公平比较，我们在相同的条件和超参数预算下评估所有模型（详细信息请见附录 §A.4.2）。这是必要的，因为这些模型最初报告的结果是在不一致的评估条件下产生的——例如数据划分或训练数据量不同。我们使用最新公开可用的模型进行所有评估，并根据官方仓库对数据进行预处理。对于雷达及雷达-光学数据集，我们将 CROMA 与 SatViT-V2 [74] 进行比较，该模型是使用 MAE [31] 在堆叠的哨兵-1 & 2 影像上预训练的；以及 DeCUR，该模型是由 [75] 使用其多模态表示学习框架在本工作同期预训练的。

3.1 多光谱光学实验

分类设置。我们通过微调、冻结线性与非线性探针、k 近邻（NN）分类以及 K -均值（means）聚类等方法，在四个 Sentinel-2 分类基准上评估 CROMA 模型对预训练表示的性能。❶ 多标签 BigEarthNet 数据集 [76]（35,420 个训练样本和 118,065 个验证样本）；该数据集为完整 BigEarthNet 训练集的一个子集 10%，目前已成为默认采用版本 [25, 26]，旨在降低微调成本，并更适合作为遥感基准 [22]。❷ fMoW-Sentinel 数据集 [26]（71,287 个训练样本和 84,939 个验证样本）；该数据集同样为完整训练集的一个子集 10%。继 BigEarthNet 的做法

之后，我们认为这一较小的训练集更适合作为模型评估的基准；但我们在附录 §A.4.1 中也展示了在完整训练集上的结果。❸ EuroSAT 数据集 [77]（16,200 个训练样本和 5,400 个验证样本）。❹ 加拿大农田数据集 [78]（53,884 个训练样本和 23,088 个验证样本）；该数据集是一个受 EuroSAT 启发的新基准，但更具挑战性，因为各类作物（如大麦、油菜、玉米等）在视觉上可能高度相似。对于微调与线性探针，我们在全图像表示之上添加一个线性层以执行这些任务，即 Linear($\mathcal{R}_{\mathrm{O}}$)；对于非线性探针，我们使用含一个隐藏层的多层感知机（MLP），该隐藏层维度为 2048，即 Linear(ReLU(Linear($\mathcal{R}_{\mathrm{O}}$)))。此外，我们还针对单标签基准执行非参数的 k 近邻（NN）分类（$k = 20$）与 K -均值（means）聚类，以评估冻结表示的性能。[79] 表明，尚无单一的表示评估方法始终最优；他们建议在线性探针之外，同时纳入 k 近邻（NN）与 K -均值（means）评估。其他研究 [80, 72, 81] 显示，k 近邻（NN）与线性探针评估之间存在秩不匹配现象——表明二者可对表示质量提供互补性的估计。有关实现细节、数据划分及超参数设置，请参见附录 §A.4.1 和 A.4.2。

表 1: **在四个基准上的分类结果，分别在微调（FT）、冻结线性（LP）和非线性（MLP）探测条件下。* 表示原始报告的结果；我们在相同条件下获得了其他所有结果。**

Method	Backbone	BigEarthNet (10%) mAP			fMoW-Sentinel (10%) Top 1 Acc.			EuroSAT Top 1 Acc.			Canadian Cropland Top 1 Acc.		
		FT	MLP	LP	FT	MLP	LP	FT	MLP	LP	FT	MLP	LP
radar↔optical [71]	ResNet50	77.65	78.79	77.44	32.03	6.46	6.01	96.31	86.35	78.81	57.44	58.09	55.55
radar↔optical [71]	Swin-T	86.41	78.65	77.93	52.01	28.54	31.06	98.09	93.50	94.78	70.98	60.36	57.05
MAE [31, 70]	ViT-S	86.15	81.70	75.94	51.79	31.70	27.69	98.78	94.46	91.80	74.02	59.07	48.38
DINO [72, 70]	ViT-S	87.04	84.96	81.58	52.79	35.62	32.64	98.63	97.07	96.07	75.27	67.35	59.94
I-JEPA [73]	ViT-B	85.92	84.27	80.80	53.54	35.76	32.35	99.20	96.60	95.63	75.13	66.69	60.17
SatMAE [26]	ViT-B	85.94	83.48	79.36	57.20	37.28	35.17	99.20	97.28	96.61	73.58	66.02	60.40
CROMA	ViT-B	87.58	86.29	**85.04**	54.47	39.67	38.42	99.22	97.89	97.59	76.17	67.62	63.39
SatMAE [26]	ViT-L	86.18/ 82.62*	84.01	80.29	58.19	38.18	36.76	99.35/ 98.98*	97.67	97.65	74.06	67.03	61.75
CROMA	ViT-L	**88.29**	**86.46**	85.01	**59.02**	**40.07**	**39.17**	**99.46**	**98.04**	**98.02**	**78.07**	**67.94**	**64.02**

分类结果. 在微调、冻结线性与非线性探测、k NN 分类以及 K -means 聚类（表 1, 2）四种 Sentinel-2（多光谱光学）基准上，CROMA 的平均排名位居第一。唯一一个使用相同主干网络的 SatMAE 模型优于 CROMA 模型的情况是，在 fMoW-Sentinel 数据集上进行微调。然而，SatMAE 是在 fMoW-Sentinel 上进行预训练的——这意味着预训练与微调之间不存在分布偏移。这一优势使得 SatMAE 在 fMoW-Sentinel 基准上表现更佳，因为下游性能受到上游与下游数据相似度的影响 [82, 83, 84]。尽管如此，在线性探测（↑ 3.3%）、非线性探测（↑ 2.4%）、k NN（↑ 5.3%）以及 K -means（↑ 2.4%）任务中，CROMA-B 仍优于 SatMAE-B。此外，CROMA 模型在微调和推理阶段的速度比其 SatMAE 对应模型快超过 4×（详见附录 §A.4.2 中的对比）。在所有评估中，CROMA 均优于在 SSL4EO 数据集上使用 I-JEPA 框架预训练的 ViT-B 模型——I-JEPA 是当前用于学习 ImageNet 自监督表示的最先进框架 [73]。我们还绘制了 UMAP [85] 嵌入图（图 3）；结果显示，CROMA 能够显著分离 EuroSAT 各类别。

表 2: **非参数 k 分类和 K -means 聚类结果。** * 表示训练集的 10%。

Method	Backbone	fMoW-Sent.* Top 1 Acc.		EuroSAT Top 1 Acc.		Can. Crop. Top 1 Acc.	
		kNN	K-means	kNN	K-means	kNN	K-means
radar↔optical [71]	ResNet50	7.07	3.94	52.09	23.52	49.82	**23.15**
radar↔optical [71]	Swin-T	19.46	7.93	85.07	56.91	48.22	21.57
MAE [31, 70]	ViT-S	22.25	7.54	87.33	41.50	56.01	18.31
DINO [72, 70]	ViT-S	28.89	8.23	94.20	45.83	60.70	20.22
I-JEPA [73]	ViT-B	25.45	8.01	89.02	42.89	57.48	18.06
SatMAE [26]	ViT-B	26.76	8.98	89.28	44.87	56.20	20.14
CROMA	ViT-B	**32.03**	**11.35**	**95.26**	**76.06**	**61.25**	22.55
SatMAE [26]	ViT-L	26.77	9.17	89.57	38.48	56.93	19.65
CROMA	ViT-L	29.54	10.12	94.70	61.24	59.41	21.27

稀疏探测。受语言模型稀疏探测的启发 [86]，我们通过将线性探测器限制在 k 个维度，对 768 维度（ViT-B 主干）的图像表示进行稀疏探测。对于每一类，我们对所有维度进行排序，并在前 k 个维度上训练一个线性探测器以执行二分类（此设置遵循 [86]，请参见附录 §A.4.2 以获取更多细节）。该实验有助于我们理解学成表示中包含的信息。例如，在图 4 (B) 中，当减少 k 时，F1 得分出现显著下降——这表明 BigEarthNet 的“沙滩、沙丘、沙地”类别并

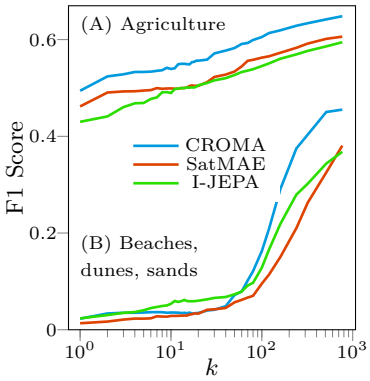

图 4: 稀疏探测两个 BigEarthNet 类别。

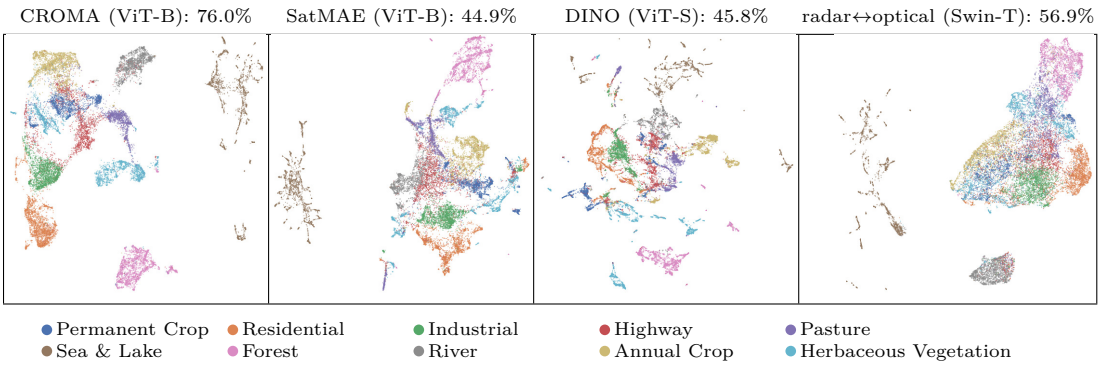

图 3: CROMA (ViT-B)、SatMAE (ViT-B) [26]、DINO (ViT-S) [70] 和雷达 ↔ 光学 (Swin-T) [71] 模型在 EuroSAT [77] 上的 UMAP 嵌入和 K -means 聚类准确率。

未由单个维度良好表示。相反，该类别是由许多与沙滩相关的特征组合所表示的。相比之下，BigEarthNet 的“农业与自然植被”类别在 CROMA 表示中很好地映射到一个 单一维度，当 $k = 1$ 时达到 F1 得分为 49% （图 4 (A)）。在附录 §A.6 中，我们展示了所有分类任务和所有类别上的稀疏探测结果。

分割设置。我们在三个哨兵-2 分割基准上评估所有基于 ViT 的模型。❶ DFC2020 数据集 [87]（46,152 个训练样本和 8,874 个验证样本）。❷ 动态世界数据集 [88] 的一个由专家标注的子集；因此我们称之为 DW-Expert (20,422 个训练样本和 51,022 个验证样本)。DW-Expert 是一个新推出的高质量基准，借助高分辨率卫星图像和街景影像进行标注。❸ MARIDA 数据集 [89] (1,682 个训练样本和 1,615 个验证样本)，这是一个小型、稀疏标注的海洋垃圾数据集。对于所有任务，我们对冻结的块编码进行线性探测，即 Linear($\mathcal{E}_{\mathrm{O}}$) 。我们将原始图像（DFC2020 为 256×256，DW-Expert 为 510×510，MARIDA 为 256×256）裁剪为 96×96 大小的图像。我们在这些 96×96 图像上训练和评估所有模型，这是 SatMAE 的默认图像大小，使与当前最先进方法的比较更加公平。

分割结果。与 SatMAE 相比，CROMA 在 ViT-B 和 ViT-L 主干网络上的平均绝对误差（Mae）分别降低了 5.4% 和 6.4% （表3）。这些结果表明，CROMA 能够有效学习到对稠密预测任务（如语义分割）有用的细粒度像素级特征。

表 3: 三个哨兵-2 基准上的语义分割（mIoU）结果。

Method	Backbone	DFC2020	DW-Expert	MARIDA
MAE	ViT-S	35.63	46.63	48.06
DINO	ViT-S	32.34	48.34	49.38
I-JEPA	ViT-B	36.72	50.82	53.85
SatMAE	ViT-B	45.53	51.03	58.17
CROMA	ViT-B	46.67	58.55	**65.56**
SatMAE	ViT-L	44.13	51.50	57.12
CROMA	ViT-L	**49.78**	**58.71**	63.32

3.2 雷达与雷达-光学实验

多模态设置。 BigEarthNet 和 DFC2020 还包含与 Sentinel-2 在空间和时间上对齐的 Sentinel-1 样本。这使我们能够评估我们的多模态表示，并在相同基准上直接与仅光学的表示进行比较。我们在 BigEarthNet 上对冻结的图像表示进行线性探测，即 Linear(CONCAT($\mathcal{R}_{\mathrm{R}}, \mathcal{R}_{\mathrm{O}}, \mathcal{R}_{\mathrm{RO}}$)) ，在 DFC2020 上对补丁编码进行线性探测，即 Linear(CONCAT($\mathcal{E}_{\mathrm{R}}, \mathcal{E}_{\mathrm{O}}, \mathcal{E}_{\mathrm{RO}}$)) 。与此同时，DeCUR [75] 通过其新颖的多模态框架学习雷达和雷达-光学表示。他们在 1 % 的 BigEarthNet 训练集上对 DeCUR 表示进行

线性探测，并报告在 BigEarthNet 验证集上的结果；我们采用相同的实验流程，对我们的 CROMA-B 模型进行直接比较。

表 4: 多模态（哨兵-1 和哨兵-2）线性探测在分类和分割基准上的结果。

Model	BigEarthNet mAP	DFC2020 mIoU
SatViT-V2 [74]	79.80	46.20
CROMA-B	**86.24**	51.58
CROMA-L	86.20	**53.24**

多模态结果。CROMA 显著优于由 SatViT-V2 [74] 学成的联合多模态表示（表 4）。我们的联合多模态表示在 BigEarthNet 上优于仅光学的表示 1.2%（CROMA-B 和 CROMA-L），在 DFC2020 上则分别高出 4.9%（CROMA-B）和 3.5%（CROMA-L）（表 1, 3, 4）——这验证了我们采用多模态方法的合理性。在线性探测实验中，CROMA 的仅雷达表示和雷达-光学表示也优于同期的 DeCUR（表 5）。

表 5: 线性探测雷达与雷达-光学表示。

	BigEarthNet (1%) mAP	
Method	Radar	Radar-Opt.
DeCUR	73.7	79.4
CROMA	**75.7**	**81.8**

4 消融分析

4.1 CROMA 设计

消融实验设置。我们通过预训练 CROMA-B 模型进行消融实验，除非另有说明，否则预训练轮次为 100 轮。对于每次消融实验，我们设定可在 640 GB 显存（使用 bfloat16 精度）中容纳的最大批量大小；调整批量大小可使不同方法之间的比较更加合理。在 BigEarthNet 上进行分类时，我们对冻结的单峰值和多模态表示进行线性探测，即 Linear($\mathcal{R}_{\mathrm{R}}$)，Linear($\mathcal{R}_{\mathrm{O}}$)，Linear($\mathcal{R}_{\mathrm{RO}}$)。在 DW-Expert-120 上进行分割时，我们对冻结的块编码进行线性探测，即 Linear($\mathcal{E}_{\mathrm{R}}$)，Linear($\mathcal{E}_{\mathrm{O}}$)，Linear($\mathcal{E}_{\mathrm{RO}}$)。对于 BigEarthNet，我们在与 §3.1 相同的 10% 划分上进行训练，但报告结果在合并的验证集和测试集上（共 236,130 个样本）。对于 DW-Expert-120，我们从 Dynamic World 的 [88] 原始 Sentinel-2 图像中选取 120×120 图像（CROMA 的默认图像大小），并按空间和时间与 Sentinel-1 图像匹配——形成一个高质量的多模态分割数据集。DW-Expert-120 包含 10,200 个训练样本和 45,367 个验证样本。

消融实验结果。❶ 移除任一自监督目标都会显著降低分类和分割任务的准确率。这验证了我们一个基本的设计选择，即针对对齐的多模态数据结合对比学习与重构方法。❷ 尽管我们设计 2D-ALiBi 的主要动机是实现输入大小的外推法（见 §4.2），但我们发现即使不进行外推，其在线性探测任务上的准确率也优于当前最优的 RPE 方法（适用于 ViTs）。在六次评估中平均来看，不使用 X-ALiBi 的 2D-ALiBi 性能优于位置编码生成器（PEG, [90]）0.5% 和 2D 正弦嵌入 1.5%。（我们通过在预训练期间对被掩码的图像块进行零填充的方式将 PEG 适配至 MAE 风格的掩码机制，灵感来自 [91]）。结合使用 X-ALiBi 与 2D-ALiBi 可进一步提升平均性能 0.2%（见表 6）——尤其在多模态性能上表现更优，这正是我们引入 X-ALiBi 的初衷。我们认为 2D-ALiBi 表现出色的原因有两点，附录 §A.2 中提供了相关证据：第一，尽管未以旋转不变为目标进行训练，2D-ALiBi 仍能学习到旋转不变的表示，这一特性对于卫星影像尤为重要，有助于提升分类性能；第二，2D-ALiBi 有效防止了块级表示崩溃（即图像

表 6: 仅雷达（“R”）、仅光学（“O”）以及雷达-光学联合（“RO”）输入下的线性探测消融结果。我们综合考虑性能与成本来选择设计方案。所有位于“全部默认”以下的行均报告了消融情况与默认情况之间的性能差异。

	Case (default)	Ablation	batch size	cost	Classification (mAP)			Segmentation (mIoU)			
					R	O	RO	R	O	RO	Avg
	all default		7.2k	1.0×	78.2	84.5	84.8	40.8	56.0	56.5	66.8
❶	objectives (both)	MAE-only	7.2k	1.0×	−10.4	−6.0	−5.6	−9.2	−8.4	−5.1	−7.5
		contrast-only	14k	0.6×	−3.2	−3.0	—	−2.9	−3.7	—	—
❷	position encoding (2D-ALiBi + X-ALiBi)	2D-ALiBi	7.2k	1.0×	−0.2	−0.2	−0.3	0.1	0.0	−0.9	−0.2
		PEG [90]	6.9k	1.0×	−0.3	0.0	−0.1	−0.6	−1.0	−1.9	−0.7
		2D-sinusoidal	7.2k	1.0×	−3.8	−2.9	−1.3	−2.2	−0.1	−0.2	−1.7
❸	masking (independent 75%)	shared 25%	2.4k	3.0×	−0.5	−1.0	−1.1	1.1	0.5	−0.2	−0.2
		shared 50%	3.7k	1.8×	−0.3	−0.7	−0.7	1.0	0.6	0.1	0.0
		shared 75%	7.2k	1.0×	−0.8	−0.5	−0.3	0.0	0.1	0.0	−0.2
		independent 50%	3.7k	1.8×	−0.2	−0.5	−0.5	0.9	0.7	0.3	0.1
❹	MAE target (radar & optical)	radar-only	7.2k	1.0×	−0.1	−0.2	−0.6	0.3	−0.2	−1.4	−0.5
		optical-only	7.2k	1.0×	−0.1	−0.2	−0.2	−0.1	−0.1	−0.6	−0.2
❺	MAE decoder (depth=1, dim=512)	depth=6, dim=768	4.3k	1.7×	0.1	−0.1	0.1	0.4	0.2	0.2	0.1
❻	scale (ViT-B, epochs=100)	ViT-B, epochs=300	7.2k	3.0×	1.6	0.5	0.4	1.7	1.3	0.5	1.0
		ViT-L, epochs=600	3k	15×	2.5	0.4	0.5	2.8	0.9	0.1	1.2

内各块的表示趋于相似，导致局部信息丢失），而这种现象在对比学习中常被观察到 [47]；保持块间多样性可能有助于提升分割性能。❸ 较低的掩码比率会损害分类性能但有利于分割，同时增加计算成本。对于 50% 与 75% 两种掩码比率，独立掩码（即光学与雷达样本分别独立掩码）略优于共享掩码。尽管 50% 独立掩码比 75% 共享掩码高出 0.1%，我们仍选择更高的掩码比率，因其能带来 1.8× 的加速效果。❹ 多模态目标（14 通道）的表现优于仅光学目标（12 通道）0.2%，后者又优于仅雷达目标（2 通道）0.3%（见表 6）；这表明重建更多信息能够获得更具泛化性的表示。多模态目标对于学习丰富的多模态表示尤为关键。❺ 更大的解码器有助于提升分割性能，但代价为 1.7× 增加。MAE 已证明深层解码器可提升线性探测准确率 [31]，但 CROMA 对解码器规模具有很强的鲁棒性。因此，我们选择效率最高的方案，即采用 1 层、512 维的解码器。❻ 我们通过在 ViT-B 模型上进行 100 轮次的预训练来设计 CROMA，并综合考虑线性探测性能与计算成本。因此，当模型规模扩大时，我们的设计可能并非最优。然而，增加训练轮次和模型规模确实能提升表示能力，尤其是对雷达仅数据的表示能力。

在附录 §A.1 中，我们还尝试了——所有结果均显示影响极小或为负——任务权重、更大的解码器大小、VICReg [92]、跨模态块编码之间的均方误差损失（受 [93] 启发）、跨模态块编码之间的 InfoNCE 损失（受 [94] 启发）、硬负样本混合 [95]，以及在预训练末尾采用更低掩码率的微调 [68]。

4.2 将表示扩展到更大的图像

外推法设置。对三个 CROMA-B 模型（2D-正弦、PEG [90] 和 2D-ALiBi）进行 100 轮次的预训练后，我们在 DW-Expert-120 的哨兵-2 图像（120 × 120 像素）上微调所有参数（以及一个线性头部）。随后，我们直接在不同大小的图像上评估模型，以测试其在测试时的外推能力。我们通过从 Dynamic World 中原始的 510 × 510 图像中裁剪创建具有不同图像大小

的验证集 [88]。无论图像大小如何，我们均保留模型训练时所用的每像素 10 m 的空间分辨率——在测试时对外推至更小或更大的地理区域。对于 2D-正弦嵌入，我们还评估了一种在将 ViTs 应用于更大图像时常使用的嵌入插值算法 [31, 26, 48, 96]。

外推法结果。2D-ALiBi 在 504×504 像素图像上优于 PEG 1.7%（表 7）。令人惊讶的是，我们在测试区域比模型训练区域 17.64× 更大时，仅看到 mIoU 下降了 0.7% — 有效地从每张图像的 225 个补丁推广到 3,969 个补丁。我们通过将 ALiBi [66] 扩展到二维输入，基于查询和键对之间的欧氏距离惩罚注意力得分来实现这一点。通过在部分注意力头中编码方向或学习标量 [97]，我们可能获得更好的结果；我们将这些研究留待未来工作。我们认为 X- 和 2D-ALiBi 在我们的 CROMA 框架之外具有巨大潜力，例如通过将这些方法扩展到其他模态、视角或三维数据。

表 7: 模型在 120×120 分辨率上训练并在不同分辨率上评估的分割结果（mIoU）。

Method \ Test Res. (Train Res. ↓)	48	96	120	224	384	448	504
2D-Sinusoidal	54.4	58.5	59.2	38.2	24.9	21.8	19.5
2D-Sinusoidal w/ interp.	50.7	58.6	59.2	58.3	56.2	55.5	54.9
PEG [90]	55.1	58.0	58.3	58.5	57.7	57.4	57.1
2D-ALiBi	**56.3**	**59.0**	**59.3**	**59.5**	**59.1**	**59.0**	**58.8**

5 相关工作

遥感表示. 遥感领域的深度学习多年来一直是活跃的研究方向。近年来，研究人员利用自监督学习框架来学习遥感数据的表示，这些表示可广泛应用于对社会具有重要意义的下游任务。在设计对比性预训练任务时，遥感研究者通过利用空间 [98, 99, 100, 101, 102, 103, 104, 105, 106, 107, 108]、时间 [24, 25, 109]、光谱 [110] 或跨模态 [111, 112, 113, 114, 115, 116] 信息构建正样本对。在设计重构性预训练任务时，研究者会保留部分光谱波段 [117]、像素 [118, 119, 120, 121] 和分辨率 [27]。然而，这些研究——包括同期的 Scale-MAE [27] 以及有影响力的 tile2vec [108]、GASSL [24] 和 SeCo [25] 研究——要么在较小规模上进行，要么仅包含可见光（红、绿、蓝）波段的波长；这限制了它们在下游应用中的实用性，因为非可见光波段包含对许多遥感任务至关重要的信息 关键 [53, 122, 123, 124]。例如，测量物体在近红外波段反射率的能力在植被识别 [125]、健康与生产力评估 [126]，以及水体识别 [127]、土壤湿度 [128] 和植被含水量 [129] 等应用中极为重要。

ViT 的相对位置编码。自然语言处理中的前沿 Transformer 模型使用了 RPE [130, 131, 132]，但固定二维正弦嵌入在 ViT 中仍占主导地位。相较于绝对位置编码，RPE 具有更优的归纳偏置，可带来性能提升，有时还能实现外推法至更大的图像尺寸，即直接将训练于某一图像尺寸的模型应用于另一尺寸而无需进一步训练。这种外推能力对遥感基础模型具有重要价值，因为图像尺寸差异显著——图像通常从大场景裁剪为尺寸各异的较小区域。位置编码生成器（PEG, [90]）是一种前沿的 RPE 方法，它在 ViT 层之间使用卷积；实验证明，当测试更大图像时，PEG 显著优于其他 RPE 方法。iRPE [133] 是另一种更为复杂的 ViT 用 RPE 方法；然而，其并未表现出外推能力。我们未发现此前有研究在交叉注意力中利用 RPE。

6 结论

我们提出了一种新颖的框架，通过联合利用对比和重构自监督目标，学习地球观测数据的单峰值和多模态表示。我们将一种最先进的 1D 序列位置编码方法扩展至 2D 输入和交叉注意力；据我们所知，这是首次在交叉注意力中显式使用位置编码。这些策略使我们的模型能够在测试时外推至更大的图像，并提升在 * 单峰值 * 和 * 多模态 * 数据上的性能。我们对预训练模型在多种任务和方法上进行了 * 广泛 * 评估，表现优于之前的最先进水平。尽管我们

的方法专为多模态卫星影像设计，但也可应用于其他提供空间对齐多模态数据的应用场景，例如医学影像或自动驾驶。

我们工作的主要局限在于我们仅关注时序静态的哨兵-1 与哨兵-2 数据；在未来，我们将探索其他能够提供更高空间或光谱分辨率以及时间序列数据的传感器。尽管存在这一局限，哨兵-1 与哨兵-2 仍是科研领域中最广泛使用的卫星影像数据源——这使得我们的模型成为遥感社区及遥感衍生产品使用者（例如地理学家、经济学家或环境科学家）极为宝贵的资源。

7 致谢

本工作得益于 Cyxtera Technologies 提供的计算资源以及 NVIDIA 学术硬件资助计划的支持。Anthony 感谢向量研究所在他硕士学习期间提供的财政支持。

参考文献

[1] Jihyeon Lee, Nina R. Brooks, Fahim Tajwar, Marshall Burke, Stefano Ermon, David B. Lobell, Debashish Biswas, and Stephen P. Luby. Scalable deep learning to identify brick kilns and aid regulatory capacity. *Proceedings of the National Academy of Sciences*, 2021.

[2] Arati Paul, Soumya Bandyopadhyay, and Uday Raj. Brick kiln detection in remote sensing imagery using deep neural network and change analysis. *Spatial Information Research*, 2021.

[3] Fen Chen, Ruilong Ren, Tim Van de Voorde, Wenbo Xu, Guiyun Zhou, and Yan Zhou. Fast Automatic Airport Detection in Remote Sensing Images Using Convolutional Neural Networks. *Remote Sensing*, 2018.

[4] Raian V. Maretto, Leila M. G. Fonseca, Nathan Jacobs, Thales S. Körting, Hugo N. Bendini, and Leandro L. Parente. Spatio-Temporal Deep Learning Approach to Map Deforestation in Amazon Rainforest. *IEEE Geoscience and Remote Sensing Letters*, 2021.

[5] Seong-Hyeok Lee, Kuk-Jin Han, Kwon Lee, Kwang-Jae Lee, Kwan-Young Oh, and Moung-Jin Lee. Classification of Landscape Affected by Deforestation Using High-Resolution Remote Sensing Data and Deep-Learning Techniques. *Remote Sensing*, 2020.

[6] Pablo Pozzobon de Bem, Osmar Abílio de Carvalho Junior, Renato Fontes Guimarães, and Roberto Arnaldo Trancoso Gomes. Change Detection of Deforestation in the Brazilian Amazon Using Landsat Data and Convolutional Neural Networks. *Remote Sensing*, 2020.

[7] Bruno Menini Matosak, Leila Maria Garcia Fonseca, Evandro Carrijo Taquary, Raian Vargas Maretto, Hugo do Nascimento Bendini, and Marcos Adami. Mapping Deforestation in Cerrado Based on Hybrid Deep Learning Architecture and Medium Spatial Resolution Satellite Time Series. *Remote Sensing*, 2022.

[8] Hannah Kerner, Gabriel Tseng, Inbal Becker-Reshef, Catherine Nakalembe, Brian Barker, Blake Munshell, Madhava Paliyam, and Mehdi Hosseini. Rapid Response Crop Maps in Data Sparse Regions. *CoRR*, abs/2006.16866, 2020.

[9] Nataliia Kussul, Mykola Lavreniuk, Sergii Skakun, and Andrii Shelestov. Deep Learning Classification of Land Cover and Crop Types Using Remote Sensing Data. *IEEE Geoscience and Remote Sensing Letters*, 2017.

[10] Foyez Ahmed Prodhan, Jiahua Zhang, Fengmei Yao, Lamei Shi, Til Prasad Pangali Sharma, Da Zhang, Dan Cao, Minxuan Zheng, Naveed Ahmed, and Hasiba Pervin Mohana. Deep Learning for Monitoring Agricultural Drought in South Asia Using Remote Sensing Data. *Remote Sensing*, 2021.

[11] R. Bentivoglio, E. Isufi, S. N. Jonkman, and R. Taormina. Deep learning methods for flood mapping: a review of existing applications and future research directions. *Hydrology and Earth System Sciences*, 2022.

[12] Maryam Rahnemoonfar, Tashnim Chowdhury, Argho Sarkar, Debvrat Varshney, Masoud Yari, and Robin Roberson Murphy. FloodNet: A High Resolution Aerial Imagery Dataset for Post Flood Scene Understanding. *IEEE Access*, 2021.

[13] Fantine Huot, R. Lily Hu, Nita Goyal, Tharun Sankar, Matthias Ihme, and Yi-Fan Chen. Next Day Wildfire Spread: A Machine Learning Dataset to Predict Wildfire Spreading From Remote-Sensing Data. *IEEE Transactions on Geoscience and Remote Sensing*, 2022.

[14] Dmitry Rashkovetsky, Florian Mauracher, Martin Langer, and Michael Schmitt. Wildfire Detection From Multisensor Satellite Imagery Using Deep Semantic Segmentation. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2021.

[15] Panagiotis Barmpoutis, Periklis Papaioannou, Kosmas Dimitropoulos, and Nikos Grammalidis. A Review on Early Forest Fire Detection Systems Using Optical Remote Sensing. *Sensors*, 2020.

[16] Arman Khachiyan, Anthony Thomas, Huye Zhou, Gordon Hanson, Alex Cloninger, Tajana Rosing, and Amit K. Khandelwal. Using Neural Networks to Predict Microspatial Economic Growth. *American Economic Review: Insights*, 2022.

[17] Esra Suel, Samir Bhatt, Michael Brauer, Seth Flaxman, and Majid Ezzati. Multimodal deep learning from satellite and street-level imagery for measuring income, overcrowding, and environmental deprivation in urban areas. *Remote Sensing of Environment*, 2021.

[18] Christopher Yeh, Anthony Perez, Anne Driscoll, George Azzari, Zhongyi Tang, David Lobell, Stefano Ermon, and Marshall Burke. Using publicly available satellite imagery and deep learning to understand economic well-being in Africa. *Nature Communications*, 2020.

[19] Michael Xie, Neal Jean, Marshall Burke, David Lobell, and Stefano Ermon. Transfer Learning from Deep Features for Remote Sensing and Poverty Mapping. In *AAAI*, 2016.

[20] Luna Yue Huang, Solomon M Hsiang, and Marco Gonzalez-Navarro. Using Satellite Imagery and Deep Learning to Evaluate the Impact of Anti-Poverty Programs. Working paper, National Bureau of Economic Research, 2021.

[21] David Rolnick, Priya L. Donti, Lynn H. Kaack, Kelly Kochanski, Alexandre Lacoste, Kris Sankaran, Andrew Slavin Ross, Nikola Milojevic-Dupont, Natasha Jaques,

Anna Waldman-Brown, Alexandra Sasha Luccioni, Tegan Maharaj, Evan D. Sherwin, S. Karthik Mukkavilli, Konrad P. Kording, Carla P. Gomes, Andrew Y. Ng, Demis Hassabis, John C. Platt, Felix Creutzig, Jennifer Chayes, and Yoshua Bengio. Tackling Climate Change with Machine Learning. *ACM Comput. Surv.*, 2022.

[22] Alexandre Lacoste, Evan David Sherwin, Hannah Kerner, Hamed Alemohammad, Björn Lütjens, Jeremy Irvin, David Dao, Alex Chang, Mehmet Gunturkun, Alexandre Drouin, Pau Rodríguez, and David Vázquez. Toward Foundation Models for Earth Monitoring: Proposal for a Climate Change Benchmark. In *NeurIPS Workshops*, 2021.

[23] Xiao Xiang Zhu, Devis Tuia, Lichao Mou, Gui-Song Xia, Liangpei Zhang, Feng Xu, and Friedrich Fraundorfer. Deep Learning in Remote Sensing: A Comprehensive Review and List of Resources. *IEEE Geoscience and Remote Sensing Magazine*, 2017.

[24] Kumar Ayush, Burak Uzkent, Chenlin Meng, Kumar Tanmay, Marshall Burke, David Lobell, and Stefano Ermon. Geography-Aware Self-Supervised Learning. In *ICCV*, 2021.

[25] Oscar Mañas, Alexandre Lacoste, Xavier Giró-i Nieto, David Vazquez, and Pau Rodríguez. Seasonal Contrast: Unsupervised Pre-Training From Uncurated Remote Sensing Data. In *ICCV*, 2021.

[26] Yezhen Cong, Samar Khanna, Chenlin Meng, Patrick Liu, Erik Rozi, Yutong He, Marshall Burke, David B. Lobell, and Stefano Ermon. SatMAE: Pre-training Transformers for Temporal and Multi-Spectral Satellite Imagery. In *NeurIPS*, 2022.

[27] Colorado J. Reed, Ritwik Gupta, Shufan Li, Sarah Brockman, Christopher Funk, Brian Clipp, Kurt Keutzer, Salvatore Candido, Matt Uyttendaele, and Trevor Darrell. Scale-MAE: A Scale-Aware Masked Autoencoder for Multiscale Geospatial Representation Learning. *CoRR*, abs/2212.14532, 2023.

[28] Aäron van den Oord, Yazhe Li, and Oriol Vinyals. Representation Learning with Contrastive Predictive Coding. *CoRR*, abs/1807.03748, 2018.

[29] Philip Bachman, R Devon Hjelm, and William Buchwalter. Learning Representations by Maximizing Mutual Information Across Views. In *NeurIPS*, 2019.

[30] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A Simple Framework for Contrastive Learning of Visual Representations. In *ICML*, 2020.

[31] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked Autoencoders Are Scalable Vision Learners. In *CVPR*, 2022.

[32] Hangbo Bao, Li Dong, Songhao Piao, and Furu Wei. BEiT: BERT Pre-Training of Image Transformers. In *ICLR*, 2022.

[33] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *NAACL*, 2019.

[34] Yonglong Tian, Dilip Krishnan, and Phillip Isola. Contrastive Multiview Coding. In *ECCV*, 2020.

[35] Michael Tschannen, Josip Djolonga, Marvin Ritter, Aravindh Mahendran, Neil Houlsby, Sylvain Gelly, and Mario Lucic. Self-Supervised Learning of Video-Induced Visual Invariances. In *CVPR*, 2020.

[36] Yonglong Tian, Chen Sun, Ben Poole, Dilip Krishnan, Cordelia Schmid, and Phillip Isola. What Makes for Good Views for Contrastive Learning? In *NeurIPS*, 2020.

[37] Tete Xiao, Xiaolong Wang, Alexei A Efros, and Trevor Darrell. What Should Not Be Contrastive in Contrastive Learning. In *ICLR*, 2021.

[38] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum Contrast for Unsupervised Visual Representation Learning. In *CVPR*, 2020.

[39] Xinlei Chen and Kaiming He. Exploring Simple Siamese Representation Learning. In *CVPR*, 2021.

[40] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Guo, Mohammad Gheshlaghi Azar, Bilal Piot, koray kavukcuoglu, Remi Munos, and Michal Valko. Bootstrap Your Own Latent - A New Approach to Self-Supervised Learning. In *NeurIPS*, 2020.

[41] Zhenda Xie, Zheng Zhang, Yue Cao, Yutong Lin, Jianmin Bao, Zhuliang Yao, Qi Dai, and Han Hu. SimMIM: A Simple Framework for Masked Image Modeling. In *CVPR*, 2022.

[42] Baruch Epstein and Ron Meir. Generalization Bounds For Unsupervised and Semi-Supervised Learning With Autoencoders. *CoRR*, abs/1902.01449, 2019.

[43] Johannes Lehner, Benedikt Alkin, Andreas Fürst, Elisabeth Rumetshofer, Lukas Miklautz, and Sepp Hochreiter. Contrastive Tuning: A Little Help to Make Masked Autoencoders Forget. *CoRR*, abs/2304.10520, 2023.

[44] Salah Rifai, Pascal Vincent, Xavier Muller, Xavier Glorot, and Yoshua Bengio. Contractive Auto-Encoders: Explicit Invariance during Feature Extraction. In *ICML*, 2011.

[45] Mannat Singh, Quentin Duval, Kalyan Vasudev Alwala, Haoqi Fan, Vaibhav Aggarwal, Aaron Adcock, Armand Joulin, Piotr Dollár, Christoph Feichtenhofer, Ross Girshick, Rohit Girdhar, and Ishan Misra. The effectiveness of MAE pre-pretraining for billion-scale pretraining. *CoRR*, abs/2303.13496, 2023.

[46] Sanghyun Woo, Shoubhik Debnath, Ronghang Hu, Xinlei Chen, Zhuang Liu, In So Kweon, and Saining Xie. ConvNeXt V2: Co-designing and Scaling ConvNets with Masked Autoencoders. In *CVPR*, 2023.

[47] Namuk Park, Wonjae Kim, Byeongho Heo, Taekyung Kim, and Sangdoo Yun. What Do Self-Supervised Vision Transformers Learn? In *ICLR*, 2023.

[48] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In *ICLR*, 2021.

[49] Jiahui Yu, Zirui Wang, Vijay Vasudevan, Legg Yeung, Mojtaba Seyedhosseini, and Yonghui Wu. CoCa: Contrastive Captioners are Image-Text Foundation Models. *Transactions on Machine Learning Research*, 2022.

[50] Yuan Gong, Andrew Rouditchenko, Alexander H. Liu, David Harwath, Leonid Karlinsky, Hilde Kuehne, and James R. Glass. Contrastive Audio-Visual Masked Autoencoder. In *ICLR*, 2023.

[51] Haoxuan You, Mandy Guo, Zhecan Wang, Kai-Wei Chang, Jason Baldridge, and Jiahui Yu. CoBIT: A Contrastive Bi-directional Image-Text Generation Model. *CoRR*, abs/2303.13455, 2023.

[52] Po-Yao Huang, Vasu Sharma, Hu Xu, Chaitanya Ryali, Haoqi Fan, Yanghao Li, Shang-Wen Li, Gargi Ghosh, Jitendra Malik, and Christoph Feichtenhofer. MAViL: Masked Audio-Video Learners. *CoRR*, abs/2212.08071, 2022.

[53] Gary A Shaw and Hsiaohua K Burke. Spectral imaging for remote sensing. *Lincoln laboratory journal*, 2003.

[54] Alberto Moreira, Pau Prats-Iraola, Marwan Younis, Gerhard Krieger, Irena Hajnsek, and Konstantinos P Papathanassiou. A tutorial on synthetic aperture radar. *IEEE Geoscience and remote sensing magazine*, 2013.

[55] Cle Pohl and John L Van Genderen. Review article multisensor image fusion in remote sensing: concepts, methods and applications. *International journal of remote sensing*, 1998.

[56] Pedram Ghamisi, Behnood Rasti, Naoto Yokoya, Qunming Wang, Bernhard Hofle, Lorenzo Bruzzone, Francesca Bovolo, Mingmin Chi, Katharina Anders, Richard Gloaguen, Peter M. Atkinson, and Jon Atli Benediktsson. Multisource and Multi-temporal Data Fusion in Remote Sensing: A Comprehensive Review of the State of the Art. *IEEE Geoscience and Remote Sensing Magazine*, 2019.

[57] Michael Schmitt and Xiao Xiang Zhu. Data Fusion and Remote Sensing: An ever-growing relationship. *IEEE Geoscience and Remote Sensing Magazine*, 2016.

[58] Sunan He, Taian Guo, Tao Dai, Ruizhi Qiao, Chen Wu, Xiujun Shu, and Bo Ren. VLMAE: Vision-Language Masked Autoencoder. *CoRR*, abs/2208.09374, 2022.

[59] Ziyang Luo, Yadong Xi, Rongsheng Zhang, Gongzheng Li, Zeng Zhao, and Jing Ma. Conditioned Masked Language and Image Modeling for Image-Text Dense Retrieval. In *EMNLP*, 2022.

[60] Junnan Li, Ramprasaath Selvaraju, Akhilesh Gotmare, Shafiq Joty, Caiming Xiong, and Steven Chu Hong Hoi. Align before Fuse: Vision and Language Representation Learning with Momentum Distillation. In *NeurIPS*, 2021.

[61] Jinyu Yang, Jiali Duan, Son Tran, Yi Xu, Sampath Chanda, Liqun Chen, Belinda Zeng, Trishul Chilimbi, and Junzhou Huang. Vision-Language Pre-training with Triple Contrastive Learning. In *CVPR*, 2022.

[62] Xiujun Li, Xi Yin, Chunyuan Li, Pengchuan Zhang, Xiaowei Hu, Lei Zhang, Lijuan Wang, Houdong Hu, Li Dong, Furu Wei, et al. Oscar: Object-semantics Aligned Pre-training for Vision-Language Tasks. In *ECCV*, 2020.

[63] Junnan Li, Dongxu Li, Caiming Xiong, and Steven Hoi. BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation. In *ICML*, 2022.

[64] Weicheng Kuo, AJ Piergiovanni, Dahun Kim, Xiyang Luo, Ben Caine, Wei Li, Abhijit Ogale, Luowei Zhou, Andrew Dai, Zhifeng Chen, et al. MaMMUT: A Simple Architecture for Joint Learning for MultiModal Tasks. *CoRR*, abs/2303.16839, 2023.

[65] Yan Zeng, Xinsong Zhang, and Hang Li. Multi-Grained Vision Language Pre-Training: Aligning Texts with Visual Concepts. In *ICML*, 2022.

[66] Ofir Press, Noah Smith, and Mike Lewis. Train Short, Test Long: Attention with Linear Biases Enables Input Length Extrapolation. In *ICLR*, 2022.

[67] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention Is All You Need. In *NeurIPS*, 2017.

[68] Yanghao Li, Haoqi Fan, Ronghang Hu, Christoph Feichtenhofer, and Kaiming He. Scaling Language-Image Pre-training via Masking. In *CVPR*, 2023.

[69] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning Transferable Visual Models From Natural Language Supervision. In *ICML*, 2021.

[70] Yi Wang, Nassim Ait Ali Braham, Zhitong Xiong, Chenying Liu, Conrad M Albrecht, and Xiao Xiang Zhu. SSL4EO-S12: A Large-Scale Multi-Modal, Multi-Temporal Dataset for Self-Supervised Learning in Earth Observation. *CoRR*, abs/2211.07044, 2022.

[71] Linus Scheibenreif, Joëlle Hanna, Michael Mommert, and Damian Borth. Self-Supervised Vision Transformers for Land-Cover Segmentation and Classification. In *CVPR Workshops*, 2022.

[72] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging Properties in Self-Supervised Vision Transformers. In *ICCV*, 2021.

[73] Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Yann LeCun, and Nicolas Ballas. Self-Supervised Learning from Images with a Joint-Embedding Predictive Architecture. In *CVPR*, 2023.

[74] Anthony Fuller, Koreen Millard, and James R. Green. Transfer Learning with Pre-trained Remote Sensing Transformers. *CoRR*, abs/2209.14969, 2022.

[75] Yi Wang, Conrad M Albrecht, Nassim Ait Ali Braham, Chenying Liu, Zhitong Xiong, and Xiao Xiang Zhu. DeCUR: decoupling common & unique representations for multimodal self-supervision. *CoRR*, abs/2309.05300, 2023.

[76] Gencer Sumbul, Arne de Wall, Tristan Kreuziger, Filipe Marcelino, Hugo Costa, Pedro Benevides, Mário Caetano, Begüm Demir, and Volker Markl. BigEarthNet-MM: A Large-Scale, Multimodal, Multilabel Benchmark Archive for Remote Sensing Image Classification and Retrieval [Software and Data Sets]. *IEEE Geoscience and Remote Sensing Magazine*, 2021.

[77] Patrick Helber, Benjamin Bischke, Andreas Dengel, and Damian Borth. Eurosat: A novel dataset and deep learning benchmark for land use and land cover classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2019.

[78] Amanda A Boatswain Jacques, Abdoulaye Baniré Diallo, and Etienne Lord. Towards the Creation of a Canadian Land-Use Dataset for Agricultural Land Classification. In *42nd Canadian Symposium on Remote Sensing: Understanding Our World: Remote Sensing for a Sustainable Future*, 2021.

[79] Matthew Gwilliam and Abhinav Shrivastava. Beyond Supervised vs. Unsupervised: Representative Benchmarking and Analysis of Image Representation Learning. In *CVPR*, 2022.

[80] Jae-Hun Lee, Doyoung Yoon, ByeongMoon Ji, Kyungyul Kim, and Sangheum Hwang. Rethinking Evaluation Protocols of Visual Representations Learned via Self-supervised Learning. *CoRR*, abs/2304.03456, 2023.

[81] Jinghao Zhou, Chen Wei, Huiyu Wang, Wei Shen, Cihang Xie, Alan Yuille, and Tao Kong. Image BERT Pre-training with Online Tokenizer. In *ICLR*, 2022.

[82] Colorado J Reed, Xiangyu Yue, Ani Nrusimha, Sayna Ebrahimi, Vivek Vijaykumar, Richard Mao, Bo Li, Shanghang Zhang, Devin Guillory, Sean Metzger, et al. Self-Supervised Pretraining Improves Self-Supervised Pretraining. In *WACV*, 2022.

[83] Klemen Kotar, Gabriel Ilharco, Ludwig Schmidt, Kiana Ehsani, and Roozbeh Mottaghi. Contrasting Contrastive Self-Supervised Representation Learning Pipelines. In *ICCV*, 2021.

[84] Samira Abnar, Mostafa Dehghani, Behnam Neyshabur, and Hanie Sedghi. Exploring the Limits of Large Scale Pre-training. In *ICLR*, 2022.

[85] Leland McInnes, John Healy, Nathaniel Saul, and Lukas Großberger. UMAP: Uniform Manifold Approximation and Projection. *Journal of Open Source Software*, 2018.

[86] Wes Gurnee, Neel Nanda, Matthew Pauly, Katherine Harvey, Dmitrii Troitskii, and Dimitris Bertsimas. Finding Neurons in a Haystack: Case Studies with Sparse Probing. *CoRR*, abs/2305.01610, 2023.

[87] Naoto Yokoya, Pedram Ghamisi, Ronny Hänsch, and Michael Schmitt. 2020 IEEE GRSS Data Fusion Contest: Global Land Cover Mapping With Weak Supervision. *IEEE Geoscience and Remote Sensing Magazine*, 2020.

[88] Christopher F Brown, Steven P Brumby, Brookie Guzder-Williams, Tanya Birch, Samantha Brooks Hyde, Joseph Mazzariello, Wanda Czerwinski, Valerie J Pasquarella, Robert Haertel, Simon Ilyushchenko, et al. Dynamic World, Near real-time global 10 m land use land cover mapping. *Scientific Data*, 2022.

[89] Katerina Kikaki, Ioannis Kakogeorgiou, Paraskevi Mikeli, Dionysios E Raitsos, and Konstantinos Karantzalos. MARIDA: A benchmark for Marine Debris detection from Sentinel-2 remote sensing data. *PloS one*, 2022.

[90] Xiangxiang Chu, Zhi Tian, Bo Zhang, Xinlong Wang, and Chunhua Shen. Conditional Positional Encodings for Vision Transformers. In *ICLR*, 2023.

[91] Peng Gao, Teli Ma, Hongsheng Li, Ziyi Lin, Jifeng Dai, and Yu Qiao. MCMAE: Masked Convolution Meets Masked Autoencoders. In *NeurIPS*, 2022.

[92] Adrien Bardes, Jean Ponce, and Yann LeCun. VICReg: Variance-Invariance-Covariance Regularization for Self-Supervised Learning. In *ICLR*, 2022.

[93] Adrien Bardes, Jean Ponce, and Yann LeCun. VICRegL: Self-Supervised Learning of Local Visual Features. In *NeurIPS*, 2022.

[94] Xinlong Wang, Rufeng Zhang, Chunhua Shen, Tao Kong, and Lei Li. Dense Contrastive Learning for Self-Supervised Visual Pre-Training. In *CVPR*, 2021.

[95] Yannis Kalantidis, Mert Bulent Sariyildiz, Noe Pion, Philippe Weinzaepfel, and Diane Larlus. Hard Negative Mixing for Contrastive Learning. In *NeurIPS*, 2020.

[96] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Herve Jegou. Training data-efficient image transformers & distillation through attention. In *ICML*, 2021.

[97] Alexei Baevski, Arun Babu, Wei-Ning Hsu, and Michael Auli. Efficient Self-supervised Learning with Contextualized Target Representations for Vision, Speech and Language. *CoRR*, abs/2212.07525, 2022.

[98] Gengchen Mai, Ni Lao, Yutong He, Jiaming Song, and Stefano Ermon. CSP: Self-Supervised Contrastive Spatial Pre-Training for Geospatial-Visual Representations. In *ICCV*, 2023.

[99] Chao Tao, Ji Qi, Weipeng Lu, Hao Wang, and Haifeng Li. Remote Sensing Image Scene Classification With Self-Supervised Paradigm Under Limited Labeled Samples. *IEEE Geoscience and Remote Sensing Letters*, 2022.

[100] Heechul Jung, Yoonju Oh, Seongho Jeong, Chaehyeon Lee, and Taegyun Jeon. Contrastive Self-Supervised Learning With Smoothed Representation for Remote Sensing. *IEEE Geoscience and Remote Sensing Letters*, 2022.

[101] Jian Kang, Ruben Fernandez-Beltran, Puhong Duan, Sicong Liu, and Antonio J. Plaza. Deep Unsupervised Embedding for Remotely Sensed Images Based on Spatially Augmented Momentum Contrast. *IEEE Transactions on Geoscience and Remote Sensing*, 2021.

[102] Yuxing Chen and Lorenzo Bruzzone. Self-Supervised SAR-Optical Data Fusion of Sentinel-1/-2 Images. *IEEE Transactions on Geoscience and Remote Sensing*, 2022.

[103] Lucas Kruitwagen. Towards DeepSentinel: An extensible corpus of labelled Sentinel-1 and -2 imagery and a general-purpose sensor-fusion semantic embedding model. *CoRR*, abs/2102.06260, 2021.

[104] Xin Huang, Mengjie Dong, Jiayi Li, and Xian Guo. A 3-D-Swin Transformer-Based Hierarchical Contrastive Learning Method for Hyperspectral Image Classification. *IEEE Transactions on Geoscience and Remote Sensing*, 2022.

[105] Johan Bjorck, Brendan H. Rappazzo, Qinru Shi, Carrie Brown-Lima, Jennifer Dean, Angela Fuller, and Carla Gomes. Accelerating Ecological Sciences from Above: Spatial Contrastive Learning for Remote Sensing. In *AAAI*, 2021.

[106] Haifeng Li, Yi Li, Guo Zhang, Ruoyun Liu, Haozhe Huang, Qing Zhu, and Chao Tao. Global and Local Contrastive Self-Supervised Learning for Semantic Segmentation of HR Remote Sensing Images. *IEEE Transactions on Geoscience and Remote Sensing*, 2022.

[107] Xinye Wanyan, Sachith Seneviratne, Shuchang Shen, and Michael Kirley. DINO-MC: Self-supervised Contrastive Learning for Remote Sensing Imagery with Multi-sized Local Crops. *CoRR*, abs/2303.06670, 2023.

[108] Neal Jean, Sherrie Wang, Anshul Samar, George Azzari, David Lobell, and Stefano Ermon. Tile2Vec: Unsupervised Representation Learning for Spatially Distributed Data. In *AAAI*, 2019.

[109] Haozhe Huang, Zhongfeng Mou, Yunying Li, Qiujun Li, Jie Chen, and Haifeng Li. Spatial-Temporal Invariant Contrastive Learning for Remote Sensing Scene Classification. *IEEE Geoscience and Remote Sensing Letters*, 2022.

[110] Vladan Stojnic and Vladimir Risojevic. Self-Supervised Learning of Remote Sensing Scene Representations Using Contrastive Multiview Coding. In *CVPR Workshops*, 2021.

[111] Gencer Sumbul, Markus Müller, and Begüm Demir. A Novel Self-Supervised Cross-Modal Image Retrieval Method in Remote Sensing. In *ICIP*, 2022.

[112] Isaac Corley and Peyman Najafirad. Supervising Remote Sensing Change Detection Models With 3d Surface Semantics. In *ICIP*, 2022.

[113] Keumgang Cha, Junghoon Seo, and Yeji Choi. Contrastive Multiview Coding With Electro-Optics for SAR Semantic Segmentation. *IEEE Geoscience and Remote Sensing Letters*, 2022.

[114] L. Scheibenreif, M. Mommert, and D. Borth. Contrastive Self-supervised Data Fusion for Satellite Imagery. *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, 2022.

[115] Umangi Jain, Alex Wilson, and Varun Gulshan. Multimodal contrastive learning for remote sensing tasks. *CoRR*, abs/2209.02329, 2022.

[116] Chenfang Liu, Hao Sun, Yanjie Xu, and Gangyao Kuang. Multi-Source Remote Sensing Pretraining Based on Contrastive Self-Supervised Learning. *Remote Sensing*, 2022.

[117] S. Vincenzi, A. Porrello, P. Buzzega, M. Cipriano, P. Fronte, R. Cuccu, C. Ippoliti, A. Conte, and S. Calderara. The color out of space: learning self-supervised representations for Earth Observation imagery. In *ICPR*, 2021.

[118] Anthony Fuller, Koreen Millard, and James R. Green. SatViT: Pretraining Transformers for Earth Observation. *IEEE Geoscience and Remote Sensing Letters*, 2022.

[119] Xian Sun, Peijin Wang, Wanxuan Lu, Zicong Zhu, Xiaonan Lu, Qibin He, Junxi Li, Xuee Rong, Zhujun Yang, Hao Chang, Qinglin He, Guang Yang, Ruiping Wang, Jiwen Lu, and Kun Fu. RingMo: A Remote Sensing Foundation Model with Masked Image Modeling. *IEEE Transactions on Geoscience and Remote Sensing*, 2022.

[120] Yuan Gao, Xiaojuan Sun, and Chao Liu. A General Self-Supervised Framework for Remote Sensing Image Classification. *Remote Sensing*, 2022.

[121] Hongmiao Wang, Cheng Xing, Junjun Yin, and Jian Yang. Land Cover Classification for Polarimetric SAR Images Based on Vision Transformer. *Remote Sensing*, 2022.

[122] Kai Wang, Steven E. Franklin, Xulin Guo, and Marc Cattet. Remote Sensing of Ecology, Biodiversity and Conservation: A Review from the Perspective of Remote Sensing Specialists. *Sensors*, 2010.

[123] Sahel Mahdavi, Bahram Salehi, Jean Granger, Meisam Amani, Brian Brisco, and Weimin Huang. Remote sensing for wetland classification: A comprehensive review. *GIScience & Remote Sensing*, 2018.

[124] Freek D Van der Meer, Harald MA Van der Werff, Frank JA Van Ruitenbeek, Chris A Hecker, Wim H Bakker, Marleen F Noomen, Mark Van Der Meijde, E John M Carranza, J Boudewijn De Smeth, and Tsehaie Woldai. Multi-and hyperspectral geologic

remote sensing: A review. *International Journal of Applied Earth Observation and Geoinformation*, 2012.

[125] John Wilson Rouse, Rüdiger H Haas, John A Schell, Donald W Deering, et al. Monitoring vegetation systems in the Great Plains with ERTS. *NASA Spec. Publ*, 1974.

[126] E Raymond Hunt, Jr. Relationship between woody biomass and PAR conversion efficiency for estimating net primary production from NDVI. *International Journal of Remote Sensing*, 1994.

[127] Bo-Cai Gao. NDWI—A normalized difference water index for remote sensing of vegetation liquid water from space. *Remote sensing of environment*, 1996.

[128] Zhao-Liang Li, Pei Leng, Chenghu Zhou, Kun-Shan Chen, Fang-Cheng Zhou, and Guo-Fei Shang. Soil moisture retrieval from remote sensing measurements: Current knowledge and directions for the future. *Earth-Science Reviews*, 2021.

[129] Compton J Tucker. Remote sensing of leaf water content in the near infrared. *Remote sensing of Environment*, 1980.

[130] Teven Le Scao, Angela Fan, Christopher Akiki, Ellie Pavlick, Suzana Ilić, Daniel Hesslow, Roman Castagné, Alexandra Sasha Luccioni, François Yvon, Matthias Gallé, et al. BLOOM: A 176B-Parameter Open-Access Multilingual Language Model. *CoRR*, abs/2211.05100, 2022.

[131] Jordan Hoffmann, Sebastian Borgeaud, Arthur Mensch, Elena Buchatskaya, Trevor Cai, Eliza Rutherford, Diego de las Casas, Lisa Anne Hendricks, Johannes Welbl, Aidan Clark, Tom Hennigan, Eric Noland, Katherine Millican, George van den Driessche, Bogdan Damoc, Aurelia Guy, Simon Osindero, Karen Simonyan, Erich Elsen, Oriol Vinyals, Jack William Rae, and Laurent Sifre. Training Compute-Optimal Large Language Models. In *NeurIPS*, 2022.

[132] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al. LLaMA: Open and Efficient Foundation Language Models. *CoRR*, abs/2302.13971, 2023.

[133] Kan Wu, Houwen Peng, Minghao Chen, Jianlong Fu, and Hongyang Chao. Rethinking and Improving Relative Position Encoding for Vision Transformer. In *ICCV*, 2021.

[134] David Arthur and Sergei Vassilvitskii. K-Means++: The Advantages of Careful Seeding. In *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms*, 2007.

[135] H. W. Kuhn. The Hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 1955.

A 附录

代码和预训练模型：`https://github.com/antofuller/CROMA`

A.1 其他预训练实验

在本节中，我们对额外的 CROMA 设置进行了实验。我们采用与论文 §4.1 中相同的实验条件；即，在 BigEarthNet [76] 上进行线性探测（在合并的验证集和测试集上报告 mAP），并在 DW-Expert-120 [88] 上对图像块编码进行线性探测（在验证集上报告 mIoU）。我们使用附录 §A.4.2 中列出的线性探测超参数。

表 8: 在仅雷达（“R”）、仅光学（“O”）以及联合雷达-光学（“RO”）输入上的线性探测结果。在所有实验中，我们使用 2D-ALiBi 与 X-ALiBi，75% 共享掩码，ViT-B 主干网络，以及 100 轮次的预训练。

Cross-Modal	Cross-Modal	Decoder	Obj. Weights	HN Mixing		Classification (mAP)			Segmentation (mIoU)		
Image Obj.	Patch Obj.	Depth, Dim	λ_{Con}, λ_{MAE}	(1024, 0, n)	Cost	R	O	RO	R	O	RO
InfoNCE	MSE	1, 512	1, 1	✗	1×	77.4	83.9	84.3	40.5	56.0	56.7
InfoNCE	MSE	1, 768	1, 1	✗	1×	77.4	83.9	84.3	40.7	56.1	56.6
InfoNCE	MSE	3, 512	1, 1	✗	1.2×	77.5	83.9	84.4	40.5	56.3	57.1
InfoNCE	MSE	3, 768	1, 1	✗	1.3×	77.5	83.9	84.4	40.7	56.2	56.6
InfoNCE	MSE	6, 512	1, 1	✗	1.4×	77.5	83.9	84.4	40.3	56.0	56.7
InfoNCE	MSE	6, 768	1, 1	✗	1.6×	77.6	83.8	84.5	40.6	56.2	56.7
InfoNCE	✗	1, 512	1, 1	✗	1×	77.4	84.0	84.5	40.8	56.1	56.4
InfoNCE	✗	1, 768	1, 1	✗	1×	77.5	84.2	84.5	40.8	56.1	56.2
InfoNCE	✗	3, 512	1, 1	✗	1.2×	77.6	84.1	84.5	40.8	56.2	56.7
InfoNCE	✗	3, 768	1, 1	✗	1.3×	77.0	83.9	84.5	40.6	56.1	56.5
InfoNCE	✗	6, 512	1, 1	✗	1.4×	77.3	84.1	84.5	40.8	56.1	56.5
InfoNCE	✗	6, 768	1, 1	✗	1.6×	77.5	84.1	84.6	40.6	56.5	56.8
InfoNCE	InfoNCE	3, 512	1, 1	✗	2.2×	72.8	80.9	82.4	39.0	55.1	55.2
InfoNCE	✗	1, 512	1, 2	✗	1×	77.5	84.3	84.2	40.7	55.9	56.2
InfoNCE	✗	1, 512	1, 4	✗	1×	77.5	84.3	84.1	40.6	55.4	56.0
InfoNCE	✗	1, 512	2, 1	✗	1×	77.5	84.1	84.5	40.4	55.9	56.3
InfoNCE	✗	1, 512	4, 1	✗	1×	77.6	83.9	84.5	40.7	55.8	56.8
InfoNCE	✗	1, 512	1, 1	128	1×	73.6	81.6	83.0	38.0	53.2	55.0
InfoNCE	✗	1, 512	1, 1	256	1×	73.0	81.0	82.8	37.8	52.9	54.7
InfoNCE	✗	1, 512	1, 1	512	1×	72.5	80.2	82.4	37.6	52.6	54.4
VICReg	MSE	1, 768	1, 1	✗	1.1×	70.7	78.7	83.3	40.0	55.5	55.1

自监督目标。受到 VICRegL [93] 局部目标的启发，我们尝试在跨模态块编码之间使用均方误差（MSE）目标，即 $\mathcal{L}_{local}$ =MSE($\mathcal{E}_{\text{R}}, \mathcal{E}_{\text{O}}$）。该目标会吸引那些对应相同位置的块编码，即它们表示地面上相同的 $80\,\text{m} \times 80\,\text{m}$ 方阵。我们发现这并未改善表示。接着，我们在跨模态图像表示之间尝试使用 VICReg [92] 目标（基于批量大小为 800 计算 VICReg 统计量），即 $\mathcal{R}_{\text{R}}$ 与 $\mathcal{R}_{\text{O}}$；我们发现其性能低于 InfoNCE [28]。最后，我们在跨模态块编码之间尝试使用 InfoNCE 目标；正样本对是跨模态中位置匹配的编码，负样本对则是来自匹配样本中的所有其他编码以及批量中所有其他样本的编码。这一方法并未改善表示，并使预训练速度降低了 2.2× （表 8）。

目标权重。我们发现，对对比损失项或平均绝对误差 [31] 损失项进行加权并不能始终改善表示；因此，我们选择使用相等的权重。

困难负样本。我们发现，在我们的框架中使用困难负样本混合 [95] （N =1024 ，s =0 ，s' =n ，β =0.5 ，其中 n 为 128 ，256 ，或 512 ）会降低性能。

解码器大小。至少在这些实验中，CROMA 对解码器大小不敏感；一个包含 1 层、512 -d 变换器的小型解码器的表现与一个更大得多的 6 层、768 -d 变换器相当。

带有共享掩码的位置编码。我们发现，使用二维正弦嵌入或 PEG [90] 配合 *共享*掩码时表现不佳。这两种位置编码方法将位置信息存储在内部表示中，如果两种模态共享掩码，则有助于解决对比目标；而 2D-ALiBi 则将位置信息存储在注意力矩阵中，这可能会阻止这种情况的发生。在我们的论文（表 6）中，我们展示了若模态独立掩码，二维正弦嵌入或 PEG 在我们的框架中可以表现良好，尽管 2D-ALiBi 仍然优于这些方法。

表 9: 线性探测结果，*共享* 75% 掩码，ViT-B，100 轮次。

Method	Classification mAP			Segmentation mIoU		
	R	O	RO	R	O	RO
PEG [90]	67.9	75.9	79.0	32.6	49.8	51.0
2D-Sin.	69.4	75.6	79.8	29.0	44.1	50.7

较低掩码微调。 FLIP [68] 使用被掩码样本的表示进行对比学习；在完成此掩码预训练后，它采用 *未掩码*微调，在 zero-shot ImageNet-1K 上将准确率提升 1.3 %。未掩码微调通过使用未掩码样本的表示继续执行对比学习，以缩小预训练与推理之间的分布差距 [68]。由于必须对图像块进行掩码以满足重构目标，我们无法进行完全未掩码微调。然而，我们可以降低掩码比例并执行 *较低*掩码微调。遵循 FLIP 的方法，使用我们预训练的 CROMA-L 模型初始化参数，我们以基础学习率 8 e-8 进行额外 5 轮训练，前 1 轮进行热身，后 4 轮采用余弦衰减调度进行冷却。我们探索了掩码比例 $\{10\%, 25\%, 50\%\}$，发现对于 CROMA，较低掩码微调并未提高线性探测准确率（表 10）。

表 10: 在预训练 CROMA-L 之后，进行 5 轮次的低掩码微调。

Mask Ratio	Classification mAP			Segmentation mIoU		
	R	O	RO	R	O	RO
10%	80.8	84.7	84.7	43.8	56.8	56.6
25%	80.8	84.7	84.8	43.9	56.8	56.6
50%	80.8	84.8	85.0	43.9	56.8	56.6

A.2 二维 ALiBi 性能优异的两个原因

我们引入 2D-ALiBi 的主要原因是为了实现 §4.2中展示的测试时外推法。但即使没有外推发生——训练和测试使用相同的图像大小——2D-ALiBi 的性能优于最常用的位置编码方法（2D-sinusoidal）和一种 SoTA 相对位置编码方法（PEG [90]）。我们认为 2D-ALiBi 优于这两种方法有两个原因。

表 11: 图像表示与同一图像变换版本表示之间的余弦相似度。相似度越高，表示该表示受图像变换的影响越小。

Method	Transformation (cosine similarity)				
	H-Flip	V-Flip	rotate(90°)	rotate(180°)	rotate(270°)
2D-ALiBi + X-ALiBi	0.992	0.992	0.992	0.992	0.992
2D-ALiBi	0.992	0.992	0.992	0.992	0.992
PEG [90]	0.992	0.992	0.988	0.992	0.988
2D-sinusoidal	0.641	0.629	0.523	0.559	0.523

❶ **2D-ALiBi 学习对旋转和翻转不变的图像表示**。学习对某些变换不变的表示通常是有益的。在 CROMA 中，光学与雷达数据之间的对比目标鼓励了传感器不变的表示。对卫星图像表示而言，对翻转和旋转的不变性是理想属性。然而，CROMA 的预训练目标并未明确鼓励这些不变性。为了探究 CROMA 的光学表示（即 $\mathcal{R}_{\mathrm{O}}$）是否对翻转和旋转具有不变性，我们使用四种位置编码策略——2D-ALiBi、带 X-ALiBi 的 2D-ALiBi、PEG 和 2D-正弦——

对来自 DW-Expert-120 的 5,000 张光学图像生成表示。然后，对于每个模型，我们对相同样本生成经过变换后的表示。我们测量原始图像与变换后图像表示之间的余弦相似度。当应用于我们的 CROMA 框架时，2D-ALiBi 学习到对翻转和旋转不变的表示（平均余弦相似度为 0.992 ，见表 11）。值得注意的是，2D-正弦学习到的表示对翻转和旋转并不具备不变性（平均余弦相似度为 0.575 ，见表 11）；我们认为这导致了 2D-正弦嵌入在图像分类任务上的较差表现。PEG 在图像分类上表现与 2D-ALiBi 相似，并且同样学习到对翻转和旋转不变的表示。

表 12: (中间列) 图像中不同位置的块编码之间的余弦相似度，对 5,000 张图像取平均。(右列) 一个 MLP 探测器的交叉熵损失，该探测器被训练为根据块编码预测块的位置。

Method	Patch Encoding Similarity (cosine similarity)	Patch Encoding Position Probing (cross entropy loss)
2D-ALiBi + X-ALiBi	0.546	4.43
2D-ALiBi	0.582	4.41
PEG [90]	0.701	4.13
2D-sinusoidal	0.493	0.00

❷ **2D-ALiBi 学习保留局部信息的图像块表示**。[47] 指出，使用对比目标训练的模型在更深的 ViT 层中会丢失大量局部信息，从而损害密集预测任务的性能。他们发现，图像中不同位置的图像块表示之间的余弦相似度变得很高，表明出现了图像块级别的表示崩溃现象。在每个 ViT 层中，2D-ALiBi 为每个注意力头和每个图像块位置注入局部偏置。为了探究 2D-ALiBi 是否能有效防止这种崩溃的发生，我们测量了同一样本中不同图像块编码之间的余弦相似度，并对 5,000 幅光学图像取平均值。我们发现，2D-ALiBi 学习到的图像块表示比 PEG 具有更高的空间多样性，而 X-ALiBi 进一步提升了多样性（表 12）。有趣的是，2D 正弦嵌入学习到的图像块表示多样性最高。我们还在图像块编码上训练了 MLP 探针以分类图像块位置；这衡量了图像块编码中所包含的位置信息量。我们发现，使用 2D 正弦嵌入的模型的图像块编码能够完全确定图像块在图像中的位置（表 12）；这是图像块编码的一个不良特性，因为图像块编码应表示图像块的 内容，而非其位置。

A.3 预训练细节

A.3.1 数据

我们使用 SSL4EO 数据集 [70]，该数据集包含在全球 25 万个位置获取的 Sentinel-1 & 2 影像；每个位置（一个 2.64 km × 2.64 km 方阵）在一年内被成像四次。我们使用这些 1 百万个 264 × 264 像素的样本进行预训练。更多细节请参见 SSL4EO 论文 [70]。

A.3.2 实施

我们使用一台 NVIDIA DGX 服务器（8× A100-80GB），在 640 GB 的显存中可容纳的最大批量大小（我们的默认 ViT-B 对应 7,200），采用 bfloat16 精度，基础学习率为 4 e-6 ，前 5 % 的总轮次进行预热，并通过余弦衰减进行降温。我们采用与 SatMAE [26] 相同的规范化过程。对于数据增强，我们从原始 264 × 264 像素图像中随机裁剪 60 -180 像素的方阵，并将裁剪区域缩放至 120 × 120 像素（我们的默认图像大小）。我们还执行垂直和水平翻转、90 度旋转以及 mixup=0.3 。关键的是，我们对两种模态应用相同的变换；如果对每种模态独立应用这些变换，我们的空间对齐将会失效。我们使用 AdamW 优化器，β_1 =0.9 且 β_2 =0.999 ，权重衰减为 0.01 。

A.4 评估细节

地球观测基础模型的评估相较于其他领域仍不够成熟。我们尽最大努力复用当前最先进（SoTA）方法——SatMAE [26]——的实验条件，并在可能的情况下加以改进。其中一项条件是报告从保留的验证集获得的结果；具体而言，报告每次微调轮次后取得的最佳验证性能。不使用测试集。为确保与先前工作的公平比较，我们采用这一方法。在尝试改进地球观测基础模型的评估方法时，我们在本附录中详细说明我们的方法，分享代码和预处理数据集，在相同条件下重新评估所有接近最先进水平的模型，并以比以往工作更多样化的方式评估模型（即线性和非线性探针、k NN 分类以及 K -means 聚类）。

我们从公开共享的预训练权重中初始化参数，并在相同条件下自行评估所有模型。尽管这一过程较为繁琐，但我们认为这显著提升了本文的价值；此前多项研究常以不同方式评估其模型，使用不同的数据划分，无法直接比较。下载预训练权重时，我们采用当前公开可获取的最新版本。例如，SatMAE [26] 在其论文被接受发表后（arxiv 编辑于 *1* 月 15th ，2023 ），发布了其多光谱 ViT-B 和 ViT-L 模型的改进版本，这些模型已预训练 200 轮次。我们在整篇论文中仅评估这些改进后的模型，确保 CROMA 与当前可用的最佳模型进行对比。对于包含 13 通道（含卷云通道）的多光谱基准，我们简单地将未包含卷云通道的预训练模型的卷云波段删除。

A.4.1 数据

BigEarthNet. [76] 我们使用与 SatMAE [26] 和 SeCo [25] 相同的划分方式，其中训练集为完整训练集的 10 %，验证集为整个验证集。然而，在消融研究中，我们使用了合并的验证集和测试集（共 236,130 个样本），以在几乎不增加成本的情况下提高结果的可靠性。图像大小为 120×120 像素。

fMoW-Sentinel. [26] 受 BigEarthNet 基准使用方式的启发（即在完整训练集的 10% 数据上进行训练，该训练集共包含354,200个样本），我们创建了完整 fMoW-Sentinel 训练集（共712,874个样本）的 10 % 划分。我们分享了随机选择的 10 % fMoW-Sentinel 训练样本的 ID。我们认为，未来的研究应使用这个更小的训练集以降低超参数搜索的成本——在完整训练集上对 SatMAE 进行一次微调运行需要在 V100 GPU 上耗时 192 小时 [26]。遵循 SatMAE 的做法，我们使用完整的验证集进行评估。图像大小各异；平均高度为45像素，平均宽度为60像素。

在我们的论文中，我们对这一新划分进行了基准测试。然而，我们在表 13 中报告了使用 CROMA 模型在完整训练集上获得的结果。由于在完整训练集（712,874 个样本）上进行微调的成本较高，我们决定将资源分配到其他地方，并且 不进行任何超参数调优。相反，我们选择我们认为合理的超参数，仅对 CROMA-B 和 CROMA-L 进行一次微调。微调时，我们采用基础学习率 1 e-5，其余所有超参数均来自 §A.4.2。

表 13: fMoW-Sentinel 结果（前 1 准确率）使用 完整训练集。* 表示结果来自 SatMAE（于 *arxiv* 上更新于 15th 年 2023 月）。

Method	Backbone	Finetuning	Linear Probing
SatMAE	ViT-B	62.65*	37.40
CROMA	ViT-B	61.00	40.94
SatMAE	ViT-L	63.84*	39.19
CROMA	ViT-L	63.59	41.96

EuroSAT. [77] 我们使用与 SatMAE 相同的训练集和验证集。图像大小为 64×64 像素。

加拿大农田。 [78] 我们是首个对这一加拿大农业农田数据集进行基准测试的团队，该数据集包含 10 个类别（大麦、油菜、玉米、混交林、燕麦、果园、牧场、马铃薯、大豆和春小麦）。我们选择该数据集是因为它是一个大规模数据集，能够评估与其他基准测试中通常将农田视为单一类别时不同的能力。参照 EuroSAT [77]，作者选择了 64×64 像素的图像大小

[78]；因此，可在对 EuroSAT 进行评估的模型上，通过极少修改即可在加拿大农田数据集上进行评估。我们使用训练集，并将验证集与测试集合并形成一个单独的保留集用于评估。我们共享完整的训练集和验证集。性能结果（表 1）以及表示可视化（本附录中的图 6 和 7）表明，该数据集中包含的 10 个类别难以分离。

DFC2020. [87] 该数据集以多种方式用于评估——包括数据划分和图像大小的选择。原始数据集包含 6,114 个样本，每个样本大小为 256×256 像素。这些样本通常被划分为两部分：一个所谓的“验证集”包含 986 个样本，以及一个所谓的“测试集”包含 5,128 个样本。一些研究使用“验证集”进行训练，而用“测试集”进行验证；另一些研究则使用“测试集”进行训练，而用“验证集”进行验证。一些研究将完整的 256×256 像素作为模型输入，而另一些研究则使用更小的输入。我们选择 5,128 个样本作为训练集，将其划分为 46,152 张大小为 96×96 像素的图像——从而留下 986 个样本作为验证集，将其划分为 8,874 张大小为 96×96 像素的图像。我们选择此最终分辨率，因为它与 SatMAE 的默认图像大小一致，从而能够与当前最优方法（SoTA）进行公平比较。我们共享完整的训练集和验证集。

DW-Expert. [88] Dynamic World [88] 收集的数据是一个由专家借助辅助信息标注的新高质量数据集。因此，在未来进行模型基准测试时应使用该数据集。我们的工作使用了 Dynamic World 的专家标注数据，将其划分为 20,422 个训练样本和 51,022 个验证样本。所有图像均为 96×96 像素，以便与 SatMAE 进行公平比较。我们共享这些完整的训练集和验证集。此外，我们还创建了一个包含 120×120 像素图像的数据集版本（即 DW-Expert-120），仅用于消融实验，因为这是 CROMA 的默认图像大小。

MARIDA. [89] 我们使用训练集，并将验证集和测试集合并形成一个单独的保留集用于评估。遵循我们对 DFC2020 和 DW-Expert 的方法，我们将原始图像划分为大小为96×96像素的图像。由于这是一个稀疏标注的数据集（即每幅图像中仅有一小部分像素被标注），我们包含至少有一个标注像素的图像。我们选择该数据集是因为它从其他语义分割基准中评估了不同的能力。该数据集包含以下类别：海洋垃圾、稠密 *Sargassum*、稀疏 *Sargassum*、天然有机物质、船只、云、海洋水体、含沉积物的水体、泡沫、浑浊水体、浅水、波浪、云阴影、尾迹以及混合水体。我们共享这些完整的训练集和验证集。

A.4.2 实施

微调。我们选择所有模型和数据集通用的合理超参数，除非另有说明，并对学习率进行遍历搜索。这种学习率遍历对于在不同模型之间建立公平的评估条件至关重要，因为每个模型获得相同的搜索预算（以微调运行次数计，而非计算时长），而不同模型具有不同的最优学习率。通过重构方法预训练的模型在微调阶段通常需要比通过对比学习预训练的模型更高的基础学习率。例如，MAE [31] 列出的基础学习率为 1 e-3 ，FLIP [68] 列出的基础学习率为 5 e-5 ，CoCa [49] 列出的基础学习率范围为 1 e-5 至 5 e-4 ，具体取决于下游数据集。

没有单一的学习率能够使所有模型和数据集之间的比较变得公平。因此，我们在一个广泛的值域 {3 e-5 ，5 e-5 ，8 e-5 ，1 e-4 ，3 e-4 ，5 e-4 ，8 e-4 ，1 e-3 } 中搜索学习率，并为每个数据集报告获得的最佳单次评估结果；这一搜索过程对 CROMA 模型和其他所有模型都进行了。我们通过广泛使用的线性缩放规则将这些基础学习率转换为实际学习率：$lr = base_lr \times batch_size/256$ 。我们使用能在 A100-40GB GPU 上运行的最大批量大小（采用 bfloat16 精度），使用 AdamW 优化器，其中 β_1 =0.9 ，β_2 =0.999 ，权重衰减为 0.01 。我们进行 5 轮次的预热和 30 轮次的余弦衰减（EuroSAT 除外，其余弦衰减为 150 轮次）；这遵循 SatMAE [26] 的做法。对于分类任务，我们使用 mixup=0.8 ，cutmix=1.0 ，切换概率 =0.5 ，标签平滑 =0.1 ，垂直和水平翻转，以及 90 度旋转。我们将图像放大到我们微调模型的默认图像大小（即模型预训练时所用的图像大小），有一个例外。SatMAE 的默认图像大

小是 96×96；然而，BigEarthNet 图像的大小是 120×120 [76]，这意味着我们必须要么裁剪 BigEarthNet 样本（导致信息丢失），要么将 SatMAE 适配到更大的图像。我们通过广泛使用的基于位置嵌入插值算法将 SatMAE 适配到 120×120 图像，从而比将 BigEarthNet 样本裁剪到 96×96 更好地提升了性能。这使我们实现了 SatMAE 的 mAP 为 86.18，相比 SatMAE 论文中报告的 82.62 显著提升。其他所有数据集均使用 96×96 或更小的图像——因此，对于其他数据集没有必要使用这种技术。

线性与非线性探测。我们在不进行数据增强的情况下对每张图像进行编码，然后在冻结的表示上训练线性和非线性探测器。由于每个模型仅对每张图像编码一次，我们可以非常快速地遍历较大的学习率范围 ($\{1, 2, 3, 4, 5, 6, 7, 8, 9\}$e{-4 , -3 , -2 })。与微调不同，我们不会在每轮次后评估探测器；相反，我们在所有轮次完成后评估训练好的探测器。我们使用批量大小为 1024 ，bfloat16 精度，AdamW 优化器，学习率 β_1 =0.9 ，权重衰减 β_2 =0.999 ，权重衰减为 0.01 。我们进行 5 轮次的预热和 100 轮次的冷却，采用余弦衰减调度。

非参数 k NN 和 K -means。对于 k NN，我们使用 [27] 中的实现。该方法包括对所有训练样本和验证样本进行编码，然后将验证样本的表示作为查询，训练样本的表示作为键来获取训练标签。这些获取到的训练标签用于对验证样本进行分类。我们使用 k =20，其他 k 值（即 10、50）按与 k =20 相同的秩排序。对于 K -means，我们使用 [79] 中的实现。该方法包括对所有训练样本和验证样本进行编码，然后使用 K -means（K -means++ [134] 初始化运行 10 次）对训练样本进行聚类。接着，我们将验证样本分配给簇，并通过匈牙利匹配算法 [135] 将簇分配给类别。

稀疏探测。对于每个模型和数据集，我们使用类间 *均值差异*对表示 $\mathcal{R}$ 的维度进行排序——[86] 表明，均值差异的表现与更复杂的排序方法相当，且实现简单。具体而言，这是对 BigEarthNet 数据集“海滩、沙丘、沙地”类别中 CROMA 模型的表示进行稀疏探测的步骤：(i) 计算 BigEarthNet 训练集中包含“海滩、沙丘、沙地”类别的所有样本的平均表示，$\mathcal{R}_{\text{CROMA}}^{\text{Beaches}} \in \mathbb{R}^{768}$；(ii) 计算 BigEarthNet 中不包含“海滩、沙丘、沙地”类别的所有样本的平均表示，$\mathcal{R}_{\text{CROMA}}^{\text{NoBeaches}} \in \mathbb{R}^{768}$；(iii) 计算这两个平均表示之间的差异，$\mathcal{R}_{\text{diff}} \in \mathbb{R}^{768}$；(iv) 根据绝对值对 768 中的所有 $\mathcal{R}_{\text{diff}}$ 维度进行排序，即两类间绝对差异最大的维度排在首位；(v) 使用分离的线性探测器在前 k 个维度上训练二分类模型，我们对 k 在 1 和 768 之间进行多次取值搜索；(vi) 使用这些训练好的探测器，在 BigEarthNet 验证集上进行评估。该过程对所有三个 ViT-B 模型（CROMA、SatMAE 和 I-JEPA）、所有分类数据集（BigEarthNet、fMoW-Sentinel、加拿大农田和 EuroSAT）以及所有类别均执行——这些结果图表展示在本附录末尾 §A.6。此外，由于我们可访问 Sentinel-1 样本，还对 BigEarthNet 的仅雷达、$\mathcal{R}_{\text{R}}$ 和雷达-光学、$\mathcal{R}_{\text{RO}}$ 表示进行了稀疏探测。

SatMAE 特性. SatMAE [26] 将光谱波段分为三组，并为每组输出图像块编码；因此，SatMAE 在每个图像块位置输出三个图像块编码。为了尽可能公平地对比 SatMAE，我们探索了四种合并这些共位置图像块编码的方法以进行分割任务：未规范化的空间连结、规范化的空间连结、未规范化的空间池化以及规范化的空间池化。我们发现未规范化的空间连结（即在 LayerNorm 之前将共位置图像块的编码进行连结）表现最佳。因此，我们在所有分割数据集上均采用未规范化的空间连结图像块编码。相反，CROMA 不对光谱波段进行分组——导致 3× 序列长度更短。使用 Transformer 处理 token 序列所需的计算量随序列长度增加而增加。这使得在给定 ViT 主干网络和图像大小的情况下，CROMA 比 SatMAE 具有更高的计算效率（表 14）。我们还在 SSL4EO 数据集上对 SatMAE-B 模型进行了 300 轮次的预训练。然而，该模型表现不佳，因此我们未报告相关结果；该实验表明，SatMAE 的超参数可能无法很好地迁移至不同的预训练数据集。

表 14: CROMA 与 SatMAE 在 A100-40GB GPU 上的训练和推理吞吐量对比。

Model	Backbone	Image Size	Train Imgs/s	Inference Imgs/s
SatMAE	ViT-B	96×96	249.3	692.5
CROMA	ViT-B	96×96	1,079.3	2,957.7
CROMA	ViT-B	120×120	555.0	1,532.1
SatMAE	ViT-L	96×96	84.2	263.2
CROMA	ViT-L	96×96	389.1	1,168.2
CROMA	ViT-L	120×120	209.6	640.3

A.5 社会影响

由于我们在 SSL4EO 数据集 [70] 上对模型进行预训练，我们的模型可能对 SSL4EO 数据采样所依据的分布产生有偏。尽管 SSL4EO 样本在地理上具有多样性（请参见 SSL4EO 论文中的图 2 [70]），但这些位置是从人类聚居区周围采样的。因此，人口稀疏的大片地理区域——例如亚马逊雨林、撒哈拉沙漠和澳大利亚内陆——代表性不足。这可能会对这些区域的表示质量产生负面影响，并影响基于这些区域做出的任何决策。

另一种分布偏移——这次是微调与推理之间的偏移——是我们关注的重点。例如，在某一地理区域的图像上对模型进行微调，然后在另一地理区域的图像上进行预测，就会产生分布偏移。结果，微调所基于地理区域的偏差可能会在微调后模型的预测中体现出来。当这些预测被用于决策时，问题尤为严重，例如分配贫困援助。然而，已有充分证据表明，预训练模型比从零开始训练的模型更能抵御分布偏移。此外，随着我们开发出更优秀的地球观测基础模型，对标注数据的需求将减少；这可能使实践者在微调阶段能够更谨慎地选择他们希望利用的数据。

我们不认为预训练模型对军事应用特别有价值，因为军方很可能能够获取比哨兵-1 和哨兵-2 提供的更高分辨率（空间、光谱和时间）的数据。然而，我们的框架可用于在更高分辨率影像上进行模型预训练，这可能对军事应用有所帮助，尽管这是所有新型学习算法的风险。

A.5.1 计算

我们对预训练和微调所使用的计算资源进行近似估算（冻结表示评估的计算资源可忽略不计）。预训练的估算单位为 A100-80GB GPU 小时；微调的估算单位为 A100-40GB GPU 小时。详见表15。

表 15: 开发和验证 CROMA 所估计使用的 GPU 小时数。

Method	Backbone	Task	GPU Hours
radar↔optical [71]	ResNet50	Classification Finetuning	10
radar↔optical [71]	Swin-T	Classification Finetuning	25
MAE [31, 70]	ViT-S	Classification Finetuning	20
DINO [72, 70]	ViT-S	Classification Finetuning	20
SatMAE [26]	ViT-B	Classification Finetuning	75
CROMA	ViT-B	Classification Finetuning	35
SatMAE [26]	ViT-L	Classification Finetuning	215
CROMA	ViT-L	Classification Finetuning	90
CROMA	ViT-B	Pretraining 300 epochs	80
CROMA	ViT-L	Pretraining 600 epochs	380
CROMA	ViT-B	Pretraining Ablations	1,100

A.6 可视化

我们使用 UMAP 和 t-SNE 可视化表示和块编码。对于两个分割数据集（DFC2020 [87] 和 DW-Expert [88]），我们可视化了随机采样的 50,000 个块的编码，并将块中占主导地位的类别作为其标签。我们还绘制了在前 k 个表示维度上训练的二分类器的稀疏探测结果。

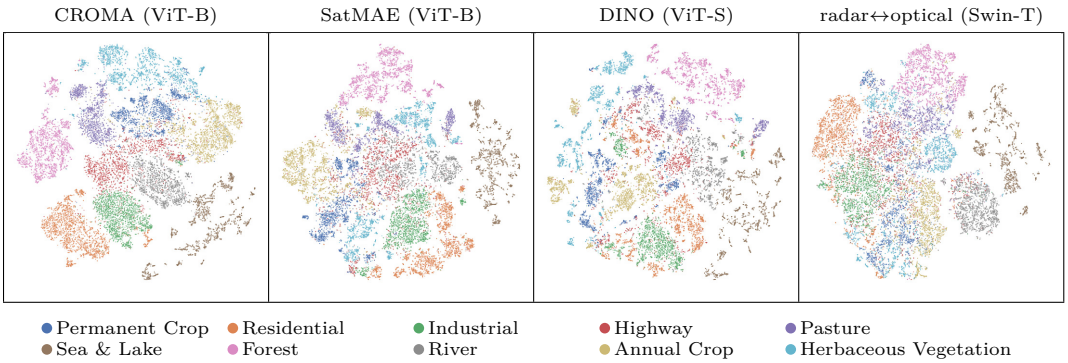

图 5: t-SNE 图展示了 EuroSAT [77] 表示。

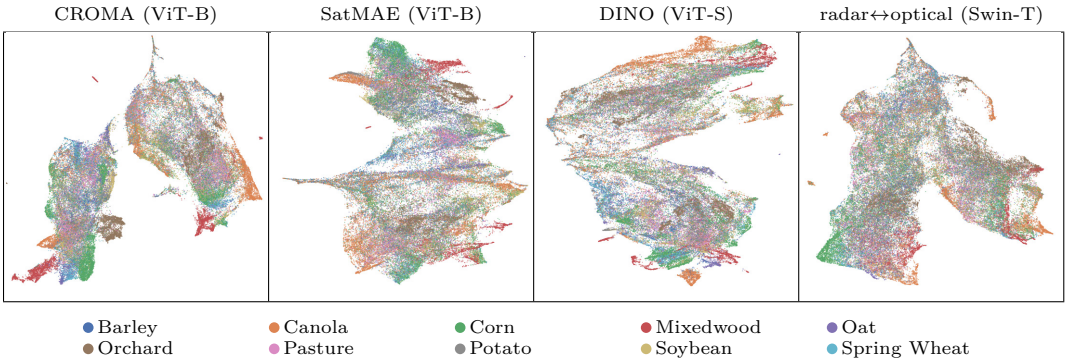

图 6: 加拿大农田 [78] 表示的 UMAP 图。

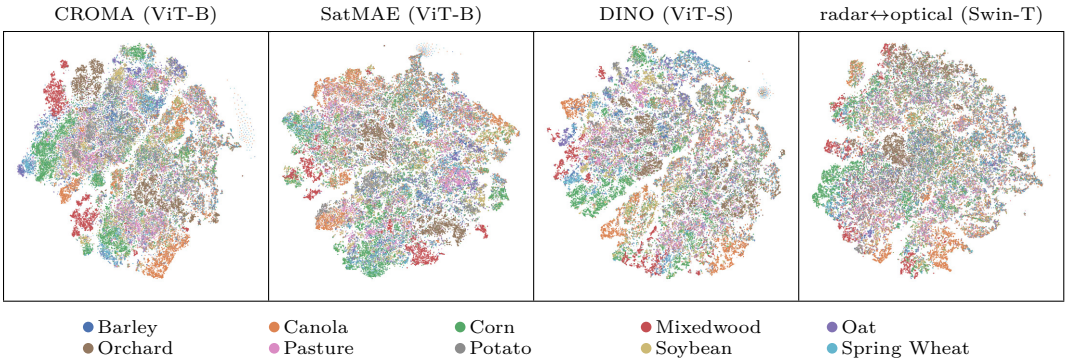

图 7: 加拿大农田 [78] 表示的 t-SNE 图。

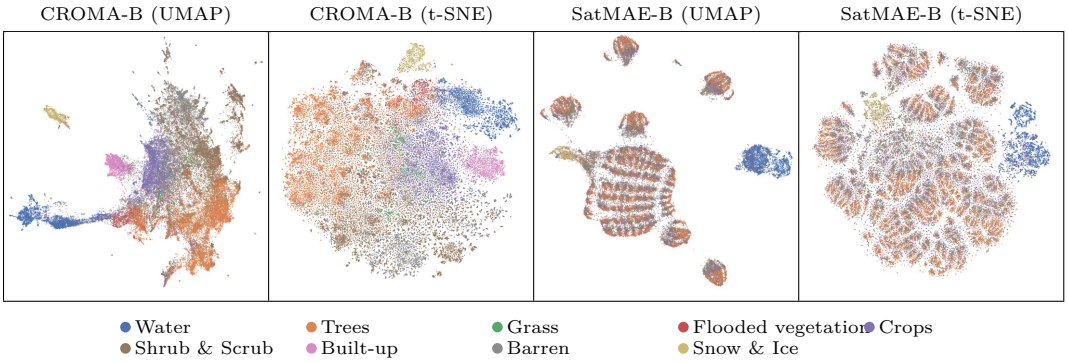

图 8: DW-Expert [88] 片段编码的 UMAP 与 t-SNE 图。

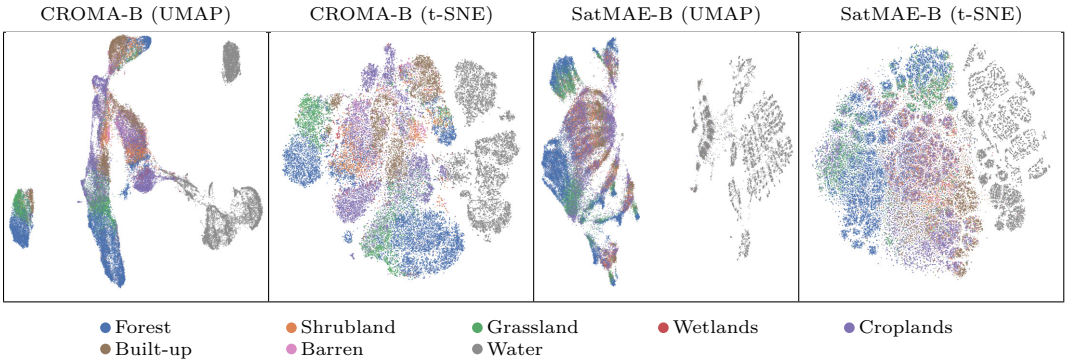

图 9: UMAP 和 t-SNE 绘图在 DFC2020 [87] 图块编码上。

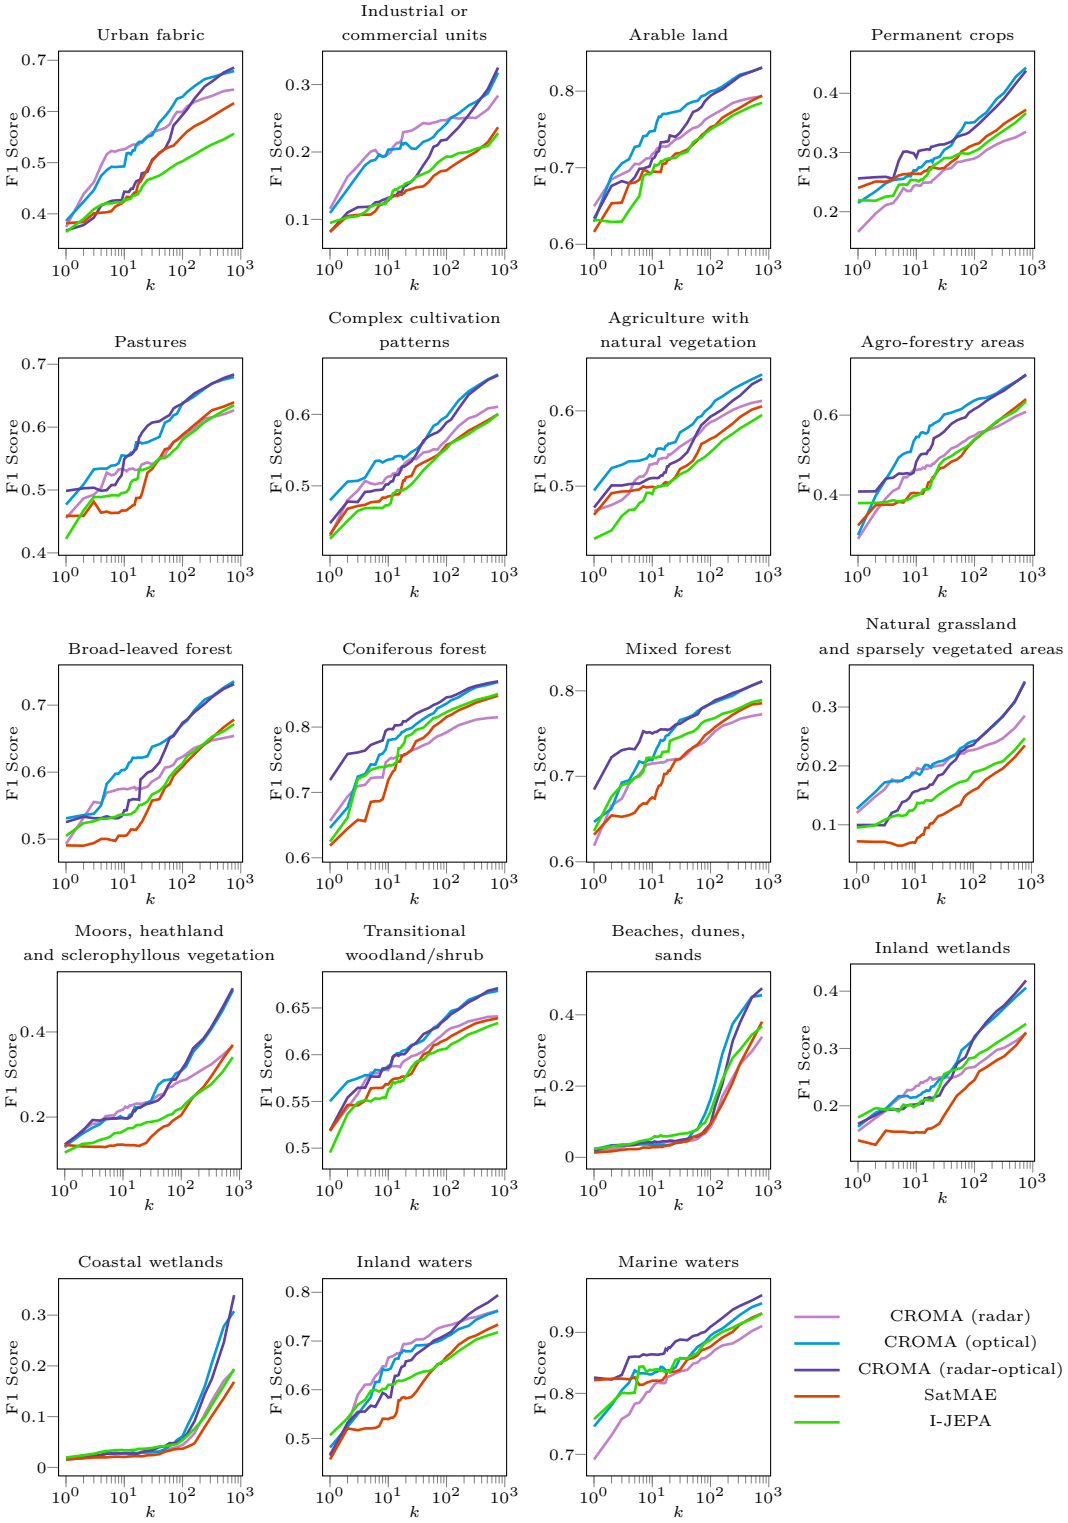

图 10: BigEarthNet 中所有类别稀疏探查

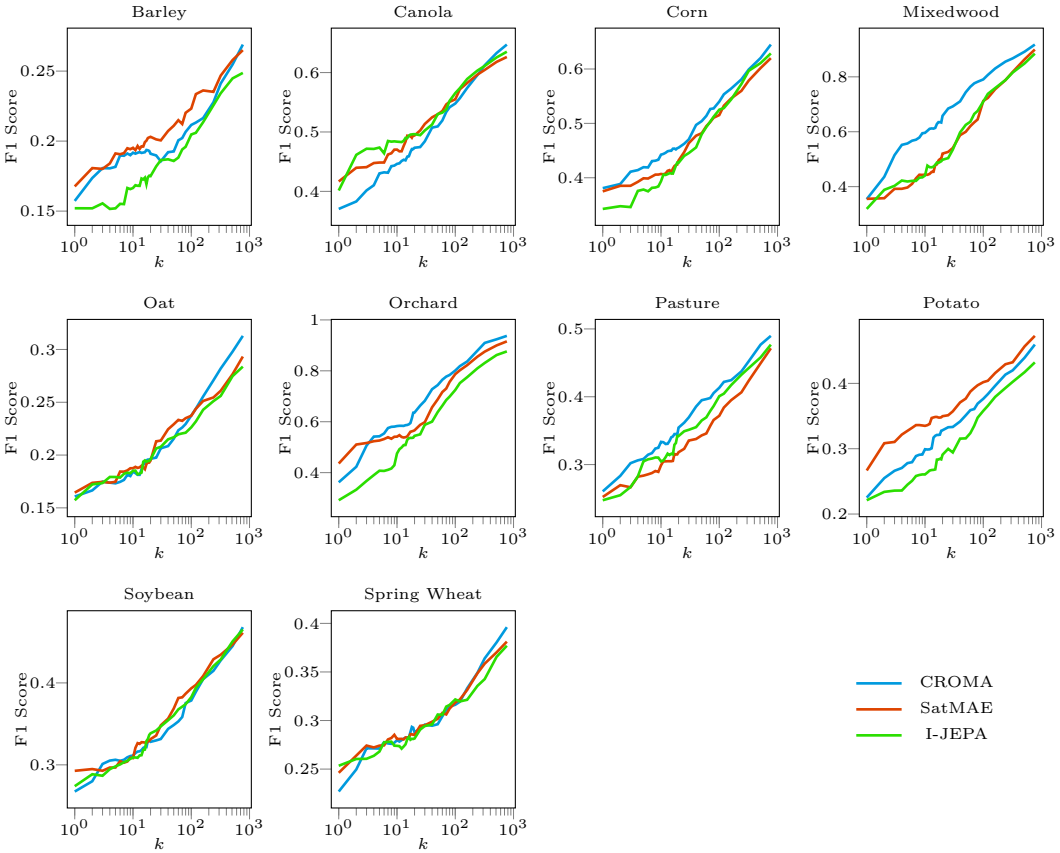

图 11: 稀疏探测加拿大农田的所有类别

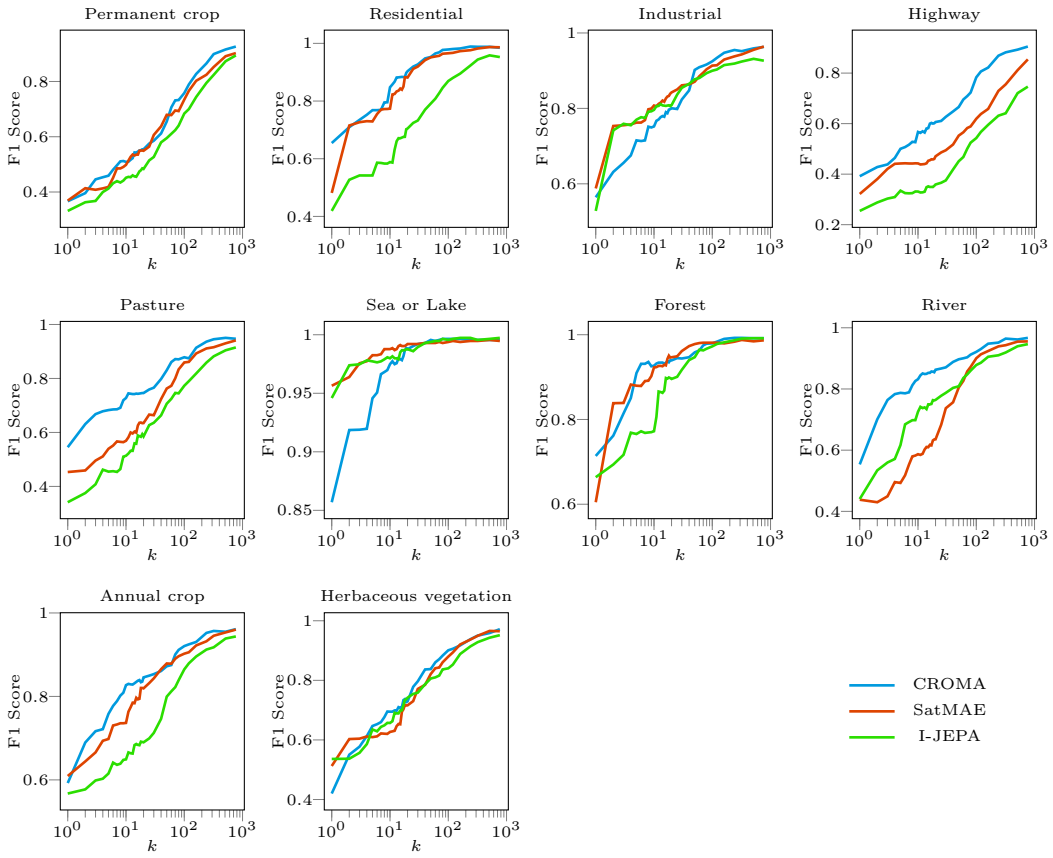

图 12: EuroSAT 中所有类别的稀疏探测

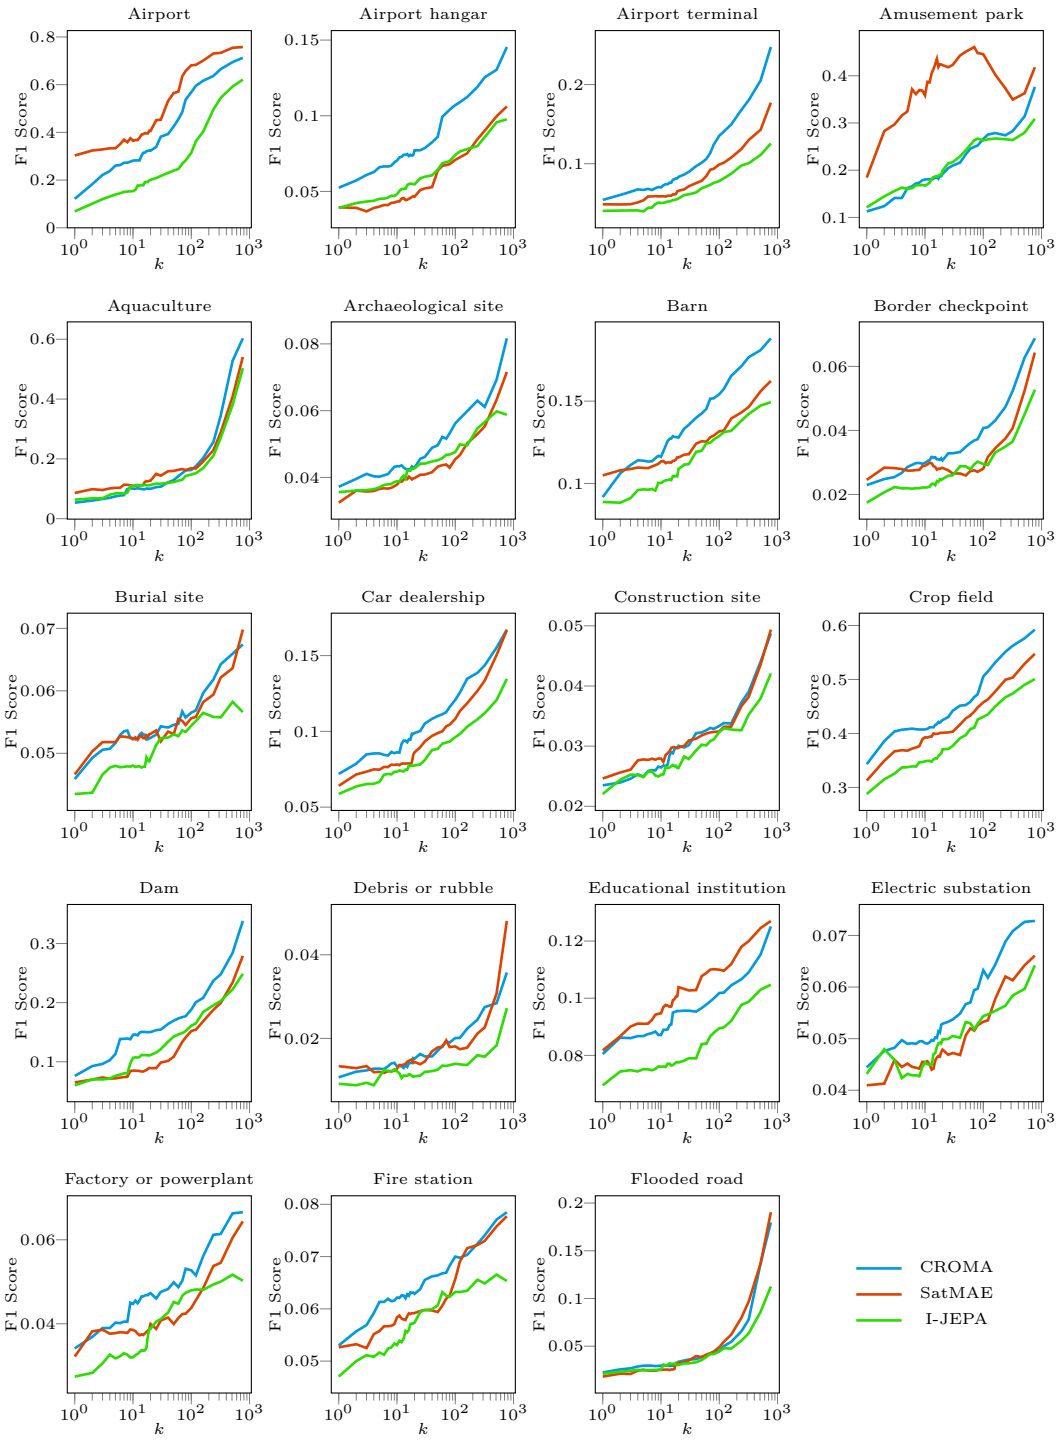

图 13: fMoW-Sentinel 中所有类别的稀疏探针（第一部分）

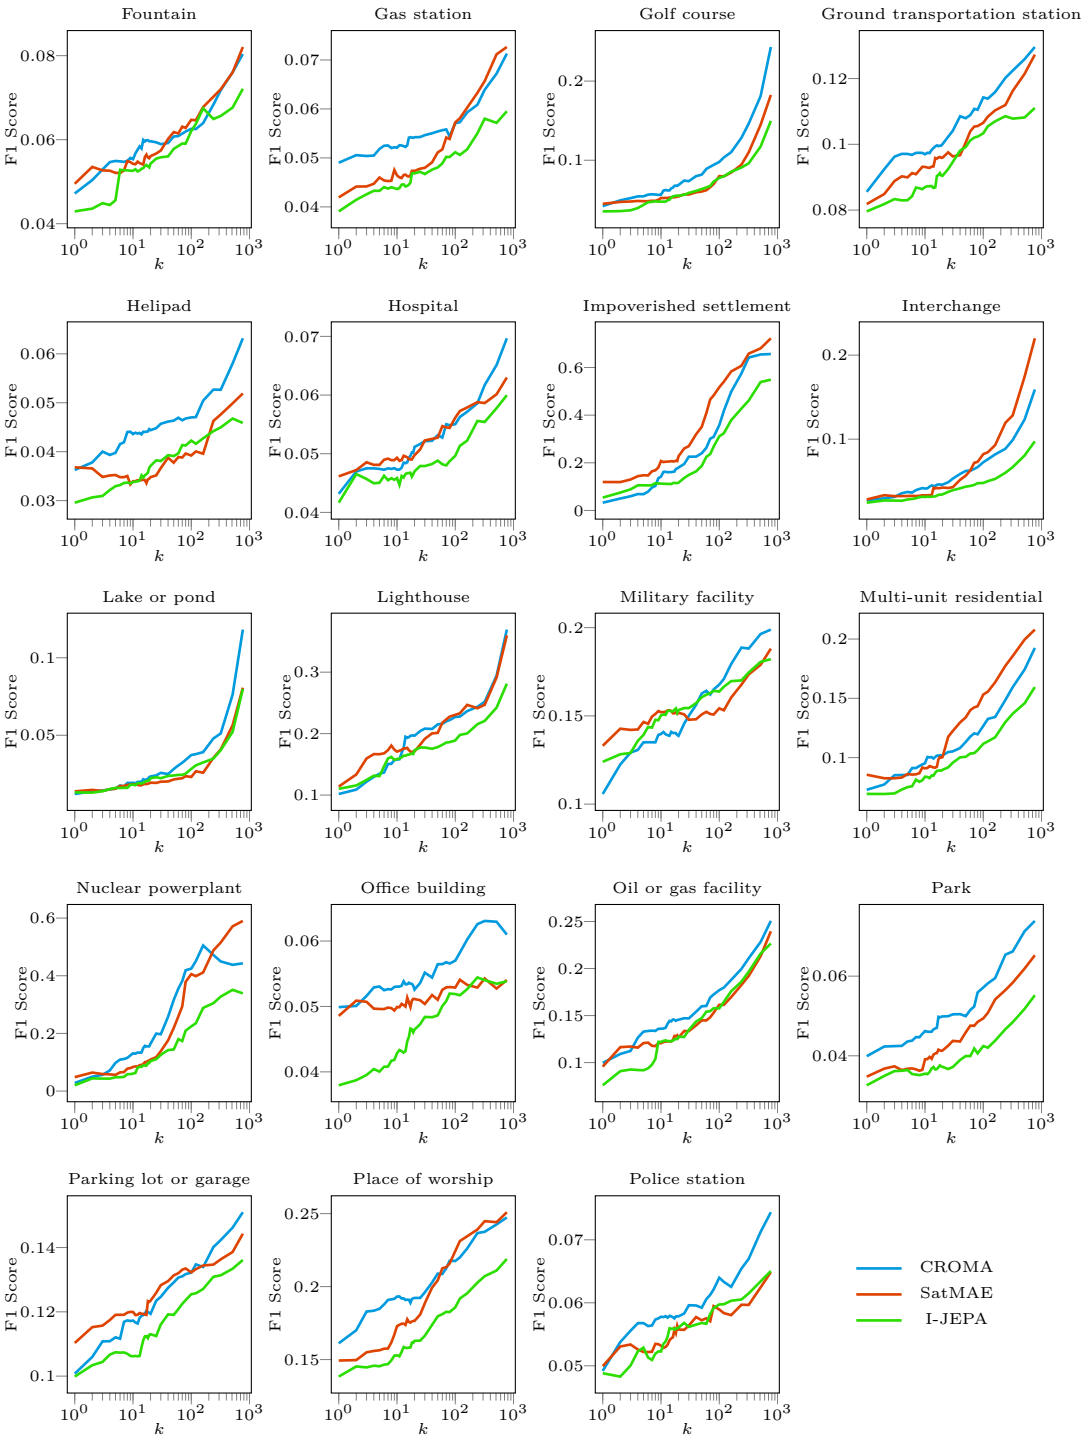

图 14: fMoW-Sentinel 中所有类别的稀疏探测（第二部分）

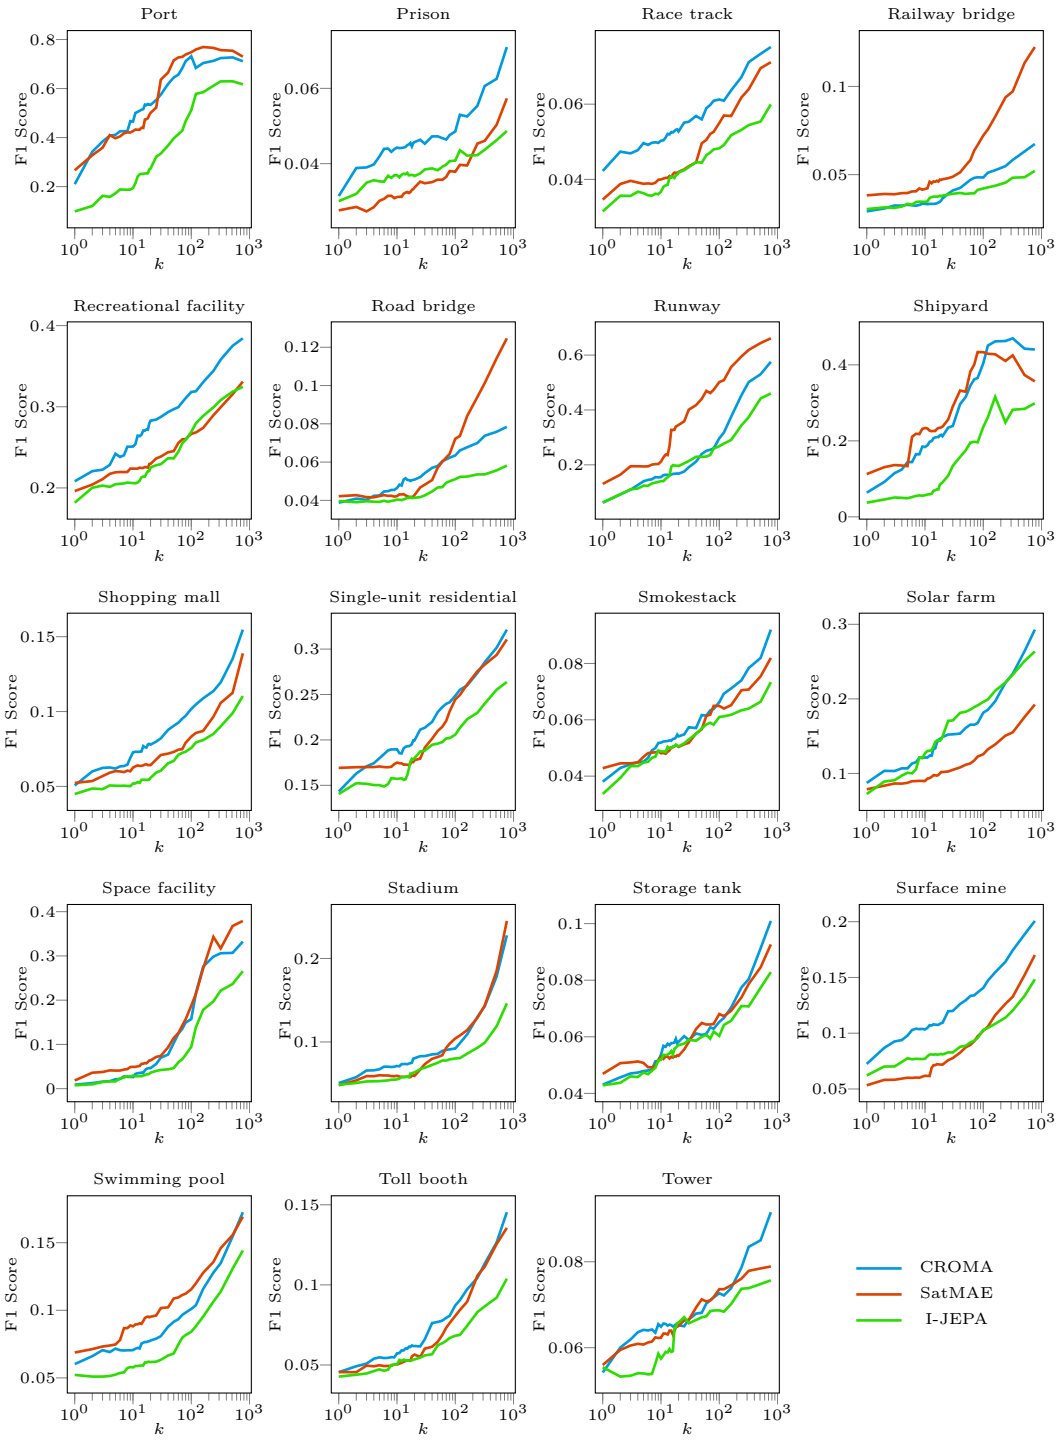

图 15: fMoW-Sentinel 中所有类别稀疏探针（第三部分）

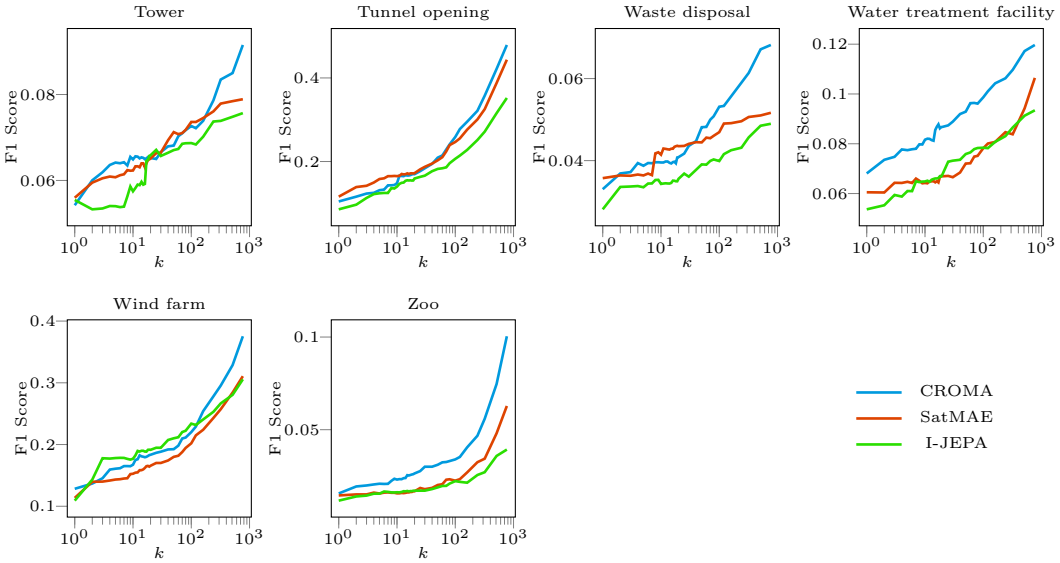

图 16: fMoW-Sentinel 中所有类别的稀疏探测（第四部分）