https://hjfy.top/arxiv/2410.16602

遥感与地球观测的基础模型：综述

Aoran Xiao, Weihao Xuan, Junjue Wang, Jiaxing Huang,
Dacheng Tao *Fellow, IEEE*, Shijian Lu, and Naoto Yokoya *Member, IEEE*

摘要—遥感（Remote Sensing, RS）是一项至关重要的技术，用于观测、监测和解析我们的星球，在地球科学、经济、人道主义等多个领域具有广泛的应用。尽管人工智能（AI），尤其是深度学习，在遥感领域取得了显著进展，但构建更智能的遥感系统仍面临诸多独特挑战，包括地球环境的复杂性、传感器模态的多样性、特征模式的独特性、空间与光谱分辨率的差异性以及时间动态变化等。与此同时，近年来大基础模型（Foundation Models, FMs）的突破性进展，因其卓越的泛化能力与 zero-shot 迁移能力，极大地拓展了 AI 在多个领域的潜力。然而，这些模型的成功主要局限于图像、视频等自然数据，对于各类非光学遥感数据，其性能明显下降甚至出现失败。这一现状激发了学术界对遥感基础模型（Remote Sensing Foundation Models, RSFMs）日益增长的研究兴趣，以应对地球观测（Earth Observation, EO）任务在地表、大气及海洋等多维度的复杂需求。本文系统综述了 RSFMs 这一新兴领域的发展。首先概述其研究动机与背景，随后介绍其核心概念；接着对现有 RSFM 研究进行分类与评述，涵盖视觉基础模型（VFMs）、视觉-语言模型（VLMs）、大语言模型（LLMs）及其他相关方向的数据集与技术贡献。此外，我们基于公开数据集对这些模型进行了基准测试，讨论当前存在的挑战，并提出该快速演进领域未来的研究方向。

***Index Terms*—基础模型，遥感，地球科学，多模态，视觉识别，视觉-语言模型，大语言模型，地球观测，人工智能。**

I. 引言

THE 深度学习的快速演化为 Remote Sensing (RS) 及各种 Earth Observation (EO) 应用带来了显著进展。然而，当前大多数模型依赖于显式设计的任务特定学习目标。这种方法需要大量的人工努力进行数据集收集和标注，同时还需要大量的计算资源进行模型训练和评估。此外，这些模型在不同任务间的泛化能力和迁移能力有限，限制了遥感（RS）系统的广泛应用。遥感（RS）数据源自多种传感器和平台，具有天然的大规模、复杂性、动态性和异构性。以协同、稳健且多功能的方式准确而智能地解析遥感（RS）数据，仍然是推动遥感（RS）解析系统发展的关键挑战，但目前仍缺乏充分探索。

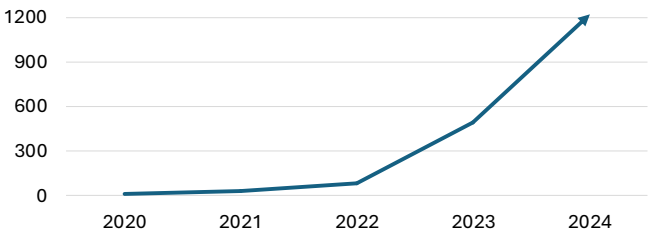

图 1: 自 2020 年以来，包含关键词“基础模型”和“遥感”的谷歌学术论文累计数量。

随着深度学习的不断发展，一种革命性的趋势正在向大规模 Foundation Models (FMs) 演化，其定义为“在广泛数据上训练（通常使用自监督方法）且能够适应多种下游任务（例如微调）的模型”[1]。FMs，包括 Large Language Models (LLMs)、Visual Foundation Models (VFMs) 和 Vision-Language Models (VLMs)，已在多种任务中展现出卓越的泛化能力和 few-shot 转移能力。这一转变标志着从单一用途模型向通用模型的过渡，以及从监督预训练向自监督预训练的转移，显著减少了训练资源需求，同时扩展了模型的应用范围。

然而，这些进展主要集中在自然数据领域，如图像和文本，当应用于分布外的领域（如遥感）时，常常面临重大挑战。例如，遥感与自然图像之间的根本差异——如传感器模态、拍摄视角、空间分辨率、光谱波段以及时间规律性——给直接在遥感应用中使用生成模型带来了障碍。尽管存在这些挑战，生成模型在自然领域的成功为Remote Sensing Foundation Models (RSFMs) 的发展提供了有前景的启示，这些模型在利用大规模地理空间数据、建模复杂动态的地球表面、提高数据效率、

Aoran Xiao is with the RIKEN Center for Advanced Intelligence Project, Japan.

Weihao Xuan and Naoto Yokoya are with the University of Tokyo and the RIKEN Center for Advanced Intelligence Project, Japan.

Junjue Wang is with the University of Tokyo, Japan.

Jiaxing Huang, Dacheng Tao, and Shijian Lu are with the Nanyang Technological University, Singapore.

Corresponding authors: Naoto Yokoya (naoto.yokoya@riken.jp); Shijian Lu (shijian.lu@ntu.edu.sg)

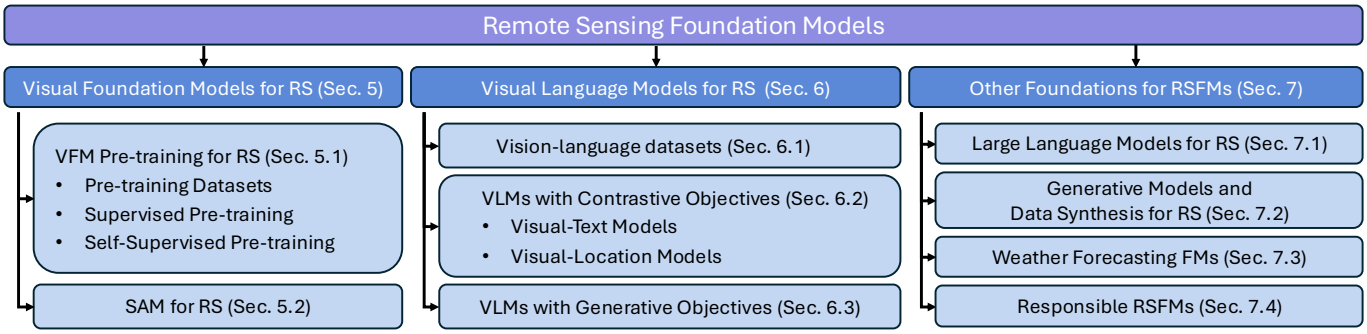

图 2: 遥感基础模型的分类

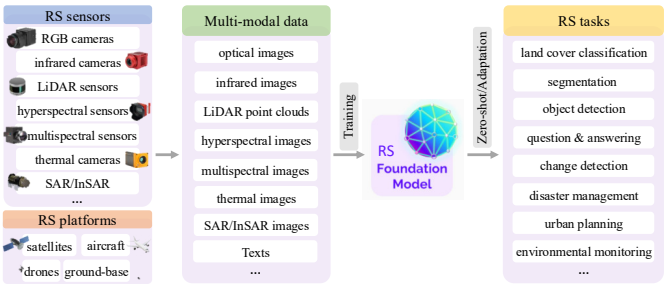

图 3: RSFMs 概述。

拓展应用范围、提升任务性能以及降低碳足迹方面展现出巨大潜力。

相较于通用领域的因子分解机（FMs），开发遥感因子分解机（RSFM）面临几个关键挑战：(1) 自然数据与遥感（RS）数据之间存在显著的领域差异；(2) 遥感因子分解机预训练所需的大规模数据集稀缺；(3) 缺乏适用于 RSFMs 的合适深度架构；以及 (4) 需要解决与自然领域通用因子分解机不同的独特遥感应用。为应对这些挑战，近期越来越多的研究致力于开发先进的 RSFMs，并更好地将各类因子分解机整合到遥感领域中，如图1所示。

尽管取得了快速进展，遥感融合模型（RSFMs）领域仍然缺乏一份全面的综述，无法深入概述这一新兴且多维度的研究方向。本文旨在填补这一空白，系统地回顾 RSFMs 领域的最新进展。我们从多个角度对这一领域进行了探讨，包括学习范式、数据集、技术方法、基准测试以及未来研究方向。如图2所示，我们根据其模型类型将现有方法分为三大类：面向遥感的视觉-语言模型（VFMs for RS）、面向遥感的视觉-语言模型（VLMs for RS），以及其他遥感融合模型（如大模型（LLMs）和生成式模型（generative FMs））。这些类别将在后续章节中进行详细评述。

本文的主要贡献有三方面：首先，它对遥感图像生成模型（RSFMs）的最新进展进行了全面而系统的综述。其次，它在多种传感器模态和任务上对 RSFMs 进行了基准测试，并提供了深入的分析。第三，它识别出该领域中的若干研究挑战，并提出了潜在的研究方向。

本调查的结构如下：在第II节中，我们提供了关于 RSFMs 的背景知识，包括学习范式、常见的遥感传感器模态以及相关调查。第III节深入探讨了 RSFMs 的基础，涵盖深度网络结构和典型的遥感理解任务。第IV、V和VI节系统性地回顾了遥感中的视觉-语言模型（VFMs）、视觉-语言模型（VLMs）以及其他类型的 RSFMs 的方法。第VII节总结并比较了现有方法在多个基准数据集上的性能。最后，第VIII节概述了 RSFMs 几个有前景的未来研究方向。

II. 背景

A. RS 学习范式

本小节简要概述了遥感（RS）模型中学习范式的演化历程，从传统的机器学习、深度学习，发展到当前的 FM 范式。接下来，我们将对每种范式进行简明介绍，突出它们的关键差异与进步，以及对遥感任务的影响。**(1) 传统机器学习.** 在这一范式中，遥感（RS）依赖于手工设计的特征和简单的学习模型，将这些特征分类到预定义的类别中。然而，该方法在特征创建方面严重依赖领域专业知识，使其在遥感领域的复杂任务和场景中效果较差。因此，其可扩展性和泛化能力受到显著限制。**(2) 从零开始的深度学习与预测**。深度学习通过用可端到端训练的深度神经网络（DNNs）取代复杂的特征工程，彻底改变了遥感（RS）图像解释，显著提升了 RS 模型的准确率和鲁棒性。该范式的研究重点在于设计有效的 DNN 架构，以从不同遥感传感器模态中提取有效特征，涵盖EO任务。然而，仍存在若干挑战：1）遥感

DNN 针对特定任务定制，限制了其泛化能力；2）从零开始训练导致收敛速度慢；3）大规模训练数据的收集与标注工作量大、耗时且成本高昂。

(3) FM 学习范式。 FM 的学习通常包含两个主要阶段，如图 3 所示：1) 预训练，模型学习可泛化且可迁移的表示；2) 利用，将预训练模型应用于下游任务。

预训练阶段可以分为两种常见方法：

- **监督预训练**。该方法涉及在大规模 标注数据集（例如，ImageNet [2]）上使用监督损失目标对深度神经网络（DNNs）进行预训练。尽管该方法在许多下游任务中实现了最先进的性能，但此方法需要大量标注数据，而收集这些数据的成本较高。
- **无监督预训练**。该方法利用自监督学习 [3], [4]，通过优化各种无监督预文本任务，从未标记数据中学习有用且可迁移的表示。这种方法在遥感（RS）领域尤其具有优势，因为不同平台（如卫星）上的众多传感器持续捕获大量数据，几乎无法进行标注。另一方面，预训练模型可能无法直接应用于特定任务。

预训练阶段之后，可以通过三种常见方法对因子模型（FMs）进行利用：

- **完全微调与预测**。该方法利用 FM 的强大表示作为起点，针对特定的下游任务对所有模型参数进行完全微调，以促进收敛并提升性能。然而，这种方法会覆盖并丢失强大 FM 的原始表示。
- **参数高效微调与预测**。与全量微调不同，Parameter-Efficient Tuning (PEFT) 仅引入轻量级、可学习的参数，同时保持 FM 主干网络冻结。这使得能够在保留 FM 强大表示空间的前提下，高效学习特定领域或特定任务的特征。在诸如推荐系统（RS）等场景中，当 FMs 因数据分布差异和多样化任务目标而面临性能挑战时，PEFT 尤其有益，能够在不损害 FM 能力的前提下，实现对这些领域和任务的适应。
- **zero-shot 预测**。在大规模数据上训练的 FMs 通常表现出强大的 zero-shot 预测能力，能够在无需针对特定领域或任务进行微调的情况下进行预测。然而，由于自然数据与遥感（RS）数据之间存在显著的领域差异，基于自然数据集训练的通用领域 FMs 在 RS 场景中经常表现不佳。此外，由于缺乏大规模的 RS 预训练数据集，令人遗憾的是，目前尚无任何 RSFM 能够展现出与通用领域 FMs 相当稳健的 zero-shot 能力。

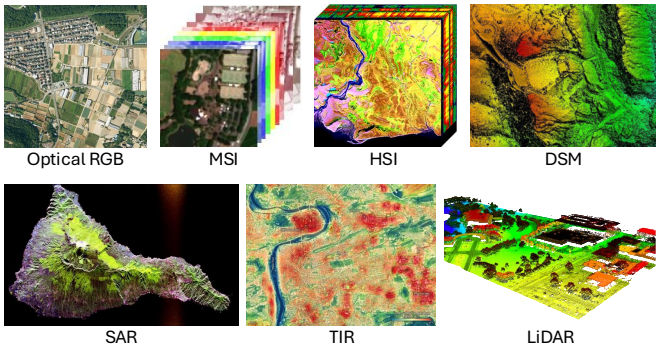

图 4: 不同射电谱学（RS）技术的实例。

B. 常见的雷达传感器模式

本小节概述了现有遥感图像融合模型（RSFMs）中常用的遥感传感器模态。这些模态的示例如图 4 所示。

- **光学 RGB 图像**，或真彩色图像，是遥感（RS）中应用最广泛的传感器模态之一。它们通过部署在卫星、飞机、无人机以及地面车辆等平台上的相机，捕捉红、绿、蓝光谱波段的可见光。尽管通用的视觉模型（FMs）可直接应用于这些图像，但由于遥感图像与自然图像之间存在领域差异，性能往往不理想。
- **MultiSpectral Images (MSI)** 在多个光谱波段上采集数据，其范围超越可见光 RGB 波段，包含部分 Near-Infrared (NIR) 和短波红外（SWIR）区域。尽管这些图像提供的光谱信息比 RGB 更丰富，但在应用于通用基础模型时仍面临输入不兼容性、领域差异以及光谱数据复杂性增加等挑战。
- **HyperSpectral Images (HSI)** 在数十个窄而连续的光谱波段上捕获数据，相较于多光谱成像（MSI）和光学 RGB 图像，提供了更为详细的光谱信息。这种精细的光谱分辨率使得材料和物质的精确识别成为可能，因此高光谱传感器非常适合用于矿物探索、植被分析和环境监测等任务。然而，高光谱图像（HSI）的高维度带来了计算复杂度增加以及过拟合的风险。此外，由于独特的光谱特性与领域差异，其与通用模型（FM）的兼容性较差。
- **Synthetic Aperture Radar (SAR)** 利用主动微波信号获取图像，可在全天候、昼夜条件下进行数据采集。合成孔径雷达（SAR）能够提供详细的地表信息，揭示地表结构与物质特性，因此在地形测绘、灾害监测和森林结构分析等应用中具有重要价

表 I: 遥感基础模型相关调查的综述。

Pub.	Year	Scopes & Contributions
[5]	2022	Developments in SSL for CV in the context of RS.
[6]	2023	Developments of SSL for various RS applications.
[7]	2024	Foundations for earth and climate RSFMs.
[8]	2024	Progress and trends for VLMs in RS.
[9]	2024	Generative AI and LLMs for RS.
[10]	2024	Broad overview of FMs in geoscience.
Ours	**2025**	**RSFMs in dataset development, model taxonomy, technical advances, and benchmarking.**

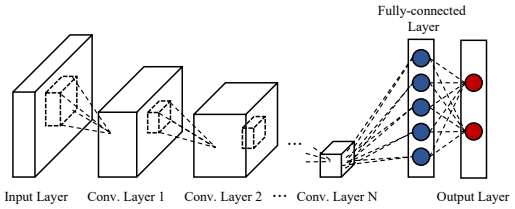

图 5: 基于 CNN 的深度神经网络架构。图源自 [11]。

值。极化合成孔径雷达（PolSAR）通过测量雷达波的极化特性，进一步增强了 SAR 的能力，使对地表特征的理解更加深入。干涉合成孔径雷达（InSAR）通过融合同一区域的多幅 SAR 图像，利用相位差分析检测微小的地表形变，对于高精度地形测绘至关重要。然而，由于斜距投影带来的独特几何特性，SAR 图像与传统的中心投影系统存在差异。此外，其复杂的特性，包括斑点噪声，给通用模型带来了显著挑战。

- **Light Detection and Ranging (LiDAR) 点云**通过发射激光脉冲并测量其在反射后返回的时间，捕捉三维（3D）空间数据。这使得能够生成地形和物体的高精度三维表示，因此激光雷达非常适合用于地形制图、森林结构分析和城市建模等任务。尽管点云包含丰富的几何信息，但其不规则且稀疏的特性给应用于图像等自然数据的通用模型带来了挑战。
- **热红外（TIR）图像**捕获物体发出的热量，基于温度差异提供数据。这使得 TIR 成像在环境监测、城市热岛分析、植被健康评估和火灾探测等应用中具有重要意义。TIR 传感器检测红外波段的发射辐射，即使在低光或夜间条件下也能实现热成像。然而，TIR 图像的空间分辨率通常低于光学传感器，且数据易受大气条件和表面发射率的影响，这给一般场景中热信息的准确解读带来了挑战。
- **Digital Surface Models (DSM)** 表示地球表面的高程，包括建筑物、植被和基础设施等各种物体。数字表面模型（DSM）通常由激光雷达、雷达或立体影像生成，广泛应用于城市规划、洪水模拟和景观分析。尽管数字表面模型提供了地表特征的宝贵三维信息，但其网格状结构和与高程相关的数据给通用模型（FM）带来了挑战。

C. 相关调查

本调查系统地回顾并基准测试了各种遥感（RS）领域中的基础模型（FMs），包括视觉基础模型（VFMs）、视觉语言模型（VLMs）、大模型（LLMs）、生成式 FMs 等。尽管在自然领域已有大量调查文献 [1], [11] 涵盖了多样化的范围和应用（见表 I），但它们并未专门针对地球科学和遥感模态进行讨论。此外，也有一些关于地球科学和遥感的调查，但它们聚焦于特定主题，例如地球与气候遥感基础模型 [7]、自监督学习 [5], [6] 和视觉-语言建模 [12]。[10] 提供了一个广泛但高层次的地球科学中基础模型的综述，主要强调通用领域的里程碑模型，而非地球科学特定的进展。该综述缺乏对遥感和地球科学数据集资源及技术进步的深入分析，限制了其捕捉最新领域发展的能力。此外，这些综述主要依赖定性分析，缺少定量基准测试，这使得评估不够全面。我们的调查旨在填补这些空白，提供一个全面且最新的遥感基础模型类型和遥感模态的概述，并突出该领域的最新进展。

III. RSFMs 的基础

FMs 的基础由两个关键技术要素支撑：*迁移学习* 和 *规模* [1]。*迁移学习*指的是利用从一个任务或模态中获得的知识来提升在另一个任务上的表现。在深度学习中，迁移学习的主要方法是预训练，即先在一个代理任务上训练模型，然后针对特定的下游任务进行微调。尽管迁移学习促进了 FMs 的发展，但真正增强其能力的是 *规模*。这一规模依赖于三个关键因素：(i) 计算硬件（尤其是 GPU）的进步；(ii) 深度学习架构的发展；(iii) 大规模训练数据集的可用性。

在第 IV、V 和 VI 节中，我们将详细回顾用于 RSFM 的预训练方法及其对应的预训练数据集。在本节中，我们首先在小节 III-A 中介绍基础深度架构，然后在小节 III-B 中讨论最常见的下游 RS 任务。

表 II: 遥感图像理解预训练中常用数据集概述。

Dataset	Date	#Samples	Modal	Annotations	Data Sources	GSD	Link
FMoW-RGB [13]	2018	363.6k	RGB	62 classes	QuickBird-2, GeoEye-1, WorldView-2/3	varying	
BigEarthNet [14]	2019	1.2 million	MSI,SAR	19 LULC classes	Sentinel-1/2	10,20,60m	
SeCo [15]	2021	1 million	MSI	None	Sentinel-2; NAIP	10,20,60m	
FMoW-Sentinel [16]	2022	882,779	MSI	None	Sentinel-2	10m	
MillionAID [17]	2022	1 million	RGB	51 LULC classes	SPOT, IKONOS,WorldView, Landsat, etc.	0.5m-153m	
GeoPile [18]	2023	600K	RGB	None	Sentinel-2, NAIP, etc.	0.1m-30m	
SSL4EO-S12 [19]	2023	3 million	MSI, SAR	None	Sentinel-1/2	10m	
SatlasPretrain [20]	2023	856K tiles	RGB,MSI,SAR	137 classes of 7 types	Sentinel-1/2, NAIP, NOAA Lidar Scans	0.5–2m,10m	
MMEarth [21]	2024	1.2 million	RGB,MSI,SAR,DSM	None	Sentinel-1/2, Aster DEM, etc.	10,20,60m	
HyperGlobal-450K [22]	2025	450K	HSI	None	EO-1, GF-5	30m	
Hyper-Seg [23]	2025	41,900	HSI	Masks	AVIRIS, Sentinel-2, GF-series, etc.	0.6-5m	

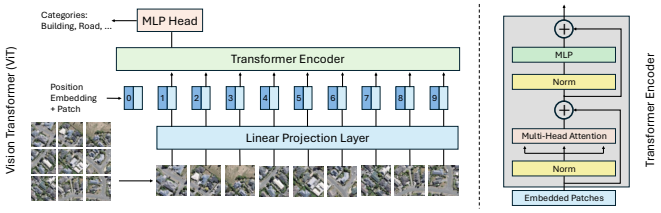

图 6: Vision Transformer (ViT) 的架构 [26].

A. 深度网络结构

卷积神经网络（CNNs）. 卷积神经网络是深度学习的基础模型，由于其能够通过局部感受野学习空间层次的特征，在视觉任务中被广泛应用，如图 5所示。其中，残差网络（ResNet）[24] 是一个突出的架构，通过引入跳跃连接来解决梯度消失或梯度爆炸等问题，从而能够构建非常深的网络。尽管卷积神经网络在许多遥感应用中十分普遍，但其在遥感特征建模中的作用主要集中在为视觉特征模型进行预训练。

Transformer. Transformer [25], [26]，如图 6 所示，通过自注意力机制设计用于处理序列数据，使其能够捕捉数据点之间的关系，而无需考虑它们的位置距离。与强调局部特征的卷积神经网络（CNN）不同，Transformer 在建模全局依赖关系方面表现优异，特别适用于长距离交互。在遥感领域中，Transformer 的一个显著优势是其跨多种模态的整合能力，使其能够处理多种输入类型，例如视觉数据（如图像、深度图、热成像）和非视觉数据（如文本、三维点云、音频）。这种跨模态集成为统一的遥感场景理解模型（RSFM）铺平了道路，使其能够处理广泛谱系的地理空间数据模态。

B. 典型的 RS 解释任务

- **场景分类**涉及将整个图像场景分类到预定义的 Land Use and Land Cover (LULC) 类别中，例如城市、森林、水域或农田。尽管场景分类是遥感（RS）中的基本任务，但由于空间分辨率的变化、光谱差异以及自然场景的复杂性，该任务仍面临挑战。
- **语义分割**涉及将图像中的每个像素分类到特定类别中，例如水体、植被或建筑区域，从而在像素级别提供土地利用/土地覆盖（LULC）的细粒度洞察。然而，遥感（RS）中的语义分割面临独特的挑战，例如光谱分歧，即不同物体可能具有相似的光谱特征，或者同一物体内部存在光谱变化。此外，复杂的空间模式以及处理多传感器和多分辨率数据的需求进一步增加了任务难度，因为这些数据集与自然图像分割中常用的通常存在显著差异。
- **目标检测**通过在图像中用边界框包围物体（如建筑物、车辆或船只）来识别和定位这些物体。遥感（RS）检测主要有两种类型：水平检测使用轴对齐的矩形，而 任意方向检测则将边界框旋转以匹配物体的方向，从而解决遥感图像中常见的各种角度问题。该任务在城市基础设施分析和监视等应用中至关重要，但面临尺度变化、遮挡等挑战。
- **变化检测**通过比较不同时期获取的图像来识别区域内的差异，从而实现对土地覆盖、城市扩展、植被健康状况或灾害影响的变化检测。该任务在环境监测、城市扩张追踪和灾害响应中发挥着关键作用。然而，其面临光照条件变化、季节性变化、传感器差异以及确保多时相图像精确配准等挑战，以实现准确分析。
- **Visual Question Answering (VQA)** 涉及基于图像内容回答语言问题。其目标是使用户能够通过直观的问题与遥感影像进行交互，例如识别物体、统计物品数量或评估 LULC 中的变化。视觉问答在帮助非专业用户从复杂的地理空间数据中获取洞察方面尤为有用。主要挑战包括理解专业问题的上

下文、将问题与不同遥感模态中的相关视觉信息关联起来等。

- **图像字幕生成**涉及为图像生成描述性文本，以总结关键特征和内容。该任务通过提供土地覆盖类型、城市结构或环境变化等元素的描述，使复杂的遥感（RS）影像更具可访问性。它支持文档编制、报告撰写和数据可及性。然而，由于遥感数据的独特特性，以及与自然图像领域相比，对应文本描述的可用性有限，因此在生成准确且详细的字幕时面临挑战，这些字幕需兼具相关性和信息量。
- **视觉定位**指将文本查询或描述与图像中的特定区域或对象进行关联的任务。在遥感（RS）领域，它能够根据文字描述定位建筑物或地表覆盖类型等特征。该任务对于查询卫星影像以及将观测结果与真实值进行验证尤其有价值。主要挑战包括处理遥感数据的空间和光谱复杂性，以及准确地将文本与相关的视觉元素对齐。

IV. 遥感领域的视觉基础模型

VFMs are large-scale pre-trained FMs tailored for visual tasks for processing images and videos. In the RS domain, VFMs are expected to handle a diverse array of visual sensor modalities beyond RGB images, such as optical MSI, HSI, SAR images, thermal images, and 3D LiDAR point clouds. Recent advancements in VFMs for RS can be categorized into two main approaches: pre-training models (encompassing both supervised and self-supervised methods) and Segment Anything Model (SAM)-based models [40].

A. 遥感中的 VFM 预训练

预训练已成为深度学习中的主流方法，其中模型首先在代理任务上进行训练，随后针对特定的下游应用进行微调 [1]。这种方法增强了知识迁移能力，能够在下游任务训练中降低计算成本并实现更快的收敛。FM 预训练的成功依赖于大规模数据集的可用性以及有效的预训练目标。在推荐系统领域，进展正在加速，*数据集*和*方法*方面均取得了显著进步。

1) 预训练数据集: 表 II 概述了近期 RSFMs 中所使用的预训练数据集。一个明显的趋势是数据集规模越来越大，训练数据的可用性不断提高，且更广泛地包含了多样化的遥感模态。令人鼓舞的是，这些数据集来自各种来源，并具有不同的 Ground Sample Distances (GSD)，为遥感研究构建了更为全面的数据库。另一方面，标注的高昂成本对预训练的收益造成了实际限制，这促使研究转向 Self-Supervised Learning (SSL)，即使用未标记的数据构建预训练数据集，从而更容易实现。尽管取得了这些进展，与通用基础模型所使用的数据集相比，遥感预训练数据集在规模（包括大小和模态多样性）方面仍显不足。

接下来，我们回顾遥感（RS）领域中的 VFM 预训练方法，包括监督式和自监督式方法。表 III 总结了代表性方法。

2) 监督预训练: 目前，大多数遥感（RS）模型都是使用来自 ImageNet [2] 的预训练参数进行初始化的，ImageNet 是一个包含超过 1400 万张跨 1000 个类别的自然图像的计算机视觉数据集。尽管这种方法取得了显著成果，但自然图像与遥感影像之间存在的显著领域差异——源于模态、视角、颜色、纹理、布局等方面的差异——常常导致在各种遥感任务中预训练性能不佳。

一些研究探索了专为遥感（RS）设计的预训练模型 [41]。例如，Wang 等人 [17] 收集了包含数百万个遥感影像场景的 MillionAID 数据集，并在此数据集上对监督式预训练进行了实证研究。他们评估了多种深度架构，包括不同的卷积神经网络（CNN）和视觉 Transformer，发现针对遥感的预训练有助于缓解使用 ImageNet 预训练时遇到的数据差异问题。然而，他们指出，某些差异可能仍会因遥感任务的不同而存在，且他们的预训练仅限于对 RGB 图像的分类任务。最近，Bastani 等人 [20] 研究了使用统一模型进行监督式多任务预训练的方法，该模型能够从七种不同类型的标签中学习，包括分类、语义分割、回归、目标检测、实例分割、折线预测和属性预测。该方法在各种下游遥感任务中均表现出明显的性能提升，即使面对不同图像分辨率也具有良好的适应性。

3) 自监督预训练: SSL follows a two-stage process: (1) *自监督预训练*，其中模型通过各种无监督的前置任务从未标记数据中学习到有用且可迁移的表示，以及 (2) *微调*，其中这些学成的表示被适配到特定的下游任务，从而实现更快的收敛和性能提升。鉴于由各类平台持续捕获的海量遥感（RS）和EO数据，对这些数据进行标注极为耗费资源，需要大量的人员投入、成本和专业知识。这种数据丰富但标签稀缺的环境使得自监督学习（SSL）成为遥感领域预训练的一种高效且有前景的

表 III: 不同预训练策略的遥感图像模型。”Sup.” 表示监督预训练；”SSL-C”、”SSL-M” 和”SSL-C&M” 分别表示自监督对比预训练、自监督掩码图像建模以及两者的结合。

Model	Pre-train	Publication	Modal	Contribution
RSP [17] [code]	Sup.	TGRS2022	RGB	Empirical study of supervised classification pretraining with large scale aerial images.
SatlasNet [20] [code]	Sup.	ICCV2023	RGB,MSI	Multi-task supervised pre-training with large scale aerial images.
SeCo [15] [code]	SSL-C	ICCV2021	MSI	Contrast across seasonal changes to learn time and position invariance.
GASSL [27] [code]	SSL-C	ICCV2021	RGB	Pre-training with temporal contrastive learning and geo-location classification.
MATTER [28] [code]	SSL-C	CVPR2022	RGB	Contrast temporally unchanged regions to learn material and texture representations.
CACo [29] [code]	SSL-C	CVPR2023	RGB	Change-aware sampling and contrastive learning for temporal satellite images.
CSP [30] [code]	SSL-C	ICML2023	RGB	Contrastive spatial pre-training for geo-tagged images.
SkySense [31]	SSL-C	CVPR2024	RGB, MSI, SAR	Contrast across modals and spatial granularities with geo-context prototype learning.
CRISP [32]	SSL-C	ECCV2024	RGB	Contrast between ground-level and aerial image pairs.
SatMAE [16][code]	SSL-M	NIPS2022	RGB, MSI	Temporal and multi-spectral MAE.
GFM [18] [code]	SSL-M	ICCV2023	RGB	Continual MIM pretraining from imagenet to the geospatial domain.
Scale-MAE [33] [code]	SSL-M	ICCV2023	RGB	MAE with low/high frequency reconstruction and a ground sample distance positional encoding.
msGFM [34] [code]	SSL-M	CVPR2024	RGB,MSI,SAR,DSM	Multimodal MIM with a shared encoder and distinct patch embedding/decoder.
SatMAE++ [35] [code]	SSL-M	CVPR2024	RGB,MSI	MAE pre-training with multi-scale reconstructions.
MA3E [36] [code]	SSL-M	ECCV2024	RGB	Pre-training with angle-aware MIM for learning angle-invariant representations.
OmniSat [37] [code]	SSL-C	ECCV2024	RGB, SAR	Cross-modal contrast among temporal and high-resolution RGB images and SAR images.
MMEarth [21] [code]	SSL-M	ECCV2024	MSI,SAR,DEM,etc.	Multimodal MAE with 12 paired pixel-level and image-level modalities.
CROMA [38] [code]	SSL-C&M	NIPS2023	MSI,SAR	Pre-training with cross-modal contrastive learning and multimodal MIM.
CS-MAE [39] [code]	SSL-C&M	NIPS2023	RGB	Cross-scale pre-training for both contrastive consistency and MIM reconstruction.
HyperSIGMA [22] [code]	SSL-M	TPAMI2025	HSI	A FM for HSI with MIM pre-training on spatial and spectral dimensions.
HyperFree [23] [code]	Sup.	CVPR2025	HSI	A channel-adaptive, tuning-free FM for HSI enabling promotable and semantic-aware segmentation.

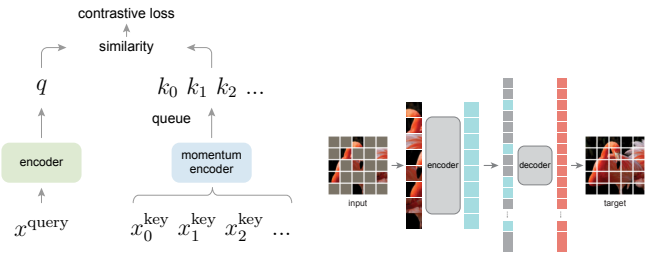

(a) MoCo [42] (b) Mae [43]

图 7: 两种自监督学习方法的典型方法。

替代方案，为利用大量未标记数据提供了一种成本效益高的途径。

受 CV [3], [4] 领域进展的启发，自监督学习（SSL）在推荐系统（RS）中取得了显著进展，主要通过两种方法推动：*对比学习*和 *Masked Image Modeling (MIM)*。尽管 SSL 在推荐系统中已被广泛研究，但大部分工作是在预训练模型（FM）出现之前完成的。相比之下，本文特别关注预训练 FMs 背景下的 SSL。如需了解推荐系统中 SSL 技术更全面且传统的综述，请参阅 [5]。

基于对比目标的预训练。自监督学习中对比学习的核心思想是将正例对（同一样本的不同增强视图）在特征空间中拉近，同时将负例对（不同样本）推开，如图 7 (a) 所示。这种方法有效地建模了数据之间的相似性和差异性，从而得到鲁棒且可迁移的表示。

给定一批 B 图像，对比学习目标（如 InfoNCE [44] 及其变体 [42], [45]）通常表述如下：

$$\mathcal{L}_I^{\text{InfoNCE}} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp\left(z_i^I \cdot z_+^I/\tau\right)}{\sum_{j=1,j\neq i}^{B}\exp\left(z_i^I \cdot z_j^I/\tau\right)}, \quad (1)$$

其中 z_i^I 是查询嵌入，$\{z_j^I\}_{j=1,j\neq i}^{B+1}$ 是键嵌入，z_+^I 表示与 z_i^I 对应的正键，其余则被视为负键。超参数 τ 控制学成表示的平滑性或分离度。尽管对比预训练 [42], [45]–[48] 在计算机视觉领域做出了重要贡献，它也激发了众多近期在推荐系统中的研究工作，这些工作可按传感器模态进行分类：

光学 RGB：大多数研究特别关注光学 RGB 模态 [49] 例如，GASSL [27] 通过将地理定位预测作为额外的预训练任务，增强了 MoCo-v2 框架 [46]。CACo [29] 利用对比学习检测短期和长期变化，充分利用了时间序列遥感图像的时空结构。MATTER [28] 在不变区域上使用多时相、空间对齐的遥感影像，构建对光照和视角变化不变的表示，专门用于材料和纹理。CSP [30] 为带地理标签的图像引入对比空间预训练，通过地理定位信息丰富表示学习。此外，Huang 等人 [50] 将未标记遥感图像上的自监督对比学习与标注自然图像上的监督学习相结合，证明了融合通用知识可显著提升遥感图像的预训练效果。

非光学 RGB：多项研究将对比学习扩展至光学 RGB 以外的模态。例如，SeCo [15] 将对比学习应用于 MSI，实现了对季节变化具有时间与位置不变性的表示学习。Li 等人 [51] 引入了全球土地覆盖产品以及遥感

图像的地理位置信息，以在对比学习框架中提供额外的监督信号。此外，Li 等人 [52] 在 RGB 与 NIR 图像上同时实施了全局与局部的对比学习技术。SkySense [31] 提出了一种整合多种模态与空间粒度的对比学习框架，通过地理上下文原型学习，促进 RGB、MSI 与 SAR 图像之间的跨模态处理。

生成式预训练。生成式预训练旨在通过生成式任务，利用未标记数据为下游微调开发丰富且通用的表示。一种广泛使用的方法是掩码图像建模（MIM），如图 7 (b) 所示，其中输入图像的随机图像块被掩码，模型的任务是在像素空间中重建缺失区域 [43]。这一重构过程要求模型理解图像中的物体及其周围上下文，从而生成对下游应用有效且有利的特征表示。对于一个批量的 B 张图像，损失函数定义为：

$$\mathcal{L}_{MIM} = -\frac{1}{B}\sum_{i=1}^{B}\log f_\theta(\overline{x}_i^I|\hat{x}_i^I) \tag{2}$$

其中 $\overline{x}_i^I$ 和 $\hat{x}_i^I$ 分别表示 x_i^I 中的掩码块和未掩码块，f_θ 指的是在掩码块 [43] 上仅计算的重建图像与原始图像之间的均方误差（MSE）。

MIM 已被广泛应用于遥感（RS）领域；然而，原始的 MAE 框架 [43]，专为静态自然 RGB 图像设计，常常难以应对遥感图像的独特特性。为此，一系列研究基于 MIM 架构提出了针对遥感特定挑战的解决方案：

- *不同的时间分辨率*: SatMAE [16] 专注于沿时间维度的嵌入进行 MAE 预训练，同时在时间上独立地掩码图像块。
- *不同的空间分辨率*: SatMAE++ [35] 为 RGB 和 MSI 提出了多尺度重构，以解决遥感图像中的空间分辨率变化问题。一些方法还探索了在频率领域进行重构 [39], [53]。例如，Scale-MAE [39] 结合了低/高频重构与地面采样距离位置编码。
- *变化的物体大小和方向*: Sun 等人 [54] 提出了一种补丁不完整掩码策略，以应对遥感图像中常见的小物体尺寸问题，该问题容易被随机掩码忽略。Wang 等人 [55] 开发了一种带有旋转、大小可变窗口注意力的 Transformer，结合了平均绝对误差（MAE）预训练。另一种方法是，MA3E [36] 使用角度感知的掩码图像建模（MIM）进行模型预训练，以学习角度不变的表示。
- *变化的光谱维度*：针对多光谱图像（MSI）[56]、高光谱图像（HSI）[22] 以及多模态数据 [57]，已在光谱维度上进行了掩码相关的研究。

此外，已有研究致力于开发针对遥感（RS）领域的高效 MAE 框架：Mendieta 等人 [18] 探讨了利用 ImageNet 模型作为辅助蒸馏目标进行持续预训练，以提升地理空间特征提取器（FMs）性能的同时降低下游计算成本；Wang 等人 [58] 提出了一种高效的 MAE 方法，仅对语义丰富的块级 token 进行编码与重建。

还有研究探索了与地理坐标对齐的配对遥感数据的多模态 MAE。例如，msGFM [34] 设计了一种具有共享编码器和独立补丁嵌入/解码器的多模态 MIM 框架，能够处理 RGB、MSI、SAR 以及 DSM 数据。另一方面，MMEarth [21] 开发了一种可处理 12 种配对像素级和图像级模态的多模态 MAE。

使用混合目标的预训练。多项研究将对比学习与 MIM 相结合，以利用判别性和生成性表示。例如，Muhtar 等 [59] 提出了一种对比掩码图像蒸馏方法，该方法在 RGB 空间内的自蒸馏框架中，通过结合对比学习与 MIM 来预训练模型。CROMA [38] 分别编码掩码的空间-时间对齐的多光谱影像（MSI）和合成孔径雷达（SAR）数据，然后采用跨模态对比学习，并借助一个额外的编码器融合传感器数据以生成联合多模态表示。这些表示随后用于通过轻量级解码器重建被掩码的块。跨尺度 MAE [39] 采用尺度增强，并通过对比损失与生成损失的组合来强制实现跨尺度一致性。这些方法表明，将对比学习与生成式自监督学习（SSL）合并能够学习互补表示，从而提升下游遥感任务的效果。

B. 遥感中的 SAM

1) SAM 概述: Segment Anything Model (SAM) [40] represents a significant advancement in image segmentation. Trained on the extensive SA-1B dataset, which includes over 11 million RGB images and 1.1 billion mask annotations, SAM excels in promptable segmentation. As shown in Fig. 8 (a), it allows users to generate high-quality object segmentation with reference of various geometric prompts, such as points, bounding boxes, or coarse masks.

SAM 对计算机视觉，尤其是图像分割领域产生了重大影响，这得益于其强大的泛化能力、稳健的 zero-shot 性能以及基于提示的灵活性。其多功能性使其能够适应众多下游应用，如医疗检查和自动驾驶，契合了人工智能模型向多任务无缝处理方向发展的趋势。

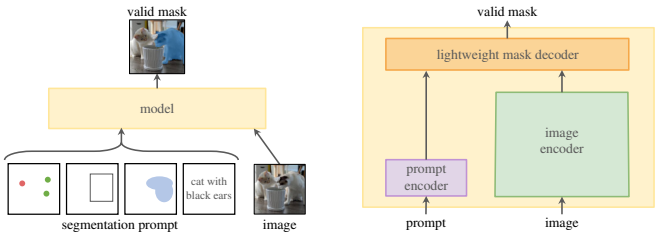

(a) **Task**: promptable segmentation (b) **Model**: Segment Anything Model (**SAM**)

图 8: SAM [40] 的概述，一个用于通用掩码分割的基础模型：(a) 可提示的分割 任务框架，以及 (b) SAM 的模型架构。该图改编自 [40]。

如图 8 (b) 所示，SAM 由三个核心组件构成：(1) 一个基于 ViT [26] 的重型编码器，将输入图像变换为嵌入；(2) 一个轻量级提示编码器，将几何提示处理为提示嵌入；(3) 一个轻量级掩码解码器，整合这些嵌入以生成精确的分割掩码。更详细的描述见 [40]。

2) 基于 SAM 的遥感研究: SAM 强大的分割能力在遥感（RS）领域引起了广泛关注。然而，由于存在若干关键挑战，其在遥感图像中的表现相较于自然图像仍有限：

- 遥感图像通常从大范围区域的航空或卫星视角获取，包含广阔而复杂的LULC模式，这些模式与 SAM 在自然领域训练数据中的特征存在显著差异。
- SAM 在无需语义理解的情况下针对通用掩码分割进行了优化，这对于解释遥感应用中的地理和环境数据至关重要。
- SAM 主要针对 RGB 图像设计，而遥感（RS）数据通常包含非 RGB 传感器模态，例如 MSI、HSI 或 SAR。

为应对这些挑战，已提出多种 SAM 的改进方法。一些研究致力于扩展 SAM 在遥感（RS）领域的语义分割能力。例如，Wang 等 [60] 提出了一种流水线，将 SAM 与常见的遥感目标检测数据集相结合，以生成光学 RGB 图像的语义分割数据集。Ma 等 [61] 利用 SAM 的对象和边界预测结果，对在标注遥感图像上训练的其他语义分割模型输出进行正则化。UV-SAM [62] 通过类别活性值映射生成的粗略掩码，优化为精确的伪标记，进而用于训练城市村落语义分割模型。

除了语义分割之外，SAM 还被应用于变化检测任务 [63]–[65]。例如，Zheng 等 [65] 探索了基于 SAM 的 zero-shot 变化检测；Chen 等 [66] 引入了一个可学习的基于锚点的提示器和掩码解码器，使 SAM 能够处理类别输入以实现实例分割。

与以往专注于 RGB 空间的研究不同，一些研究探索将语义分割扩展至非 *RGB* 领域。例如，Yan 等人 [67] 通过冻结 SAM 的编码器，采用 LoRA 进行PEFT，并为每种模态集成分离的解码器，将 SAM 适配到多种遥感（RS）模态（RGB、SAR、PolSAR、DSM、MSI），实现了跨多种传感器类型的语义分割。类似地，Osco 等人 [68] 将 SAM 与 GroundDINO [69]（一种开放集目标检测模型）结合，对无人机、航空及卫星的 RGB 图像实现基于文本的语义分割。

虽然大多数这些方法依赖于需要大量标注数据的完全监督方法，但 CAT-SAM [70] 提供了一种数据高效的 *few-shot adaptation* 替代方案。它采用提示桥结构，通过条件联合微调设计共同微调 SAM 的图像编码器和掩码解码器。该方法解决了编码器与解码器之间微调不平衡的问题，在下游微调样本极少的情况下，仍能在多种遥感（RS）传感器模态上实现优越的分割性能。

C. 总结与讨论

综上所述，遥感领域中关于视觉-语言模型的研究主要集中在预训练策略上，包括监督和无监督方法，尤其侧重于自监督学习。自监督学习方法，如对比学习和生成式掩码图像建模，已在减少对昂贵且耗时的标注依赖方面发挥关键作用。然而，当前遥感领域的自监督数据集在规模和多样性方面仍有限，无论是在单一模态还是多模态应用中，都制约了广泛采用的预训练模型的发展。

此外，SAM 的引入激发了众多针对遥感（RS）数据的适配方法，拓展了其在不同 RS 特定场景、语义识别任务、跨模态迁移和多模态处理中的应用。尽管已有少数研究探索了其他视觉基础模型（VFM），例如 *depth anything model* [71] 在树冠高度估计 [72] 和建筑物提取 [73] 等任务中的应用，但这些领域的进展仍较为缓慢。

值得注意的是，尽管许多被综述的框架已在多个传感器模态上分别进行训练和测试，但仅有少数遥感多模态框架（RSFMs）能够同时接受多种传感器模态作为互补输入。例如，msGFM [34] 表明，多模态预训练可在微调后提升多模态推理任务的下游性能。另一个例子是 TerraMind [74]，其整合了多种模态的配对数据，包括光学 RGB、SAR、NDVI、LULC、DSM、文本描述以及地理坐标。借助一个全球范围内可用的公开数据集，TerraMind 实现了大规模多模态掩码图像建模（MIM）

预训练，在跨模态合成数据生成以及 zero-shot 和 few-shot 场景中均取得了令人瞩目的成果。MM-SAM [75] 将 SAM 的 RGB 处理能力扩展至支持跨模态与多模态处理，从而在遥感中常用的多种传感器套件（如 RGB 加 HSI、RGB 加 LiDAR 等）上实现了更优的分割表现。

然而，这些研究中报告的多模态学习相对于单模态微调的性能提升仍然相对有限。这表明，尽管多模态学习是一个有前景的方向，但异构传感器模态的有效融合仍面临显著挑战，主要源于不同模态之间固有的空间分辨率、光谱特性以及物理感知原理差异。

重要的是，视觉基础模型（VFMs）已展现出超越传统遥感（RS）方法的新能力。例如，通过多模态掩码建模（MIM），实现了跨多种遥感传感器模态和产品的任意到任意生成框架 [74]；基于 SAM 的加速语义掩码标注流水线 [60]；以及仅需极少微调数据即可实现高精度分割性能 [70]。这些进展表明，VFMs 正开始加速遥感解释任务的演化。尽管当前的遥感基础模型（RSFM）研究尚未从根本上重塑传统上由常规方法解决的特定遥感应用，与通用领域中 GPT-4 或 SAM 带来的范式转变相比尚有差距，但未来仍具有巨大的潜力，有望充分释放 VFMs 在遥感领域的全部潜能。

V. 视觉-语言模型在遥感领域的应用

Vision-Language Models (VLMs) are multimodal models designed to integrate and process both visual and textual data. In contrast to VFMs, which focus exclusively on visual data, VLMs incorporate language understanding, unlocking powerful semantic interpretation and human-system interaction facilitated by textual representations. By training on extensive image-text datasets, VLMs excel in tasks requiring deep comprehension of both visual content and linguistic context, such as image classification [76]–[78], segmentation [79], [80], visual grounding [81]–[83], and image captioning [84]–[86], bridging the gap between visual perception and language-based interpretation. 图 9 给出了遥感领域中视觉语言模型任务的示例。

A. 视觉语言模型在自然领域中的预备知识

VLMs typically consist of two core components: a 视觉编码器和 语言编码器。视觉编码器将原始图像转换为稠密特征表示，而语言编码器则将文本输入处理为相应的嵌入。这些嵌入随后在共享的潜在空间中进行融合或对齐，使模型能够建立视觉与语言概念之间的关联。预训练视觉语言模型（VLMs）的一个关键方面是通过图像-文本对来连接视觉与语言，通常通过两种主要目标实现：对比学习和 生成式建模 [11]。

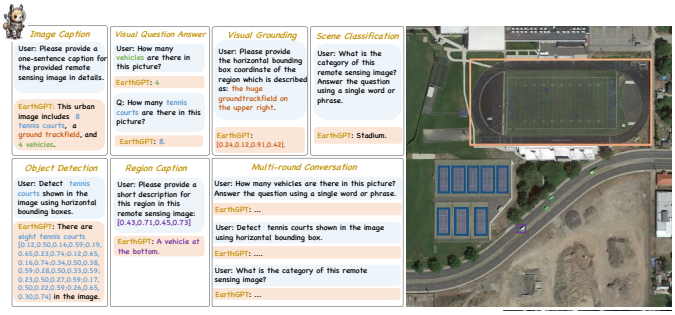

图 9: 生成式视觉语言模型的多任务输出。该图源自 [87]。

对比目标通过在表示空间中将匹配的图像-文本对拉近、不匹配的对推远，聚焦于对齐匹配的图像-文本对。代表性工作 CLIP [76] 联合训练图像编码器和文本编码器，采用对比学习方法。该方法使 CLIP 能够为视觉和文本数据学习统一的表示空间，从而实现卓越的 zero-shot 分类能力。CLIP 的灵活性使其在多种开放词表感知任务中表现出色 [109]–[111]。然而，原始的 CLIP 模型并未完全开源，这促使了 OpenCLIP [77] 的开发，这是一个完全开源的实现。在此基础上，EVA-CLIP [78] 引入了增强的训练策略以提升性能和效率。这些改进使 EVA-CLIP 在保持计算开销较低的同时，显著提升了训练稳定性，并在先前的 CLIP 模型上取得了令人瞩目的成果。

生成目标旨在训练模型生成连贯且相关的文本或图像。通常，这些目标主要有两种方法：掩码重构和自回归的下一个 token 预测。

- 掩码重构，在 FLAVA [112] 和 MaskVLM [113] 等模型中使用，涉及预测文本中的掩码 token 或图像中的掩码块。该技术提升了模型理解跨视觉与语言模态之间上下文和关系的能力，从而增强了跨模态理解能力。
- 自回归下一个 *token* 预测训练模型根据先前的上下文生成序列中的下一个 token。这一方法已成为视觉语言模型（VLM）训练的主导范式，很大程度上得益于其与预训练LLMs的协同作用。VLM 借

表 IV: 遥感视觉-语言生成数据集综述

Task	Dataset	Image Size	GSD (m)	#Text	#Images	Content	Link
VQA	RSVQA-LR [88]	256	10	77K	772	Questions for existing judging, area estimation, object comparison, scene recognition	
	RSVQA-HR [88]	512	0.15	955K	10,659	Questions for existing judging, area estimation, object comparison, scene recognition	
	RSVQAxBen [89]	120	10–60	15M	590,326	Questions for existing judging, object comparison, scene recognition	
	RSIVQA [90]	512–4,000	0.3–8	111K	37,000	Questions for existing judging, area estimation, object comparison, scene recognition	
	HRVQA [91]	1,024	0.08	1,070K	53,512	Questions for existing judging, object comparison, scene recognition	
	CDVQA [92]	512	0.5–3	122K	2,968	Questions for object changes	
	FloodNet [93]	3,000–4,000	-	11K	2,343	Questions for for building and road damage assessment in disaster scenes	
	RescueNet-VQA [94]	3,000–4,000	0.15	103K	4,375	Questions for building and road damage assessment in disaster scenes	
	EarthVQA [95]	1,024	0.3	208K	6,000	Questions for relational judging, relational counting, situation analysis, and comprehensive analysis	
Image-Text Pre-tranining	RemoteCLIP [96]	varied	varied	not specified	not specified	Developed based on retrieval, detection and segmentation data	
	RS5M [97]	not specified	varied	5M	5M	Filtered public datasets, captioned existing data	
	SKyScript [98]	not specified	0.1 - 30	2.6M	2.6M	Earth Engine images linked with OpenStreetMap semantics	
Captioning	RSICD [99]	224	-	24,333	10,921	Urban scenes for object description	
	UCM-Caption [100]	256	0.3	2,100	10,500	Urban scenes for object description	
	Sydney [100]	500	0.5	613	3,065	Urban scenes for object description	
	NWPU-Caption [101]	256	0.2-30	157,500	31,500	Urban scenes for object description	
	RSITMD [102]	224	-	4,743	4,743	Urban scenes for object description	
	RSICap [103]	512	varied	3,100	2,585	Urban scenes for object description	
	ChatEarthNet [104]	256	10	173,488	163,488	Urban and rural scenes for object description	
Visual Grounding	GeoVG [105]	1,024	0.24–4.8	7,933	4,239	Visual grounding based on object properties and relations	
	DIOR-RSVG [104]	800	0.5–30	38,320	17,402	Visual grounding based on object properties and relations	
Mixed Multi-task	MMRS-1M [105]	varied	varied	1M	975,022	Collections of RSICD, UCM-Captions, FloodNet, RSIVQA, UC Merced, DOTA, DIOR-RSVG, etc	
	Geochat-Set [104]	varied	varied	318k	141,246	Developed based on DOTA, DIOR, FAIR1M, FloodNet, RSVQA and NWPU-RESISC45	
	LHRS-Align [106]	256	1.0	1.15M	1.15M	Constructed from Google Map and OSM properties	
	VRSBench [106]	512	varied	205,307	29,614	Developed based on DOTA-v2 and DIOR dataset	
	TEOChatlas [107]	varied	varied	554K	1,244,393	Temporal EO dataset for multimodal instruction-tuning	
	SARLANG-1M [108]	varied	0.1-25	1,126,277	118,331	High quality SAR image-text dataset for image captioning and VQA.	

助大模型（LLMs）丰富的知识和语言理解能力，同时将这些能力扩展至视觉领域。代表性模型如 LLaVA [114]，已在多种视觉-语言任务中表现出色。这些模型通常由三个核心组件构成：一个预训练的语言模块（例如，Llama2 [115]、Vicuna [116]、Llama3 [117]）、一个预训练的视觉编码器（例如，CLIP [76]、EVA-CLIP [78]、SigLIP [118]），以及一个可训练的连接模块，用于桥接视觉与语言嵌入（例如，线性投影 [114]、两层 MLP [119]、Q-Former [86]）。该架构使模型能够充分利用预训练的视觉与语言模块的优势，而连接模块则学习在不同模态间对齐信息。

- 一些视觉语言模型（VLMs） [85], [86], [120] 采用混合方法，通过结合多种训练目标，利用不同方法的优势来提升模型在多样化视觉-语言任务中的鲁棒性和适应性。

值得注意的是，近期的研究已将这一框架扩展至图像-文本对之外，探索了大模型与编码器在其他模态（如音频 [121], [122] 和点云 [122], [123]）中的组合应用。这些进展旨在构建更加全面的多模态模型，能够从更广泛的感官输入中理解并生成文本内容，为遥感领域内的高级多模态理解提供了新的视角。

B. 遥感领域的视觉-语言数据集

在通用领域视觉语言模型（VLMs）取得进展的基础上，遥感（RS）领域正积极构建针对遥感的视觉-语言数据集，以奠定技术进步的基础。值得注意的是，遥感领域的视觉-语言任务有着悠久的历史，甚至早于基础模型（FMs）时代。为了全面概述这些努力，我们在表 IV中总结了现有的遥感视觉-语言数据集。

RS VQA：RS VQA 数据集旨在解析用户问题，识别相关的视觉证据，分析地理空间对象之间的空间关系，并生成简洁的文本回答。近年来，为城市规划和灾害评估等应用，开发了更大、更多样化的数据集。代表性例子包括 EarthVQA [95]、RSVQA [88]、RSIVQA [90] 和 FloodNet [93]。

遥感图像-文本预训练: 像 CLIP [76] 这样的对比预训练技术极大地推动了将遥感（RS）图像与文本描述配对的数据集的创建，使得 zero-shot 分类和跨模态检索等任务成为可能。多个关键数据集应运而生，各自采用独特的方法生成大规模的遥感图像-文本对以服务于遥感应用。例如，RemoteCLIP [96] 将检测和分割数据集中的标注转换为图像-标题对。GRAFT [124] 将来自 NAIP 和 Sentinel-2 的遥感影像与从互联网收集的同位置地面级图像进行关联。RS5M [97] 通过筛选并标注现有的遥感数据集来丰富视觉-语言任务的数据。SkyScript [98] 则利用地理坐标将 Google Earth Engine

影像与 OpenStreetMap 数据相连接。这些数据集展示了将现有资源重新利用和整合以支持新兴视觉-语言任务的共同努力，显著扩展了遥感应用的值域。

遥感图像描述生成：遥感图像描述生成通过生成长度可变的描述性句子，对遥感图像中的目标和特征进行总结，无需输入特定指令或问题。许多现有的遥感图像描述数据集都是基于场景分类数据集二次开发的，例如从 NWUPU45 数据集 [101] 衍生的 NWUPU45-Caption [125]，以及从 UCM 数据集 [126] 衍生的 UCM-Caption [100]。

遥感视觉定位：遥感视觉定位旨在根据给定的文本描述，在图像中识别出正确的地理空间对象。模型必须准确地定位目标对象，同时过滤掉不符合指定条件的无关对象。遥感视觉定位的数据集包括 GeoVG [105] 和 DIOR-RSVG [104] 数据集。

令人鼓舞的是，遥感（RS）领域的视觉-语言数据集开发取得了快速进展。然而，该领域仍落后于通用领域，且尚未满足EO应用的高需求。此外，大多数研究仍集中于 RGB 影像，对其他重要的遥感模态如SAR、MSI和HSI数据的探索仍然有限。

C. 具有对比性目标的视觉语言模型

类似于第IV-A3节中讨论的 VFMs 中的对比学习，VLMs [76] 中的对比预训练也采用 InfoNCE 损失 [44] 作为训练目标。FM 的一个典型例子是 CLIP [76]。主要区别在于，在 CLIP 中，对比样本是图像-文本对，目标变为对称的图像-文本 InfoNCE 损失，定义为：

$$\mathcal{L}_{infoNCE}^{IT} = \mathcal{L}_{I\to T} + \mathcal{L}_{T\to I}, \tag{3}$$

此处，第一项 $L_{I\to T}$ 将查询图像与文本键进行对比（即图像到文本），而第二项 $L_{T\to I}$ 将查询文本与图像键进行对比（即 文本到图像）。给定一个批量的 B 图像-文本对，$L_{I\to T}$ 和 $L_{T\to I}$ 定义为：

$$\mathcal{L}_{I\to T} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp\left(z_i^I\cdot z_i^T/\tau\right)}{\sum_{j=1}^{B}\exp\left(z_i^I\cdot z_j^T/\tau\right)}, \tag{4}$$

并且

$$\mathcal{L}_{T\to I} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp\left(z_i^I\cdot z_i^T/\tau\right)}{\sum_{j=1}^{B}\exp\left(z_i^T\cdot z_j^I/\tau\right)}, \tag{5}$$

其中 z_I 和 z_T 分别为图像和文本的嵌入，τ 为可学习的温度参数。最小化该损失能够对齐图像与文本的表示，确保匹配的图像-文本对具有更高的相似度得分，而不匹配的对则得分较低。这一过程使 CLIP 能够学习到丰富的视觉-语言表示，这些表示可以有效应用于多种任务，而无需进行特定任务的微调。

尽管 CLIP 在众多视觉任务中表现出色，但其训练数据主要由从互联网获取的通用图像-文本对组成。虽然这种广泛的方法非常强大，但可能无法充分捕捉遥感（RS）数据的独特属性和特征。为解决这一局限性，研究人员开发了专为遥感应用量身定制的 CLIP 改进版本。这些改进通常分为两类：*视觉-文本模型*和 *视觉-位置模型*，将在本小节剩余部分进行综述。

*1) 视觉-文本模型：*该方向的现有研究主要将 CLIP 扩展至遥感领域，重点集中在开发遥感专用的数据集和基准。这些努力使得 CLIP/OpenCLIP 能够通过完全监督的方法或更高效、资源节约的微调策略，针对遥感任务进行微调。

例如，RemoteCLIP [96] 通过持续预训练方式适配 CLIP，同时保留其原始架构。在分类和跨模态检索等任务上进行评估，还引入了 RemoteCount 基准用于物体计数。类似地，SkyCLIP [98] 也在自定义数据集上采用持续预训练，评估模型在 zero-shot 场景分类、细粒度属性分类和跨模态检索上的性能。此外，GeoRSCLIP [97] 探索了完整和PEFT 技术，目标是实现 across 多个基准的 zero-shot 分类、跨模态检索和语义定位。

不同的是，GRAFT [124] 引入了一种无需文本标注的独特策略。通过使用对比学习将卫星图像与地面级图像对齐，GRAFT 构建了遥感（RS）领域的图像级和像素级视觉-语言模型。在分类、检索和分割任务上的评估表明，其性能显著提升，尤其是在 zero-shot 情景下，充分利用了卫星图像与地面级图像之间的对齐关系。

*2) 视觉-位置模型：*对比学习型遥感视觉语言模型（VLM）的另一重要研究方向是利用经纬度等地理定位信息对遥感数据进行建模。这些视觉-位置模型旨在将遥感图像与几何位置上下文相结合，从而对EO数据提供更加交互式和全面的理解。

CSP [30] 是一项开创性研究，采用双编码器架构分别处理带有地理标签的图像和位置信息，然后通过自监督方式下的对比学习对齐其嵌入表示。CSP 探索了正负样本对的不同采样策略，并评估了多种自监督损失函数，在不依赖文本标注的情况下，于 iNat2018 [127] 和 fMoW [13] 数据集上表现出色，尤其在少样本学习设置下的地理感知分类任务中表现优异。

GeoCLIP [128] 采用了一种不同的方法，将地理定

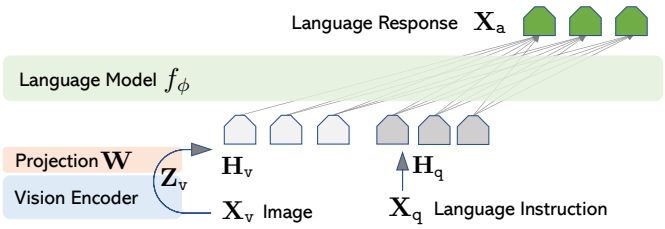

图 10: LLaVA 中基于视觉语言模型的条件生成流水线 [114].

位问题视为图像到 GPS 的检索任务。它结合了基于等面积投影的编码器、随机傅里叶特征以及分层表示，使其能够将 GPS 坐标表示为连续函数，从而绕过了预定义地理类别所带来的限制。通过与基于 CLIP 的图像编码器相结合，GeoCLIP 实现了精确的 GPS 检索，而非简单的区域分类，能够在低数据场景下提供灵活且准确的定位能力，具有超越地理定位的潜在应用价值。

SatCLIP [129] 强调采样中的地理多样性。与 CSP 不同，它采用全球采样的 S2-100K 数据集，该数据集包含 100,000 幅哨兵-2 卫星图像，以确保广泛的地理覆盖。该模型使用基于球谐函数的位置编码器，将卫星图像与地理嵌入对齐，从而增强在不同区域间的泛化能力。该方法在多种依赖位置的任务中表现出色，例如温度预测和人口密度估计，有助于开发具备全球泛化能力的地理平衡模型。

SatMIP [130] 将位置和时间等元数据编码为文本描述，并通过元数据-图像对比学习任务在共享嵌入空间中将其与图像对齐。该方法使模型能够学习到鲁棒的图像表示，从而借助元数据提供的丰富上下文信息，提升其处理识别任务的能力。

D. 具有生成式目标的视觉语言模型

在视觉语言模型（VLMs）中，生成式目标使网络能够通过生成数据（无论是图像、文本还是跨模态输出）来学习语义特征 [11]。尽管遥感（RS）领域采用这些技术的步伐较慢，但当前关于具有生成式目标的遥感视觉语言模型的研究大多基于 LLaVA [114] 框架，这是一个用于图像条件文本生成的著名开源视觉语言模型。

LLaVA 通过指令微调来提升其多模态对话能力。Liu 等人生成了 150k 个合成的视觉指令样本以对模型进行微调。如图 10 所示，原始的 LLaVA 架构将预训练的 Vicuna 语言模型编码器与预训练的 CLIP ViT-L/14 视觉编码器相结合，通过一个线性投影器将其输出对齐到共享特征空间中。其生成目标使模型能够基于先前的 token 逐个预测每个 token，从而实现自回归式响应生成。该生成目标可定义为：

$$\mathcal{L}_G = \sum_i \log P(x_a^i | x_a^{i-k}, ..., x_a^{i-1}; \phi), \tag{6}$$

其中 x_a^i 表示答案中预测的 i^{th} 词，ϕ 表示语言模型中的可学习权重。

为了在遥感（RS）中利用 LLaVA 架构，已提出若干开创性研究。例如，GeoChat [131] 通过整合多种遥感数据集（包括 RSVQAxBEN [89]、FloodNet [93] 和 DOTA [132]），构建了一个全面的多任务指令遵循数据集。在使用低秩适应（LoRA）[133] 对语言模型进行微调后，GeoChat 在各类遥感任务中展现出强大的 zero-shot 性能。

LHRS-Bot [106] 通过逐步微调视觉和语言模型，利用大量志愿者提供的地理信息和全球可用的遥感图像，进一步增强了生成能力。针对精细化遥感场景理解，SkysenseGPT [134] 在自定义数据集上对 LLaVA 模型进行微调，以实现对象、区域和图像级别的理解。

除了光学影像之外，EarthGPT [87] 还将 SAR 和红外影像纳入其指令遵循数据集，从而提升了在多传感器影像上的表现。为了更好地分析城市场景，UrBench [135] 开发了结合遥感（RS）影像与街景影像的多视角指令，突显出视觉语言模型（VLMs）在解读不同城市视角时的不一致性。

尽管先前的研究集中于单张静态图像，TEOChat [107] 专注于关于地球观测数据的 时间序列的对话，包括建筑物变化与损毁评估、语义变化检测以及时间场景分类。EarthDial [136] 是一种最近提出的遥感对话助手，支持多种 EO 任务，包括分类、检测、描述生成、视觉问答、视觉推理和定位，适用于多光谱、多时相和多分辨率影像。它可处理多种模态，包括 RGB、SAR 以及多光谱波段（例如 NIR 和红外），并支持双时相及多时相分析以实现变化检测。

先前的研究通常将不同 GSDs 的遥感（RS）影像进行融合，以适应空间分辨率的差异；然而，其调参数据通常仅限于低分辨率和中等分辨率影像。遥感领域的一个显著挑战在于解析超高分辨率影像，其中图像尺寸庞大，而感兴趣目标往往极其微小。为了评估现有模型在此情境下的能力，Wang 等人 [137] 提出了 XLRS-Bench，这是一个基于超高清遥感影像构建的基

准测试，揭示了当前模型在该类条件下存在显著的性能局限性。

E. 总结与讨论

总而言之，遥感领域的视觉语言模型旨在捕捉并建模不同类型视觉数据与相应文本描述之间的相关系数。该领域的研究可大致分为两个主要方向：对比学习，通过视觉-文本模型和视觉-位置模型等方法对齐图像-文本对；以及生成式学习，侧重于基于图像的自回归文本生成，典型代表为基于 LLaVA 的方法。一方面，正在开发更大、更丰富的遥感数据集以支持各类视觉语言模型任务；另一方面，多数研究仍主要集中于光学 RGB 空间，重点在于高效地将通用领域模型的知识迁移至遥感应用中。

尽管当前大多数遥感领域的视觉语言模型仍针对特定应用进行定制，但它们已展现出实现更灵活、可扩展且用户友好的遥感解决方案的初步迹象。这些模型为遥感解译提供了一种新范式，通过促进地理空间数据的更互动和多功能使用，有望超越传统的任务专用方法。

VI. RSFM 的其他基础

在本节中，我们探讨了除 RSFMs、VFMs 和 VLMs 之外的其他类型的 RSFMs。这些包括用于 RS 的 Large Language Models (LLMs)、用于 RS 的生成式基础模型以及气象预报模型。

A. 用于遥感的大型语言模型

大模型（LLMs），如 GPT 系列 [138]–[141]，已在多个领域推动人工智能和地理信息系统（FMs）的发展中发挥关键作用。它们通过利用大规模文本语料库中的海量知识（通常包含数十亿甚至数万亿个来自互联网的文本 token），在跨任务泛化方面表现出极高的有效性。尽管取得了广泛应用的成功，但大模型在遥感（RS）领域的应用仍相对较少被探索，尤其与视觉-语言模型（VFMs）和视觉-语言大模型（VLMs）相比。这一差距主要源于大模型缺乏许多遥感应用所必需的视觉感知能力。然而，大模型凭借其丰富的基于文本的知识，在支持地理空间预测任务方面具有巨大潜力，这一方向仍是一个有价值但尚未得到充分研究的领域。

Manvi 等人 [142] 提供了早期的洞见，揭示了 GPT 3.5 等大模型具备超出预期的空间知识。然而，他们也发现，仅通过地理坐标（例如纬度和经度）对大模型进行查询，无法准确预测人口密度等关键地理空间指标。为克服这一局限，他们提出了 GeoLLM，一种使用来自 OpenStreetMap 的辅助 地图数据增强提示词来微调大模型的方法。[1]. 通过引入空间上下文，GeoLLM 使大模型能够更有效地利用其潜在的地理空间知识。因此，GeoLLM 在人口密度、资产财富、平均收入和女性教育等多个关键地理空间指标上均表现出更优的性能。

B. 生成式模型与遥感数据合成

尽管以往关于遥感特征模型（RSFMs）的多数研究集中于判别式下游任务，生成式建模代表了一个至关重要的互补方向，尤其在数据合成方面。RSFMs 的发展需要大规模且多样化的数据集以实现有效的预训练；然而，遥感数据通常稀缺、不完整，模态异质性强，且收集或标注成本高昂。通过扩展可用数据的多样性和数量，合成数据生成提供了一种有前景的解决方案，常可自动提供标注，从而加速大规模、多功能遥感模型的构建。

生成式基础模型，特别是扩散模型 [143]–[146]，在自然图像生成方面取得了显著成功，通常利用文本提示或元数据等辅助信息实现可控生成。然而，遥感（RS）数据具有独特的特性，例如变化的光谱波段、不规则的时间采样以及复杂的时空结构，这些特性带来了超出自然图像领域挑战的额外难题。这些差异要求开发专门针对遥感数据特性的生成方法。尽管面临这些挑战，生成式模型在推动遥感应用方面仍具有巨大潜力，包括超分辨率、云层去除、时间插补以及跨模态数据生成，凸显了构建面向遥感领域的专用生成式基础模型的迫切需求。

最近的研究已经开始探索这一方向。Khanna 等人 [147] 提出了 DiffusionSat，这是首个专为卫星影像设计的生成式频域模型，其架构受 Stable Diffusion 启发 [146]。DiffusionSat 在图像生成过程中不仅依赖文本描述，还结合了卫星特有的元数据，如纬度、经度、时间戳以及 GSD。这种数据驱动的条件设定使模型能够灵活适应多种生成任务，包括单图合成、超分辨率、图像修复以及从公开卫星数据集出发的时序生成。与此同时，Zheng 等人 [148] 提出了一种基于扩散过程的生成式概率变化检测模型，展示了生成式模型在解决核心 EO 问题方面的实用性。

[1] https://www.openstreetmap.org

除了基于扩散的方法外，多模态掩码建模也成为了合成数据生成的另一条路径。例如，TerraMesh [149] 通过结合光学影像、SAR、DEM 和土地覆盖数据，构建了一个全局多样化的多模态数据集，利用掩码重构目标生成合成的多模态输出。这使得能够创建丰富且跨模态的训练样本，而这些样本在大规模获取时通常困难且成本高昂。

另一个有前景的方向是基于物理的仿真用于遥感数据合成 [150], [151]。诸如 SynRS3D [151] 这类流水线利用 Blender 等 3D 图形引擎，结合 GPT-4 生成的文本描述以及 Stable Diffusion 提供的纹理真实感，以合成大规模、高分辨率的光学数据集。SynRS3D 具有多种地表覆盖类型、精确的高度信息以及标注的建筑物变化，为训练遥感特征模型（RSFMs）提供了可扩展且灵活的高质量遥感数据集创建方案。

总体而言，这些生成式建模工作标志着遥感基础模型（RSFM）能力的重大拓展，超越了传统的判别任务，突显了合成数据流水线在构建强大、通用且可扩展的遥感基础模型中的重要性。

C. 计算效率与可扩展性

FMs are highly computation-intensive, and RS applications further exacerbate this due to high-resolution, multimodal, and temporally rich data, along with demands for real-time processing and edge deployment. These factors pose substantial challenges to the scalability and efficiency of RSFMs.

一种常用策略是采用 *PEFT* 方法（例如，LoRA 和适配器模块）以及 知识蒸馏，以减轻训练数据和计算资源的需求。如前文所述，大多数遥感特征建模（RSFM）研究都利用了这些技术，在保持对遥感特定任务的适应性的同时降低开销。

除了微调之外，另一个有前景的方向是设计针对遥感（RS）边缘设备部署的轻量级主干架构。例如，Wang 等人 [152] 提出了一种精简架构，通过动态调整空间感受野来适应遥感数据中常见的目标尺度变化，从而增强遥感图像中的空间上下文建模能力。类似地，Li 等人 [153] 提出了一个双分支卷积神经网络-Transformer 混合架构，专为在轨推理优化，在表示容量与计算效率之间取得了平衡。

此外，模型压缩在 RSFMs 中仍然是一个关键但相对研究不足的领域。其主要目标是在保持任务性能的同时减少模型大小、推理延迟和内存占用，这是实现资源受限环境部署的重要步骤。在这方面的一项早期工作由 Shinde 等人提出。[154]

鉴于遥感数据的多模态异质性和时空复杂性，未来的工作应聚焦于专业化策略，包括多模态感知压缩、自适应推理和动态资源管理，以实现遥感特征匹配的实用化和可扩展部署。

D. 天气预报基础模型

RSFMs 在其他地球科学应用中也取得了令人瞩目的进展，尤其是在天气预报领域。一个典型的例子是 *Pangu-Weather* [155]，这是一个由人工智能驱动的系统，能够生成高度准确的确定性预测。该模型基于全球 39 年的数据进行训练，采用了一种定制的三维地球特异性 Transformer（3DEST）架构，将诸如高度等与地球相关的先验知识融入模型。此外，它还采用了分层的时间聚合算法，使模型针对逐步延长的预报提前期进行训练。与世界顶尖的传统数值天气预报（NWP）系统相比，Pangu-Weather 始终表现更优，凸显了 RSFMs 在 EO 及相关地球科学应用中的变革潜力。

E. 负责任的 *RSFMs*

随着遥感特征模型（RSFMs）的持续发展，必须考虑其超越技术革新的更广泛影响。大规模的训练与部署引发了重要的环境与伦理问题，同时也带来了显著的社会效益潜力 [1]。这一点尤其重要，因为遥感（RS）在 EO、环境监测、灾害响应和国家安全中具有战略地位。最近，Ghamisi 等人 [156] 提供了一篇及时且全面的关于 EO 的负责任人工智能的综述。他们的工作强调了安全、隐私、伦理风险、算法偏见和公平性等关键维度，并提出了切实可行的路径，以确保模型开发与社会价值及公共利益相一致。尽管本综述侧重于 RSFMs 的技术基础，我们仍建议读者参考此项工作，以深入了解负责任实践及其对遥感（RS）社区的相关性。

F. 总结与讨论

综上所述，尽管大模型和通用领域生成式模型在各类应用中展现出革命性的性能，但其在遥感领域的对应模型仍落后于前者。然而，近期将这些模型适配至遥感领域的进展令人鼓舞，显示出巨大的潜力与机遇。此外，诸如气象预报等专业遥感应用，凸显了将先进人工智能技术与特定领域遥感知识相结合的专用遥感生成模型

（RSFMs）的必要性。这进一步强调了人工智能创新与地理空间科学更深度融合的重要性，以充分发挥遥感生成模型的潜能。

VII. 基准性能

在本节中，我们对比、分析并讨论了本文综述所回顾的现有遥感特征建模（RSFM）研究。需要特别注意的是，这些研究在研究重点、模态、学习设置以及目标任务或应用方面各不相同，因此难以使用统一的基准对所有研究进行公平比较。此外，由于 RSFM 的发展仍处于早期阶段，跨不同任务和模态的稳健且全面的评估框架尚未完全建立。

鉴于上述局限性，我们聚焦于关键维度，力求为当前进展及未来方向提供具有信息量的分析与洞察。

A. VFM 预训练性能

如第 IV-A 节所述，VFM 预训练模型随后被微调以应用于各种下游遥感任务 [157]。表 V 展示了在不同模态下广泛采用的七项下游任务的评估结果，包括：BigEarthNet [14] 用于 多标签地表覆盖分类；EuroSAT [158] 用于 *LULC* 分类；Onera Satellite [159] 用于 变化检测任务；SpaceNet [160] 用于 建筑物分割；功能世界地图（FMoW） [13] 用于 高分辨率卫星影像时序分类，涵盖 62 个类别；DIOR-H [161] 用于 水平目标检测，DIOR-R [162] 用于 定向目标检测。所有指标均源自相应论文。我们选取了最广泛使用的数据集进行比较，尽管其他基准（如 Geo-Bench [163]）以及针对不同任务定制的基准也可能提供有价值的见解。

从表中可以看出，各种遥感任务均受益于日益先进的预训练方法。此外，许多预训练方法在多个下游任务中均表现出有效性。然而，必须认识到，不同方法可能针对特定应用场景，这凸显了建立全面且标准化基准以实现公平比较的必要性。此外，该领域仍存在巨大的发展潜力，表明未来研究具有广阔机遇。

B. VLM 迁移学习性能

本小节评估了多种视觉语言模型（VLM）在遥感（RS）领域的 zero-shot 性能。我们首先进行 *closed-set* 评估，将通用领域 VLM 如 CLIP 与基于 CLIP 微调的 RS 领域专用模型（如 CLIP-RSID[2]、RemoteCLIP [96] 和 GRAFT [124]）在图像分类和检索等关键 RS 任务上的表现进行比较。这些模型通过将图像和文本映射到共享嵌入空间，实现 zero-shot 评估。该过程包括使用图像编码器提取图像特征，并利用文本编码器从特定类别提示（例如任意类别名称）生成文本嵌入。随后，模型计算图像嵌入与文本嵌入之间的余弦相似度，并将得分最高的标签作为预测结果。性能通过标准分类指标进行衡量，使模型能够在无需额外任务特定训练的情况下，泛化至多样化任务。

表 VI 展示了来自 [124] 的基准测试结果。结果显示，尽管 CLIP 在遥感（RS）数据集上表现出一定的有效性，但其性能相较于在自然图像基准上的表现仍有不足。相比之下，近期针对遥感领域的特定视觉语言模型（VLM）展现出显著提升，凸显了为遥感应用定制 VLM 的潜力。然而，这些专用模型往往在特定基准上表现良好，但在整体鲁棒性方面不如 CLIP。这些结果既突显了当前取得的进展，也揭示了该领域未来发展的巨大机遇。

另一种基于 VQA 的基准用于 *open-set* 评估。这些模型通过分离编码图像和问题，然后融合它们的表示来理解视觉与文本信息之间的关系，实现 zero-shot 评估。基于这种联合表示，不同类型的模型要么以开放式格式生成答案，要么从预定义集合中选择最可能的答案。

作为开放集基准的一个例子，GEOBench-VLM [164] 最近被提出用于评估遥感（RS）中的视觉语言模型（VLM），涵盖八个广泛类别下的 31 个细粒度任务，包括场景和物体分类、目标检测、分割、图像描述、事件检测以及非光学和时间理解任务。该基准为 VLM 在地理空间应用中的感知任务提供了全面的评估。图 11展示了对 10 个开源及先进专有 VLM 的评估结果。结果显示，开源模型与闭源模型之间存在显著性能差距，而所有模型在各类地理空间识别任务中均表现出次优性能。其主要限制源于训练数据中的偏差，因为当前大规模多模态数据集包含的地理空间数据有限，制约了模型在遥感特定任务上的有效泛化能力。这凸显了构建更先进、更专业的模型以支持复杂的地球观测和地理空间解释任务的必要性，强调了在建设更强大且领域适配的遥感基础模型（RSFM）方面，开展专门的地球科学与遥感研究的重要性。

VIII. 未来方向

尽管在遥感基础模型（RSFM）方面已取得显著进展，但其仍处于早期发展阶段，尤其是在与通用基础模

[2]https://github.com/arampacha/CLIP-rsicd

表 V: 不同预训练方法在常用下游基准上的性能。*, ⋆ , † 表示指标数值分别来源于 [31], [36], [35]。"FT" 表示微调。

Method	Backbone	BigEarthNet (mAP)		EuroSAT	Onera Satellite			SpaceNet	fMoW RGB	DIOR-H	DIOR-R
		10% FT	100% FT	Acc.	Prec.	Rec.	F1	mIoU	Acc.	mAP_{50}	mAP
SeCo [15]	ResNet-18	81.9	87.3	93.1	65.5	38.1	46.9	-	-	-	-
SeCo [15]	ResNet-50	82.6	87.8	-	-	-	-	-	-	-	-
GASSL [27]	ResNet-50	80.2	-	89.5†	-	-	46.3*	78.5	71.6	67.4*	65.7*
MATTER [28]	ResNet-34	-	88.0	-	61.8	57.1	59.4	81.1	-	-	-
SatMAE [16]	ViT-L	82.1	-	98.9	-	-	52.8*	78.1	77.8	70.9*	65.7*
CACo [29]	ResNet-18	-	-	-	60.7	42.9	50.3	-	-	-	-
CACo [29]	ResNet-50	81.3*	87.0*	-	62.9	44.5	52.1	-	-	66.9*	64.1*
GFM [18]	Swin-B	86.3	-	-	58.1	61.7	59.8	-	-	72.8*	67.7*
Scale-MAE [33]	ViT-L	-	-	-	-	-	-	78.9	77.9	73.8*	66.5*
CSP [30]	ResNet-50	-	-	-	-	-	-	-	71.0	-	-
CROMA [38]	ViT-B	85.0	-	99.2	-	-	-	-	-	-	-
CROMA [38]	ViT-L	85.0	-	99.5	-	-	-	-	-	-	-
SkySense [31]	ViT-L	88.7	92.1	-	-	-	60.1	-	-	78.7	74.3
msGFM [34]	Swin-B	87.5	92.9	-	-	-	-	-	-	-	-
SatMAE++ [35]	ViT-L	85.1	-	99.0	-	-	-	-	78.1	-	-
MA3E [36]	ViT-B	-	-	-	-	-	-	-	-	-	71.8

表 VI: 基于哨兵-2 数据的 VLMs 在遥感图像分类与检索基准上的 zero-shot 性能比较。

Model	Downstream Annotations	Backbone	Classification		Retrieval			
			EuroSAT	BEN	EuroSAT		BEN	
			Acc.	mAP	mAP^{100}	mAP^{20}	mAP^{100}	mAP^{20}
CLIP [76]	✗	ViT-B/32	47.61	21.31	46.86	49.61	30.45	32.20
CLIP [76]	✗	ViT-B/16	53.59	23.13	63.99	72.57	32.54	33.10
CLIP-RSICD[2]	✓	ViT-B/32	45.93	27.68	49.88	53.50	38.76	36.11
RemoteCLIP [96]	✓	ViT-B/32	38.59	22.76	51.21	53.27	34.39	38.42
GRAFT [124]	✗	ViT-B/32	47.80	29.31	66.12	72.36	45.88	45.35
GRAFT [124]	✗	ViT-B/16	63.76	32.46	81.56	85.21	49.61	53.86

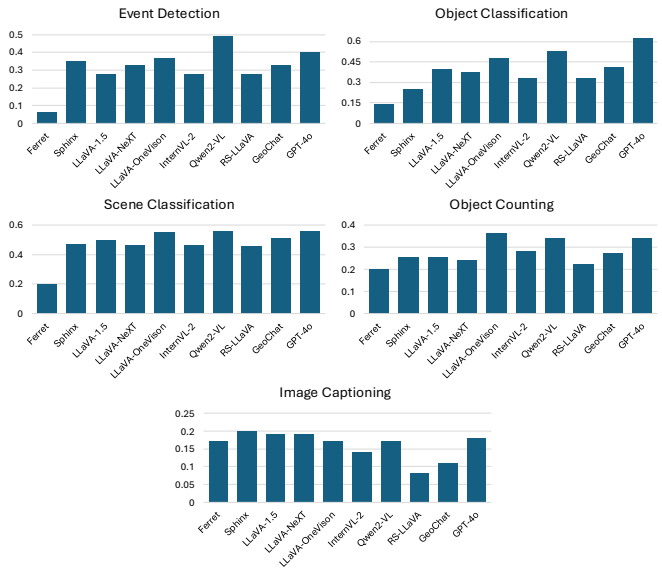

图 11: 不同任务上典型 VLM 在 GEOBench-VLM [164] 上的 zero-shot 性能比较。

型相比时。然而，该领域的发展潜力和机遇极为巨大。以下是几个关键的未来研究方向。

更大更丰富的数据集: FMs 依赖于海量数据，其核心原则是"数据越多越好" [1]。然而，当前的遥感 (RS) 数据集尚不足以支持真正大规模的 RSFM 训练。一个显著的现象是，通用领域 FMs 中观察到的"涌现能力"在 RS 领域中并未出现，这表明现有 RS 数据的规模和多样性仍不足以促成类似的进展。与此同时，尽管基于通用 FMs 微调得到的 RSFMs 在特定基准上通常表现出更优性能，但在分布外数据上的泛化能力仍然不足。

未来的数据集构建工作不应仅关注数据量的增加，还应优先考虑模态多样性、光谱与时间分辨率以及数据集偏差等关键维度。如表 II 和 IV 所总结，目前大多数可用数据集仍以光学 RGB 和 MSI 为主。尽管在 GSD 方面存在一些差异，但多数研究仍依赖于中等分辨率、公开可获取的来源，例如哨兵影像。为了支持更复杂的地理空间任务，迫切需要更高分辨率且包含更丰富上下文信息的数据集。此外，尽管近期的一些举措已开始将时间序列纳入遥感变化检测，但仍需显著进展。

此外，由于遥感数据固有的复杂性和异质性，对大规模多模态遥感数据集进行标注仍然是一个主要瓶颈。随着遥感数据规模的持续增长，稳健的数据管理实践，包括数据集成、质量保证、治理和隐私控制，将变得日

益关键。尽管取得了快速进展，我们预计遥感基础模型（RSFM）的下一阶段发展将需要不仅规模更大、多样性更高，而且在结构和语义上更加丰富的数据集。

多模态 RSFM：理想的遥感解释系统应具备同时处理多种传感器模态的能力，从而提供更丰富、更全面的地理空间数据视图。除了传感器模态外，RSFMs 还应融合其他数据类型，例如文本、用于分割的稠密标注以及用于目标检测的边界框，使其能够以更高的灵活性应对广泛的任务。

时空处理: 与自然图像不同，遥感（RS）影像在时间上通常为非规则采样，且由于传感器和平台的差异，在尺度和分辨率上也存在变化。开发具备先进时空处理能力的遥感特征模型（RSFMs）对于观测和分析地球表面的动态变化至关重要，将有助于提升短期监测和长期环境分析的能力。

高效迁移: 尽管通用领域模型在处理自然数据方面具备强大的能力，但将其适配至遥感（RS）应用既是一种成本效益高且实际可行的解决方案。适配通常涉及通过在输入中引入额外数据或提示，或选择性地更新模型参数的某些部分以与新上下文对齐，从而对基础模型进行条件化处理。为实现高效迁移，必须采用诸如 *任务特化*、*时空适配*和 *领域特定调优*等先进技术。此外，应探索 *持续学习*方法，使模型能够在不断接收新数据的同时避免 *灾难性遗忘*，从而确保在遥感任务中保持持续的性能和相关性。

可扩展性与计算效率: RSFM 的可扩展性仍然是一个关键挑战，因为处理大规模、多模态和高分辨率的遥感数据带来了较高的计算成本。与传统的视觉任务相比，遥感应用通常需要更大的内存和处理能力，尤其是在多时相和高光谱分析方面。在卫星、无人机或边缘设备上进行机载处理的场景中，这些挑战尤为突出，因为计算资源有限。尽管其重要性不言而喻，但很少有研究探索剪枝、量化或知识蒸馏等模型压缩技术，以将大型 RSFM 转化为轻量高效的变体。此类策略对于提升适应性和部署可行性至关重要。在灾害响应和环境监测等对时间敏感的地球观测应用中，RSFM 必须支持实时或近实时推理。未来的研究应优先优化 RSFM，以在性能与效率之间取得平衡，从而实现及时、可扩展且可操作的地理空间智能。

面向更广泛遥感应用的 RSFMs：遥感数据的独特性质，结合地球观测应用的多样性，使其应用范围远远超出了通用领域因子分解机（FM）通常处理的任务。开发能够支持更广泛地球观测应用（如天气预报、环境监测和城市规划）的遥感因子分解机（RSFM）是一项极具价值但极具挑战性的任务。这些 RSFM 需要处理多种输入模态，例如卫星/航空影像、GPS 信号、温度数据以及遥感导出的产品（如归一化植被指数（NDVI）[165] 图），同时输出范围可从大气预测到土地利用评估。实现这一目标不仅需要先进的人工智能方法，还需要对遥感和地球科学的深入理解，体现了这些应用复杂的跨学科特性。

地理空间任务的推理: 现有遥感基础模型（RSFMs）主要聚焦于感知类任务，如场景分类、目标检测和语义分割，仅有限地扩展到相对简单的推理功能（例如空间关系判断）。这些能力构成了众多地理空间应用的基础。然而，现实世界中的EO任务通常需要超越直接识别的高阶推理。例如，分析人员可能需要整合多时相观测数据，推断因果关系（例如将森林砍伐归因于特定政策或气候驱动因素），或关联多模态数据源以检测异常模式或变化。这些任务要求具备*空间推理*（例如理解拓扑关系）、*时间推理*（例如趋势预测或事件发展过程）以及*因果推理*（例如识别土地利用变化中的因果动态）。与通常关注结构化或文本环境中语言学或常识推理的一般基础模型（FMs）不同，地理空间推理必须在噪声大、高维度且标签稀疏的空间数据上运行。推动 RSFMs 支持此类推理能力，需要融合领域知识，引入因果和时间模型，并开发能够实现跨模态和多尺度协同数据融合的架构。此类模型不仅能够感知，还能解释、预测并推理复杂地球观测（EO）场景，从而推动下一代地理空间智能系统的发展。

RSFM 的可解释性: 随着 RSFM 在关键地球观测应用中的日益采用，提升其可解释性对于确保信任、透明度和问责性变得至关重要。大型模型的黑箱特性使得理解决策过程面临挑战，尤其是在整合超出光学 RGB 的异构传感器模态输入时。尽管可解释人工智能（XAI）在通用视觉任务中已取得进展，但其在遥感（RS）领域的应用仍有限。开发针对遥感数据特征定制的、具备模态感知能力的可解释性工具是一个有意义的方向，使用户能够将预测追溯到地理空间和物理证据。这在环境政策、灾害评估和气候监测等敏感应用中尤为重要。

RSFMs 的泛化能力：RSFMs 的一个关键要求是能够在多样化的空间、时间和传感器领域中实现泛化。然而，遥感数据通常由于季节变化、地理差异以及不同的获取条件而表现出显著的分布偏移。目前许多 RSFMs

仍然依赖于特定任务数据的微调，这限制了其泛化能力。未来的研究应探索无领域依赖的预训练目标、跨模态的鲁棒对齐策略以及能够模拟真实世界变异性的数据增强技术。提升分布外泛化能力对于在标注数据稀缺或面临未见情景的操作环境中部署 RSFMs 至关重要。

混合专家模型：混合专家模型（MoE）通过利用针对不同任务或数据模态量身定制的专用子模型（或专家），为增强遥感特征模型（RSFM）的适应性和效率提供了一种有前景的方法。鉴于遥感数据的多样性和地球观测应用的复杂性，构建一个单一统一的 RSFM 可能颇具挑战。MoE 框架通过动态选择或组合专门处理特定遥感任务的专家来解决这一问题。该方法不仅提升了任务相关的预测性能，还通过仅激活每个任务所需的专家，提高了计算效率，从而减少了不必要的处理。此外，将 MoE 集成到 RSFM 中可实现更灵活的系统，能够在无需大量重新训练的情况下扩展至多种地理空间应用。然而，设计高效的路由机制以将任务分配给合适的专家，并确保它们之间无缝协调，仍然是一个重大挑战。

IX. 结论

在本综述中，我们对遥感基础模型（RSFM）的最新进展进行了全面回顾，探讨了其背景、基本概念、数据集、技术方法、基准测试工作以及未来研究方向。本综述旨在为当前遥感基础模型的发展提供清晰且连贯的概述，作为指导该快速发展的领域未来研究的宝贵资源。我们希望这项工作不仅能帮助梳理未来的学术研究，还能促进对构建智能地球观测系统及推进遥感解译中仍存挑战的深入理解。

致谢

本工作部分得到科学技术创新理事会（CSTI）、跨部门战略创新推进计划（SIP）、面向自然灾害的弹性智能网络系统开发项目（资助机构：国立地质研究所以及日本科学促进会（JST）、FOREST，资助编号：JPMJFR206S）的支持。同时也得到了新加坡教育部通过二级计划（Tier-2 Scheme）下项目 MOE-T2EP20123-0003 的部分支持。

附录

图注

图 4：不同遥感模态的示例。
光学 RGB：源图像来自 https://maps.gsi.go.jp/development/ichiran.html
HSI：来自 https://commons.wikimedia.org/w/index.php?curid=25442380 的源图像
LiDAR：源图像来自 10.1109/MGRS.2019.2893783
TIR：源图像来自 https://www.esa.int/ESA_Multimedia/Images/2022/07/Land-surface_temperature_in_Prague_on_18_June_2022
DSM：源图像来自 https://commons.wikimedia.org/w/index.php?curid=24447099
SAR：源图像来自 https://commons.wikimedia.org/w/index.php?curid=117320

Acronyms

CV Computer Vision 4, 7

DSM Digital Surface Models 4, 8, 9

EO Earth Observation 1, 2, 6, 12–15, 18

FMs Foundation Models 1, 15

GSD Ground Sample Distances 6, 13, 14, 17

HSI HyperSpectral Images 3, 6, 9, 10, 12

LiDAR Light Detection and Ranging 4, 6, 10
LLMs Large Language Models 1, 4, 10, 14
LULC Land Use and Land Cover 5, 9, 16

MIM Masked Image Modeling 7
MSI MultiSpectral Images 3, 6, 7, 9, 12

NIR Near-Infrared 3, 8, 13

PEFT Parameter-Efficient Tuning 3, 9, 12, 15

RS Remote Sensing 1, 4
RSFMs Remote Sensing Foundation Models 1, 4, 6, 14

SAM Segment Anything Model 6, 8
SAR Synthetic Aperture Radar 3, 6, 8, 9, 12, 13
SSL Self-Supervised Learning 4, 6

VFMs Visual Foundation Models 1, 6, 10, 14
VLMs Vision-Language Models 1, 4, 10, 14
VQA Visual Question Answering 5, 16

参考文献

[1] R. Bommasani, D. A. Hudson, E. Adeli, R. Altman, S. Arora, S. von Arx, M. S. Bernstein, J. Bohg, A. Bosselut, E. Brunskill *et al.*, "On the opportunities and risks of foundation models," *arXiv preprint arXiv:2108.07258*, 2021.

[2] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "Imagenet: A large-scale hierarchical image database," in *2009 IEEE conference on computer vision and pattern recognition*. Ieee, 2009, pp. 248–255.

[3] L. Jing and Y. Tian, "Self-supervised visual feature learning with deep neural networks: A survey," *IEEE transactions on pattern analysis and machine intelligence*, vol. 43, no. 11, pp. 4037–4058, 2020.

[4] A. Xiao, J. Huang, D. Guan, X. Zhang, S. Lu, and L. Shao, "Unsupervised point cloud representation learning with deep neural networks: A survey," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 9, pp. 11 321–11 339, 2023.

[5] Y. Wang, C. M. Albrecht, N. A. A. Braham, L. Mou, and X. X. Zhu, "Self-supervised learning in remote sensing: A review," *IEEE Geoscience and Remote Sensing Magazine*, vol. 10, no. 4, pp. 213–247, 2022.

[6] L. Jiao, Z. Huang, X. Lu, X. Liu, Y. Yang, J. Zhao, J. Zhang, B. Hou, S. Yang, F. Liu *et al.*, "Brain-inspired remote sensing foundation models and open problems: A comprehensive survey," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2023.

[7] X. X. Zhu, Z. Xiong, Y. Wang, A. J. Stewart, K. Heidler, Y. Wang, Z. Yuan, T. Dujardin, Q. Xu, and Y. Shi, "On the foundations of earth and climate foundation models," *arXiv preprint arXiv:2405.04285*, 2024.

[8] X. Li, C. Wen, Y. Hu, Z. Yuan, and X. X. Zhu, "Vision-language models in remote sensing: Current progress and future trends," *IEEE Geoscience and Remote Sensing Magazine*, 2024.

[9] A. Hadid, T. Chakraborty, and D. Busby, "When geoscience meets generative ai and large language models: Foundations, trends, and future challenges," *Expert Systems*, vol. 41, no. 10, p. e13654, 2024.

[10] H. Zhang, J.-J. Xu, H.-W. Cui, L. Li, Y. Yang, C.-S. Tang, and N. Boers, "When geoscience meets foundation models: Toward a general geoscience artificial intelligence system," *IEEE Geoscience and Remote Sensing Magazine*, 2024.

[11] J. Zhang, J. Huang, S. Jin, and S. Lu, "Vision-language models for vision tasks: A survey," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024.

[12] Y. Zhou, L. Feng, Y. Ke, X. Jiang, J. Yan, X. Yang, and W. Zhang, "Towards vision-language geo-foundation model: A survey," *arXiv preprint arXiv:2406.09385*, 2024.

[13] G. Christie, N. Fendley, J. Wilson, and R. Mukherjee, "Functional map of the world," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018, pp. 6172–6180.

[14] G. Sumbul, M. Charfuelan, B. Demir, and V. Markl, "Bigearthnet: A large-scale benchmark archive for remote sensing image understanding," in *IGARSS 2019-2019 IEEE International Geoscience and Remote Sensing Symposium*. IEEE, 2019, pp. 5901–5904.

[15] O. Manas, A. Lacoste, X. Giró-i Nieto, D. Vazquez, and P. Rodriguez, "Seasonal contrast: Unsupervised pre-training from uncurated remote sensing data," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2021, pp. 9414–9423.

[16] Y. Cong, S. Khanna, C. Meng, P. Liu, E. Rozi, Y. He, M. Burke, D. Lobell, and S. Ermon, "Satmae: Pre-training transformers for temporal and multi-spectral satellite imagery," *Advances in Neural Information Processing Systems*, vol. 35, pp. 197–211, 2022.

[17] D. Wang, J. Zhang, B. Du, G.-S. Xia, and D. Tao, "An empirical study of remote sensing pretraining," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 61, pp. 1–20, 2022.

[18] M. Mendieta, B. Han, X. Shi, Y. Zhu, and C. Chen, "Towards geospatial foundation models via continual pretraining," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023, pp. 16 806–16 816.

[19] Y. Wang, N. A. A. Braham, Z. Xiong, C. Liu, C. M. Albrecht, and X. X. Zhu, "Ssl4eo-s12: A large-scale multimodal, multitemporal dataset for self-supervised learning in earth observation [software and data sets]," *IEEE Geoscience and Remote Sensing Magazine*, vol. 11, no. 3, pp. 98–106, 2023.

[20] F. Bastani, P. Wolters, R. Gupta, J. Ferdinando, and A. Kembhavi, "Satlaspretrain: A large-scale dataset for remote sensing image understanding," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023, pp. 16 772–16 782.

[21] V. Nedungadi, A. Kariryaa, S. Oehmcke, S. Belongie, C. Igel, and N. Lang, "Mmearth: Exploring multi-modal pretext tasks for geospatial representation learning," *arXiv preprint arXiv:2405.02771*, 2024.

[22] D. Wang, M. Hu, Y. Jin, Y. Miao, J. Yang, Y. Xu, X. Qin, J. Ma, L. Sun, C. Li *et al.*, "Hypersigma: Hyperspectral intelligence comprehension foundation model," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2025.

[23] J. Li, Y. Liu, X. Wang, Y. Peng, C. Sun, S. Wang, Z. Sun, T. Ke, X. Jiang, T. Lu *et al.*, "Hyperfree: A channel-adaptive and tuning-free foundation model for hyperspectral remote sensing imagery," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[24] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.

[25] A. Vaswani, "Attention is all you need," *Advances in Neural Information Processing Systems*, 2017.

[26] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," *arXiv preprint arXiv:2010.11929*, 2020.

[27] K. Ayush, B. Uzkent, C. Meng, K. Tanmay, M. Burke, D. Lobell, and S. Ermon, "Geography-aware self-supervised learning," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2021, pp. 10 181–10 190.

[28] P. Akiva, M. Purri, and M. Leotta, "Self-supervised material and texture representation learning for remote sensing tasks," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022, pp. 8203–8215.

[29] U. Mall, B. Hariharan, and K. Bala, "Change-aware sampling and contrastive learning for satellite images," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 5261–5270.

[30] G. Mai, N. Lao, Y. He, J. Song, and S. Ermon, "Csp: Self-supervised contrastive spatial pre-training for geospatial-visual representations," in *International Conference on Machine Learning*. PMLR, 2023, pp. 23 498–23 515.

[31] X. Guo, J. Lao, B. Dang, Y. Zhang, L. Yu, L. Ru, L. Zhong, Z. Huang, K. Wu, D. Hu *et al.*, "Skysense: A multi-modal remote sensing foundation model towards universal interpretation for earth observation imagery," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 27 672–27 683.

[32] A. V. Huynh, L. E. Gillespie, J. Lopez-Saucedo, C. Tang, R. Sikand, and M. Expósito-Alonso, "Contrastive ground-level image and remote sensing pre-training improves representation learning for natural world imagery," *arXiv preprint arXiv:2409.19439*, 2024.

[33] C. J. Reed, R. Gupta, S. Li, S. Brockman, C. Funk, B. Clipp, K. Keutzer, S. Candido, M. Uyttendaele, and T. Darrell, "Scale-mae: A scale-aware masked autoencoder for multiscale geospatial representation learning," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023, pp. 4088–4099.

[34] B. Han, S. Zhang, X. Shi, and M. Reichstein, "Bridging remote sensors with multisensor geospatial foundation models," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 27 852–27 862.

[35] M. Noman, M. Naseer, H. Cholakkal, R. M. Anwer, S. Khan, and F. S. Khan, "Rethinking transformers pre-training for multi-spectral satellite imagery," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 27 811–27 819.

[36] Z. Li, B. Hou, S. Ma, Z. Wu, X. Guo, B. Ren, and L. Jiao, "Masked angle-aware autoencoder for remote sensing images," *arXiv preprint arXiv:2408.01946*, 2024.

[37] G. Astruc, N. Gonthier, C. Mallet, and L. Landrieu, "Omnisat: Self-supervised modality fusion for earth observation," *arXiv preprint arXiv:2404.08351*, 2024.

[38] A. Fuller, K. Millard, and J. Green, "Croma: Remote sensing representations with contrastive radar-optical masked autoencoders," *Advances in Neural Information Processing Systems*, vol. 36, 2024.

[39] M. Tang, A. Cozma, K. Georgiou, and H. Qi, "Cross-scale mae: A tale of multiscale exploitation in remote sensing," in *Advances in Neural Information Processing Systems*, A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine, Eds., vol. 36. Curran Associates, Inc., 2023, pp. 20 054–20 066.

[40] A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A. C. Berg, W.-Y. Lo *et al.*, "Segment anything," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023, pp. 4015–4026.

[41] D. Wang, J. Zhang, M. Xu, L. Liu, D. Wang, E. Gao, C. Han, H. Guo, B. Du, D. Tao *et al.*, "Mtp: Advancing remote sensing foundation model via multi-task pretraining," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2024.

[42] K. He, H. Fan, Y. Wu, S. Xie, and R. Girshick, "Momentum contrast for unsupervised visual representation learning," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020, pp. 9729–9738.

[43] K. He, X. Chen, S. Xie, Y. Li, P. Dollár, and R. Girshick, "Masked autoencoders are scalable vision learners," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 16 000–16 009.

[44] A. v. d. Oord, Y. Li, and O. Vinyals, "Representation learning with contrastive predictive coding," *arXiv preprint arXiv:1807.03748*, 2018.

[45] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, "A simple framework for contrastive learning of visual representations," in *International conference on machine learning*. PMLR, 2020, pp. 1597–1607.

[46] X. Chen, H. Fan, R. Girshick, and K. He, "Improved baselines with momentum contrastive learning," *arXiv preprint arXiv:2003.04297*, 2020.

[47] J.-B. Grill, F. Strub, F. Altché, C. Tallec, P. Richemond, E. Buchatskaya, C. Doersch, B. Avila Pires, Z. Guo, M. Gheshlaghi Azar *et al.*, "Bootstrap your own latent-a new approach to self-supervised learning," *Advances in neural information processing systems*, vol. 33, pp. 21 271–21 284, 2020.

[48] M. Caron, I. Misra, J. Mairal, P. Goyal, P. Bojanowski, and A. Joulin, "Unsupervised learning of visual features by contrasting cluster assignments," *Advances in neural information processing systems*, vol. 33, pp. 9912–9924, 2020.

[49] N. Jean, S. Wang, A. Samar, G. Azzari, D. Lobell, and S. Ermon, "Tile2vec: Unsupervised representation learning for spatially distributed data," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 33, no. 01, 2019, pp. 3967–3974.

[50] Z. Huang, M. Zhang, Y. Gong, Q. Liu, and Y. Wang, "Generic knowledge boosted pre-training for remote sensing images," *IEEE Transactions on Geoscience and Remote Sensing*, 2024.

[51] W. Li, K. Chen, H. Chen, and Z. Shi, "Geographical knowledge-driven representation learning for remote sensing images," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, pp. 1–16, 2021.

[52] H. Li, Y. Li, G. Zhang, R. Liu, H. Huang, Q. Zhu, and C. Tao, "Global and local contrastive self-supervised learning for semantic segmentation of hr remote sensing images," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, pp. 1–14, 2022.

[53] Z. Dong, Y. Gu, and T. Liu, "Generative convnet foundation model with sparse modeling and low-frequency reconstruction for remote sensing image interpretation," *IEEE Transactions on Geoscience and Remote Sensing*, 2024.

[54] X. Sun, P. Wang, W. Lu, Z. Zhu, X. Lu, Q. He, J. Li, X. Rong, Z. Yang, H. Chang *et al.*, "Ringmo: A remote sensing foundation model with masked image modeling," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 61, pp. 1–22, 2022.

[55] D. Wang, Q. Zhang, Y. Xu, J. Zhang, B. Du, D. Tao, and L. Zhang, "Advancing plain vision transformer toward remote sensing foundation model," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 61, pp. 1–15, 2022.

[56] D. Hong, B. Zhang, X. Li, Y. Li, C. Li, J. Yao, N. Yokoya, H. Li, P. Ghamisi, X. Jia *et al.*, "Spectralgpt: Spectral remote sensing foundation model," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024.

[57] Z. Xiong, Y. Wang, F. Zhang, A. J. Stewart, J. Hanna, D. Borth, I. Papoutsis, B. L. Saux, G. Camps-Valls, and X. X. Zhu, "Neural plasticity-inspired foundation model for observing the earth crossing modalities," *arXiv preprint arXiv:2403.15356*, 2024.

[58] F. Wang, H. Wang, D. Wang, Z. Guo, Z. Zhong, L. Lan, J. Zhang, Z. Liu, and M. Sun, "Scaling efficient masked autoencoder learning on large remote sensing dataset," *arXiv preprint arXiv:2406.11933*, 2024.

[59] D. Muhtar, X. Zhang, P. Xiao, Z. Li, and F. Gu, "Cmid: A unified self-supervised learning framework for remote sensing image understanding," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 61, pp. 1–17, 2023.

[60] D. Wang, J. Zhang, B. Du, M. Xu, L. Liu, D. Tao, and L. Zhang, "Samrs: Scaling-up remote sensing segmentation dataset with segment anything model," in *Advances in Neural Information Processing Systems*, A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine, Eds., vol. 36. Curran Associates, Inc., 2023, pp. 8815–8827.

[61] X. Ma, Q. Wu, X. Zhao, X. Zhang, M.-O. Pun, and B. Huang, "Sam-assisted remote sensing imagery semantic segmentation with object and boundary constraints," *IEEE Transactions on Geoscience and Remote Sensing*, 2024.

[62] X. Zhang, Y. Liu, Y. Lin, Q. Liao, and Y. Li, "Uv-sam: Adapting segment anything model for urban village identification," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, no. 20, 2024, pp. 22 520–22 528.

[63] L. Wang, M. Zhang, and W. Shi, "Cs-wscdnet: Class activation mapping and segment anything model-based framework for weakly supervised change detection," *IEEE Transactions on Geoscience and Remote Sensing*, 2023.

[64] L. Ding, K. Zhu, D. Peng, H. Tang, K. Yang, and L. Bruzzone, "Adapting segment anything model for change detection in vhr remote sensing images," *IEEE Transactions on Geoscience and Remote Sensing*, 2024.

[65] Z. Zheng, Y. Zhong, L. Zhang, and S. Ermon, "Segment any change," *arXiv preprint arXiv:2402.01188*, 2024.

[66] K. Chen, C. Liu, H. Chen, H. Zhang, W. Li, Z. Zou, and Z. Shi, "Rsprompter: Learning to prompt for remote sensing instance segmentation based on visual foundation model," *IEEE Transactions on Geoscience and Remote Sensing*, 2024.

[67] Z. Yan, J. Li, X. Li, R. Zhou, W. Zhang, Y. Feng, W. Diao, K. Fu, and X. Sun, "Ringmo-sam: A foundation model for segment anything in multimodal remote-sensing images," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 61, pp. 1–16, 2023.

[68] L. P. Osco, Q. Wu, E. L. de Lemos, W. N. Gonçalves, A. P. M. Ramos, J. Li, and J. M. Junior, "The segment anything model (sam) for remote sensing applications: From zero to one shot," *International Journal of Applied Earth Observation and Geoinformation*, vol. 124, p. 103540, 2023.

[69] S. Liu, Z. Zeng, T. Ren, F. Li, H. Zhang, J. Yang, C. Li, J. Yang, H. Su, J. Zhu *et al.*, "Grounding dino: Marrying dino with grounded pre-training for open-set object detection," *arXiv preprint arXiv:2303.05499*, 2023.

[70] A. Xiao, W. Xuan, H. Qi, Y. Xing, R. Ren, X. Zhang, and S. Lu, "Cat-sam: Conditional tuning for few-shot adaptation of segmentation anything model," in *European Conference on Computer Vision (ECCV)*, 2024.

[71] L. Yang, B. Kang, Z. Huang, X. Xu, J. Feng, and H. Zhao, "Depth anything: Unleashing the power of large-scale unlabeled data," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 10 371–10 381.

[72] D. R. Cambrin, I. Corley, and P. Garza, "Depth any canopy: Leveraging depth foundation models for canopy height estimation," *arXiv preprint arXiv:2408.04523*, 2024.

[73] J. Chen, B. Liu, A. Yu, Y. Quan, T. Li, and W. Guo, "Depth feature fusion network for building extraction in remote sensing images," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2024.

[74] J. Jakubik, F. Yang, B. Blumenstiel, E. Scheurer, R. Sedona, S. Maurogiovanni, J. Bosmans, N. Dionelis, V. Marsocci, N. Kopp *et al.*, "Terramind: Large-scale generative multimodality for earth observation," *arXiv preprint arXiv:2504.11171*, 2025.

[75] A. Xiao, W. Xuan, H. Qi, Y. Xing, N. Yokoya, and S. Lu, "Segment anything with multiple modalities," *arXiv preprint arXiv:2408.09085*, 2024.

[76] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark *et al.*, "Learning transferable visual models from natural language supervision," in *International conference on machine learning*. PMLR, 2021, pp. 8748–8763.

[77] G. Ilharco, M. Wortsman, R. Wightman, C. Gordon, N. Carlini, R. Taori, A. Dave, V. Shankar, H. Namkoong, J. Miller, H. Hajishirzi, A. Farhadi, and L. Schmidt, "Openclip," Jul. 2021, if you use this software, please cite it as below. [Online]. Available: https://doi.org/10.5281/zenodo.5143773

[78] Q. Sun, Y. Fang, L. Wu, X. Wang, and Y. Cao, "Eva-clip: Improved training techniques for clip at scale," *arXiv preprint arXiv:2303.15389*, 2023.

[79] B. Li, K. Q. Weinberger, S. Belongie, V. Koltun, and R. Ranftl, "Language-driven semantic segmentation," *arXiv preprint arXiv:2201.03546*, 2022.

[80] Z. Zhou, Y. Lei, B. Zhang, L. Liu, and Y. Liu, "Zegclip: Towards adapting clip for zero-shot semantic segmentation," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 11 175–11 185.

[81] H. Zhang, H. Li, F. Li, T. Ren, X. Zou, S. Liu, S. Huang, J. Gao, L. Zhang, C. Li *et al.*, "Llava-grounding: Grounded visual chat with large multimodal models," *arXiv preprint arXiv:2312.02949*, 2023.

[82] J. Bai, S. Bai, S. Yang, S. Wang, S. Tan, P. Wang, J. Lin, C. Zhou, and J. Zhou, "Qwen-vl: A versatile vision-language model for understanding, localization, text reading, and beyond," 2023.

[83] Q. team, "Qwen2-vl," 2024.

[84] J. Wang, Z. Yang, X. Hu, L. Li, K. Lin, Z. Gan, Z. Liu, C. Liu, and L. Wang, "Git: A generative image-to-text transformer for vision and language," *arXiv preprint arXiv:2205.14100*, 2022.

[85] J. Li, D. Li, C. Xiong, and S. Hoi, "Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation," in *International conference on machine learning*. PMLR, 2022, pp. 12 888–12 900.

[86] J. Li, D. Li, S. Savarese, and S. Hoi, "Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models," in *International conference on machine learning*. PMLR, 2023, pp. 19 730–19 742.

[87] W. Zhang, M. Cai, T. Zhang, Y. Zhuang, and X. Mao, "Earthgpt: A universal multi-modal large language model for multi-sensor image comprehension in remote sensing domain," *IEEE Transactions on Geoscience and Remote Sensing*, 2024.

[88] S. Lobry, D. Marcos, J. Murray, and D. Tuia, "Rsvqa: Visual question answering for remote sensing data," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 58, no. 12, pp. 8555–8566, 2020.

[89] S. Lobry, B. Demir, and D. Tuia, "Rsvqa meets bigearthnet: a new, large-scale, visual question answering dataset for remote sensing," in *2021 IEEE International Geoscience and Remote Sensing Symposium IGARSS*. IEEE, 2021, pp. 1218–1221.

[90] X. Zheng, B. Wang, X. Du, and X. Lu, "Mutual attention inception network for remote sensing visual question answering," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, pp. 1–14, 2021.

[91] K. Li, G. Vosselman, and M. Y. Yang, "Hrvqa: A visual question answering benchmark for high-resolution aerial images," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 214, pp. 65–81, 2024.

[92] Z. Yuan, L. Mou, Z. Xiong, and X. X. Zhu, "Change detection meets visual question answering," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, pp. 1–13, 2022.

[93] M. Rahnemoonfar, T. Chowdhury, A. Sarkar, D. Varshney, M. Yari, and R. R. Murphy, "Floodnet: A high resolution aerial imagery dataset for post flood scene understanding," *IEEE Access*, vol. 9, pp. 89 644–89 654, 2021.

[94] A. Sarkar and M. Rahnemoonfar, "Rescuenet-vqa: A large-scale visual question answering benchmark for damage assessment," in *IGARSS 2023-2023 IEEE International Geoscience and Remote Sensing Symposium*. IEEE, 2023, pp. 1150–1153.

[95] J. Wang, Z. Zheng, Z. Chen, A. Ma, and Y. Zhong, "Earthvqa: Towards queryable earth via relational reasoning-based remote sensing visual question answering," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, no. 6, 2024, pp. 5481–5489.

[96] F. Liu, D. Chen, Z. Guan, X. Zhou, J. Zhu, Q. Ye, L. Fu, and J. Zhou, "Remoteclip: A vision language foundation model for remote sensing," *IEEE Transactions on Geoscience and Remote Sensing*, 2024.

[97] Z. Zhang, T. Zhao, Y. Guo, and J. Yin, "Rs5m: A large scale vision-language dataset for remote sensing vision-language foundation model," 2023.

[98] Z. Wang, R. Prabha, T. Huang, J. Wu, and R. Rajagopal, "Skyscript: A large and semantically diverse vision-language dataset for remote sensing," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, no. 6, 2024, pp. 5805–5813.

[99] X. Lu, B. Wang, X. Zheng, and X. Li, "Exploring models and data for remote sensing image caption generation," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 56, no. 4, pp. 2183–2195, 2017.

[100] B. Qu, X. Li, D. Tao, and X. Lu, "Deep semantic understanding of high resolution remote sensing image," in *2016 International conference on computer, information and telecommunication systems (Cits)*. IEEE, 2016, pp. 1–5.

[101] Q. Cheng, H. Huang, Y. Xu, Y. Zhou, H. Li, and Z. Wang, "Nwpu-captions dataset and mlca-net for remote sensing image captioning," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, pp. 1–19, 2022.

[102] Z. Yuan, W. Zhang, K. Fu, X. Li, C. Deng, H. Wang, and X. Sun, "Exploring a fine-grained multiscale method for cross-modal remote sensing image retrieval," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, pp. 1–19, 2021.

[103] Y. Hu, J. Yuan, C. Wen, X. Lu, and X. Li, "Rsgpt: A remote sensing vision language model and benchmark," *arXiv preprint arXiv:2307.15266*, 2023.

[104] Y. Zhan, Z. Xiong, and Y. Yuan, "Rsvg: Exploring data and models for visual grounding on remote sensing data," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 61, pp. 1–13, 2023.

[105] Y. Sun, S. Feng, X. Li, Y. Ye, J. Kang, and X. Huang, "Visual grounding in remote sensing images," in *Proceedings of the 30th ACM International Conference on Multimedia*, 2022, pp. 404–412.

[106] D. Muhtar, Z. Li, F. Gu, X. Zhang, and P. Xiao, "Lhrs-bot: Empowering remote sensing with vgi-enhanced large multimodal language model," *arXiv preprint arXiv:2402.02544*, 2024.

[107] J. A. Irvin, E. R. Liu, J. C. Chen, I. Dormoy, J. Kim, S. Khanna, Z. Zheng, and S. Ermon, "Teochat: A large vision-language assistant for temporal earth observation data," *arXiv preprint arXiv:2410.06234*, 2024.

[108] Y. Wei, A. Xiao, Y. Ren, Y. Zhu, H. Chen, J. Xia, and N. Yokoya, "Sarlang-1m: A benchmark for vision-language modeling in sar image understanding," *arXiv preprint arXiv:2504.03254*, 2025.

[109] Y. Zhong, J. Yang, P. Zhang, C. Li, N. Codella, L. H. Li, L. Zhou, X. Dai, L. Yuan, Y. Li *et al.*, "Regionclip: Region-based language-image pretraining," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 16 793–16 803.

[110] F. Liang, B. Wu, X. Dai, K. Li, Y. Zhao, H. Zhang, P. Zhang, P. Vajda, and D. Marculescu, "Open-vocabulary semantic segmentation with mask-adapted clip," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 7061–7070.

[111] T. Cheng, L. Song, Y. Ge, W. Liu, X. Wang, and Y. Shan, "Yolo-world: Real-time open-vocabulary object detection," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 16 901–16 911.

[112] A. Singh, R. Hu, V. Goswami, G. Couairon, W. Galuba, M. Rohrbach, and D. Kiela, "Flava: A foundational language and vision alignment model," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022, pp. 15 638–15 650.

[113] G. Kwon, Z. Cai, A. Ravichandran, E. Bas, R. Bhotika, and S. Soatto, "Masked vision and language modeling for multi-modal representation learning," in *The Eleventh International Conference on Learning Representations*.

[114] H. Liu, C. Li, Q. Wu, and Y. J. Lee, "Visual instruction tuning," in *NeurIPS*, 2023.

[115] H. Touvron, L. Martin, K. Stone, P. Albert, A. Almahairi, Y. Babaei, N. Bashlykov, S. Batra, P. Bhargava, S. Bhosale *et al.*, "Llama 2: Open foundation and fine-tuned chat models," *arXiv preprint arXiv:2307.09288*, 2023.

[116] W.-L. Chiang, Z. Li, Z. Lin, Y. Sheng, Z. Wu, H. Zhang, L. Zheng, S. Zhuang, Y. Zhuang, J. E. Gonzalez *et al.*, "Vicuna: An open-source chatbot impressing gpt-4 with 90%* chatgpt quality," *See https://vicuna. lmsys. org (accessed 14 April 2023)*, vol. 2, no. 3, p. 6, 2023.

[117] A. Dubey, A. Jauhri, A. Pandey, A. Kadian, A. Al-Dahle, A. Letman, A. Mathur, A. Schelten, A. Yang, A. Fan *et al.*, "The llama 3 herd of models," *arXiv preprint arXiv:2407.21783*, 2024.

[118] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer, "Sigmoid loss for language image pre-training," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023, pp. 11 975–11 986.

[119] H. Liu, C. Li, Y. Li, B. Li, Y. Zhang, S. Shen, and Y. J. Lee, "Llava-next: Improved reasoning, ocr, and world knowledge," January 2024. [Online]. Available: https://llava-vl.github.io/blog/2024-01-30-llava-next/

[120] W. Dai, J. Li, D. Li, A. M. H. Tiong, J. Zhao, W. Wang, B. Li, P. Fung, and S. Hoi, "Instructblip: Towards general-purpose vision-language models with instruction tuning," 2023.

[121] Y. Chu, J. Xu, X. Zhou, Q. Yang, S. Zhang, Z. Yan, C. Zhou, and J. Zhou, "Qwen-audio: Advancing universal audio understanding via unified large-scale audio-language models," *arXiv preprint arXiv:2311.07919*, 2023.

[122] A. Panagopoulou, L. Xue, N. Yu, J. Li, D. Li, S. Joty, R. Xu, S. Savarese, C. Xiong, and J. C. Niebles, "X-instructblip: A framework for aligning x-modal instruction-aware representations to llms and emergent cross-modal reasoning," *arXiv preprint arXiv:2311.18799*, 2023.

[123] R. Xu, X. Wang, T. Wang, Y. Chen, J. Pang, and D. Lin, "Pointllm: Empowering large language models to understand point clouds," *arXiv preprint arXiv:2308.16911*, 2023.

[124] U. Mall, C. P. Phoo, M. K. Liu, C. Vondrick, B. Hariharan, and K. Bala, "Remote sensing vision-language foundation models without annotations via ground remote alignment," in *The Twelfth International Conference on Learning Representations*, 2024.

[125] G. Cheng, J. Han, and X. Lu, "Remote sensing image scene classification: Benchmark and state of the art," *Proceedings of the IEEE*, vol. 105, no. 10, pp. 1865–1883, 2017.

[126] Y. Yang and S. Newsam, "Bag-of-visual-words and spatial extensions for land-use classification," in *Proceedings of the 18th SIGSPATIAL international conference on advances in geographic information systems*, 2010, pp. 270–279.

[127] G. Van Horn, O. Mac Aodha, Y. Song, Y. Cui, C. Sun, A. Shepard, H. Adam, P. Perona, and S. Belongie, "The inaturalist species classification and detection dataset," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 8769–8778.

[128] V. Vivanco Cepeda, G. K. Nayak, and M. Shah, "Geoclip: Clip-inspired alignment between locations and images for effective worldwide geo-localization," *Advances in Neural Information Processing Systems*, vol. 36, 2024.

[129] K. Klemmer, E. Rolf, C. Robinson, L. Mackey, and M. Rußwurm, "Satclip: Global, general-purpose location embeddings with satellite imagery," *arXiv preprint arXiv:2311.17179*, 2023.

[130] J. Bourcier, G. Dashyan, K. Alahari, and J. Chanussot, "Learning representations of satellite images from metadata supervision," in *European Conference on Computer Vision (ECCV) 2024*, 2024.

[131] K. Kuckreja, M. S. Danish, M. Naseer, A. Das, S. Khan, and F. S. Khan, "Geochat: Grounded large vision-language model for remote sensing," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 27 831–27 840.

[132] G.-S. Xia, X. Bai, J. Ding, Z. Zhu, S. Belongie, J. Luo, M. Datcu, M. Pelillo, and L. Zhang, "Dota: A large-scale dataset for object detection in aerial images," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 3974–3983.

[133] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models," in *International Conference on Learning Representations*, 2022. [Online]. Available: https://openreview.net/forum?id=nZeVKeeFYf9

[134] J. Luo, Z. Pang, Y. Zhang, T. Wang, L. Wang, B. Dang, J. Lao, J. Wang, J. Chen, Y. Tan *et al.*, "Skysensegpt: A fine-grained instruction tuning dataset and model for remote sensing vision-language understanding," *arXiv preprint arXiv:2406.10100*, 2024.

[135] B. Zhou, H. Yang, D. Chen, J. Ye, T. Bai, J. Yu, S. Zhang, D. Lin, C. He, and W. Li, "Urbench: A comprehensive benchmark for evaluating large multimodal models in multi-view urban scenarios," *arXiv preprint arXiv:2408.17267*, 2024.

[136] S. Soni, A. Dudhane, H. Debary, M. Fiaz, M. A. Munir, M. S. Danish, P. Fraccaro, C. D. Watson, L. J. Klein, F. S. Khan *et al.*, "Earthdial: Turning multi-sensory earth observations to interactive dialogues," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2025.

[137] F. Wang, H. Wang, M. Chen, D. Wang, Y. Wang, Z. Guo, Q. Ma, L. Lan, W. Yang, J. Zhang *et al.*, "Xlrs-bench: Could your multimodal llms understand extremely large ultra-high-resolution remote sensing imagery?" in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2025.

[138] A. Radford, "Improving language understanding by generative pre-training," 2018.

[139] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, I. Sutskever *et al.*, "Language models are unsupervised multitask learners," *OpenAI blog*, vol. 1, no. 8, p. 9, 2019.

[140] T. B. Brown, "Language models are few-shot learners," *arXiv preprint arXiv:2005.14165*, 2020.

[141] J. Achiam, S. Adler, S. Agarwal, L. Ahmad, I. Akkaya, F. L. Aleman, D. Almeida, J. Altenschmidt, S. Altman, S. Anadkat *et al.*, "Gpt-4 technical report," *arXiv preprint arXiv:2303.08774*, 2023.

[142] R. Manvi, S. Khanna, G. Mai, M. Burke, D. B. Lobell, and S. Ermon, "Geollm: Extracting geospatial knowledge from large language models," in *The Twelfth International Conference on Learning Representations*, 2024.

[143] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli, "Deep unsupervised learning using nonequilibrium thermodynamics," in *International conference on machine learning*. PMLR, 2015, pp. 2256–2265.

[144] J. Song, C. Meng, and S. Ermon, "Denoising diffusion implicit models," in *International Conference on Learning Representations*, 2021.

[145] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," *Advances in neural information processing systems*, vol. 33, pp. 6840–6851, 2020.

[146] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-resolution image synthesis with latent diffusion models," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 10 684–10 695.

[147] S. Khanna, P. Liu, L. Zhou, C. Meng, R. Rombach, M. Burke, D. B. Lobell, and S. Ermon, "Diffusionsat: A generative foundation model for satellite imagery," in *The Twelfth International Conference on Learning Representations*, 2023.

[148] Z. Zheng, S. Ermon, D. Kim, L. Zhang, and Y. Zhong, "Changen2: Multi-temporal remote sensing generative change foundation model," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024.

[149] B. Blumenstiel, P. Fraccaro, V. Marsocci, J. Jakubik, S. Maurogiovanni, M. Czerkawski, R. Sedona, G. Cavallaro, T. Brunschwiler, J. Bernabe-Moreno *et al.*, "Terramesh: A planetary mosaic of multimodal earth observation data," *arXiv preprint arXiv:2504.11172*, 2025.

[150] A. Xiao, J. Huang, D. Guan, F. Zhan, and S. Lu, "Transfer learning from synthetic to real lidar point cloud for semantic segmentation," in *Proceedings of the AAAI conference on artificial intelligence*, vol. 36, no. 3, 2022, pp. 2795–2803.

[151] J. Song, H. Chen, W. Xuan, J. Xia, and N. Yokoya, "Synrs3d: A synthetic dataset for global 3d semantic understanding from monocular remote sensing imagery," in *The Thirty-eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track*.

[152] L. Wang, R. Li, C. Zhang, S. Fang, C. Duan, X. Meng, and P. M. Atkinson, "Unetformer: A unet-like transformer for efficient semantic segmentation of remote sensing urban scene imagery," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 190, pp. 196–214, 2022.

[153] Y. Li, X. Li, Y. Dai, Q. Hou, L. Liu, Y. Liu, M.-M. Cheng, and J. Yang, "Lsknet: A foundation lightweight backbone for remote sensing," *International Journal of Computer Vision*, pp. 1–22, 2024.

[154] T. Shinde, "Model compression meets resolution scaling for efficient remote sensing classification," in *Proceedings of the Winter Conference on Applications of Computer Vision*, 2025, pp. 1200–1209.

[155] K. Bi, L. Xie, H. Zhang, X. Chen, X. Gu, and Q. Tian, "Accurate medium-range global weather forecasting with 3d neural networks," *Nature*, vol. 619, no. 7970, pp. 533–538, 2023.

[156] P. Ghamisi, W. Yu, A. Marinoni, C. M. Gevaert, C. Persello, S. Selvakumaran, M. Girotto, B. P. Horton, P. Rufin, P. Hostert *et al.*, "Responsible artificial intelligence for earth observation: Achievable and realistic paths to serve the collective good," *IEEE Geoscience and Remote Sensing Magazine*, 2025.

[157] A. Lacoste, N. Lehmann, P. Rodriguez, E. Sherwin, H. Kerner, B. Lütjens, J. Irvin, D. Dao, H. Alemohammad, A. Drouin *et al.*, "Geo-bench: Toward foundation models for earth monitoring," *Advances in Neural Information Processing Systems*, vol. 36, 2023.

[158] P. Helber, B. Bischke, A. Dengel, and D. Borth, "Eurosat: A novel dataset and deep learning benchmark for land use and land cover classification," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 12, no. 7, pp. 2217–2226, 2019.

[159] R. C. Daudt, B. Le Saux, A. Boulch, and Y. Gousseau, "Urban change detection for multispectral earth observation using convolutional neural networks," in *IGARSS 2018-2018 IEEE International Geoscience and Remote Sensing Symposium*. Ieee, 2018, pp. 2115–2118.

[160] A. Van Etten, D. Lindenbaum, and T. M. Bacastow, "Spacenet: A remote sensing dataset and challenge series," *arXiv preprint arXiv:1807.01232*, 2018.

[161] K. Li, G. Wan, G. Cheng, L. Meng, and J. Han, "Object detection in optical remote sensing images: A survey and a new benchmark," *ISPRS journal of photogrammetry and remote sensing*, vol. 159, pp. 296–307, 2020.

[162] G. Cheng, J. Wang, K. Li, X. Xie, C. Lang, Y. Yao, and J. Han, "Anchor-free oriented proposal generator for object detection," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, pp. 1–11, 2022.

[163] A. Lacoste, N. Lehmann, P. Rodriguez, E. Sherwin, H. Kerner, B. Lütjens, J. Irvin, D. Dao, H. Alemohammad, A. Drouin *et al.*, "Geo-bench: Toward foundation models for earth monitoring," *Advances in Neural Information Processing Systems*, vol. 36, 2023.

[164] M. S. Danish, M. A. Munir, S. R. A. Shah, K. Kuckreja, F. S. Khan, P. Fraccaro, A. Lacoste, and S. Khan, "Geobench-vlm: Benchmarking vision-language models for geospatial tasks," *arXiv preprint arXiv:2411.19325*, 2024.

[165] J. W. Rouse, R. H. Haas, J. A. Schell, D. W. Deering *et al.*, "Monitoring vegetation systems in the great plains with erts," *NASA Spec. Publ*, vol. 351, no. 1, p. 309, 1974.