https://hjfy.top/arxiv/2603.00988

遥感中的基础模型：从单峰值到多模态的演进

Danfeng Hong, *Senior Member, IEEE,* Chenyu Li, Xuyang Li, Gustau Camps-Valls, *Fellow, IEEE,* and Jocelyn Chanussot, *Fellow, IEEE*

摘要—遥感（RS）技术正日益成为深化我们对地球认知的关键手段。随着遥感数据的规模和多样性持续呈指数级增长，迫切需要先进的数据建模与理解能力，以有效管理和解读这些海量数据集。基础模型为遥感领域带来了显著的新发展机遇，并具有彻底变革该领域的巨大潜力。本文对遥感中的基础模型进行了全面的技术综述，通过探索其从单峰值到多模态的演化过程，提供了一个全新的视角。我们希望这项工作能为对基础模型和遥感均感兴趣的科研人员提供有价值的切入点，帮助他们启动新项目或探索该快速演进领域中的新研究课题。本综述聚焦以下三个关键问题：

- **遥感中的基础模型是什么？**
- **为什么遥感（RS）中需要基础模型？**
- **我们应如何有效引导初级研究人员全面且实践性地理解遥感应用中的基础模型？**

更具体地说，我们首先概述了背景和动机，强调了基础模型在遥感（RS）领域的重要性。随后，我们回顾了现有的遥感基础模型，并将其系统地分类为单峰值和多模态方法。此外，我们还提供了一个类似教程的章节，指导研究人员，尤其是初学者，如何在遥感领域训练基础模型并将其应用于实际任务。本综述旨在帮助遥感领域的研究人员更深入、更高效地理解基础模型，使其能够轻松有效地将这些模型应用于各种遥感应用场景。

***Index Terms*—人工智能，基础模型，多模态，单峰值，遥感，地球观测。**

This work was supported by the National Natural Science Foundation of China under Grant 42271350 and by the International Partnership Program of the Chinese Academy of Sciences under Grant No.313GJHZ2023066FN. GCV gratefully acknowledges the support from the European Research Council (ERC) through the USMILE project (grant agreement 855187) and the European Commission through the HORIZON projects ELIAS (grant agreement 101120237) and ELLIOT (grant agreement101214398).

D. Hong is with the School of Automation, Southeast University, Nanjing 211189, China. (e-mail: danfeng.hong@seu.edu.cn)

C. Li is with the School of Mathematics, Southeast University, Nanjing 211189, China. (e-mail: chenyuli.erh@gmail.com)

X. Li is with the Aerospace Information Research Institute, Chinese Academy of Sciences, Beijing 100094, China, and the School of Electronic, Electrical and Communication Engineering, University of Chinese Academy of Sciences, Beijing 100049, China.

G. Camps-Valls is with the Image Processing Laboratory (IPL), Universitat de València, Paterna, València 46980, Spain. (e-mail: gustau.camps@uv.es)

J. Chanussot is with Univ. Grenoble Alpes, INRIA, CNRS, Grenoble INP, LJK, Grenoble 38000, France. (e-mail: jocelyn.chanussot@grenoble-inp.fr)

I. 引言

R最近，地球观测（EO）技术的进展，特别是遥感（RS），彻底改变了我们监测地球表面和环境各个方面的能力，如土地特征、地下状况、空气和水质，以及生物体健康状况 [?]。EO 技术是获取地球物理属性、环境状况及动态变化关键信息的重要工具。从太空监测这些方面能够实现更准确、及时的决策，从而改善自然资源管理、灾害预防和环境保护。

这些能力推动了对地球系统科学理解的深化，在应对气候变化、生物多样性损失和可持续发展等全球性挑战中发挥着至关重要的作用。遥感数据为在不同尺度上研究地球提供了独特的视角，能够提供传统地面观测方法难以甚至无法获得的洞察。整合这些洞察可推动有利于提升人类福祉、促进社会稳定性并确保环境可持续性的行动。

A. 基础模型在遥感中的作用日益凸显

然而，遥感数据在数量和多样性上的快速增长已超出传统模型的处理能力，迫切需要开发更先进的方法来处理和分析高维数据。随着遥感数据集变得越来越复杂，包含卫星影像、光谱数据、时间序列以及激光雷达等传感器模态，传统方法难以充分捕捉这些数据源中的信息丰富性。这凸显了亟需下一代人工智能模型，以应对多模态、时空及高维数据的挑战。

基础模型的出现为解决这一挑战提供了有效方案 [?]。这些大规模模型可以在海量且多样化的数据集上进

行预训练，并针对特定任务进行微调，为遥感（RS）应用带来了巨大潜力。它们能够利用遥感数据的规模和复杂性，发展出可迁移的表示，适用于广泛的地理空间任务，如土地覆盖分类、气候监测、灾害管理以及农业应用。在标注数据稀缺或获取成本高昂的情况下，基础模型的多功能性尤为宝贵，这在遥感领域十分常见，因为对大范围区域进行像素级标注既耗时又费资源。基础模型的自监督预训练与微调方法使大量未标记数据能够学习到通用特征，这些特征可应用于多种遥感任务中。该框架提升了遥感分析的可扩展性和效率，使其能够更好地捕捉地球观测数据复杂、多模态及动态的特性 [?], [?], [?], [?]。

B. 挑战与困难

尽管取得了这些令人鼓舞的进展，基础模型在遥感领域的应用仍相对未被充分探索。尽管这些模型具有巨大潜力，但若干障碍阻碍了它们在该领域的采用与整合，我们将在下文概述这些障碍以及当前出现的解决方案。

- 第一个挑战是许多从事遥感（RS）、地球观测（EO）和地球科学领域的研究人员对基础模型缺乏认知和理解。这些领域中的大多数研究人员不熟悉基础模型的潜在原理，例如自监督学习和迁移学习，或者缺乏将这些先进技术应用于实际工作的专业能力。这种知识鸿沟显著阻碍了基础模型在实际遥感任务中的成功应用，因为研究人员可能难以理解这些模型的工作机制，以及如何将其适配到自身特定需求中。为缓解这一问题，近期一些教程类论文和基准研究（如 BigEarthNet [?]、SpectralGPT [?]）已开始提供实践性资源，帮助遥感研究人员理解预训练和微调策略的实际应用。
- 其次，尽管一些调查尝试从特定角度对遥感基础模型进行组织和分类（如表I所示），但目前仍缺乏一个全面、类别清晰且面向教程的分类体系。现有基础模型数量庞大，其中一些模型彼此之间仅存在微小差异，这导致研究人员感到困惑和不确定。在缺乏统一评估与分类框架的情况下，研究人员难以为其特定应用选择最合适的模型，也难以在不同任务间比较各模型的性能。这种不明确性加剧了遥感领域在充分挖掘基础模型潜力时所面临的挑战。为此，社区驱动的努力逐渐兴起，例如 HuggingFace 上专为遥感设立的模型仓库，以及标准化的评估数据集，如 SEN12MS [?] 或 C2Seg [?]，这些为模型比较提供了更透明的基准。
- 最后，遥感（RS）研究领域对基础模型的技术使用指南仍存在显著的不确定性。即使这些模型已经可用，许多研究人员仍然不清楚如何对其进行微调或适应到具体应用中。关于模型在真实遥感场景下的性能、可扩展性和鲁棒性等问题，仍缺乏明确解答。由于缺乏适当的指导方针和评估基准，研究人员可能犹豫是否采用这些模型，担心其性能无法满足实际应用需求。此外，基础模型与现有遥感系统集成的标准化协议缺失，进一步阻碍了其广泛采用和部署。然而，近期多项研究已展示了实用的适配流水线，例如对预训练模型进行微调以实现作物分类、灾害监测或洪涝制图。这些工作为将基础模型融入实际遥感任务提供了具体的指导。

这些挑战严重阻碍了基础模型在遥感（RS）领域的开发与应用。随着遥感数据的体量和复杂性持续增长，必须解决这些障碍，才能充分发挥基础模型在地球观测（EO）中的潜力。为此，本综述旨在提供一份全面且易于理解的资源，阐明基础模型的核心概念，并解决阻碍其融入遥感领域的关键问题。

C. 与现有综述的比较

最近，已有几篇综述探讨了遥感（RS）、地球科学和地球观测（EO）中的基础模型，但该领域仍相对研究不足。表 I 按发表年份总结了这些工作。

Jiao 等人（2023）对遥感中的类脑基础模型进行了综述，讨论了其在处理复杂任务方面的独特优势，并分析了实施过程中面临的挑战 [?]。与此同时，Tan 等人（2023）探讨了多模态基础模型在地理学、环境、农业和城市规划领域的前景与挑战，通过案例研究强调了其适应性 [?]。

Li 等 (2024) 聚焦于遥感中的视觉-语言模型（VLMs），对它们的最新进展、应用及未来方向进行了综述 [?]。与此同时，Zhu 等 (2024) 将注意力转向地球与气候基础模型，讨论了其理论基础，并提出了在地球科学中开发此类模型的框架 [?]。Zhou 等 (2024) 引入了地理视觉-语言基础模型的概念，强调将地理空间先验与多模态学习相结合以进行地理信息处理 [?]。

Lu 等 (2024) 对遥感（RS）中的人工智能基础模型进行了全面综述，系统地分析了它们在不同 RS 任务中的应用与挑战 [?]。Zhang 等 (2024) 采取了不同的方

表 I
一份关于遥感、地球科学和地球观测领域基础模型的综述论文列表，包含论文标题、出版年份、期刊名称、描述及参考链接。

Title	Year	Journal	Description	Ref.
Brain-Inspired Remote Sensing Foundation Models and Open Problems: A Comprehensive Survey	2023	IEEE JSTARS	This review examines brain-inspired foundational models in RS, highlighting their applications, challenges, and advantages in complex tasks.	[?]
On the Promises and Challenges of Multimodal Foundation Models for Geographical, Environmental, Agricultural, and Urban Planning Applications	2023	Arxiv	This review highlights the potential, challenges, and flexibility of multimodal foundation models in geography, environment, agriculture, and urban planning through case studies.	[?]
Vision-Language Models in Remote Sensing: Current Progress and Future Trends	2024	IEEE GRSM	This review explores vision-language models in RS, highlighting their progress, applications, and future trends.	[?]
On the Foundations of Earth and Climate Foundation Models	2024	Arxiv	This review explores the theory behind Earth and climate models, proposing a foundational framework for Earth and climate sciences.	[?]
Towards Vision-Language Geo-Foundation Model: A Survey	2024	Arxiv	This review introduces geographic vision-language models, emphasizing geospatial priors and their multimodal fusion capabilities in geographic information processing.	[?]
AI Foundation Models in Remote Sensing: A Survey	2024	Arxiv	This review summarizes AI foundational models in RS, analyzing their applications and challenges across different tasks.	[?]
Foundation model for generalist remote sensing intelligence: Potentials and prospects	2024	Science Bulletin	This review envisions universal RS models with a “one model, multiple tasks” architecture to tackle task fragmentation and explores bottlenecks in high-resolution image processing.	[?]
Foundation Models for Remote Sensing and Earth Observation: A Survey	2024	Arxiv	This survey reviews RS foundation models, covering their motivation, key concepts, existing studies, benchmarks, challenges, and future directions.	[?]
When Geoscience Meets Foundation Models: Toward a general geoscience artificial intelligence system	2024	IEEE GRSM	This review explores the potential of geoscience foundation models in advancing Earth system modeling, highlighting their advantages, construction techniques, recent advancements, and future challenges.	[?]
Advancements in Vision-Language Models for Remote Sensing: Datasets, Capabilities, and Enhancement Techniques	2025	RS	This review covers advancements in vision-language models, introduces RS-optimized multimodal datasets, and shifts models from descriptive analysis to decision support.	[?]
When Remote Sensing Meets Foundation Model: A Survey and Beyond	2025	RS	This review examines the potential and challenges of foundation models for RS, highlighting recent advancements, open issues, and future directions to bridge the gap between natural and RS images.	[?]
Foundation Models in Remote Sensing: Evolving from Unimodality to Multimodality (ours)	2025	–	This review provides a comprehensive survey of foundation models in RS, uniquely framing their evolution from unimodality to multimodality with emphasis on tutorial-style practical guidance for researchers.	–

法，构想了一种面向通用智能的通用 RS 基础模型，探索“一个模型，多个任务”的范式及其解决任务碎片化问题的潜力 [?]。Xiao 等 (2024) 提供了对 RS 基础模型的结构化回顾，涵盖其动机、关键方法、现有基准以及未解决的挑战 [?]。

Zhang 等 (2024) 将讨论扩展至地球科学基础模型，探讨其在地球系统建模中的作用，并识别出关键的构建技术、进展及未来研究方向 [?]。进入 2025 年，Tao 等 (2025) 深入研究了遥感领域视觉-语言模型的最新进展，强调了针对遥感任务优化的新多模态数据集，并将这些模型的关注重点从描述性分析转向决策支持 [?]。最后，另一项 (2025) 综述考察了基础模型在遥感中的潜力与局限性，聚焦于弥合自然图像与遥感图像之间的差距，同时识别出关键的开放挑战及未来研究方向 [?]。

尽管这些综述为遥感领域的基础模型提供了宝贵的见解，但它们主要聚焦于特定的子领域、方法或应用。相比之下，我们的综述工作从更广阔的视角探讨了从单峰值到多模态的转移过程。我们强调了遥感领域中的关键挑战与开放性问题，厘清了基本概念与学习范式，探索了新兴趋势，并提供了以未来遥感基础模型发展为重点的实用指导。

D. 目标与贡献

本文的主要目标是为遥感（RS）研究人员和实践者提供一条清晰的路径，帮助他们理解并有效应用基础模型。我们介绍了这些模型，解释了它们独特的学习范式，并展示了其在遥感领域的实际应用。本综述强调一种直观、用户友好的方法，以促进基础模型在遥感研究与应用中的广泛采用。

本文的贡献可概括为三个主要目标：

- 我们旨在为遥感（RS）领域提供一份详细且易于理解的基础模型综述。尽管基础模型在自然语言处理、计算机视觉等多个领域已受到广泛关注，但其在遥感领域的应用与潜力仍相对未被充分探索。本

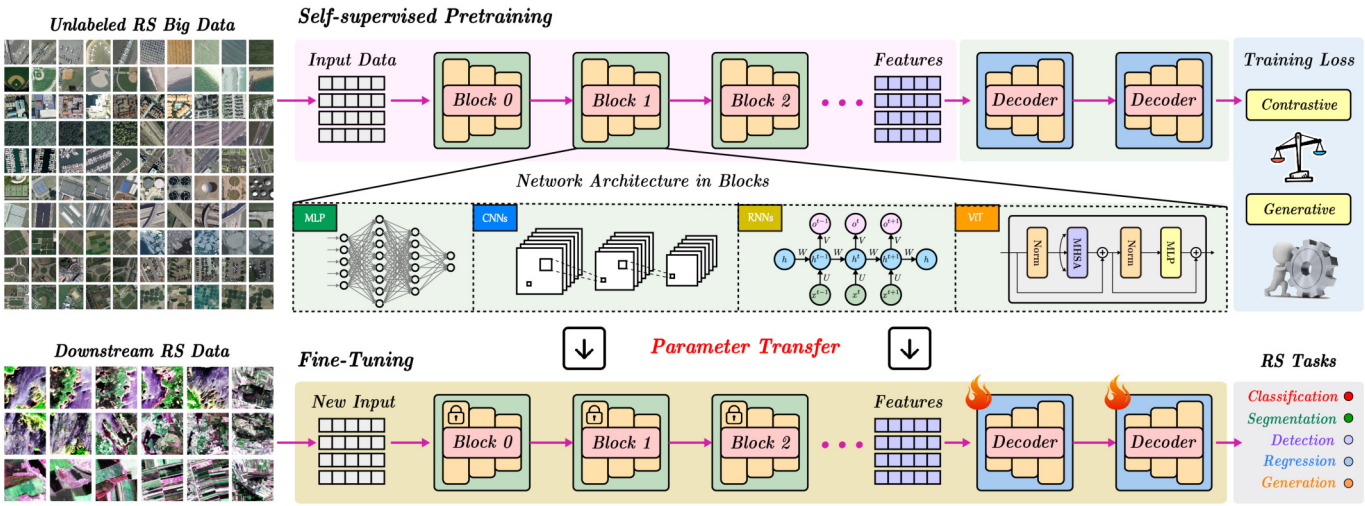

图 1. 遥感领域基础模型的一种通用学习范式：自监督预训练 + 微调。为便于说明，考虑一个与视觉相关示例：模型首先在大量未标记的遥感数据上进行预训练，使用如 MLP、CNN、RNN 或 ViT 等主干架构。预训练过程中通常采用对比损失和生成（重构）损失。预训练权重随后被迁移至下游遥感任务中，这些权重可保持冻结状态，也可进行微调（通常重点关注解码器权重），从而实现分类、分割、检测、回归及生成等应用。

综述旨在填补这一空白，深入概述基础模型的核心原理，阐明其在遥感背景下的运作机制，并与传统的遥感数据处理与分析方法进行对比。通过清晰解释其学习范式，我们希望帮助遥感领域的研究人员、学生及工程师更好地理解基础模型与传统方法之间的根本差异。

- 在基础模型应用于遥感（RS）领域的一个显著趋势是，其从处理单一类型数据的单峰值模型演变为能够整合和分析多种数据类型的多模态模型（如光学、激光雷达和合成孔径雷达数据）。这一演进标志着遥感数据处理与分析方式的根本性转变，朝着更加全面、集成的方向发展。在本综述中，我们系统地回顾了该领域的关键研究成果，为读者提供了关于基础模型如何演进以应对遥感中多模态数据融合挑战的全新且全面的视角。通过突出这一转变，我们旨在帮助读者直观、易懂地理解基础模型在遥感领域日益增长的复杂性与能力。
- 尽管遥感（RS）领域对基础模型的认识日益增强，许多研究人员和从业者仍难以理解如何在实际的遥感任务中有效应用这些模型。为解决这一问题，我们专门设立了一个部分，作为用户将预训练基础模型融入工作的实用教程。该教程将引导读者完成从在特定遥感任务上微调预训练模型，到将其集成到现有遥感工作流中的必要步骤。通过提供类似教程的指导，我们旨在帮助研究人员和从业者在其各自领域中有效利用遥感基础模型，从而应对下一代地球观测面临的日益复杂的挑战。

E. 论文结构

本文其余部分组织如下：第二节介绍了遥感领域中基础模型的概念，简要概述了这些模型在遥感领域的运作机制。第三节回顾了遥感领域基础模型的演化历程，追溯了从单峰值模型向多模态模型的转变，并重点阐述了关键进展。第四节提供了一个教程式的指南，介绍如何在遥感领域应用预训练的基础模型，帮助用户掌握使用这些模型完成特定任务的实际操作。最后，第五节讨论了遥感领域基础模型面临的现存挑战，探索潜在解决方案，并提出未来研究方向，以进一步提升这些模型的有效性与应用前景。通过兼顾基础模型的理论与实践层面，本综述旨在为遥感领域提供有价值的参考资源，助力推动这些强大工具在地球观测中的广泛应用与快速落地。

II. 基础模型

本节从概念角度简要概述了基础模型，并介绍了它们的新型学习范式。它回答了两个问题：“什么是基础模型?”以及“其学习范式与以往有何不同?”

A. 基础模型简要理解

1) **机器学习的范式转变**: 基础模型的特点是规模庞大，并在海量且多样化的数据集上进行预训练，以学习泛化的表示。与通常针对特定任务设计、需要大量领

域特定训练的传统模型不同，基础模型旨在跨广泛的任务和领域实现泛化。其架构通常基于 Transformer 模型或类似的深度学习框架，能够捕捉数据中的复杂模式和关系。这种泛化能力源于大规模参数化以及从异构数据源中学习的能力，使这些模型能够在少量额外数据的情况下进行微调，以适应具体的下游应用。

基础模型最显著的优势之一是其可扩展性。它们能够处理大规模数据集和复杂的数据结构，适用于从自然语言处理（如 GPT、BERT）到计算机视觉（如 CLIP、DINO）等多个领域。此外，其良好的迁移能力使其能够在有限的领域特定调整下适应新任务，大幅减少了对大规模标注数据集的需求。这一点在标注数据稀缺或获取成本高昂的领域尤为有益。同时，它们处理多模态数据（如文本、图像、音频等）的能力，有助于更全面地理解和表示复杂现象。

2) **遥感中的基础模型实现对地球观测的变革***:* 遥感（RS）领域的基础模型是旨在解决地球观测（EO）数据相关独特挑战的变革性工具。遥感数据本质上具有复杂性，涵盖多种模态，如光学 RGB、合成孔径雷达（SAR）、光谱数据、激光雷达（LiDAR）以及时空序列。传统的遥感模型在整合这些多模态数据集方面常常面临困难，并且每个特定应用都需要大量标注数据。基础模型通过在多样化遥感数据集上进行大规模预训练，克服了这些限制，使模型能够学习通用表示，适用于广泛的地理空间任务。表 II 总结了用于预训练遥感基础模型的常用数据集，强调了领域侧重、传感模态、空间分辨率、数据规模及下游适用性等关键特征。具体而言，*fMoW* 和 *MillionAID* 提供丰富的类别标注和中高分辨率的 RGB 影像，光谱数据覆盖有限（0.3–11.4 米），特别适合图像级或场景级分类以及目标存在识别。*SSL4EO-S12*（哨兵 1/2，10–60 米）[?] 和 *SSL4EO-L*（陆地卫星，30 米）[?] 结合了广泛的光谱覆盖与规律重访周期，支持大规模语义分割和土地覆盖制图，适用于中等分辨率即可满足需求的应用。*Satlas* 专为目标检测、变化检测、分类和语义分割设计，利用 NAIP/RGB/哨兵影像（1–10 米），以满足需要精细空间细节和跨源一致性的任务。广泛覆盖“通用场景”的语料库，如 *SeCo*、*GeoPile (GFM)*、*Prithvi*、*DOFA-data*、*Skysense* 和 *MMEarth*，涵盖多种模态（RGB、SAR、光谱、DEM）和分辨率（0.1–30 米），促进在下游任务中的鲁棒迁移能力。特别是 *DOFA-data*、*Skysense* 和 *MMEarth* 集成了 SAR 和/或 DEM 层，为需要天气鲁棒感知（SAR）或地形上下文（DEM）的应用提供了优势。

这些模型在预训练阶段采用自监督或无监督学习技术，能够从海量的未标记遥感数据中提取有意义的模式和特征。这种方法显著降低了对标注数据集的依赖，因为遥感领域由于在大范围复杂地理区域进行像素级标注存在挑战，标注数据往往有限。通过实现高效的迁移学习，基础模型仅需少量标注数据即可微调，从而完成土地覆盖分类、气候监测、灾害响应和农业评估等特定任务。

基础模型在遥感领域的适应性使其能够处理不同数据分辨率、传感器类型和时间频率，适用于动态且异构的地球观测应用。其可扩展性确保了能够处理大规模数据集，例如连续的卫星影像流或全球气候数据，为科学研究和实际应用提供强大而及时的洞察。

B. 遥感中的学习范式

1) **传统遥感方法中的瓶颈***:* 遥感（RS）图像处理与分析中的传统学习范式通常包含两种主要方法。第一种方法侧重于从遥感图像中手动或自动提取特征表示，随后应用分类或回归算法来解释这些特征，以完成土地覆盖分类、目标检测或环境监测等特定任务。第二种方法则采用端到端模型，直接将输入数据映射到输出标签，通过跳过显式的特征抽取过程，简化了学习流程。尽管在某些应用中表现出色，但这些传统方法从根本上受限于标注数据的可用性。在遥感领域，标注尤为困难，因为需要在像素级别对大量数据进行标注，且通常需从俯视视角覆盖广阔的地理区域。这一耗时耗力的过程导致大规模标注数据集稀缺，使得大量遥感数据处于未标记状态，未能得到充分利用。

2) **用基础模型革新遥感***:* 相比之下，基础模型的出现引入了一种变革性的学习范式，其特征为 **“自监督预训练 + 微调”**。这种方法在遥感（RS）领域日益成为主导框架，为传统方法所面临的局限性提供了有效解决方案。自监督预训练使模型能够通过识别数据内部固有的模式、结构和关系，从海量未标记遥感数据中学习丰富且具备泛化能力的表示。该过程利用遥感数据集固有的冗余性和复杂性，如时间序列、多模态输入（例如光学、合成孔径雷达、激光雷达）以及光谱变化，构建鲁棒的特征表示，而无需依赖人工标注。

在预训练阶段之后，采用微调方法，利用少量标注数据将预训练模型适配到特定的下游任务中。这显著降

表 II
遥感基础模型的代表性预训练数据集。

Name	Domain	Modality	Resolution	Image Number
SeCo	General Scenes	Spectral	10 m	About 1 million
SSL4EO-S12	Land Cover	Spectral, SAR	10–60 m	1,004,316
fMoW	Classification	RGB, Spectral	0.3–10 m	1,047,691
MillionAID	Classification	RGB	0.5–11.4 m	400,695
SSL4EO-L	General Scenes	Spectral	30 m	5 million
Satlas	OD, CD, Class, SemSeg	RGB, spectral	1–10 m	856K
GeoPile (GFM)	General Scenes	RGB	0.1–30 m	587,954
DOFA-data	General Scenes	RGB, SAR, spectral	0.5–30 m	8,081,411
Prithvi	General Scenes	Spectral	30 m	4.2 million
Skysense	General Scenes	RGB, SAR, Spectral	0.31–20 m	21.5 million
MMEarth	General Scenes	RGB, spectral, SAR, DEM	10 m	1.2 million

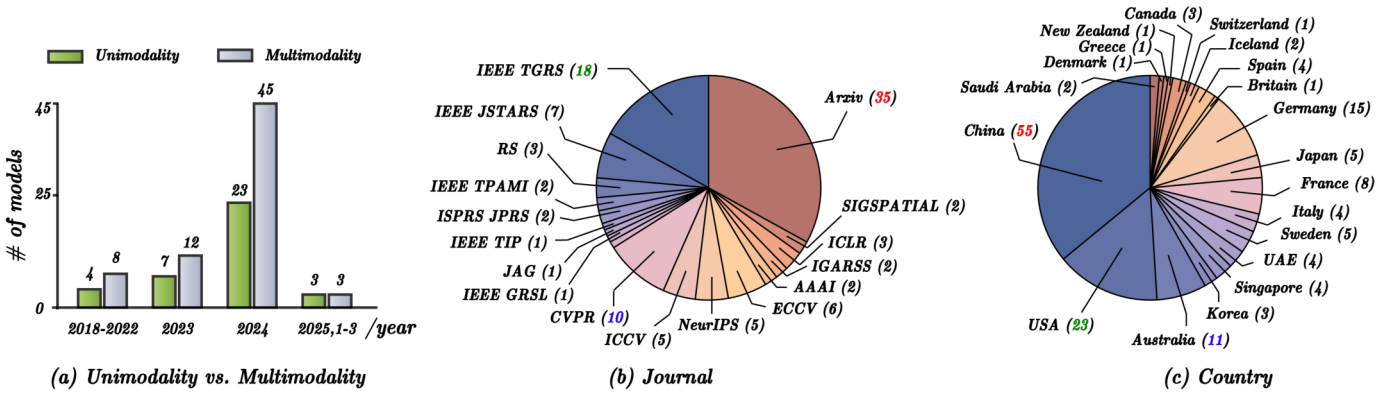

图 2. 遥感相关领域基础模型的统计概览。(a) 对遥感中的单峰值与多模态基础模型进行了定量比较。(b) 用饼图展示了遥感基础模型在不同期刊中的分布情况。(c) 描绘了不同国家研发的遥感基础模型数量。两个饼图中数量排名前三位的分别用红色、绿色和蓝色突出显示。

低了对大规模标注数据集的依赖，同时在各种应用中保持了较高的性能。微调过程优化了模型的表示，使其与特定任务的目标（如土地覆盖分类、变化检测或目标识别）相一致，从而提升了准确率和泛化能力。

基于基础模型的范式在遥感（RS）场景中尤为有利，因为来自多种传感器和平台的未标记数据极为丰富。通过有效利用这些数据，基础模型能够克服传统方法固有的数据稀缺问题，从而实现更高效、可扩展的解决方案。此外，基础模型在不同遥感任务和数据集之间具备良好的泛化能力，使其具有高度的灵活性，广泛支持从环境监测到城市规划的各种应用。

图 1 展示了遥感领域基础模型的一般学习范式，强调了从传统的监督方法向更灵活、更强大的自监督预训练与微调框架的转移。这一转变不仅提高了遥感数据的利用效率，也为更先进的、具有更好泛化能力的遥感应用铺平了道路。

III. 从单峰值到多模态的演化

本节对遥感（RS）领域的基础模型进行了直观概述，追溯了其从单峰值到多模态的演化历程。通过这一视角，我们探讨了这些模型如何越来越多地整合多种数据类型，即单峰值和多模态数据。图3展示了 2018 年至 2025 年间遥感领域基础模型从单峰值向多模态发展的路线图。如图所示，相较于单峰值模型，多模态基础模型自 2024 年以来获得了越来越多的关注与青睐，标志着其发展出现了显著增长。值得注意的是，与大语言模型（LMMs）融合的视觉基础模型正受到研究人员日益增长的兴趣。

A. 概览：统计分析

我们收集了 105 篇关于遥感相关领域基础模型的论文，并进行了统计分析，以更好地理解其发展趋势和影响。图2从三个角度概述了这些模型：模态分布、发表期刊以及各国贡献情况。

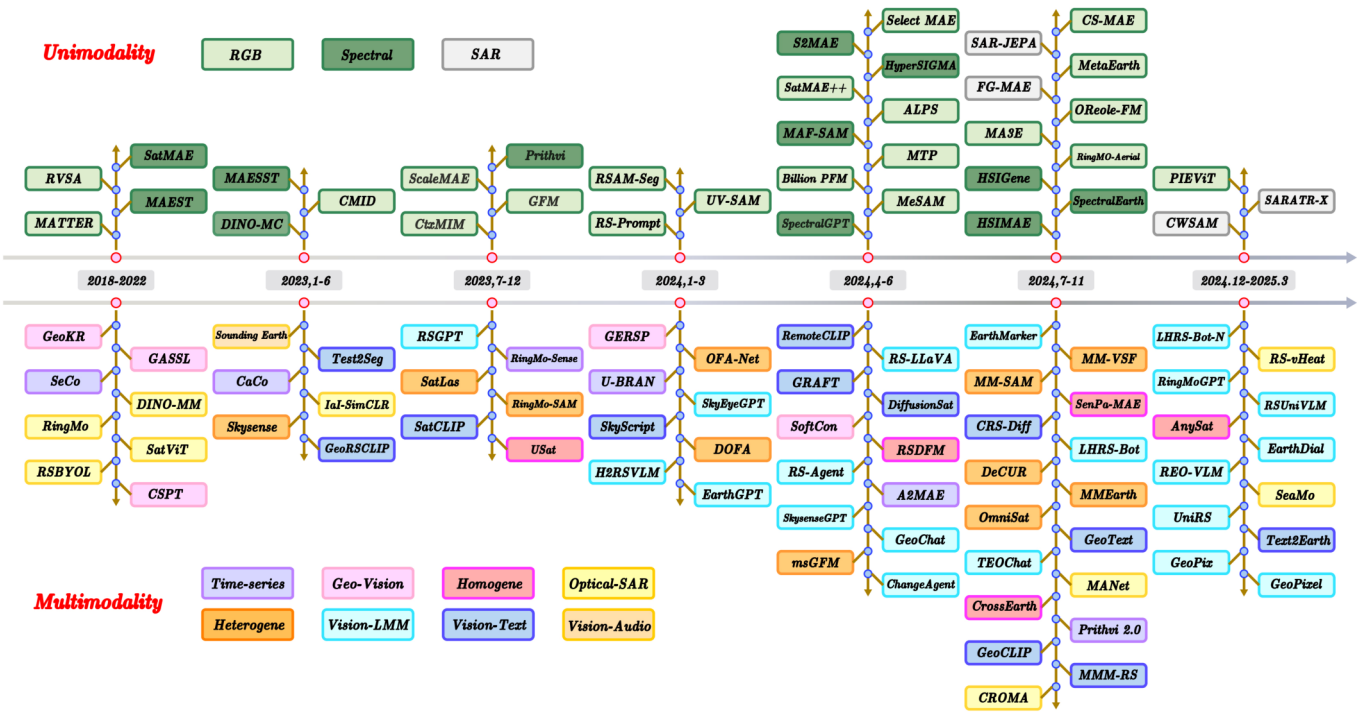

图 3. 遥感领域基础模型发展路线图（2018–2025 年）：从单峰值到多模态方法的演化。单峰值数据包括 RGB、光谱和合成孔径雷达（SAR）数据。多模态融合分为同质数据（如多光学）、光学-SAR，以及异构数据（如光学-SAR-光谱-数字表面模型、视觉-文本、视觉-音频、地理空间-视觉、时间序列，以及视觉-语言大模型）。不同模型类别以颜色编码，以区分各类数据模态与融合类型，各时期内模型按时间顺序排列（纵向布局）。

图 2(a) 比较了单峰值和多模态遥感基础模型，显示出向多模态方法的明显转变。这一趋势在 2024 年尤为显著，随着遥感基础模型的快速发展，多种数据源（如光学影像、合成孔径雷达（SAR）和光谱数据）的整合日益增加。对多模态模型日益增长的兴趣反映了在遥感应用中对更全面、更稳健解决方案的需求。

关于发表分布（见图2(b)），arXiv 拥有最多的论文数量，凸显了研究成果在正式同行评审前的早期传播。在经过同行评审的出版物中，IEEE TGRS 排名第二，突显了地球科学与遥感领域社区的强大影响力，而作为人工智能和计算机视觉领域顶级会议的 CVPR 则位列第三。这表明遥感技术与前沿人工智能及视觉研究之间的交叉日益加深。

图 2(c) 展示了遥感基础模型研究的地理分布。中国在贡献方面处于领先地位，紧随其后的是美国和澳大利亚，这表明传统上占主导地位的人工智能研究枢纽以及专注于遥感的人工智能新兴领导者均表现出强劲参与度。这一分布凸显了遥感基础模型开发的全球性特征，其背后是地球观测与空间分析领域对先进人工智能解决方案的需求驱动。

总体而言，这些统计量凸显了基础模型在遥感领域的快速发展，多模态趋势的兴起，以及人工智能驱动方法日益增多的参与。这一趋势反映了研究界不断致力于拓展遥感智能的边界，并为多样化应用开发更具泛化能力、可扩展性和高性能的模型。

B. 遥感中的单峰值基础模型

遥感中的单峰值基础模型旨在对单一来源或传感器类型的数据进行预训练，利用特定数据模态的独特特性。例如高分辨率 RGB 影像、雷达数据、点云数据、光谱数据。[1]，以及气象数据。这些模型旨在从各自模态中提取最具信息量的特征和模式，优化其能力以应对不同的属性和挑战。这种有针对性的方法为推动特定数据领域内的遥感任务发展奠定了基础。

1) ***光学 RGB 图像****:* 光学 RGB 图像中的高分辨率空间和语义信息可通过自监督和对比学习方法得到良好表示 [?]。例如，MATTER [?] 采用对比学习来强调遥感（RS）图像中的纹理信息，而 RVSA [?] 则借鉴 MAE 的掩码策略，在 MillionAID [?] 数据集上进行预训练，随后使用其 RVSA 模块进行微调。CMID [?] 通过将对比学习（CL）与掩码图像建模（MIM）相结合，

[1]我们统称遥感中的多光谱和高光谱数据为光谱数据。

提出一种对比掩码图像蒸馏方法，以实现全局语义可分离性和局部空间感知性。CtxMIM [?] 引入一种上下文增强的生成分支，通过一致性约束提供补丁级重构所需的上下文信息。GFM 模型 [?] 利用大规模公开数据集以及基于掩码图像重构作为目标的教师-学生双流网络，在场景分类、变化检测和语义分割任务中取得了显著成功。

如 Scale-MAE [?] 和 SatMAE++ [?] 所示，这些模型均针对遥感（RS）图像的大小和分辨率问题：Scale-MAE 专注于尺度不变的表示学习，而 SatMAE++ 提升了对分辨率敏感的特征抽取能力。因此，Scale-MAE 在跨尺度泛化任务中具有优势，而 SatMAE++ 则在高分辨率应用（如目标检测和细粒度分割）中表现更优。SelectiveMAE [?] 动态编码并重建根据语义丰富度选择的图像块，采用一种渐进式语义 token 选择模块，从重构语义相似的 token 逐步演变为编码互补的语义依赖关系。MA3E [?] 提出了一种基于旋转角度变化的掩码自监督学习框架，解决了遥感图像与自然图像之间的差异。RingMo-Aerial [?] 将光谱信息作为辅助信号，通过对比学习进行训练。Billion PFM [?] 与 OReole-FM [?] 使用 MAE 方法将高分辨率遥感图像的预训练扩展至十亿参数模型。文献 [?] 提出了一种分辨率引导的自级联生成框架，称为 MetaEarth，能够生成任意区域、涵盖广泛地理分辨率的图像。Cross-Scale MAE [?] 在不同大小的图像上执行对比掩码建模，构建了一个统一的预训练最优化框架。PIEViT [?] 是一种专为遥感图像设计的新颖自监督学习框架，采用教师-学生架构，同时处理图像级与块级任务。

此外，通用分割模型（SAM）的分割能力在遥感（RS）领域引起了广泛关注。MeSAM [?] 设计了一种适用于 RS 光学图像的新适配器，将其嵌入到 SAM 编码器中，利用多尺度卷积核更有效地处理图像，同时保留高频特征。RSAM-Seg [?] 通过引入领域知识和缩放模块对 SAM 进行增强，能够完成云、建筑物、田地和道路等任务的分割。Rsprompter [?] 引入了可学习的基于锚点的提示和掩码解码器，使 SAM 能够处理类别输入以实现实例分割。UV-SAM [?] 将类激活图生成的粗略掩码精炼为伪标记，用于在遥感图像上训练语义分割模型。ALPS [?] 提出了一种无需先验知识或提示即可实现完全自动稠密标注的框架。

2) **光谱数据***:* 各种模型利用多时相和多波段数据以提升空间与光谱信息的重构能力 [?]。SatMAE [?] 提出了一种针对多时相、多通道数据的分组掩码策略，从而更好地学习通道与空间之间的关系。DINO-MC [?] 采用对比学习框架，而 Prithvi [?] 通过掩码单个通道来增强光谱-空间表示学习。MAF-SAM [?] 提出一种多阶段自适应微调策略，将光谱数据压缩至三个通道，使用前缀适配器，并对图像编码器应用 LoRA 微调以注入作物特定知识，生成具备精确类别信息的多类分割掩码。相较于以往方法，SpectralGPT [?] 是首个专为光谱遥感（RS）数据设计的基础模型。通过显式建模多/高光谱观测中固有的空间-光谱耦合性与光谱序列性，SpectralGPT 引入三维掩码策略及光谱一致性约束。该设计使得光谱序列的有效学习与结构化光谱表示得以实现，从而显著推动了光谱遥感数据的建模范式与实际理解水平。MAEST [?] 与 MAESST [?] 提出了针对光谱特性的掩码自监督学习算法，以提升土地覆盖分类准确率。Wang 等人 [?] 在大规模光谱立方体上进行了自监督掩码建模预训练。SpectralEarth [?] 引入一种自监督学习算法，为 EnMap 数据的预训练提供了坚实的数据基础与算法支持，并支撑一系列下游微调应用。HyperSIGMA [?] 提出一种双流框架，分别建模空间与光谱信息。在此方法中，输入的光谱数据通过随机选择光谱波段并打乱光谱序列，统一为固定数量的波段。Pang 等人 [?] 提出一种生成型基础模型，基于潜在扩散模型，支持多条件控制，并设计了两阶段超分辨率框架，以生成具有真实感的图像。

3) **合成孔径雷达（*SAR*）***:* FG-MAE [?] 利用方向梯度直方图（HOGs）作为重构特征，利用合成孔径雷达（SAR）数据中固有的空间信息。SAR-JEPA [?] 采用联合嵌入预测架构，对 SAR 图像进行预训练时预测梯度信息。CWSAM [?] 通过引入任务特定的输入模块和分类掩码解码器，将 SAM 框架适配于 SAR 图像的地表覆盖分类，并在分割任务中注入 SAR 低频信息。SARATR-X [?] 在 SAR 图像的预训练中采用多尺度掩码策略，实现了目标检测和分类任务。

C. 遥感中的多模态基础模型

尽管遥感（RS）中的单峰值模型通常专注于单一数据类型，如光学、雷达或激光雷达数据，但融合多模态数据由于遥感数据的异质性而引入了额外的复杂性。这些数据往往来自不同的传感器、平台和尺度，导致空间、时间和光谱特征上的差异。例如，光学、雷达和激光雷达数据各自提供了地球表面的不同视角，但其融合

需要解决分辨率、数据格式和噪声特性等方面的差异。此外，将结构化数据（如时间序列或地理坐标）与非结构化数据（如文本或图像）相结合，进一步增加了处理难度。多模态融合的主要挑战之一在于如何将这些多样化数据类型协调整合到一个统一的模型中，以准确捕捉潜在现象，同时保留各模态的优势。此外，这种融合还必须考虑每种数据类型固有的不确定性与不完整性程度差异，使得构建稳健且可靠的模型变得更加困难。

遥感中的多模态基础模型通过整合来自多种数据类型的相关信息，超越了单一模态的限制。这些模型能够处理同质和异构数据，并将视觉数据与其他模态（如时间序列、地理空间、文本、大语言模型和音频）相结合。与强调遥感数据不同来源的多源数据不同，多模态更注重多样化数据类型或形式的融合，从而实现对地球观测数据更全面的理解。这种方法通过捕捉每种模态内部的独特特征和关系，提升了模型性能，最终提高了遥感应用的准确率和鲁棒性。在处理多模态遥感数据时，区分同质与异构数据源至关重要。同质数据（来自相同来源但不同传感器，例如 Sentinel-2、Landsat、EnMap、GF-1/2/5/6）通常可在数据层面直接进行融合，采用波段堆叠、重采样或分辨率增强等操作 [?]。相比之下，异构数据（如光学与合成孔径雷达，或光学与数字高程模型）由于传感原理、分辨率和噪声特性差异，一般无法在原始数据层面直接结合。此时，更推荐采用特征层面的融合策略，包括早期特征拼接、中间特征交互以及晚期决策层组合。近年来，先进的交互式融合策略（如跨模态注意力、基于图形的推理和协同学习机制）被提出，能够动态捕捉跨模态间的互补性，从而提升复杂下游任务的表现。关于最佳实践的更详细讨论，读者可参考 [?]。

1) **异构数据 ↦ 时间序列***:* 在视觉与时间数据的融合中，多个模型引入了新颖策略以增强遥感（RS）数据中的时空表示。SeCo [?] 通过从不同季节的图像中构建正负例对，显式考虑了 RS 数据的季节特性，提升了模型对季节变化的敏感性。然而，SeCo 在识别长期时间不变性方面存在困难。为解决此问题，CACo [?] 采用对比损失函数增强时间一致性，从而从时序数据中提取更鲁棒的不变特征。

进一步的进展扩展到了遥感视频数据。RingMo-Sense [?] 通过采用多策略掩码进行预训练，以应对航拍视频。与此同时，U-BARN [?] 采用了类似 BERT 的生成式预训练任务，对光学卫星图像序列中的掩码部分进行重建。

其他模型通过先进的掩码策略优化时空编码。A^2-MAE [?] 将锚点感知的掩码策略与地理编码模块相结合，有效捕捉空间、时间和光谱变化。最后，Prithvi-EO-2.0 [?] 通过通道掩码预训练，利用来自陆地卫星和哨兵-2 的时间序列数据，从同质数据集中提取时间特征，进一步强化了遥感中的时间序列建模能力。

2) **异构数据 ↦ 地理空间-视觉***:* GeoKR [?] 利用地图信息作为标签，结合蒸馏和对比学习实现半监督预训练。GASSL [?] 将对比学习应用于统一增强的图像数据，引入地理坐标作为辅助监督。CSPT [?] 提出一种对比空间预训练方法，采用双编码器分别对图像和地理坐标进行编码。通过对比目标，从图像中提取有效的位置信息，用于下游监督任务如图像分类。Mai 等 [?] 通过引入自监督对比学习框架，提出了 CSP 模型以构建地理空间-视觉表示。GERSP [?] 采用教师-学生蒸馏网络，对齐自然图像与遥感（RS）图像的地理信息，以增强预训练模型对通用地表覆盖知识的感知能力。SoftCon [?] 引入软对比学习，利用来自地表覆盖数据的多标签监督信号，优化跨场景软相似度度量，提升模型在复杂遥感图像中的泛化能力。

3) **同质数据***:* 对于同质数据，USat [?] 模型具有独特的块投影层和位置编码，使其能够处理来自多个传感器的光谱数据并适应不同的空间尺度。RSDFM [?] 采用 BEVFormer 架构，从不同平台、视角和高度的数据中构建统一视角。SenPa-MAE [?] 将光谱波长信息作为网络的先验嵌入，并应用掩码建模自监督学习，使模型在不同光谱传感器的数据上表现优异。CrossEarth [?] 引入领域泛化方法，实现基础模型在下游数据集风格不同的语义分割任务中的应用。AnySat [?] 是一个多模态模型，探索了分辨率自适应的空间编码器。通过使用尺度自适应的补丁编码模块，AnySat 能够有效提升模型对分辨率的敏感性，特别适用于分辨率各异的光学遥感数据。CSMAE [?] 训练了一个跨传感器 MAE 模型，用于多传感器遥感图像检索，以高效搜索跨不同图像模态的语义相似图像。

4) **异构数据 ↦ 光学-*SAR***:* RingMo [?] 采用针对异构遥感图像特性的稀疏掩码策略和 Transformer 架构。这些模型，例如 IaI-SimCLR [?]、DINO-MM [?]、RS-BYOL [?]，在多模态、多源卫星影像背景下采用对比学习范式。SatViT [?] 直接将 MAE 框架迁移至光学与 SAR 数据源的异构数据学习中。RS-BYOL [?] 通过

结合单通道与三通道特征抽取，从光谱与 SAR 数据中学习不变特征嵌入。MANet [?] 在 SAM 编码器中引入两个适配器，一个用于提取单模态信息，另一个用于融合多模态信息。CROMA [?] 利用 CoCa 框架，采用对比掩码预训练来结合光谱与雷达数据，从而提升模型处理数据异构性的能力。RS-vHeat [?] 探索使用基于热传导的并行计算模型，模拟高分辨率遥感图像中局部区域的相关性。最近，Li 等人 [?] 提出了一种新的遥感多模态基础模型——SeaMo，通过嵌入季节知识以提升其在广泛下游应用中的性能。

5) **异构数据 ↦ 光学/ *SAR*/光谱/ *DSM***: 在多模态遥感领域，已开发出多种模型以有效整合多样化的数据源。SkySense [?] 采用分解式多模态时空编码器来处理光学与 SAR 时序数据，利用多粒度对比学习增强其对复杂遥感数据集的理解能力。类似地，SatLas [?] 利用 Swin Transformer 在 NAIP、LiDAR 和 Sentinel-2 数据上进行大规模监督预训练，提升了其处理多样化地理空间输入的容量。

对于分割任务，RingMo-SAM [?] 通过冻结 SAM 编码器并应用基于 LoRA 的参数高效微调（PEFT），增强了多模态分割能力，同时为 RGB、SAR、PolSAR、DSM 和 MSI 数据引入了模态特定的解码器。在多模态标记化方面，OFA-Net [?] 为不同输入类型（RGB、光谱和雷达）引入了专用标记器，确保模型对多样化的光谱和空间信息具有敏感性。与此同时，DOFA [?] 采用动态权重生成器，自适应地融合多种光谱波段的特征，构建了一个支持灵活输入（RGB、光谱和雷达数据）的高效基础模型。

为了进一步增强跨传感器学习，msGFM [?] 采用基于掩码图像建模的跨传感器预训练方法，实现光学、SAR、光谱和 DSM 数据的联合表示，从而提升多模态融合能力。类似地，MM-VSF [?] 在知识引导框架下结合光谱影像与气象数据，以可变步长预测作为其预训练目标，以增强环境预测能力。

对于多模态分割，MM-SAM [?] 将 SAM 扩展以支持跨模态和多模态处理，在多传感器遥感应用中显著提升了分割性能。同时，DeCUR [?] 引入了一种解耦策略，以分离共有的和独特的表示，从而有效融合不同模态间的互补信息，例如雷达-光学、RGB-高程和 RGB-深度。

多个模型专注于整体多模态融合与数据融合。MMEarth [?] 在预训练过程中重构 ℓ_2 不同的像素级和区域级模态及标签，为下游任务提供了全面的视角。最后，OmniSat [?] 通过利用具有对比掩码策略的异构模块，整合高分辨率 RGB、光谱时间序列和雷达时间序列数据进行预训练，在广泛的多模态应用中实现了出色的表现。

6) **异构数据 ↦ 视觉-语言多模态模型***:* 大模型的快速发展已将多模态模型的应用拓展至遥感任务，超越了传统的视觉模型，实现了更为复杂的多模态交互。一种常见方法是利用视觉-语言基础模型，通过将视觉编码器与文本语义对齐，以促进与大模型的集成。例如，RSGPT [?] 采用 EVA-CLIP 编码器，并在遥感任务中应用先进的训练技术进行训练。RS-LLaVA [?] 采用 LoRA 微调，显著提升了 LLaVA 的性能。EarthGPT [?] 构建了一种视觉增强感知机制，优化了粗粒度语义理解与细粒度细节提取之间的融合。

除了静态图像分析之外，交互式和对话式模型在遥感（RS）应用中扮演着至关重要的角色。RS-Agent [?] 将大语言模型（LLM）定位为“中心控制器”，整合多个高性能的遥感图像处理工具，实现多工具、多轮次的交互。GeoChat [?] 首次提出了支持视觉地理定位任务的对话式视觉语言生成模型（VLGFM），为交互式遥感图像分析引入了新的范式。Change-Agent [?] 提出了一种交互式智能体，能够根据用户指令执行全面的变化检测、目标计数和因果分析。EarthMarker [?] 设计了一种跨领域分阶段学习策略，实现了图像级、区域级和点级遥感解释的多粒度视觉感知。

多个模型专注于遥感视频分析与时间推理。SkyEyeGPT [?] 是为遥感视频描述设计的视觉语言生成框架，提供了自动化视频内容描述的新解决方案。TEOChat [?] 作为一种能够与时间序列遥感数据交互的视觉语言模型，在各种时间推理任务中表现出色。UniRS [?] 是一个统一的视觉语言模型，适用于多时相遥感任务，能够在统一框架下支持单张图像、图像对以及视频，实现全面的时间分析。

为了提升遥感图像理解能力，LHRS-Bot [?] 采用分层的视觉-语言对齐策略和课程学习方法，在遥感分析中提供了新的视角。LHRS-Bot-Nova [?] 在 LHRS-Bot 基础上引入了由混合专家模型增强的视觉编码器以及一种新型桥接模块，提升了多模态大语言模型对遥感图像的理解能力，支持交互式自然语言对话。RingMoGPT [?] 通过一种位置与指令感知的 Q-Former 及变化检测模块，解决了遥感中的关键问题，如目标级识别、定位以及多时相变化检测，实现了目标检测与变化描述。

RSUniVLM [?] 提出了一种面向粒度的混合专家模型，增强了模型在不同粒度下捕捉视觉信息的能力。

新兴模型强调高分辨率和细粒度感知。GeoPix [?] 将多模态大语言模型对遥感图像的理解扩展到像素级别。GeoPixel [?] 是一个端到端的高分辨率多模态模型，支持像素级定位，通过对话中的交错掩码实现细粒度视觉感知。它支持高达 4K 的高分辨率遥感图像分析，并兼容任意长宽比。EarthDial [?] 支持光谱、多时相和多分辨率图像，能够执行广泛的遥感任务，包括分类、检测、描述生成、问答系统、视觉推理和视觉定位。

一些模型将特定领域的人工智能与地球观测相结合。REO-VLM [?] 将回归能力与传统的生成功能相结合，利用语言驱动的推理来融入科学领域知识，从而实现对地球观测数据的复杂解读，并支持生物量回归和图像内容解释等任务。SkySenseGPT [?] 融入了计算机图形学的原理，以增强模型感知和推理遥感目标之间关系的能力。这些进展标志着向更加交互式、领域感知且高分辨率的基于人工智能的遥感分析转变，开启了地理空间智能的新时代。

7) **异构数据 ↦ 视觉-文本***:* 在视觉-文本领域，已开发出多种模型以弥合遥感（RS）图像与文本描述之间的差距。Text2Seg [?] 将 SAM 的 zero-shot 分割能力与 CLIP 及 Grounding DINO 相结合，采用两阶段框架（如 PreSAM 和 PostSAM），实现对 RS 图像的文本引导语义分割。类似地，GeoRSCLIP [?] 与 RS5M 数据集一同发布，是一种专为遥感影像设计的视觉-语言预训练模型。受 CLIP 启发，Li. 等 [?] 提出了一种基于对比视觉-语言监督的遥感场景分类视觉-语言模型（RS-CLIP），而 SatCLIP [?] 则增强了图像与其地理位置之间的对齐，提升了模型的地理空间感知能力。

除了直接的图像-文本对齐外，其他模型利用外部地理空间信息来丰富遥感（RS）图像的理解。SkyScript [?] 利用 OpenStreetMap 数据根据地面采样距离（GSD）对 RS 图像进行标注，从而实现更结构化的地理空间标签方法。与此同时，RemoteCLIP [?] 是一个用于 RS 图像-语言任务的预训练模型，通过现有数据集构建图像-文本对，以增强检索、检测和分割能力。为解决文本标注的 RS 数据稀缺问题，GRAFT [?] 将来自 Flickr 的地理参考地面级图像与相应的 RS 图像及描述配对，有效扩充了可用的训练数据。

在生成式建模领域，基于扩散的方法已成为遥感（RS）应用中的强大工具。DiffusionSat [?] 将元数据（如地理定位信息）融入扩散模型，解决了时间序列生成、从光谱输入进行超分辨率重构以及大规模高分辨率数据集上的图像还原等任务。在此基础上，CRS-Diff [?] 引入了多条件控制机制，通过支持文本、元数据和图像输入，实现了更精确的生成。GeoText [?] 进一步通过将地表覆盖目标与文本描述对齐，增强了空间感知和细粒度理解能力，提升了地理空间数据集的可解释性。

此外，多个模型还探索了图像-位置对齐和多模态数据融合的新策略。GeoCLIP [?] 受图像到 GPS 检索策略的启发，通过利用傅里叶域中的位置编码，将遥感（RS）图像与其对应的 GPS 位置对齐为连续函数。MMM-RS [?] 通过在大规模多模态、多分辨率遥感影像上训练基于 CycleGAN 的模型，推进了文本到图像生成。最后，Text2Earth [?] 是一个基于扩散框架构建的 13 亿参数生成式模型，专为全球尺度遥感场景建模设计，进一步推动了文本条件下的遥感图像合成边界。

8) **异构数据 ↦ 视觉-音频***:* 在视觉-音频融合中，SoundingEarth [?] 利用与遥感（RS）图像匹配的音频数据构建训练样本对。在对比学习框架内，它对齐音频和图像表示，以实现需要多模态理解的任务的有效预训练。

D. 遥感领域基础模型的简要概述

我们总结了单峰值和多模态遥感基础模型，详细介绍了它们对应的出版物、预训练架构、下游应用以及代码可用性。表 III 和 V 分别按单模态和多模态对这些模型进行了分类，提供了关于其架构、实际应用及可用实现的见解，以帮助读者有效区分并利用现有的基础模型。

我们进一步展示了多模态在代表性遥感任务中相对于单峰值基础模型的性能提升，如表 IV 所总结。更具体地说，多模态预训练模型在分类、分割和变化检测任务中始终取得更优的结果。为评估这一改进，我们采用 PANGAEA-Bench，这是一个涵盖 11 个数据集的综合性基准，覆盖语义分割、变化检测和回归任务。这些数据集涵盖了多样的时间情景（单时相、双时相和多时相）、全球地理分布、从每像素 1.5 到 30 米的空间分辨率以及异构传感器模态（RGB、光谱、SAR）。因此，该基准为评估遥感基础模型提供了严格且统一的框架。如表 IV 所示，多模态模型在几乎所有任务中均占据表现最佳的位置。特别是在 CTM-SS 等数据集上，其相较于单峰值模型展现出显著优势，凸显了其在遥感应用中的优越泛化能力和有效性。

表 III

现有单峰值遥感基础模型（如 RGB、光谱数据、SAR）的简明对比，包括对应出版物、预训练架构、下游应用及代码可获取性。CL：对比学习，MAE：掩码自编码器，MIM：掩码图像建模，Diff：扩散模型，JEPA：联合嵌入预测架构，SC：场景分类，SS：语义分割，CD：变化检测，OD：目标检测，SR：超分辨率，AD：异常检测，SU：光谱解混，DN：降噪，IG：图像生成。

Modality	Models	Publications	Architectures	Downstreams	Codes
RGB	Matter [?]	CVPR'23	CL	SC, SS, CD	https://github.com/periakiva/MATTER
	Scale-MAE [?]	ICCV'23	MAE	SC, SS	https://github.com/bair-climate-initiative/scale-mae
	RVSA [?]	TGRS'22	MIM	SC, SS, OD	https://github.com/ViTAE-Transformer/Remote-Sensing-RVSA
	CMID [?]	TGRS'23	CL&MIM	SC, CD, OD	https://github.com/NJU-LHRS/official-CMID
	GFM [?]	ICCV'23	MIM	SC, SS, CD, SR	https://github.com/mmendiet/GFM
	Cross-Scale MAE [?]	NeurIPS'23	MAE	SC, SS	https://github.com/aicip/Cross-Scale-MAE
	MTP [?]	JSTARS'24	Supervised	SS, CD, OD	https://github.com/ViTAE-Transformer/MTP
	Selective MAE [?]	Arxiv'24	MAE	SC, SS, OD	https://github.com/Fengxiang23/SelectiveMAE
	MA3E [?]	ECCV'24	MAE	SC, SS, OD	https://github.com/benesakitam/MA3E
	SatMAE++ [?]	CVPR'24	MAE	SC	https://github.com/techmn/satmae_pp
	RS-Prompter [?]	TGRS'24	Supervised	SS	https://github.com/KyanChen/RSPrompter
	UV-SAM [?]	AAAI'24	Supervised	SS	https://github.com/tsinghua-fib-lab/UV-SAM
	RSAM-Seg [?]	RS'24	Supervised	SS	https://github.com/Chief-byte/RSAM-Seg
	ALPS [?]	TIP'24	Supervised	SS	https://github.com/StriveZs/ALPS
	MeSAM [?]	TGRS'24	Supervised	SS	https://github.com/Magic-lem/MeSAM
	MetaEarth [?]	TPAMI'24	Diff	IG	https://jiupinjia.github.io/metaearth/
Spectral Data	SatMAE [?]	NeurIPS'22	MAE	SC,SS	https://sustainlab-group.github.io/SatMAE/
	DINO-MC [?]	CVPRW'24	CL	SC, CD	https://github.com/WennyXY/DINO-MC
	SpectralGPT [?]	TPAMI'24	MAE	SC, SS, CD	https://github.com/danfenghong/IEEE_TPAMI_SpectralGPT
	MAEST [?]	TGRS'22	MAE	SS	https://github.com/ibanezfd/MAEST
	MAESST [?]	CVPRW'23	MAE	SS	https://github.com/HSG-AIML/MaskedSST/
	HyperSIGMA [?]	TPAMI'25	MAE	SS, AD, OD, CD, SU, SR, DN	https://github.com/WHU-Sigma/HyperSIGMA
	HSIMAE [?]	JSTARS'24	MAE	SS	https://github.com/Ryan21wy/HSIMAE
	HSIGene [?]	Arxiv'24	Diff	IG	https://github.com/LiPang/HSIGene
SAR	FG-MAE [?]	JSTARS'24	MAE	SC, SS	https://github.com/zhu-xlab/FGMAE
	SAR-JEPA [?]	ISPRS'24	JEPA	OD	https://github.com/waterdisappear/SAR-JEPA
	CWSAM [?]	JSTARS'25	Supervised	SS	https://github.com/xypu98/CWSAM
	SARATR-X [?]	TIP'25	MAE	SC, OD	https://github.com/waterdisappear/SARATR-X

表 IV

在 PANGAEA 基准上，单峰值模型与多模态模型的性能对比。每个数据集表现最佳的模型以红色突出显示，第二佳的以蓝色突出显示，第三佳的以下划线标示。

Modality	**Model**	**BurnSr**	**MADOS**	**PASTIS**	**Sen1Fl11**	**FBP**	**DEN**	**CTM-SS**	**SN7**	**AI4Farms**	**Xview2**	**BioMassters**
		Wildfire	*Marine*	*Agriculture*	*Flood*	*Land*	*Land*	*Agriculture*	*CD*	*Agriculture*	*CD*	*Regression*
Unimodal	SatlasNet	79.96	55.86	17.51	90.30	50.97	36.31	46.97	61.88	25.13	52.23	<u>41.67</u>
	Prithvi 1.0	83.62	49.98	33.93	<u>90.37</u>	46.81	27.86	43.07	56.54	<u>26.86</u>	49.35	39.99
	SpectralGPT	80.47	57.99	<u>35.44</u>	89.07	33.42	37.85	46.95	58.86	26.75	48.40	36.11
	S.-S12-MoCo	81.58	51.76	34.49	89.26	<u>53.02</u>	35.44	48.58	57.64	25.38	51.59	40.21
	S.-S12-DINO	81.72	49.37	36.18	88.61	51.15	34.81	48.66	56.47	25.62	50.56	41.23
	S.-S12-MAE	<u>81.91</u>	49.90	32.03	87.79	51.92	34.08	45.80	57.13	24.69	50.44	41.07
Multimodal	RemoteCLIP	76.59	<u>60.00</u>	18.23	74.26	69.19	31.78	52.05	57.76	25.12	57.41	49.79
	CROMA	82.42	67.55	32.32	90.89	51.83	38.29	49.38	59.28	25.65	<u>53.27</u>	36.81
	DOFA	80.63	59.58	30.02	89.37	43.18	39.29	<u>51.33</u>	61.84	27.07	59.64	42.81
	TerraMind	82.42	69.52	40.51	90.62	59.72	<u>37.87</u>	55.80	<u>60.61</u>	28.12	-	-

IV. 如何在遥感下游任务中使用预训练基础模型：教程

遥感领域的预训练基础模型通过在大规模数据集上进行广泛的预训练，为下游任务提供了强大的能力。高效地将这些模型应用于各种任务是遥感研究与实践中的关键关注点。本章提供了一个逐步指南，涵盖模型选择、环境设置、模型加载、微调和部署，为利用遥感基础模型提供了实用方法。这些步骤的详细工作流如图4所示。

表 V

现有遥感多模态基础模型的简明对比，按模态类型分类（如：时序、地理视觉、同质、光学-SAR、异质、视觉-大语言模型、视觉-文本、视觉-音频）。表格详细列出了其对应论文、预训练架构、下游应用及代码可获取性。CL：对比学习，MAE：掩码自编码器，MIM：掩码图像建模，Diff：扩散模型，JEPA：联合嵌入预测架构，SC：场景分类，SS：语义分割，RE：回归，CD：变化检测，OD：目标检测，SR：超分辨率，IG：图像生成，VP：视觉预测，VG：视觉定位，OT：目标跟踪，IR：图像检索，GM：几何测量，PS：全色锐化，REC：指代表达理解，TRE：时间指代表达，RES：指代表达分割，VQA：视觉问答，CR：云去除

Modality	Models	Publications	Architectures	Downstreams	Codes
Time-series	SeCo [?]	ICCV'21	CL	SC, CD	https://github.com/ServiceNow/seasonal-contrast
	CaCo [?]	CVPR'23	CL	SC,SS, CD	https://github.com/utkarshmall13/CACo
	RingMo-Sense [?]	TGRS'23	MAE	OD,VP,OT	https://github.com/
	U-BARN [?]	JSTARS'24	MAE	SS	https://src.koda.cnrs.fr/iris.dumeur/ssl_ubarn
	Prithvi2.0 [?]	Arxiv'24	MAE	SC, SS, VP, GM	https://github.com/NASA-IMPACT/Prithvi-EO-2.0
Geo-Vision	GASSL [?]	ICCV'21	CL	SC, SS, OD	https://github.com/sustainlab-group/geography-aware-ssl
	GeoKR [?]	TGRS'21	CL	SC,SS, OD	https://ieeexplore.ieee.org/abstract/document/9559903
	CSPT [?]	RS'22	MAE	SC, OD	https://github.com/ZhAnGToNG1/transfer_learning_cspt
	GERSP [?]	TGRS'24	CL	SS, IC, OD	https://github.com/floatingstarZ/GeRSP
	SoftCon [?]	TGRS'24	CL	SC, SS, CD	https://github.com/zhu-xlab/softcon?tab=readme-ov-file
Homogeneous	Usat [?]	Arxiv'23	MAE	SC	https://github.com/stanfordmlgroup/USat
	SenPa-MAE [?]	GCPR'25	MAE	SS	https://github.com/JonathanPrexl/SenPa-MAE
	CrossEarth [?]	Arxiv'24	Supervised	SS	https://github.com/Cuzyoung/CrossEarth
	AnySat [?]	CVPR'25	JEPA	SC, SS	https://github.com/gastruc/AnySat
Optical-SAR	RingMo [?]	TGRS'22	MIM	SC, SS, CD, OD	https://github.com/comeony/RingMo
	SatViT [?]	GRSL'22	MAE	SC	https://github.com/antofuller/SatViT
	DINO-MM [?]	IGARSS'22	CL	SC	https://github.com/zhu-xlab/DINO-MM
	RS-BYOL [?]	JSTARS'22	CL	SC, SS	https://github.com/
	CROMA [?]	NeurIPS'23	CL&MAE	SC, SS	https://github.com/antofuller/CROMA
	MANet [?]	Arxiv'24	Supervised	SS	https://github.com/sstary/SSRS
	CSMAE [?]	TGRS'25	MAE	IR	https://github.com/jakhac/CSMAE
Heterogeneous	SatLas [?]	ICCV'23	Supervised	SC, SS, OD, RE, GM	https://github.com/allenai/satlaspretrain_models
	DeCUR [?]	ECCV'24	CL	SC, SS	https://github.com/zhu-xlab/DeCUR
	DOFA [?]	Arxiv'24	MAE	SC, SS	https://github.com/zhu-xlab/DOFA
	msGFM [?]	CVPR'24	MAE	SC, SS, PS, CR	https://github.com/boranhan/Geospatial_Foundation_Models
	OmniSat [?]	ECCV'24	CL&MAE	SC,SS	https://github.com/gastruc/OmniSat?tab=readme-ov-file
	MMEarth [?]	ECCV'24	MAE	SC, SS	https://github.com/vishalned/MMEarth-train
	MM-SAM [?]	Arxiv'24	Supervised	SS	https://xiaoaoran.github.io/projects/MM-SAM
Vision-LLM	RSGPT [?]	ISPRS'25	Supervised	VQA, IC	https://github.com/Lavender105/RSGPT
	GeoChat [?]	CVPR'24	Supervised	VQA, IC, SC, REC, VG, OC	https://github.com/mbzuai-oryx/GeoChat
	SkyEyeGPT [?]	ISPRS'25	Supervised	VQA, IC, REC, REG	https://github.com/ZhanYang-nwpu/SkyEyeGPT
	VHM [?]	AAAI'25	Supervised	SC, VQA, IC, REC, REG, OC, GM	https://github.com/opendatalab/VHM
	RS-LLaVA [?]	RS'24	Supervised	VQA, IC	https://github.com/BigData-KSU/RS-LLaVA?tab=readme-ov-file
	LHRS-Bot [?]	ECCV'24	Supervised	SC, VQA, IC, REC	https://github.com/NJU-LHRS/LHRS-Bot
	EarthGPT [?]	TGRS'24	Supervised	SC, VQA, IC, REC, REG	https://github.com/wivizhang/EarthGPT
	SkysenseGPT [?]	Arxiv'24	Supervised	VQA, IC, REC, REG	https://github.com/Luo-Z13/SkySenseGPT
	RS-Agent [?]	Arxiv'24	Agent	VQA, OC, REG	https://github.com/IntelliSensing/IntelliSensing.github.io
	EarthMarker [?]	TGRS'24	Supervised	VQA, SC, IC, VG, REC	https://github.com/wivizhang/earthmarker
	LHRS-Bot-Nova [?]	ISPRS'25	Supervised	SC, VQA, IC, OD, VG, REG	https://github.com/NJU-LHRS/LHRS-Bot/tree/nova
	UniRS [?]	Arxiv'24	Supervised	VQA, IC, SC, TRE	https://github.com/IntelliSensing/UniRS
	ChangeAgent [?]	TGRS'24	Supervised	CD, TRE	https://github.com/Chen-Yang-Liu/Change-Agent
	RSUniVLM [?]	Arxiv'24	Supervised	VQA, SC, VG, CD, RES, TRE	https://github.com/xuliu-cyber/RSUniVLM
	TEOChat [?]	ICLR'25	Supervised	VQA,REC,TRE	https://github.com/ermongroup/TEOChat
	GeoPixel [?]	ICML'25	Supervised	RES, VQA, VG, OC	https://github.com/mbzuai-oryx/GeoPixel
Vision-Text	RS-CLIP [?]	JAG'23	CL	SC	https://github.com/lx709/RS-CLIP
	RemoteCLIP [?]	TGRS'24	CL	SC, IR, OC	https://github.com/ChenDelong1999/RemoteCLIP
	GeoRSCLIP [?]	TGRS'24	CL	SC, IR	https://github.com/om-ai-lab/RS5M
	GeoCLIP [?]	NeurIPS'23	CL	SC, GM, IR	https://vicentevivan.github.io/GeoCLIP/
	SatCLIP [?]	AAAI'25	CL	SC, GM, IR	https://github.com/microsoft/satclip
	SkyScript [?]	AAAI'24	CL	SC, IR	https://github.com/wangzhecheng/SkyScript
	GeoText [?]	ECCV'24	Supervised	IR, VG, OC	https://multimodalgeo.github.io/GeoText/
	Text2Seg [?]	SIGSPATIAL-W'24	CL	SS	https://github.com/Douglas2Code/Text2Seg
	DiffusionSat [?]	ICLR'24	Diff	IG, SR	https://github.com/samar-khanna/DiffusionSat
	CRS-Diff [?]	TGRS'24	Diff	IG	https://github.com/Sonettoo/CRS-Diff
	Text2Earth [?]	GRSM'25	Diff	IG, IR	https://chen-yang-liu.github.io/Text2Earth
Vision-Audio	Sounding Earth [?]	JAG'23	CL	SC, SS, IR	https://github.com/khdlr/SoundingEarth

A. 选择合适的 RS 基础模型

不同的遥感基础模型在预训练数据、网络结构和模型特征方面表现出独特的特性。因此，选择合适的模型需要根据下游任务的需求进行仔细评估。

首先，考虑预训练数据的来源及其特征，例如所使用的传感器类型、卫星平台、图像维度、通道数量以及数据格式（如整数或浮点数）。这些因素有助于评估模型的预训练数据与下游任务数据需求之间的匹配程度。

其次，模型架构起着至关重要的作用。需评估模型是否采用 Transformer、卷积网络或混合主干结构，以及参数量和计算复杂度，以确保与任务的资源约束相兼容。此外，还需评估该架构是否满足轻量化部署或实时性能的特定需求。

最后，还应考虑模型的独特特征，例如其整合多模态数据或融入时间信息的能力。这些特征可显著提升在特定任务中的表现。

B. 模型配置

选定基础模型后，下一步是根据其文档配置相应的运行环境。核心目标是确保模型所需的各种库和框架正确安装。

大多数遥感基础模型依赖于 Python 和 PyTorch 等深度学习框架。此外，用于处理遥感数据的工具，如 rasterio[2] 此外，GDAL 也常常是必需的。在配置环境时，应特别注意安装与所选模型兼容的框架版本。确保预训练权重已正确下载并存储在指定位置。

正确配置环境对于支持后续任务（如模型加载和微调）至关重要，并能确保整个工作流的可靠运行。

C. 加载预训练的基础模型

加载预训练模型的过程不仅涉及权重的导入，还需解决遥感数据独特特性带来的挑战。若不加以处理，图像尺寸和通道数的变化可能导致预训练模型无法正常工作。

1) 图像维度不匹配的处理:

- **问题：** 预训练模型通常针对固定图像大小（例如，$224 \times 224 \times 3$ ）进行设计，而下游任务中的图像尺寸可能不同（例如，$128 \times 128 \times 3$ ）。
- **解决方案：** (i) 图像缩放或插值：调整输入图像的维度以匹配预训练模型的要求。(ii) 位置编码插值：对于使用位置编码的模型（例如 Transformer），对编码值进行插值，以适应新的输入维度，同时保持空间一致性。

2) 处理通道维度不匹配的问题:

- **问题：** RS 数据在通道数量上通常表现出显著的差异，例如单通道 SAR 图像或具有数十个甚至数百个通道的光谱图像。
- **解决方案：** (i) 通道复制或主成分分析（PCA）降维：通过复制通道或使用 PCA 降低输入维度，以适应模型的需求。(ii) 添加卷积层：在输入阶段引入卷积层，将通道数变换为与预训练模型匹配的数值。(iii) 修改输入层：直接调整模型的输入层以适应新的通道数，确保与特定数据特征的兼容性。

D. 微调与部署基础模型

加载模型后，需要进行微调以适应特定任务。微调策略可以从冻结某些参数并仅训练特定模块（如输入层或输出层）到对整个模型进行完全微调不等。

1) 选择微调策略:

- **资源感知的微调：** 在计算资源有限的场景下，冻结预训练参数，仅调整任务相关的模块，以降低计算开销。
- **全面微调：** 对于需要高准确率的任务或在资源充足的情况下，对整个模型进行微调，以充分优化其在下游任务上的表现。

2) 部署微调后的模型: 微调完成后，模型即可部署以对新数据进行预测。经过微调的模型结合了预训练阶段的泛化能力以及微调阶段的任务特定优化，通常在实际应用中实现更优的准确率和鲁棒性。

E. 教程扩展：面向遥感的视觉-语言基础模型

为何扩展此功能？ 上述教程聚焦于仅视觉的基础模型。然而，许多实际的遥感（RS）应用需要对图像以及文本/元数据信息（例如场景描述、传感器元数据、时间或地理空间属性）进行联合推理。为回应审稿人的关切，我们提供了一份实用的、分步指南，介绍如何在 RS 工作流中采用视觉-语言基础模型（VLFMs）。本节与之前的流水线结构相似，但更强调多模态特性。

1) 第一步：明确任务类型和数据配对:

- **任务分类：** 判断下游任务是否为 图像到文本（图像描述、报告生成）、文本到图像检索、视觉问答

[2]https://github.com/mapbox/rasterio

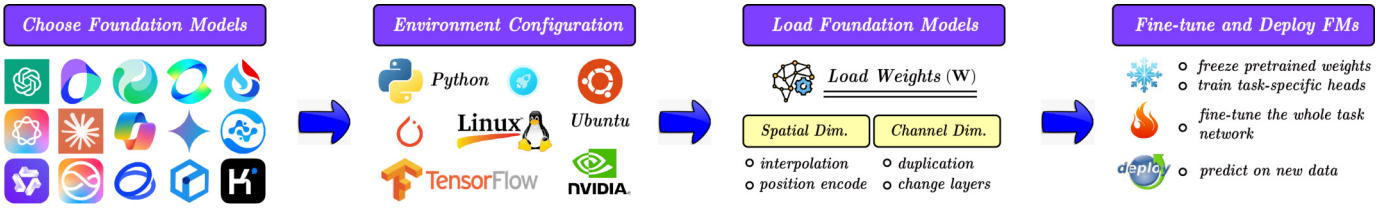

图 4. 在遥感下游任务中应用预训练基础模型的逐步工作流。这一教程式流程从模型选择开始，接着进行环境配置和模型加载，最后完成所选基础模型的微调并部署到具体的遥感应用中。

（*VQA*）、指令遵循/对话，或 带有文本提示的多模态分类/检测。

- **成对数据构建：** 遥感（RS）语料库很少附带丰富的人工编写标题。考虑（i）利用现有元数据（传感器名称、获取时间、地理位置、地表覆盖标签）自动生成弱标题；（ii）使用大模型（LLMs）将噪声元数据提炼为自然语言；以及（iii）采用教师模型（例如，通用视觉-语言模型）为图像生成伪标题，随后通过人工筛选以构建关键数据集。
- **文本粒度：** 决定是否需要逐图像、逐图块或逐对象的文本标注。细粒度的监督通常能提升 VQA/定位性能，但会增加标注成本。

2) 步骤 2: 选择/配置 RS Vision 语言 FM:

- **模型家族：**
  1) 编码器-解码器风格（例如，类似 BLIP-2）：一个冻结的视觉编码器、一个轻量级连接模块（Q-Former / MLP / 交叉注意力），以及一个冻结或部分可调优的大语言模型。
  2) 统一的 *Transformer*（视觉和文本共用单一主干网络），联合编码来自视觉和文本的 token。
  3) *RS-specific VLFMs*（例如类似 GeoChat 的），已适配地理语义和 RS 词表。
- **连接器设计：** 确保连接器能够处理特定于遥感（RS）的视觉 token（例如，多个波段、大尺寸图块）。对于光谱信息丰富的数据，应在前面添加波段 文本 *token*（“Band-11 (SWIR 1.61 µm)”）或波长描述符，以帮助语言模型理解光谱语义。
- **分词器和词表：** 确认传感器名称、地表覆盖类别和地理空间术语存在于分词器中；如果不存在，则扩展词表或通过别名映射到现有 token。

3) 步骤 3: 加载并对齐多模态权重:

- **视觉侧不匹配：** 重用第 IV 节中的图像维度/通道策略（调整大小、位置编码插值、输入适配器）。对于光谱输入，考虑 (i) 光谱分组或 1× 1 卷积，同时 (ii) 将被丢弃/合并波段的文本描述符传递到语言侧以补偿丢失的信息。
- **文本侧初始化：** 首先加载大语言模型的分词器和权重；然后初始化或映射连接器参数。如果连接器需要固定数量的视觉 token，则对图像块 token 进行插值或稀疏采样以匹配。
- **跨模态对齐头：** 一些带有图像-文本对比或匹配头的检查点。在更换编码器或分词器时，验证维度的一致性。

4) 第四步：多模态微调策略:

- **轻量级适配（资源感知）：** 冻结视觉编码器和大语言模型，仅微调（i）连接器（例如，Q-Former），（ii）大语言模型中的 LoRA/适配器层，以及/或者（iii）一个浅层的光谱通道投影。这对于检索和字幕生成通常已足够。
- **指令微调：** 对于视觉问答或对话式任务，整理指令-响应对（关于遥感场景的问题，以及基于图像内容的答案）。应用监督微调（SFT），若具备人类偏好数据，可选地进行偏好最优化（DPO/RLHF）。
- **多任务调度：** 结合图像-文本对比损失、图像条件语言模型化以及多语言目标（例如英语/中文）以增强泛化能力。

5) 第五步：部署与提示:

- **提示设计：** 提供结构化提示以揭示遥感上下文：“你是一名遥感分析师。根据一幅哨兵-2 影像（10 米空间分辨率，波段：B2、B3、B4、B8），回答问题。”。此类明确提示可减少幻觉。
- **推理效率：** 对于大模型，可通过压缩得到更小的语言头或缓存键值状态以应对重复查询。在视觉方面，可预先计算图像嵌入并对其进行索引，以支持检索任务。
- **评估：** 除了标准的自然语言处理指标（BLEU、

CIDEr）外，对于安全关键任务，还应采用考虑遥感（RS）特性的度量方法（如土地覆盖准确率、地理空间定位准确率）以及人工专家评估。

要点. 将 VLFM 集成到 RS 流水线中需要（1）构建或整理可靠的图像-文本配对，（2）选择合适的多模态架构/连接器，（3）仔细对齐光谱/空间 token 与文本描述符，以及（4）采用资源敏感的微调和提示策略。遵循这些步骤可实现稳健的跨模态理解与交互，适用于实际的 RS 应用。

F. 基础模型的计算资源

为了帮助读者或潜在研究人员根据其计算资源选择合适的基座模型，我们在表 VI 中总结了遥感基座模型的代表性骨干架构。除非另有说明，所有数值均在以下一致假设下计算（或重新计算）：*(i)* 单次前向传播，*(ii)* FP32 精度，*(iii)* 批量大小为 1，以及 *(iv)* 输入分辨率为 $3 \times 224 \times 224$（适用于基于 CNN、ViT 和 Swin 的模型）。对于 SAM 变体，FLOPs 按照 SAM 论文中指定的原始输入设置（1024×1024）报告。FLOPs 表示每次前向传播的浮点运算次数；当报告乘加操作（MACs）时，我们通过乘以 2 将其转换为 FLOPs。参数数量（“Params”）指可学习权重的总数，而“推理内存”表示在 NVIDIA GPU 上实测的值域范围，该值可能因驱动程序、PyTorch 版本和活性值检查点设置的不同而有所变化。对于广泛研究的模型（例如 ResNet-50、ViT-B/L/H、Swin-T/B/L），我们采用官方或普遍接受的参考实现。

我们还报告了主流开源基础模型在遥感领域的计算性能，以补充骨干网络层面的总结，如表 VI 所示。此外，表 VII 列出了各模型的复杂度（以 GMacs 为单位）、可训练参数数量以及总参数量，数据来源于 PANGAEA-Bench 发布版本。除非另有说明，所有 GMacs 均在基准测试默认输入配置下，以单次前向传播中的乘加操作数衡量（1 MAC = 2 FLOPs）。“可训练参数”指在下游任务微调过程中更新的权重子集。该表格旨在帮助读者在选择当前主流遥感基础模型时，权衡潜在准确率提升与计算成本之间的关系。

V. 结论

基础模型通过从大规模异构数据源中实现可扩展且可迁移的学习，彻底改变了遥感领域。早期的遥感基础模型主要关注单峰值表示，在单一传感模态内学习通用特征。近年来，这一范式已演变为多模态基础模型，能够联合利用光学 RGB、合成孔径雷达（SAR）、光谱、激光雷达以及辅助数据源之间的互补信息。通过大规模预训练和任务自适应微调，这些模型为图像分类、目标检测、语义分割、变化检测等众多下游任务建立了一个统一而稳健的框架。

此外，本综述还采用了教程导向的视角，系统地概述了在遥感应用中有效利用预训练基础模型的关键步骤，包括模型选择、环境配置、模型加载、微调和部署。每个步骤都需要仔细考虑遥感数据的独特特性、计算约束以及领域特定的挑战，以确保模型具备稳健的性能和实际的适应能力。

VI. 未来方向与挑战

尽管取得了显著进展，遥感领域基础模型的发展仍面临若干有待进一步研究的开放性挑战：

- **缩放法则与模型增长：**理解缩放法则在遥感领域的基础模型中是否成立，对于指导模型开发、优化数据需求以及平衡计算效率与性能至关重要。
- **定义通用性与模型标准：**未来的研究应建立明确的标准，以确定什么是通用的或足够大的遥感基础模型，并阐明此类模型是否必须为自监督的。
- **预训练模型的比较分析：**需要更深入地研究为何在许多情况下，随机权重或在其他领域上预训练的模型能够取得与现有的遥感特定基础模型相当的结果。
- **灾难性遗忘与知识保留：**解决训练好的遥感基础模型中的灾难性遗忘问题对于确保长期适应性和高效持续学习至关重要。
- **数据管理与可扩展性：**管理大规模遥感数据，包括预处理、标注和高效存储，仍然是一个瓶颈。未来的研究应探索标准化框架和策略，以促进遥感基础模型的可扩展发展。
- **多模态适应性与开放协作：**提升模型对多样化遥感数据模态的适应能力，并促进预训练模型、数据集和基准的共享与协作，将加速整个社区的创新进程。
- **鲁棒性与不确定性：**未来的遥感基础模型应超越事后鲁棒性评估（例如，REOBench [**?**]），转向具备鲁棒性意识和不确定性意识的预训练，显式建模传感器噪声、领域偏移以及极端条件。融入不确定性量化（例如，概率表示或受贝叶斯启发的学习）将

表 VI
遥感领域基础模型代表性主干架构的计算资源。

Model	Architecture	Params (M)	FLOPs (G)	Inference Memory (GB)
ResNet-50	ResNet-50	25.6	4.1	1–2
ViT-Base	ViT-B/16	86.0	17.6	2–4
ViT-Large	ViT-L/16	304.0	61.6	4–8
ViT-Huge	ViT-H/14	632.0	190.7	8–12
SAM-B	ViT-B/16 (SAM)	91.0	22.0	2–4
SAM-L	ViT-L/16 (SAM)	308.0	62.0	4–8
SAM-H	ViT-H/14 (SAM)	641.0	200.0	8–12
Swin-T	Swin-T	28.3	4.5	1–2
Swin-B	Swin-B	87.8	15.4	2–4
Swin-L	Swin-L	197.3	34.5	4–6

表 VII
遥感领域代表性基础模型的计算统计量。

Model	FLOPs (G)	Trainable Params (M)	Total Params (M)
CROMA	278.46	46.95	350.0
DOFA	130.04	39.35	150.9
GFM-Swin	38.10	33.71	120.4
Prithvi	129.70	39.34	125.7
RemoteCLIP	35.14	39.35	16.8
SatlasNet	33.40	33.25	121.2
Scale-MAE	207.54	46.95	350.1
SpectralGPT	761.38	164.40	249.8
S12-MoCo	93.80	30.89	53.5
S12-DINO	95.86	30.89	53.5
S12-MAE	93.80	30.89	53.5
S12-Data2Vec	93.78	30.89	53.5

对于实现可靠决策和风险感知的现实地球观测应用部署至关重要。

通过应对这些挑战，基础模型将继续推动遥感技术的发展，实现更精准的环境监测、可持续的资源管理以及对地球动态过程更深入的洞察。

VII. 主要缩写

为便于理解，我们将文中使用的所有缩写汇总如下。希望此列表能帮助读者更方便地查找和理解这些缩写。

CNNs: convolutional neural networks
CROMA: contrastive radar-optical masked autoencoders
CSPT: consecutive pretraining
CWSAM: class-wise SAM
DOFA: dynamic one for all
EO: Earth observation
FG-MAE: feature guided masked autoencoders
GASSL: geography-aware self-supervised learning
GDAL: geospatial data abstraction library
GeoKR: geographical knowledge-driven representation learning
GFM: geospatial foundation models
GRAFT: ground remote alignment for training
GSD: ground sampling distance
HOGs: histograms of oriented gradients
LoRA: low-rank adaptation
LMM: large language models

MAE:	masked autoencoders
MAF-SAM:	multistage adaptation fine-tuning segme anything model
MANet:	multimodal adapter-based network
MATTER:	material and texture representation lea
MLP:	multilayer perception
msGFM:	multisensor geospatial foundation model
omniSat:	omni satellite
OFA-Net:	one for all network
RingMo:	remote sensing foundation model
RNNs:	recurrent neural networks
RS:	remote sensing
RS-BYOL:	remote sensing bootstrap your own late
RS-DFM:	remote sensing distributed foundation m
RVSA:	rotated varied-size attention
S2MAE:	spatial-spectral masked autoencoders
SatMAE:	satellite masked autoencoders
SatViT:	satellite vision transformer
SpectralGPT:	spectral generative pretrained transform
SAM:	segment anything model
SAR:	synthetic aperture radar
SARATR-X:	SAR automatic target recognition
SAR-JEPA:	SAR joint-embedding predictive archite
SeaMo:	seasonal and multimodal foundation mo
SenPa-MAE:	sensor parameter masked autoencoders
SoftCon:	soft contrastive learning
ViTs:	vision transformers

VIII. 致谢

本工作得到了中国国家自然科学基金（项目编号 42271350）和中国科学院国际合作伙伴计划（项目编号 313GJHZ2023066FN）的资助。GCV 感谢欧洲研究理事会（ERC）通过 USMILE 项目（协议编号 855187）以及欧盟委员会通过 HORIZON 项目 ELIAS（协议编号 101120237）和 ELLIOT（协议编号 101214398）提供的支持。

Danfeng Hong (IEEE Senior Member) 2019 年于德国慕尼黑工业大学（TUM）地球观测中的信号处理（SiPEO）专业获得工学博士（summa cum laude）学位。现任中国南京东南大学教授，此前曾担任中国科学院航空航天信息研究院教授。研究方向包括人工智能、多模态感知、基础模型、高光谱遥感与地球科学。

洪博士担任 IEEE 模式分析与机器智能汇刊（TPAMI）、IEEE 图像处理汇刊（TIP）以及 IEEE 地球科学与遥感汇刊（TGRS）的副编辑。自 2022 年起，他连续被科睿唯安评为高被引科学家。

Chenyu Li 2018 年、2021 年和 2025 年分别获得中国南京东南大学学士、硕士和博士学位。她的研究兴趣包括可解释人工智能、大地球数据预测、基础模型和高光谱成像。

李博士在 WHISPERS2025 会议上荣获杰出学生论文奖（Paul Gader 奖），并获得 IEEE 地球科学与遥感汇刊（TGRS）最佳审稿人奖。

Xuyang Li 2023 年获得中国电子科技大学光电信息科学与工程学院学士学位，现于中国科学院空天信息研究院攻读博士学位，研究方向包括机器学习、遥感基础模型和多模态解译。

古 斯塔乌 · 坎普斯-万尔斯（IEEE 会士）是西班牙瓦伦西亚大学电气工程学院的全职教授，专注于人工智能与机器学习在环境与气候挑战中的应用。他领导图像与信号处理（ISP）研究组，致力于地球与气候科学中的人工智能研究。其研究涵盖利用人工智能预测极端事件、提升地球系统模型以及理解气候变化对社会的影响，如气候引发的移民问题。他是高被引研究人员（2011 年，2021–2024 年），曾获谷歌经典论文奖（2019 年）等多项荣誉。他曾担任 IEEE IGARSS 2018 和 AISTATS 2022 程序主席，五份 IEEE 期刊的副编辑，并任 IEEE 杰出讲者（2017–2019 年）。他是 IEEE、ELLIS、欧洲科学院（EurASc）、欧洲科学院（Academia Europaea）及人工智能协会（AAIA）会士。他在多个机构担任顾问角色，包括欧空局 PhiLab 和欧洲气象卫星组织（EUMETSAT），并负责协调 ELLIS 在地球与气候科学领域的人工智能计划。他已获得两项欧洲研究理事会（ERC）资助项目（巩固者与协同研究类），以推动人工智能在地球与气候科学中的发展。

Jocelyn Chanussot (IEEE Fellow) 1995 年获得法国格勒诺布尔理工学院（Grenoble INP）电气工程硕士学位，1998 年获得法国尚贝里大学（Université de Savoie）博士学位。1999 年至 2023 年期间，他在格勒诺布尔理工学院任职，担任信号与图像处理教授。目前为法国国家信息与自动化研究所（INRIA）格勒诺布尔研究中心的研究主任。他的研究兴趣包括图像分析、高光谱遥感、数据融合、机器学习和人工智能。

陈博士是 IEEE 地球科学与遥感法国分会的创始主席。他曾担任 IEEE 地球科学与遥感学会副主席，负责会议与研讨会事务。他是《IEEE 地球科学与遥感汇刊》、《IEEE 图像处理汇刊》以及《美国电气电子工程师学会会刊》的副编辑。2011 至 2015 年间，他担任《IEEE 精选主题在应用地球观测与遥感期刊》主编。他是 IEEE 会士、ELLIS 会士、美国人工智能协会会士，2012 至 2017 年期间为法国大学研究院成员，自 2018 年起连续被评为高被引研究人员（科睿唯安/汤森路透）。