https://hjfy.top/arxiv/2502.09356

Galileo：学习多种遥感模态的全局与局部特征

Gabriel Tseng [*1 2 3] **Anthony Fuller** [*4] **Marlena Reil** [1 2] **Henry Herzog** [3] **Patrick Beukema** [3] **Favyen Bastani** [3] **James R. Green** [4] **Evan Shelhamer** [4 5 6] **Hannah Kerner** [†7] **David Rolnick** [†1 2]

Abstract

我们引入了一种高度多模态的 Transformer，用于在时空范围内表示多种遥感模态——多光谱光学、合成孔径雷达、高程、气象、伪标记等。这些输入对多种遥感任务非常有用，例如作物制图和洪水检测。然而，由于相关数据模态的多样性，且感兴趣目标的尺度差异巨大（从小型船只（1–2 像素且快速）到数千像素且缓慢的冰川），学习遥感数据的共享表示具有挑战性。我们提出了一种新颖的自监督学习算法，通过掩码建模在灵活的一组输入模态中提取多尺度特征。我们的双全局与局部对比损失在目标（深层表示与浅层输入投影）和掩码策略（结构化与非结构化）上有所不同。我们的 **Galileo** 是一个单一的通用模型，在十一项基准测试和多个任务中，其性能优于当前最先进的专用模型，适用于卫星图像和像素时间序列。

[*]Equal contribution [†]Equal Supervision [1]Mila – Quebec AI Institute [2]McGill University [3]Allen Institute for AI (Ai2) [4]Carleton University [5]University of British Columbia [6]Vector Institute [7]Arizona State University. Correspondence to: Gabriel Tseng <gabriel.tseng@mail.mcgill.ca>.

Proceedings of the 42nd International Conference on Machine Learning, Vancouver, Canada. PMLR 267, 2025.
Copyright 2025 by the author(s).

1. 引言

学习大规模多模态遥感与地理空间数据的表示是长期存在的科学与实践目标。这一目标源于机器学习（ML）和遥感（RS）在社会重要领域（例如粮食安全 (Kerner et al., 2020) 和灾害响应 (Frame et al., 2024)）中日益增长的影响，而在这些领域中获取标签的成本高昂或极为困难 (Kebede et al., 2024)。

自监督学习（SSL）可以使得利用遥感中大量未标记数据成为可能。然而，现有的遥感 SSL 方法 (Jean et al., 2019; Manas et al., 2021) 已被专门用于特定的输入模态或形状，例如像素时间序列与图像时间序列，这遵循了从图像 (Chen et al., 2020; He et al., 2022) 和文本 (Devlin et al., 2018) 中学习的开创性方法。简而言之，这些方法创建输入的两个版本（“视图”），并预训练模型以根据其中一个视图预测另一个视图。预训练之后，学成的表示可以通过微调或作为特征重用，转移到实际任务中，即使标签或计算资源有限也是如此。我们统一了遥感实践中使用的多种模态和输入形状的 SSL，从而得到一个对图像和像素时间序列都具有*灵活性*的模型。

在时空尺度上，卫星影像涵盖了各种空间和时间尺度的对象。常见的分辨率是每像素 10 米，每月 6 次获取。因此——与大多数自然图像（例如 ImageNet (Deng et al., 2009)）或视频（例如 Kinetics-400 (Kay et al., 2017)）不同——遥感中的一个对象（如一艘小型渔船）可能仅由遥感影像中的一个 *单像素*表示，并且可能只出现在一个 *单帧*中 (Beukema et al., 2023)。相反，一个对象可能是一个千米级的冰川，需要跨数十年进行追踪 (Baraka et al., 2020)。

第二个挑战来自于遥感（RS）中使用的传感器数量和种类，其中大多数方法在处理的数据类型上灵活性有限。许多方法仅对多光谱光学（MS）数据 (Cong et al., 2022; Noman et al., 2024; Nedungadi et al., 2024)、合成孔径雷达（SAR）数据 (Wang et al., 2024b;a)，或联合的 MS 与 SAR 数据 (Fuller et al., 2024; Xiong et al., 2024) 进行建模，而无法处理其他模态，也无法跨时间建模。另一些方法虽能对跨时间的 MS 数据进行建模，但不涉及其他模态 (Bastani et al., 2023; Szwarcman et al., 2024)。限制学习过程中对地球观测的视角数量和多样性，可能会限制所得表示在预测和分析中的实用性与通用性。这可能会影响迁移能力，无论是否进行微调，尤其在不进行微调的情况下，对于应用型和跨学科实践者而言，计算上更具可行性。

为应对上述两个挑战，我们提出 **Galileo**，一种面向多种模态（光学、雷达等）、尺度以及形状（像素时序、图像时序、单张图像）的遥感数据的新模型家族。我们的模型能够学习地球观测任务中具有*多模态、多尺度且灵活的表示*，并在当前最先进的下游任务结果上取得优异表现。这一目标通过以下两点实现：(i) 一种新颖的自监督学习（SSL）算法，该算法将掩码数据建模框架扩展至学习“局部”与“全局”特征的有用表示；(ii) 一个全局采样、高度多模态的预训练数据集，其中包含因在多样化遥感任务中广泛应用而特别选取的输入。

我们展示了 Galileo 在涵盖多种应用、领域和遥感数据类型的广泛基准测试中的准确率。具体而言，我们的 Galileo-Base 模型在性能上优于针对图像优化的更大规模遥感模型，如 SatMAE (Cong et al., 2022) 和 CROMA (Fuller et al., 2024)；在使用相同权重的情况下，Galileo-Base 还优于针对像素时序数据优化的遥感模型，如 Presto (Tseng et al., 2023)。

2. 全局、局部、多模态自监督

我们收集了一个大规模、丰富的多模态遥感数据集，该数据集专门针对地理和语义多样性进行采样（第2.3节）。为了在不同时空尺度下学习该数据集中多种模态的丰富表示，我们设计了一种新颖且高效的自监督学习算法，以同时学习局部和全局特征。

2.1. 方法直觉

Galileo 通过 两个掩码数据建模目标来学习表示：我们的 **全局** 和 **局部** 任务（图 2）。掩码建模将输入 $\mathbf{x}$ 分割为被掩码的“目标” $\mathbf{x}_t$ 与“可见”视图 $\mathbf{x}_v$，然后从可见部分预测被掩码的部分。我们利用 Transformer 架构对遥感数据的深层和浅层表示进行掩码建模。作为 Transformer 模型，该模型需要对其输入进行 tokenization（第 2.2.1 节）。我们的掩码和预测是在潜在 token 上进行的，而非像素上。

我们的 **全局** 和 **局部** 目标在目标和掩码方面有所不同，如下所述。

深度目标 → 全局特征；浅层目标 → 局部特征. 我们的目标预测发生在潜在空间中，因此我们通过将目标输入 $\mathbf{x}_t$ 输入到一个“冻结”的编码器（第 2.2.3 节）来构建目标 token。我们通过使用冻结编码器处理目标输入 $\mathbf{x}_t$ 来构建 **全局** 目标。我们通过使用一个最小的线性层处理目标输入 x_t 以匹配维度来构建 **局部** 目标。**直观上，更深的表示由于注意力带来的更多非局部处理而更具全局性，而更浅的表示由于对输入的处理较少而更具局部性**。伽利略通过同时在深度和浅层目标上进行预训练，学习了全局和局部特征的表示。

时空掩码 → 全局特征；非结构化掩码 → 局部特征. 掩码决定了哪些 token 可见，即哪些用作输入，哪些用作目标输出（第 2.2.2 节）。掩码的选择对于学成的表示至关重要，因为它决定了所需预测的类型和难度。**直观上，较大的掩码需要更大或更全局的预测，而较小的掩码需要更小或更局部的预测**。因此，我们专门设计 **全局掩码** 通过较长的跨度划分可见与目标 token，采用相关的“时空”掩码方式，并专门设计 **局部掩码** 将可见与目标 token 均匀随机划分。在预训练过程中，Galileo 通过同时应用全局结构化掩码（较长跨度）和非结构化局部掩码（较短跨度），学习多尺度特征。

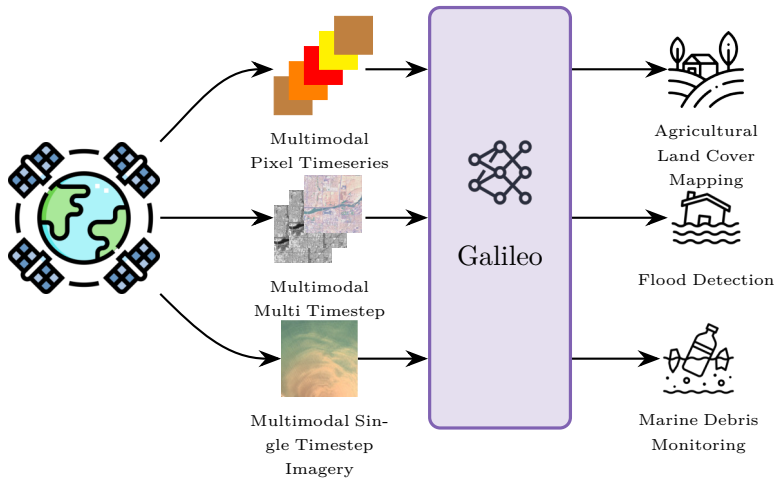

Figure 1. 一个单一的 Galileo 模型可以应用于广泛的遥感任务。我们通过在不同应用中从业者使用的遥感模态的多样性上训练 Galileo 来实现这一点。此外，我们还训练 Galileo 处理从业者使用的这些模态的视图，包括像素时间序列、多时相影像到单时相影像。

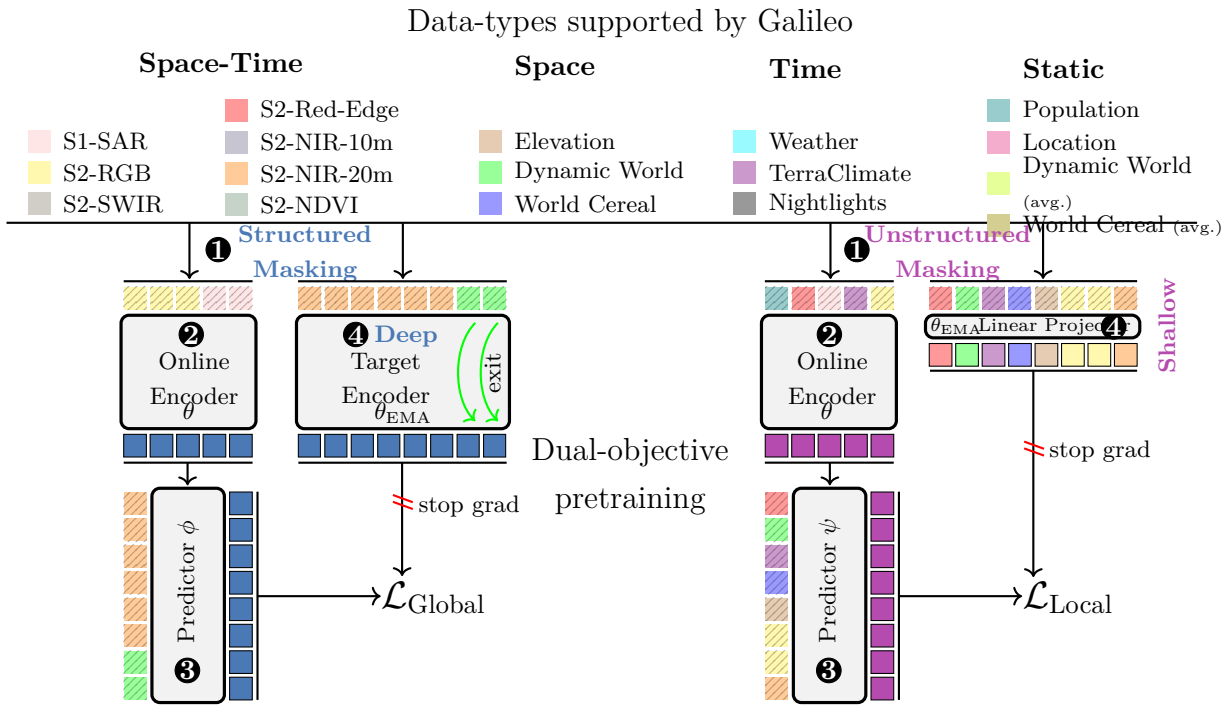

Figure 2. 我们使用 全局（左） 和 局部（右） 的预训练损失来训练 Galileo。黑色轮廓的 token 为模型输出，黑色条纹的 token 为模型输入。步骤：❶ 从数据集中采样并进行掩码处理（结构化左，非结构化右），❷ 编码“可见”token，❸ 给定目标查询和可见编码预测目标，❹ 使用停止梯度对目标进行编码（深层左，浅层右），以及 ❺ 计算样本内 token 的对比损失。

2.2. 方法细节

2.2.1. 输入 Token 化

我们的视觉 Transformer（ViT）架构需要通过分词将遥感输入转换为一系列 token。我们的编码器将输入分割为空间方阵、时间步以及通道组（与遥感产品中相关通道子集有关，例如哨兵-2 数据中的 10 米通道组）。然后通过以下变换将这些输入投影到编码器维度 D：(i) 时空数据，$\mathbb{R}^{H\times W\times T\times C} \to \mathbb{R}^{\frac{H}{P}\cdot\frac{W}{P}\cdot T\cdot G\times D}$，$H$ 为高度，W 为宽度，P 为块大小（每边像素数），T 为时间步数，C 为通道数，G 为通道组数。(ii) 空间数据，$\mathbb{R}^{H\times W\times C} \to \mathbb{R}^{\frac{H}{P}\cdot\frac{W}{P}\cdot G\times D}$，(iii) 时间数据，$\mathbb{R}^{T\times C} \to \mathbb{R}^{T\cdot G\times D}$，以及 (iv) 静态数据，$\mathbb{R}^{C} \to \mathbb{R}^{G\times D}$。

Token 嵌入。经过这些线性投影后，我们的编码器创建了空间和时间正弦位置嵌入、可学习通道嵌入以及月份嵌入，以支持季节性推理；我们将这些 token 位置嵌入表示为 $\mathsf{e} \in \mathbb{R}^{L\times D}$，其中 L 为 token 序列长度。我们的编码器将这些嵌入加到已计算的线性投影上。它沿序列维度连结所有通道组——形成我们的输入序列，$\mathbf{x} \in \mathbb{R}^{L\times D}$。

除了我们自定义的分词方式以及可调整大小的线性投影权重 (Beyer et al., 2023) 外，我们的 Transformer 架构仍与标准 ViT 兼容。这使得其使用简单且在输入序列长度、不同通道组以及其他数据源间的差异方面具有高度灵活性。

2.2.2. 通过掩码构建输入

给定输入 $\mathbf{x}$，我们构建一个“可见”视图 $\mathbf{x}_v \in \mathbb{R}^{L_v\times D}$ 和一个“目标”视图 $\mathbf{x}_t \in \mathbb{R}^{L_t\times D}$。对于全局和局部任务，目标都是根据可见 token 预测目标 token。然而，我们的掩码策略（即控制视图构建的规则）在不同任务之间有所不同。

通过空间和时间掩码获得全局特征。 “空间掩码”在保持时间一致性的同时，随机采样空间上的 token；“时间掩码”在保持空间一致性的同时，随机采样时间上的 token。在两种情况下，我们选择需要编码 或解码的模态。该策略增加了可见 token 与目标 token 之间的距离。

通过非结构化掩码获取局部特征。 非结构化掩码以相同的概率随机采样 token，与它们的空间、时间或通道分组位置无关。该策略最小化可见 token 与目标 token 之间的平均距离。

2.2.3. 编码可见和目标 token

输入。我们的“在线”编码器为可见 token 计算编码，$\mathbf{z}_v = \mathbf{E}(\mathbf{x}_v)$。该模型的参数通过梯度下降进行更新。

目标. 我们的“目标”编码器为目标 token 计算编码，$\mathbf{z}_t = \mathbf{E}_{\text{EMA}}(\mathbf{x})$。该模型的参数通过计算在线编码器的指数移动平均来更新；这种使用 EMA 的方式在自监督学习（SSL）中很常见 (Chen et al., 2021; Assran et al., 2023)。与先前的工作不同，Galileo 训练根据任务的不同（**全局** 与 **局部**），选择不同的深度（编码器层）作为目标。

通过深度目标获得全局特征。 我们以 ℓ^{th} 层后的 token 表示为目标，其中 ℓ 根据模态而变化。我们根据每种模态的处理层级选择 ℓ：伪标记仅使用线性投影（无编码器层），Sentinel-1 和 Sentinel-2 使用全部编码器层，其他通道使用一半的编码器层。我们将特定层级的目标编码器记为 $\mathbf{E}^{\ell}_{\text{EMA}}$。

通过浅层目标的局部特征。我们针对最低表示层级：输入空间。为了兼容维度，我们使用目标编码器的线性投影来计算目标，$\mathbf{E}^{proj}_{\text{EMA}}$ 该投影将所有 token 映射到嵌入维度 D。此策略 *跳过了所有更深层次的处理*。

2.2.4. 预测 & 计算损失

一个预测器 Transformer $\mathbf{P}$ 接收目标 token 的位置、时间、月份和通道组嵌入 e_t，并通过交叉注意力机制对可见编码进行查询，以预测补丁编码 $\mathbf{p}_t$，即 $\mathbf{p}_t = \mathbf{P}(\mathsf{e}_t, \mathbf{z}_v)$。最后，将预测结果 $\mathbf{p}_t$ 与目标值 $\mathbf{z}_t$ 进行比较，以计算损失 $\mathcal{L}(\mathbf{p}_t, \mathbf{z}_t)$，进而更新在线编码器。

我们对两个任务均使用“块判别”损失（PatchDisc

Table 1. 与现有的预训练遥感模型相比，Galileo 模型在性能和灵活性方面均表现最佳。**性能**通过表 15、16 & 17 中图像任务的排名（数值越低越好）以及表 6 中像素时序任务的排名来衡量。为清晰起见，我们为每种方法选取了最优架构；完整排名详见表 18。**灵活性**通过记录模型支持的输入类型来衡量：多光谱（MS）、合成孔径雷达（SAR）、其他遥感模态（+modalities）、具有空间维度的输入以及时间步数超过 1 或 4 的输入。相较于专注于图像的模型（如 CROMA）和专注于像素时序的模型（如 Presto），Galileo-Base 是性能最佳的模型。

		Rank ↓		Supported Inputs					
Method	Arch.	Images	Pixel-timeseries	MS	SAR	+modalities	Spatial dims	> 1 timestep	> 4 timesteps
SatMAE	ViT-Large	10.4	N/A	✓			✓		
SatMAE++	ViT-Large	10.9	N/A	✓			✓		
CROMA	ViT-Base	4.3	N/A	✓	✓		✓		
SoftCon	ViT-Base	5.9	N/A	✓	✓		✓		
DOFA-v1	ViT-Large	9.4	N/A	✓	✓		✓		
Satlas	Swin-Tiny	12.9	N/A	✓			✓	✓	
MMEarth	CNN-atto	12.3	N/A	✓			✓		
DeCUR	ViT-Small	8.3	N/A	✓	✓		✓		
Prithvi 2.0	ViT-Large	11.7	N/A	✓			✓	✓	
AnySat	ViT-Base	11.1	4.5	✓	✓	✓	✓	✓	✓
Presto	ViT-Presto	N/A	3.0	✓	✓	✓		✓	✓
Galileo	ViT-Nano	10.9	3.5	✓	✓	✓	✓	✓	✓
Galileo	ViT-Tiny	6.4	2.3	✓	✓	✓	✓	✓	✓
Galileo	ViT-Base	**3.0**	**1.8**	✓	✓	✓	✓	✓	✓

(Wei et al., 2024))，该损失在输入内的 token 之间应用 InfoNCE 损失：

$$\mathcal{L}(\mathbf{u},\mathbf{v}) = \frac{1}{L_i}\sum_j^{L_i} \log \frac{\exp(\text{sim}(\mathbf{u}_{i,j},\mathbf{v}_{i,j})/\tau)}{\sum_j^{L_i}\exp(\text{sim}(\mathbf{u}_{i,j},\mathbf{v}_{i,j})/\tau)}$$

使用 Softmax 温度 τ ，输入索引 i ，token 索引 j ，i^{th} 输入中的 token 数量 L_i ，以及 l_2 规范化的点积 $\text{sim}(\mathbf{u},\mathbf{v}) = \mathbf{u}^\top\mathbf{v}/\|\mathbf{u}\|\|\mathbf{v}\|$ 。

通过输入对比学习增强局部特征。 我们通过将像素的线性投影应用于输入的浅层表示，设计了一个具有挑战性的自监督任务，该任务使用 PatchDisc。预测器必须输出与相同位置像素相似但与其他位置像素不相似的 token。这不同于重构方法（如 MAE (He et al., 2022)），后者通过均方误差预测像素，但不会使序列中其他像素相互排斥。这也不同于联合嵌入方法（如 LatentMIM (Wei et al., 2024) 或 I-JEPA (Assran et al., 2023)），后者仅针对深层表示进行目标优化。

最后，我们对 **全局** 和 **局部** 损失进行平均：

$$\mathcal{L}_{Galileo} = \frac{1}{2}(\mathcal{L}_{Global} + \mathcal{L}_{Local})$$

Table 2. 伽利略的联合算法保留了我们本地算法的输入内多样性，并在我们的全局与本地算法之间实现了输入间多样性。多样性在欧空局训练数据上通过 1 − cosine similarity 进行衡量。

Pretraining Objective	Within-input Diversity	Between-input Diversity
Global only	0.10	0.25
Local only	0.34	0.14
Combined	0.35	0.19

2.2.5. 测量学成表示

我们通过实验验证关于全局任务和局部任务的直觉：**全局**任务应促进**输入间**特征多样性，而我们的**局部**任务应促进**输入内**特征多样性。对于所有 EuroSat 训练输入，我们通过计算 token 表示之间的余弦相似度 $\mathbf{z} \in \mathbb{R}^{L\times D}$，衡量特征在单个输入内部的差异程度（即局部差异）。类似地，我们通过计算全局平均 token 表示之间的余弦相似度 $\mathbf{z} \in \mathbb{R}^{D}$，衡量特征在不同输入之间的差异程度（即全局差异）。我们的局部任务增强了输入内部特征，而全局任务增强了输入间特征（表2）。我们在第4.1节的下游任务中确认了这些直觉。

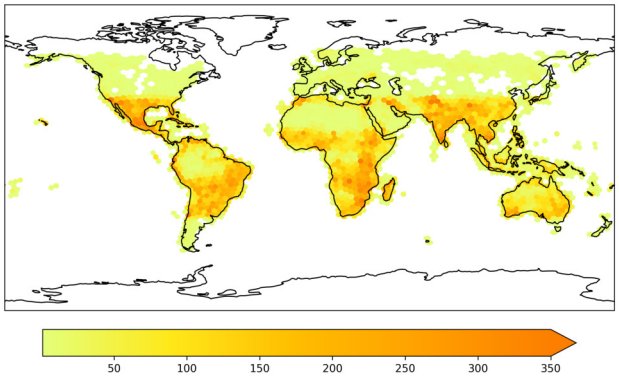

Figure 3. 每个 H3 单元 (Uber, 2018) 在分辨率 = 2 下的训练样本数量。我们从全球范围内采样以保证地理和语义多样性（以 WorldCover 类别 (Zanaga et al., 2022) 为衡量标准）。

2.3. 伽利略的预训练数据

我们收集了一个包含 127,155 个实例的大型全球预训练数据集。图 3 展示了训练点的分布。我们包含了广泛的遥感输入，以支持多样化的应用需求。每个实例包含 4 种类型的数据，覆盖 9 种遥感数据模态。我们根据这些模态在机器学习用于遥感任务中的用途进行选择 (Van Tricht et al., 2023; Beukema et al., 2023; Poggio et al., 2021)。第 B.1 节描述了我们完整的数据采样过程。

我们根据模态在空间、时间、两者或均不上的变化情况对其进行分组。一个实例包含 24 个月时间步和 96×96 个像素，分辨率为 10 m/像素。

时空变化数据。这些数据由 Sentinel-1 & -2 卫星获取的影像组成。对于 Sentinel-1，我们采用 VV 和 VH 极化；对于 Sentinel-2，我们采用所有波段，但不包括 B1、B9 和 B10 波段。所有波段均重采样至 10 m/pixel 分辨率。我们还包含来自 Sentinel-2 的 NDVI (Tucker, 1979) 作为输入。

空间变化数据。这些数据包括由航天飞机雷达地形测绘任务 (NASA JPL, 2000) 捕获的高程和坡度，这些数据在时间上是恒定的；随时间平均以保证时间一致性的动态世界土地覆盖地图概率 (Brown et al., 2022)；以及世界谷物农业土地覆盖地图 (Van Tricht et al., 2023)。

时变数据。这些数据包括来自 ERA5 数据集的降水和温度 (Hersbach et al., 2020)；来自 TerraClimate 的气候水分亏缺、土壤湿度和实际蒸散量 (Abatzoglou et al., 2018)；以及 VIIRS 夜间灯光数据 (Elvidge et al., 2017)。尽管这些模态在空间上也存在变化，但它们的空间分辨率（ERA5 的空间分辨率为每像素数十公里）意味着从单个实例的角度来看，我们将其视为静态空间数据。

静态数据。这些数据包括来自 LandScan 数据集的人口估算值 (Dobson et al., 2000)、实例的空间位置（由其中心纬度和经度定义）、在实例范围内空间平均的 Dynamic World 类别，以及在实例范围内空间平均的 World Cereal 农业土地覆盖图。除了空间变化的输入外，我们还包含了平均后的 Dynamic World 和 World Cereal 输入。

3. 实验框架

预训练。我们使用第 2.2 节中描述的算法，对三种模型大小分别进行 500 轮次的预训练。详细信息请参见附录 B.2。

下游任务. 我们在 GeoBench 中的所有 Sentinel-2 任务上评估我们的模型 (Lacoste et al., 2024)。这些任务涵盖了不同应用和地理区域的单时间步图像分类与分割。我们还通过 MADOS 海洋垃圾数据集测试细粒度分割 (Kikaki et al., 2024)，通过 Sen1Floods11 测试 Sentinel-1 图像分割 (Bonafilia et al., 2020)，通过 PASTIS 测试图像时序序列分割 (Garnot & Landrieu, 2021)，通过 Breizhcrops 测试光学像素时序序列分类 (Rußwurm et al., 2019)，以及通过 CropHarvest 测试多模态像素时序序列分类 (Tseng et al., 2021)。

基准比较。 我们将 Galileo 与所有最先进的预训练遥感模型（详见第 5 节）进行了基准对比。我们报告了每个任务在完整测试集上的结果。输入规范化、图像大小和超参数选择会影响性能 (Corley et al., 2024)，因此我们重新运行了所有对比的评估，并对规范化方法和学习率（如适用）进行了遍历。此外，我们将每种模型的所有图像调整为其预训练时的图

		m-EuroSat		m-BigEarthNet		m-So2Sat		m-Brick-Kiln	
		Top-1 Acc.		F1 Score		Top-1 Acc.		Top-1 Acc.	
		Training %		Training %		Training %		Training %	
Method	Arch.	100%	1%	100%	1%	100%	1%	100%	1%
SatMAE	ViT-Base	84.1	34.8	50.6	29.0	36.0	23.1	86.1	73.5
SatMAE++	ViT-Large	82.7	48.5	50.8	31.6	34.7	23.4	89.6	76.7
CROMA	ViT-Base	85.6	51.3	58.8	44.7	48.8	33.8	**92.6**	**85.1**
SoftCon	ViT-Small	89.8	27.2	**64.7**	43.3	51.1	31.4	89.2	77.8
DOFA-v1	ViT-Base	82.8	49.6	49.4	29.9	41.4	29.4	88.3	78.3
Satlas	Swin-Tiny	81.7	35.8	51.9	29.6	36.6	27.1	88.2	73.0
MMEarth	CNN-atto	81.7	30.0	58.3	39.6	39.8	25.1	89.4	79.7
DeCUR	ViT-Small	89.0	46.6	63.8	**49.6**	45.8	30.9	83.7	74.2
Prithvi 2.0	ViT-Large	80.2	48.0	49.4	28.8	29.5	26.1	87.9	80.6
AnySat	ViT-Base	82.2	47.1	54.9	33.7	39.8	29.0	85.3	72.0
Galileo	ViT-Nano	89.7	41.7	53.8	33.9	50.1	37.4	86.7	79.7
Galileo	ViT-Tiny	90.1	41.3	55.5	34.4	49.7	36.2	86.9	77.3
Galileo	ViT-Base	**93.0**	**56.6**	59.0	36.5	**54.8**	**43.2**	90.7	78.0

Table 3. Galileo-Base 是图像分类 (%) 的最佳模型，由 k NN 提出。我们展示了每种方法的最佳架构。我们将所有方法和架构中排名第一的 st 和第二名的 nd 结果以 **粗体** 和 下划线 标出，如表 15 所示。

		m-EuroSat		m-BigEarthNet		m-So2Sat		m-Brick-Kiln	
		Top-1 Acc.		F1 Score		Top-1 Acc.		Top-1 Acc.	
		Training %		Training %		Training %		Training %	
Method	Arch.	100%	1%	100%	1%	100%	1%	100%	1%
SatMAE	ViT-Large	96.6	56.9	68.3	41.8	57.2	36.4	98.4	96.1
SatMAE++	ViT-Large	96.5	56.4	67.9	45.6	56.0	36.9	98.6	92.5
CROMA	ViT-Large	96.6	52.7	71.9	**47.9**	60.6	40.9	98.7	96.7
SoftCon	ViT-Base	97.5	56.3	70.3	38.5	61.7	49.2	98.7	**97.3**
DOFA-v1	ViT-Large	96.9	53.4	68.0	43.5	58.7	37.0	98.6	94.5
Satlas	Swin-Base	97.5	51.9	**72.8**	25.8	61.9	30.6	98.4	94.7
MMEarth	CNN-atto	95.7	47.5	70.0	43.4	57.2	30.0	**98.9**	89.2
DeCUR	ViT-Small	**97.9**	54.2	70.9	44.7	61.7	47.0	98.7	96.9
Prithvi 2.0	ViT-Large	96.5	51.5	69.0	37.1	54.6	31.0	98.6	96.2
AnySat	ViT-Base	95.9	51.3	70.3	13.3	51.8	29.7	98.6	85.6
Galileo	ViT-Nano	94.5	52.6	67.1	23.3	57.4	34.9	96.1	94.2
Galileo	ViT-Tiny	96.9	60.6	69.7	39.5	61.9	43.1	98.7	96.6
Galileo	ViT-Base	97.7	**63.5**	70.7	40.9	**63.3**	**50.6**	98.7	96.8

Table 4. Galileo-Base 是用于图像分类 (%) 的最佳模型，通过微调实现。我们展示了每种方法对应的最佳架构。我们 **bold** 和underline 了所有方法和架构中排名 1st 和 2nd 的最佳结果，如表格16所示。

像大小。对于图像分类和分割任务，我们在四个训练集大小（“划分”）下进行评估：100 %，20 %，5 %，以及 1 %。对于具有可变补丁大小的所有模型，我们使用 4 的补丁大小。当将单时间步模型应用于多时间步的 PASTIS 数据集时，我们额外遍历了池化方法以对每个时间步的表示进行池化。完整细节见附录 C。

4. 结果

我们在表 1 中展示了所有任务和划分下的模型秩的平均值。我们对 Galileo 在常见的遥感基准上进行了评估。尽管这些常见的遥感基准通常仅包含有限的遥感模态（光学和雷达数据），但 Galileo 在预训练期间学习了多种额外的模态。这些模态对实践者来说很容易获取（表 1，“支持的输入”），可能在测试时带来性能提升。

图像结果。我们在表 3、4 和 5 中将 Galileo 与针对图像优化的模型进行了比较。这些模型均在单时间步图像上进行预训练，将其全部容量用于图像处理，除了 Satlas。尽管如此，Galileo-Base 在图像分类和分割任务上仍优于所有其他模型。我们的小型 ViT-{Nano, Tiny} 模型在这些任务上同样表现出色，且经常超越更大规模的模型，这对计算资源受限的应用场景具有重要价值。此外，Galileo 的可变补丁大小可在计算成本与任务性能之间实现权衡：我们在图 4 中绘制了这一权衡关系。通过增大补丁大小，输入被分割成更少的 token，从而降低了特征抽取所需的 MACs。

		m-Cashew-Plant		m-SA-Crop-Type		MADOS		Sen1Floods11		PASTIS	
		Training %		Training %		Training %		Training %		Training %	
Method	Arch.	100%	1%	100%	1%	100%	1%	100%	1%	100%	1%
SatMAE	ViT-Large	30.8	22.7	24.8	16.9	55.6	13.2	N/A		29.6	11.5
SatMAE++	ViT-Large	29.6	23.3	25.7	16.8	49.9	12.7	N/A		30.5	12.0
CROMA	ViT-Base	31.8	26.8	**32.0**	18.3	64.2	**24.4**	78.9	77.6	44.4	18.5
SoftCon	ViT-Base	29.6	22.8	30.8	18.5	60.3	16.5	78.0	74.8	31.3	10.5
DOFA-v1	ViT-Large	27.7	23.3	25.4	16.8	51.6	19.1	78.1	77.4	29.8	13.4
Satlas	Swin-Tiny	25.1	18.6	23.4	16.2	45.9	12.4	N/A		28.0	10.9
MMEarth	CNN-atto	24.2	20.3	22.2	14.1	34.2	16.1	N/A		24.0	10.5
DeCUR	ViT-Small	26.2	22.8	21.5	15.3	54.8	16.6	74.5	72.2	22.4	11.0
Prithvi 2.0	ViT-Large	26.7	23.2	22.9	15.7	50.0	18.9	N/A		29.3	13.2
AnySat	ViT-Base	26.1	21.7	27.1	15.8	50.2	17.0	77.9	76.9	**46.2**	**23.5**
Galileo	ViT-Nano	24.4	24.5	19.7	14.5	54.8	13.9	78.6	77.1	17.5	13.1
Galileo	ViT-Tiny	27.4	27.9	22.5	17.1	60.8	17.5	78.0	77.9	28.1	16.9
Galileo	ViT-Base	33.0	**30.2**	30.1	**19.4**	**67.6**	14.7	**79.4**	**78.2**	39.2	18.7

Table 5. Galileo 模型在图像分割任务中表现出色，通过线性探测测量的 % mIoU（Galileo-Base 的平均秩为 2.7，见表 18）。我们展示了每种方法的最佳架构。我们在所有方法和架构中，将第 1st 和第 2nd 名的结果以 **粗体**和 下划线 标出，如表 17 所示。Sen1Floods11 数据集包含从 SAR 数据标注的洪水信息；不支持该模态的模型结果以N/A 替代。

Table 6. Galileo 模型在像素时间序列分类任务中表现最佳（-Base）和次佳（-Tiny），评估方式为线性探测。最佳结果以**粗体**标出，次佳结果以 下划线 标出。CropHarvest 数据集除了哨兵-2 光学影像外，还包含多种模态数据，包括地形、气象和 SAR 数据。我们使用每个模型所能支持的所有模态。

		CropHarvest			
Method	Arch.	Togo	Brazil	Kenya	Breizhcrops
Presto	ViT-Presto	**75.5**	98.8	84.0	63.0
AnySat	ViT-Base	73.4	76.7	75.5	66.1
Galileo	ViT-Nano	73.5	76.4	84.5	67.3
Galileo	ViT-Tiny	74.7	97.2	**85.4**	69.0
Galileo	ViT-Base	74.8	**99.3**	84.2	**73.0**

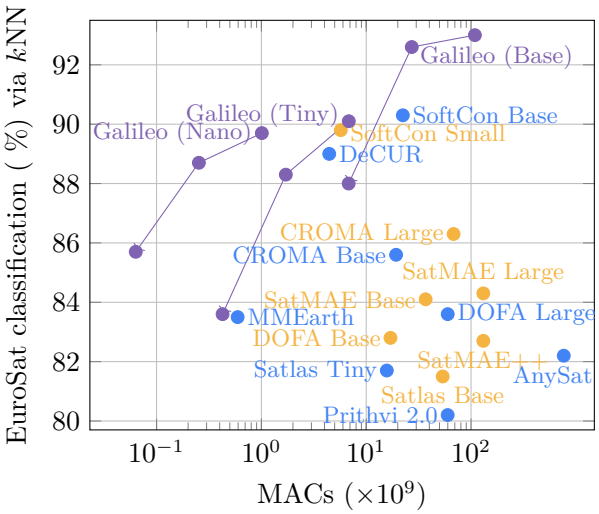

Figure 4. 准确率随补丁大小变化而与推理成本权衡，如 {4, 8, 16} 所示。成本以编码一个 EuroSat 输入所需的乘加操作（MACs）数量衡量（注意 x 轴采用对数尺度）。Galileo 模型大小和补丁大小在性能与成本之间提供了平衡。详见表 14 的完整结果。

除了 Galileo 之外，AnySat 是唯一支持单时间步图像和像素时间序列的模型。在这两个通用模型中，Galileo 在标准基准上更准确（例如，在 EuroSat 上通过 10.8% 实现）。（注：对于语义分割，AnySat 的特征是逐像素的，而非逐块的。为了训练成本相当，训练时我们对每张图像采样 6.25% 个其像素特征，但测试时使用所有像素特征进行评估。我们通过与 AnySat 的作者私下沟通确认了该评估的公平性。）

时间序列结果。我们将 Galileo 与通用模型 AnySat 以及像素时间序列专用模型 Presto 进行比较（表 6）。Galileo 的排名高于 Presto，且远超 AnySat。

4.1. 消融

在所有消融实验中，我们预先训练 ViT-Tiny 模型 200 轮次。我们选取了四个不同的任务进行分割（Sen1Floods11 和 MADOS）、图像分类（EuroSat）以及时间序列分类（CropHarvest），消融实验仅使用验证集。

我们首先对全局任务和局部任务进行消融实验：虽然全局任务在分类任务上表现优异，局部任务在分割任务上表现优异，但两者均无法在两项任务上都表现出色。随后，我们对组合算法进行消融实验，该算法在分类和分割任务上均表现优异。我们对算法中的以下具体组件进行了消融分析：

全局任务消融实验。 我们关注分类任务，这是我们的全局学习所针对的任务（见表 7）。我们的全局任务在计算目标时选择每模态的深度。其性能略

Table 7. 深度目标结合结构化时空掩码在全局特征抽取方面表现优异。分割任务被灰度化以专注于我们全局任务的分类。我们通过 k NN 测量 % top-1 准确率。

masking strategy	target enc. computation	loss function	MADOS	Floods	CropH.	EuroSat
space+time	varied	PatchDisc$_B$	58.91	76.92	88.72	89.50
random	varied	PatchDisc$_B$	11.71	69.62	82.12	17.40
random+space+time	varied	PatchDisc$_B$	22.87	71.62	76.53	66.30
space+time	0	PatchDisc$_B$	61.73	76.66	85.79	86.90
space+time	6	PatchDisc$_B$	63.83	76.93	88.17	89.20
space+time	12	PatchDisc$_B$	60.35	77.19	87.30	87.90
space+time	varied	MSE	62.35	76.78	86.02	87.20
space+time	varied	PatchDisc	25.74	71.68	75.30	62.50

Table 8. 深度-浅层对比学习结合非结构化随机掩码在局部特征抽取方面表现优异。分类任务被灰化以专注于分割的局部任务。我们测量线性预测在冻结特征上的% mIoU (↑)。

masking strategy	target enc. computation	loss function	MADOS	Floods	CropH.	EuroSat
random	0	PatchDisc	71.48	77.39	86.77	86.90
random+space+time	0	PatchDisc	68.63	77.82	85.31	88.80
space+time	0	PatchDisc	62.25	77.22	86.82	87.00
random	6	PatchDisc	58.53	75.66	76.58	65.40
random	12	PatchDisc	11.65	72.60	71.92	27.50
random	varied	PatchDisc	8.25	68.89	77.83	18.40
random	0	MSE	65.34	77.09	86.71	87.40
random	0	PatchDisc$_B$	70.12	77.26	85.27	88.20

Table 9. 我们的双目标算法在分类和分割任务上均表现优异，且比单目标算法更加稳定。通过线性探测获得的 MADOS 和 Sen1Floods11（% mIoU），以及通过 k NN 获得的 CropHarvest 和 EuroSat（% top-1 准确率）。

global loss	local loss	share predictors	target context	MADOS	Floods	CropH.	EuroSat
PatchDisc$_B$	PatchDisc	no	all	64.37	77.33	87.72	89.70
PatchDisc	PatchDisc	no	all	67.79	77.66	87.87	91.00
PatchDisc$_B$	PatchDisc	no	dec.	63.54	76.95	86.98	89.30
PatchDisc	PatchDisc	no	dec.	36.98	74.21	85.49	83.30
PatchDisc	PatchDisc	no	dec.+enc.	63.41	77.36	85.87	89.30
PatchDisc	PatchDisc	yes	all	67.04	78.23	85.23	88.50
PatchDisc$_B$	PatchDisc$_B$	no	all	67.88	77.08	86.61	89.50
MSE	MSE	no	all	62.36	77.17	86.28	88.70

优于将所有目标深度设为 6（一半层）和 12（所有层）的模型。仅使用线性投影进行目标处理时，在 EuroSat 上下降了 2.6%，在 CropHarvest 上下降了 2.9%，证实了对分类任务而言，深入特征的目标设定至关重要。在未使用我们局部任务的情况下，仅使用 PatchDisc 损失会失败，在 EuroSat 上仅达到 62.5%，这可能源于对位置嵌入的捷径利用。我们通过在对比目标中引入批量中其他样本的 token 作为负例来解决此问题（我们的 PatchDisc$_B$）。最后，当应用于我们的全局任务时，无结构的随机掩码方法失效。

局部任务消融实验。 我们专注于分割任务，这是我们的局部学习所针对的任务（见表 8）。我们的局部目标具有 0 的深度，即它们是输入的浅层线性投影，不包含更深层次的建模。选择浅层目标非常有效：在包含微小物体（如海洋垃圾）的 MADOS 数据集上，其达到了 71.5% mIoU，而全局任务仅达到 58.9% 。使用 PatchDisc 损失略优于 PatchDisc$_B$；仅针对线性投影（即不使用位置嵌入）可防止利用批量中的负样本带来的潜在捷径。这些对比损失在 MADOS 上的表现比 MSE 损失高出 5+% ，这表明将像素从其他 token 中排斥能增强局部特征。我们的方法是首次将深层-浅层对比学习应用于遥感领域的自监督学习，也适用于自监督学习的一般场景。最后，非结构化随机掩码在 MADOS 上的表现优于结构化掩码 9% ，这验证了我们的直觉：跨较短跨度进行预测有助于促进局部特征。

完整算法消融实验。 尽管单独使用时，PatchDisc$_B$ 对我们的全局任务至关重要，但当与局部任务结合使用时，其作用变得不再必要。在不同目标之间不共享预测器参数是最优的。有趣的是，我们的双目标策略能够更一致地实现成功的训练过程（例如，表 9 中 100% 的训练运行在 EuroSat 上达到 $> 80\%$，而表 7 和 8 中仅为 63%）。

5. 相关工作与背景

自监督学习。 对掩码或噪声输入进行重建是自监督预训练的一种常见形式，适用于自然语言 (Devlin et al., 2018; Radford et al., 2018; Mikolov et al., 2013) 和自然图像 (Xie et al., 2022; He et al., 2022; Vincent et al., 2008)。尽管这些方法在输入空间中进行预测（例如，像 MAE He et al. (2022) 所做的那样重建像素），但近期工作已开始探索在潜在空间 (Assran et al., 2022; Wei et al., 2024) 中进行预测。这些方法预测由编码器的指数移动平均计算出的块表示。Galileo 独特地在潜在空间的不同深度进行预测和学习，涵盖从输入空间（线性投影）到潜在空间完整深度的范围。

对比学习 (Le-Khac et al., 2020; Oord et al., 2018;

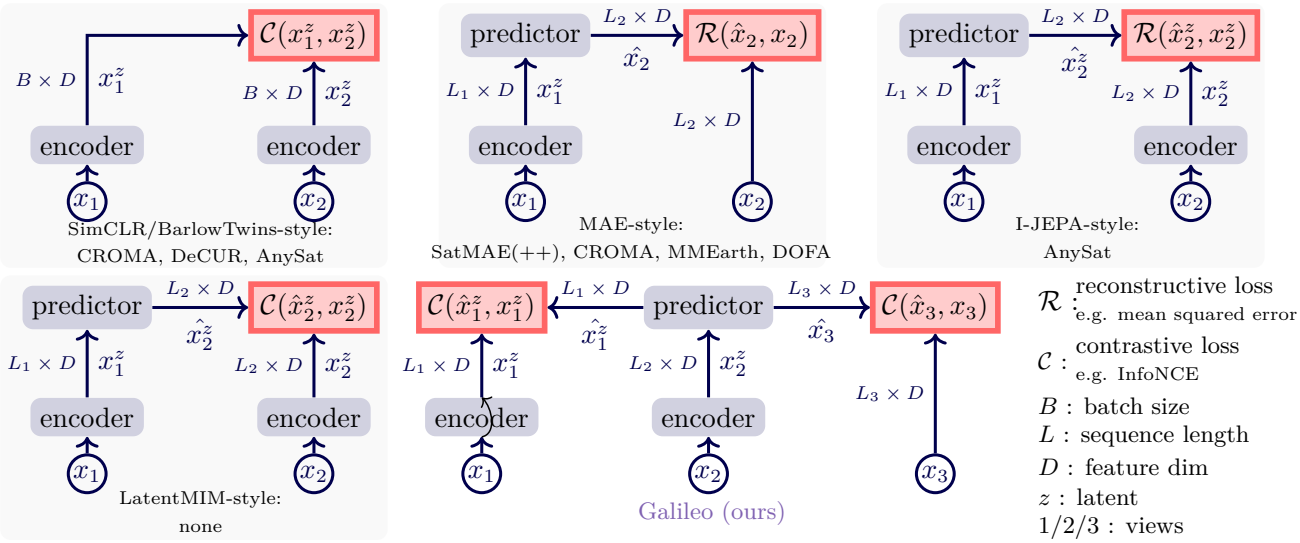

Figure 5. ***RS* 的自监督学习。左上角：** 对比方法吸引来自同一样本的表示，并排斥来自其他样本的表示。**中上角：** 重构方法预测隐藏块的像素。**右上角：** I-JEPA 和 AnySat 预测隐藏块的表示。**左下角：** 潜在 MIM（缺乏 RS 实例化）吸引来自同一块的表示，并排斥来自其他块的表示。**Galileo（我们的方法）：** 我们的方法同时吸引同一块的多层级表示并排斥其他位置的表示，同时吸引同一块的像素预测并排斥其他位置的预测。这种策略促进了全局与局部特征的学习。

Chen et al., 2020; Chopra et al., 2005) 是一种不同的自监督预训练方法：它将输入进行复制和变换，对所有输入进行编码，然后吸引相同输入的表示（称为正例）并排斥不同输入的表示（称为负例）。潜在 MIM (Wei et al., 2024) 将对比学习应用于掩码输入的潜在表示，以提高这些方法相比重建损失的稳定性：其补丁判别损失（PatchDisc loss）吸引图像中同一位置的补丁表示，并排斥同一输入但不同位置的补丁表示。我们采用了补丁判别损失，但观察到其仍容易发生坍缩。伽利略的 双重损失能够稳定预训练过程，从而实现损失的可靠提升。

预训练遥感模型。在对遥感数据进行预训练时，大多数方法仅处理 单个时间步的数据，包括仅处理多光谱光学影像（SatMAE (Cong et al., 2022)，MMEarth (Nedungadi et al., 2024)）、将多光谱光学影像与合成孔径雷达（SAR）数据分别处理（SoftCon Wang et al. (2024b)，DOFA Xiong et al. (2024)，DeCUR Wang et al. (2024a)），或联合处理多光谱光学影像与 SAR 数据（CROMA (Fuller et al., 2024)）。能够处理多个时间步数据的模型，要么仅处理多光谱光学影像（Prithvi 2.0 (Szwarcman et al., 2024)，Satlas (Bastani et al., 2023)），要么忽略空间关系，将数据视为像素时间序列（Presto (Tseng et al., 2023)）。这些模型在预训练过程中采用不同的自监督学习方法；我们在图 5 中展示了其中一些方法。

Galileo 学习并处理的模态比以往的方法更多。它不仅能联合处理多光谱光学影像和合成孔径雷达（SAR）影像，还能处理包括地形、气象、人口分布图、夜间灯光以及土地覆盖分类图在内的多种遥感产品。这些产品在遥感任务中被广泛使用，因此对于 Galileo 在多种遥感应用中的实用性至关重要。此外，Galileo 可以灵活地建模此类多模态数据的空间与时间维度，从而处理单时相影像、多时相影像或像素时间序列等输入形式。这反映了遥感从业者常用的多模态、多形态方法（从像素时间序列 (Van Tricht et al., 2023; Kruse et al., 2023) 到单时相或多时相影像 (Beukema et al., 2023)），使 Galileo 能够无缝融入现有的遥感工作流。

AnySat (Astruc et al., 2024) 与我们的工作同时进行，并且具有相同的精神。AnySat 可以处理来自多颗卫星的数据，还能够灵活地处理这些数据的空间和时间维度。然而，AnySat 缺少 Galileo 处理的许

多其他模态，而这些模态可能对于建模一系列遥感现象 (Poggio et al., 2021; Van Tricht et al., 2023)) 至关重要，并在我们的基准测试中产生实际差异（表 11）。

6. 结论

我们识别出在广泛遥感（RS）应用场景中应用预训练模型的两个要求：(i) 能够灵活处理不同模态和输入形状，以及 (ii) 能够建模不同尺度下发生的遥感现象。为满足这些要求，我们提出了伽利略系列预训练遥感模型。

我们通过以下创新实现了这些需求：(i) 对伽利略模型架构进行改进，以灵活处理在时空上均存在变化的高多模态输入；(ii) 采用双层局部-全局自监督学习算法，促使模型学习不同尺度下的现象；(iii) 使用用于训练伽利略模型的预训练数据集。

我们进行了数百次评估，包括对大量基准预训练遥感（RS）模型的广泛测试，以在广泛的领域和任务类型中稳健地展示 Galileo 的性能。我们对方法进行了全面的消融实验。在确认了使用 Galileo 实现统一的局部、全局及多模态自监督学习的有效性和可迁移性后，我们注意到，对于遥感以外的数据，仍需更多研究来探索局部与全局自监督学习。

处理多种遥感模态的能力对遥感从业者至关重要，他们发现使用多种输入对于获得良好结果极为关键 (Poggio et al., 2021; Rao et al., 2020; Van Tricht et al., 2023)。这在基准数据集中的反映却很少，这些数据集通常仅包含光学或雷达数据。尽管许多预训练模型只能处理基准中的模态，但 Galileo 经过训练可处理实践中常见的额外模态。尽管这些标准基准未能体现这一功能，但对于需要充分利用可用数据的从业者而言，这一能力仍然非常有价值。

模型权重、预训练代码、预训练数据和评估代码已在 github.com/nasaharvest/galileo 开源。

影响声明

机器学习在遥感（RS）中的应用涵盖了从物种分布建模 (Teng et al., 2024) 到灾害管理 (Kansakar & Hossain, 2016) 等一系列对社会至关重要的领域。通过提供一组即使在标签数据较少的情况下仍能表现良好的遥感模型，我们希望帮助遥感从业者持续探索并部署这些应用。为促进这些模型的采用，我们采取了多项措施，包括在公开可用的遥感数据上训练模型，并训练多种大小的模型，以使其能够在计算资源受限的环境中使用。此外，我们通过计算开销较大的迁移学习（带微调）和计算成本较低的迁移学习（使用 k NN 和线性探测）两种方式展示了 Galileo 的性能。

Tuia et al. (2023) 强调这些模型的一个风险是，它们可能被用来收集有关人群的信息，从而在未征得其参与的情况下做出决策。我们鼓励在与当地社区和利益相关者合作的前提下部署伽利略模型 (Krafft, 2023; Kshirsagar et al., 2021; Nakalembe & Kerner, 2023)。

致谢

AF 主要由加拿大自然科学与工程研究理事会研究生奖学金项目（NSERC PGS-D）支持。DR 和 ES 由加拿大戴尔计算机科学与人工智能主席资助计划（Canada CIFAR AI Chairs）支持。GT 由加拿大自然科学与工程研究理事会-创造领导力项目（NSERC-CREATE LEADS）支持。GT 和 HK 由美国国家航空航天局收获计划资助（NASA Harvest Grant #80NSSC23M0032）支持。

本研究在一定程度上得益于 Mila（mila.quebec）提供的计算资源，其中包括 NVIDIA Corporation 的物质支持。我们感谢 Ai2 的 Beaker 团队在 Ai2 的 (Guerquin, 2022) 集群上的支持。

参考文献

Abatzoglou, J. T., Dobrowski, S. Z., Parks, S. A., and Hegewisch, K. C. Terraclimate, a high-

resolution global dataset of monthly climate and climatic water balance from 1958–2015. *Scientific data*, 5(1):1–12, 2018.

Assran, M., Caron, M., Misra, I., Bojanowski, P., Bordes, F., Vincent, P., Joulin, A., Rabbat, M., and Ballas, N. Masked siamese networks for label-efficient learning. In *European Conference on Computer Vision*, pp. 456–473. Springer, 2022.

Assran, M., Duval, Q., Misra, I., Bojanowski, P., Vincent, P., Rabbat, M., LeCun, Y., and Ballas, N. Self-supervised learning from images with a joint-embedding predictive architecture. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 15619–15629, 2023.

Astruc, G., Gonthier, N., Mallet, C., and Landrieu, L. AnySat: An Earth observation model for any resolutions, scales, and modalities. *arXiv preprint arXiv:2412.14123*, 2024.

Baraka, S., Akera, B., Aryal, B., Sherpa, T., Shresta, F., Ortiz, A., Sankaran, K., Ferres, J. L., Matin, M., and Bengio, Y. Machine learning for glacier monitoring in the hindu kush himalaya. *arXiv preprint arXiv:2012.05013*, 2020.

Bastani, F., Wolters, P., Gupta, R., Ferdinando, J., and Kembhavi, A. Satlaspretrain: A large-scale dataset for remote sensing image understanding. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 16772–16782, 2023.

Beukema, P., Bastani, F., Wolters, P., Herzog, H., and Ferdinando, J. Satellite imagery and ai: A new era in ocean conservation, from research to deployment and impact. *arXiv preprint arXiv:2312.03207*, 2023.

Beyer, L., Izmailov, P., Kolesnikov, A., Caron, M., Kornblith, S., Zhai, X., Minderer, M., Tschannen, M., Alabdulmohsin, I., and Pavetic, F. Flexivit: One model for all patch sizes. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 14496–14506, 2023.

Bonafilia, D., Tellman, B., Anderson, T., and Issenberg, E. Sen1floods11: A georeferenced dataset to train and test deep learning flood algorithms for sentinel-1. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pp. 210–211, 2020.

Brown, C. F., Brumby, S. P., Guzder-Williams, B., Birch, T., Hyde, S. B., Mazzariello, J., Czerwinski, W., Pasquarella, V. J., Haertel, R., Ilyushchenko, S., et al. Dynamic world, near real-time global 10 m land use land cover mapping. *Scientific Data*, 9(1):251, 2022.

Chen, T., Kornblith, S., Norouzi, M., and Hinton, G. A simple framework for contrastive learning of visual representations. In *International conference on machine learning*, pp. 1597–1607. PMLR, 2020.

Chen, X., Xie, S., and He, K. An empirical study of training self-supervised vision transformers. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 9640–9649, 2021.

Chopra, S., Hadsell, R., and LeCun, Y. Learning a similarity metric discriminatively, with application to face verification. In *2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05)*, volume 1, pp. 539–546. IEEE, 2005.

Cong, Y., Khanna, S., Meng, C., Liu, P., Rozi, E., He, Y., Burke, M., Lobell, D., and Ermon, S. Satmae: Pre-training transformers for temporal and multi-spectral satellite imagery. *Advances in*

Neural Information Processing Systems, 35:197–211, 2022.

Corley, I., Robinson, C., Dodhia, R., Ferres, J. M. L., and Najafirad, P. Revisiting pre-trained remote sensing model benchmarks: Resizing and normalization matters. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, pp. 3162–3172, June 2024.

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., and Fei-Fei, L. Imagenet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, 2009. doi: 10.1109/CVPR.2009.5206848.

Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018.

Dobson, J. E., Bright, E. A., Coleman, P. R., Durfee, R. C., and Worley, B. A. Landscan: a global population database for estimating populations at risk. *Photogrammetric engineering and remote sensing*, 66(7):849–857, 2000.

Elvidge, C. D., Baugh, K., Zhizhin, M., Hsu, F. C., and Ghosh, T. Viirs night-time lights. *International journal of remote sensing*, 38(21):5860–5879, 2017.

Frame, J. M., Nair, T., Sunkara, V., Popien, P., Chakrabarti, S., Anderson, T., Leach, N. R., Doyle, C., Thomas, M., and Tellman, B. Rapid inundation mapping using the us national water model, satellite observations, and a convolutional neural network. *Geophysical Research Letters*, 51 (17):e2024GL109424, 2024.

Fuller, A., Millard, K., and Green, J. CROMA: Remote sensing representations with contrastive radar-optical masked autoencoders. *Advances in Neural Information Processing Systems*, 36, 2024.

Garnot, V. S. F. and Landrieu, L. Panoptic segmentation of satellite image time series with convolutional temporal attention networks. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 4872–4881, 2021.

Garrido, Q., Assran, M., Ballas, N., Bardes, A., Najman, L., and LeCun, Y. Learning and leveraging world models in visual representation learning. *arXiv preprint arXiv:2403.00504*, 2024.

Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., and Moore, R. Google earth engine: Planetary-scale geospatial analysis for everyone. *Remote sensing of Environment*, 202:18–27, 2017.

Guerquin, M. Introducing ai2' s beaker. https://web.archive.org/web/20241231204439/https://medium.com/ai2-blog/beaker-ed617d5f4593, 2022. Accessed: 2025-05-15.

Gwilliam, M. and Shrivastava, A. Beyond supervised vs. unsupervised: Representative benchmarking and analysis of image representation learning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 9642–9652, 2022.

He, K., Chen, X., Xie, S., Li, Y., Dollár, P., and Girshick, R. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 16000–16009, 2022.

Helber, P., Bischke, B., Dengel, A., and Borth, D. Eurosat: A novel dataset and deep learning benchmark for land use and land cover classification. *IEEE Journal of Selected Topics in Applied*

Earth Observations and Remote Sensing, 12(7): 2217–2226, 2019.

Hersbach, H., Bell, B., Berrisford, P., Hirahara, S., Horányi, A., Muñoz-Sabater, J., Nicolas, J., Peubey, C., Radu, R., Schepers, D., et al. The era5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 146(730):1999–2049, 2020.

Hoffer, E., Ben-Nun, T., Hubara, I., Giladi, N., Hoefler, T., and Soudry, D. Augment your batch: better training with larger batches. *arXiv preprint arXiv:1901.09335*, 2019.

Jean, N., Wang, S., Samar, A., Azzari, G., Lobell, D., and Ermon, S. Tile2vec: Unsupervised representation learning for spatially distributed data. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pp. 3967–3974, 2019.

Kansakar, P. and Hossain, F. A review of applications of satellite earth observation data for global societal benefit and stewardship of planet earth. *Space Policy*, 2016.

Kay, W., Carreira, J., Simonyan, K., Zhang, B., Hillier, C., Vijayanarasimhan, S., Viola, F., Green, T., Back, T., Natsev, P., et al. The kinetics human action video dataset. *arXiv preprint arXiv:1705.06950*, 2017.

Kebede, E. A., Abou Ali, H., Clavelle, T., Froehlich, H. E., Gephart, J. A., Hartman, S., Herrero, M., Kerner, H., Mehta, P., Nakalembe, C., et al. Assessing and addressing the global state of food production data scarcity. *Nature Reviews Earth & Environment*, 5(4):295–311, 2024.

Kerner, H., Tseng, G., Becker-Reshef, I., Nakalembe, C., Barker, B., Munshell, B., Paliyam, M., and Hosseini, M. Rapid response crop maps in data sparse regions. In *ACM SIGKDD Conference on Data Mining and Knowledge Discovery Workshops*, 2020.

Kikaki, K., Kakogeorgiou, I., Hoteit, I., and Karantzalos, K. Detecting marine pollutants and sea surface features with deep learning in sentinel-2 imagery. *ISPRS Journal of Photogrammetry and Remote Sensing*, 210:39–54, 2024.

Krafft, A. ASU researcher combats food insecurity with AI. https://news.asu.edu/20230303-solutions-asu-researcher-combats-food-insecurity-ai, 2023. Accessed: 2023-09-21.

Kruse, C., Boyda, E., Chen, S., Karra, K., Bou-Nahra, T., Hammer, D., Mathis, J., Maddalene, T., Jambeck, J., and Laurier, F. Satellite monitoring of terrestrial plastic waste. *PloS one*, 18 (1):e0278997, 2023.

Kshirsagar, M., Robinson, C., Yang, S., Gholami, S., Klyuzhin, I., Mukherjee, S., Nasir, M., Ortiz, A., Oviedo, F., Tanner, D., et al. Becoming good at ai for good. In *AAAI/ACM Conference on AI, Ethics, and Society*, 2021.

Lacoste, A., Lehmann, N., Rodriguez, P., Sherwin, E., Kerner, H., Lütjens, B., Irvin, J., Dao, D., Alemohammad, H., Drouin, A., et al. Geo-bench: Toward foundation models for earth monitoring. *Advances in Neural Information Processing Systems*, 36, 2024.

Le-Khac, P. H., Healy, G., and Smeaton, A. F. Contrastive representation learning: A framework and review. *Ieee Access*, 8:193907–193934, 2020.

Lee, J., Brooks, N. R., Tajwar, F., Burke, M., Ermon, S., Lobell, D. B., Biswas, D., and Luby, S. P. Scalable deep learning to identify brick kilns and aid regulatory capacity. *Proceedings of the National Academy of Sciences*, 118(17): e2018863118, 2021.

Manas, O., Lacoste, A., Giró-i Nieto, X., Vazquez, D., and Rodriguez, P. Seasonal contrast: Unsupervised pre-training from uncurated remote sensing data. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 9414–9423, 2021.

Mikolov, T., Chen, K., Corrado, G., and Dean, J. Efficient estimation of word representations in vector space, 2013. URL https://arxiv.org/abs/1301.3781.

Nakalembe, C. and Kerner, H. Considerations for ai-eo for agriculture in sub-saharan africa. *Environmental Research Letters*, 2023.

NASA JPL. NASA shuttle radar topography mission global 1 arc second. NASA EOSDIS Land Processes Distributed Active Archive Center, 2000.

Nedungadi, V., Kariryaa, A., Oehmcke, S., Belongie, S., Igel, C., and Lang, N. Mmearth: Exploring multi-modal pretext tasks for geospatial representation learning, 2024.

Noman, M., Naseer, M., Cholakkal, H., Anwer, R. M., Khan, S., and Khan, F. S. Rethinking transformers pre-training for multi-spectral satellite imagery. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 27811–27819, 2024.

Oord, A. v. d., Li, Y., and Vinyals, O. Representation learning with contrastive predictive coding. *arXiv preprint arXiv:1807.03748*, 2018.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., et al. Scikit-learn: Machine learning in python. *the Journal of machine Learning research*, 12:2825–2830, 2011.

Poggio, L., De Sousa, L. M., Batjes, N. H., Heuvelink, G. B., Kempen, B., Ribeiro, E., and Rossiter, D. Soilgrids 2.0: producing soil information for the globe with quantified spatial uncertainty. *Soil*, 7(1):217–240, 2021.

Radford, A., Narasimhan, K., Salimans, T., and Sutskever, I. Improving language understanding by generative pre-training. *OpenAI technical reports*, 2018.

Rao, K., Williams, A. P., Flefil, J. F., and Konings, A. G. Sar-enhanced mapping of live fuel moisture content. *Remote Sensing of Environment*, 245: 111797, 2020.

Reed, C. J., Gupta, R., Li, S., Brockman, S., Funk, C., Clipp, B., Keutzer, K., Candido, S., Uyttendaele, M., and Darrell, T. Scale-mae: A scale-aware masked autoencoder for multiscale geospatial representation learning. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 4088–4099, 2023.

Rußwurm, M., Lefèvre, S., and Körner, M. Breizhcrops: A satellite time series dataset for crop type identification. In *Proceedings of the International Conference on Machine Learning Time Series Workshop*, volume 3, 2019.

Sumbul, G., Charfuelan, M., Demir, B., and Markl, V. Bigearthnet: A large-scale benchmark archive for remote sensing image understanding. In *IGARSS 2019-2019 IEEE International Geoscience and Remote Sensing Symposium*, pp. 5901–5904. IEEE, 2019.

Szwarcman, D., Roy, S., Fraccaro, P., Gíslason, T. E., Blumenstiel, B., Ghosal, R., de Oliveira, P. H., Almeida, J. L. d. S., Sedona, R., Kang, Y., et al. Prithvi-eo-2.0: A versatile multi-temporal foundation model for earth observation applications. *arXiv preprint arXiv:2412.02732*, 2024.

Teng, M., Elmustafa, A., Akera, B., Bengio, Y., Radi, H., Larochelle, H., and Rolnick, D. Satbird: a dataset for bird species distribution modeling using remote sensing and citizen science data. *Advances in Neural Information Processing Systems*, 36, 2024.

Tseng, G., Zvonkov, I., Nakalembe, C. L., and Kerner, H. Cropharvest: A global dataset for crop-type classification. In *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track (Round 2)*, 2021.

Tseng, G., Cartuyvels, R., Zvonkov, I., Purohit, M., Rolnick, D., and Kerner, H. Lightweight, pre-trained transformers for remote sensing timeseries. *arXiv preprint arXiv:2304.14065*, 2023.

Tucker, C. J. Red and photographic infrared linear combinations for monitoring vegetation. *Remote sensing of Environment*, 8(2):127–150, 1979.

Tuia, D., Schindler, K., Demir, B., Camps-Valls, G., Zhu, X. X., Kochupillai, M., Džeroski, S., van Rijn, J. N., Hoos, H. H., Del Frate, F., et al. Artificial intelligence to advance earth observation: a perspective. *arXiv preprint arXiv:2305.08413*, 2023.

Uber. H3: A hexagonal hierarchical geospatial indexing system. https://h3geo.org, 2018. Accessed: 2024-12-04.

Van Tricht, K., Degerickx, J., Gilliams, S., Zanaga, D., Battude, M., Grosu, A., Brombacher, J., Lesiv, M., Bayas, J. C. L., Karanam, S., et al. Worldcereal: a dynamic open-source system for global-scale, seasonal, and reproducible crop and irrigation mapping. *Earth System Science Data Discussions*, 2023:1–36, 2023.

Vincent, P., Larochelle, H., Bengio, Y., and Manzagol, P.-A. Extracting and composing robust features with denoising autoencoders. In *Proceedings of the 25th international conference on Machine learning*, pp. 1096–1103, 2008.

Wang, Y., Braham, N. A. A., Xiong, Z., Liu, C., Albrecht, C. M., and Zhu, X. X. SSL4EO-S12: A large-scale multimodal, multitemporal dataset for self-supervised learning in Earth observation. *IEEE Geoscience and Remote Sensing Magazine*, 11(3):98–106, 2023.

Wang, Y., Albrecht, C. M., Braham, N. A. A., Liu, C., Xiong, Z., and Zhu, X. X. Decoupling common and unique representations for multimodal self-supervised learning. *arXiv preprint arXiv:2309.05300*, 2024a.

Wang, Y., Albrecht, C. M., and Zhu, X. X. Multi-Label Guided Soft Contrastive Learning for Efficient Earth Observation Pretraining. *arXiv preprint arXiv:2405.20462*, 2024b.

Wei, Y., Gupta, A., and Morgado, P. Towards latent masked image modeling for self-supervised visual representation learning. In *ECCV*, 2024.

Xie, Z., Zhang, Z., Cao, Y., Lin, Y., Bao, J., Yao, Z., Dai, Q., and Hu, H. Simmim: A simple framework for masked image modeling. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 9653–9663, 2022.

Xiong, Z., Wang, Y., Zhang, F., Stewart, A. J., Hanna, J., Borth, D., Papoutsis, I., Saux, B. L., Camps-Valls, G., and Zhu, X. X. Neural plasticity-inspired foundation model for observing the earth crossing modalities. *arXiv preprint arXiv:2403.15356*, 2024.

Yin, L., Ghosh, R., Lin, C., Hale, D., Weigl, C., Obarowski, J., Zhou, J., Till, J., Jia, X., You, N., et al. Mapping smallholder cashew plantations to inform sustainable tree crop expansion

in benin. *Remote Sensing of Environment*, 295: 113695, 2023.

Zanaga, D., Van De Kerchove, R., Daems, D., De Keersmaecker, W., Brockmann, C., Kirches, G., Wevers, J., Cartus, O., Santoro, M., Fritz, S., et al. Esa worldcover 10 m 2021 v200. *ESA WorldCover Project*, 2022.

Zhu, X. X., Hu, J., Qiu, C., Shi, Y., Kang, J., Mou, L., Bagheri, H., Haberle, M., Hua, Y., Huang, R., et al. So2sat lcz42: A benchmark data set for the classification of global local climate zones [software and data sets]. *IEEE Geoscience and Remote Sensing Magazine*, 8(3):76–89, 2020.

A. 方法论细节

A.1. 伽利略 SSL 算法

我们采用一种受Assran et al. (2023)、Garrido et al. (2024)和Wei et al. (2024) 启发的潜在预测框架，其工作方式如下：❶ 给定一批样本，我们为每个样本构建两个不同的视图，即 $\mathbf{x}_1 \in \mathbb{R}^{L_1 \times D}$ 和 $\mathbf{x}_2 \in \mathbb{R}^{L_2 \times D}$。❷ 我们的“在线”编码器计算图像块编码 $\mathbf{z}_1 = \mathbf{E}(\mathbf{x}_1)$，而我们的“目标”编码器——即在线编码器的指数移动平均——则计算目标图像块编码 $\mathbf{z}_2 = \mathbf{E}_{\text{EMA}}(\mathbf{x}_2)$。❸ 一个预测器 Transformer $\mathbf{P}$ 接收目标视图的位置、时间、月份及通道组嵌入 $\mathtt{e}_2 \in \mathbb{R}^{L_2 \times D}$ 作为占位符查询，并通过对在线图像块编码进行交叉注意力操作来预测图像块编码 $\mathbf{p} \in \mathbb{R}^{L_2 \times D}$，即 $\mathbf{p} = \mathbf{P}(\mathtt{e}_2, \mathbf{z}_1)$。❹ 预测结果 $\mathbf{p}$ 与目标值 $\mathbf{z}_2$ 被用于计算损失 $\mathcal{L}(\mathbf{p}, \mathbf{z}_2)$，该损失用于更新在线编码器。

Table 10. 我们的全局任务，采用可变的小批量大小。默认情况下，我们使用单个 H100 GPU 内存中能容纳的最大小批量大小（32）。我们还包含 PatchDisc_I 的结果，其效果等同于使用 PatchDisc_B 且小批量大小为 1 的情况。

Minibatch size	MADOS	Floods	CropH.	EuroSat
32	58.91	76.92	88.72	89.50
16	64.24	77.76	88.51	90.10
1 (PatchDisc_I)	25.74	71.68	75.30	62.50

我们对潜在预测框架进行调整，以学习局部和全局特征。以下是这些调整的概述。

A.1.1. 学习全局特征

我们设计这个算法来学习适合分类应用的抽象、低频特征。❶ 视图构建包括：ⓐ 均匀采样通道组的数量 $N \in \{2, 3, \ldots, 17\}$，ⓑ 随机选择 N 通道组（例如，RGB、SAR、ERA5），ⓒ 对目标编码器重复步骤（a-b）同时排除重叠的通道组，ⓓ 应用空间或时间掩码，以及 ⓔ 对两个视图进行 token 化以得到 $\mathbf{x}_1$ 和 $\mathbf{x}_2$。空间掩码在空间上采样掩码，同时保持时间上的一致性；时间掩码在时间上做同样的操作，同时保持空间上的一致性。在这两种情况下，都会选择模态用于编码或解码。❷-❸ 遵循我们的通用框架，我们计算 $\mathbf{z}_1$ 和 $\mathbf{p}$，并使用目标编码器的不同退出深度计算目标，$\mathbf{E}^{\ell}_{\text{EMA}}$。❹ 为了鼓励全局判别性表示，我们扩展 PatchDisc 损失，通过从批量中采样负样本（而不是仅针对单个实例）来更好地区分批量中的样本。这种方法（“PatchDisc_B”）定义如下（注意如果移除 $\sum_{i'}^{B}$ 求和，则与 PatchDisc_I 等价）：

$$\mathcal{L}(\mathbf{u}, \mathbf{v}) = \frac{-\tau}{B} \sum_i^B \frac{1}{L_i} \sum_j^{L_i} \log \frac{\exp(\text{sim}(\mathbf{u}_{i,j}, \mathbf{v}_{i,j})/\tau)}{\sum_{i'}^B \sum_{j'}^{L_{i'}} \exp(\text{sim}(\mathbf{u}_{i,j}, \mathbf{v}_{i',j'})/\tau)}$$

使用 Softmax 温度 τ，样本索引 i，批量大小 B，token 索引 j，i^{th} 样本中的 token 数量 L_i，以及 l_2 规范化的点积 $\text{sim}(\mathbf{u}, \mathbf{v}) = \mathbf{u}^\top \mathbf{v} / \|\mathbf{u}\| \|\mathbf{v}\|$。这得到了以下全局任务：

$$\mathcal{L}_{global} = \text{PatchDisc}_B(\mathbf{P}(\mathtt{e}_2, \mathbf{E}(\mathbf{x}_1)), \text{sg}(\mathbf{E}^{\ell}_{\text{EMA}}(\mathbf{x}_2)))$$

测量批量大小的影响 PatchDisc_B 从一个 批量内的所有样本中抽取负样本块，而 PatchDisc_I 则是在单个样本内进行。这引入了对批量大小的依赖；我们在表 10 中测量了批量大小的影响。

A.1.2. 学习局部特征

我们设计此算法以学习适合分割应用的细粒度、高频特征。❶ 视图构建包括：ⓐ 对整个样本进行分词，以及 ⓑ 随机选择 5% 个 token 进行 $\mathbf{x}_1$ 和 50% 用于 $\mathbf{x}_2$。❷-❸ 按照我们的通用框架，我们计算 $\mathbf{z}_1$ 和 $\mathbf{p}$，但使用仅目标编码器的线性投影来计算目标，即 $\mathbf{E}^{proj}_{\text{EMA}}$ ——跳过 Transformer 块，使得预测器专注于低级特征。❹ 我们使用 LatentMIM 的 PatchDisc 损失，任务是让模型仅基于低级特征来区分 patch：

$$\mathcal{L}_{local} = \text{PatchDisc}(\mathbf{P}(\mathtt{e}_2, \mathbf{E}(\mathbf{x}_1)), \text{sg}(\mathbf{E}^{proj}_{\text{EMA}}(\mathbf{x}_2)))$$

A.1.3. 结合局部与全局目标

如第2.2节所述，我们的联合方法在预训练期间交替使用局部目标和全局目标：

$$\mathcal{L}_{Galileo} = \tfrac{1}{2}(\mathcal{L}_{global} + \mathcal{L}_{local})$$

B. 预训练细节

B.1. 全球采样的预训练数据集

为了构建伽利略数据集，我们将全球 WorldCover 地图 (Zanaga et al., 2022) 拆分为 1000×1000 个像素（$10km \times 10km$ ）的瓦片。对于每个瓦片，我们计算两个特征集：❶ 每个 WorldCover 分类类别的像素数量，以及 ❷ 瓦片的纬度和经度。我们使用这些特征来训练一个 k =150,000 k -均值聚类算法，并选择每个簇中心最近的瓦片。这得到了 150,000 个训练点，其中 85% (127,155) 成功通过 Google Earth Engine (Gorelick et al., 2017) 导出。通过将像素数量和纬度经度同时作为 k -均值算法的特征，我们确保了模型训练点在语义和地理上的多样性——图 3 展示了导出点的分层统计地图。

我们使用此采样过程构建一个丰富的数据集，用于预训练我们的模型。该数据集包含 9 种遥感输入，范围从直接感知的输入（如哨兵-2 光学影像）到语义稠密的地图（如动态世界土地覆盖地图）——这些内容在第 2.3 节中有详细讨论。表 11 通过在预训练联合全局-局部模型时剔除单一数据产品，研究了每一模态对模型下游性能的影响。

Table 11. 移除伽利略数据集。通过线性探测得到 MADOS 和 Sen1Floods11（% mIoU），通过 k NN 得到 CropHarvest 和 EuroSat（% OA）。

Removed input	MADOS	Sen1Floods11	CropHarvest	EuroSat
None	67.79	77.66	87.87	91.00
S1	67.67	N/A	85.27	90.20
NDVI	67.89	78.10	88.32	90.00
ERA5	68.10	77.10	87.14	91.20
TerraClim	61.30	74.90	82.78	81.20
VIIRS	63.48	74.52	84.10	81.10
SRTM	66.14	77.62	86.74	91.00
DynamicWorld	67.24	77.86	87.80	89.30
WorldCereal	65.94	77.56	87.71	89.60
LandScan	60.74	77.45	87.89	91.10
Location	69.25	77.36	87.14	91.20

B.2. 实施

所有模型均在单个 H100 GPU 上进行训练（模型大小和训练时间详见表12）。我们采用有效的批量大小为 512，该批量由 32 个实例的小批量组成，并经过 4 次数据增强和重复 (Hoffer et al., 2019)。对于数据增强，我们对每个实例随机应用垂直翻转、水平翻转以及 90 度旋转。在重复数据时，我们首先随机选择一个补丁大小 $P \in [1, 2, 3, 4, 5, 6, 7, 8]$。然后随机选择一个（大小，时间步）组合 $(S, T) \in$

Table 12. 我们 ViT 模型的配置及其相关的预训练成本。GPU 小时数表示在 H100 GPU 上将每个模型预训练 500 轮次所需的 GPU 小时数。

architecture	blocks	dim	heads	params	GPU-hours
ViT-Nano	4	128	8	0.8M	200
ViT-Tiny	12	192	3	5.3M	259
ViT-Base	12	768	12	85.0M	573

$[(4,12),(5,6),(6,4),(7,3),(9,3),(12,3)]$。接着从批量中的每个实例中随机子集选取空间高度 $H = P \times S$、宽度 $W = P \times S$ 以及时间步 T。

我们使用 bfloat16 准确率，以及带有 $\beta_1 = 0.9$ 和 $\beta_2 = 0.999$ 的 AdamW 优化器，并采用梯度裁剪。我们对学习率进行预热，在 30 轮次内提升至最大学习率，随后通过余弦衰减策略进行冷却。我们使用指数移动平均（EMA）来更新目标编码器，动量值为 0.996，并在预训练过程中线性增加至 1，遵循 Assran et al. (2022)。

对于所有消融实验（第 4.1 节），我们对 ViT-Tiny 模型进行 200 轮次的预训练，学习率最大值为 2×10^{-3} ，权重衰减为 0.02 。对于最终的 Galileo 模型，我们对模型进行 500 轮次的预训练，并进行 [learning rate $\times$ weight decay] 的搜索。对于 ViT-Nano 和 ViT-Tiny 架构，我们搜索 learning rates $\in [1 \times 10^{-3}, 2 \times 10^{-3}, 3 \times 10^{-3}]$ 和 weight decays $\in [1 \times 10^{-2}, 2 \times 10^{-2}, 3 \times 10^{-2}]$ 。对于 ViT-Base 架构，我们搜索 learning rates $\in [1 \times 10^{-4}, 3 \times 10^{-4}, 1 \times 10^{-3}, 2 \times 10^{-3}, 3 \times 10^{-3}]$ 和 weight decays $\in [1 \times 10^{-2}, 2 \times 10^{-2}, 3 \times 10^{-2}]$ 。

C. 评估细节

C.1. 实施

为确保在比较预训练模型时实验情景的一致性，我们在相同条件下重新运行所有评估。对于 k NN 探针，我们遵循 Gwilliam & Shrivastava (2022) 的实现方式——使用预训练模型计算测试数据的表示（作为值）和训练数据的表示（作为键），然后利用这些键对测试数据进行分类。遵循 Fuller et al. (2024) 和 Reed et al. (2023)，我们使用 $k = 20$ 。在线性探针（Linear probing）中，我们使用预训练模型计算训练数据的表示，并用此来训练线性探针。我们在训练线性探针时调整学习率（$\{1,3,4,5\} \times 10^{\{-4,-3,-2,-1\}}$），并将训练好的线性探针应用于计算得到的测试数据表示。在微调（finetuning）时，我们在微调过程中调整学习率（$\{1,3,6\} \times 10^{\{-5,-4,-3\}}$），并将微调后的模型应用于测试数据。

C.2. 评估数据集

我们在以下描述的数据集上评估我们的模型。对于所有 GeoBench 修订后的数据集 (Lacoste et al., 2024) - m-Eurosat、m-BigEarthnet、m-So2Sat、m-Brick-Kiln、m-Cashew-Plant 和 m-SA-Crop-Type，我们使用 GeoBench 共享的训练、验证和测试划分。此外，我们还使用 GeoBench 共享的 1%、5% 和 20% 划分。

- **m-EuroSat** (Helber et al., 2019)：训练集总共包含 2,000 张图像，验证集和测试集各包含 1,000 张图像。图像大小为 64×64 像素。

- **m-BigEarthNet** (Sumbul et al., 2019)：完整训练集包含 20,000 张图像，测试集包含 1,000 张图像。图像大小为 120×120 像素。

- **m-So2Sat** (Zhu et al., 2020)：训练集包含完整的 19,992 张图像，测试集包含 986 张图像，图像大小为 32×32 像素。
- **m-Brick-Kiln** (Lee et al., 2021)：完整训练集包含 15,063 张图像，测试集中有 999 张图像。图像大小为 64×64 像素。
- **m-Cashew-Plant** (Yin et al., 2023)：训练集总共包含 1,350 张图像，测试集中有 50 张图像。图像进行 256×256 ；我们将它们划分为 64×64 张图像。
- **m-SA-crop-type** (link)：训练集包含 3,000 张图像，测试集包含 93 张图像。图像为 256×256；我们将它们分割为 64×64 张图像。
- **MADOS** (Kikaki et al., 2024)：完整的 MADOS 数据集包含 2,804 140×140 张图像，这些图像是从 174 景 Sentinel-2 影像中提取的。我们使用 MADOS 中的训练/验证/测试划分（50% /25% /25%）——每个划分都是整个 MADOS 数据集的代表性子集。此外，我们将每张图像进一步划分为 80×80 张图像。
- **PASTIS** (Garnot & Landrieu, 2021)：完整的 PASTIS 数据集包含 2,433 128×128 个时间序列，每个时间序列有 38 至 61 个时间步。我们将每个时间序列在空间上划分为 64×64 个图像。此外，我们计算时间序列的月度聚合数据。Garnot & Landrieu (2021) 共享 5 个数据折；我们使用第 $\{1, 2, 3\}$ 折进行训练，4 折用于验证，5 折用于测试。当将单时间步模型应用于该数据集时，我们额外尝试不同的池化方法来对每个时间步的编码进行池化（如第 C 节所述）。
- **Breizhcrops** (Rußwurm et al., 2019)：Breizhcrops 数据集包含法国布列塔尼地区 4 个 NUTS-3 区域的像素时间序列。我们使用其中 2 个区域进行训练（FRH01，包含 178,613 个地块，FRH02 包含 140,645 个地块）。我们使用 FRH03（166,391 个地块）进行验证，FRH04（122,614 个地块）用于测试。该数据集包含不同长度的时间序列；我们对时间序列计算月度聚合值。
- **CropHarvest** (Tseng et al., 2021)：CropHarvest 数据集包含 3 个像素时间序列任务：(i) 多哥的作物与非作物分类，训练集中有 1,319 个样本，测试集中有 306 个样本；(ii) 肯尼亚的玉米与其他作物分类，训练集中有 1,345 个样本，测试集中有 1,942 m^2 的稠密标签像素；(iii) 巴西的咖啡与其他作物分类，训练集中有 794 个样本，测试集中有 4.2 km^2 的稠密标签像素。

C.3. 与基准模型相比

Corley et al. (2024) 发现输入图像的大小和特征缩放方法对预训练遥感模型的性能有显著影响。因此，我们将所有输入图像调整为模型预训练时所使用的大小。此外，我们将特征缩放方法视为一个额外的超参数，在学习率（适用于线性探测和微调的情况）的基础上进行搜索。最后，PASTIS 数据集包含多时相的光学影像。由于所有基准模型（除 AnySat 外）均无法原生处理完整的时序序列，我们采用多次前向传播的方式。我们测试了使用均值和最大值来融合模型输出的方法，遵循 Bastani et al. (2023)。

Table 13. Galileo MADOS 分类测试性能 (%) 随补丁大小的变化，通过线性探测在不同训练集% 下测量。

Arch.	patch size	100 %	20 %	5%	1%
ViT-Nano	2	53.6	43.9	33.5	16.6
	4	54.8	41.5	28.9	13.9
ViT-Tiny	2	61.9	49.9	32.6	15.2
	4	60.8	50.6	34.0	17.5

因此，报告的测试结果是通过在下游数据集的验证集上，对以下超参数的笛卡尔积进行遍历计算得出的。

$$[\text{Learning Rate}] \times [\text{Temporal aggregations}]$$

除了进行此次搜索外，我们还运行线性探测 5 次并取结果的平均值。在运行线性探测时，首次运行中同时对学习率和特征缩放方法进行搜索。根据首次运行的结果选择特征缩放方法，并在后续所有运行中固定该方法。然后针对每次运行选择最优的其他超参数，并将这些结果汇总以获得最终结果。

我们对所有评估数据集运行此搜索，但不包括 CropHarvest 任务；这些任务的训练集较小，且没有可用于选择超参数的验证集。因此，我们遵循 Tseng et al. (2023)，使用预训练期间所采用的相同特征缩放方法，并对所有模型使用 scikit-learn 的回归算法及默认参数 (Pedregosa et al., 2011)。

C.3.1. 特征缩放

我们基准对比的预训练模型在预训练过程中采用的是标准化（MMEarth、DOFA、AnySat 和 Presto）或规范化（其他所有模型）。我们对以下规范化统计量进行扫描，具体取决于预训练流程，选择标准化或规范化：❶ 来自下游数据集的统计量，❷ SatMAE 预训练统计量，❸ SSL4EO (Wang et al., 2023) 统计量，❹ Galileo 预训练数据集统计量，❺ Presto 预训练数据集统计量。对于所有这些统计量，我们还额外扫描了标准差倍数。Prithvi 2.0 的统计量仅涵盖部分 Sentinel-2 波段；因此，我们仅在 Prithvi 2.0 模型的扫描中包含这些统计量。

Table 14. Galileo m-Eurosat 分类测试性能（%）随补丁大小的变化，通过 k NN 测量，针对不同的训练集百分比。同时记录了处理单个 EuroSat 实例所需的 MACs；通过选择模型大小和补丁大小，实践者可以在模型性能和推理成本之间进行权衡。

Arch.	patch size	GMACs	100 %	20 %	5%	1%
ViT-Nano	8	0.25	88.7	81.9	55.0	38.5
	16	0.06	85.7	79.3	56.0	41.1
ViT-Tiny	8	1.71	88.3	83.0	59.7	41.3
	16	0.43	83.6	78.4	50.1	33.8
ViT-Base	8	27.20	92.6	88.3	72.4	56.9
	16	6.80	88.0	82.4	58.6	48.9

D. 结果

我们包含了图像分类任务的完整结果（表 15）和分割任务的完整结果（表 17）。此外，m-Eurosat 数据集在不同块大小下的完整结果记录在表 14 中——这些数值用于图 4。类似地，我们在表 13 中记录了 MADOS 在不同块大小下的结果——表 5 和 17 中使用了块大小为 4 的设置。

我们在表 18 中对模型进行排序。在对模型进行排序时，我们计算每个模型在每个数据集和划分下的平均秩。

Table 15. 图像分类测试性能 (%) 通过 k NN。秩是通过对所有结果求平均值并排名平均值来计算的。

		m-EuroSat				**m-BigEarthNet**				**m-So2Sat**				**m-Brick-Kiln**			
		Training %, Top-1 Acc. ↑				Training %, F1 Score ↑				Training %, Top-1 Acc. ↑				Training %, Top-1 Acc. ↑			
Method	Arch.	100%	20%	5%	1%	100%	20%	5%	1%	100%	20%	5%	1%	100%	20%	5%	1%
SatMAE (Cong et al., 2022)	ViT-Base	84.1	73.3	50.1	34.8	50.6	42.5	35.7	29.0	36.0	32.9	29.7	23.1	86.1	81.9	80.3	73.5
SatMAE (Cong et al., 2022)	ViT-Large	84.3	74.7	53.1	46.4	50.8	42.9	35.6	27.7	36.6	34.3	31.0	24.4	87.9	84.0	80.4	74.7
SatMAE++ (Noman et al., 2024)	ViT-Large	82.7	75.9	51.1	48.5	50.8	42.8	36.7	31.6	34.7	32.7	29.9	23.4	89.6	87.1	82.8	76.7
CROMA (Fuller et al., 2024)	ViT-Base	85.6	79.4	66.2	51.3	58.8	55.3	49.3	44.7	48.8	48.0	43.9	33.8	**92.6**	**90.6**	**87.7**	**85.1**
CROMA (Fuller et al., 2024)	ViT-Large	86.3	78.1	59.9	49.0	56.6	50.6	44.1	38.0	47.6	45.0	43.2	33.7	91.0	86.7	82.9	80.2
SoftCon (Wang et al., 2024b)	ViT-Small	89.8	83.4	55.9	27.2	**64.7**	58.7	52.6	43.3	51.1	49.9	43.3	31.4	89.2	86.9	80.5	77.8
SoftCon (Wang et al., 2024b)	ViT-Base	90.3	82.1	54.2	19.8	63.7	57.5	52.0	42.5	51.0	49.7	45.3	35.4	90.0	86.1	80.6	74.5
DOFA-v1 (Xiong et al., 2024)	ViT-Base	82.8	72.1	60.9	49.6	49.4	43.6	37.2	29.9	41.4	40.7	37.5	29.4	88.3	86.2	82.0	78.3
DOFA-v1 (Xiong et al., 2024)	ViT-Large	83.6	72.1	53.5	41.7	49.9	41.6	35.3	27.6	45.4	40.6	35.6	31.8	86.8	85.2	84.8	80.6
Satlas (Bastani et al., 2023)	Swin-Tiny	81.7	70.3	48.3	35.8	51.9	44.8	37.8	29.6	36.6	30.7	29.6	27.1	88.2	85.2	82.4	73.0
Satlas (Bastani et al., 2023)	Swin-Base	81.5	69.1	42.1	10.0	47.0	41.1	35.0	25.8	35.8	33.4	29.6	30.4	80.0	78.3	76.9	73.3
MMEarth (Nedungadi et al., 2024)	CNN-atto	81.7	73.5	60.3	30.0	58.3	52.2	46.5	39.6	39.8	38.8	36.8	25.1	89.4	85.4	84.1	79.7
DeCUR (Wang et al., 2024a)	ViT-Small	89.0	85.3	**72.3**	46.6	63.8	**59.2**	**55.4**	**49.6**	45.8	43.1	38.5	30.9	83.7	81.7	77.9	74.2
Prithvi 2.0 (Szwarcman et al., 2024)	ViT-Large	80.2	69.4	54.1	48.0	49.4	42.9	35.5	28.8	29.5	31.2	29.6	26.1	87.9	86.8	83.3	80.6
AnySat (Astruc et al., 2024)	ViT-Base	82.2	73.7	62.5	47.1	54.9	47.2	40.7	33.7	39.8	34.9	32.0	29.0	85.3	81.7	78.0	72.0
Galileo	ViT-Nano	89.7	82.4	56.6	41.7	53.8	46.3	41.5	33.9	50.1	50.3	47.5	37.4	86.7	82.2	83.2	79.7
Galileo	ViT-Tiny	90.1	83.9	59.5	41.3	55.5	48.2	41.6	34.4	49.7	50.5	44.2	36.2	86.9	83.7	83.8	77.3
Galileo	ViT-Base	**93.0**	**88.5**	71.3	**56.6**	59.0	51.5	45.4	36.5	**54.8**	**53.8**	**51.1**	**43.2**	90.7	86.9	85.8	78.0

Table 16. 图像分类测试性能 (%) 通过微调实现。

		m-EuroSat				**m-BigEarthNet**				**m-So2Sat**				**m-Brick-Kiln**			
		Training %, Top-1 Acc. ↑				Training %, F1 Score ↑				Training %, Top-1 Acc. ↑				Training %, Top-1 Acc. ↑			
Method	Arch.	100%	20%	5%	1%	100%	20%	5%	1%	100%	20%	5%	1%	100%	20%	5%	1%
SatMAE (Cong et al., 2022)	ViT-Base	96.5	90.8	79.7	55.5	67.8	59.3	51.1	39.0	54.5	52.0	45.2	34.8	98.5	97.4	97.0	94.0
SatMAE (Cong et al., 2022)	ViT-Large	96.6	91.5	82.5	56.9	68.3	61.1	52.4	41.8	57.2	56.2	49.7	36.4	98.4	97.3	97.3	96.1
SatMAE++ (Noman et al., 2024)	ViT-Large	96.5	90.6	80.1	56.4	67.9	60.4	51.9	45.6	56.0	52.4	46.0	36.9	98.6	97.3	96.0	92.5
CROMA (Fuller et al., 2024)	ViT-Base	96.0	91.2	79.2	53.6	70.0	63.4	54.0	43.4	59.7	59.1	54.1	43.3	98.7	97.8	97.0	96.1
CROMA (Fuller et al., 2024)	ViT-Large	96.6	92.9	80.7	52.7	71.9	**66.0**	**58.3**	**47.9**	60.6	57.9	52.9	40.9	98.7	98.0	97.1	96.7
SoftCon (Wang et al., 2024b)	ViT-Small	97.4	95.4	84.9	57.5	69.5	62.5	53.3	36.0	61.7	60.3	54.2	49.2	98.8	**98.1**	97.7	97.2
SoftCon (Wang et al., 2024b)	ViT-Base	97.5	95.0	**88.2**	56.3	70.3	63.6	53.8	38.5	61.7	60.3	54.2	49.2	98.7	**98.1**	**98.0**	**97.3**
DOFA-v1-v1 (Xiong et al., 2024)	ViT-Base	94.6	86.1	74.2	50.9	68.1	60.3	51.9	41.9	56.7	49.9	45.8	33.8	98.7	97.3	96.2	95.0
DOFA-v1-v1 (Xiong et al., 2024)	ViT-Large	96.9	91.5	82.2	53.4	68.0	60.3	52.2	43.5	58.7	55.4	47.4	37.0	98.6	96.9	96.1	94.5
Satlas (Bastani et al., 2023)	Swin-Tiny	96.3	89.1	78.1	52.9	71.3	63.8	53.6	32.0	57.3	52.7	45.9	30.8	98.5	97.7	96.8	94.7
Satlas (Bastani et al., 2023)	Swin-Base	97.5	92.2	81.2	51.9	**72.8**	65.1	54.9	25.8	61.9	55.0	47.0	30.6	98.4	97.9	97.2	94.7
MMEarth (Nedungadi et al., 2024)	CNN-atto	95.7	86.1	73.0	47.5	70.0	62.7	52.6	43.4	57.2	51.0	44.1	30.0	**98.9**	98.0	96.5	89.2
DeCUR (Wang et al., 2024a)	ViT-Small	**97.9**	95.3	87.9	54.2	70.9	64.9	54.7	44.7	61.7	**61.0**	54.2	47.0	98.7	98.0	97.1	96.9
Prithvi 2.0 (Szwarcman et al., 2024)	ViT-Large	96.5	89.2	77.6	51.5	69.0	61.8	51.4	37.1	54.6	50.5	40.2	31.0	98.6	97.6	96.7	96.2
AnySat (Astruc et al., 2024)	ViT-Base	95.9	88.2	74.4	51.3	70.3	61.6	46.1	13.3	51.8	49.8	42.0	29.7	98.6	97.2	96.8	85.6
Galileo (ours)	ViT-Nano	94.5	88.3	80.2	52.6	67.1	59.3	44.1	23.3	57.4	54.7	47.8	34.9	98.5	97.7	96.1	94.2
Galileo (ours)	ViT-Tiny	96.9	94.4	85.2	60.6	69.7	62.2	53.4	39.5	61.9	57.2	54.9	43.1	98.7	97.9	97.2	96.6
Galileo (ours)	ViT-Base	97.7	**96.0**	87.0	**63.5**	70.7	63.1	53.9	40.9	**63.3**	57.8	**56.7**	**50.6**	98.7	98.0	97.5	96.8

Table 17. 图像（及图像时序）分割测试性能（%）通过线性探测实现。* 对于语义分割，AnySat 输出稠密的每像素特征，而非每块特征。为保持线性探测的训练成本与其他模型相似，我们在训练 AnySat 的线性探测器时，每个图像采样了 6.25% 个像素特征。评估时使用了图像中的所有像素特征。

		m-Cashew-Plant Training %, mIoU ↑				**m-SA-Crop-Type** Training %, mIoU ↑				**MADOS** Training %, mIoU ↑				**Sen1Floods11** Training %, mIoU ↑				**PASTIS** Training %, mIoU ↑			
Method	Arch.	100%	20%	5%	1%	100%	20%	5%	1%	100%	20%	5%	1%	100%	20%	5%	1%	100%	20%	5%	1%
SatMAE (Cong et al., 2022)	ViT-Base	28.9	28.1	27.6	23.0	23.8	23.4	21.5	16.8	53.2	39.1	26.4	12.4	not supported				27.6	24.2	18.5	11.2
SatMAE (Cong et al., 2022)	ViT-Large	30.8	29.7	28.7	22.7	24.8	24.0	21.9	16.9	55.6	41.0	29.9	13.2	not supported				29.6	25.3	19.1	11.5
SatMAE++ (Noman et al., 2024)	ViT-Large	29.6	28.0	27.5	23.3	25.7	24.3	21.5	16.8	49.9	38.2	27.5	12.7	not supported				30.5	26.0	19.3	12.0
CROMA (Fuller et al., 2024)	ViT-Base	31.8	31.4	30.2	26.8	**32.0**	**29.9**	**26.1**	18.3	64.2	49.1	**39.6**	**24.4**	78.9	78.1	77.4	77.6	44.4	38.4	29.2	18.5
CROMA (Fuller et al., 2024)	ViT-Large	**34.3**	**33.3**	32.5	27.9	**32.0**	**29.9**	25.6	18.0	66.3	**52.5**	36.2	13.9	78.6	78.0	77.1	77.2	42.9	35.9	25.8	16.1
SoftCon (Wang et al., 2024b)	ViT-Small	27.0	26.8	25.6	23.0	28.5	27.8	24.3	17.7	57.1	44.0	29.4	19.1	78.5	78.3	76.9	75.6	28.6	26.1	19.3	11.8
SoftCon (Wang et al., 2024b)	ViT-Base	29.6	28.9	27.2	22.8	30.8	29.3	24.7	18.5	60.3	42.4	31.9	16.5	78.0	77.4	74.9	74.8	31.3	26.5	19.3	10.5
DOFA-v1 (Xiong et al., 2024)	ViT-Base	26.9	26.7	26.8	22.2	24.8	23.9	21.0	16.6	48.3	37.4	30.0	19.1	78.1	77.8	77.0	77.1	29.8	25.6	19.5	13.2
DOFA-v1 (Xiong et al., 2024)	ViT-Large	27.7	27.4	27.3	23.3	25.4	23.9	21.3	16.8	51.6	38.5	31.0	19.1	78.1	77.9	77.3	77.4	29.8	25.5	19.5	13.4
Satlas (Bastani et al., 2023)	Swin-Tiny	25.1	24.8	24.2	18.6	23.4	22.7	19.8	16.2	45.9	35.7	26.5	12.4	not supported				28.0	24.0	17.4	10.9
Satlas (Bastani et al., 2023)	Swin-Base	24.5	24.4	23.3	19.4	22.4	21.6	19.3	14.7	48.0	36.5	25.9	15.9	not supported				25.4	21.6	16.1	9.2
MMEarth (Nedungadi et al., 2024)	CNN-atto	24.2	24.6	24.6	20.3	22.2	21.0	18.7	14.1	34.2	26.4	19.5	16.1	not supported				24.0	21.6	16.0	10.5
DeCUR (Wang et al., 2024a)	ViT-Small	26.2	26.2	26.0	22.8	21.5	20.8	19.2	15.3	54.8	40.9	30.3	16.6	74.5	74.6	73.5	72.2	22.4	19.7	15.4	11.0
Prithvi 2.0 (Szwarcman et al., 2024)	ViT-Large	26.7	26.6	26.8	23.2	22.9	22.3	20.3	15.7	50.0	41.8	33.7	18.9	not supported				29.3	26.8	20.2	13.2
AnySat * (Astruc et al., 2024)	ViT-Base	26.1	26.1	24.9	21.7	27.1	25.2	21.4	15.8	50.2	39.8	30.5	17.0	77.9	77.6	77.1	76.9	**46.2**	**41.9**	**33.7**	**23.5**
Galileo	ViT-Nano	24.4	24.6	24.6	24.5	19.7	19.7	17.1	14.5	54.8	41.4	28.9	13.9	78.6	78.5	77.7	77.1	17.5	17.0	15.7	13.1
Galileo	ViT-Tiny	27.4	27.0	27.3	27.9	22.5	22.4	20.5	17.1	60.8	50.6	34.0	17.5	78.0	77.8	77.7	77.9	28.1	27.0	23.1	16.9
Galileo	ViT-Base	33.0	32.8	**33.1**	**30.2**	30.1	29.3	25.4	**19.4**	**67.6**	49.0	34.1	14.7	**79.4**	**79.0**	**78.5**	**78.2**	39.2	36.7	27.9	18.7

Table 18. 模型排名，基于表 15 中的完整图像分类（Im. Class.）结果、表 17 中的图像分割（Im. Seg.）结果以及表 6 中的时间序列（TS）结果计算得出。我们将图像分类和图像分割的排名合并为单一的“图像”（Im.）排名。在进行此操作时，我们对所有任务的排名取平均值（而非简单地对合并后的图像分类和图像分割排名进行平均）。

		Im. Class.		Im. Seg		
Method	Arch.	KNN	FT	LP	Im.	TS
SatMAE (Cong et al., 2022)	ViT-Base	13.8	12.5	11.7	12.6	N/A
SatMAE (Cong et al., 2022)	ViT-Large	11.9	9.1	10.1	10.4	N/A
SatMAE++ (Noman et al., 2024)	ViT-Large	10.9	11.4	10.4	10.9	N/A
CROMA (Fuller et al., 2024)	ViT-Base	3.6	7.4	**2.5**	4.3	N/A
CROMA (Fuller et al., 2024)	ViT-Large	5.9	5.3	3.5	4.8	N/A
SoftCon (Wang et al., 2024b)	ViT-Small	5.6	4.7	7.7	6.1	N/A
SoftCon (Wang et al., 2024b)	ViT-Base	5.9	4.0	7.3	5.9	N/A
DOFA-v1 (Xiong et al., 2024)	ViT-Base	9.4	13.1	9.6	10.6	N/A
DOFA-v1 (Xiong et al., 2024)	ViT-Large	10.6	10.2	7.7	9.4	N/A
Satlas (Bastani et al., 2023)	Swin-Tiny	12.7	10.6	14.9	12.9	N/A
Satlas (Bastani et al., 2023)	Swin-Base	15.9	7.9	15.7	13.4	N/A
MMEarth (Nedungadi et al., 2024)	CNN-atto	8.3	11.7	16.1	12.3	N/A
DeCUR (Wang et al., 2024a)	ViT-Small	7.0	3.6	13.0	8.3	N/A
Prithvi 2.0 (Szwarcman et al., 2024)	ViT-Large	12.0	12.5	10.8	11.7	N/A
AnySat (Astruc et al., 2024)	ViT-Base	11.1	14.5	8.3	11.1	4.5
Presto (Tseng et al., 2023)	ViT-Presto	N/A	N/A	N/A	N/A	3.0
Galileo	ViT-Nano	7.0	13.1	12.2	10.9	3.5
Galileo	ViT-Tiny	6.6	5.8	6.8	6.4	2.3
Galileo	ViT-Base	**2.9**	**3.5**	2.7	**3.0**	**1.8**