https://hjfy.top/arxiv/2407.15837

面向潜在掩码图像建模的自监督视觉表示学习

Yibing Wei[1], Abhinav Gupta[2], and Pedro Morgado[1]

[1] University of Wisconsin-Madison
[2] Carnegie Mellon University

摘要 掩码图像建模（MIM）作为一种从未标记图像数据中提取视觉表示的有前景方法，通过预测图像被掩码区域缺失的像素来实现。它在区域感知学习方面表现出色，并为各种任务提供了强大的初始化，但在缺乏进一步监督微调的情况下难以捕捉高层语义，这可能归因于其像素重构目标的低层特性。一个有前景但尚未实现的框架是通过潜在空间中的掩码重构来学习表示，该方法结合了 MIM 的局部性与高层目标。然而，这种方法带来了重大的训练挑战，因为重构目标与模型同时学习，可能导致平凡或次优解。我们的研究是首个全面分析并解决此类框架挑战的工作，我们称之为潜在 MIM。通过一系列精心设计的实验和广泛分析，我们识别出这些挑战的根源，包括联合在线/目标优化导致的表示坍缩、学习目标、潜在空间中高区域相关性以及解码条件依赖性。通过逐步解决这些问题，我们证明了潜在 MIM 确实能够学习高层表示，同时保留 MIM 模型的优势。代码可在 https://github.com/yibingwei-1/LatentMIM 获得。

1 引言

掩码图像建模（Masked Image Modeling, MIM）是一种从未标记图像数据中提取视觉表示的学习框架，近年来备受关注。该技术通过掩码图像的大部分区域，并训练模型利用周围上下文来预测缺失的像素。尽管学习目标简单，但研究表明，MIM 能够学习到强大的表示，经过微调后可在多种下游任务（包括物体分类、检测和分割）上达到顶尖性能 [3,13]。

相较于其他自监督视觉表示学习方法，MIM 方法具有若干关键优势。通过要求模型准确重建所有被掩码的图像块，MIM 促使模型保持每个图像区域的清晰局部式表征，并迫使模型对物体子部分的空间布局进行推理。这些优势使 MIM 成为一种流行的自监督视觉表示学习方法。

然而，通过该框架学成的表示在未经过进一步监督微调的情况下，无法捕捉高级语义，这从其在线性探测和最近邻分类中表现较差可看出。我们假设，由于使用了像原始像素这样的低级学习目标，MIM 并未直接学习到高

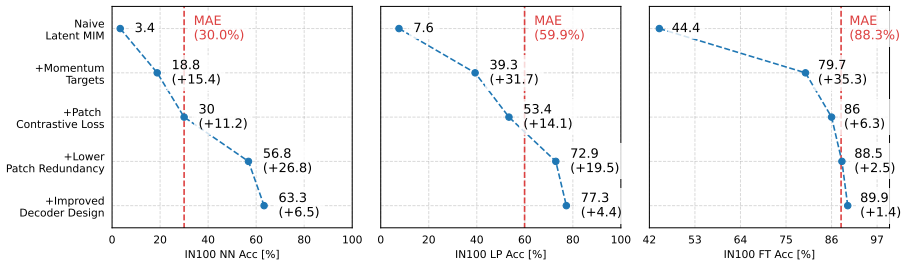

图 1: 潜在 MIM 的挑战. 由 MIM 方法学成的表示无法捕捉高层语义，如最近邻和线性探测评估中表现不佳所示。

级语义。为了有效重建高频细节，学成的表示必须保留图像的低级描述，这限制了它们编码更高级语义的能力。

解决这一挑战的一种自然方法是执行潜在空间中的**掩码图像建模**，我们将其称为潜在 MIM（Latent MIM）的通用框架。这意味着，与重建原始像素不同，潜在 MIM 方法应通过为每张图像定义局部（块级）潜在表示，并从可见区域重建被掩码区域的表示来学习表示。通过绕过低层次的像素目标，专注于区分被掩码区域的潜在表示，潜在 MIM 方法有望显著提升通过像素级 MIM 方法获得的语义信息，从而可能提高其下游任务的表现。

然而，将 MIM 直观地应用于潜在空间重构时存在不稳定性，原因在于（1）存在平凡解以及（2）邻近块语义之间的高相关性。首先，当学成的潜在表示退化为易于预测但信息量极少的输入图像表示时，便会出现平凡解；例如，使用均方误差（MSE）损失时，解码器可能在所有区域生成恒定的潜在表示。其次，即使潜在表示能够反映每个区域的内容，邻近块的语义也比像素本身具有更高的相关性。这同样会导致不良表示，因为模型可能通过简单复制邻近可见区域的信息来预测被掩码的区域。因此，尽管其潜力巨大，这些挑战已显著阻碍了潜在 MIM 的发展。

在本工作中，我们对纯潜在信息掩码（MIM）的挑战进行了深入研究。我们的目标是提供一个全面的分析，识别、表征并探索核心挑战的潜在解决方案。Fig. 1 展示了我们分析的概览，显示了随着我们逐步解决四个挑战，下游分类性能的变化情况，其中最近邻、线性探测和微调的准确率均有显著提升。

① *Joint optimization of visible and masked regions representations leads to representation collapse.* 相反，正如对比学习方法所推广的那样，使两个

表示之间产生不对称性，同时避免目标编码器参与梯度计算，对于学习有意义的表示至关重要。

② *Direct reconstruction results in poor representations, regardless of the specific loss used* 除了直接重构外，我们还探索了图像块内的对比预测编码。[3]，这不仅促使模型预测出与目标图像块表示相似的表示（从而实现重构目标），还促进了图像中更丰富且空间上多样的表示。

③ *Controlling the redundancy between visible and target patches is critical.* 具体而言，像素空间中 MIM 的最优掩码策略（即规则网格 75% 的掩码）可能导致目标块的表示与可见块过于相似（从而容易从可见块中预测），为此，为减少块间的冗余性，我们研究了生成可见块和目标块 token 序列的不同方法，包括使用非连续网格（相邻块之间间隔随机数量的像素）、更高的掩码比例以及显式的块相似度约束。

④ *The decoder design must be carefully crafted since Latent MIM decoders predict high-level representations of mask regions from those of visible regions.* 解码器需要具备足够的容量来填补缺失的信息，但同时又不能过于深邃，以免承担编码器的角色（即计算图像语义）。为此，我们研究了多种解码器架构。我们发现，采用经过修改的掩码 token 的交叉注意力解码器在直接编码附近可见区域表示时尤为有效。

通过显式探究潜在 MIM 固有的挑战，我们证明了与现有的 MIM 方法相比，潜在 MIM 框架确实能够无需监督微调即可学习到更丰富的语义信息和多样化的局部式表征。我们进一步通过将基于我们发现的潜在 MIM 实例放大至 ImageNet-1K 来验证我们的结论。学成的表征在最近邻分类上达到了 50.1%（相较于 MAE 提升 37.9%），在线性探测中达到 72.0%（相较于 MAE 提升 4.2%）的 top-1 分类准确率。在三种需要鲁棒局部表征的任务中——无监督场景分割、视频对象分割以及跨多种任务的 few-shot 迁移学习——学成表征的语义信息和可定位性得到了进一步验证。值得注意的是，通过潜在 MIM 方法学成的表征即使在缺乏监督的情况下也能生成视觉场景的精确分割结果。在视频对象分割和 few-shot 迁移学习任务中，潜在 MIM 超越了诸如 MAE 等像素级 MIM 技术，以及 data2vec 等先前的潜在 MIM 方法。

[3] 我们明确避免使用批量对比目标，以将研究重点放在纯掩码重构上。

2 潜在掩码图像建模

2.1 框架概述

潜在 MIM 是一种自监督学习框架，旨在通过潜在空间中的掩码图像建模来学习视觉表示。如 Fig. 2所示，潜在 MIM 模型包含三个组成部分：一个在线编码器 $f(\cdot)$、一个目标编码器 $f_T(\cdot)$，以及一个解码器 $g(\cdot)$。与基于像素的 MIM 方法 [3,13] 类似，每张图像首先被划分为一组 L 的小块 x_i，以及它们在图像中的位置 p_i。这组 $X = \{(x_i, p_i)\}_{i=1}^{L}$ 被随机分割为两个不相交的集合：可见 $X_{\mathcal{V}} = \{(x_i, p_i)\}_{i\in\mathcal{V}}$ 和 目标 $X_{\mathcal{T}} = \{(x_i, p_i)\}_{i\in\mathcal{T}}$ 块，其中 $\mathcal{V}$ 和 $\mathcal{T}$ 是网格位置的非重叠索引集。顾名思义，可见块用于生成图像的潜在表示，而目标块则用作重构目标。为了实现这一点，在线编码器提取可见块的潜在表示

$$\{\boldsymbol{z}_i\}_{i\in\mathcal{V}} = Z_{\mathcal{V}} = f(X_{\mathcal{V}}), \tag{1}$$

然后用于告知解码器以预测目标位置处的图像块 $P_{\mathcal{T}} = \{p_i\}_{i\in\mathcal{T}}$

$$\hat{Z}_{\mathcal{T}} = g(Z_{\mathcal{V}}, P_{\mathcal{T}}). \tag{2}$$

然而，与预测像素值不同，潜在 MIM 将从目标编码器获得的潜在表示作为重构目标，

$$\{\boldsymbol{z}_i\}_{i\in\mathcal{T}} = Z_{\mathcal{T}} = f_T(X_{\mathcal{T}}). \tag{3}$$

潜在 MIM 模型可以进一步训练以最小化预测目标表示 Δ 与目标编码器获得的表示 $\hat{Z}_{\mathcal{T}}$ 之间的差异。这是通过重构损失 $Z_{\mathcal{T}}$ 实现的。

$$\mathcal{L}_{rec} = \mathbb{E}\left[\Delta\left(Z_{\mathcal{T}}, \hat{Z}_{\mathcal{T}}\right)\right], \tag{4}$$

其中期望是针对训练数据集取的。在基于像素的 MIM 中，均方误差（MSE）是 Δ、$\Delta = \frac{1}{|\mathcal{T}|}\sum_{i\in\mathcal{T}}\|\hat{\boldsymbol{z}}_i - \boldsymbol{z}_i\|^2$ 的一个常见选择。然而，如 Section 3.4 所示，MSE 损失对于潜在空间 MIM 并不有效。

2.2 与其他框架的差异与相似之处

掩码图像建模（MIM）方法通过预测图像中被掩码的部分来学习，其目标来源于对原始图像进行简单变换所得。目标可以是原始像素 [13,31]、手工设计的特征如 HOG [25]，或预训练的特征 [3]。因此，低层次的掩码图像建

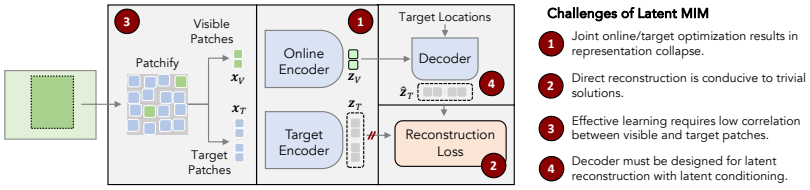

图 2: 潜在掩码图像建模概述。模型被训练以重构在隐藏位置由目标编码器生成的潜在表示。本文识别出有效部署潜在掩码图像建模所面临的四大挑战，以及相应的潜在解决方案。这些挑战涉及联合编码器最优化、直接重构损失、可见块与目标块之间的语义相关系数，以及解码器设计。

模（MIM）需要保持图像的局部表示。然而，模型容量部分被低层次细节所占用，限制了其对高层次语义的表达能力。

对比学习（CL） 相比之下，对比学习在图像所处的数据集上下文中学习每张图像的表示 [5,7,12]。尽管对比学习无需微调即可实现出色的语义表示，但在某些情况下，上下文学习可能并不理想，例如当数据分布无法提供合适的负例以突出图像之间有意义的语义差异时。批量依赖性也使得对比目标的灵活性和可复现性降低，因为其依赖于可用的计算资源。相反，纯粹的潜在掩码图像建模目标从图像本身学习表示，且独立于其他图像。

潜在 MIM 的前期探索 潜在 MIM 的潜力与其从高级别和区域感知目标中学习的能力相关联，这些目标在训练过程中不断得到改进。然而，试图部署潜在 MIM 的先前研究（e [2,6,9,21,29,32]）并未直接解决潜在 MIM 中固有的核心最优化挑战，这些挑战在 Section 3中已被讨论。这些挑战已通过将潜在 MIM 视为其他技术的补充目标（例如全局对比学习 [21,32]、低级重构 [6]）得到缓解，或者通过使用固定的预训练特征作为潜在目标 [3,9]，而非联合学习目标和在线表示。

最相关的先验工作集中在纯潜在区域的掩码图像建模（MIM）上，包括 data2vec [2]、ConMIM [29] 和 I-JEPA [1]。尽管它们做出了贡献，但 data2vec 和 ConMIM 使用掩码 token 而非图像块移除来隐藏图像区域，导致预训练与真实世界部署中未掩码图像之间存在不匹配，从而在下游任务中表现不佳，除非进行微调。I-JEPA 通过均方误差（MSE）损失在潜在空间中预测连续区域进行学习，可能导致低分辨率（“模糊”）或可定位性较差的语义信息（这是基于像素的 MIM 模型的主要优势之一）。

尽管这些工作已超越了像素级的 MIM，但它们并未深入分析或解决潜在 MIM 固有的特定挑战。因此，我们认为该框架的全部潜力尚未被挖掘，使潜在 MIM 成为一个重要且高回报的研究领域。潜在 MIM 有望生成丰富且可定位的高层语义表示，同时保持 MIM 方法特有的多样化局部块表示特性。

3 潜在 MIM 的挑战

为了更专注于潜在 MIM 最优化中的各种困难，我们分别引入并分析每一项挑战。我们首先描述一种简单的实现方法，该方法无法学习到有意义的表示。随后，我们逐一介绍四项挑战（Section 3.3-3.6），并对应对这些挑战的潜在策略进行深入分析。每个部分都建立在前一部分的发现之上，从而逐步产生越来越有效的潜在 MIM 框架实例。Fig. 1展示了这一进展过程中的性能概览。

3.1 实验设计

预训练 为了在可接受的计算预算内进行全面的实验分析，我们使用标准的 ViT-B Transformer 主干网络对在线解码器和目标解码器均进行了实验，并在 ImageNet-100（IN100）数据集上训练模型，该数据集是 ImageNet-1k 的一个子集，包含随机选取的 100 个类别。所使用的类别划分遵循 [23,27] 中的方法。该数据集包含约 125,000 张图像，足以执行具有统计显著性的实验。第 4 节进一步讨论了所提出框架在更大数据集（如 ImageNet-1k）背景下的缩放特性。

所有模型均使用 AdamW [16] 优化器进行了 300 轮次的预训练，批量大小为 1024，基础学习率为 1.5×10^{-4} ，包含 30 轮次的预热阶段和余弦衰减调度。对输入图像应用了数据增强，包括随机水平翻转和随机图像裁剪，裁剪区域的极小点为 0.2。

下游任务 我们使用最近邻、线性探测和微调方法在相同数据集上评估了所有模型。对于**最近邻**评估，我们提取测试集中所有图像的表示，并报告其最近邻具有相同类别的样本比例。对于**线性探测**，我们使用 LARS 优化器 [30] 训练 20 轮次，基础学习率为 0.5，预热 2 轮次，批量大小为 1024。对于**微调**，我们使用 AdamW [16] 优化器训练 50 轮次，基础学习率为 0.001，权重衰减为 0.05，预热 5 轮次，批量大小为 1024。

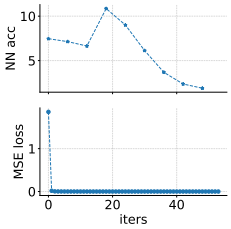

图 3: Naive 潜在 MIM 的训练崩溃。该解决方案实现了零重构损失，但未能捕捉输入图像的任何有意义信息。因此，最近邻（NN）评估表现随机。上图：NN 准确率；下图：训练损失。

3.2 朴素潜在 MIM

为了充分理解通过潜在变量掩码图像建模（Latent MIM）学习有意义表示所涉及的复杂性，我们从一个简单且直观的实现开始讨论，紧密遵循基于像素的 MIM 模型 [13] 的方法。分辨率为 224× 224 的输入图像被划分为一个 14× 14 的规则补丁网格，并按 25/75% 的比例划分，分别生成可见/目标补丁集合。随后，我们使用标准的 ViT-B Transformer [10] 对可见补丁和目标补丁分别进行编码（f 和 f_T），并使用 Transformer 解码器 g 从可见补丁的潜在表示中重建目标补丁。我们采用与 MAE [13] 中相同的自注意力解码器，但将其深度减少至仅 3 层，因为在潜在变量 MIM 中，解码任务（从潜在变量预测潜在变量）比基于像素的 MIM（从潜在变量预测像素）要简单。在线编码器、目标编码器和解码器通过预测潜在变量与目标潜在变量之间的均方误差（MSE）损失联合训练。

如图 Fig. 3所示，朴素潜在 MIM 模型极不稳定。我们观察到，在少量迭代后，该模型迅速坍塌至退化解。后续章节旨在探究这一现象的潜在成因，并提出相应的缓解策略。

3.3 挑战 1：潜在目标最优化

潜在表示坍缩在隐式掩码图像建模（MIM）中与无负样本对比学习方法（如 BYOL [12]）的发现一致。不足为奇的是，因为在线编码器和目标编码器都旨在最小化它们表示之间的差异，这很容易导致退化解，即所有图像都被映射到相同的潜在空间。防止坍缩的常见策略包括在编码器之间引入不对称性，并将目标编码器从梯度计算中分离出来 [12]。我们探索了三种策略：

Stand-alone target encoder. 第一种策略是将目标编码器与在线编码器独立处理，不进行权共享。

Weight-sharing with stop gradient. 或者，我们可以使用具有共享权重的孪生架构，但避免使用目标网络的梯度来更新在线编码器。

表 1: 目标编码器最优化。除了下游性能外，我们还报告了（均值池化后的）潜在表示之间的平均成对余弦相似度 Z 。

Method	Sim	NN	LP	Ft
Naive Latent-MIM	1.00	0.9	7.9	nan
No weight sharing	0.96	3.4	7.6	44.4
Weight sharing & stop-grad	0.99	11.3	26.6	56.9
Momentum targets	**0.50**	18.8	39.3	79.7
MAE [13]	0.67	**30.0**	**70.4**	**88.3**

Momentum targets. 使用动量编码器 [22] 也是一种常见的创建不对称性的策略，并同时增强目标编码器。随着 $f(\cdot)$ 的演化，其权重的指数移动平均被追踪，并用作动量编码器的权重 $\bar{\theta} \leftarrow m\theta + (1-m)\bar{\theta}$ 。

研究结果 我们报告了 Table 1 中各种模型的性能。为了评估表示坍塌情况，我们计算了潜在空间中样本之间的成对相似度。如预期所示，朴素的潜在型 MIM 模型发生了坍塌，所有样本都被映射到相同的潜在表示（相似度为 1.0）。如较低的余弦相似度所示，所有三种策略均有助于防止完全的表示坍塌，其中动量目标在下游分类任务中始终优于其他策略。然而，没有任何一种策略能够达到 MAE 的性能水平，这表明潜在目标最优化并非影响潜在型 MIM 成功的唯一因素。

3.4 挑战 2：潜在 MIM 的重构目标

在基于像素的掩码图像建模中，通过最小化解码器输出与目标位置像素强度之间的均方误差（MSE），强制执行补丁重构。为了从有限的可见上下文中准确重构目标像素，模型被鼓励学习能够捕捉全局语义以及补丁特有信息的表示。然而，在潜在空间掩码图像建模（Latent MIM）中，目标是学成的潜在表示，因此我们假设直接的重构目标也可能导致最优化挑战，因为缺乏负例来稳定学习过程。因此，我们研究了不同重构目标对潜在空间掩码图像建模有效性的影响。

直接重构 我们研究了三种直接最小化预测表示与目标表示之间差异的损失函数，即均方误差（MSE）、L1 和 Huber 损失。尽管 MSE 由于其简单性和有效性而被广泛使用，但 L1 损失对异常值具有鲁棒性。Huber 损失通过在小误差时采用二次形式、大误差时采用线性形式，结合了 MSE 和 L1 损失的优点，从而在鲁棒性与效率之间取得了平衡。

数学上，第 k 个目标块的重构损失为

$$\Delta_{L2}^{k} = \|\hat{\boldsymbol{z}}_k - \boldsymbol{z}_k\|_2^2, \quad \Delta_{L1}^{k} = \|\hat{\boldsymbol{z}}_k - \boldsymbol{z}_k\|_1, \tag{5}$$

$$\Delta_{Huber}^{k} = \begin{cases} \frac{1}{2}\Delta_{L2}^{k} & \text{if } \Delta_{L2} < \delta^2 \\ \delta \cdot \left(\Delta_{L1}^{k} - \delta/2\right) & \text{otherwise.} \end{cases} \tag{6}$$

补丁辨别 直接重构潜在变量的 MIM 的主要缺点在于其无法显式激励模型学习图像中多样化的表示。这与基于像素的 MIM 不同，后者能保证图像中像素强度的变化。为克服这一限制，我们提出一种块判别目标，通过 InfoNCE 损失 [18] 训练模型以区分目标块。具体而言，对于每个目标块 k，预测的潜在表示 $\hat{\boldsymbol{z}}_k$ 将与所有目标块的潜在表示 $\boldsymbol{z}_l$ 进行对比。

$$\Delta_{PatchDisc}^{k} = -\tau \log \frac{\exp\left(-\frac{1}{\tau}\texttt{sim}\left(\hat{\boldsymbol{z}}_k, \boldsymbol{z}_k\right)\right)}{\sum_{l\in\mathcal{T}} \exp\left(-\frac{1}{\tau}\texttt{sim}\left(\hat{\boldsymbol{z}}_k, \boldsymbol{z}_l\right)\right)}, \quad \texttt{sim}(\hat{\boldsymbol{z}}, \boldsymbol{z}) = \frac{\hat{\boldsymbol{z}}^T \boldsymbol{z}}{\|\hat{\boldsymbol{z}}\|\|\boldsymbol{z}\|} \tag{7}$$

其中 τ 为温度超参数。[4] 为了最小化这种损失，模型不仅必须准确对齐预测的潜在变量和目标潜在变量，还必须确保图像内潜在变量之间的充分多样性。

研究结果 我们比较了上述各项潜在表示重构的损失函数。基于 Section 3.3 的发现，目标由动量编码器计算得出。Table 2 中展示的结果表明，尽管仍不足以通过潜在 MIM 实现有效的表示学习，但区块判别损失（PatchDisc）所学得的表示优于直接重构损失。特别是，我们注意到最近邻和线性探测准确率有显著提升，这两项指标对学成表示的质量更为敏感。

Loss	NN	LP	Ft
MSE	18.8	39.3	79.7
L1	15.2	36.7	81.7
Huber	24.3	46.4	82.1
PatchDisc	**30.0**	53.4	86.0
MAE [13]	**30.0**	**59.9**	**88.3**

表 2：损失影响。

3.5 挑战 3：相邻图像块之间的语义相关系数

图像内容在邻近区域具有较高的相关性。这使得掩码重构变得简单，因为模型可以从附近的可见块中插值缺失信息。为了应对这一问题，基于像素的 MIM 会遮蔽图像的较大比例（高达 75%）[13]。潜在表示预期包含高层

[4] 块级判别损失没有批量依赖性，因为负例来自图像本身。

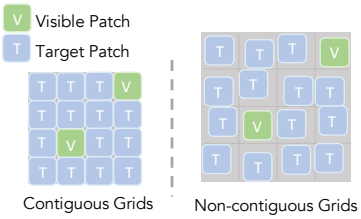

图 4: 补丁生成策略。左：掩码连续网格。右：非连续随机掩码。

Mask	Gap	Sim.	NN	LP	Ft
0.75	0	✗	30.0	53.4	86.0
0.9	0	✗	53.3	70.4	87.6
0.9	4	✗	54.6	71.2	88.0
0.9	4	✓	**56.8**	**72.9**	**88.5**
MAE [13]			30.0	59.9	88.3

表 3: 通过采用高掩码比率、非连续随机掩码以及逐块相似度约束等策略，降低语义相关性缓解带来的改进。

语义，其跨块的相关性比对应像素更高。这种相关性可能削弱任务在表示学习中的有效性。

高掩码比率。潜在 MIM 也受益于高掩码比率。除了降低图像块相关系数并增强表示学习外，该策略还能实现更快的训练速度和更低的 GPU 内存占用。然而，必须保留足够的可见图像块以捕捉图像中的关键特征。

非连续网格。为了进一步降低可见块与目标块之间的相关系数，同时不减少可见线索的数量，我们尝试使用随机非连续网格（Fig. 4）。该策略通过在每个块与其相邻块之间插入随机数量的未使用像素，增加了块之间的距离。具体而言，设 P 为块的大小，G 为连续块之间的平均间隔。可以通过先将图像划分为大小为 $(P+G)\times(P+G)$ 的规则网格，然后从每个网格位置随机提取一个 $P\times P$ 块，从而方便地生成随机非连续网格。

补丁相似度约束 尽管先前的策略通过优化补丁选择过程来降低相关系数，我们也可以施加显式约束以避免潜在空间中的相关性。这一点尤为重要，因为如前所述的挑战（Table 2）所示，当在无约束条件下训练时，补丁表示倾向于聚集在一起。为应对这一问题，我们对可见和预测的潜在表示 $Z_{\mathcal{V}}$ 和 $\hat{Z}_{\mathcal{T}}$ 施加约束，

$$\mathcal{R} = \left(\gamma - \mathbb{E}_{i,j\in\mathcal{T}}\left[\mathtt{sim}\left(\hat{\boldsymbol{z}}_i, \hat{\boldsymbol{z}}_j\right)\right]\right)^2 + \left(\gamma - \mathbb{E}_{i,j\in\mathcal{V}}\left[\mathtt{sim}\left(\boldsymbol{z}_i, \boldsymbol{z}_j\right)\right]\right)^2, \tag{8}$$

其中 γ 为预定义的期望块间相似度。

研究结果 我们再次基于前一个挑战的发现，使用补丁判别来实现潜在表示的重构。Table 3 展示了每种缓解语义相关性的策略对表示质量的增量改进。潜在 MIM 在比像素级 MIM 更高的掩码比例下仍表现出显著提升，最优比例为 90%。超过 90% 的掩码比例反而会适得其反，因为可见补丁数量不足，

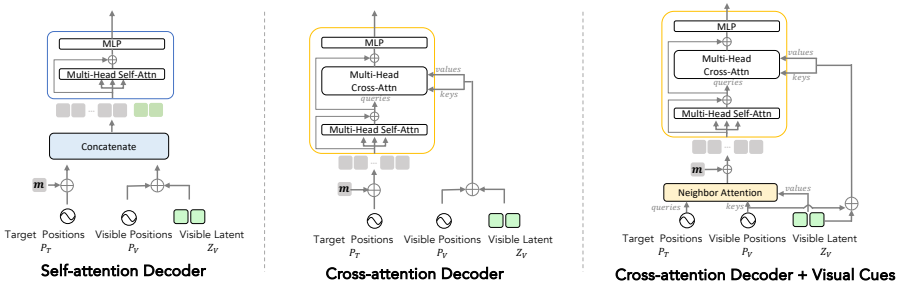

图 5: 三种不同解码器设计的比较。自注意力解码器常用于低层次的 MIM 模型中。交叉注意力解码器在每一层上直接对可见潜在变量进行条件控制。

难以捕捉图像中的关键特征。采用非连续随机掩码（gap=4）可进一步提升表示质量，通过降低空间冗余性同时保留足够的可见信息。最后，添加一个显式约束补丁间平均相似度的正则化项也能增强性能。我们将每种策略的消融实验及更多探索内容放在 Section B 中。

3.6 挑战 4：用于潜在重构的解码器设计

潜在掩码图像建模（Latent MIM）的最后一个关键组件是解码器，其负责从可见图像块中预测目标表示。解码器的设计对于模型有效利用编码器提取的高层语义至关重要。我们探讨了不同解码器架构的影响。

自注意力解码器 基于像素的 MIM 模型使用自注意力 Transformer 来预测目标像素 $X_{\mathcal{T}}$ 。为了完成这一任务，解码器接收两组输入：可见块的潜在表示 $Z_{\mathcal{V}}$ 以及一组可学习的掩码 token $\boldsymbol{m}$ ，这些 token 由其对应位置的固定 SinCos 位置嵌入 $\boldsymbol{p}$ 标记（即 $\boldsymbol{m}+\boldsymbol{p}_t\ \forall t\in\mathcal{T}$ 和 $\boldsymbol{z}_v+\boldsymbol{p}_v\ \forall v\in\mathcal{V}$ ）。经过一系列自注意力块的处理后，解码器通过线性头输出目标表示。

交叉注意力解码器 与基于像素的 MIM 不同，在潜在 MIM 中，目标 $Z_{\mathcal{T}}$ 是与编码器 $Z_{\mathcal{V}}$ 所获得特征具有相似抽象层次的表示。因此，解码器能够更直接地依赖这些可见表示 $Z_{\mathcal{V}}$ 。虽然自注意力仅通过输入序列一次进行条件化 $Z_{\mathcal{T}}$ ，但交叉注意力使解码器能够在每一层上对 $Z_{\mathcal{V}}$ 进行条件化。采用标准的交叉注意力架构 [24]，交替使用自注意力、交叉注意力和前馈 MLP 块来更新预测 token $\boldsymbol{m}+\boldsymbol{p}_t\ \forall t\in\mathcal{T}$ 。

来自邻近可见区域的视觉线索 如 (Section 3.5) 所讨论，相邻补丁的潜在表示具有高度相关性。为防止解码器过度关注这些补丁之间的插值，我们直接

表 4: 不同解码器设计的比较. 其他配置遵循前文找到的最优情景.

Decoder	Proj.	Depth	NN	LP	Ft
Self-attn	none	3	56.8	72.9	88.5
Self-attn	mlp	3	59.7	76.8	89.4
Cross-attn	mlp	3	61.1	77.0	89.4
Cross-attn w/ Vis Cues	mlp	3	**63.3**	**77.3**	**89.9**
Cross-attn w/ Vis Cues	mlp	8	35.9	65.8	86.2
MAE [13]		8	30.0	59.9	88.3

将视觉线索嵌入到其输入序列中。这使得解码器能够更好地专注于更精细的空间推理。

具体而言，以 $P_{\mathcal{V}}$ 和 $P_{\mathcal{T}}$ 分别作为可见补丁和目标补丁的位置嵌入，我们在每个目标位置 $i \in \mathcal{T}$ 初始化预测 token 为 $\boldsymbol{m}_i = \boldsymbol{m} + \boldsymbol{p}_t + Softmax_t\left(P_{\mathcal{T}} P_{\mathcal{V}})^T\right) Z_{\mathcal{V}}$。这种设置使掩码 token $M_{\mathcal{T}} = \{\boldsymbol{m}_i\}_{i \in \mathcal{T}}$ 获得来自最近可见补丁的潜在表示的加权混合，从一开始就提供精确的位置和视觉线索。

潜在投影仪 遵循对比学习方法，我们实验了非线性投影头 $h(\cdot)$，以准备来自可见块的潜在表示 $Z_{\mathcal{V}}$ 供解码器使用。通过一系列使用不同非线性投影器 h 的实验，我们发现一个包含三层的多层感知机（MLP），采用 GELU 活性值和层规范化，产生了最有效的表示。

研究结果 Table 4 评估了不同解码器设计对学成表示质量的影响。基于像素的 MIM 模型（如 MAE）采用深度为 8 层的轻量级自注意力解码器。我们的研究结果强调了针对潜在空间 MIM 需要采用不同的解码器设计，因为解码器的任务性质有所不同。

具体而言，我们发现交叉注意力能够更有效地将重构过程与可见块进行条件关联，从而在所有下游任务中均取得更优性能，尤其是在使用邻近可见块的视觉线索初始化预测 token，且结合非线性投影头处理输入可见块时表现尤为突出。

此外，由于输入和目标均为高层特征，潜在空间 MIM 解码器可设计得极为轻量。采用浅层（3 层）Transformer 即可达到最优性能，远小于 MAE 解码器的 8 层结构。

综上所述，这些策略使解码器能够更好地利用编码器提取的高层语义特征，在所有下游任务中的表现均超越基于像素的 MIM 模型。

4 缩放至 ImageNet-1k

上一节详细分析了在中等规模数据集上对潜在 MIM 的最优化挑战和设计决策。本节展示了潜在 MIM 在更大数据集（特别是 ImageNet-1k）上的可扩展性，并与先前的工作进行比较。此外，我们通过在无监督场景分割、视频目标分割和 few-shot 迁移学习任务上评估训练好的模型，突出了潜在 MIM 所学得的强局部语义特性。

实施 我们使用 Section 3 中最优的潜在 MIM 配置，将预训练规模扩展到 ImageNet-1k。该模型使用 Adam 优化器进行 800 轮次的预训练。完整实现细节见 Section A。

4.1 ImageNet-1k 分类

遵循 [13]，我们使用最近邻（NN）和线性探测（LP）协议在 ImageNet-1K 上评估学成表示。Table 5 将我们的潜在 MIM 与低层 MIM 方法以及先前的潜在 MIM 方法在 ViT-B/16 上进行了比较。对于 MAE 和 data2vec，我们采用表现最佳的特征（无论是 cls-token 还是平均汇聚）。

潜在 MIM 在 NN 分类任务上显著优于低层级 MIM 方法（平均绝对误差降低 37.2%），在 LP 任务上也表现优异（平均绝对误差降低 3.3% 且 SimMIM 提升 14.4%），充分证明了通过潜在掩码重构学习更优语义的有效性。此外，我们的方法相较于相关先验工作 data2vec 和 ConMIM 也取得了显著优势。

表 5: Top-1 NN 和 LP 在 ImageNet 上的分类准确率。

Method	Epochs	NN	LP
Low-level			
MAE [13]	1600	12.2	67.8
SimMIM [28]	800	-	56.7
Latent			
ConMIM [29]	800	-	39.3
data2vec [2]	800	25.7	60.3
Latent MIM	800	**50.1**	**72.0**

4.2 分类之外的特性

潜在 MIM 框架旨在学习可定位且语义丰富的表示。我们通过无监督分割、半监督视频对象分割以及迁移学习展示了这些特性。

无监督分割 潜在 MIM 的一个新兴特性是其对局部式表征进行语义聚类的能力，这使得无需监督微调即可实现出色的分割和场景解析效果。Fig. 6 展示了通过层次聚类得到的补丁级表征生成的无监督分割图。与诸如 MAE 等

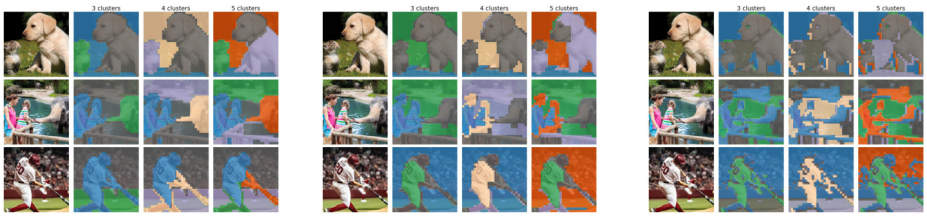

(a) 潜在 MIM **(b)** data2vec **(c)** MAE

图 6: 无监督分割图通过在每幅图像内对块表示进行层次聚类得到。建议数字放大后查看。

Method	**epochs**	$\mathcal{J}\&\mathcal{F}_m$	$\mathcal{J}_m$	$\mathcal{F}_m$
MAE	1600	57.5	54.8	60.2
data2vec	800	28.5	27.8	29.2
Latent MIM	800	**65.5**	**63.1**	**68.0**

表 6: 视频对象分割在 DAVIS-2017 上。$\mathcal{J}$ 和 $\mathcal{F}$ 分别量化区域相似度和边界对齐度。

图 7: 可视化. 第 1 列：真实值；第 2-3 列：在 25%、50% 和 100% 时间步的预测结果。

低层级 MIM 方法以及 data2vec 等早期潜在 MIM 方法相比，我们的潜在 MIM 模型学习到了更优的语义和可定位表征。

视频目标分割 我们的潜在 MIM 模型在复杂、动态的视频序列中也能保持语义完整性和定位准确性。DAVIS-2017 半监督视频对象分割基准评估了从初始帧的真实值掩码出发，生成视频中精确对象分割掩码的能力。我们遵循 [14] 中的实验协议，通过在连续帧之间应用最近邻策略来分割场景。关键在于，该基准测试无需额外训练即可检验预训练特征的鲁棒性和适应性。Table 6显示，潜在 MIM 在性能上超越了像素级和先前的潜在 MIM 模型。Fig. 7展示了样本的定性结果。

少样本迁移学习 为了评估超越 ImageNet-1k 的泛化能力，我们将学成的表示迁移至多种数据集。按照 [33] 的情景，我们通过在冻结表示上训练一个线性分类器，进行 16 次射击的迁移学习实验。所有模型均使用带有 0.9 动量的 SGD 进行训练，学习率为 0.1，批量大小为 128，并总共更新 2500 次

面向潜在掩码图像建模的自监督视觉表示学习 15

表 7: 在多种数据集上的少样本学习。我们报告了在 3 次不同运行中顶-1 准确率的均值和标准差。每次运行均使用每类 16 张训练图像进行训练。

Method	Caltech101 [11]	DTD [8]	Oxford Flowers [17]	Oxford Pets [19]	Stanford Cars [15]	SUN397 [26]	UCF101 [20]
MAE	80.5± 0.4	51.8± 2.2	62.7± 1.8	60.2± 3.6	7.8± 1.0	21.9± 0.4	53.2± 0.4
data2vec	76.6± 2.1	52.0± 2.1	74.1± 2.2	58.5± 2.0	8.8± 0.4	29.0± 0.5	52.6± 1.2
Latent MIM	**89.2**± 1.0	**55.9**± 2.0	**84**± 1.0	**79.8**± 2.6	**16.3**± 2.0	**48.4**± 0.6	**75.8**± 2.8

迭代。Table 7 展示了潜在 MIM 在所有数据集上均优于 MAE 和 data2vec，突显了其鲁棒性、通用性以及在各种识别任务中的潜力。

5 结论

我们识别并解决了潜在 MIM 中的关键训练挑战，证明了其生成空间多样且具有高级语义表示的能力。这在 ImageNet 上的最近邻和线性探测评估、少样本迁移学习以及需要极少或无需监督的分割任务中得到了显著提升的证据支持。我们希望这项工作能激发人们对潜在 MIM 在无监督情况下学习细粒度语义的进一步探索。

参考文献

1. Assran, M., Duval, Q., Misra, I., Bojanowski, P., Vincent, P., Rabbat, M., LeCun, Y., Ballas, N.: Self-supervised learning from images with a joint-embedding predictive architecture. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (2023) 5
2. Baevski, A., Hsu, W.N., Xu, Q., Babu, A., Gu, J., Auli, M.: Data2vec: A general framework for self-supervised learning in speech, vision and language. In: International Conference on Machine Learning. pp. 1298–1312. PMLR (2022) 5, 13, 23
3. Bao, H., Dong, L., Piao, S., Wei, F.: Beit: Bert pre-training of image transformers. In: Proceedings of the International Conference on Learning Representations (ICLR) (2021) 1, 4, 5
4. Bao, H., Dong, L., Piao, S., Wei, F.: BEIT: BERT pre-training of image transformers. arXiv preprint arXiv:2106.08254 (2021) 23

5. Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., Joulin, A.: Emerging properties in self-supervised vision transformers. In: Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) (2021) 5, 23

6. Chen, X., Ding, M., Wang, X., Xin, Y., Mo, S., Wang, Y., Han, S., Luo, P., Zeng, G., Wang, J.: Context autoencoder for self-supervised representation learning. International Journal of Computer Vision pp. 1–16 (2023) 5, 23

7. Chen*, X., Xie*, S., He, K.: An empirical study of training self-supervised vision transformers. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) (2021) 5, 23

8. Cimpoi, M., Maji, S., Kokkinos, I., Mohamed, S., , Vedaldi, A.: Describing textures in the wild. In: Proceedings of the IEEE Conf. on Computer Vision and Pattern Recognition (CVPR) (2014) 15

9. Dong, X., Bao, J., Zhang, T., Chen, D., Zhang, W., Yuan, L., Chen, D., Wen, F., Yu, N., Guo, B.: Peco: Perceptual codebook for bert pre-training of vision transformers. In: Proceedings of the AAAI Conference on Artificial Intelligence. vol. 37, pp. 552–560 (2023) 5, 23

10. Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., Houlsby, N.: An image is worth 16x16 words: Transformers for image recognition at scale. In: Proceedings of the International Conference on Learning Representations (ICLR) (2020) 7, 18

11. Fei-Fei, L., Fergus, R., Perona, P.: Learning generative visual models from few training examples: An incremental bayesian approach tested on 101 object categories. In: 2004 conference on computer vision and pattern recognition workshop. pp. 178–178. IEEE (2004) 15

12. Grill, J.B., Strub, F., Altché, F., Tallec, C., Richemond, P.H., Buchatskaya, E., Doersch, C., Pires, B.A., Guo, Z.D., Azar, M.G., Piot, B., Kavukcuoglu, K., Munos, R., Valko, M.: Bootstrap your own latent: A new approach to self-supervised learning. In: Advances in Neural Information Processing Systems (NeurIPS) (2020) 5, 7

13. He, K., Chen, X., Xie, S., Li, Y., Dollár, P., Girshick, R.: Masked autoencoders are scalable vision learners. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). pp. 16000–16009 (2022) 1, 4, 7, 8, 9, 10, 12, 13, 18, 23

14. Jabri, A., Owens, A., Efros, A.: Space-time correspondence as a contrastive random walk. Advances in neural information processing systems **33**, 19545–19560 (2020) 14

15. Krause, J., Stark, M., Deng, J., Fei-Fei, L.: 3d object representations for fine-grained categorization. In: Proceedings of the IEEE international conference on computer vision workshops. pp. 554–561 (2013) 15

16. Loshchilov, I., Hutter, F.: Decoupled weight decay regularization. In: International Conference on Learning Representations (2018) 6

17. Nilsback, M.E., Zisserman, A.: Automated flower classification over a large number of classes. In: 2008 Sixth Indian Conference on Computer Vision, Graphics & Image Processing. pp. 722–729. IEEE (2008) 15

18. Oord, A.v.d., Li, Y., Vinyals, O.: Representation learning with contrastive predictive coding. arXiv preprint arXiv:1807.03748 (2018) 9

19. Parkhi, O.M., Vedaldi, A., Zisserman, A., Jawahar, C.: Cats and dogs. In: 2012 IEEE conference on computer vision and pattern recognition. pp. 3498–3505. IEEE (2012) 15

20. Soomro, K., Zamir, A.R., Shah, M.: Ucf101: A dataset of 101 human actions classes from videos in the wild. arXiv preprint arXiv:1212.0402 (2012) 15

21. Tao, C., Zhu, X., Su, W., Huang, G., Li, B., Zhou, J., Qiao, Y., Wang, X., Dai, J.: Siamese image modeling for self-supervised vision representation learning. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 2132–2141 (2023) 5

22. Tarvainen, A., Valpola, H.: Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results. Advances in Neural Information Processing Systems (NeurIPS) **30** (2017) 8

23. Tian, Y., Krishnan, D., Isola, P.: Contrastive multiview coding. In: Proceedings of the European Conference on Computer Vision (ECCV). pp. 776–794. Springer (2020) 6

24. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I.: Attention is all you need. Advances in neural information processing systems **30** (2017) 11

25. Wei, C., Fan, H., Xie, S., Wu, C.Y., Yuille, A., Feichtenhofer, C.: Masked feature prediction for self-supervised visual pre-training. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 14668–14678 (2022) 4, 23

26. Xiao, J., Ehinger, K.A., Hays, J., Torralba, A., Oliva, A.: Sun database: Exploring a large collection of scene categories. International Journal of Computer Vision **119**, 3–22 (2016) 15

27. Xiao, T., Wang, X., Efros, A.A., Darrell, T.: What should not be contrastive in contrastive learning. In: Proceedings of the International Conference on Learning Representations (ICLR) (2020) 6

28. Xie, Z., Zhang, Z., Cao, Y., Lin, Y., Bao, J., Yao, Z., Dai, Q., Hu, H.: Simmim: A simple framework for masked image modeling. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 9653–9663 (2022) 13, 23

29. Yi, K., Ge, Y., Li, X., Yang, S., Li, D., Wu, J., Shan, Y., Qie, X.: Masked image modeling with denoising contrast. arXiv preprint arXiv:2205.09616 (2022) 5, 13, 23

30. You, Y., Gitman, I., Ginsburg, B.: Large batch training of convolutional networks. arXiv preprint arXiv:1708.03888 (2017) 6

31. Zhang, R., Guo, Z., Gao, P., Fang, R., Zhao, B., Wang, D., Qiao, Y., Li, H.: Point-m2ae: multi-scale masked autoencoders for hierarchical point cloud pre-training. arXiv preprint arXiv:2205.14401 (2022) 4

32. Zhou, J., Wei, C., Wang, H., Shen, W., Xie, C., Yuille, A., Kong, T.: ibot: Image bert pre-training with online tokenizer. arXiv preprint arXiv:2111.07832 (2021) 5, 23

33. Zhou, K., Yang, J., Loy, C.C., Liu, Z.: Conditional prompt learning for vision-language models. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 16816–16825 (2022) 14

附录

A 实现细节

A.1 最优化细节

为确保可复现性，我们在 Table 8 中提供了所有实验的详细实现细节。该表格展示了用于预训练以及线性探测和微调下游任务的超参数，涵盖主研究（正文第 3 节）和 ImageNet-1k 数据集（正文第 4 节）的情况。这些配置与先前工作 [13] 所使用的保持一致。

表 8: 主研究（第 3 节）和 ImageNet-1k 数据集（第 4 节）所使用的实现细节，若有所不同。

(a) 预训练配置。

Config	Value (Main, Sec 3)	Value (IN1K, Sec 4)
Backbone	ViT-B/16	
Dataset	ImageNet-100	ImageNet-1k
Optimizer	AdamW	
Epochs	300	800
Batch size	1024	4096
LR Schedule	Cosine Decay w/ Warmup	
Base LR	1.5e-4	
Warmup Epochs	30	40
Weight Decay	0.05	
Optimizer Momentum	$\beta_1 = 0.9$, $\beta_2 = 0.95$	
Target Encoder Momentum	$0.99 \rightarrow 1.0$	
Data Augmentations	RandomHorizontalFlip RandomResizedCrop	

(b) 线性探测配置。

Config	Value (Main, Sec 3)	Value (IN1K, Sec 4)
Dataset	ImageNet-100	ImageNet-1k
Optimizer	LARS	
Epochs	20	90
Batch size	1024	16384
LR Schedule	Cosine Decay w/ Warmup	
Base LR	0.5	0.1
Warmup Epochs	2	10
Weight Decay	0.	
Optimizer Momentum	0.9	
Data Augmentations	RandomHorizontalFlip RandomResizedCrop	

(c) 微调配置。

Config	Value (Main, Sec 3)	Value (IN1K, Sec 4)
Dataset	ImageNet-100	ImageNet-1k
Optimizer	AdamW	
Epochs	50	100
Batch size	1024	
LR Schedule	Cosine Decay w/ Warmup	
Base LR	1e-3	5e-4
Warmup Epochs	5	10
Weight Decay	0.05	
Optimizer Momentum	$\beta_1 = 0.9$, $\beta_2 = 0.999$	
Data Augmentations	RandAug(9,0.5)	
Label Smoothing	0.1	
Mix-Up	0.8	
Cut-Mix	1.0	
Drop Path	0.1	

A.2 用于 ImageNet-1k（第 4 节）的潜在 MIM 配置

我们使用主文中第 3 节讨论的最优潜在 MIM 配置，将预训练规模扩展至 ImageNet-1k。我们采用标准的 ViT-B/16 [10] 作为在线编码器和动量编码器，并使用第 3 节主文中描述的带有视觉线索的 3 层交叉注意力解码器。投影器为一个 3 层 MLP，隐藏维度为 4096，激活函数为 GELU，使用层范数。我们采用 90% 的掩码比例，以间隔 $G = 4$ 的非连续方式对 14× 14 网格进行掩码，每样本产生 20 个可见块和 176 个目标块。模型在补丁判别损失的基础上，同时施加对 $Z_{\mathcal{V}}$ 和 $\hat{Z}_{\mathcal{T}}$ 的相似度约束，约束系数为 0.1，其中目标相似度按余弦调度从 0.75 更新至 0.25。对于线性探测和微调，我们也尝试了分类前用于特征抽取的池化方法。除了标准的最大汇聚、平均池化以及使用 CLS token 外，我们还应用了一种介于最大与平均池化之间的池化方法，即对顶部 k 个特征值进行平均。实证结果表明，设置 $k = 10$ 能够获得最佳性能。

B 补充分析

B.1 与 I-JPEA 的比较

I-JEPA 是在纯潜在信息掩码（MIM）中的一次先验探索，已展现出有前景的结果，但仍表现出训练不稳定的迹象。Fig. 8 展示了使用 ViT-B 在 ImageNet-1K 上训练 800 轮的 I-JEPA 训练曲线。注意训练末期性能出现明显下降，这可能是由于直接采用 MSE 图块重构损失，我们证明该损失容易导致退化解。此外，我们发现我们的方法获得的语义定位比 I-JEPA 更精确。我们将模型与预训练的 I-JEPA ViT-H/14 在视频对象传播 (Table 9) 和无监督分割 (Fig. 9) 上进行了对比。即使使用更小的主干网络，我们的模型也优于 I-JEPA。这些改进得益于我们对局部语义的强调，这是潜在 MIM 的一个关键优势。我们的研究识别出在不牺牲局部语义的前提下稳定潜在 MIM 训练的方法。

B.2 潜在 MIM：从低层潜在变量到高层潜在变量。

为了评估不同目标类型下学成表示的有效性，我们在训练过程中使用了深度不同的动量编码器进行实验，其深度范围从 0（即像素重构）到完整的深度为 12 的动量编码器。我们还发现，目标深度的选择显著影响了最优解

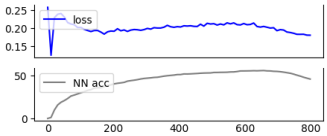

图 8: I-JPEA 训练。

Method	Backbone	$\mathcal{J}\&\mathcal{F}_m$	$\mathcal{J}_m$	$\mathcal{F}_m$
I-JEPA	ViT-H/14	62.5	60.6	64.4
Latent MIM	ViT-B/16	**65.5**	**63.1**	**68.0**

表 9: 与 I-JEPA 在 Davis-2017 上的比较。

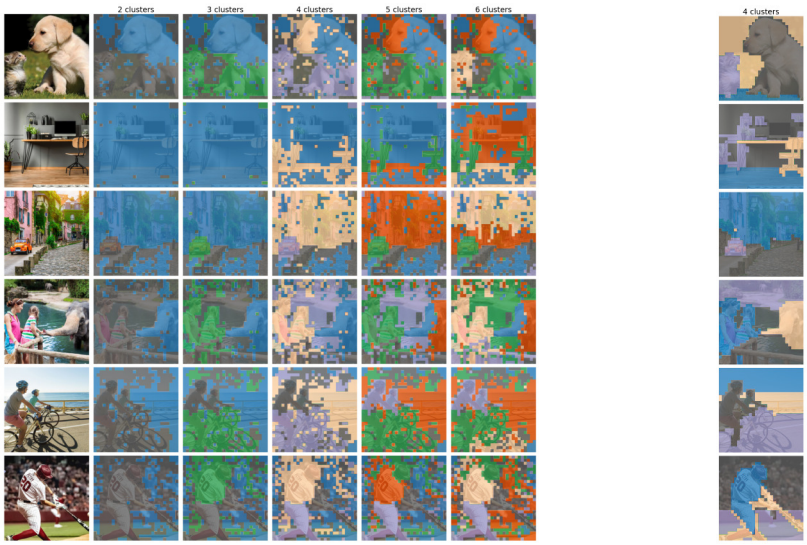

(a) I-JEPA (ViT-H/14) **(b)** 我们的（ViT-B/16）

图 9: 无监督分割图

码器的深度。因此，针对每个目标深度，我们探索了不同的解码器深度，并报告了最优配置。这些实验采用主论文第 3 节的实验设置，在挑战 4 之后找到了最优配置。Table 10 比较了各种模型的下游性能。首先，如预期所示，像素级和低层目标需要更大的解码器，因为编码器表示与目标表示之间的差距更大。其次，随着目标动量编码器变浅，我们观察到所有评估指标下的学成表示的下游性能急剧下降。这些结果表明，局部高层目标的重构具有显著益处，从而激励了潜在 MIM 框架的提出。

B.3 最优配置附近的消融实验

在主论文中，我们按顺序解决了潜在 MIM 模型所面临的挑战，提出了一系列逐步递进的解决方案。然而，早期解决方案的有效性可能源于初始潜

表 10: 使用不同深度的动量编码器和解码器时，潜在 MIM 模型在 IN100 数据集上的下游性能。

Target depth	Decoder depth	NN	LP	Ft
0	7	44.0	67.4	86.4
3	5	52.7	74.3	88.7
6	4	52.7	74.8	88.9
9	4	53.6	75.8	89.4
12	3	**63.3**	**77.3**	**89.9**

在 MIM 实现的不足之处。为了进一步剖析每个组件的影响，我们在最优配置周围进行了消融实验。这些模型的下游性能详见 Table 11。结果表明，所提出的解决方案能够有效应对挑战，即使与包含除一项外所有所提方案的稳健潜在 MIM 模型相比亦然。

C ImageNet-1K 分类：超越低级和潜在的 MIM。

主论文在 ImageNet-1k 上对先前的低级和潜在 MIM 框架进行了比较，重点关注表示质量。Table 12提供了更全面的下游性能视图，包括对除低级和潜在 MIM 之外其他方法的比较，同时评估了微调性能。

如图所示，在评估冻结表示（即最近邻分类和线性探测）时，所提出的潜在 MIM 框架优于先前的低级和潜在 MIM 方法，以及使用冻结预训练目标模型的 MIM 模型。

至于微调，尽管尚未达到最先进水平，潜在 MIM 仍取得了具有竞争力的结果，表明所提出的模型也可用于提供强大的模型初始化。由于我们主要致力于表示质量和潜在 MIM 框架的挑战，我们认为对微调方案进行更深入的探索将进一步提升我们模型的性能。

图 Table 12 的下两个面板将独立的 MIM 类别扩展为（1）全局联合嵌入框架（或对比学习）以及（2）将潜在 MIM 与额外的自监督学习目标相结合的混合变体。表现最佳的方法 iBoT 和 SIM 将潜在 MIM 与全局对比学习目标相结合，从而证明了结合互补监督来源的优势。与这些工作类似，我们的框架也可轻松与其他自监督学习目标结合，以进一步提升性能。然而，我们认为，若不借助附加目标来掩盖潜在 MIM 的缺陷，而是将其作为一个独

表 11: 最优配置附近的消融实验. 我们报告了在 IN100 数据集上的 top-1 最近邻（NN）、线性探测（Lin）和微调（Ft）准确率（%）。默认配置用 灰色 标出。

(a) 补丁间隙

g	NN	Lin	Ft
0	27.6	51.8	83.3
2	44.2	66.5	87.1
4	63.3	**77.3**	**89.9**
6	62.2	76.5	89.0
8	**63.6**	75.9	89.2

(b) 掩码比率

mask ratio	NN	Lin	Ft
0.5	7.6	26.3	71.4
0.75	44.5	71.3	89.7
0.85	61.7	76.9	89.8
0.9	**63.3**	**77.3**	**89.9**
0.95	51.3	71.0	87.8

(c) 相似度约束

Sim	NN	Lin	Ft
✗	59.9	74.0	88.7
✓	**63.3**	**77.3**	**89.9**

(d) 解码器设计

decoder	NN	Lin	Ft
Self-attn	59.7	76.8	89.4
Cross w/ Visual Cues	**63.3**	**77.3**	**89.9**

(e) 投影仪

projector	NN	Lin	Ft
none	57.8	73.0	88.7
mlp	**63.3**	**77.3**	**89.9**

(f) 损失

loss	NN	Lin	Ft
MSE	58.4	71.6	87.4
PatchDisc	**63.3**	**77.3**	**89.9**

立问题进行研究，将能加速其发展，最终促成更有效的混合方法。基于这些原因，尽管混合方法具有前景，但我们仍将其探索留作未来工作。

D 潜在 MIM 局部特征的可视化

我们通过可视化图像中学习到的局部表征，展示了潜在 MIM 特征的可定位性和语义丰富性。所有可视化结果均使用在 ImageNet-1K 上训练的 ViT-B/16 模型生成。

Fig. 11 展示了通过局部块表示进行层次聚类生成的无监督分割图，与 MAE 和 data2vec 进行对比。结果表明，相较于更底层的 MIM 方法（如 MAE）以及早期的潜在 MIM 方法（如 data2vec），我们的模型在语义聚类像素方面具有显著优势。这一表现适用于多种场景。这些定性示例也验证了

表 12: 与 ImageNet-1k 上先前工作相比。

Method	Epochs	NN	Lin	Ft
▷ *Low-level MIM*				
MAE [13]	1600	12.2	67.8	83.6
MaskFeat [25]	300	-	-	83.6
SimMIM [28]	800	-	56.7	83.8
▷ *MIM using frozen pretrained target*				
BeiT [4]	300	-	56.7	82.9
PeCo [9]	800	-	-	**84.5**
▷ *Latent MIM*				
ConMIM [29]	800	-	39.3	83.7
data2vec [2]	800	25.7	60.3	84.2
Latent-MIM (Ours)	800	**50.1**	**72.0**	83.0
▷ *Global Joint Embeddings*				
MoCo v3 [7]	300×2	61.3	76.7	83.2
DINO [5]	300	-	78.2	-
▷ *Hybrid MIM*				
iBoT [32]	1600	-	79.5	84.0
SIM	1600	-	76.4	83.6
CAE [6]	800	-	68.6	83.8

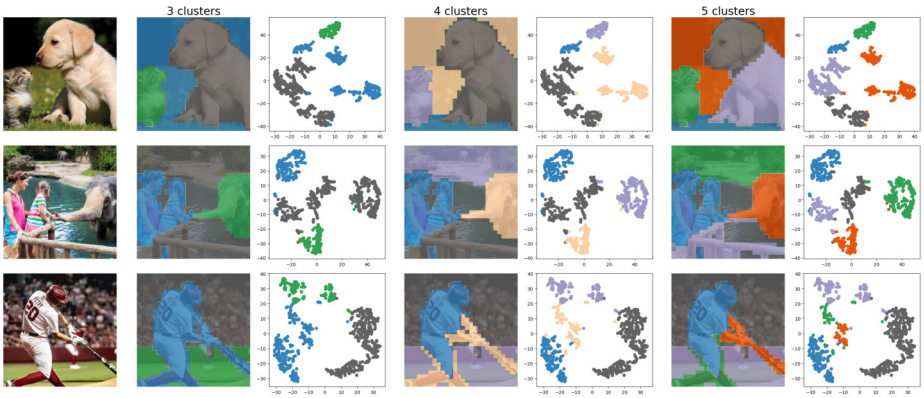

图 10: 单张图像内局部特征的层次聚类以及相应潜在特征的 t-SNE 嵌入。

我们的假设：低层 MIM 特征不足以捕捉高层语义。例如，在棒球运动员的案例中，MAE 生成的分割图显示像素似乎基于颜色进行聚类，将白色球衣与背景中的白色标志归为一类。相比之下，我们的模型能够准确捕捉场景中各个组件的语义边界。

为了进一步理解潜在 MIM 学成表示的聚类情况，我们在 Fig. 10中可视化了图像内局部特征的 t-SNE 嵌入。t-SNE 图中的每个点代表图像中的一个补丁，其颜色根据紧邻其旁分割图中所示的层次聚类标签进行编码。如图所示，潜在表示形成了与物体和物体部分分别相关的语义上有意义的簇和子簇。例如，注意棒球棒、球员身体和腿部在球员这一大簇内被分别聚类。

最后，我们在 Fig. 12 中可视化了多种图像中补丁的语义邻域。在每幅图像中，我们可视化与给定像素具有相似表示的区域。我们观察到，随着相似度阈值的降低，语义邻域变得更为包容，捕捉到图像中越来越大的区域，同时仍保持邻域的语义一致性。这表明学成的表示编码了图像的语义和空间信息。

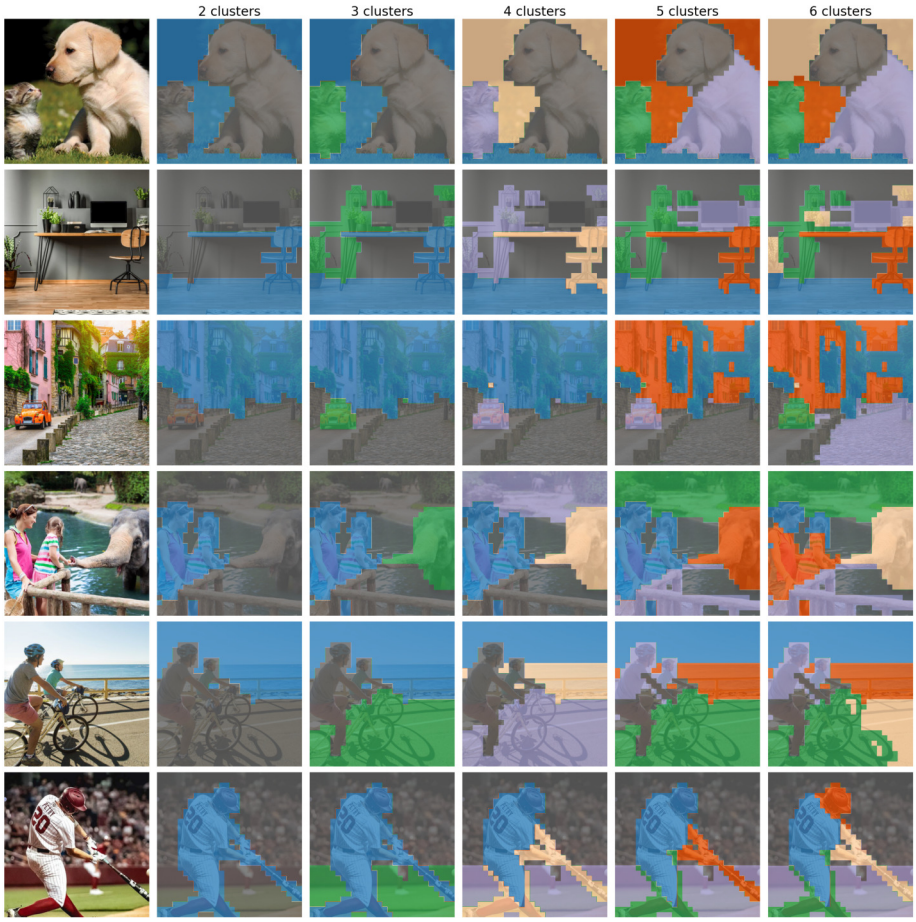

(a) 我们的

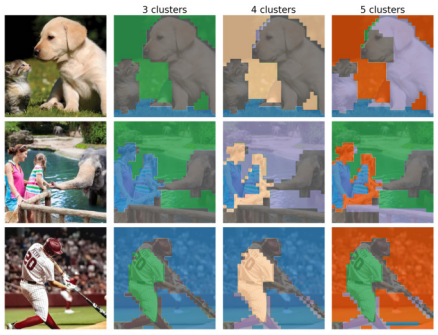

(b) data2vec

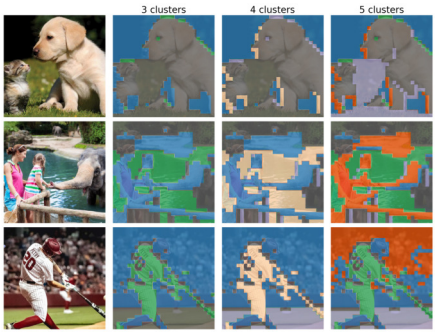

(c) MAE

图 11: 无监督分割图通过在每张图像内对块表示进行层次聚类得到。

图 12: 图像块的语义邻域。在每张图像中，我们随机选取 3 个像素点（用绿色标出），并可视化与这些像素点表示相似的图像区域，相似度通过余弦相似度衡量。相似度阈值从左到右逐渐降低。

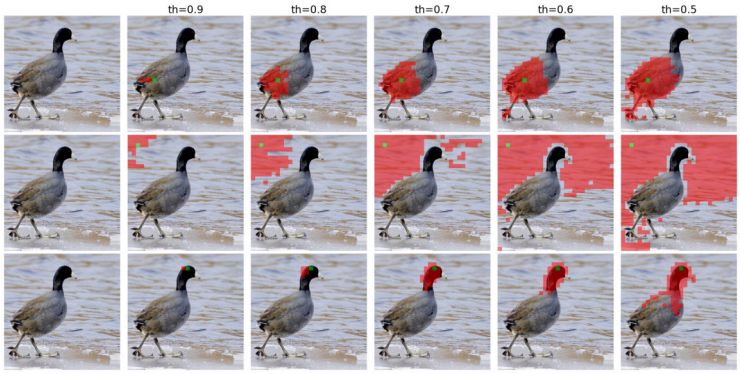

(a)

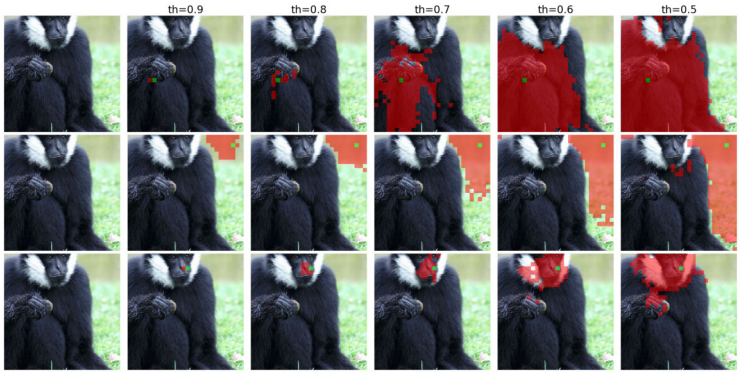

(b)

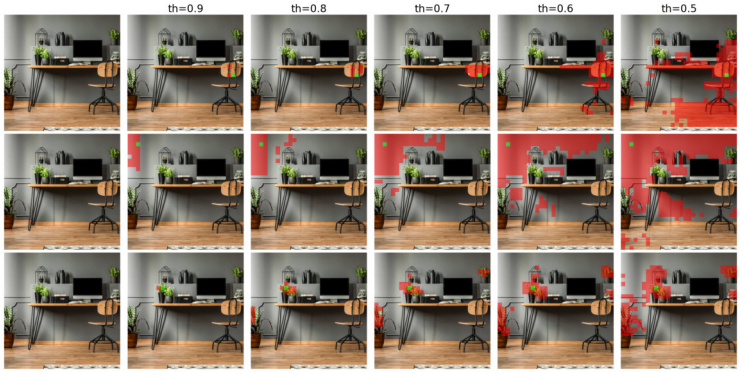

(c)