https://hjfy.top/arxiv/2511.13655

OlmoEarth：用于多模态地球观测的稳定潜在图像建模

Team OlmoEarth[★]

Henry Herzog[♥1] **Favyen Bastani**[♥1] **Yawen Zhang**[♥1] **Gabriel Tseng**[♥1] **Joseph Redmon**[♥1]

Hadrien Sablon[1] **Ryan Park**[1] **Jacob Morrison**[1,2] **Alexandra Buraczynski**[1]
Karen Farley[1] **Joshua Hansen**[1] **Andrew Howe**[1] **Patrick Alan Johnson**[1] **Mark Otterlee**[1]
Ted Schmitt[1] **Hunter Pitelka**[1] **Stephen Daspit**[1] **Rachel Ratner**[1] **Christopher Wilhelm**[1]
Sebastian Wood[1] **Mike Jacobi**[1]

Hannah Kerner[3] **Evan Shelhamer**[4]

Ali Farhadi[1,2] **Ranjay Krishna**[1,2] **Patrick Beukema**[♥1]

[1]Allen Institute for AI [2]University of Washington [3]Arizona State University [4]University of British Columbia

[★]OlmoEarth was a team effort.

[♥]Equal contribution from modeling team. Authors are listed in reverse alphabetical order by last letter of first name.

Platform: olmoearth.allenai.org

Training Code: olmoearth_pretrain (pretraining) olmoearth_projects (fine-tuning)

OlmoEarth Pre-trained Models: OlmoEarth-v1-Nano OlmoEarth-v1-Tiny OlmoEarth-v1-Base OlmoEarth-v1-Large

OlmoEarth Pre-training Dataset: olmoearth_pretrain_dataset

Contact: olmoearth@allenai.org

Abstract

地球观测数据面临独特挑战：它在空间上类似于图像，时间序列上类似于视频或文本，且高度多模态。我们提出 OlmoEarth：一种时空多模态基础模型，采用专为地球观测领域设计的新型自监督学习公式、掩码策略和损失函数。OlmoEarth 在多个研究基准和外部合作伙伴提供的实际任务中，相较于其他 12 种基础模型，均取得了领先性能。在评估嵌入时，OlmoEarth 在 24 项任务中的 15 项表现最佳；在全量微调后，其在 29 项任务中的 19 项表现最优。我们将 OlmoEarth 部署为端到端平台的核心，用于地球观测模型的数据采集、标签标注、训练与推理。OlmoEarth 平台 将前沿基础模型与强大的数据管理工具提供给致力于解决全球重大问题的非营利组织和非政府组织。OlmoEarth 的源代码、训练数据及预训练权重可在https://github.com/allenai/olmoearth_pretrain 获取。

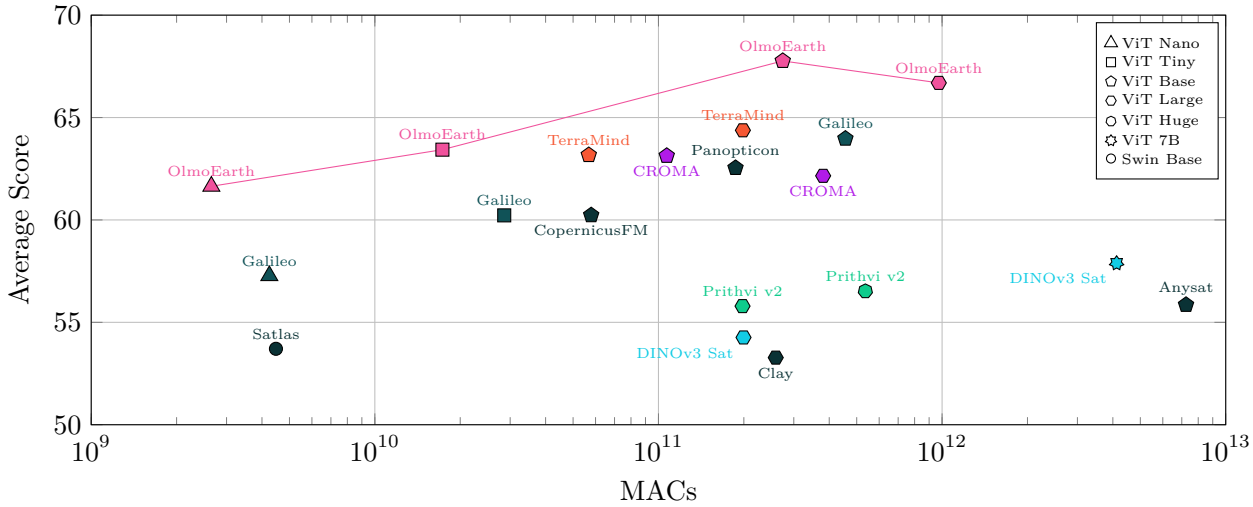

Figure 1 OlmoEarth 定义了在 13 个嵌入任务上性能与计算效率的帕累托最优（通过 kNN 和线性探测衡量）[1]。图表显示了在所有任务中编码一个样本所需的平均乘加操作数（输入大小随任务变化）。详见表 2 的完整结果。

1 引言

地球观测基础模型在研究环境中展现出令人鼓舞的结果 [? ? ? ? ? ? ?]。然而，在实际应用任务中的采用速度较慢，尤其是在非营利部门。基础模型规模庞大，训练复杂，部署成本高昂。

为了帮助非营利组织、人道主义机构和环境组织使用这些强大工具，我们采用一种新颖且稳定的训练方法，训练了 OlmoEarth 这一新型模型家族。我们在研究基准和合作组织提供的实际任务上，对 OlmoEarth 与另外 12 个基础模型进行了全面评估。最后，我们将这些模型部署在一个开放的端到端平台上，将前沿模型直接送达最需要它们的组织。

1.1 稳定训练

基础模型训练复杂且成本高昂。在尝试复现现有工作时，我们经常遇到训练不稳定、表示崩溃以及模型表现低于其宣称潜力的问题。我们提出了一种稳定的训练方法，该方法在潜在空间中对图像进行建模，同时避免了不稳定性和崩溃问题。

我们的方法在自监督学习中两种常见方法之间找到了一个平衡点。掩码自编码器（**MAE**）预测被掩码输入的像素级重构，而像 **I-JEPA** 和潜在掩码图像建模（**Latent MIM**）这样的方法则在特征空间中进行重构 [? ?]。MAE 通常表现稳定，但其特征表示能力有限；而潜在方法虽然不稳定，却能生成更优的特征 [?]。

我们提出了一种线性不变 token 嵌入的潜在掩码图像建模方法（**Latent MIM Lite**），这是对潜在 MIM 的简化，能够实现稳定的训练并取得更优性能。我们将潜在 MIM 中的目标编码器替换为从图像块到 token 空间的线性投影，该投影随机初始化且在训练过程中永不更新。这一简单修改稳定了训练过程，同时保持了潜在空间建模的表达能力。此外，通过将观测数据和标注地图均通过冻结的随机投影层映射至 token 空间，并以相同方式计算损失，该方法统一了自监督学习与监督学习。

[1] 所有任务的平均性能，具体包括：Sentinel-2 版本的 m-bigearthnet、m-so2sat、m-brick-kiln、m-eurosat、BreizhCrops、CropHarvest-Togo、CropHarvest-PRC、m-cashewplant、m-SA-crop-type、PASTIS、MADOS、AWF、Nandi。

1.1.1 掩码

在图像或文本建模中，只需随机掩码输入的某些部分，并让模型从上下文中重构输入即可。对于多模态遥感数据，输入中的任意 token 在空间、时间或不同对齐模态中都可能有许多相似的 token。除非使用非常高的掩码比例 [?]，否则随机掩码的任务过于简单。我们提出了一种模态感知的掩码策略，该策略结合了随机 token 掩码与完整模态重构。这使得任务具有挑战性，而无需依赖倾斜的掩码比例。

1.1.2 损失

与其他在潜在空间中的自监督学习方法类似，我们使用对比损失而非重构损失。然而，将一个重构的 token 与批量中所有其他 token，甚至同一样本中的其他 token 进行对比，由于地球观测数据的冗余性，会导致大量简单负样本。因此，我们仅将每个 token 与其对应波段集（模态的一个子集，详见 2.1）中的其他 token 进行对比。这使模型训练聚焦于更具挑战性但更高效的目標，如我们的实验所示。

1.2 综合评估

遥感模型尚无标准的评估套件。尽管存在一些既定的标准实践 [? ? ?]，但这些实践并非总是被遵循。为了更全面地了解基础模型的发展现状，我们对 OlmoEarth 与另外 12 个基础模型在 18 个研究基准和来自 7 合作组织的 19 个数据集上进行了全面的评估，这些组织在其工作中使用了地球观测建模。

按照标准做法，我们使用简单的迁移学习技术（kNN 和线性探测）以及完整的端到端微调来评估所有模型。我们采用标准的训练流程，并对多种超参数进行搜索以评估所有模型。OlmoEarth 在 kNN/LP 评估中的 24 个任务里取得了最佳性能的 15 个，在完整微调的 29 个任务中取得了最佳性能的 19 个。详见图 1。

1.3 开放平台

训练和微调对大多数环境与人道主义非营利组织而言仍遥不可及。将一个基础模型应用于某项任务，需要数据收集、对齐、预处理、标注、微调以及推理运行。我们通过将 OlmoEarth 部署在 OlmoEarth 平台中，简化并优化了这一流程。

OlmoEarth 平台 是为希望将地球观测数据用于公共利益的组织提供的端到端解决方案。我们的合作伙伴已经利用该平台开展红树林保护、生态系统制图和粮食安全等工作。OlmoEarth 平台 解决了将前沿研究成果落地应用的“最后一公里”难题，让真正能产生最大效益的人们能够使用这些成果。

2 OlmoEarth

OlmoEarth 是一种基于视觉变换器（Vision Transformer, ViT）的编码器-解码器架构。它处理对齐的卫星图像与衍生地图的多模态图像时序数据。一种类似 FlexiViT 的投影层 [?] 将输入数据从像素转换为 token，且可变的块大小。位置、时间和模态编码为 token 添加了额外的上下文信息。在训练过程中，部分输入 token 会被掩码。编码器的 Transformer 层在空间、时间以及不同模态之间进行注意力计算，生成输入 token 的表示。解码器则预测被掩码的输入 token 的表示。

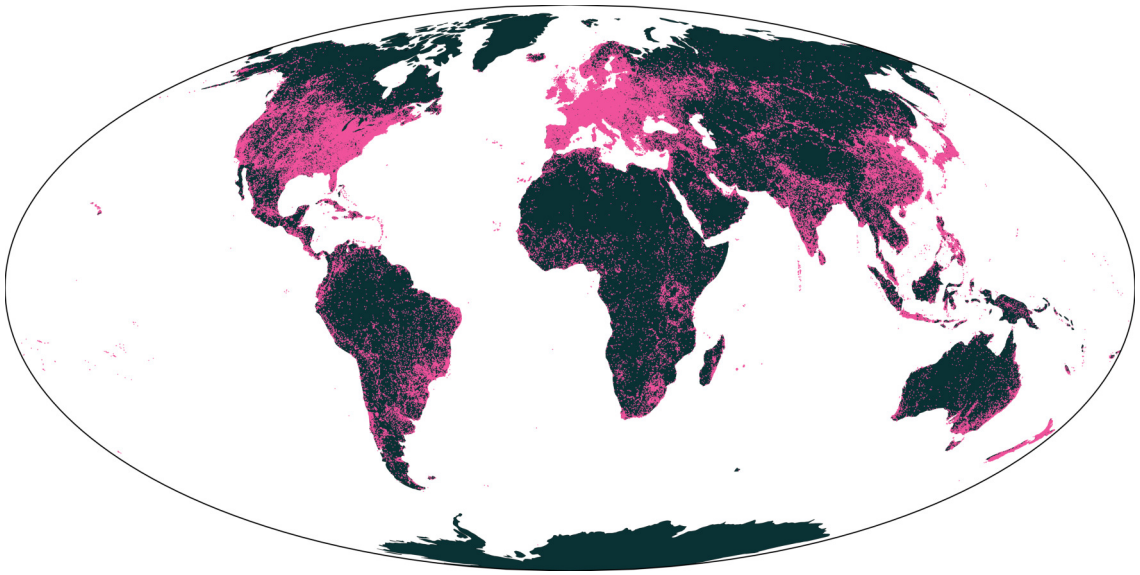

Figure 2 OlmoEarth 预训练数据的全球分布。我们基于 OpenStreetMap 分类，采样了 285,288 个位置。

2.1 数据

OlmoEarth 旨在灵活处理不同空间和时间分辨率的地球观测数据。在我们的预训练实验中，我们对三种卫星模态和六种衍生地图进行了训练：

Observations	Maps	
Sentinel-1	WorldCereal [?]	OpenStreetMap [?]
Sentinel-2	WorldCover [?]	Cropland Data Layer [?]
Landsat-8	SRTM [?]	Canopy Height Map [?]

我们的预训练数据集包含来自全球的 285,288 个样本。每个样本覆盖一个 2.56km × 2.56km 空间区域和一年的时间范围。对于多时相模态，我们最多使用一年中每月采样的 12 个时间步，尽管许多样本仅包含部分时间步和模态。

对于上述模态，我们将数据重采样为每像素均匀的 10 米。我们尝试在 2.5 米每像素的 NAIP 数据 [?] 和 160 米每像素的 ERA5 数据 [?] 中加入，但在评估中未发现显著改进。

我们进一步根据波段的原始分辨率将 Landsat 和 Sentinel-2 划分为**波段集**，将相同分辨率下获取的波段归为一组。Landsat 包含 2 个波段集，而 Sentinel-2 包含 3 个波段集。详细的划分请参见 OlmoEarth 源代码。

样本的位置根据 OpenStreetMap 中的特征进行选择。我们在 OpenStreetMap 中选取了 120 类地图特征，值域从道路到地热发电厂不等，并枚举包含每一类特征的所有 2.56km × 2.56km 瓦片。随后，我们每类最多随机采样 10,000 个瓦片，以获得 285,288 个样本（许多类别包含的瓦片少于 10,000 个）。每个样本的一年时间范围在 2016 年 1 月到 2024 年 12 月之间均匀采样。

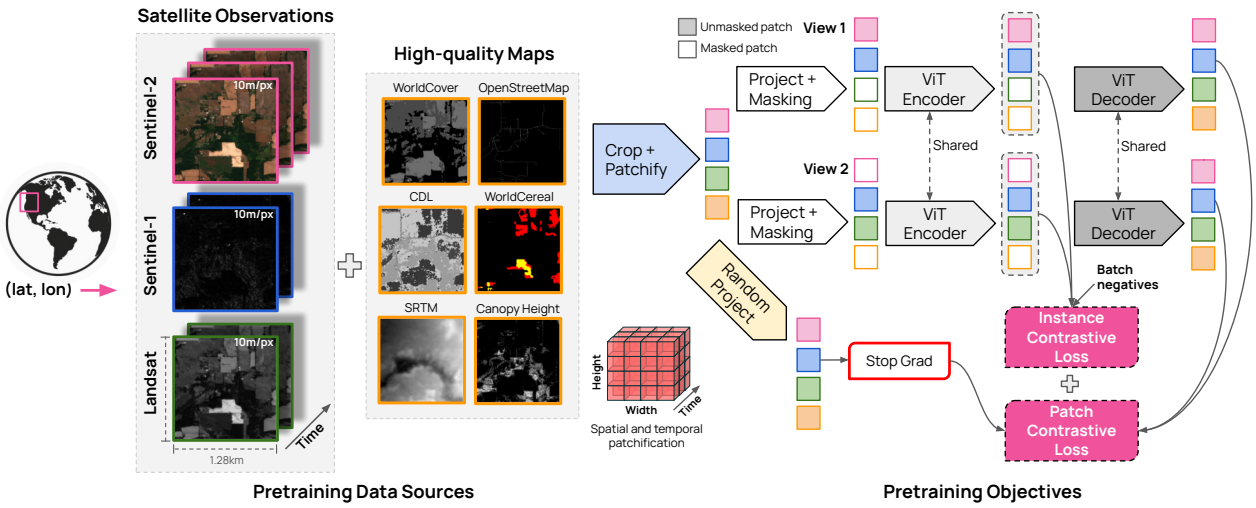

Figure 3 我们使用卫星观测数据和高质量地图的组合来训练 OlmoEarth。在对这些输入进行分词后，我们执行以下步骤：(1) 应用一种模态感知的掩码策略，以确定哪些 token 作为输入，哪些作为目标；(2) 将目标 token 通过固定的随机投影来构建目标；(3) 将输入 token 通过我们学成的编码器；然后 (4) 通过解码器预测目标 token；(5) 在预测 token 与目标 token 之间应用一种模态感知的补丁判别损失。步骤 1-5 在相同数据上重复两次，随后 (6) 对每个实例的聚合 token 应用实例对比损失。

2.2 架构

与许多地球观测模型类似，OlmoEarth 是一种基于 Transformer 的编码器-解码器架构。受 Galileo 启发，我们使用了一个灵活的块嵌入层 [? ?]。然而，与 FlexiViT 中令人困惑的伪逆操作不同，我们保持实际投影权重的大小不变，并通过调整输入图像的大小来模拟改变块大小的效果。这大概基本上是等价的。

输入进入 token 空间后，OlmoEarth 为每个 token 添加了二维的 sincos 位置嵌入、正弦时间嵌入以及可学习的模态嵌入。在训练过程中，部分 token 会被掩码掉，否则所有 token 都会传递给编码器 Transformer，该编码器在空间、时间以及不同模态之间执行完整的自注意力操作。

Architecture	Depth	Dim	Heads	Parameters
ViT Nano	4	128	8	1.4M
ViT Tiny	12	192	3	6.2M
ViT Base	12	768	12	90M
ViT Large	24	1024	16	300M

Table 1 ViT 编码器架构及四种 OlmoEarth 模型大小的参数数量。

我们基于标准的视觉 Transformer 尺寸训练了四种不同大小的编码器，详见表1。对于每种模型大小，解码器具有相同的特征维度和注意力头数，但深度仅为 4。我们设计了一个更小的解码器，以便编码器承担大部分建模任务。

训练期间，解码器使用一个学成的 < MASK > token 来表示输入中被掩码的部分，并将其添加到相应的位置、时间及模态嵌入中。解码器随后与编码器中的可见 token 进行交叉注意力计算，并预测被掩码 token 的潜在表示。

2.3 掩码

OlmoEarth 采用模态感知的掩码策略。对于每个样本，该掩码策略会选择一些波段集进行编码，同时也会选择一些波段集进行解码，且二者不互斥。因此，每个波段集都属于以下四类之一：

- **未选择**：此示例中忽略。
- **仅编码**：随机掩码，输入到编码器。
- **仅解码**：用作解码器的目标。
- **编码与解码**：随机掩码，输入编码器，掩码的 token 用作解码器的目标。

这种掩码策略将问题稍作重新表述，从重建部分被掩码的数据转变为从其他波段集的部分视图中重建缺失的波段集。当所有波段集都被编码和解码时，任务变得过于简单。波段集中的掩码 token 很可能在相同波段集中存在与其他 token 高度相关的可见 token，这些 token 在空间或时间上彼此邻近。在这种更简单的范式下进行训练，需要使用非常高的掩码比例（即掩码掉输入的 90%）才能获得良好结果。完全掩码部分波段集会使问题变得更难，从而允许使用更均衡的掩码比例。

OlmoEarth 在观测数据和地图数据上进行训练，但在推理时我们仅使用观测数据。地图数据可能会随时间变化——事实上，下游任务常常是检测这类变化——因此我们在推理时仅依赖观测数据。因此，在训练过程中，我们的掩码策略从不编码地图数据，只负责解码它。尽管观测数据可能属于上述四类中的任意一类，但地图数据只能是“仅解码”或“未被选择”。

2.4 潜在 MIM 轻量版

在训练过程中，OlmoEarth 会预测潜在空间中被掩码输入的重构结果。我们为每种模态使用一个随机初始化且冻结的投影层，将输入中的掩码块投影到 token 空间。因此，OlmoEarth 执行线性不变 token 嵌入的潜在掩码图像建模（潜在 MIM Lite）。

从理论和实践角度来看，对原始输入数据进行随机投影能够提取出有价值的特征 [**？？？**]。因此，我们的预测是在输入数据的真实潜在空间中进行的。然而，由于我们使用固定的目标编码器，避免了潜在对比学习（Latent MIM）训练中常见的表示坍缩问题。尽管在自然图像处理等更多样化领域中，这种方法可能过于简单，但实证结果表明，在地球观测数据这一领域中，该方法具有明显优势。

潜在 MIM Lite 使我们能够在同一架构下统一监督训练和自监督训练。我们将每种模态（无论是观测数据还是地图）通过一个冻结的随机投影映射到 token 空间。两种模态的损失计算方式相同。我们无需为监督数据添加特定的预测器头，也不需要调整训练策略或损失函数。在消融实验中，我们发现该方法在纯自监督情景下表现优异，并且还能从额外的监督数据中获益。

其他模型如 Galileo 和 Terramind 在监督和无监督数据上进行训练，然而它们将监督地图视为模型的有效输入 [**？？**]。这意味着其编码器必须学习将这些地图模态作为输入进行建模，而在训练过程中可能利用地图模态来预测观测结果或其他地图模态。尽管这也统一了监督和半监督训练，但我们认为我们的方法简化了编码器的学习过程，同时保持了使用监督数据训练的优势。在我们的评估中，大多数任务上性能均优于这些模型。

2.4.1 模态补丁区分

在像素空间中的掩码图像建模通常使用 Smooth L1 等重构损失。潜在空间掩码图像建模（Latent MIM）则提出用对比损失（补丁判别）替代重构损失，以激励潜在空间预测的多样性。补丁判别损失将 token 重构问题转化为分类任务，要求某个补丁的预测 token 与目标 token 相似，但与其他补丁的真实值 token 不相似。补丁判别使用余弦相似度来衡量 token 之间的相似度，并采用交叉熵损失来区分正负样本匹配。

典型的补丁判别任务将一个预测的 token 与输入中的所有目标 token 进行对比。在图像建模中，图像的目标 token 是图像不同部分的编码，因此它们来自同一分布，使得对比任务具有挑战性。在 OlmoEarth 中，不同的目标 token 可能来自不同的模态、不同的时间步或不同的空间位置。

不同模态的 token 具有非常不同的分布，因此区分它们很容易。然而，来自其他模态的 token 数量众多，导致相当一部分损失来自于这些“简单”的负样本。我们发现，消除这些简单负样本，仅对同一模态的目标进行对比，能带来显著的性能提升。

2.4.2 实例对比损失

补丁判别损失作用于编码器和解码器生成的局部式表征，但许多任务（如分类）需要对输入区域具有全局理解。一些基础模型使用单个 <CLASS> token 来表示这种全局信息。相反，我们选择对所有模态、时间步和位置上的信息进行全局池化，以获取输入的全局表示。为了生成输入的全局表示，我们运行 OlmoEarth 编码器并对输出 token 进行平均池化。

来自同一模态的 token 具有相似语义，而不同模态的 token 可能看起来非常不同。我们希望能够将所有模态的 token 进行平均，从而获得输入的合理全局表示。因此，我们在编码器的池化表示上使用对比损失，以促使 token 存在于一个共同的表示空间中，并在池化时表现良好。

我们希望对比损失同时包含正例和负例，因此采用类似于 SimCLR [?] 的方法，对同一输入编码两个版本，将这两个版本视为正例，而将批次中的其余样本视为负例。然而，与使用不同数据增强来生成两个样本的方法不同，我们采用不同的随机掩码。

我们进行两次随机掩码，然后使用我们的编码器对两个批量进行编码，对生成的 token 进行池化，并对池化后的表示应用对比损失。我们运行解码器两次，分别解码两张图像的掩码区域，并计算模态 patch 辨别损失。一个标量控制实例对比损失对模态 patch 辨别损失的贡献。在本文的实验中，我们将实例对比损失放大 0.1 倍。

3 实验

我们在标准研究基准以及来自合作机构的真实世界下游任务上对 OlmoEarth 进行了广泛评估。遵循遥感基础模型的常规做法，我们同时评估了冻结编码器下的 kNN/线性探针性能和完整微调性能 [? ? ?]。

为了获得尽可能全面的评估，我们将其他表现优异的基础模型引入我们的评估框架，并对它们进行评估，以便实现直接比较 [? ? ? ? ? ? ? ? ? ? ? ? ?]。我们为每个基础模型使用相同的训练配方，但对多种超参数进行搜索，以在每个任务上找到每个模型的最佳性能。对于不支持特定模态的模型，我们留空评估结果。由于计算资源和时间限制，我们也没有对部分大型模型在合作伙伴任务上进行微调。

		m-bigearthnet	m-so2sat	m-brick-kiln	m-forestnet	m-eurosat	BreizhCrops	CropHarvest-PRC	CropHarvest-PRC	CropHarvest-PRC	CropHarvest-Togo	CropHarvest-Togo	CropHarvest-Togo	m-cashewplant	m-SA-crop-type	PASTIS	PASTIS	MADOS	Sen1Floods11	AWF	AWF	AWF	Nandi	Nandi	Nandi
	Modalities	S2	S2	S2	L8	S2	S2	S1	S2	S1,S2	S1	S2	S1,S2	S2	S2	S1	S2	S2	S1	L8	S1	S2	L8	S1	S2
	Time series	✘	✘	✘	✘	✘	✔	✔	✔	✔	✔	✔	✔	✘	✘	✔	✔	✘	✘	✔	✔	✔	✔	✔	✔
	Method	kNN	kNN	kNN	kNN	kNN	LP	LP	LP	LP	LP	LP	LP	LP	LP	LP	LP	LP	LP	kNN	kNN	kNN	kNN	kNN	kNN
Model	Metric	μF1	Acc.	Acc.	Acc.	Acc.	Acc.	Acc.	Acc.	Acc.	Acc.	Acc.	Acc.	mIOU	mIOU	mIOU	mIOU	mIOU	mIOU	Acc.	Acc.	Acc.	Acc.	Acc.	Acc.
Anysat	ViT Base	54.5	36.5	84.5	34.0	80.4	62.7	57.0	74.1	72.3	69.6	78.4	74.5	24.6	27.2	24.2	41.9	41.3	77.8	60.0	60.0	64.0	47.4	20.5	55.8
Clay	ViT Large	48.8	38.7	90.8	40.3	86.3	57.0	56.7	66.5	63.4	78.4	67.0	67.3	30.8	23.1	19.9	22.6	47.5	78.9	59.5	61.5	56.5	52.2	23.4	57.0
CopernicusFM	ViT Base	64.6	50.3	85.9	-	84.7	65.5	55.1	72.8	74.4	77.5	75.8	70.6	32.2	28.4	15.9	32.1	63.9	77.6	-	59.0	67.0	-	24.4	59.8
CROMA	ViT Base	61.3	51.3	92.0	-	84.6	69.0	56.8	74.3	75.1	76.8	80.7	76.5	24.9	30.3	26.3	44.7	60.4	78.8	-	67.5	**79.0**	-	24.6	68.2
CROMA	ViT Large	59.2	48.2	91.7	-	85.8	68.2	56.2	72.7	71.0	79.4	76.5	81.0	27.0	30.4	25.9	42.7	66.4	78.8	-	62.5	71.0	-	26.1	68.2
DINOv3	ViT Base	51.0	47.1	91.3	43.3	86.6	31.3	-	64.5	-	-	67.0	-	23.5	26.7	-	18.1	53.5	-	48.5	-	61.0	42.5	-	54.1
DINOv3	ViT Large	55.8	45.3	89.9	46.0	84.0	31.3	-	66.1	-	-	68.3	-	24.5	26.1	-	17.4	52.4	-	43.5	-	60.5	39.9	-	49.8
DINOv3	ViT Huge+	57.0	45.7	88.2	46.9	86.1	31.3	-	68.7	-	-	68.3	-	25.1	26.7	-	17.4	48.1	-	47.5	-	54.0	43.5	-	55.4
DINOv3	ViT 7B	60.8	46.6	91.3	48.0	85.2	31.3	-	68.7	-	-	70.9	-	34.3	27.9	-	21.1	52.2	-	47.5	-	57.0	44.7	-	56.7
DINOv3 Sat	ViT Large	60.2	44.0	91.4	44.2	89.2	31.3	-	70.1	-	-	68.6	-	32.4	28.5	-	22.5	57.5	-	42.5	-	69.5	35.5	-	48.4
DINOv3 Sat	ViT 7B	61.6	50.1	91.4	47.0	91.3	31.3	-	72.2	-	-	71.9	-	**54.1**	**31.7**	-	26.3	59.7	-	49.5	-	68.5	31.8	-	42.5
Galileo	ViT Nano	55.0	53.7	90.9	-	89.4	66.3	60.9	74.4	72.4	75.2	70.3	78.1	21.2	19.5	19.2	19.1	53.1	78.6	-	65.5	67.5	-	24.4	64.2
Galileo	ViT Tiny	55.8	53.1	87.5	-	89.1	66.7	55.7	80.3	79.3	69.9	78.8	77.1	23.6	21.5	23.4	27.7	61.1	78.6	-	65.5	71.0	-	25.0	66.7
Galileo	ViT Base	58.3	55.7	91.1	-	92.8	69.7	**60.9**	**81.9**	79.3	67.3	80.1	77.5	28.9	25.3	28.0	39.6	**68.4**	79.4	-	66.5	72.5	-	**26.8**	67.3
Panopticon	ViT Base	**64.9**	60.5	92.9	**52.3**	95.2	57.7	55.9	75.9	75.6	72.2	72.9	76.5	32.7	27.3	23.7	30.2	66.1	78.0	66.0	65.0	71.5	60.4	22.9	65.2
Presto	ViT Nano	-	-	-	-	-	60.9	59.3	74.3	76.6	78.4	81.4	72.5	-	-	16.3	28.2	-	-	-	60.5	53.5	-	25.2	57.6
Prithvi v2	ViT Large	51.6	34.7	89.7	37.9	82.2	66.2	-	67.6	-	-	71.9	-	46.8	24.7	-	37.2	50.9	-	57.0	-	49.0	57.7	-	52.8
Prithvi v2	ViT Huge	51.0	34.0	90.1	41.4	81.2	66.1	-	69.5	-	-	69.9	-	45.8	26.6	-	37.5	52.2	-	59.0	-	55.0	57.9	-	55.9
Satlas	Swin Base	52.3	44.5	83.0	36.9	82.2	64.6	57.4	71.3	-	76.8	75.8	-	30.6	24.0	10.5	14.4	30.2	72.9	57.5	52.0	62.0	61.5	25.1	60.2
TerraMind	ViT Base	63.9	46.7	91.9	-	85.6	66.4	57.0	75.1	75.6	74.2	74.8	77.5	46.0	30.4	22.7	40.9	66.0	78.7	-	66.0	69.5	-	24.7	-
TerraMind	ViT Large	63.9	47.4	92.2	-	90.0	68.2	56.2	74.7	72.0	75.2	77.8	75.2	50.4	31.2	22.3	41.3	67.5	78.4	-	62.0	67.0	-	23.3	65.3
TESSERA		-	-	-	-	-	-	-	-	72.2	-	-	81.0	-	-	-	-	-	-	-	-	-	-	-	-
OlmoEarth	ViT Nano	59.5	54.3	**96.2**	38.8	89.9	64.1	58.0	79.5	74.3	73.5	81.7	**83.7**	25.5	23.6	18.1	35.0	55.2	78.2	73.0	61.5	69.5	57.7	24.8	67.4
OlmoEarth	ViT Tiny	59.4	61.8	92.0	40.5	91.6	64.0	58.3	78.6	**80.3**	75.8	85.6	82.4	24.7	23.2	21.4	40.1	58.6	78.5	75.5	64.0	76.0	60.7	24.7	69.0
OlmoEarth	ViT Base	62.4	67.7	93.3	41.9	94.7	**70.9**	56.8	73.4	75.4	**80.1**	**87.3**	82.0	32.3	28.9	29.7	50.6	67.2	79.2	**77.0**	**68.5**	77.5	**67.9**	26.5	**74.7**
OlmoEarth	VIT Large	62.0	**68.2**	93.4	41.6	**96.3**	70.7	56.6	74.1	76.1	67.6	78.1	79.7	30.9	28.5	**30.6**	**51.8**	66.4	**79.8**	76.0	66.5	73.0	66.4	26.2	73.6

Table 2 我们在研究基准和合作伙伴提供的实际任务上进行了 kNN/线性探针测试。对于单时间步分类任务，我们采用 kNN 方法；对于其他所有任务，则使用线性探针。我们对数据规范化策略、特征池化方式以及线性探针的学习率进行了全面搜索，并报告在验证集表现最佳时的测试集结果。由于输入模态不兼容，并非所有模型都能在所有任务上运行。OlmoEarth 始终表现出色，在 24 项任务中有 15 项表现最佳。

		m-bigearthnet	m-so2sat	m-brick-kiln	m-forestnet	m-eurosat	m-cashewplant	m-SA-crop-type	PASTIS	MADOS	Sen1Floods11	AWF	AWF	GEA North Africa	Forest Loss Driver	Live Fuel Moisture Content	Live Fuel Moisture Content	Mangrove	Mangrove	Marine Infrastructure	Marine Infrastructure	Nandi	Nandi	Vessel Detection	Vessel Detection	Vessel Detection	Vessel Length	Vessel Type	Solar Farm Detection	Solar Farm Detection
	Modalities	S2	S2	S2	L8	S2	S2	S2	S2	S2	S1	S2	S2, S1	S2	S2	S2	S2, S1	S2	S2, S1	S2	S2, S1	S2	S2, S1	L8	S1	S2	S2	S2	S2	S1, S2
	Time series	✘	✘	✘	✘	✘	✘	✘	✔	✘	✘	✔	✔	✔	✔	✔	✔	✔	✔	✔	✔	✔	✔	✘	✘	✘	✘	✘	✔	✔
Model	Metric	μF1	Acc.	Acc.	Acc.	Acc.	mIOU	mIOU	mIOU	mIOU	mIOU	Acc.	Acc.	Acc.	Acc.	L1	L1	Acc.	Acc.	F1	F1	Acc.	Acc.	F1	F1	F1	L1	Acc.	mIoU	mIoU
Anysat	ViT Base	68.4	56.7	98.7	51.6	95.9	80.4	34.2	60.9	63.3	77.4	78.0	83.0	59.3	84.6	19.1	19.4	96.9	97.1	52.7	5.2	78.4	76.7	-	-	-	73.4	43.5	82.6	79.7
Clay	ViT Large	65.7	61.3	98.7	49.2	95.8	73.9	33.4	48.9	68.9	78.5	77.0	-	53.4	93.3	24.8	-	96.6	-	86.0	-	30.9	-	70.7	**79.9**	72.4	16.4	68.3	82.2	-
CopernicusFM	ViT Base	71.3	66.8	98.1	-	98.5	78.7	33.6	54.6	66.0	78.6	79.0	79.0	58.8	90.0	25.2	24.5	97.1	97.1	82.8	88.9	68.2	55.9	-	77.4	76.9	16.7	69.6	77.6	76.8
CROMA	ViT Base	69.5	59.1	98.7	-	95.6	46.4	34.8	56.3	66.6	79.4	76.5	75.5	57.5	93.2	24.3	24.0	96.4	96.3	86.1	84.3	62.2	67.4	-	-	70.0	19.8	64.4	79.5	79.5
CROMA	ViT Large	71.8	58.9	97.8	-	97.5	47.8	36.0	58.1	68.8	79.4	79.5	-	56.6	92.3	24.6	24.1	96.6	96.2	-	-	76.4	-	-	-	-	-	-	81.7	-
DINOv3 Sat	ViT Large	69.9	63.3	98.9	**59.2**	96.7	80.6	34.5	42.8	64.7	-	34.5	-	43.0	80.4	90.2	-	65.8	-	82.9	-	35.8	-	-	-	58.0	30.3	54.8	70.7	-
Galileo	ViT Base	69.2	64.7	98.3	-	97.8	78.8	35.7	61.2	71.9	79.7	81.0	81.5	**62.9**	95.1	20.1	18.7	97.3	97.5	85.5	88.0	**81.9**	81.9	-	78.7	75.4	16.4	73.0	83.1	85.1
Panopticon	ViT Base	69.3	65.4	**99.0**	56.0	98.2	79.7	33.4	54.4	72.8	79.1	75.5	78.5	54.3	96.4	24.5	23.7	97.1	97.4	86.4	88.6	65.2	69.5	74.9	76.7	76.8	17.7	69.4	81.8	79.3
Prithvi v2	ViT Huge	70.6	64.7	98.2	-	96.8	81.1	38.8	58.6	69.3	-	80.0	-	60.6	92.4	-	-	97.2	-	84.8	-	77.1	-	71.1	-	74.8	17.4	68.2	84.1	-
Satlas	Swin Base	72.7	65.1	98.7	56.0	97.0	77.0	37.8	57.4	60.5	78.5	78.0	-	56.1	63.3	25.0	24.6	96.6	-	**87.5**	-	47.6	-	-	-	77.6	16.2	71.6	83.3	-
TerraMind	ViT Base	72.6	66.1	98.5	-	97.6	80.9	39.2	59.9	73.2	79.5	84.0	82.0	49.8	96.4	24.3	23.8	**97.7**	96.8	84.0	87.8	66.1	79.3	-	79.6	74.7	18.1	-	83.5	82.1
TerraMind	ViT Large	**74.0**	65.4	98.1	-	97.8	**81.3**	**41.1**	60.9	71.5	79.5	81.5	-	51.1	93.9	24.5	24.5	96.5	96.9	-	-	66.1	-	-	-	-	-	-	83.0	-
OlmoEarth (Random Init)	ViT Base	61.0	48.9	94.7	41.7	80.3	43.0	27.5	43.9	45.6	77.0	62.5	-	52.9	52.7	20.9	20.5	96.3	96.4	-	-	60.6	56.1	-	-	-	-	-	74.1	70.3
OlmoEarth	ViT Nano	66.8	61.5	98.0	50.3	95.3	39.5	35.4	53.0	60.6	78.8	82.5	82.5	61.1	96.0	20.4	19.7	97.4	97.4	86.8	87.8	75.6	74.8	70.2	75.5	75.0	17.1	72.0	82.1	79.6
OlmoEarth	ViT Tiny	69.6	63.5	98.7	53.2	97.1	72.5	38.5	60.3	71.5	79.7	85.0	85.5	60.6	97.7	19.8	19.2	97.6	97.7	85.6	89.3	78.2	76.4	74.4	76.9	77.6	15.8	73.5	85.2	85.2
OlmoEarth	ViT Base	72.0	**68.6**	98.6	51.2	**98.7**	79.8	39.6	64.3	77.8	79.8	**87.0**	**86.0**	62.4	97.1	**18.5**	**17.9**	97.6	**97.9**	86.3	**89.6**	81.8	**82.2**	**75.4**	79.2	**78.8**	**15.4**	**74.6**	**85.4**	**86.7**
OlmoEarth	ViT Large	72.4	68.1	98.6	52.7	98.5	80.6	40.8	**66.3**	**81.8**	**79.8**	84.5	-	58.8	**97.9**	19.9	18.5	97.6	97.6	-	-	81.0	-	-	-	-	-	-	84.2	-

Table 3 在研究基准（左）和合作伙伴任务（右）上的微调结果。我们使用相同的训练方法训练所有模型，并报告验证集性能最佳的模型检查点在测试集上的结果。部分模型仅适用于任务子集。由于资源限制，我们并未在所有任务上对大型模型进行微调。OlmoEarth 在 29 项任务中的 19 项上表现最佳。

3.1 预训练

我们在 2.1 描述的预训练数据集上对 OlmoEarth 进行预训练，采用潜在 MIM Lite。我们使用 AdamW 最优化方法，基础学习率为 1×10^{-4}，权重衰减为 0.02，批量大小为 512，线性学习率预热 8000 步，学习率余弦退火 0.1，总共 $667,200$ 步。由于内存限制，我们使用微批量大小为 32，因此池化对比损失仅在这 32 个样本上应用，而非完整的 512 批量。

在训练过程中，OlmoEarth 使用一个在范围 $\{1 \ldots 8\}$ 内的随机有效补丁大小，并从输入中随机裁剪出边长为 $\{1 \ldots 12\}$ 个 token 的正方形区域。因此，在空间维度上，最小的输入是一个 1×1 像素区域，其补丁大小为 1 ，最大的输入是 96×96 像素区域，其补丁大小为 8 。在时间维度上，我们的模型处理 3 到 12 个时间步。在训练过程中，我们的模型总共处理约 1000 亿个 token。

3.2 研究基准与合作任务

我们在多种常见的分类与分割基准上进行评估，涵盖单模态和多模态传感器。我们的评估包含 GEO-Bench [?] 中的全部七个哨兵-2 和陆地卫星基准：m-bigearthnet、m-so2sat、m-brick-kiln、m-forestnet、m-eurosat、m-cashewplant 以及 m-SA-crop-type。我们还对分类基准 BreizhCrops [?] 和 CropHarvest [?] 以及分割基准 PASTIS [?]、MADOS [?] 和 Sen1Floods11 [?] 进行评估。

在开发 OlmoEarth 期间，我们与多家已使用或希望使用遥感数据进行环境、气候或研究任务的组织合作。这些组织为我们提供了涵盖多个领域的标注数据，用于评估模型性能，从而深入了解模型在真实任务中的表现。例如，我们与非洲野生动物基金会（AWF）合作，对肯尼亚南部的土地利用和土地覆盖情况进行制图。我们结合不同的哨兵-1、哨兵-2 和陆地卫星观测数据组合来完成这些任务。

3.3 kNN 与线性探测

在不进行微调的评估中，我们从训练集、验证集和测试集中提取嵌入，并应用 K 近邻模型进行单时间步分类，或使用线性探针模型进行分割和多时序分类。对于 OlmoEarth，我们使用 4 的块大小，但在 m-Cashew Plant 上对适用的模型进行块大小的扫描（详见附录讨论）。对于外部模型，我们采用推荐的块大小设置，并按照 [?] 的方法将输入数据调整为该模型预训练时的大小。对于不支持时间序列数据的模型，我们分别输入每个时间步。我们对结果嵌入在时间上的池化方法进行扫描（均值与最大值）。同时，我们也对规范化统计量进行扫描（在预训练期间计算与在评估集上计算）。

我们使用余弦相似度在 kNN 上运行 $k = 20$，并遵循标准的评估实践 [? ?]。对于输出 <CLASS> 嵌入 token 的模型，我们将其用作整个图像的嵌入；否则，我们对生成的 token 进行平均。

我们在输出嵌入上进行线性探测，训练 50 轮次。对于每个模型 $\{1 \times 10^{-4}, 5 \times 10^{-4}, 1 \times 10^{-3}, 5 \times 10^{-3}, 1 \times 10^{-2}, 5 \times 10^{-2}, 1 \times 10^{-1}, 5 \times 10^{-1}\}$，我们尝试多种学习率，并报告验证集性能最高的测试结果。

3.4 微调

在微调评估中，对于每个模型，我们采用其编码器并添加一个解码器，用于进行分类、回归、语义分割或目标检测预测。我们的微调方案在前 20% 的轮次中冻结编码器参数，仅训练新增的解码器层，随后解冻并微调整个模型以完成剩余轮次的训练。我们使用 AdamW 最优化方法，并采用平台调度器，在验证集上连续 2 轮无改进时将学习率降低 0.2 倍，且在降低后设置 10 轮的冷却期。

	m-so2sat	m-eurosat	PASTIS
Full Latent MIM*	32.2	68.4	7.9
Latent MIM Lite	42.2	87.2	35.2
+ Modality Masking	53.6	90.2	46.6
+ Modality Patch Disc	55.3	91.5	48.1
+ Contrastive Loss	56.8	92.3	49.0
+ Maps	**62.4**	**92.9**	**50.7**

Table 4 OlmoEarth 基础模型的发展路径，展示了从潜在 MIM 方法开始，逐步加入我们各项贡献的效果。* 完整的潜在 MIM 在训练过程中崩溃。

在研究基准上的微调中，解码器是一个单层线性探针；对于分类任务，它使用图像上池化后的嵌入进行预测；对于分割任务，它在每个空间块上使用时序池化（如适用）的嵌入进行预测。我们为每个模型在 $\{1 \times 10^{-4}, 5 \times 10^{-4}, 1 \times 10^{-3}\}$ 范围内搜索学习率。

在合作伙伴任务的微调中，解码器是：

- **分类**： 3 层 MLP。
- **分割**：转置卷积层，或用于多尺度编码器的 U-Net 解码器 [**?**]。
- **目标检测**： Faster R-CNN 头部，搭配用于多尺度编码器的 FPN [**? ?**]。

我们对所有任务使用 10^{-4} 的学习率，除了 Nandi 任务，该任务中某些模型表现出不稳定的学习行为，因此我们对 $\{10^{-4}, 10^{-5}\}$ 进行了超参数搜索。

3.5 结果

在 kNN/LP 评估中，OlmoEarth 在 18 个研究基准中的 11 个和 6 个合作伙伴任务中的 4 个表现最佳。在微调评估中，OlmoEarth 在 10 个研究任务中的 5 个和 19 个合作伙伴任务中的 14 个表现最佳。除了少数情况外，OlmoEarth 始终表现出较高的性能。

OlmoEarth 大型模型并不总是优于 OlmoEarth 基础模型，对于基于嵌入的像素时间序列任务，其表现甚至显著更差。这可能反映出我们在训练基础模型方面投入的探索比大型模型更多。在许多任务中，Terramind 和 CROMA 基础模型的表现往往优于大型模型，这可能反映了缩放地球观测模型所面临的挑战。

其他值得关注的模型包括在嵌入任务中表现强劲的 Panopticon，以及在微调任务中表现出色的 Terramind。DINOv3 在主要依赖视觉信息的任务中表现良好，但在需要时间理解的关键任务上落后于专用模型。Galileo 在多个基准测试中表现强劲，尤其在农业相关任务中。

3.6 消融

我们基于潜在 MIM 自监督训练构建了 OlmoEarth，并对多种修改进行了迭代，保留了最优方案。表 4 展示了我们的开发过程，从标准的潜在 MIM 开始，逐步引入随机掩码、仅使用补丁判别损失以及不使用地图数据。表中模型均按照子节 3.1 中的训练配方进行训练，但仅训练 140,000 步。结果展示了在三个基准的验证集上 kNN 和 LP 的表现。在开发过程中，我们对部分评估进行了 “环内评估”，但发现代表性子集上的改进能够延续到完整评估中。

我们观察到，由于表示崩溃，潜在 MIM 模型表现不佳。切换到潜在 MIM Lite 后，性能显著提升。进

一步的修改表明，所有任务的性能均有所提高。我们在附录C中进行了额外的消融实验。

3.7 环境影响

最近关于语言模型环境影响分析的研究 [? ? ?] 表明，训练 OlmoEarth 的总能耗、碳排放和水消耗如表 5 所示。与其它环境影响估计类似，这应被视为一个下限，因为它未考虑硬件制造、运输等影响。

Model	Stage	Hardware	GPU Hrs	Energy (kWh)	Carbon (tCO_2eq)	Water (kL)
OlmoEarth Nano	Pretraining	H100	1,149	195	0.08	0.30
OlmoEarth Tiny	Pretraining	H100	1,149	205	0.08	0.32
OlmoEarth Base	Pretraining	H100	2,989	803	0.32	1.24
OlmoEarth Large	Pretraining	B200	5,240	1,933	0.77	2.99
OlmoEarth Nano	Fine-tuning	–	647	186	0.07	0.29
OlmoEarth Tiny	Fine-tuning	–	723	261	0.10	0.40
OlmoEarth Base	Fine-tuning	–	1,224	685	0.27	1.06
OlmoEarth Large	Fine-tuning	–	58	39	0.02	0.06
Total	Overall	–	13,179	4,307	1.72	6.67

Table 5 预训练和微调的环境影响近似值 OlmoEarth。微调 OlmoEarth Nano、Tiny 和 Base 的指标包括研究基准和合作伙伴任务。微调 OlmoEarth Large 的指标仅包括研究基准。

我们在单个数据中心内使用 NVIDIA H100 和 B200 GPU 对所有模型进行训练。通过每 ~ 25ms 跟踪实际的 GPU 功率利用率，计算训练过程中功耗的加权平均值，从而得出单次训练所需的总 GPU 功率。随后，根据数据中心提供商提供的电源使用效率（PUE）因子对这一数值进行乘算，再将最终的 GPU 功率使用量分别乘以电网的碳强度或数据中心的用水效率因子，分别计算出总的碳排放量和用水量。

训练期间的总能耗（4,307 千瓦时）足以为美国平均家庭供电 5 个月。总的碳排放量相当于从西雅图飞往葡萄牙的经济舱机票的碳排放量。

4 相关工作

预训练用于遥感模型最初集中在对比方法上 [? ? ?]。最近，掩码建模已取代成为主导范式，与语言和视觉领域类似 [? ?]。早期的遥感预训练方法直接重构被掩码的像素值 [? ? ?]。受自然图像研究的启发 [? ? ?]，遥感领域的研究更多地关注潜在空间中的重构。潜在空间方法表现良好 [? ? ?]，但已有文献记录其不稳定性 [? ?]。

TerraMind 通过在预训练期间使用冻结的 token 化器来避免稳定性问题。对于图像模态，它们训练一个量化自编码器，并在多模态掩码建模期间将编码器用作冻结的 token 化器。

预计算嵌入为可访问性提供了另一种方法 [? ?]，但仍需要专业知识来检索和使用。最佳结果可能仍需在嵌入之上训练解码器。预计算嵌入还限制了灵活性；AEF 和 TESSERA 均生成年度嵌入，使得实时或跨年度预测成为不可能。OlmoEarth 嵌入在合作伙伴任务上的表现与 AEF 嵌入相当或更优，而完整的微调可实现更佳结果（附录表 7）。

5 讨论

我们希望 OlmoEarth 能对世界产生积极影响。为此，我们将其作为 OlmoEarth 平台 的一部分发布，这是一个端到端的、开放的地球观测解决方案。OlmoEarth 平台 使合作组织能够在其环境、保护、粮食

安全等领域的工作中使用最新的优质基础模型。像全球红树林监测、全球生态系统图谱以及国际食物政策研究所这样的组织正在利用 OlmoEarth 平台 进行数据监管和标签标注、模型微调以及推理。

5.1 案例研究

全球红树林观测 地图和追踪沿海红树林森林的范围与健康状况。红树林森林能够固碳，保护海岸免受侵蚀，并为小鱼提供栖息地。全球红树林地图（GMW）使用随机森林模型，以 95.3% F1 得分生成年度地图，但仅覆盖了约一半的相关沿海区域。利用 OlmoEarth 平台，我们使用其数据对 OlmoEarth 模型进行微调，将 F1 得分提升至 98.1%。OlmoEarth 平台 可以以每月频率运行推理以生成新地图，或以滚动方式运行以更快地检测变化。

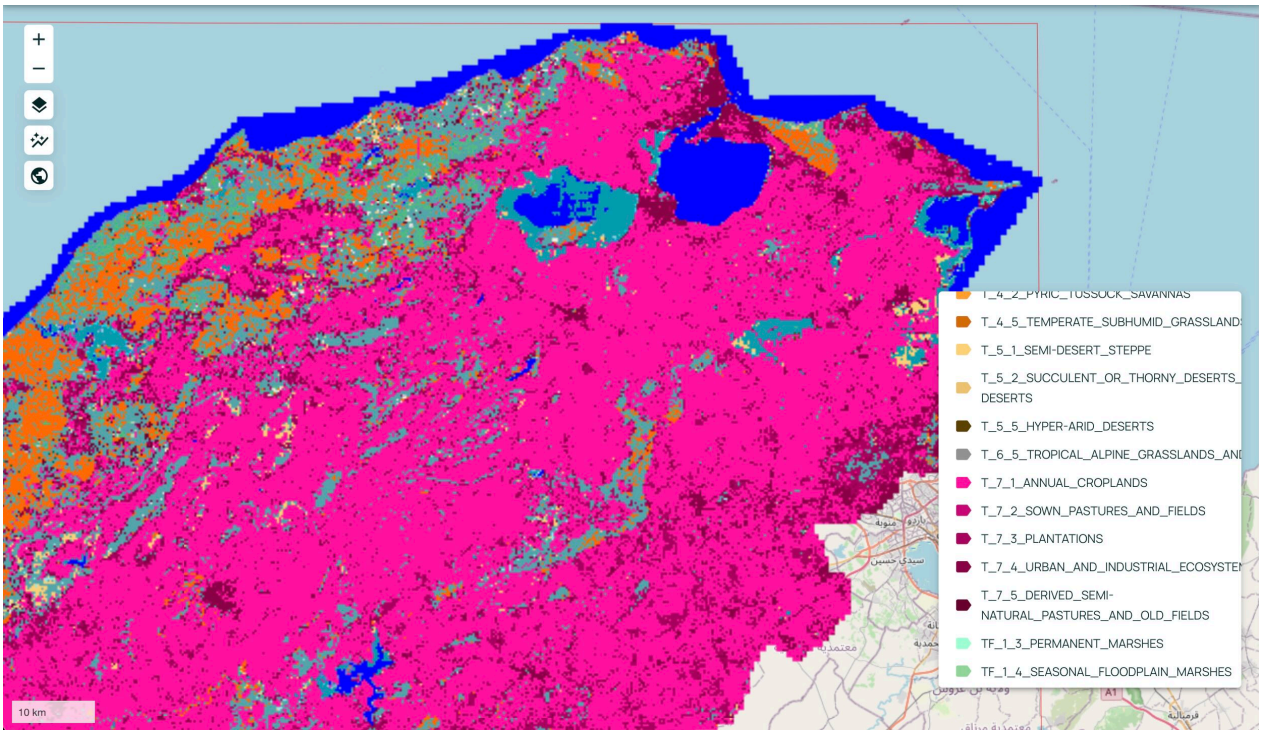

Figure 4 OlmoEarth 平台上微调后的生态系统分类模型结果。用户可在 OlmoEarth 平台中对数据进行标注、微调模型，并运行推理以生成地图。

全球生态系统图集 正在构建全球生态系统的综合地图 [?]。在过去三个月中，他们使用 OlmoEarth Platform 对超过 15,000 个数据点进行了标签标注。OlmoEarth Platform 允许他们对感兴趣区域进行划分，生成待标注点，将这些点分配给标注人员，审查结果，并直接在平台上导出数据或微调模型。利用北非地区的一小部分数据，他们微调了一个模型，该模型达到了业界领先水平的准确率，并运行推理以生成新的生态系统地图。人类可以审查结果，将更优质的标签反馈至训练流水线中。

5.2 下游风险

OlmoEarth 所具备的强大功能与多功能性也带来了风险。我们以开放许可的方式发布 OlmoEarth，旨在通过允许自由使用、修改和共享模型权重、数据集及相关代码来应对部分风险，同时限制其在军事、国防相关以及采掘行业应用中的使用。

5.3 未来

我们计划向 OlmoEarth 模型中加入气候和天气数据及预测，以辅助火灾预测和作物产量预测等任务。扩展到此类数据将需要处理更广泛的输入分辨率，包括空间分辨率（从米到千米）和时间分辨率（从天到年）。

我们还计划向模型中加入非地理空间数据。通常，像作物类型制图这类任务的数据标注需要亲自前往现场观察实际情况。我们希望模型也能具备这种能力。能够处理带有地理定位的自然图像将提升 OlmoEarth 在处理这些细粒度识别任务方面的能力。

最终，我们希望支持并壮大那些为这项工作带来非凡知识、专业技能和热情的合作伙伴组织。我们将计划向合作伙伴学习他们所需的工具和功能，然后改进 OlmoEarth 平台，以更好地帮助他们。我们希望 OlmoEarth 平台能成为众多致力于解决世界最重大问题的组织在数据、模型、训练和推理方面的枢纽。

致谢

我们衷心感谢早期的合作者们，正是他们分享了数据、专业知识和时间，使这些模型在现实世界中关键任务应用上取得了成功：亚马逊保护协会、非洲野生动物基金会、国际农业发展基金/国际粮食政策研究所（IFPRI）、全球红树林观测网、全球生态系统图集、特温特大学信息技术中心（ITC）、美国国家航空航天局喷气推进实验室（JPL）以及美国国家航空航天局丰收项目。

我们还要感谢艾 2 的 OLMo-core、Beaker、通讯和法务团队的支持，尤其是皮特 · 沃尔什、迪尔克 · 格罗内维尔德、萨姆 · 斯科恩斯伯格、塔拉 · 威尔金斯、吴佳琳、约翰 · 达姆、戴维 · 阿尔布莱希特、凯尔 · 威格斯、乔丹 · 斯图尔特、南晶、威尔 · 史密斯和戴西 · 杜。

A 研究基准

我们将在下文更详细地描述第 3.2 节中介绍的研究基准。我们还分享了对某些基准局限性的观察。

GEO-Bench 通过修改基准，形成一个统一且一致的数据集集合：

m-bigearthnet 由 BigEarthNet [?] 修改而来，涉及 120×120 Sentinel-2 图像块的多标签地表覆盖分类。该数据集包含 19 个类别，例如耕地、内陆湿地和城市结构。原始数据集包含 549,488 个样本，但 GEO-Bench 中的修改子集仅包含 22,000 个，其中 20,000 个用于训练，1,000 个用于验证，1,000 个用于测试。

m-so2sat 由 So2Sat LCZ42 [?] 修改而来，涉及从同配准的哨兵-1 和哨兵-2 图像中进行局部气候区的图像级分类。该数据集包含 17 个类别，例如高层建筑、工业区和水体。原始数据集包含 400,673 个样本，但 GEO-Bench 中的修改子集仅包含 21,964 个，其中 19,992 个用于训练，986 个用于验证，986 个用于测试。

m-brick-kiln 是对孟加拉国砖窑分类数据集的修改版本 [?]。原始数据集涉及对高分辨率 224×224 卫星图像裁剪片进行图像级分类，判断其是否至少包含一个砖窑，共包含 6,329 个正例和 67,284 个负例。GEO-Bench 中的修改数据集在对应的 64×64 Sentinel-2 裁剪片上执行相同任务，仅包含 17,061 个样本，其中 15,063 个用于训练，999 个用于验证，999 个用于测试。虽然在 Sentinel-2 图像中识别砖窑是一项具有挑战性的任务，但我们发现 GEO-Bench 版本数据集中负例的性质使分类任务变得过于简单；例如，许多负例似乎仅包含深色像素，使其易于区分。

m-forestnet 是基于 ForestNet [?] 进行修改的，该方法从每个森林损失事件发生后五年内拍摄的复合 332×332 Landsat 8 卫星图像中进行图像级分类，以识别导致森林砍伐的驱动因素。共有四类驱动因素：种植园、小农户农业、草地/灌木丛地以及其他。原始数据集包含 2,756 个样本。GEO-Bench 中的修改子集包含 6,464 个训练样本、989 个验证样本和 993 个测试样本；我们无法确定额外样本的来源。

m-eurosat 是基于 EuroSat [?] 修改而来，涉及从 64×64 Sentinel-2 图像裁剪进行图像级土地利用和土地覆盖分类。该数据集包含 10 个类别，例如一年生作物、河流和高速公路。原始数据集包含 27,000 个样本，但 GEO-Bench 中的修改子集仅包含 4,000 个，其中 2,000 个用于训练，1,000 个用于验证，1,000 个用于测试。

m-cashewplant 是基于贝宁小农户腰果种植园数据集 [?] 修改而来，涉及 256×256 Sentinel-2 图像块的分割。该数据集包含六个与腰果种植园相关的类别：管理良好种植园、管理不良种植园、非种植园、不确定、住宅区和背景。修改后的数据集包含 1,800 个样本，其中 1,350 个用于训练，400 个用于验证，50 个用于测试。由于多个模型对该数据集的输入块大小敏感，因此对于具有可变块大小的模型，我们对输入块大小进行了遍历，并报告最佳结果。最终，这很可能是由于标签为大区域多边形而非逐像素标签所导致的影响。

m-SA-crop-type 由南非作物类型竞赛数据集 [?] 修改而来，涉及 256×256 Sentinel-2 和 Sentinel-1 图像块的作物类型分割。该数据集包含 10 个类别，例如休闲地、葡萄和小麦。GEO-Bench 中修改后的数据集仅使用 Sentinel-2 图像，共包含 5,000 个样本，其中 3,000 个用于训练，1,000 个用于验证，1,000 个用于测试。

GEO-Bench 数据集均存在一个显著局限：尽管任务涉及的标签在时间上变化不快，但输入仅包含一张

卫星图像或一对图像。我们发现，遥感模型在使用多张输入图像时通常表现更佳，因此我们认为，仅当标签仅在单一时间步有效时（如船舶检测任务），才应使用单张图像作为输入。

我们在 GEO-Bench 之外的五个额外数据集上进行比较：

BreizhCrops [?] 涉及从单像素的 Sentinel-2 时间序列进行作物类型分类。它包含九个类别，例如小麦、玉米和永久草地。数据集共包含 61 万条样本。

CropHarvest [?] 涉及从单像素时间序列进行二元耕地分类。提供的时间序列包括哨兵-2 和哨兵-1 卫星影像观测数据，以及来自 SRTM 的高程数据和来自 ERA-5 的气象数据。该数据集包含 95,186 个样本。

PASTIS [?] 涉及从哨兵-1 和哨兵-2 影像时序中进行作物类型分割，包含 128×128 个影像地块。它共有 19 个类别，例如葡萄、春大麦和大豆。数据集包含 2,433 个样本。

MADOS [?] 涉及在 80×80 Sentinel-2 图像裁剪中的海洋垃圾分割。该数据集包含 15 个类别，例如石油泄漏、稠密的萨尔加索藻和泡沫。共包含 2,803 个样本。MADOS 的一个关键局限在于，它提供了经过自定义处理的图像，这使得难以将基础模型与其预期的规范化统计量一起应用。此外，该数据集包含大量罕见类别，这些类别对测试集上的 mIoU 产生显著影响，导致同一模型在不同随机种子下的运行结果指标变化较大。

Sen1Floods11 涉及在聚焦洪水区域的 512×512 Sentinel-2 图像裁剪中进行二值水体分割。该数据集包含 4,831 个样本。我们测试的所有遥感模型的准确率均在 78% 至 80% 之间，且发现准确率与其他基准之间的相关性不强。然而，Sen1Floods11 是少数几个 Sentinel-1 基准之一。

B 合作伙伴任务

我们将在下文更详细地描述第 3.2 节中引入的合作伙伴任务。

AWF - 非洲野生动物基金会 *(AWF)* 肯尼亚南部土地覆盖分类。该数据集包含 1,459 个样本，共 9 个类别，值域从熔岩林和农业用地到城市开发不等。AWF 团队以 Planet 影像为主要参考，对这些样本进行了标注。

活燃料含水量 - *NASA JPL* 回归数据集包含来自 Globe-LFMC-2.0 [?] 的 41,214 个样本，标注有 LFMC 值。我们与 NASA JPL 合作，部署基于此数据训练的模型。LFMC 预测用于理解野火风险。

红树林 - 全球红树林观测将 100,000 个沿海区域分为 3 类：红树林森林、水域或其他。利用不同年份的红树林地图来了解红树林的生长与损失。

Nandi - *CGIAR* 肯尼亚南迪郡作物类型分类。该数据集包含 6,924 个样本，分为 6 个类别（咖啡、玉米、甘蔗等）。真实标签通过实地调查收集。

生态系统类型制图方法类似，但仅使用六时相的输入影像：

GEA 北非 - 全球生态系统图集北非区域 2,361 个样例的生态系统类型分类，标签对应于 IUCN 全球生态系统分类体系第 3 级的 110 个类别 [?]。

其他任务则更加独特：

森林损失驱动因素 - 亚马逊保护用于将亚马逊雨林的森林损失原因分类为 10 个类别（采矿、伐木、农业等）。

输入包含 4 张森林损失前拍摄的 Sentinel-2 图像和 4 张森林损失后拍摄的图像。通过驱动因素预测，可优先安排执法和诉讼行动，以阻止进一步的人为森林损失。

海洋基础设施 - *Skylight* 全球海洋基础设施检测数据集，包含 7,197 个标注为海上平台或风力涡轮机的样本。输入由 4 幅哨兵-2 或哨兵-2 + 哨兵-1 影像的时间序列组成。

船舶检测、类型、长度 - *Skylight* 三个目标检测任务，用于在 Landsat（8,000 个样本）、Sentinel-1（1,776 个样本）和 Sentinel-2（45,545 个样本）图像中检测船舶；一个分类任务，用于预测位于检测到的船舶中心的 Sentinel-2 图像中的船舶类型（584,432 个样本）；以及一个回归任务，用于估计 Sentinel-2 图像中的船舶长度（584,432 个样本）。对于所有这些任务，输入均为单张图像。

太阳能农场检测：二值分割数据集，包含 3,561 个示例，以太阳能农场多边形进行稠密标注。输入包含 4 个时间步，可以是哨兵-2 数据，或哨兵-2 + 哨兵-1 数据。太阳能农场地图用于理解可再生能源部署的全球变化趋势。

C 额外的消融

	m-bigearthnet	m-so2sat	m-brick-kiln	m-forestnet	m-eurosat	BreizhCrops	PASTIS	PASTIS	MADOS	Sen1Floods11	Average	Average Rank
	S2	S2	S2	L8	S2	S2	S1	S2	S2	S1		
	Acc.	Acc.	Acc.	Acc.	Acc.	F1	F1	F1	F1	F1		
MAE	60.6	48.1	96.2	42.0	89.3	71.5	**31.1**	46.6	68.7	78.3	63.2	5.1
Only S2 Data	53.7	45.9	91.3	-	89.2	**71.7**	-	42.4	69.5	-	46.4	-
No Maps	59.5	58.6	95.2	**46.0**	92.6	71.4	29.1	48.0	70.2	77.9	64.9	4.7
No Agricultural Maps	60.9	66.5	94.3	**46.0**	93.9	71.4	29.0	48.5	71.4	78.8	66.1	3.6
Random Masking	60.7	**67.4**	94.7	43.5	91.8	70.3	24.7	51.1	71.9	77.8	65.4	4.7
No Inst. Contrastive Loss	60.5	65.6	93.6	44.9	93.6	70.2	28.5	51.4	72.1	78.4	65.9	4.7
Patch Disc Loss	62.0	62.1	**96.3**	44.8	94.0	70.3	29.6	50.0	**74.1**	**79.3**	66.2	3.0
Final Recipe	**62.3**	65.9	94.2	45.8	**94.6**	71.4	29.4	**52.2**	71.7	78.8	**66.6**	**2.9**

Table 6 消融实验有选择性地移除 OlmoEarth 基础模型的组件。

除了第 3.6 节中的消融实验外，我们在表 6 中进行了第二组消融实验。第二组消融实验通过逐一移除最终模型和训练方案的各个组件来评估其贡献，除了第一行作为 MAE 基准。这些模型均训练了 300,000 步。在数据消融部分，我们看到仅使用 Sentinel-2 的模型表现相对较差，然而“无地图”运行（仅使用观测数据）仍保持相对较高的性能。尽管我们的模型可以从标注数据中受益，但即便采用纯自监督训练，依然表现出良好的性能。

构建遥感基础模型需要在某些方面做出权衡。尽管我们的最终模型在每个指标上并非表现最佳，但它整体性能优异，并且平均得分最高，各任务的平均秩最低。

D 与 AlphaEarth 基础模型的比较

AlphaEarth 基础模型 [?] 与 OlmoEarth 相当，因为两者均基于相似的数据源，并旨在支持类似的下游任务。谷歌并未发布该模型，而是仅发布了 AlphaEarth 计算的全球年度嵌入。我们将 OlmoEarth 与之比较，既作为冻结的特征提取器（此时仅使用嵌入，与 AlphaEarth 类似），也作为可端到端微调的模型。

Model	Training	Nandi Acc.	AWF Acc.	Ecosystem Acc.	LFMC L1	Solar Farm mIOU
AEF	kNN	55.6	81	60.6	-	-
AEF	Frozen + Decoder	66.0	75.9	61.2	23.1	77.5
AEF	Full Fine-tuning	Not Possible				
OlmoEarth	kNN	66.2	82	59.3	-	-
OlmoEarth	Frozen + Decoder	62.9	84.0	61.1	19.9	84.8
OlmoEarth	Full Fine-tuning	**82.2**	**86.0**	**62.4**	**17.9**	**86.7**

Table 7 将 AlphaEarth 基础模型（AEF）嵌入与 OlmoEarth ViT Base 模型在三种不同的训练策略下进行比较：kNN、冻结主干 + 解码器，以及全量微调的解码器。在这些评估中，我们使用第3.4节所述的“合作任务”解码器。

从 Google Earth Engine 导出和下载 AlphaEarth 嵌入非常昂贵：我们对 32×32 作物的导出任务平均耗时 26 EECU-秒，对于包含 10 万作物的数据集而言，费用高达 290 美元。因此，我们仅能在五个任务上评估 AlphaEarth：三个分类任务（Nandi、AWF 和生态系统）、一个逐像素回归任务（LFMC）以及一个分割任务（太阳能农场）。

由于 AlphaEarth 模型尚未发布，我们无法在微调设置下评估 AlphaEarth。我们使用简单的 KNN 分类器，将年度化后的 AlphaEarth 嵌入与来自 ViT Base 编码器的 OlmoEarth 嵌入进行性能对比。我们采用与标签值域重叠度最高的 AlphaEarth 嵌入时间步。为了评估更复杂解码器的优势，我们使用第3.4节中描述的配对任务解码器，并对输入大小进行扫描（由于 AlphaEarth 嵌入已捕捉空间上下文，我们发现较小的输入大小表现更优）。

使用 KNN 分类器时，OlmoEarth 在 Nandi 和 AWF 任务上表现优于 AlphaEarth，而在生态系统制图任务上，AEF 则优于 OlmoEarth。然而，OlmoEarth 在进行完整微调后表现出显著提升，其微调后的模型在所有五个任务上的得分均超过了可能达到的最佳水平的 AlphaEarth。这凸显了开放模型的价值，使其能够实现针对特定任务的微调。

E `m_cashew_plant` 的补丁大小分析

我们观察到，在 `m_cashew_plant` 评估任务中，对于支持可变块大小的模型（如 OlmoEarth 和 Galileo），较大的块大小会带来更好的性能。表 8 总结了不同块大小下 `m_cashew_plant` 的线性探测和微调结果。

这种现象很不寻常：通常情况下，较小的图像块大小会提升性能（例如，[**?**] 的图 4）。我们推测这是由于数据集中空间上较为粗略的标签所致，这些标签是多边形而非像素（图 5）。

Model	Patch 4×4		Patch 8×8		Patch 16×16	
	LP	FT	LP	FT	LP	FT
OlmoEarth-Base	27.7	71.9	27.9	76.2	32.3	79.8
Galileo	24.3	73.0	25.6	76.9	28.9	78.8

Table 8 不同块大小下的性能（mIoU）对比（LP = 线性探测，FT = 微调）。

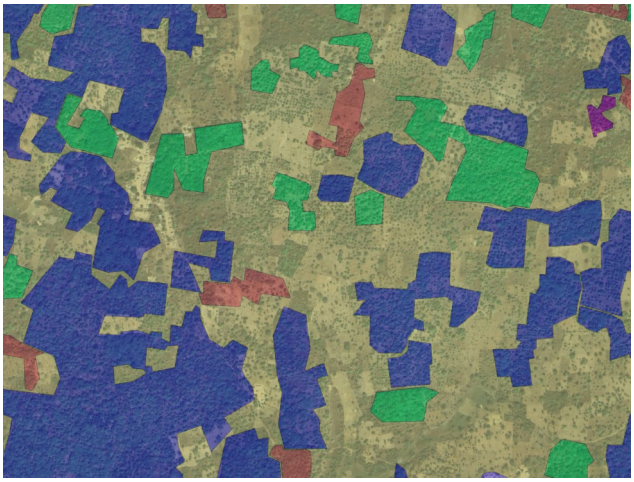

Figure 5 `m_cashew_plant` 数据集中的一个示例实例：请注意粗略的、多边形的标签

F OlmoEarth 平台

OlmoEarth 平台 是一个端到端解决方案，将我们的基础模型与专为应对环境挑战的组织设计的数据管理工具相结合。该平台涵盖了从卫星数据采集、标签标注、模型微调到推理的完整工作流，使组织无需自行管理 GPU 基础设施或具备深度学习专业知识。通过让我们的模型易于访问，OlmoEarth 平台 解决了将研究转化为实际应用工具的“最后一公里”难题，助力保护生物多样性、气候行动和粮食安全等领域的应用。

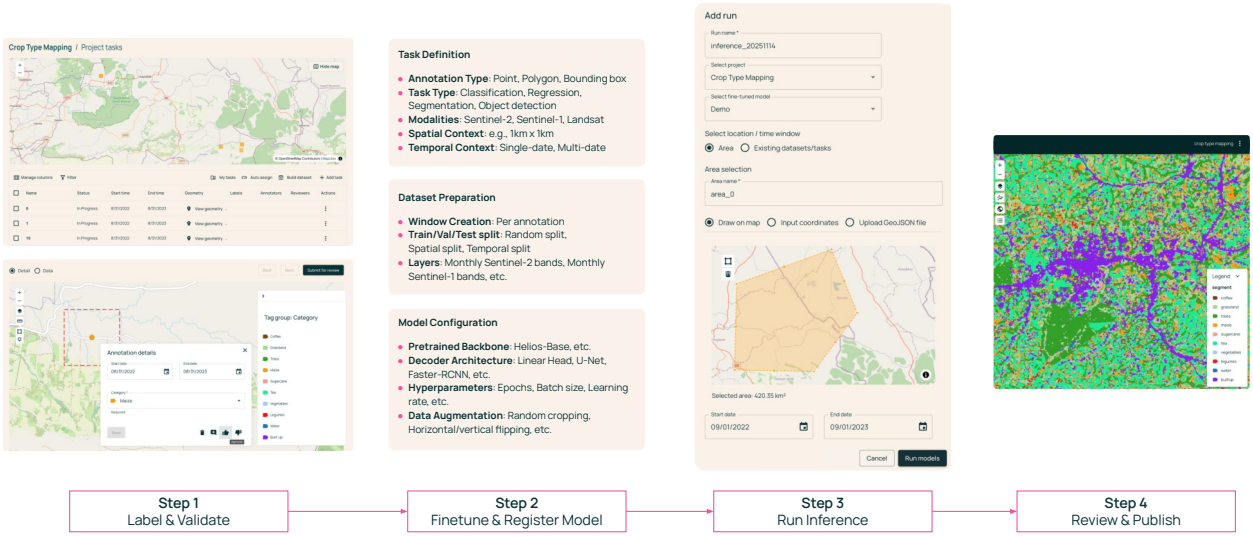
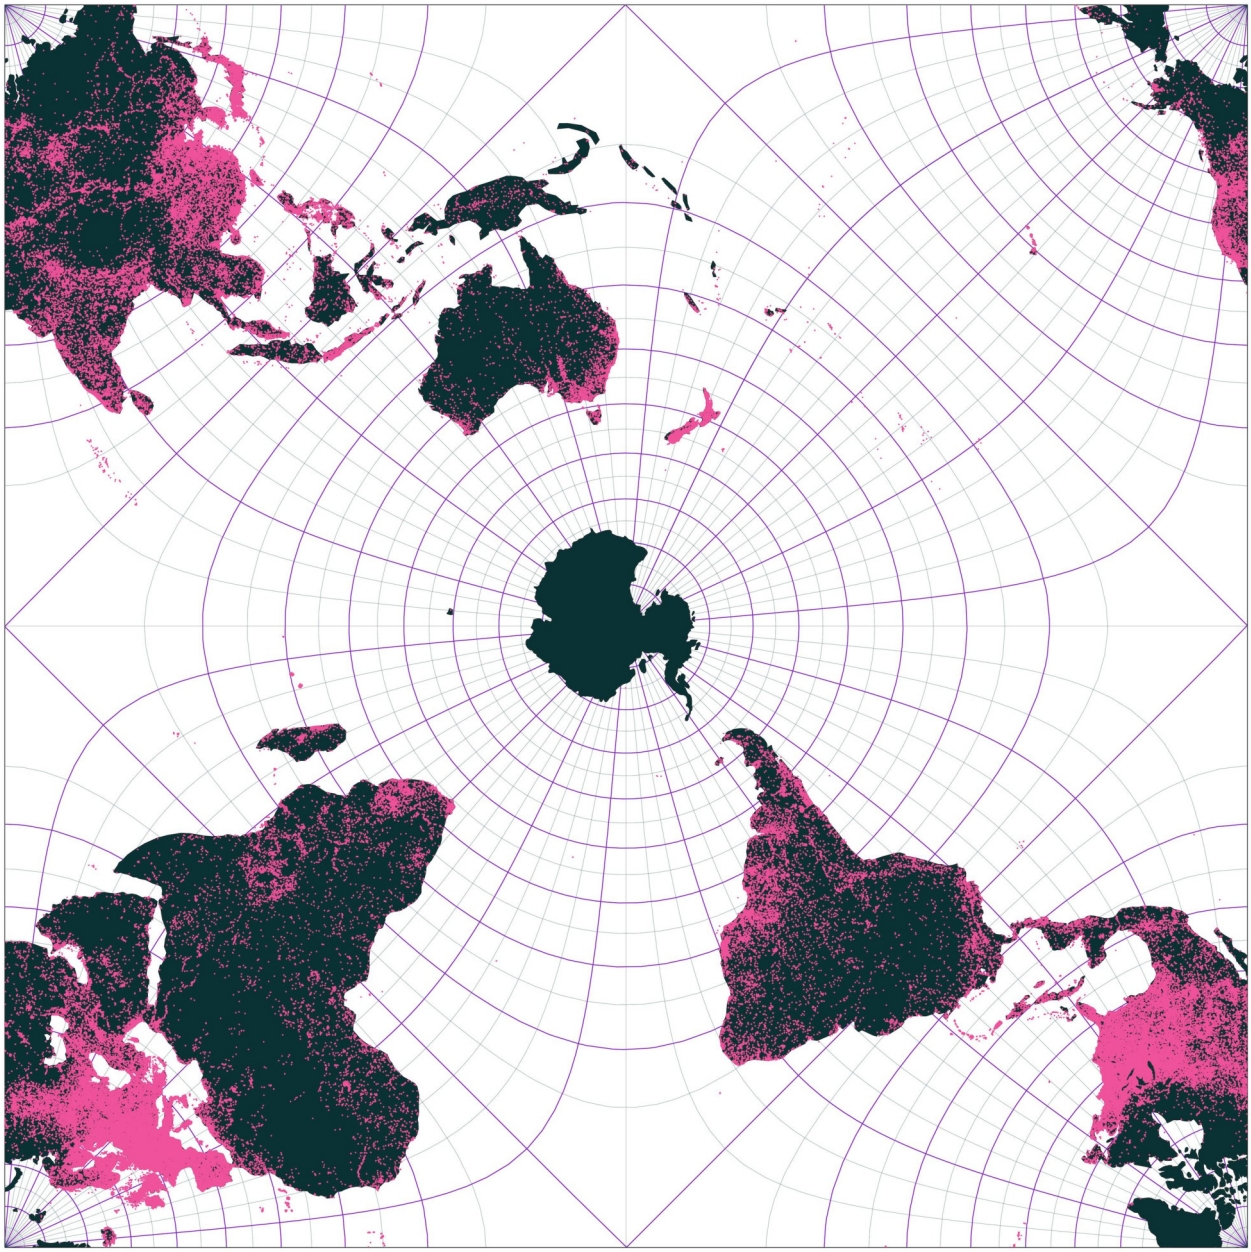
Figure 6 OlmoEarth 平台：端到端工作流（以作物类型制图为示例）。该平台使用户能够完成从数据标注到地图发布的完整流程：**步骤 1**：标注并审核标注信息，**步骤 2**：针对特定任务微调并注册模型，**步骤 3**：在选定区域和时间值域内运行推理，以及 **步骤 4**：审核并发布最终地图。