https://hjfy.top/arxiv/2503.10845

全景监狱：推动面向地球观测的多传感器基础模型发展

Leonard Waldmann[1,2*] Ando Shah[1*] Yi Wang[2] Nils Lehmann[2,3]
Adam J. Stewart[2,3] Zhitong Xiong[2] Xiao Xiang Zhu[2,3] Stefan Bauer[2]
John Chuang[1]

[1] 加州大学伯克利分校；[2] 慕尼黑工业大学；[3] 慕尼黑机器学习中心
对应至 ando@berkeley.edu

Abstract

地球观测（EO）数据来自多种传感平台，具有不同的光谱波段、空间分辨率和感知模式。尽管以往大多数研究将输入限制在固定传感器上，但最近出现了一类能够处理任意传感器的“任意传感器”基础模型。在此研究方向上，我们提出了 Panopticon，一个基于 DINOv2 框架构建的任意传感器基础模型。我们通过以下方式扩展了 DINOv2：(1) 将同一地理位置不同传感器获取的图像视为自然的数据增强；(2) 对通道进行下采样以丰富光谱输入；(3) 引入通道间的交叉注意力作为灵活的补丁嵌入机制。

通过分别编码光学传感器与合成孔径雷达传感器的波长和感知模式，Panopticon 能够有效处理任意通道组合。在广泛的评估中，我们在 GEO-Bench 上取得了最先进的性能，尤其是在广泛使用的 Sentinel-1 和 Sentinel-2 传感器上表现优异，不仅超越了其他任意传感器模型，也优于针对特定传感器配置进行领域适配的固定传感器模型。Panopticon 可立即推广至现有及未来的卫星任务，推动了无传感器依赖的地球观测发展。

1. 引言

地球观测（EO）卫星为监测我们的星球提供了重要数据，从检测非法挖掘 [58] 和暗影船舶 [47]，到田块划分 [28] 和产量预测 [52]。近年来，遥感基础模型（RSFMs）取得了显著进展，这些模型将专为 RGB 影像设计的计算机视觉方法适配到了地球观测数据上 [12, 45, 51, 72]。然而，与自然图像相比，遥感数据表现出显著的异质性 [53, 61, 64]。地球观测平台在多个维度上产生了极其多样的数据，包括空间分辨率（厘米至千米）、光谱特性（多光谱、高光谱、雷达）、重访时间（连续至静态）、条带宽度、预处理级别（原始数据、大气顶层、地表反射率）以及感知机制（主动与被动）。尽管遥感基础模型最初是针对特定传感器设计的 [12, 26, 36, 56, 67]，但当前趋势正朝着能够处理多种地球观测数据的更灵活模型发展 [1, 17, 34, 59, 70, 75]。

最近，一类新兴的任意传感器模型开始解决地球观测（EO）中传感器无关性这一根本挑战。在撰写本文时，这类模型仅包含少量示例 [50, 74]，但它们能够处理任意传感器配置的数据——包括未见过的光谱波段、分辨率和模态组合——而在推理过程中无需进行特定于传感器的调整。它们通过解耦光谱与空间处理，并融入特定于传感器的属性知识（如光谱响应函数（SRFs）和地面采样距离（GSDs））来实现这一目标。

在本工作中，我们提出了 Panopticon，这是一种新型的任意传感器模型（参见 Section A 了解该名称的

* 表示共同第一作者，顺序随机排列。共同第一作者应在个人简历/网站上优先列出自己的姓名

代码：https://github.com/Panopticon-FM/panopticon

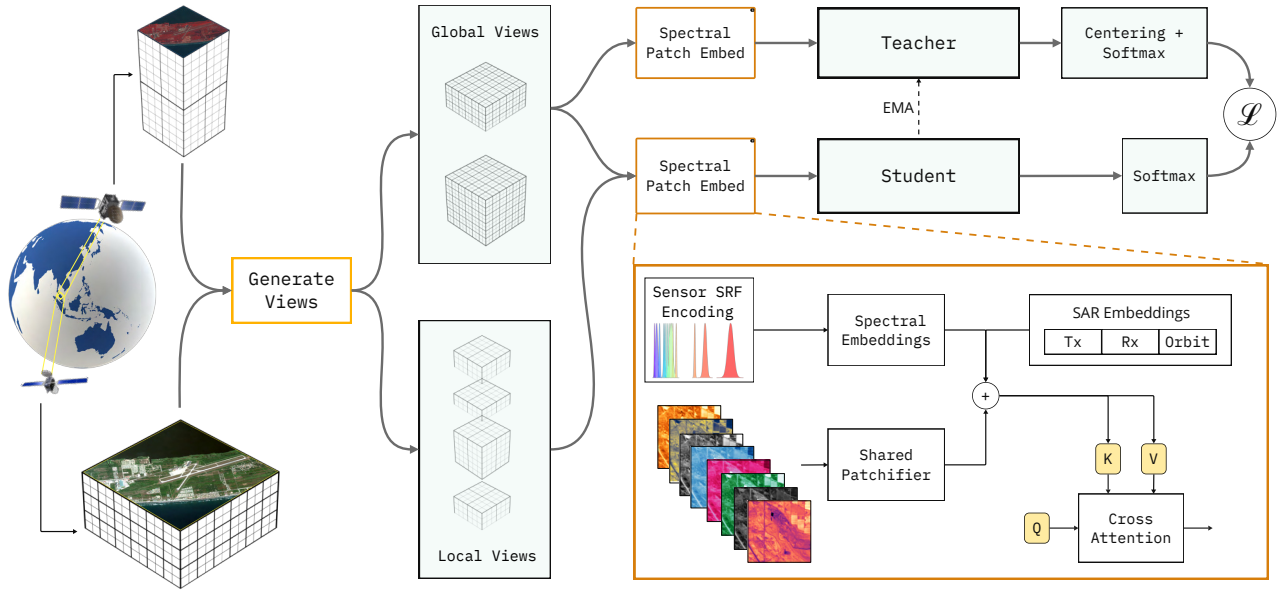

图 1. Panopticon 的架构。突出显示的块表示对 DINOv2 框架的修改。在生成视图时，由不同传感器在不同时刻、不同尺度等条件下捕捉到的同一地理范围的图像被视为增强数据。光谱块嵌入块使用共享的块化器对输入视图进行 token 化，并通过单个查询的交叉注意力机制，在每个空间块内跨通道融合 token。

词源）。基于 DINOv2 [46] 框架，我们针对卫星数据作为独立模态的更强融合，进行了三项关键改进 [53]。首先，我们不再仅在单张图像内进行知识蒸馏，而是将给定地理坐标或“足迹”视为关注对象，并将来自不同传感器的同一足迹快照视为同一对象的不同增强视图。这种方法使我们能够通过整合具有不同通道特性、模态、时间戳和处理层级的图像，采样广泛自然的传感器间差异。其次，除了标准的 DINOv2 空间增强外，我们还对多光谱（MS）、高光谱（HS）和合成孔径雷达（SAR）训练数据应用了光谱增强，通过下采样通道实现。第三，为处理通道数量不同的视图，我们实现了通道上的交叉注意力机制，并引入了包含传感器特异性光谱信息的位置嵌入，以生成统一表示。

为了评估光谱灵活性，我们使用高光谱（HS）数据集模拟新的传感器，并通过光谱卷积 [6] 对模型进行测试，同时减少光谱和尺度信息以评估其对这些属性的不变性，此外还评估了模型在预训练过程中未遇到的传感器上的表现。我们证明了 Panopticon 在 GEO-Bench [32] 上也达到了最先进的性能，该基准包含诸如 Sentinel-1 (S1) 和 Sentinel-2 (S2) 等常用传感器。为应对固定传感器模型中的传感器分布偏移问题，我们采用补丁嵌入重新训练作为参数高效的领域自适应 [5, 24]。一个令人惊讶的发现是，DINOv2 在这些对比中表现出了极为强劲的基准性能，暗示了未来研究的方向。通过对 23 个多光谱（MS）、高光谱（HS）和合成孔径雷达（SAR）数据集的全面实验，我们为当前遥感领域中传感器无关学习方法的能力与局限性提供了宝贵的见解。

总之，我们的贡献如下：

- 我们介绍了 Panopticon，这是一种 RSFM，能够为任意的 MS、HS 或 SAR 传感器构建表示，无论其地面采样距离（GSD）或光谱特性如何。
- 在保持对现有基准测试的竞争力至前沿性能的同时，潘诺普蒂康在涵盖重要应用领域的更多独特传感器配置上，表现优于其他任意传感器模型。
- 我们发现，结合更宽的嵌入维度以及在通道注意力模块中使用光谱嵌入的光谱渐进预训练对于实现最佳性能至关重要。

2. 相关工作

固定传感器的 RSFM 不同方法在如何使用同一模型处理不同传感器方面存在差异。USat [25] 和 ms-GFM [21] 采用传感器特定的图像块嵌入，输入单一编码器，其中 USat 在 token 中添加了位置信息。Sat-

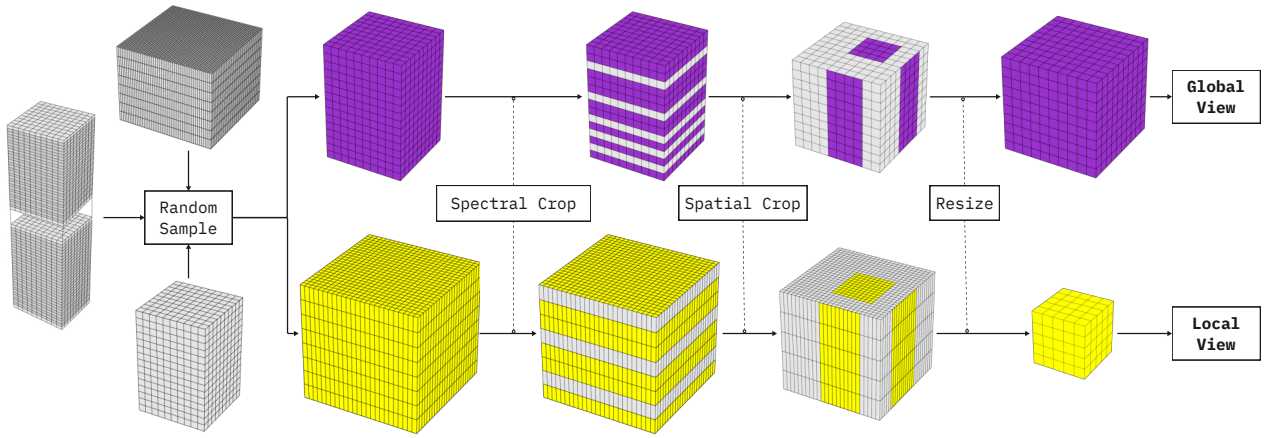

图 2. 视图生成。给定一个足迹，我们随机采样一个快照，执行隐式的光谱、尺度和时间增强。为了增加光谱方差，我们应用光谱裁剪，同时遵循 DINOv2 的方法，进行空间裁剪并调整大小。为简化起见，省略了额外的翻转和颜色抖动。局部视图和全局视图通过不同的增强参数类似地创建。

MAE [12]、Galileo [60] 和 AnySat [1] 采用更细粒度的方法，对通道组使用图像块嵌入。受视频模型启发的模型如 Prithvi [27] 和 S2MAE [35] 在时空或空谱维度上进行图像块划分。另一类工作则使用分离的编码器，并通过对比损失和重构损失对齐所得的传感器特定表示，如 CROMA [17]；或使用修改后的对比损失，如 IAI-SimCLR [49]；或对协方差矩阵进行正则化，如 DeCUR [69]。

任意传感器 RSFMs　据我们所知，已有两种通用型多传感器模型被提出，均基于 MAE [22] 架构。DOFA [74] 提出了一种基于输入通道波长的超网络 [20] 动态生成权重，用于原本固定形状的输入投影层和解码器最终层。SenPa-MAE [50] 将每个通道分别进行块化处理，采用相同的投影方式，并在编码器和解码器的 token 中加入由通道光谱响应函数（SRF）计算得到的位置嵌入、地面采样距离（GSD）嵌入和光谱嵌入。与此同时，Copernicus-FM [71] 在 DOFA 基础上扩展了非光谱模态，适用于所有 Copernicus 任务传感器。

传感器视图作为增强功能　多个遥感图像建模方法（RSFM）利用同一像元范围内图像之间固有的时间与光谱差异作为数据增强手段。具体而言，DINO-MC [73] 使用时间正样本对，SeCo [40] 将季节性差异引入其分支结构，CaCo [38] 定义了感知变化的时间正负样本对。另一方面，DINO-MM [66] 通过随机为每个视图选择不同传感器实现光谱增强。最后，A2MAE [76] 采用元信息感知掩码，生成在光谱和时间上均具有多样性的 token。

DINOv2　DINO [7] 匹配由教师网络和学生网络从同一图像的不同增强局部视图和全局视图计算出的离散概率分布。学生权重通过反向传播进行更新，而教师权重则设为学生权重的指数移动平均。为防止崩溃，教师应用中心化和锐化处理。DINOv2 [46] 将 DINO 与基于块的 iBOT 损失 [77] 相结合并扩展了训练规模。重要的是，已提供从 ViT-g 运行中蒸馏得到的强 DINOv2 ViT-B 检查点。

3. 方法

我们提出 Panopticon，其基于 DINOv2 架构 [46]，对视图生成和块嵌入进行了改进，如 Figure 1 所示。

3.1. 传感器视图作为足迹的增强

DINO 框架在相同图像的不同增强视图之间自蒸馏知识 [7]。与将单张图像视为关注对象不同，我们以地理足迹作为关注对象，并将来自不同传感器的图像视为视图，因此视为同一对象的不同增强。由于增强定义了不变性，我们的模型特别对光谱配置具有不变性，同时也对地面采样距离（GSD）、获取时间以及处理级别具有不变性，参见 Table 1。

Dataset	Locations	Sensors	GSD (m)	Footprint (km^2)	Sensor Modalities (# bands)	Temporal Range	Processing Level
fMoW [9, 12]	90 K	QB, GE, WV, S2	0.3–10	0.2–25	RGB (3), MSI (4, 8, 12)	2002–2020	L2A
MMEarth [42]	1.2 M	S1, S2	10	1.7	SAR (8), MSI (12)	2017–2020	L1C, L2A
SatlasPretrain [3]	770 K	S1, S2, L9	10–100	25	SAR (2), MSI (9), Thermal (2)	2022	L1C
SpectralEarth [5]	415 K	EnMAP	30	14.7	HSI (202)	2022–2024	L2A

表 1. 预训练数据集。fMoW 指 fMoW-full 与 fMoW-Sentinel 数据集的合并。位置数指唯一足迹的数量，足迹大小以平方千米表示。模态名称周围的括号内为该模态的通道数。MSI = 多光谱成像仪，HSI = 超光谱成像仪，QB = QuickBird-1，GE = GeoEye-2，WV = WorldView，S1 = Sentinel-1，S2 = Sentinel-2，L9 = Landsat 9。

3.2. 局部与全局视图生成

给定一个包含一组来自该区域不同传感器的快照 X 的足迹，我们首先生成一个局部视图。我们从选择一个具有 $x \in X$ 个通道的快照 C 开始，这隐式地应用了光谱、尺度和时间上的增强组合。由于训练数据集中唯一传感器的数量在实践中有限，我们通过下采样通道来增加光谱信息的方差。具体来说，我们首先在边界 $C' \in \{\min(C, C^l_{\text{low}}), ..., \min(C, C^l_{\text{high}})\}$ 内随机采样通道数量 $C^l_{\text{low}}, C^l_{\text{high}}$ ，然后从 C' 中均匀随机选择 x 个唯一通道。所有采样均以均匀随机方式进行。如同 DINO 中的做法，我们对空间形状 $W^l \times H^l$ 应用随机缩放裁剪，详见 Figure 2，同时进行额外的翻转和颜色抖动处理。我们重复此过程以生成 n^l 个局部视图。类似地，我们使用参数 n^g 生成 $C^g_{\text{low}}, C^g_{\text{high}}, W^g, H^g$ 个全局视图。与 DINOv2 对应，我们设置 $n^l = 4$ ，$n^g = 2$ ，$H^l = W^l = 96$ ，以及 $H^g = W^g = 224$ 。为了能够将完整的 S2 图像放入全局裁剪中，我们设置 $C^g_{\text{high}} = 13$ ，并为了最大灵活性，我们设置 $C^l_{\text{low}} = 1$ 。最后，我们设置 $C^l_{\text{high}} = C^g_{\text{low}} = 4$ ，详见 Section G。

3.3. 通道上的注意力机制作为图像块嵌入

令 $x \in \mathbb{R}^{C \times H \times W}$ 为输入图像的补丁嵌入（PE），其中 C 为通道数，H 为高度，W 为宽度。由于 C 在图像间变化，我们无法使用 ViTs [14] 中的标准二维卷积作为 PE。相反，如 Bao et al. [2] 所示，我们首先对每个通道进行补丁化并使用相同的二维卷积进行嵌入至 $x_p \in \mathbb{R}^{L \times C \times D}$，其中 L 为补丁数量，D 为主干网络的嵌入维度。类似地，如 Nguyen et al. [43] 所示，我们随后通过单个学成查询 $q \in \mathbb{R}^{1 \times D}$ 与 x_p 作为键和值的交叉注意力机制，将 C 降低至 $x_{\text{out}} \in \mathbb{R}^{L \times D}$。我们在维度 D_{attn} 上执行交叉注意力，即查询、键、值的投影以及交叉注意力图的最终投影分别从和到 D_{attn}。我们发现 $D_{\text{attn}} > D$ 会提升性能，参见 Section 5。

为了获取关于各个通道的光谱信息，我们向 x_p 添加以下嵌入。对于光学通道，我们在等于该通道中心波长 λ （单位为纳米，例如红光为 664 nm）的位置上选择标准位置编码 [65]，即

$$\text{PE}_{(\text{pos},2i)} = \sin(\omega_i \lambda), \tag{1}$$

$$\text{PE}_{(\text{pos},2i+1)} = \cos(\omega_i \lambda), \tag{2}$$

其中 $\omega_i = 1/10000^{2i/D}$.

我们将 SAR 通道根据其 3 种可能的轨道方向（即上升、下降、未知/两者皆有）和 4 种可能的发射与接收极化方式（即 VV、VH、HH、HV），分为 12 个类别，形成 12 种可能的极化-轨道组合。我们为每个发射、接收和轨道变量学习维度为 $D/3$ 的嵌入，并将其连结成完整的嵌入向量。这符合已知研究结果，即跨极化 [11, 63] 和轨道 [37, 64] 生成的 SAR 数据具有显著差异。注意，我们仅引入光谱信息，未包含地面采样距离（GSD）、时间或处理级别等相关信息。

3.4. 光谱渐进式预训练

我们发现，直接使用多样传感器对 Panopticon 进行训练会得到较差的性能。受渐进式预训练 [41, 74] 的启发，我们在两个阶段进行预训练：第一阶段减少光谱多样性，第二阶段则最大化光谱多样性。在 Section 5

中，我们展示了这种方法显著提升了性能。

3.5. 实现细节

数据集 我们使用 Table 1 中提出的数据集，理由如下：

- fMoW，包括 fMoW [9] 和 fMoW-Sentinel [12]，结合了常用的光学波段（RGB、S2）以及商用多光谱传感器——WorldView（WV）2/3，具有较大的地面分辨率差异和极高分辨率的 RGB 图像。
- SatlasPretrain [3] 在全球多样化的区域范围内，配对了 S1 SAR、S2 光学影像，以及 Landsat 9 的光学和热红外传感器数据。
- MMEarth [42] 提供了额外的 SAR 配置——包括 SatlasPretrain 中未包含的上升轨道和下降轨道，以及 VV、VH、HV 和 HH 极化。
- SpectralEarth [5] 是一个具有 202 个通道的高光谱数据集，因此在光学波长范围内提供了丰富的光谱多样性。

每个数据集都经过标准化处理，其均值和标准差是基于训练划分计算的。更多详细信息见 Section C。

模型权重和训练 我们使用 ViT-B 作为骨干网络，$D = 768$，并加载已发布的 DINOv2 权重。由于未提供分类和 iBOT 头的权重，并且随机初始化它们时训练不稳定，我们使用标准的 patch 嵌入在 fMoW 上预训练完整的 DINOv2 权重（仅使用 RGB 通道），并将这些头权重用作 Panopticon 的初始化。最后，我们使用通道上的注意力作为位置编码（PE），$D_{\text{attn}} = 2304$，从而使学生模型拥有 98.1 M 参数，其中 12.9 M 属于 patch 嵌入。

我们分两个阶段训练模型，第一阶段仅使用 fMoW，第二阶段使用所有数据集，详见 Section 5。遵循 DINOv2 的做法，我们人为将一轮次定义为 1250 次迭代，在 16 块 A100 40GB GPU 上每个阶段训练 87.5K 次迭代或 70 轮次，有效批量大小为 1200。更多细节见 Section F。

4. 评估

我们在线性探测和 k NN 情景下，针对 11 个分类、7 个分割和 4 个回归下游任务，将我们的模型与 DINOv2、固定传感器模型以及任意传感器模型进行对比评估。我们从两个具体方面测试传感器泛化能力：a) 对未见过的传感器配置的泛化能力；b) 生成在尺度和光谱上不变的表示的能力。此外，我们在常用的遥感基准（如 GEO-Bench [32]）上测试性能。所有评估均在 ViT-Base 模型架构上进行。本节中使用的数据集处理和评估协议的更多细节可参见 Table 1 和 Section F。

4.1. 对独特传感器的泛化

我们将在预训练期间未显式遇到过的传感器配置的数据集上，对 Panopticon 与当前最先进的（SOTA）固定传感器模型进行评估。鉴于商用传感器的公开数据和基准资源有限 [54]，我们采用高光谱（HS）波段上的光谱卷积来模拟具有不同光谱特征的现有传感器；更多细节见 Section E。利用 SpectralEarth-Corine 数据集 [5]，我们将 HS 波段转换为对应于 Planet 的 SuperDove 传感器（8 波段）[48, 62] 和 MODIS Terra 传感器（16 波段）[55]，分别构建了 ❶ Corine-SD 与 ❷ Corine-MODIS 数据集。我们对 Hyperview [31] HS 数据集应用相同的变换，将其映射至 ❸ SuperDove 与 ❹ MODIS 波段。最后，我们采用风速估计任务 ❺ TropicalCylone [39] 与 ❻ DigitalTyphoon [30]，因其具有波长达 10.4 μ m 的极端光谱分布偏移而具有参考价值。

为了将固定传感器模型适配至新传感器，我们重新训练一个二维卷积作为补丁嵌入（patch embedding），同时保持主干网络冻结，记作后缀 “-PE”。该方法已被证明是地球观测基础模型的一种参数高效的领域自适应策略 [24]。这使得原本固定的传感器模型能够适应源自其他传感器的数据集。

此外，我们包含两个基准数据集，它们包含两种商用传感器：❼ SpaceNet 1 [15] 使用的是 WV2 传感器，而㉓ fMoW 数据集仅包含 WV2+WV3 传感器（10%）。

Table 2 总结了结果。尽管领域自适应的固定传感器模型表现良好，通常优于以往的任意传感器模型，但潘诺普蒂康在这些任务中几乎始终表现更佳，大多数情况下优势显著。

4.2. 光谱不变性

受 Reed et al. [51]的启发，我们通过逐步减少可用通道数来评估谱不变性，如 Figure 3(top) 所示。我们在数据集❽ EuroSAT [23] 和❾ Brick Kiln [33] 上采用 k-最近邻 (k NN) 分类，这两个数据集均经过 GEO-Bench 修改 [32]，并使用均匀子采样的通道。对于 HS

	Commercial Sensors		Synthesized Sensors				OOD Sensors	
	SpaceNet1 WV7 miJacc (%) ↑	fMoW-10% WV8 Acc (%) ↑	Corine SuperDove mAP (%) ↑	Corine MODIS mAP (%)↑	Hyperview SuperDove MSE ↓	Hyperview MODIS MSE ↓	TC-10% GOES-16 MSE ↓	DT-10% Himawari MSE ↓
DINOv2-PE	90.0 / 90.6*	29.2 / 47.0*	66.8 / 80.6*	63.6 / 80.7	1.043 / 0.340*	0.639 / 0.335*	0.635	0.502
Croma-PE	89.4	33.7	75.1	78.4	0.343	0.519	0.394	0.925
Softcon-PE	90.1	32.8	77.3	80.2	0.353	0.533	0.471	0.810
Anysat-PE	87.7	26.2	73.4	76.6	0.326	0.519	0.449	1.406
SenPa-MAE	86.2	16.9	64.2	62.7	0.366	0.355	-	-
DOFA	89.9	42.0	81.0	80.2	0.334	0.338	0.385	1.032
Panopticon	90.3	50.3	85.8	86.2	0.313	0.321	0.315	0.963

表 2. 光谱泛化性能。通过光谱卷积从 EnMAP 源波段生成合成传感器通道，以模拟目标传感器，并在 SpectralEarth Corine 数据集上进行测试。类似地，Intuition-1 HS 传感器也被变换为目标波段，用于 Hyperview 数据集。对于 Planet SuperDove (SD) 的 8 个波段或 MODIS Terra 的 16 个波段，目标波段通过光谱卷积生成。分布外（OOD）传感器指中心波长为 10.4 μ m 的气象卫星通道。'-' 表示该模型无法适应该数据集。最佳结果用 **粗体**标注，次优结果用 下划线 标注。* 使用仅 RGB 通道重新初始化的 PE / 冻结预训练 PE 进行训练。DT = DigitalTyphoon，TC = TropicalCyclone，miJacc = micro Jaccard 指数

	Classification (top-1 Accuracy %) ↑						Segmentation (miJacc %) ↑			
	reBEN-10% S2	reBEN-10% S1	m-eurosat S2	m-forestnet L8	m-so2sat S2	RESISC45 RGB	m-sacrop S2	m-cashew S2	m-nzcattle RGB	m-pv4ger RGB
DINOv2	80.1	-	95.5	53.5	60.8	94.0	51.2	65.9	92.7	96.9
CROMA	79.4	70.3	91.1	-	53.5	-	48.4	44.3	-	-
SoftCon	84.3	80.0	92.2	-	52.1	-	51.3	54.5	-	-
AnySat	76.8	64.4	87.6	50.9	42.5	65.5	39.5	38.8	92.5	92.2
Galileo	76.5	70.3	88.6	-	54.2	-	39.5	40.4	-	-
SenPa-MAE	63.8	-	77.5	33.5	33.7	28.2	39.3	40.7	89.5	78.3
DOFA	78.8	72.0	92.9	53.2	54.2	92.0	51.3	56.4	92.8	96.3
Panopticon	83.9	78.4	96.4	56.3	61.7	90.9	52.6	59.3	92.6	95.2

表 3. 在包含来自 GEO-Bench、reBEN 和 RESISC45 数据集的知名传感器数据上的分类与分割任务。'-' 表示该模型无法适应该数据集。我们以仅使用相应数据集的 RGB 通道的原始预训练 DINOv2 权重作为基准，构成一个非常强的基准。Panopticon 在除 2 个任务外的所有任务中均位列前 2 模型。最佳结果用 **粗体**表示，次佳结果用 下划线 表示。L8 = Landsat 8，miJacc = micro Jaccard 指数

⑩ EnMAP-Corine 数据集 [5]，我们使用线性探测（LP）并进行分箱通道子采样。对于每种情景，我们采样 5 个子集，并报告任务指标的均值和标准差。注意，所有模型的采样通道是相同的。我们仅在任意传感器模型上进行评估，因为我们关注的是表示质量，而不调整骨干网络。

Panopticon 在几乎整个光谱子采样值域范围内均保持生成高质量表示的能力，这些任务中表现出较高的光谱不变性。特别值得注意的是，Panopticon 在子采样通道上的方差较低，表明其具有更高的通道（因此也是光谱）不变性。DOFA 和 SenPa-MAE 均倾向于在整个范围内保持稳定性能（尽管方差较高），这表明任

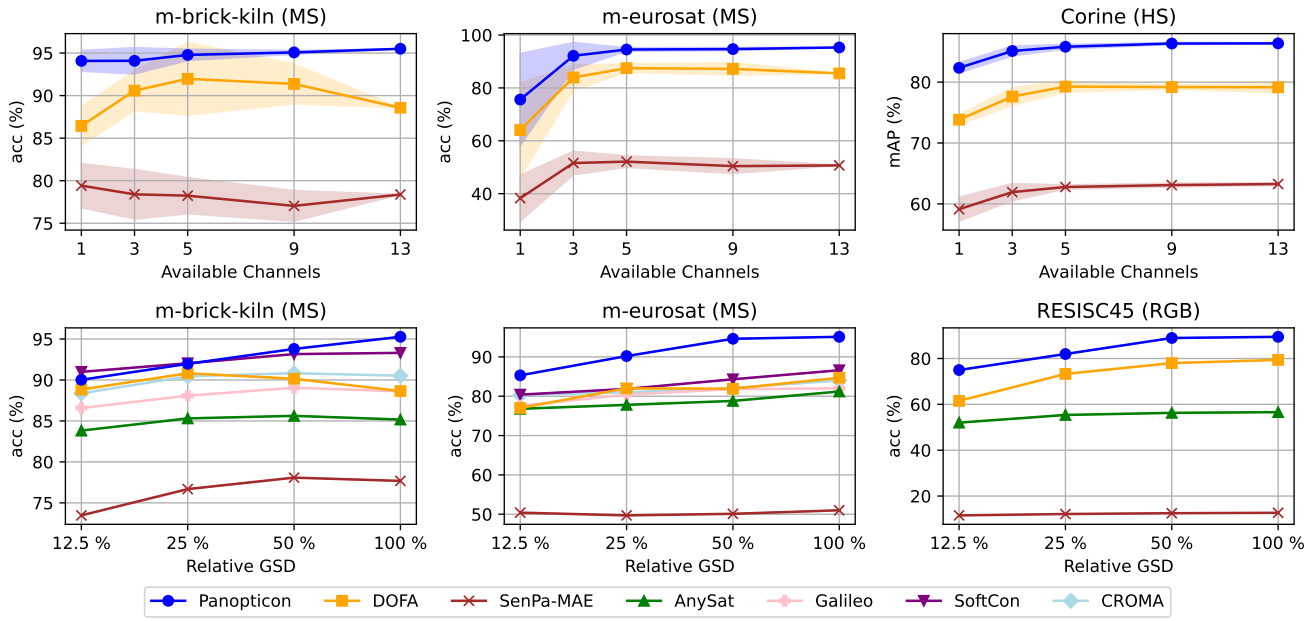

图 3. 表示稳定性在信息缩减下。对于 m-eurosat、m-brick-kiln 和 RESISC45，我们报告来自 k 神经网络分类（使用 $k = 20$）的 top-1 准确率（acc），对于 EnMAP-Corine，我们报告来自线性探测的平均平均精度（mAP）。Panopticon 在所有图表中以深蓝色线显示。**上：**在光谱下采样下学习稳定表示，每个使用 5 个不同子集以及对应的 ±1 标准差带（由阴影区域表示）。**下：**通过对训练数据和测试数据进行下采样和上采样来学习尺度不变表示。

意传感器模型的预训练范式可能对这种行为有所贡献。此外，我们还评估了 Panopticon 的跨传感器泛化能力，结果详见 Section D.1。

4.3. 尺度不变性

我们通过在两个多光谱和一个 RGB 数据集上的 k 神经网络分类来评估尺度不变性，如 Figure 3(bottom) 所示。MS 数据集包括⑧ EuroSAT [24] 和⑨ Brick Kiln [33]，均根据 GEO-Bench 规范进行了修改 [32]。对于 RGB 评估，我们使用⑪ RESISC45 [8] 数据集，因为它本身具有较大的地面采样距离（GSD）方差，我们进一步对其进行增强。MS 数据集的 GSD 固定为 10 米。类似于 Reed et al. [51]建立的协议，我们将训练集和测试集均下采样至逐步粗略的 GSD，以评估模型对空间分辨率退化的鲁棒性。

对于 MS 数据集，Panopticon 的表示在 GSD 范围内保持非常稳定，且表现优于竞争对手。

4.4. 主流传感器的性能表现

我们在 GEO-Bench 的 6 个分类和 6 个分割数据集上对比了现有的固定传感器与任意传感器模型。我们用⑫ BigEarthNet-S2 和⑬ BigEarthNet-S1 替代 reBEN，因为其具有更稳健的划分和更低的标签噪声 [10]。这些基准任务代表了在 S1、S2、Landsat 8、RGB 以及 RGBN 传感器上的广泛真实世界下游任务。我们额外包含了⑪ RESISC45 [8] 作为另一个 RGB 地表覆盖分类任务，以及来自⑭–㉒ GEO-Bench [32] 的另外 9 个任务。结果的简要汇总如 Table 3 所示。完整的 GEO-Bench 表格以及任务描述可在 Section D 中找到。

Panopticon 在大多数任务上表现出最先进的结果，在其余任务上也具有竞争力，表明该模型在流行的开源传感器上也能表现良好。

5. 消融研究

我们对预训练阶段进行了消融实验，遵循 Section 3.5 的配置，但将轮次减少至 30，有效批量大小为 300。为了在比 Section 4 更小的计算预算下评估在 MS、SAR 及非标准传感器上的性能，我们定义了以下指标：i) MS_{acc}：在 m-eurosat 上，包含和不包含 RGB 通道时的平均 k NN 准确率，ii) SAR_{acc}：在 Eurosat-sar [68]

			Avg ↑	MS_{acc} ↑	SAR_{acc} ↑	Sim_{mAP} ↑
Stage 1	Default	fMoW	83.5	92.2	75.8	79.6
	Datasets	MME	81.7	86.4	81.7	80.8
		SP	81.2	84.4	77.5	82.1
		fMoW, MME	78.3	82.0	80.1	79.2
		fMoW, SP, MME, SE	73.9	79.1	74.4	76.8
Stage 2	Default	Fine PE, multi-view	86.8	93.1	82.2	83.4
	PE	None	84.8	91.5	81.2	80.7
		Coarse	85.1	91.0	82.1	80.8
		Fine-std	85.9	91.7	82.9	80.4
	Views	Single	82.2	84.2	78.8	83.0

表 4. Panopticon 主要设计决策的消融实验结果按预训练阶段划分。指标为在多个任务上的平均值(%),反映在 MS、SAR 以及通过通道下采样模拟的非标准传感器上的性能表现。每个阶段的最佳结果以 **粗体**标出。SP = SatlasPretrain, SE = SpectralEarth, MME = MMEarth。

上，k NN 和线性探测的平均准确率，iii) Sim_{mAP}：通过通道下采样从 HS Corine 数据模拟的两个传感器上的平均 mAP，以及 iv) Avg：所有独立任务上的平均值。有关指标的详细信息请见 Section F，更多消融实验详见 Section G。我们的主要发现是，光谱渐进式预训练、相对于主干网络更大的通道注意力维度，以及光谱位置嵌入对于良好性能至关重要。

渐进式预训练 我们对预训练的数据集组成进行了消融实验，如 Table 4所示。可以看出，使用多个数据集进行训练，从而引入更多光谱多样性的输入反而导致了次优的结果。需要注意的是，例如，仅在 MMEarth 上进行训练的表现优于在 fMoW 和 MMEarth 上联合训练的所有指标表现。这促使我们提出了两阶段的预训练方法。如 Table 4所示，第一阶段仅在 fMoW 上进行训练，第二阶段通过在所有数据集上进行训练来增加光谱多样性。尽管可以尝试更多阶段，但我们发现超过这两个阶段并无额外收益。

通道注意力架构 我们在第一阶段的 PE 模块中通道注意力部分，对不同的注意力头数量 n_h 和嵌入维度 D_{attn} 进行了搜索，分别使用两个学习率各训练 15 轮次。结果如 Table 5 所示。特别值得注意的是，使用 $D_{\text{attn}} \geq 1536$ 相比 $D_{\text{attn}} = 768$ 显著提升了性能。而 n_h 的影响则相对较小。需要注意的是，增加 D_{attn} 会显著增加参数数量，如 Table 5 的第二行所示。

D_{attn}		768	1536	2304	3072
# params (in M)		1.9	6.2	12.9	21.9
n_h	12	77.7	82.4	83.9	-
	16	77.8	84.9	85.8	81.5
	24	-	83.8	<u>85.5</u>	84.4
	32	-	-	-	82.1

表 5. 通道注意力架构的消融实验。MS_{acc} 在改变注意力头数 n_h 的行和嵌入维度 D_{attn} 的列时报告的指标。通道注意力模块的参数量以百万为单位显示在第二行。最佳结果用**粗体**表示，次佳结果用<u>下划线</u> 表示。

传感器视图作为增强功能 在生成给定足迹的视图时，Panopticon 从该足迹的所有可用图像中采样一个传感器图像作为增强。在 Table 4 中，我们提出了一种消融实验（'Single'），即从单张图像生成给定足迹的所有视图。这会显著降低性能。

谱嵌入 在 Table 4 中，我们将所提出的对单个波长和 SAR 配置进行编码的嵌入方法（'Fine-PE'）与仅

区分 SAR 和光学通道的粗粒度嵌入（‘Coarse’）、无嵌入（‘None’），以及额外编码光学传感器点扩散函数（SRF）标准差的嵌入方法（‘Fine-std’）进行了对比，详见 Section E。对于光学传感器，细粒度光谱信息显著提升了性能，而增加关于标准差的信息似乎并未带来收益。对于 SAR，粗粒度嵌入可能已足够。然而需要注意的是，下游数据集中的 SAR 数据仅包含单一发射和接收极化（VV+VH），限制了我们对这一结论的验证能力。有关设计决策的更多见解，请参见 Table 7 和 Section D.3。

6. 讨论与结论

本文中，我们提出了 Panopticon，一种灵活的多传感器基础模型，能够处理任意传感器配置的数据，而无需针对特定传感器进行调整。通过将 DINOv2 扩展为支持多传感器视图生成、频谱下采样以及通道间的交叉注意力机制，我们的方法在标准基准测试中取得了当前最优性能，并展现出在不同传感器配置下的优异泛化能力。通过减少空间和光谱信息的测试以及跨传感器泛化实验，我们对模型的传感器无关性进行了严格评估。研究结果表明，Panopticon 在构建真正意义上的传感器无关表示方面，始终优于现有的固定传感器和多传感器模型。在超出典型训练分布的数据集上的测试显示，大多数模型能够适应新型传感器模态，尽管成功率各不相同。值得注意的是，经过适当领域自适应技术调整后的 DINOv2，在 RGB 应用及部分多光谱（MS）场景中，表现出出乎意料的强大基准性能。

我们在 23 项不同任务上的评估代表了在验证多传感器能力方面的重要进展，尽管仍存在一些局限性。我们未探索时间不变性或等变性——这是未来研究的一个关键方向——也未充分研究引入通道带宽信息以及使用谱卷积作为增强策略。此外，由于缺乏利用多种合成孔径雷达（SAR）通道组合的评估任务，限制了我们全面测试模型 SAR 泛化能力的能力。

尽管潘多拉克罗普模型显式地模拟了通道级传感器特性，但它依赖于视角增强来学习与采集时间、处理层级以及地面采样距离相关的其他重要地球观测不变性。虽然我们特别测试并验证了后一类不变性，但其他属性在分离和评估方面证明具有挑战性。我们的结果表明，将显式的光谱建模与多样化的增强策略相结合，为实现真正传感器无关的地球观测提供了一条有前景的路径。

鲁棒的任意传感器模型的发展受到来自多样化卫星平台的机器学习就绪数据稀缺性的制约，这阻碍了公平的行星监测 [54]。随着遥感平台的不断增多，能够跨传感器配置进行泛化的框架（如 Panopticon）将越来越有价值，有助于最大化科学与社会效益。未来的工作应纳入更多特定于传感器的归纳偏置，扩展时间建模能力，并建立全面的跨传感器评估基准。

致谢

本材料基于美国国家科学基金会资助号为 DGE-2125913 的项目支持。作者感谢卡尔斯鲁厄理工学院（KIT）国家高性能计算中心（NHR@KIT）提供的高性能计算机 HoreKa 的计算时间。该中心由德国联邦教育与研究部以及巴登-符腾堡州科学、研究与艺术部共同资助，作为国家高性能计算（NHR）联合资助计划的一部分。[1]. HoreKa 部分由德国研究基金会（DFG）资助。作者还感谢 Joshua Blumenstock 教授以及伯克利高性能计算（Savio）部门提供的计算基础设施。

参考文献

[1] Guillaume Astruc, Nicolas Gonthier, Clement Mallet, and Loic Landrieu. AnySat: An Earth observation model for any resolutions, scales, and modalities. arXiv preprint arXiv:2412.14123, 2024.

[2] Yujia Bao, Srinivasan Sivanandan, and Theofanis Karaletsos. Channel vision transformers: An image is worth c x 16 x 16 words. arXiv preprint arXiv:2309.16108, 2023.

[3] Favyen Bastani, Piper Wolters, Ritwik Gupta, Joe Ferdinando, and Aniruddha Kembhavi. Satlaspretrain: A large-scale dataset for remote sensing image understanding. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 16772–16782, 2023.

[4] Jeremy Bentham. Panopticon or the inspection house. Bentham, Jeremy, 1791.

[5] Nassim Ait Ali Braham, Conrad M Albrecht, Julien Mairal, Jocelyn Chanussot, Yi Wang, and Xiao Xiang Zhu. Spectralearth: Training hyperspectral foundation models at scale. arXiv preprint arXiv:2408.08447, 2024.

[6] Olivier Burggraaff. Biases from incorrect reflectance convolution. Optics express, 28(9):13801–13816, 2020.

[7] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging Properties in Self-Supervised Vision Transformers, 2021. arXiv:2104.14294 [cs].

[8] Gong Cheng, Junwei Han, and Xiaoqiang Lu. Remote sensing image scene classification: Benchmark and state of the art. Proceedings of the IEEE, 105 (10):1865–1883, 2017.

[9] Gordon Christie, Neil Fendley, James Wilson, and Ryan Mukherjee. Functional map of the world. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 6172–6180, 2018.

[10] Kai Norman Clasen, Leonard Hackel, Tom Burgert, Gencer Sumbul, Begüm Demir, and Volker Markl. reben: Refined bigearthnet dataset for remote sensing image analysis. arXiv preprint arXiv:2407.03653, 2024.

[11] Shane R Cloude and Eric Pottier. A review of target decomposition theorems in radar polarimetry. IEEE transactions on geoscience and remote sensing, 34(2): 498–518, 1996.

[12] Yezhen Cong, Samar Khanna, Chenlin Meng, Patrick Liu, Erik Rozi, Yutong He, Marshall Burke, David B. Lobell, and Stefano Ermon. SatMAE: Pre-training transformers for temporal and multi-spectral satellite imagery. In Advances in Neural Information Processing Systems, 2022.

[13] MMSegmentation Contributors. MMSegmentation: Openmmlab semantic segmentation toolbox and benchmark. https://github.com/open-mmlab/mmsegmentation, 2020.

[14] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale, 2021.

[15] Van Etten. Spacenet: A remote sensing dataset and challenge series. (No Title), 2018.

[16] Michel Foucault. Panopticism. In The information society reader, pages 302–312. Routledge, 2020.

[17] Anthony Fuller, Koreen Millard, and James Green. Croma: Remote sensing representations with contrastive radar-optical masked autoencoders. Advances in Neural Information Processing Systems, 36:5506–5538, 2023.

[18] Priya Goyal, Piotr Dollár, Ross Girshick, Pieter Noordhuis, Lukasz Wesolowski, Aapo Kyrola, Andrew Tulloch, Yangqing Jia, and Kaiming He. Accurate, large minibatch sgd: Training imagenet in 1 hour, 2018.

[1] https://www.nhr-verein.de/en/our-partners

[19] Luis Guanter, Hermann Kaufmann, Karl Segl, Saskia Foerster, Christian Rogass, Sabine Chabrillat, Theres Kuester, André Hollstein, Godela Rossner, Christian Chlebek, et al. The enmap spaceborne imaging spectroscopy mission for earth observation. Remote Sensing, 7(7):8830–8857, 2015.

[20] David Ha, Andrew Dai, and Quoc V. Le. Hypernetworks, 2016.

[21] Boran Han, Shuai Zhang, Xingjian Shi, and Markus Reichstein. Bridging remote sensors with multisensor geospatial foundation models. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 27852–27862, 2024.

[22] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners, 2021.

[23] Patrick Helber, Benjamin Bischke, Andreas Dengel, and Damian Borth. Eurosat: A novel dataset and deep learning benchmark for land use and land cover classification. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 12(7): 2217–2226, 2019.

[24] Chia-Yu Hsu, Wenwen Li, and Sizhe Wang. Geospatial foundation models for image analysis: Evaluating and enhancing nasa-ibm prithvi' s domain adaptability. International Journal of Geographical Information Science, pages 1–30, 2024.

[25] Jeremy Irvin, Lucas Tao, Joanne Zhou, Yuntao Ma, Langston Nashold, Benjamin Liu, and Andrew Y Ng. Usat: A unified self-supervised encoder for multi-sensor satellite imagery. arXiv preprint arXiv:2312.02199, 2023.

[26] Johannes Jakubik, Sujit Roy, CE Phillips, Paolo Fraccaro, Denys Godwin, Bianca Zadrozny, Daniela Szwarcman, Carlos Gomes, Gabby Nyirjesy, Blair Edwards, et al. Foundation models for generalist geospatial artificial intelligence. arXiv preprint arXiv:2310.18660, 2023.

[27] Johannes Jakubik, Sujit Roy, C. E. Phillips, Paolo Fraccaro, Denys Godwin, Bianca Zadrozny, Daniela Szwarcman, Carlos Gomes, Gabby Nyirjesy, Blair Edwards, Daiki Kimura, Naomi Simumba, Linsong Chu, S. Karthik Mukkavilli, Devyani Lambhate, Kamal Das, Ranjini Bangalore, Dario Oliveira, Michal Muszynski, Kumar Ankur, Muthukumaran Ramasubramanian, Iksha Gurung, Sam Khallaghi, Hanxi, Li, Michael Cecil, Maryam Ahmadi, Fatemeh Kordi, Hamed Alemohammad, Manil Maskey, Raghu Ganti, Kommy Weldemariam, and Rahul Ramachandran. Foundation Models for Generalist Geospatial Artificial Intelligence, 2023. arXiv:2310.18660 [cs].

[28] Hannah Kerner, Snehal Chaudhari, Aninda Ghosh, Caleb Robinson, Adeel Ahmad, Eddie Choi, Nathan Jacobs, Chris Holmes, Matthias Mohr, Rahul Dodhia, et al. Fields of the World: A machine learning benchmark dataset for global agricultural field boundary segmentation. arXiv preprint arXiv:2409.16252, 2024.

[29] Ethan King, Jaime Rodriguez, Diego Llanes, Timothy Doster, Tegan Emerson, and James Koch. Stars: Sensor-agnostic transformer architecture for remote sensing. arXiv preprint arXiv:2411.05714, 2024.

[30] Asanobu Kitamoto, Jared Hwang, Bastien Vuillod, Lucas Gautier, Yingtao Tian, and Tarin Clanuwat. Digital typhoon: Long-term satellite image dataset for the spatio-temporal modeling of tropical cyclones. Advances in Neural Information Processing Systems, 36: 40623–40636, 2023.

[31] Rıdvan Salih Kuzu, Frauke Albrecht, Caroline Arnold, Roshni Kamath, and Kai Konen. Predicting soil properties from hyperspectral satellite images. In 2022 IEEE International Conference on Image Processing (ICIP), pages 4296–4300, 2022.

[32] Alexandre Lacoste, Nils Lehmann, Pau Rodriguez, Evan Sherwin, Hannah Kerner, Björn Lütjens, Jeremy Irvin, David Dao, Hamed Alemohammad, Alexandre Drouin, et al. Geo-bench: Toward foundation models for earth monitoring. Advances in Neural Information Processing Systems, 36, 2024.

[33] Jihyeon Lee, Nina R Brooks, Fahim Tajwar, Marshall Burke, Stefano Ermon, David B Lobell, Debashish Biswas, and Stephen P Luby. Scalable deep learning to identify brick kilns and aid regulatory capacity. Proceedings of the National Academy of Sciences, 118 (17):e2018863118, 2021.

[34] Xuyang Li, Danfeng Hong, and Jocelyn Chanussot. S2mae: A spatial-spectral pretraining foundation model for spectral remote sensing data. In Proceedings

of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 24088–24097, 2024.

[35] Xuyang Li, Danfeng Hong, and Jocelyn Chanussot. S2MAE: A spatial-spectral pretraining foundation model for spectral remote sensing data. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 24088–24097, 2024.

[36] Lei Ma, Yu Liu, Xueliang Zhang, Yuanxin Ye, Gaofei Yin, and Brian Alan Johnson. Deep learning in remote sensing applications: A meta-analysis and review. ISPRS journal of photogrammetry and remote sensing, 152:166–177, 2019.

[37] Sahel Mahdavi, Meisam Amani, and Yasser Maghsoudi. The effects of orbit type on synthetic aperture radar (sar) backscatter. Remote sensing letters, 10(2): 120–128, 2019.

[38] Utkarsh Mall, Bharath Hariharan, and Kavita Bala. Change-Aware Sampling and Contrastive Learning for Satellite Images. In 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 5261–5270, Vancouver, BC, Canada, 2023. IEEE.

[39] Manil Maskey, Rahul Ramachandran, Iksha Gurung, Brian Freitag, Muthukumaran Ramasubramanian, and Jeffrey Miller. Tropical cyclone wind estimation competition dataset. Version 1.0, Radiant MLHub, 2022.

[40] Oscar Mañas, Alexandre Lacoste, Xavier Giro-i Nieto, David Vazquez, and Pau Rodriguez. Seasonal Contrast: Unsupervised Pre-Training from Uncurated Remote Sensing Data, 2021. arXiv:2103.16607 [cs].

[41] Matías Mendieta, Boran Han, Xingjian Shi, Yi Zhu, and Chen Chen. Towards geospatial foundation models via continual pretraining. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 16806–16816, 2023.

[42] Vishal Nedungadi, Ankit Kariryaa, Stefan Oehmcke, Serge Belongie, Christian Igel, and Nico Lang. Mmearth: Exploring multi-modal pretext tasks for geospatial representation learning. arXiv preprint arXiv:2405.02771, 2024.

[43] Tung Nguyen, Johannes Brandstetter, Ashish Kapoor, Jayesh K Gupta, and Aditya Grover. Climax: A foundation model for weather and climate. arXiv preprint arXiv:2301.10343, 2023.

[44] Nicki Skafte Detlefsen, Jiri Borovec, Justus Schock, Ananya Harsh, Teddy Koker, Luca Di Liello, Daniel Stancl, Changsheng Quan, Maxim Grechkin, and William Falcon. TorchMetrics - Measuring Reproducibility in PyTorch, 2022.

[45] Mubashir Noman, Muzammal Naseer, Hisham Cholakkal, Rao Muhammad Anwer, Salman Khan, and Fahad Shahbaz Khan. Rethinking transformers pre-training for multi-spectral satellite imagery. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 27811–27819, 2024.

[46] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. Dinov2: Learning robust visual features without supervision. arXiv preprint arXiv:2304.07193, 2023.

[47] Fernando Paolo, Tsu-ting Tim Lin, Ritwik Gupta, Bryce Goodman, Nirav Patel, Daniel Kuster, David Kroodsma, and Jared Dunnmon. xView3-SAR: Detecting dark fishing activity using synthetic aperture radar imagery. Advances in Neural Information Processing Systems, 35:37604–37616, 2022.

[48] Planet Labs PBC. Understanding planetscope instruments, 2025. https://developers.planet.com/docs/apis/data/sensors/.

[49] Jonathan Prexl and Michael Schmitt. Multi-Modal Multi-Objective Contrastive Learning for Sentinel-1/2 Imagery. In 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Vancouver, BC, Canada, 2023. IEEE.

[50] Jonathan Prexl and Michael Schmitt. Senpa-mae: Sensor parameter aware masked autoencoder for multi-satellite self-supervised pretraining. arXiv preprint arXiv:2408.11000, 2024.

[51] Colorado J Reed, Ritwik Gupta, Shufan Li, Sarah Brockman, Christopher Funk, Brian Clipp, Kurt Keutzer, Salvatore Candido, Matt Uyttendaele, and Trevor Darrell. Scale-mae: A scale-aware masked autoencoder for multiscale geospatial representation learning. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 4088–4099, 2023.

[52] Felix Rembold, Clement Atzberger, Igor Savin, and

Oscar Rojas. Using low resolution satellite imagery for yield prediction and yield anomaly detection. Remote Sensing, 5(4):1704–1733, 2013.

[53] Esther Rolf, Konstantin Klemmer, Caleb Robinson, and Hannah Kerner. Mission critical–satellite data is a distinct modality in machine learning. arXiv preprint arXiv:2402.01444, 2024.

[54] Philippe Rufin, Patrick Meyfroidt, Felicia O Akinyemi, Lyndon Estes, Esther Shupel Ibrahim, Meha Jain, Hannah Kerner, Sá Nogueira Lisboa, David Lobell, Catherine Nakalembe, et al. To enhance sustainable development goal research, open up commercial satellite image archives. Proceedings of the National Academy of Sciences, 122(7):e2410246122, 2025.

[55] A Savtchenko, D Ouzounov, S Ahmad, J Acker, G Leptoukh, J Koziana, and D Nickless. Terra and aqua modis products available from nasa ges daac. Advances in Space Research, 34(4):710–714, 2004.

[56] Adam Stewart, Nils Lehmann, Isaac Corley, Yi Wang, Yi-Chia Chang, Nassim Ait Ali Braham, Shradha Sehgal, Caleb Robinson, and Arindam Banerjee. SSL4EO-L: Datasets and foundation models for Landsat imagery. Advances in Neural Information Processing Systems, 36:59787–59807, 2023.

[57] Adam J Stewart, Caleb Robinson, Isaac A Corley, Anthony Ortiz, Juan M Lavista Ferres, and Arindam Banerjee. TorchGeo: deep learning with geospatial data. In Proceedings of the 30th international conference on advances in geographic information systems, pages 1–12, 2022.

[58] Merugu Suresh and Kamal Jain. Change detection and estimation of illegal mining using satellite images. In Proceedings of 2nd International conference of Innovation in Electronics and communication Engineering (ICIECE-2013), 2013.

[59] G Tseng, R Cartuyvels, I Zvonkov, M Purohit, D Rolnick, and H Kerner. Lightweight, pre-trained transformers for remote sensing timeseries. arxiv. arXiv preprint arXiv:2304.14065, 2023.

[60] Gabriel Tseng, Anthony Fuller, Marlena Reil, Henry Herzog, Patrick Beukema, Favyen Bastani, James R Green, Evan Shelhamer, Hannah Kerner, and David Rolnick. Galileo: Learning global and local features in pretrained remote sensing models. arXiv preprint arXiv:2502.09356, 2025.

[61] Arsenios Tsokas, Maciej Rysz, Panos M Pardalos, and Kathleen Dipple. Sar data applications in earth observation: An overview. Expert Systems with Applications, 205:117342, 2022.

[62] Yu-Hsuan Tu, Kasper Johansen, Bruno Aragon, Marcel M El Hajj, and Matthew F McCabe. The radiometric accuracy of the 8-band multi-spectral surface reflectance from the planet superdove constellation. International Journal of Applied Earth Observation and Geoinformation, 114:103035, 2022.

[63] Fawwaz T Ulaby, Daniel Held, Myron C Donson, Kyle C McDonald, and Thomas BA Senior. Relating polaization phase difference of sar signals to scene properties. IEEE Transactions on Geoscience and Remote Sensing, GE-25(1):83–92, 1987.

[64] Susan L Ustin and Elizabeth M Middleton. Current and near-term advances in earth observation for ecological applications. Ecological Processes, 10(1):1, 2021.

[65] A Vaswani. Attention is all you need. Advances in Neural Information Processing Systems, 2017.

[66] Yi Wang, Conrad M. Albrecht, and Xiao Xiang Zhu. Self-supervised Vision Transformers for Joint SAR-optical Representation Learning, 2022. arXiv:2204.05381 [cs].

[67] Yi Wang, Nassim Ait Ali Braham, Zhitong Xiong, Chenying Liu, Conrad M Albrecht, and Xiao Xiang Zhu. SSL4EO-S12: A large-scale multimodal, multitemporal dataset for self-supervised learning in Earth observation. IEEE Geoscience and Remote Sensing Magazine, 11(3):98–106, 2023.

[68] Yi Wang, Hugo Hernández Hernández, Conrad M Albrecht, and Xiao Xiang Zhu. Feature guided masked autoencoder for self-supervised learning in remote sensing. arXiv preprint arXiv:2310.18653, 2023.

[69] Yi Wang, Conrad M. Albrecht, Nassim Ait Ali Braham, Chenying Liu, Zhitong Xiong, and Xiao Xiang Zhu. Decoupling Common and Unique Representations for Multimodal Self-supervised Learning, 2024. arXiv:2309.05300 [cs].

[70] Yi Wang, Conrad M Albrecht, and Xiao Xiang Zhu. Multi-label guided soft contrastive learning for efficient earth observation pretraining. arXiv preprint arXiv:2405.20462, 2024.

[71] Yi Wang, Zhitong Xiong, Chenying Liu, Adam J. Stewart, Thomas Dujardin, Nikolaos Ioannis Bountos, Angelos Zavras, Franziska Gerken, Ioannis Papoutsis, Laura Leal-Taixé, and Xiao Xiang Zhu. Towards a unified copernicus foundation model for earth vision, 2025.

[72] Xinye Wanyan, Sachith Seneviratne, Shuchang Shen, and Michael Kirley. Dino-mc: Self-supervised contrastive learning for remote sensing imagery with multi-sized local crops. arXiv preprint arXiv:2303.06670, 2023.

[73] Xinye Wanyan, Sachith Seneviratne, Shuchang Shen, and Michael Kirley. Extending global-local view alignment for self-supervised learning with remote sensing imagery, 2024. arXiv:2303.06670 [cs].

[74] Zhitong Xiong, Yi Wang, Fahong Zhang, Adam J Stewart, Joëlle Hanna, Damian Borth, Ioannis Papoutsis, Bertrand Le Saux, Gustau Camps-Valls, and Xiao Xiang Zhu. Neural plasticity-inspired foundation model for observing the earth crossing modalities. arXiv preprint arXiv:2403.15356, 2024.

[75] Zhitong Xiong, Yi Wang, Fahong Zhang, and Xiao Xiang Zhu. One for all: Toward unified foundation models for Earth vision. In IGARSS 2024-2024 IEEE International Geoscience and Remote Sensing Symposium, pages 2734–2738. IEEE, 2024.

[76] Lixian Zhang, Yi Zhao, Runmin Dong, Jinxiao Zhang, Shuai Yuan, Shilei Cao, Mengxuan Chen, Juepeng Zheng, Weijia Li, Wei Liu, Wayne Zhang, Litong Feng, and Haohuan Fu. A^{2}-MAE: A spatial-temporal-spectral unified remote sensing pre-training method based on anchor-aware masked autoencoder, 2024. arXiv:2406.08079 [cs] version: 2.

[77] Jinghao Zhou, Chen Wei, Huiyu Wang, Wei Shen, Cihang Xie, Alan Yuille, and Tao Kong. iBOT: Image BERT Pre-Training with Online Tokenizer, 2022. arXiv:2111.07832 [cs].

全景监狱：推动面向地球观测的多传感器基础模型发展

Supplementary Material

A. 为什么叫“全景监狱”？

全景监狱的概念最早由哲学家杰里米 · 边沁 [4] 提出，作为一种理想的监狱设计模型，其中一个人可以监视整个监狱。米歇尔 · 福柯后来将其重新阐释为现代社会中压制性权力、控制和监视系统的强大隐喻 [16]，而随着数字监控技术的普及，这种隐喻或许在今天更加相关。

我们深知这一术语所承载的历史负担和争议性内涵；那么为何仍选择使用它？我们希望重新诠释这一术语，扭转其原有含义，将其作为比喻，指代那些能够以警觉而仁慈的视角关注地球的系统。与其监视人类，不如让“全景监狱”（Panopticon）观察地球本身——其不断变化的地貌、生态系统以及气候模式。

我们的模型之美在于，与原始全景敞视概念一样，它能够从单一观察点实现全面的可视性。但不同于边沁的监狱设计，我们的目标并非控制与恐惧，而是理解与监测。在技术层面，我们也发现一个恰如其分的类比：原始的全景敞视建筑旨在从中心位置观察一切，无论注意力指向何处。同样，我们的模型可以“观察”任何传感器配置，而无需进行特定调整——一种不依赖传感器的视觉能力，映射了概念上全景敞视的全知特性，但被重新用于造福地球。

B. 代码和数据可用性

所有数据加载器和模型代码将贡献至 TorchGeo 库 [57]，以确保可复现性并便于未来的实验。

C. 数据集

C.1. 预训练数据集

我们按照地理覆盖范围将四个预训练数据集组织如正文表 1 所示，其中“覆盖范围”定义为具有确切地理参考匹配的图像。在预训练过程中，从每个覆盖范围内随机抽取若干个“快照”，如图 1 所示。

fMoW　fMoW [9] 由 4 个 MS 卫星传感器的数据组成，QuickBird-1 和 GeoEye-2 具有 4 个通道（RGB，NIR），

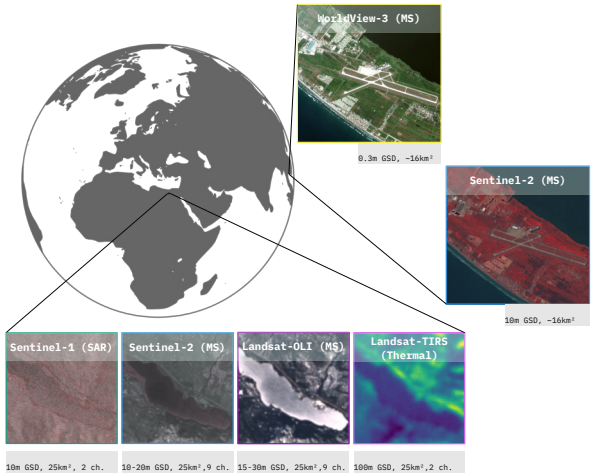

Supp. Fig. 1. 快照：来自不同观测足迹的示例快照。我们的预训练数据集包含从地球表面获取的多种传感器模态、通道、地面分辨率（GSD）、尺度和时间步的数据。不同的通道、地面分辨率（GSD）和观测足迹大小可提供关于地理空间对象不同属性的信息。注意：部分图像以伪彩色显示，以便于将非可见光谱信息映射到图像中。

而 WorldView-2 和 -3 具有 8 个通道，地面采样距离（GSD）通常在 1–2 m 之间。此外，该数据集还包括相同图像的全色锐化版本（RGB），其 GSD <1 m。选择该数据集的原因是其具有全球空间覆盖和广泛的光谱覆盖。[2] 同时具有非常低的地面采样距离（GSD）值以及对人类改造地表类型广泛的函数覆盖。此外，该数据集在成像时间、偏离天底角方面也表现出较大的方差，这两者都会影响目标的光照条件。由于所有图像都具备空间足迹信息，我们生成了该数据集的地理索引版本，将与其余代码一同发布。另外，我们移除了大于 1024 像素的图像，这些图像通常是全色锐化后的 RGB 图像，以降低内存开销。

fMoW-Sentinel　fMoW-Sentinel [12] 是为了创建一个与 fMoW 捕捉位置完全相同的副本，但使用的是哨兵-2 遥感影像。我们通过基于影像覆盖范围和传感器类型

[2] 包括“非标准”波段，即光谱覆盖范围超出 Landsat 和 Sentinel 系列等主流开源数据源的波段。

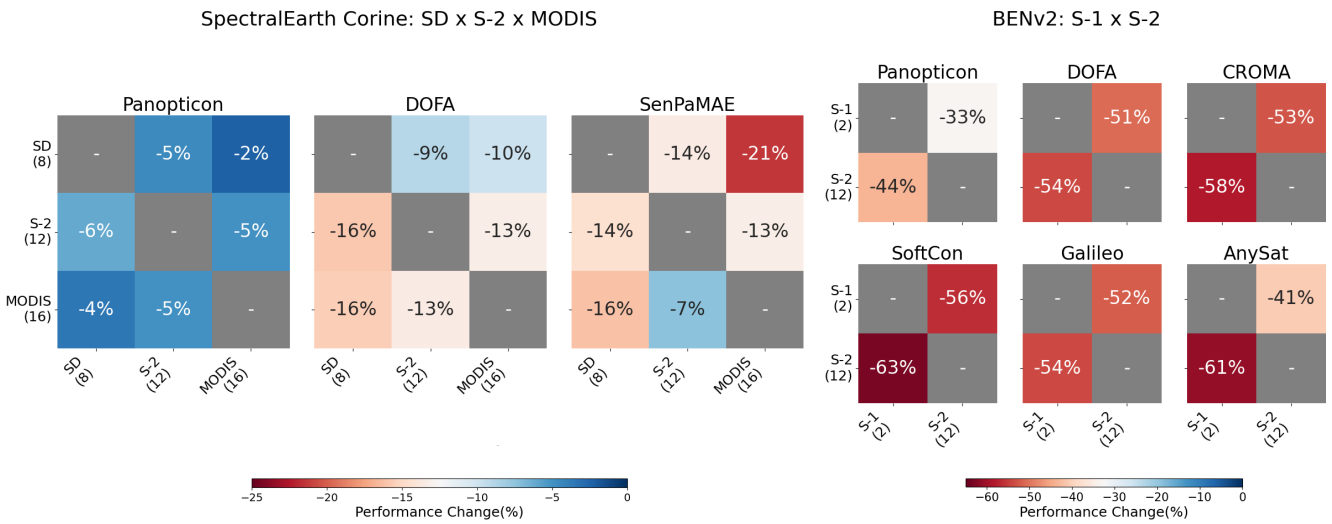

Supp. Fig. 2. 跨传感器不变性。除了训练/验证/测试集划分外，我们还按传感器对数据集进行划分，以明确测试传感器不变性。热图中的 y 轴表示训练传感器，x 轴表示测试传感器。对角线表示训练与测试使用相同传感器的情况，被灰化处理；非对角线元素表示跨传感器结果，其数值以相对于对角线的百分比差异表示。这使得能够可视化跨传感器性能相对于同传感器性能的变化情况，以（负）百分数形式表达。**左图**：针对任意传感器模型，划分基于通过光谱卷积从 HS EnMAP 传感器合成的传感器（MODIS、Sentinel-2 和 Planet SuperDove）。**右图**：reBEN；划分在 Sentinel-1 与 Sentinel-2 传感器之间实施，适用于所有任意传感器和多数传感器模型，但 SenPaMAE 无法处理 SAR 图像。Panopticon 在所有任意传感器模型中表现始终更优。注意两个子图的值域不同。

对 fMoW 与 fMoW-Sentinel 进行索引，构建了一个综合数据集。这两个数据集共同涵盖了 2002 年至 2022 年间五个不同传感器平台的地表特性，为同一覆盖范围提供了丰富的自然变化。最后，每幅影像的覆盖范围差异极大，从 0.2 到 25 km^2，在不同尺度上提供了广泛的特征。该综合数据集包含 89,666 个唯一的覆盖范围，每个覆盖范围在这些传感器之间可对应数十幅影像。

MMEarth　多模态地球（MMEarth）[42] 作为包含多种模态的配对数据集发布，这些模态包括哨兵-1 SAR、哨兵-2 MS、高程及其他配对模态。最重要的是，哨兵-2 数据包含了多个处理级别（L1C 和 L2A），而哨兵-1 数据则涵盖了全部 4 种极化组合（VV、VH、HH、HV）以及两种轨道类型（上升轨、下降轨）。该数据集主要旨在模拟 SAR 数据的极化与轨道效应以及光学数据的处理级别影响。此外，这一大规模数据集包含 1,239,937 个独特的足迹，按土地覆盖类型均衡分布，每个足迹均提供一对 S1 和 S2 图像。

光谱地球　SpectralEarth [5] 是撰写本文时可用的最大的开源高光谱数据集，包含由 EnMAP 卫星 [19] 全球采样的 45 万张样本，由德国航空航天中心（DLR）提供。该数据集还提供了四个下游基准任务，使用来自同一传感器的数据，但采用不重叠的样本，与预训练数据分离。选择该数据集是因为其丰富的光谱多样性，使模型能够学习高光谱特性并模拟任意多光谱波段。SpectralEarth 提供了 41.5 万个唯一的地面足迹，每个足迹提供一张包含 202 个波段的单个高光谱图像。

SatlasPretrain　SatlasPretrain 包含来自 Sentinel-1、Sentinel-2、Landsat-9 以及 NAIP 传感器的 30 TB 影像数据。我们仅使用前三个传感器的数据，因为 NAIP 的地理覆盖范围仅限于美国，且其光谱波段仅包含 RGB 和 NIR。我们创建了一个统一索引的数据集，包含 768,800 个唯一的影像足迹，每个足迹可包含 2022 年内获取的最多 3 个传感器影像。该数据集也是目前唯一包含 Landsat 9-TIRS 传感器热红外影像的大规模预训练数据集。

C.2. 评估数据集

我们使用以下基准任务和数据集。在可能的情况下，我们使用了现有的 Python 库，如 TorchGeo [57] 和 GEO-Bench [32]。有关完整数据集列表，请参阅 Tab. 6。大多数数据集均使用 TorchGeo 库 [57] 实现，当可用时。

以下是我们对标准数据集所做修改的概述：

SpaceNet　我们使用 TorchGeo 提供的 SpaceNet 1 数据集，该数据集是针对里约热内卢城市区域的建筑物轮廓分割任务，包含由 WorldView 2 获取的 8 波段多光谱图像和 3 波段融合锐化 RGB 图像。我们仅使用 8 波段图像。由于原始数据集仅提供训练集的标签，我们将其随机划分为训练集、验证集和测试集，比例为 80:10:10。

D. 附加结果

D.1. 传感器不变性

我们显式测试模型在不同传感器输入下生成稳定表示的能力。为此，我们在具有配对传感器的数据集中引入额外的分割维度，按传感器进行划分。我们使用 ⑩ EnMAP-Corine [5] 数据集，采用光谱卷积模拟 MODIS、Sentinel-2 和 Planet SuperDove 传感器（Fig. 2(left)），以及 ⑫ reBEN [10] 数据集，该数据集包含来自 Sentinel-1 和 Sentinel-2 的配对影像（补充材料 Fig. 2(right)）。模型在数据集的训练划分上仅使用单一传感器进行训练，而在验证和测试时则使用不同传感器的数据，对应于数据集的相应划分。随后，我们将结果与同传感器设置下的相对差异绘制成非对角线单元格中的值。这使我们能够验证在相同数据集和预测目标下，由一个传感器生成的表示与由另一个传感器生成的表示之间的接近程度。理想情况下，非对角线单元格的值应接近 0%，即与同传感器设置相似。以 Corine 数据集为例，Panopticon 在此表现良好（Fig. 2(left)），而其他任意传感器模型难以泛化，尤其是在使用较少波段（SD，8 波段）训练并测试于更多波段的传感器（MODIS，16 波段）时表现更差。在 Fig. 2(right) 中，这种现象较不明显，因为从光学到 SAR 再反向的领域偏移非常强烈。然而，即使在此情景下，Panopticon 在平均上仍比所有任意传感器模型和多数多传感器模型分别高出 18% 和 14%，分别对应 S1→ S2 与 S2→ S1 设置。

这些实验的绝对值以及在 fMoW 数据集上根据三个包含传感器划分的额外结果，可见附录 Fig. 3。

D.2. Geo-Bench

我们在 Table 10 中报告了 Geo-Bench 分类数据集的完整结果，在 Table 11、Table 12 和 Table 13 中报告了分割数据集的不同指标结果。

D.3. 个人设计决策的影响

我们评估了 Table 7 中各项设计决策的贡献。我们发现谱渐进预训练和样本传感器增强是影响最大的设计决策。有趣的是，移除 DINOv2 权重并从零开始训练，仅导致 Avg 指标下降 6.1 个百分点。

E. 利用完整的光谱信息

在任意传感器模型领域，DOFA [74] 使用超网络和 SRF 的均值来学习每通道的光谱编码，而 SenPaMAE [50] 则利用了完整的 SRF。我们还尝试了以下机制，以结合每通道的 SRF 和/或带宽信息，除了平均波长之外。

频谱积分位置编码　为了实现传感器无关性，我们引入了一种新颖的光谱集成位置编码（sIPE），该方法利用已知的传感器特性。基于 Nguyen et al. [43] 中提出的通道注意力机制，我们将每个传感器的 SRF 建模为一个未归一化的高斯核，其由均值 μ 和标准差 σ 定义。这一思路源于观察到，这种高斯核能够相对较好地拟合诸如 Sentinel-2A 和 Landsat-9 OLI 传感器的 SRF，如 Fig. 4 所示。我们还尝试了 Epanechkinov 核拟合，其提供了更好的 R^2 结果，但由于高斯核具有良好的理论基础且存在闭式解，因此更易于处理。

因此，我们采用高斯拟合的参数 $\{\mu, \sigma\}$ 来建模某一通道的 SRF。随后，我们将绝对位置嵌入 [65] 扩展为通过与正弦基函数积分的方式融入光谱信息。

$$\begin{aligned} \mathrm{PE}_{\mathrm{spectral}}(\mu, \sigma, 2i) &= \int e^{-\frac{(\mu-\lambda)^2}{2\sigma^2}} \cdot \sin(\omega_i \lambda) \cdot \mathrm{d}\lambda, \\ \mathrm{PE}_{\mathrm{spectral}}(\mu, \sigma, 2i+1) &= \int e^{-\frac{(\mu-\lambda)^2}{2\sigma^2}} \cdot \cos(\omega_i \lambda) \cdot \mathrm{d}\lambda, \end{aligned} \tag{3}$$

其中 $\omega = \frac{1}{10000^{\frac{2i}{D}}}$ 和 $i \in (0, D]$。

Index	Name	Name used in this paper	Modifications
1	Corine [SuperDove]		Spectral convolution from EnMap to Planet Superdove
2	Corine [MODIS]		Spectral convolution from EnMap to MODIS
3	Hyperview [SuperDove]		Spectral convolution from Intuition to SuperDove
4	Hyperview [MODIS]		Spectral convolution from Intuition to MODIS
5	TropicalCyclone	TC	TorchGeo, we use 10% of train
6	DigitalTyphoon	DT	TorchGeo, we use 10% of train
7	SpaceNet 1	SpaceNet 1	Randomly split the train set into train, val, and test (80:10:10)
8	EuroSAT	m-eurosat	GEO-Bench
9	BrickKiln	m-brick-kiln	GEO-Bench
10	EnMAP-Corine	Corine	Original 202 band dataset
11	RESISC45	RESISC	GEO-Bench
12	reBEN-S2		
13	reBEN-S1		
14	ForestNet	m-forestnet	GEO-Bench
15	So2Sat	m-so2sat	GEO-Bench
16	PV4Ger (cls.)	m-pv4ger	GEO-Bench
17	PV4Ger (segm.)	m-pv4ger-seg	GEO-Bench
18	Cheasapeake Landcover	m-chesapeake-landcover	GEO-Bench
19	Cashew Plantation	m-cashew-plantation	GEO-Bench
20	SA Crop Type	m-SA-crop-type	GEO-Bench
21	NZ Cattle	m-nz-cattle	GEO-Bench
22	NEON Tree	m-NeonTree	GEO-Bench
23	fMoW		Subset to WV2+WV3 sensors

表 6. 所有评估数据集的总结及对其所做的修改。

Individual contributions	Avg ↑	
Panopticon	83.5	
– Spectral Progr. Pre-Training	72.2	−11.3
– Sample sensor augm.	73.2	−10.3
– Chn. attn.	76.7	−6.8
– DINOv2 weights	77.4	−6.1
– D_{attn} to 2304	79.9	−3.6
– Spectral cropping	81.3	−2.2

表 7. 个体设计选择的影响。我们采用 Panopticon，移除个体设计选择，观察平均指标的性能下降情况。Progr.= 渐进式，augm.= 增强，Chn. attn.= 通道注意力

我们推导出 Eq. (3) 的闭式解如下：

$$\begin{aligned} \mathrm{PE}_{\text{spectral}}(\mu,\sigma,2i) &= \sigma\sqrt{2\pi}\cdot e^{-\frac{\omega_i^2\sigma^2}{2}}\cdot\sin(\omega_i\mu), \\ \mathrm{PE}_{\text{spectral}}(\mu,\sigma,2i) &= \sigma\sqrt{2\pi}\cdot e^{-\frac{\omega_i^2\sigma^2}{2}}\cdot\cos(\omega_i\mu). \end{aligned} \tag{4}$$

Eq. (4) 使我们能够高效地生成谱特征嵌入（spectral PEs），并将它们添加到通道 token 中。我们的假设是，尽管查询学习如何在不同通道间最优融合谱特征 token，但它只能基于这些图像块中提取的低层特征来实现这一目标。将 sIPE 添加到图像块 token 中，为每个 token 相对于其中心波长和带宽提供了谱归纳偏置，从而有效地将图像块 token 与其物理捕获属性对齐。

光谱卷积 受 King et al. [29] 启发，我们采用谱卷积 [6] 作为高光谱（HS）输入的谱增强方法。给定一个由 i 通道组成的源高光谱图像 $x^s(\lambda)$ 及其谱响应函数 SRF_s，谱卷积 R 定义为 x^s 与 SRF_s 乘积的积分，再除以其谱响应函数（SRF）的积分。

为了生成具有未知 SRF 的任意多光谱（MS）通道，我们将它们的 SRF SRF_t 建模为均值波长为 λ_t、标准差为 σ_t 的非规范化高斯核。

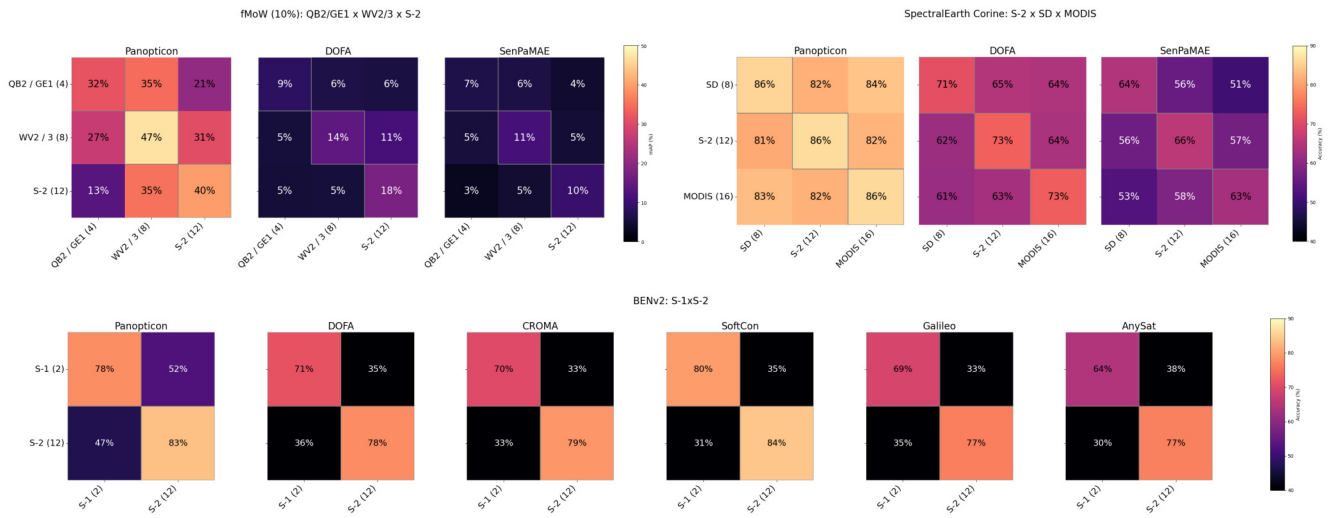

Supp. Fig. 3. 跨传感器不变性（绝对值）。除了训练/验证/测试集划分外，我们还按传感器对数据集进行划分，以显式测试传感器不变性。热图中的 y 轴表示训练传感器，x 轴表示测试传感器。对角线表示训练与测试使用相同传感器的情况，而非对角线元素表示跨传感器结果，所有数值均以百分比形式表示绝对性能值。**左侧**：划分基于 QuickBird-2 (QB2) / GeoEye-1 (GE1)，二者均为 RGB-NIR 传感器。**右侧**：划分基于通过光谱卷积从高光谱 EnMAP 传感器合成的传感器（MODIS、Sentinel-2 和 Planet SuperDove），适用于任意传感器模型。**底部**：reBEN；划分在 Sentinel-1 与 Sentinel-2 传感器之间实施，适用于所有任意传感器和多传感器模型，但 SenPaMAE 无法处理 SAR 图像。在两种情景下，Panopticon 均持续优于其他模型。注意，每个子图的值域有所不同。

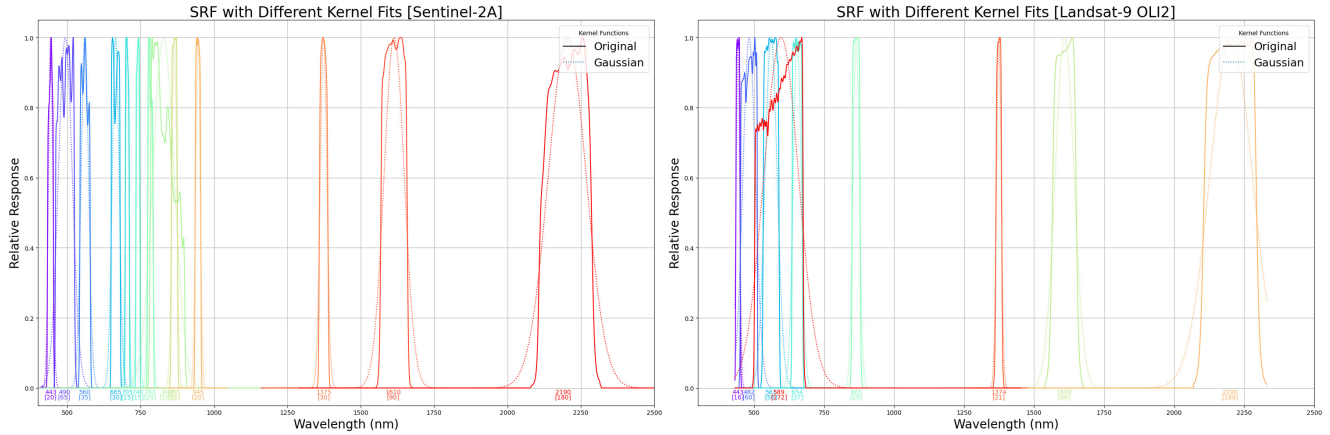

Supp. Fig. 4. Sentinel-2（左）和 Landsat 9（右）的光谱响应函数（SRF）拟合。

通过这一过程，我们能够从任意高光谱源生成新的多光谱视图，极大地扩展了该框架的谱增强能力。我们假设这种组合可能为模型引入有用的谱归纳偏置。

评估 为了评估这些设计选择，我们在一个根据 Section 3.5中规定的规范训练的模型上运行了评估套件，即与主论文中描述的模型完全相同。我们称该模型为 Panopticon-IPE。结果如 Tab. 8所示。

将这些结果与表 2 和表 3 进行比较，可以看出 Panopticon-IPE 的性能与 Panopticon 相比相对接近，在某些情况下（如 TropicalCyclone）甚至表现更优。然而，平均而言，该模型的表现不如我们默认设置的模型，因此我们未将其包含在主论文中。我们将这些发现留给未来的研究人员参考。

表 8. Panopticon-IPE 在各类数据集上的性能指标。miJacc = 微 Jaccard 指数

Dataset	Score
Classification (Accuracy %)	
m-eurosat	96.1
m-brick-kiln	95.8
m-pv4ger-cls	95.8
RESISC45	91.2
m-forestnet	54.0
Segmentation (miJacc %)	
m-pv4ger	95.4
m-nzcattle	92.8
spacenet1	90.3
m-neontree	79.6
m-chesapeake	78.0
m-cashew	59.1
m-sacrop	52.3
Multi-Label Classification (mAP %)	
Corine-MODIS	80.0
Corine-SuperDove	79.8
Regression (MSE)	
DigitalTyphoon	0.93
Hyperview-MODIS	0.35
Hyperview-SuperDove	0.35
TropicalCyclone	0.28

F. 技术细节

F.1. 预训练

通道注意力的实现 我们通过一个 $1\times p\times p$ 3D 卷积 [2] 实现 PE 的初始共享 2D 卷积，其中 p 为块大小。注意，在我们的流水线中，批量内的图像可能来自不同的传感器，因此批量内的通道数并不一致。为了高效计算批处理输入的交叉注意力，我们采用填充和掩码。

超参数 我们遵循 DINOv2 的大部分配置，但做了以下修改：我们将骨干网络中 ViT 块的学习率乘以 0.2，将 iBOT 损失权重降低至 0.1，并移除了 KoLeo 正则化项。我们对这些选择进行了早期的非正式消融实验。除此之外，对于第 1 阶段和第 2 阶段，我们均训练 70 个虚拟轮次，每轮次包含 1250 次迭代，使用 AdamW 优化器，基础学习率为 5e-4，标准学习率缩放 $\mathrm{lr}\cdot\mathrm{bsz}/256$，以及前 5 轮次的线性学习率预热，随后采用余弦衰减至极小点 1e-6 的学习率。

指标 有关消融实验中定义的平均指标的详细信息，请参见 Tab. 9。

F.2. 评估

所有任务均在 40 GB A100 或 48 GB L40S GPU 上执行。批量大小针对每个任务和模型进行优化，以最大化 GPU 内存利用率，基础学习率 lr 根据线性缩放规则 $\mathrm{lr}\cdot\mathrm{bsz}/256$ [18] 随批量大小进行缩放。在我们的评估中，使用以下任务类型。

k NN k 最近邻 (k NN) 采用 $k = 20$ 和温度 0.07，遵循 Reed et al. [51]。

线性探测 我们主要遵循 DINOv2 的实现，并对多种提取方法进行了搜索。具体而言，我们从最后一个或最后四个 Transformer 块中提取 token，并通过拼接 cls token、平均池化或模型本身建议的默认聚合方式对它们进行聚合。对于每种聚合方式，我们搜索了 13 个基础学习率：1e-5、5e-5、1e-4、5e-4、1e-3、5e-3、1e-2、5e-2、0.1、0.5、1、5 和 10，共产生 $2\cdot 3\cdot 13 = 78$ 次运行。需要注意的是，我们使用了 DINOv2 实现的一个扩展版本，能够从骨干网络的单次前向传播中同时计算所有这些不同配置。我们以 0.9 动量的随机梯度下降优化器训练 50 轮次。此外，在线性头之前添加了一个可训练的批量规范化。在 Fig. 2 和 Fig. 3 中的跨传感器评估中，我们仅从最后一个 Transformer 块提取 token，以简化使用不同编码器处理 SAR 与光学模态的模型之间的兼容性问题。

线性探测与重新初始化的补丁嵌入 我们将模型的图像块嵌入替换为一个随机初始化的二维卷积层，其通道数与当前数据集的通道数一致。我们在编码器中添加了一个可训练的批量归一化层和线性头部，解冻新的图像块嵌入层，同时冻结其余编码器部分。我们固定特征聚合方式为模型作者建议的默认设置，分别测试基础学习率 0.01、0.001、0.0005 和 0.0001，每个学习率运行 50 轮次，采用随机梯度下降优化器，并进行 5 轮次的学习率预热。

Agg.	Id	Dataset	Task details	Metric
$\mathrm{MS}_{\mathrm{acc}}$	1	m-eurosat	kNN, $k = 20$, $T = 0.07$	top-1 micro accuracy
	2	m-eurosat without RGB channels	kNN, $k = 20$, $T = 0.07$	top-1 micro accuracy
$\mathrm{SAR}_{\mathrm{acc}}$	3	m-eurosat-SAR [68]	kNN, $k = 20$, $T = 0.07$	top-1 micro accuracy
	4	m-eurosat-SAR	linear probing for 10 epochs	top-1 micro accuracy
$\mathrm{Sim}_{\mathrm{mAP}}$	5	Corine-4	linear probing on 10% subset for 10 epochs	top-1 micro multilabel average precision
	6	Corine-12	linear probing on 10% subset for 10 epochs	top-1 micro multilabel average precision
Avg	1–6			
	7	RESISC45	kNN, $k = 20$, $T = 0.07$	top-1 micro accuracy
	8	m-eurosat only RGB channels	kNN, $k = 20$, $T = 0.07$	top-1 micro accuracy

表 9. 用于指导设计决策并在正文消融实验部分报告的指标。聚合指标计算为其所有指标的平均值。Corine-n 表示将 Corine 数据集子采样至 n 个随机选择的通道。

AnySat 和 Galileo 由于其模态特定编码器的实现方式，带来了独特的挑战。对于 AnySat，我们选择特定模态，并重新训练该分支的 2D 卷积层；我们选择了 NAIP 编码器，因为它未实现时间注意力机制，从而避免了大量内存和计算资源的消耗。而对于 Galileo，这种情况不可行，因为其采用通道分组机制，每组生成一组独立的 token，与其他模型中通道维度被合并的方式不同。若要替换此机制，我们必须创建一个具有自定义通道数的新分组，这将破坏 Galileo 按组处理 token 的原有方式。此外，Galileo 采用了 FlexiPatchEmbed，该模块在预训练阶段通过随机化图像块大小进行训练。为了正确训练该模块，我们需要在评估阶段模拟这一过程，但这超出了本文评估阶段的范围。因此，我们在需要为领域自适应重新训练图像块嵌入模块的测试中，省略了对 Galileo 的评估。

语义分割 我们冻结主干网络，并从 MMSegmentation 库中添加可训练的标准模块 [13]。具体来说，我们使用 Feature2Pyramid 作为颈部，UPerNet 解码器和辅助的 FCNHead。我们对基础学习率进行搜索：1e-1、1e-2、1e-3、1e-4、1e-5、1e-6，并在 50 轮次中使用 AdamW 优化器，不使用学习率预热。

模型适应 在评估过程中，我们选择了模型原始训练时使用的图像大小，以最大化该模型生成表示的能力。

G. 额外消融

光谱增强 与 DINO 在随机缩放裁剪中对尺度的消融实验一致，我们对谱大小进行消融，即 $(1, s), (s, 13)$ 对 $s \in \{2, 4, 8, 13\}$ 。在 Table 14 中，我们观察到 $s = 4$ 表现最佳。

	m-brick-kiln (S2)	m-eurosat (S2)	m-forestnet (L8)	m-pv4ger (RGB)	m-so2sat (S2)	reBEN (S2)
DINOv2	97.5	95.5	53.5	97.5	60.8	80.1
CROMA	94.5	91.1	-	-	53.5	79.4
SoftCon	94.9	92.2	-	-	52.1	80.6
AnySat	90.3	87.6	50.9	92.8	42.5	76.8
Galileo	93.1	88.6	-	-	54.2	76.5
SenPaMAE	83.9	77.5	33.5	87.1	33.7	63.8
DOFA	95.8	92.9	53.2	97.4	54.2	78.8
Panopticon	96.7	96.4	56.3	96.4	61.7	83.9

表 10. 在 GEO-Bench 分类数据集和 reBEN 上的线性探测。我们以百分比报告单标签数据集的微观准确率和多标签数据集的平均精度。

	m-cashew (S2)	m-chesapeake (RGBN)	m-neontree (RGB)	m-nzcattle (RGB)	m-pv4ger (RGB)	m-sacrop (S2)
DINOv2	65.9	78.5	80.9	92.7	96.9	51.2
CROMA	44.3	-	-	-	-	48.4
SoftCon	54.5	-	-	-	-	51.3
AnySat	38.8	75.9	79.6	92.5	92.2	39.5
Galileo	40.4	-	-	-	-	39.5
SenPaMAE	40.7	59.9	79.5	89.5	78.3	39.3
DOFA	56.4	78.2	80.4	92.8	96.3	51.3
Panopticon	59.3	78.1	79.6	92.6	95.2	52.6

表 11. GEO-Bench 分割性能。我们报告使用 torchmetrics 包（版本 x.y.z [44]）中的 torchmetrics.classification.JaccardIndex 计算的微平均 Jaccard 指数，以百分比表示。

	m-cashew (S2)	m-chesapeake (RGBN)	m-neontree (RGB)	m-nzcattle (RGB)	m-pv4ger (RGB)	m-sacrop (S2)
DINOv2	53.4	64.0	59.1	76.9	95.2	32.0
CROMA	34.3	-	-	-	-	34.4
SoftCon	39.9	-	-	-	-	33.7
AnySat	21.8	61.7	49.9	67.6	89.2	23.6
Galileo	30.4	-	-	-	-	28.4
SenPaMAE	17.8	46.9	48.3	49.6	80.4	18.4
DOFA	41.9	59.2	55.4	74.3	94.6	32.5
Panopticon	45.1	60.8	50.4	73.9	94.1	35.7

表 12. GEO-Bench 分割性能。我们报告使用 torchmetrics 包（版本 1.6.1 [44]）中的 torchmetrics.classification.JaccardIndex 计算的宏 Jaccard 指数（百分比）。

	m-cashew (S2)	m-chesapeake (RGBN)	m-neontree (RGB)	m-nzcattle (RGB)	m-pv4ger (RGB)	m-sacrop (S2)
DINOv2	52.7	26.8	55.8	77.4	92.7	13.9
CROMA	33.8	-	-	-	-	14.2
SoftCon	39.2	-	-	-	-	14.2
AnySat	20.9	25.5	47.4	67.9	86.0	10.0
Galileo	30.1	-	-	-	-	11.9
SenPaMAE	17.6	19.7	46.3	49.0	69.4	9.1
DOFA	41.2	26.6	51.5	74.6	89.7	13.9
Panopticon	44.7	26.6	47.8	73.0	88.2	14.9

表 13. GEO-Bench 分割性能。我们报告以百分比形式平均到图像上的 mIoU，该 mIoU 由 torchmetrics 包（版本 1.6.1）中的 torchmetrics.segmentation.MeanIoU 计算得出 [44]

s	2	4	8	13
$\mathrm{MS}_{\mathrm{acc}}$	81.2	85.3	83.6	81.2

表 14. 非重叠光谱作物大小的消融。