https://hjfy.top/arxiv/2507.20776

RingMo-Agent：面向多平台与多模态推理的统一遥感基础模型

Huiyang Hu, Peijin Wang, Yingchao Feng, Kaiwen Wei, Wenxin Yin, Wenhui Diao, Mengyu Wang, Hanbo Bi, Kaiyue Kang, Tong Ling, Kun Fu, Xian Sun
Aerospace Information Research Institute, Chinese Academy of Sciences
School of Electronic, Electrical and Communication Engineering, University of Chinese Academy of Sciences
University of Chinese Academy of Sciences
Key Laboratory of Target Cognition and Application Technology (TCAT)
{huhuiyang22, wangpeijin17}mails.ucas.ac.cn

Abstract

来自多种模态和平台的遥感（RS）图像由于传感器特性及成像视角的差异，呈现出丰富的细节。现有的遥感视觉-语言研究大多依赖于相对同质的数据源，且仍局限于分类、描述生成等传统视觉感知任务。因此，这些方法难以作为统一且独立的框架，在真实应用中有效处理来自多样化数据源的遥感影像。为解决上述问题，我们提出 RingMo-Agent，一种专为多模态、多平台数据设计的模型，能够根据用户文本指令执行感知与推理任务。相较于现有模型，RingMo-Agent 具备以下优势：1）基于大规模视觉-语言数据集 RS-VL3M，该数据集包含超过 300 万张图像-文本对，涵盖光学、合成孔径雷达（SAR）和红外（IR）模态，数据来源于卫星与无人机平台，覆盖感知任务及具有挑战性的推理任务；2）通过引入分离的嵌入层，构建异构模态的独立特征表示，实现模态自适应表示学习，有效降低跨模态干扰；3）通过引入任务特定 token，并采用基于 token 的高维隐状态解码机制，实现任务建模的统一，特别适用于长时序空间任务。在多种遥感视觉-语言任务上的大量实验表明，RingMo-Agent 不仅在视觉理解与复杂分析任务中表现优异，还在不同平台和传感模态间展现出强大的泛化能力。

Keywords 基础模型 · 多模态 · 多平台 · 遥感多模态大语言模型 · 指令微调

1 引言

随着大模型（LLMs）在语义理解与推理能力方面的显著进步，面向开放世界环境的视觉-语言模型也迎来了快速发展 [1–3]。借助 DeepSeek [4–7]、GPT [8,9] 以及 Llama [10–12] 等先进语言模型的能力，这些模型现已能够感知复杂语义、开展多轮交互，并执行上下文感知的任务规划。这一演化标志着从静态感知向动态理解与自主决策的重大转变，从而推动了智能交互与高层场景推理等更广泛应用的发展。

受自然场景研究进展的推动，视觉-语言模型的范式逐渐扩展至 RS [13]，将指令微调和联合视觉-语言建模等能力引入到 RS 图像分析中。这些努力催生了在基础 RS 感知任务（如目标识别和场景分类）中表现令人瞩目的模型 [14–24]。然而，当前用于 RS 的视觉-语言模型仍面临显著局限：

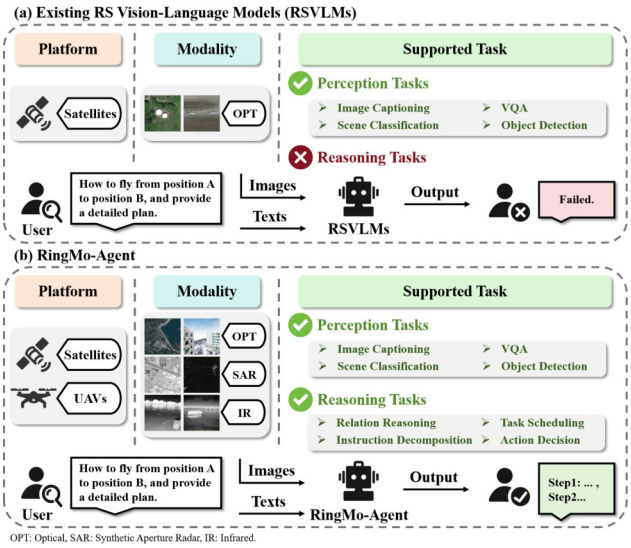

图 1: 在数据平台、模态和支持任务方面，RingMo-Agent 与大多数现有的视觉-语言推荐系统（RS）模型的对比。

- **单一源建模在多样化遥感数据中的局限性**。由于数据获取平台（如卫星和无人机）及成像模态（如光学、合成孔径雷达（SAR）和红外）的差异，遥感数据在空间分辨率、观测几何和光谱响应等物理特性上表现出显著差异。这些异质特性从根本上影响了图像中信息的表征方式。然而，现有的大多数遥感视觉-语言模型仅在单一模态或平台的数据上进行训练，限制了其处理真实场景中多源数据复杂性的能力。因此，这些方法在跨平台和跨模态应用中往往存在泛化能力差和兼容性有限的问题。

- **现有推理任务范式的局限性**。现有的遥感视觉-语言研究主要集中在特定的视觉感知任务上。然而，这些任务仍局限于基础的感知与识别，模型缺乏在场景实体间关系推理和动作预测等高级认知能力方面的训练。因此，这些模型的应用范围受限于狭窄领域，在面对需要决策能力的高层次任务时，难以复现智能体系统在自然场景中展现出的优越智能，如图 Figure 1所示。这一局限性的根本原因在于缺乏面向复杂语义交互与推理的大规模遥感图像-文本数据集，从而限制了模型对多模态知识的泛化能力。

为解决上述局限性，我们提出 RingMo-Agent，一种旨在处理多模态和多平台数据的智能体模型，能够根据用户指令执行感知与推理任务。**首先**，为了充分挖掘视觉-语言模型在智能体应用中的潜力，我们构建了一个名为 RS-VL3M 的视觉-语言数据集，包含跨越三种模态（光学、SAR 和红外）、两个平台（卫星与无人机）以及八项任务的 300 万张图像-文本对，如 Figure 2 所示。**其次**，我们采用基于特殊 token 的高维隐状态解码机制，通过聚焦于最后一层的隐状态表示来建模动态轨迹信息，从而支持遥感长时程推理任务。**第三**，引入一种模态感知的视觉编码器，其采用分离的嵌入方式，以缓解不同传感平台与模态之间的分布偏移问题，支持鲁棒的特征抽取与对齐。**最后**，与以往主要关注光学影像和基础感知任务的方法不同，RingMo-Agent 实现了异构模态与平台间感知与推理的统一，如 Table 1 所总结。我们进一步在公开及自构建的多源遥感数据集上，对所提出的模型与现有先进方法进行了全面对比。

主要贡献可以概括如下：

1. 我们提出 RingMo-Agent，一种支持三种感知模态和八种任务类型、跨两个平台的智能体，能够实现从基础视觉感知到高级推理的统一框架。

表 1: 模型架构与能力对比，包括大模型、视觉编码器、支持的模态以及任务覆盖范围。SAR：合成孔径雷达，IR：红外，IC：图像描述，CL：分类，RR：关系推理，OD：目标检测（含视觉定位），ID：指令分解，AD：动作决策，TS：任务调度。

Model	LLM	Visual Encoder	Size	Modalities			Perception Tasks				Reasoning Tasks			
				Optical	SAR	IR	IC	VQA	CL	OD	RR	ID	AD	TS
EarthGPT [14]	LLaMA-2	DINOv2 ViT-L/14, CLIP ConvNeXt-L	-	✓	✓	✓	✓	✓	✓	✓				
Popeye [15]	LLaMA-2 (7B)	DINOv2 ViT-L/14, CLIP ViT-L/14	-	✓	✓					✓				
RS-CapRet [16]	LLaMA-2 (7B)	CLIP ViT-L/14	224	✓			✓							
LHRS-Bot [17]	LLaMA-2 (7B)	CLIP ViT-L/14	224	✓			✓	✓	✓	✓				
SkyEyeGPT [18]	LLaMA-2-Chat (7B)	EVA ViT-G	448	✓			✓	✓	✓	✓				
SkySenseGPT [19]	Vicuna-v1.5	CLIP ViT-L/14	504	✓			✓	✓	✓	✓	✓			
GeoChat [20]	Vicuna-v1.5 (7B)	CLIP ViT-L/14	504	✓			✓	✓	✓	✓				
H^2RSVLM [21]	Vicuna-v1.5 (7B)	CLIP ViT-L/14	336	✓			✓	✓	✓	✓				
RingMoGPT [22]	Vicuna-v1.1 (13B)	EVA ViT-G	448	✓			✓	✓	✓	✓				
RSGPT [23]	Vicuna (7B/13B)	EVA ViT-G	224	✓			✓	✓						
RS-LLaVA [24]	Vicuna-v1.5 (7B/13B)	CLIP ViT-L/14	336	✓			✓	✓						
RingMo-Agent (ours)	**DeepSeekMoE (3B)**	**SigLIP-SO400M-384**	**Any**	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓

2. 我们构建了 RS-VL3M，这是首个大规模的遥感视觉-语言数据集，整合了多平台和多模态数据，包含超过 300 万对图像-文本数据。该数据集还包含一个高质量的共享多模态子集，专门用于多轮对话评估。
3. RingMo-智能体采用分离的嵌入层以缓解模态特定的分布偏移，并实现对异构输入的联合处理。它进一步引入由长时程任务特定 token 引导的高维隐状态解码器，通过关键的隐状态表示来建模动态轨迹。

在验证中，RingMo-Agent 在八项遥感任务中表现出色，优于专家模型和通用模型，同时展现出强大的 zero-shot 泛化能力。

2 相关作品

2.1 自然场景中的视觉-语言研究

近年来，视觉-语言模型取得了显著进展，已成为连接视觉与语言理解的重要桥梁。

早期研究主要集中在感知层面的任务，如图像-文本匹配、图像描述生成和闭式问答系统，强调视觉与语言之间的跨模态对齐和表示学习。例如，BLIP-2 [25] 采用三种损失策略来对齐视觉与文本内容，在 VQA 和图像-文本检索任务上取得了优异性能。InstructBLIP [26] 探索了一种统一的指令微调范式，通过具备指令感知能力的视觉特征抽取来完成基础的视觉感知任务。后续工作则深入研究了像素级任务，包括定位、检测和分割。MiniGPT-v2 [27]、Kosmos-2 [28] 和 Shikra [29] 探讨了通过自然语言表示空间坐标的方法。LISA [30] 进一步引入了嵌入即掩码的范式，通过预测特殊 token 的隐藏表示来解码分割掩码。

随着模型能力的提升，以 GPT-4 [9] 为代表的研究逐渐扩展至开放性问答、视觉常识推理以及多轮对话任务，涵盖了上下文建模与知识推理。Gemini 系列 [31–33] 提供了多种针对不同计算约束和应用场景优化的模型变体，在多模态理解、视觉美感以及工具使用等多个维度上均展现出业界领先的表现。GPT-4o [34] 在 50 种语言上表现出色，对非英语文本的处理能力显著增强。其轻量级版本 GPT-4o Mini [35] 在性能与计算成本之间提供了更均衡的权衡。Qwen-VL 系列 [36–38] 在涵盖编程、数学及通用推理的基准测试中取得了极具竞争力的结果。基于 DeepSeekMoE [5,39] 的低成本与高性能特性，训练于多样化多模态数据的 DeepSeek-VL2 [40] 能够准确解析科学图表并分析各类网络梗图。

图 2: RingMo-Agent 支持图像描述、目标检测、视觉问答和场景分类等感知任务，以及关系推理、指令分解、动作决策和任务调度等推理任务。部分任务由光学（OPT）、合成孔径雷达（SAR）和红外（IR）模态支持。

最近的研究强调了基于大模型的智能体作为实现人类水平决策的有前景的研究方向，其中智能体架构旨在感知动态环境，并将规划结果转化为可执行的动作 [41]。例如，Reflexion [42] 引入了一种自我反思机制，能够在不微调大模型的情况下提升性能，从而保持较低的计算开销。HuggingGPT [43] 提出了整合由社区开发的丰富而强大的人工智能模型生态系统，其中任务被规划并选择合适的模型来执行子任务并生成响应。Toolformer [44] 则探索了大模型做出决策并自主通过 API 接口调用外部工具的能力。MetaGPT [45] 采用流水线范式来组织多个智能体进行协同合作。

当前的模型正从以感知驱动的系统演变为具备推理能力的通用智能体，但仍主要聚焦于自然场景，难以应对遥感影像的复杂性。

2.2 遥感中的视觉-语言研究

随着遥感基础模型的发展 [46, 47]，集成大模型已成为一个新兴方向。然而，由于数据异构性和任务多样性，其在遥感领域的应用仍处于初步探索阶段，大多数方法依赖于对现有架构进行微调。

随着 RSGPT [23] 和 RSVG [48] 等研究证明视觉-语言模型在遥感图像上具有良好的泛化能力，相关研究越来越多地聚焦于这些模型的设计与训练。RemoteCLIP [49] 构建了一个统一的遥感视觉-语言模型，并在图像分类、图文检索和目标计数等下游任务中验证了其有效性。GeoChat [20] 引入了一个具备多任务对话能力的遥感视觉-语言模型，主要关注目标存在性判断，以及颜色、数量等属性判断。同时，它还初步尝试探索目标存在性与场景语义之间的关系。SkyEyeGPT [18] 融合了无人机视频字幕生成任务，探究遥感基础模型联合学习卫星与无人机影像的能力。RingMoGPT [22] 进一步将任务范围扩展至变化检测与基于图像的字幕生成。

然而，现有研究主要集中在使用光学影像的感知任务上，仅涵盖了遥感数据的一小部分。最近，EarthGPT [14] 将合成孔径雷达（SAR）和红外数据融入，以增强视觉-语言模型的多模态检测能力。SkySenseGPT [19] 探索了模型对图像中物体间关系进行推理的能力。AeroVerse [50] 试图将基于无人机的智能体任务整合到视觉-语言模型中，以探索导航探索能力。

尽管取得了最近的进展，当前的遥感（RS）研究仍主要局限于基础感知表示，缺乏自主决策能力。此外，它们主要集中在单平台和单模态数据上，这限制了其在真实遥感场景中的应用。

2.3 遥感视觉-语言研究的任务与数据集

为了支持遥感智能系统的训练，已开发出大量视觉-语言数据集，其中大多数是从最初为目标检测、语义分割、图像分类和变化检测等任务设计的单模态数据集扩展而来，并逐步演变为大规模多模态基准。

早期的数据集主要基于人工标注的图像描述，语义层次有限，主要支持如视觉问答（VQA）和分类等基础任务，例如 RSVQA [51] 和 AID [52]。随着任务的扩展，数据集类型和规模也逐渐增长。例如，RemoteCLIP [49] 通过将基于规则的方法应用于面向检测、分割和检索的遥感（RS）数据集，构建了一个大规模的图像描述数据集，实现了视觉与语言数据的对齐。RSVG [48] 基于光学遥感目标检测数据集 DIOR [53]，对图像中的物体进行属性分析，并通过基于规则的处理生成一个视觉定位数据集。RSGPT [23] 在光学遥感目标检测数据集 DOTA [54] 的基础上进行扩展，利用遥感领域专家的标注，构建了一个全面的图像描述数据集。

多项研究致力于构建大规模、高质量的遥感(RS)图像-文本数据集，涵盖多种任务类型。XLRS-Bench [55] 针对光学超高分辨率遥感影像设计，提供了一个全面的评估基准，涵盖感知与推理类别的 16 个子任务。VRSBench [56] 提供了一个大规模的遥感视觉-语言数据集，包含 29,614 张图像，其标注覆盖三个关键应用场景：目标指代、视觉问答（VQA）以及人工验证的详细描述。EarthGPT [14] 收集了涵盖五种任务类型和三种图像模态的多样化遥感数据，并通过设计不同指令构建预训练数据集。此外，GeoChat [20]、RingMoGPT [22] 和 SkySenseGPT [19] 等模型利用受限的大模型（LLMs）生成增强任务的响应，作为训练数据使用。

尽管取得了这些进展，仍缺乏能够支持多种任务类型、多模态和多种平台的数据集，而这一点对于推动通用智能体的发展至关重要。

3 数据集构建

3.1 总体数据分析

我们构建了一个大规模、高质量的遥感图像-文本数据集，命名为 RS-VL3M，包含由安装在不同成像平台上的多种传感器捕获的图像。该数据集包含具有多样化分辨率、观测角度和成像机制的图像，总计超过 300 万对图像-文本数据。它支持两大类任务：以推理为导向的任务（任务调度、动作决策、指令分解和关系推理），以及以感知为导向的任务（图像描述、目标检测、图像分类和视觉问答），具体详见 Table 2。此外，为了在一致的数据条件下提升模型的多轮对话能力，我们基于共享的图像资源池建立了一个多模态对话子集。该子集能够在同一图像上同时实现红外与合成孔径雷达模态的交互式分类、检测和描述任务。

表 2: RS-VL3M 数据集的概览，包括任务类型、数据集大小、模态和图像大小。<x, x> 表示可变的图像大小，代表从极小点到最大值的值域。

Task	Dataset	Dataset Size	Modality	Image Size
Task Scheduling	CityNav [57]	32,637	optical	384×384
Action Decision	SkyAgent-Plan3k [50]	3,000	optical	512×512
Instruction Decomposition	ReCon1M-DEC (ours)	27,821	optical	<135, 1000>
Relation Reasoning	FIT-RS [19]	97,843	optical	512×512
	ReCon1M-REL (ours)	125,000	optical	<135, 1000>
Object Detection	DIOR [53]	23,463	optical	800×800
	DOTA [54]	108,047	optical	800×800
	NWPU VHR-10 [58]	800	optical	<500, 1100>
	SARDet-100k [59]	116,598	SAR	<190, 1000>
	IR-DET (ours)	56,353	infrared	<92, 6912>
Image Captioning	UCM-Captions [60]	10,500	optical	256×256
	Sydney-Captions [60]	3,065	optical	500×500
	RSICD [61]	54,605	optical	224×224
	NWPU-Captions [62]	157,500	optical	256×256
	SAR-CAP (ours)	582,990	SAR	<190, 1000>
	IR-CAP (ours)	281,765	infrared	<92, 6912>
Scene Classification	AID [52]	10,000	optical	600×600
	NWPU-RESISC45 [63]	31,500	optical	256×256
	WHU-RS19 [64]	1,005	optical	600×600
	UCMerced-LandUse [65]	2,100	optical	256×256
	SAR-CLA (ours)	116,597	SAR	<190, 1000>
	IR-CLA (ours)	56,353	infrared	<92, 6912>
VQA	RSVQA-HR [51]	1,066,316	optical	512×512
	RSVQA-LR [51]	77,232	optical	256×256

3.2 任务数据集构建

除了直接使用公开数据集外，我们还通过处理开源多模态数据来构建复杂任务的数据集。整体工作流如 Figure 3 所示。我们从光学、合成孔径雷达 (SAR) 和红外图像中提取对象级别的属性信息，并根据每个任务的设计要求对数据进行格式化。在数据使用方面，为确保空间表示的一致性，所有坐标均规范化的值域为 $[0, 999]$ 。提供 `[label]` 选项以在训练和推理过程中指示模态分支，同时在网页界面中以可点击按钮的形式呈现，可能的取值为 `opt`、`sar` 和 `ir`。各任务类别的数据详情如下所述。

任务调度。该任务聚焦于基于遥感影像的复杂城市环境中自主空中导航的轨迹规划。给定描述目标位置周围空间上下文的指令，模型必须根据附近建筑物或地标作为参考，识别目标的三维位置，并在已知智能体初始位姿的情况下，生成一系列三维航点及相应的朝向角度。我们的任务调度数据集源自 CityNav [57]，其结构如下：

- $<|\texttt{navigation}|>$ 你需要根据此地图制定一架四旋翼无人机的飞行计划，使其能够飞越所有建筑物并抵达目标位置。目标位置描述如下：$<description>$。地标处的三维坐标如下：$<|\texttt{ref}|><landmark><|/\texttt{ref}|>$ $<|\texttt{pos}|>[x_1, y_1, z_1]<|/\texttt{pos}|>$ 。你的起始三维坐标和姿态角为：$<|\texttt{pose}|>[[x_0, y_0, z_0,\ \phi_0, \theta_0, \psi_0]]<|/\texttt{pose}|>$ 。你需要提供一系列三维航点及姿态角，以使四旋翼无人机到达目标位置。
- 响应：步骤 1：提取基本信息如下：目标：$<target>$。特征点：$<landmark>$。周围环境：$<surrounding>$。

  步骤 2：获取特征点位置：$<|\texttt{ref}|><landmark><|/\texttt{ref}|><|\texttt{pos}|>[x_1, y_1, z_1]<|/\texttt{pos}|>$。

  步骤 3：获取目标位置：$<|\texttt{ref}|><target><|/\texttt{ref}|><|\texttt{pos}|>[x_2, y_2, z_2]<|/\texttt{pos}|>$。

  步骤 4：轨迹：$<|\texttt{pose}|>[[x_0, y_0, z_0, \phi_0, \theta_0, \psi_0], ..., [x_n, y_n, z_n, \phi_n, \theta_n, \psi_n]]<|/\texttt{pose}|>$。

一组特殊 token 被嵌入到提示中：$<|\texttt{navigation}|>$ 定义任务类型。$<|\texttt{ref}|>$ 和 $<|\texttt{/ref}|>$ 表示地标名称，而 $<|\texttt{pos}|>$ 和 $<|\texttt{/pos}|>$ 代表其对应的坐标。轨迹使用 $<|\texttt{pose}|>$ 和 $<|\texttt{/pose}|>$ 标签进行结构化，其中每个姿态条目包含六个元素：空间位置 (x, y, z) 和方向角 (ϕ, θ, ψ)，分别表示俯仰角、横滚角和偏航角。此外，$<landmark>$、$<surrounding>$ 和 $<target>$ 等占位符用于标记类别信息（例如“惠灵顿路”），而 $<description>$ 是一个用于描述目标周围空间环境的占位符句子（例如“在惠灵顿路与莱斯利路交叉口处灰色房屋左侧的一排灰褐色房屋”）。

动作决策。该任务聚焦于智能体在城市环境中进行精细化的动作决策规划，将视觉-语言推理与控制执行相衔接。给定初始和目标三维位姿以及城市地图图像，模型需生成详细的指令序列。每条指令对应一个可解释的运动步骤（例如，“直行”，“轻微右转”），并基于可观察的视觉线索（如附近建筑物、颜色、形状或空间布局）进行定位。我们的动作决策数据集使用了 SkyAgent-Plan3k [50] 的数据，如下例所示：

- $<|\texttt{decision}|>$ 如何从位置 $<|\texttt{pose}|>$ $[[x_0, y_0, z_0, \phi_0, \theta_0, \psi_0]]$ $<|\texttt{/pose}|>$ 飞往位置 $<|\texttt{pose}|>$ $[[x_n, y_n, z_n, \phi_n, \theta_n, \psi_n]]$ $<|\texttt{/pose}|>$，以及提供详细的飞行计划。
- 步骤 1：$<description>$.
  步骤 2：$<description>$.
  …
  步骤 n：$<description>$.

我们引入一个特殊 token $<|\texttt{decision}|>$ 来指定任务语义。$<|\texttt{pose}|>$ 和 $<|\texttt{/pose}|>$ 的使用方式与任务调度数据集保持一致。起点出现在第一张图像中，终点出现在最后一张图像中。输出格式要求对每个场景转移用 $<description>$ 标签进行标注，每一步均以智能体的视角用自然语言描述，以支持人类理解和决策制定。

指令分解。该任务旨在通过将复杂的、高层级的遥感（RS）指令分解为一系列细粒度、可解释的子任务，从而提升模型执行此类指令的能力。在我们的情景中，模型接收一张图像以及一个可能涉及特定区域或语义目标的自然语言指令。模型需要将该输入分解为结构化的多步推理过程，包括区域定位、目标检测、关系分析和上下文总结。我们的指令分解数据集基于遥感关系理解数据集 ReCon1M [66] 构建。

- $<|\texttt{decomposition}|>$ 分析图像中区域 $<|\texttt{det}|>[[x_1, y_1, x_2, y_2]]$ $<|\texttt{/det}|>$ 的部分。
- 响应：步骤 1：定位目标区域：目标区域位于图像的 $<direction>$ 处；
  步骤 2：执行目标检测：目标区域内有 N 个实体，包括：N_1 $<|\texttt{ref}|><object><|\texttt{/ref}|><|\texttt{det}|>$ $[[x_1^1, y_1^1, x_2^1, y_2^1]]$ $<|\texttt{/det}|>, ..., N_n$ $<|\texttt{ref}|><object><|\texttt{/ref}|><|\texttt{det}|>$ $[[x_1^n, y_1^n, x_2^n, y_2^n]]$ $<|\texttt{/det}|>$；
  步骤 3：执行关系分析：发现 M 个关系：$<|\texttt{ref}|><object><|\texttt{/ref}|><|\texttt{det}|>$ $[[x_1^1, y_1^1, x_2^1, y_2^1]]$ $<|\texttt{/det}|>$ 是 $<|\texttt{rel}|><relation><|\texttt{/rel}|>$ 的 $<|\texttt{ref}|><object><|\texttt{/ref}|><|\texttt{det}|>$ $[[x_1^m, y_1^m, x_2^m, y_2^m]]$ $<|\texttt{/det}|>$；
  步骤 4：执行上下文摘要：包含 N 物体类型与 M 相互作用。

如上图所示，$<direction>$ 有 9 个方向，分别为上、下、左、右、左上、右上、左下、右下和中心。N 表示检测到的物体总数，其中 N_1 至 N_n 表示各类别物体的数量。$<|\texttt{ref}|><object><|\texttt{/ref}|><|\texttt{det}|>$ $[[x_1^1, y_1^1, x_2^1, y_2^1]]$ $<|\texttt{/det}|>$ 表示具有空间位置信息的具体物体类别，其中 $[x_1^1, y_1^1, x_2^1, y_2^1]$ 分别表示两个物体的左上角和右下角坐标。$<|\texttt{rel}|><relation><|\texttt{/rel}|>$ 表示两个物体之间的关系。

关系推理。该任务要求模型推断出主体和客体的类别，并描述它们之间的关系，从而使其能够识别图像中的物体并推理它们之间的交互。我们的数据集源自 RS 指令微调数据集 FIT-RS [19] 和 RS 关系理解数据集 ReCon1M [66]。

- $<|\texttt{reasoning}|><|\texttt{ref}|><object_1><|\texttt{/ref}|><|\texttt{det}|>$ $[[x_1^1, y_1^1, x_2^1, y_2^1]]$ $<|\texttt{/det}|>$ 与 $<|\texttt{det}|>$ $[[x_1^2, y_1^2, x_2^2, y_2^2]]$ $<|\texttt{/det}|>$ 图像中物体之间的关系是什么？并输出它们的类别。

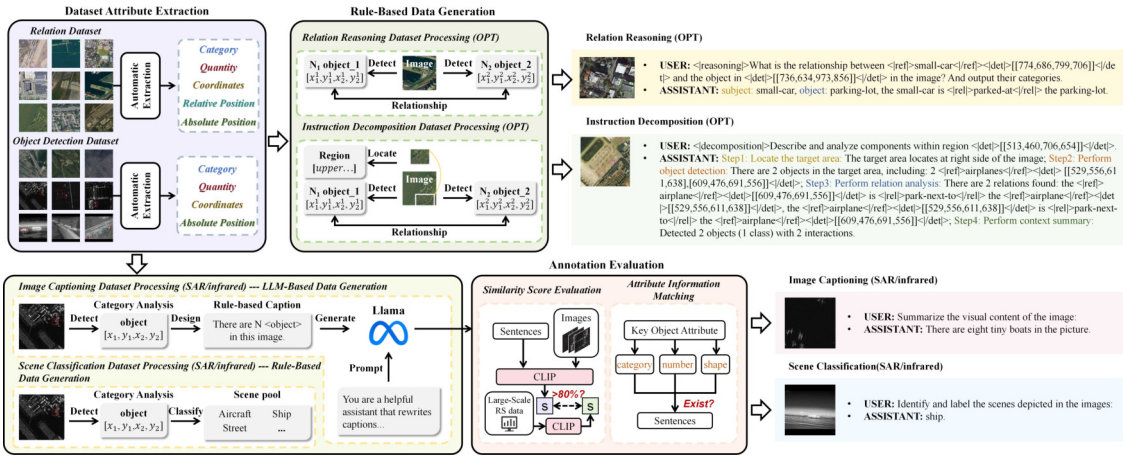

图 3: 一种数据集构建工作流，从现有的关系和检测数据集中提取相关属性，用于指令分解、关系推理、分类和图像描述任务。

- 响应：主语：$< object_1 >$，宾语：$< object_2 >$，$< object_1 >$ 是 $< |\texttt{rel}| >< relation >< |/\texttt{rel}| >$，$< object_2 >$。

与其它任务一致，我们定义了一组特殊 token，以显式标记提示和响应中的不同语义组件。

目标检测. 光学图像来自 DIOR [53]、DOTA [54] 和 NWPU VHR-10 [58]，SAR 图像来自 SARDet-100k [59]，红外图像来自 HIT-UAV [67]、Sea shipping [68]、Infrared-security [69]、Aerial-mancer [70]、Double-light-vehicle [71] 以及 Oceanic ship [72]。

- 检测遥感图像中显示的所有物体，并使用水平边界框（HBBs）进行描述。
- 图像中存在 $M < |\texttt{ref}| >< object >< |/\texttt{ref}| > < |\texttt{det}| > [[x_1^1, y_1^1, x_2^1, y_2^1], ..., [x_1^m, y_1^m, x_2^m, y_2^m]] < |/\texttt{det}| >$。

占位符 $< object >$ 用于表示类别名称（例如，“ship”）。坐标使用方式与之前所述方法相同。

图像描述. 我们利用 SAR-CAP、IR-CAP 以及多种光学图像描述数据集构建了一个多模态图像描述基准。SAR 和红外数据来源于目标检测任务所使用的相同数据集，而光学数据则来自公开数据集 [60–62]。

光学图像的标注通常更丰富，因为人工标注相对容易，通常描述包含建筑物和植被的简单场景。相比之下，SAR 和红外数据需要专家分析。为解决这一问题，我们首先使用标准模板生成图像中物体的基于规则的描述，如 Figure 3 所示。这些描述随后作为文本输入提供给 Llama3.1 [12]，并附带精心设计的提示，以约束模型在保持三个关键属性——物体数量、形状和类别——的同时丰富语言表达。该模型为每幅图像生成五个不同的文本描述。我们对生成的文本进行自动化验证，包括相似度得分评估和属性信息匹配。我们使用 RemoteCLIP [49] 计算生成文本与遥感图像之间的相似度得分，并将其与开源图像标注数据集获得的基准得分进行比较。仅保留相似度得分超过基准 80% 的文本。对于属性一致性，我们进一步验证文本中描述的物体的数量、形状和类别，允许同义表达，并仅保留满足所有这些标准的样本。这种方法有效确保了生成描述的准确性和一致性。

- 画面中，一片宁静的湖面倒映着蓝天白云，岸边绿树成荫，几只水鸟在水面轻盈地掠过，远处山峦起伏，景色宜人。
- 场景中只有一艘帆船。

图像分类. 我们使用与之前相同的来源构建了 SAR 和红外分类数据集。对于 SAR，我们采用原始的类别定义；而对于红外数据，通过将标签合并为两个粗粒度类别——街景和船只——来解决不同数据集间标注不一致的问题。光学数据来源于公开可用的数据集。

- 请输出与图像相对应的场景：
- 飞机。

在我们的数据集中，用于检测、描述和分类任务的红外图像与合成孔径雷达（SAR）图像构成一个共享子集，这意味着每幅图像均被标注以支持所有三项任务。这种设计使得在一致的视觉输入下能够进行多轮评估，而在此研究中，我们将其验证为三个独立的任务。

VQA. 我们使用公开数据集 [51] 作为训练和评估基准。这些数据集被广泛用作评估视觉-语言模型的标准基准。

- 有一条小路吗？这个问题的答案是
- 回应：是。

4 方法

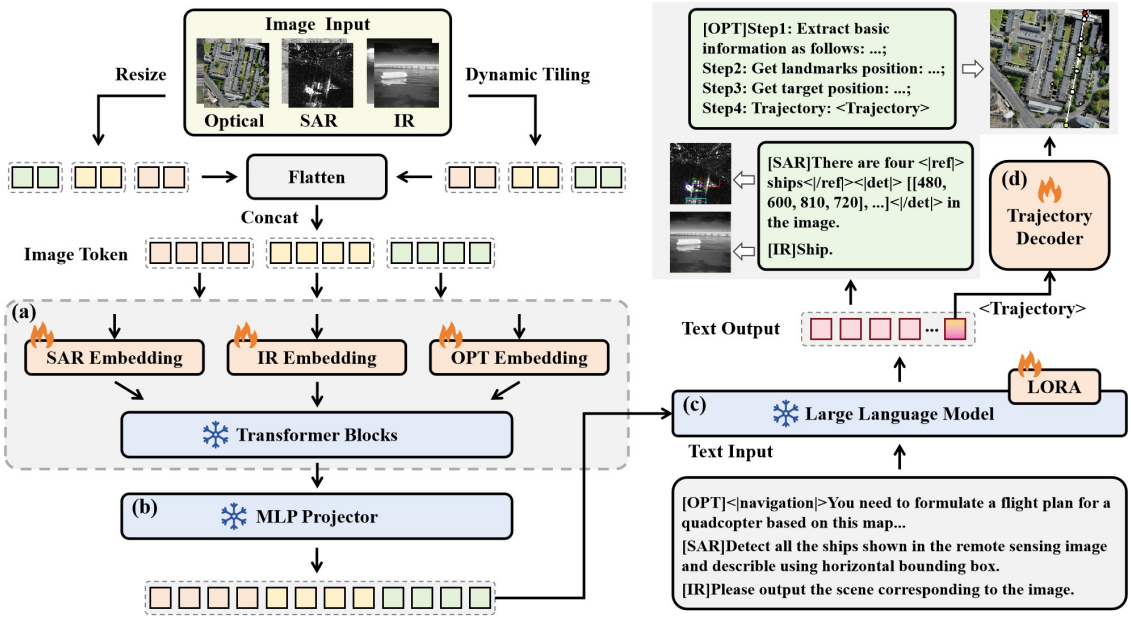

图 4: RingMo-Agent 的整体架构支持来自多个平台和模态的图像输入，实现感知与推理能力。图像特征首先输入（a）视觉编码器，经过（b）一个冻结的 MLP 和（c）通过 LoRA 微调的 LLM 后，模型直接生成文本内容，并在涉及轨迹输出的任务中应用（d）额外的解码过程。

4.1 架构

所提出的 RingMo-Agent 包含四个主要组件：用于提取视觉特征的视觉编码器、用于处理语言信息的语言模型、作为中间适配器将视觉特征投影到语言模型语义空间的 MLP 投影器，以及用于时空建模的轨迹解码器，如 Figure 4 所示。我们的方法采用两阶段训练策略，统一多源数据（如光学、红外和 SAR 图像），同时将传统的感知任务扩展到更具挑战性的推理任务，例如从无人机视角理解复杂城市场景。

Algorithm 1 Trajectory Decoding from Predicted Tokens

Input: The hidden representation of the < `trajectory` > token h_{tra}, the global visual embedding v, the goal embedding g, the previous-point embedding b, maximum termination step T. termination threshold p, finished flag P_{flag}.

Output: Updated trajectory S.

$h_0 \leftarrow$ LatentProjection (h_{tra})
while $t \leq T$ && P_{flag} **do**:
    $f_t \leftarrow$ Concatenate (h_0, v, g, b)
    $h_t \leftarrow$ GRUCell (f_t, h_{t-1})
    $S_t \leftarrow$ OutputProjection (h_t)
    $S \leftarrow$ Update (S_t)
    $P_{flag} \leftarrow$ TerminationCondition (S_t, p)
    $t \leftarrow t + 1$
end while

视觉编码器。视觉编码器基于 SigLIP [73] 方法，动态地将输入图像缩放到 384 的倍数，同时适应具有不同宽高比的 RS 图像。具体而言，给定一个大小为 $(H \times W \times C) \in \mathbb{R}$ 的输入图像，该图像被缩放至维度 $m \times 384, n \times 384, c$ ，其中 $m, n \in \mathbb{N}, \quad 1 \leq m, n, mn \leq 9$ 。m 和 n 的值通过选择大于或等于原始图像高度 H 与宽度 W 的最小 384 倍数来确定。缩放完成后，图像被划分为大小为 384×384 的独立块。此外，通过直接将图像缩放至 384×384 来生成一个全局缩略图，以提供粗粒度的全局表示。

现有的大多数研究集中在单模态光学学习上，而不同模态之间的分布差异限制了统一编码器的有效性。为解决这一问题，我们为光学、SAR 和红外输入采用特定于模态的嵌入层。具体而言，使用三个具有共享架构但独立参数的并行图像块嵌入层，将每种模态投影到统一的 1152 维嵌入空间中，从而减少跨模态干扰。为了形式化这一过程，令 $x_{\text{opt}}, x_{\text{ir}}, x_{\text{sar}} \in \mathbb{R}^{H \times W \times C}$ 分别表示来自光学、红外和 SAR 模态的输入图像。各模态的视觉嵌入获取如下：

$$z_{\text{opt}} = E_{\text{opt}}(x_{\text{opt}}), \quad z_{\text{ir}} = E_{\text{ir}}(x_{\text{ir}}), \quad z_{\text{sar}} = E_{\text{sar}}(x_{\text{sar}}), \tag{1}$$

其中，E_{opt}、E_{ir} 和 E_{sar} 分别是光学、红外和 SAR 数据的嵌入层。这些嵌入随后被传送到后续的图像编码器进行进一步处理。冻结的视觉编码器，记为 F_V，接收输入图像 z 并输出相应的视觉特征：

$$V = F_V(z), \qquad z = \{z_{\text{opt}}, z_{\text{ir}}, z_{\text{sar}}\}, \tag{2}$$

其中 V 表示提取的视觉特征。

冻结的 MLP 投影器。适配器遵循由线性层组成的 MLP 架构。根据 DeepSeek-VL2 [40] 的设置，适配器执行的映射可以表示为以下计算：

$$Q = F_A(V), \tag{3}$$

其中，F_A 表示由 MLP 层组成的适配器，Q 代表映射后的特征。在 F_A 中，首先对每个块的视觉 token 执行 2× 2 的洗牌操作，将每个块的视觉 token 从 27× 27 布局变换为 14× 14。随后，向视觉特征中插入三种类型的特殊 token 作为位置指示符：一种附加到全局缩略图块每行的末尾，另一种附加到局部块最后一列的末尾，第三种则放置在全局块与局部块之间。然后，如 Figure 4 所示，处理后的嵌入被输入到 LLM 中。

LoRA 微调的大语言模型。 该语言模型基于 DeepSeekMoE 架构 [5, 6] 构建，通过将键值缓存压缩为潜在表示来引入多头潜在注意力，从而降低训练成本。我们使用 DeepSeek-VL2 的 3B 版本 [40]，并通过在语言模型自注意力块的查询和值投影层中插入少量可训练的低秩矩阵，应用 LoRA [74] 实现参数高效适配，秩为 64，缩放因子为 16。随后仅对这些额外参数进行微调。该过程可表述如下：

$$\hat{y} = F_L(Q, x_{txt}), \tag{4}$$

其中，F_L 表示使用 LoRA 微调的大型语言模型，x_{txt} 表示文本输入，$\hat{y}$ 表示输出结果。

可训练的轨迹解码器。传统模型通过序列 token 解码生成文本或二维坐标，限制了空间运动建模能力。受 LISA [30] 启发，我们提出一种高维隐状态解码机制，利用任务特定 token 显式捕捉最终 Transformer 层中的动态轨迹。通过联合整合全局图像特征与其他嵌入向量，该机制提升了动作的时间连续性。 解码机制的详细过程在 Algorithm 1 中描述。特殊 token < `trajectory` > 仅在任务调度场景中被预测，此时需要输出坐标，从而在统一框架内实现端到端训练。

具体而言，令 h_{tra} 表示最后一层中 < `trajectory` > token 的嵌入向量。我们将轨迹解码器的内部计算定义如下：

$$h_0 = \phi_{latent}(h_{\text{tra}}), \tag{5}$$

其中 ϕ_{latent} 为线性投影。将潜在向量投影到隐状态空间，以获得初始隐状态 h_0 ，用于编码当前环境的上下文特征。在每个时间步 t ，解码器更新隐状态并预测下一个轨迹状态，公式如下：

$$h_t = \text{GRUCell}(f_t, h_{t-1}), \tag{6}$$

其中 h_t 表示更新后的隐状态，f_t 由前一点的 256 维嵌入、全局视觉特征、目标位置以及初始隐状态 h_0 拼接而成，这些均通过线性投影获得。

然后，通过输出投影层从隐状态预测下一个轨迹状态：

$$S_t = \phi_{output}(h_t), \tag{7}$$

其中 ϕ_{output} 是一个线性的投影，用于预测下一个点的偏移量。在每一步预测的轨迹状态都会被追加到相应的轨迹序列 S 中。我们将终止距离阈值设置为 1e-3，并根据场景中最长轨迹来定义最大步数。当任一条件满足时，环即终止。

约束损失由两个部分组成：用于文本预测的交叉熵损失 L_{txt}，以及对每个轨迹点应用的均方误差损失 L_{mse}。整体目标是它们的加权和：

$$L = \lambda_{\text{txt}} L_{\text{txt}} + \lambda_{\text{mse}} L_{\text{mse}}, \tag{8}$$

其中系数设置为 $\lambda_{\text{txt}} = 1$ 和 $\lambda_{\text{mse}} = 5$。

4.2 训练方法学

RingMo-智能体采用两阶段训练方法，包括视觉-语言生成阶段和指令微调阶段。

在视觉-语言生成阶段，主要目标是将模型从自然场景理解适应到遥感（RS）图像领域。原始的预训练权重难以处理复杂的遥感场景，常常将多个不同物体误识别为单一实体，这使得其在细粒度识别任务中表现不足。为解决此问题，我们采用配对的遥感图像-文本数据进行生成式训练。在此过程中，我们使用图像-文本配对数据集，通过大模型（LLMs）的生成损失实现优化。数据来源于公开可用的分类、描述生成和检测数据集 [53, 54, 60, 61, 63–65, 75–79]。对于本文实验所涉及的所有数据集，我们仅使用训练集。为了增强语言多样性同时保持语义准确性，我们使用 GPT-4 [9] 扩展原始标注，施加如生成句子必须包含原始真实值等约束。此外，我们采用基于规则的提取方法，验证生成的描述是否准确反映原始标签。在指令微调阶段，模型被优化以生成与给定指令一致的输出，确保任务执行的准确性。

5 实验

本节详细描述了训练过程，并通过定性和定量分析，对指令微调模型在感知任务（检测、视觉问答、分类、图像描述）和推理任务（关系推理、任务调度、指令分解、动作决策）上的表现进行了评估。

在报告的结果中，FT 表示微调结果，而 ZS 指的是 zero-shot 结果。**加粗**表示最佳性能，<u>下划线</u> 表示第二佳。

5.1 实验情景

在视觉-语言生成阶段，我们使用 8 块 NVIDIA A100 GPU（每块 80 GB）训练模型，优化器采用 AdamW。学习率采用线性预热后接余弦衰减的调度策略，初始学习率为 1e-4，预热阶段学习率为 1e-6，极小学习率为 1e-5。我们施加 0.05 的权重衰减以实现正则化，并在超过 50 万样本上训练模型 10 轮次，图像大小固定为 384。

在指令微调阶段，RingMo-Agent 采用线性预热后接余弦衰减的学习率调度策略。训练过程中使用 AdamW 优化器，初始学习率为 1e-6，预热阶段从 1e-8 开始，最低学习率衰减至 0。为进一步提升模型泛化能力并缓解过拟合问题，在整个优化过程中应用了 0.05 的权重衰减。在此阶段，不对图像分辨率施加限制，保留每个样本的原始维度。模型共训练 10 轮次。合并的训练集、验证集和测试集包含超过 300 万个样本，统称为 RS-VL3M。在用于报告准确率的评估数据集上，除了零样本设置外，我们还进行了分离的微调实验。

5.2 任务调度

数据集。 我们使用 CityNav 数据集 [57]，该数据集包含 34 种多样的城市场景环境。该数据集涵盖了广泛的目標物体类别。

指标. 我们在所有三个测试分割上进行评估。遵循 CityNav [57]，使用四个指标来评估生成轨迹的准确率：导航误差（NE）、成功率（SR）、最优成功率（OSR）以及按路径长度加权的成功率（SPL）。

表 3: CityNav 数据集上的评估结果。

Model	Validation Seen				Validation Unseen				Test Unseen			
	NE ↓	SR ↑	OSR ↑	SPL ↑	NE ↓	SR ↑	OSR ↑	SPL ↑	NE ↓	SR ↑	OSR ↑	SPL ↑
Specialist models												
Seq2Seq (FT) [80]	257.1	1.81	7.89	1.58	317.4	0.79	8.82	0.61	245.3	1.50	8.34	1.30
CMA (FT) [81]	240.8	0.95	9.42	0.92	268.8	0.65	7.86	0.63	252.6	0.82	9.70	0.79
AerialVLN + GSM (FT) [57]	**56.6**	**10.16**	**22.20**	**7.89**	**72.7**	**6.35**	**15.24**	**5.06**	**85.1**	**6.72**	**18.21**	**5.16**
RSVLMs												
RingMo-Agent (FT)	132.0	5.89	21.39	5.24	156.0	4.91	17.22	4.33	149.6	4.74	18.94	4.17

结果. 如图 Table 3所示，RingMo-智能体的表现优于微调的 Seq2Seq [80] 和 CMA [81]，且接近于融合了地图编码和多视角特征的 AerialVLN [57] 的性能。与 AerialVLN 不同，我们仅依赖内部特征，无需外部地图先验即可取得具有竞争力的结果，在未见过的验证集上仅有 1.44% 的成功率差距。当前通用视觉-语言模型（VLM）和遥感视觉-语言模型（RSVLM）在完成这一复杂的空间导航任务时仍存在困难。

5.3 动作决策

数据集。我们在 SkyAgent-Plan3k [50] 数据集上评估该任务，该数据集包含四种不同的城市场景类型：上海、深圳、校园和住宅区。

指标。为了评估生成的逐步动作计划的质量，我们采用 BLEU 和 SPICE 作为评估指标。

结果。 如 Table 4 所示，我们的方法在所有场景类别中均明显优于基准方法。现有的 RSVLM 仍未探索在多图像输入引导下的三维空间推理能力。这些结果验证了我们的模型在弥合视觉-语言推理与可执行控制之间差距方面的有效性。

表 4: SkyAgent-Plan3k 数据集上的评估结果。

Model	ShangHai		ShenZhen		Campus		Residence	
	BLEU-1 ↑	SPICE ↑	BLEU-1 ↑	SPICE ↑	BLEU-1↑	SPICE ↑	BLEU-1 ↑	SPICE ↑
VLMs								
InstructBLIP-Flan-T5-XXL (ZS) [26]	0.04	5.79	0.03	4.23	0.95	4.58	0.14	7.20
InstructBLIP-Vicuna-7B (ZS) [26]	0.15	0.68	0.04	3.23	0.74	1.21	0.18	1.86
InstructBLIP-Vicuna-13B (ZS) [26]	0.12	1.14	0.34	2.18	0.63	0.46	0.07	1.51
MiniGPT-4 (ZS) [82]	12.88	4.03	13.96	4.51	16.89	4.25	15.85	4.51
GPT-4o (ZS) [34]	10.64	5.12	11.52	5.20	11.67	5.03	11.83	4.83
Qwen-VL (ZS) [36]	15.74	5.41	15.36	5.06	12.18	3.10	10.01	3.75
RSVLMs								
SkyAgent (FT) [50]	**40.87**	26.53	36.05	24.04	34.03	22.57	42.56	24.29
RingMo-Agent (FT)	37.33	**31.68**	**37.76**	**31.85**	**42.79**	**28.45**	**42.78**	**37.68**

5.4 关系推理

数据集. 我们在两个关系推理数据集上进行评估实验：FIT-RS 数据集 [19] 和我们自构建的 ReCon1M-REL 数据集。FIT-RS 数据集包含 54 种关系类别，所有图像均裁剪为固定分辨率 512× 512。相比之下，ReCon1M-REL 保留了 59 种关系类别，并采用可变分辨率。

指标。我们使用 F1 得分来评估此任务。

表 5: 在 FIT-RS 和 ReCon1M-REL 数据集上的评估结果。

Model	FIT-RS	ReCon1M-REL
	F1-score ↑	F1-score ↑
VLMs		
MiniGPT-v2 (ZS) [27]	0.00	0.00
DeepSeek-VL2 (ZS) [40]	0.06	0.30
Kosmos-2 (ZS) [28]	0.00	0.15
Shikra (ZS) [29]	0.52	0.65
Qwen3-VL (ZS) [38]	0.00	4.56
Gemini 2.5 (ZS) [33]	0.41	1.36
GPT-4o (ZS) [34]	3.32	3.04
RSVLMs		
SkySenseGPT (FT) [19]	74.33	-
RingMo-Agent (FT)	**75.34**	**90.23**

结果。如 Table 5所示，RingMo-智能体表现出优越的性能，准确率达到 75.34%，略高于 SkySenseGPT [19] 获得的 74.33%。在 ReCon1M-REL 数据集上，我们的 F1 得分达到了 90.23%。相比之下，最先进的视觉语言模型 [33, 34, 38] 即使在提供更明确提示的情况下，仍然无法有效完成此类任务。这一局限性主要源于缺乏针对宽视野图像中对象间关系推理的针对性训练，从而导致性能显著下降。

5.5 指令分解

数据集。我们在自构建的 ReCon1M-DEC 数据集上评估我们的模型。

指标. 为了全面评估性能，我们使用 mAP@50 和 F1 得分来评估模型，其中 mAP@50 衡量的是交并比阈值为 0.5 时的平均准确率，F1 得分则用于衡量模型的综合表现。

表 6: ReCon1M-DEC 数据集上的评估结果。

Model	mAP@50 ↑	F1-Score ↑
VLMs		
MiniGPT-v2 (ZS) [27]	0.00	0.00
DeepSeek-VL2 (ZS) [40]	0.00	0.00
Qwen3-VL (ZS) [38]	0.28	0.03
Gemini 2.5 (ZS) [33]	0.50	0.07
GPT-4o (ZS) [34]	0.14	0.13
RSVLMs		
RingMo-Agent (FT)	**24.20**	**32.85**

结果. Table 6 报告目标识别准确率和目标区域内的关系推理性能。我们采用精心设计的提示来评估先进的视觉语言模型作为基准。如图所示，现有视觉语言模型表现出显著较低的准确率，这主要是由于在大范围场景中对目标类别、空间位置以及目标间关系的训练关注不足。因此，当存在多个目标时，这些模型通常仅预测一到两个实例，无法反映真实的目标多重性。相比之下，RingMo-Agent 通过捕捉小目标的细粒度特征并生成正确的单对单关系预测，有效处理了具有挑战性的 ReCon1M-DEC 数据集，实现了 24.20% 的目标检测 mAP@50 和 32.85% 的区域内关系检测 F1 得分。

5.6 图像描述

数据集. 我们在光学、SAR 和红外模态上分别进行评估。光学数据集采用 UCM-Captions [60] 和 NWPU-Captions [62]，而 SAR 和红外模态则在我们自构建的数据集上进行测试。

指标。性能使用 BLEU、METEOR、ROUGE-L 和 CIDEr 指标进行报告。

表 7: SAR-CAP 和 IR-CAP 数据集上的评估结果。

Model	SAR-CAP						IR-CAP					
	BLEU-1 ↑	BLEU-2 ↑	BLEU-3 ↑	BLEU-4 ↑	METEOR ↑	ROUGE-L ↑	BLEU-1 ↑	BLEU-2 ↑	BLEU-3 ↑	BLEU-4 ↑	METEOR ↑	ROUGE-L ↑
VLMs												
MiniGPT-v2 (ZS) [27]	7.00	3.64	1.59	0.60	7.67	9.25	5.65	3.35	1.92	0.98	7.62	8.67
DeepSeek-VL2 (ZS) [40]	12.52	5.88	1.88	0.60	10.65	14.10	13.95	7.57	3.47	1.43	12.48	15.12
Qwen3-VL (ZS) [38]	12.51	5.70	1.43	0.42	11.74	12.85	7.62	4.30	1.91	0.82	8.43	9.90
Gemini 2.5 (ZS) [33]	13.00	5.43	1.81	0.77	12.46	13.23	17.70	7.76	3.17	1.32	14.14	17.99
GPT-4o (ZS) [34]	19.93	9.76	3.14	1.15	13.52	19.24	28.05	14.43	6.15	2.41	16.23	26.76
RSVLMs												
RingMo-Agent (FT)	**55.93**	**44.49**	**33.57**	**23.94**	**25.06**	**51.12**	**56.84**	**40.45**	**29.17**	**21.50**	**26.15**	**43.13**

结果. 如 Table 8 和 Table 9 所示，RingMo-智能体在 UCM-Captions [60] 与 NWPU-Captions [62] 光学图像描述生成基准上始终优于专用模型和多模态视觉语言模型（VLM）。在 UCM-Captions 基准上，其 METEOR 得分为 51.79，ROUGE-L 得分为 85.51，CIDEr 得分为 373.68，超越了现有 RSVLM。此外，在 SAR 与红外图像描述生成基准（Table 7）上，RingMo-智能体相较于 Qwen3-VL [38] 等先进 VLM 显现出明显优势。这一性能差距源于这些模型在多模态遥感数据，尤其是 SAR 图像上的训练不足；具体而言，它们常将船只和飞机等目标错误分类为恒星。

表 8: UCM 数据集上的评估结果。

Model	BLEU-4 ↑	METEOR ↑	ROUGE-L ↑	CIDEr ↑
Specialist models				
SAA (FT) [83]	64.77	38.59	69.42	294.51
Post-processing (FT) [84]	62.62	40.80	74.06	309.64
VLMs				
MiniGPT-4 (ZS) [82]	18.10	33.36	41.37	0.03
Shikra (ZS) [29]	33.98	32.56	56.73	56.69
MiniGPT-v2 (ZS) [27]	36.16	32.41	56.57	60.66
DeepSeek-VL2 (ZS) [40]	5.44	15.95	27.22	26.42
Qwen3-VL (ZS) [38]	1.82	15.73	24.92	8.85
Gemini 2.5 (ZS) [33]	2.78	17.05	25.96	11.74
GPT-4o (ZS) [34]	3.33	15.37	26.31	21.13
RSVLMs				
RSGPT (FT) [23]	65.74	42.21	78.34	333.23
RingMoGPT (FT) [22]	-	49.90	83.29	359.32
RS-CapRet (FT) [16]	67.00	47.20	81.70	354.80
RS-LLaVA (FT) [24]	72.84	47.98	85.17	349.43
SkyEyeGPT (FT) [18]	**78.41**	46.24	79.49	236.75
RingMo-Agent (FT)	77.63	**51.79**	**85.51**	**373.68**

表 9: 在 NWPU-Captions 数据集上的 zero-shot 结果。

Model	METEOR ↑	ROUGE-L ↑	CIDEr ↑
VLMs			
Qwen-VL [36]	12.60	26.24	24.64
MiniGPT-v2 [27]	13.70	26.60	19.70
LLaVA [85]	13.70	28.80	32.60
DeepSeek-VL2 [40]	14.88	19.56	3.18
Qwen3-VL [38]	15.92	23.91	7.72
Gemini 2.5 [33]	16.17	24.00	8.40
GPT-4o [34]	15.93	27.33	15.33
RSVLMs			
RingMoGPT [22]	**20.90**	**37.50**	**74.70**
RingMo-Agent	18.81	34.11	48.39

5.7 VQA

数据集。我们报告了在 RSVQA-LR [51] 测试集上的微调结果以及在 RSVQA-HR [51] 上的 zero-shot 结果。这些基准测试评估了模型理解物体类型、数量和空间位置的能力。

指标。我们计算每种题型的准确率以及总体平均准确率。

结果. Table 10 展示了在 RSVQA-LR 上的结果，重点关注两种问题类型：存在性问题和比较性问题。与其他方法相比，我们在存在性问题上达到了 93.10% 的准确率，比 RS-LLaVA [24] 高出 0.3%。Table 11 表明，我们在存在性问题上的准确率为 75.24%，比较性问题上的准确率为 83.92%，整体平均准确率为 79.58%。此外，我们的模型在两个数据集上均持续优于视觉语言模型（VLMs），进一步证明了其在遥感（RS）应用中的适用性。

5.8 分类

数据集。我们报告了在 AID [52] 和 NWPU-RESISC45 [63] 数据集上的结果，以及我们自构建的 IR-CLA 和 SAR-CLA 数据集的结果，并提供了在 UCMerced-LandUse [65] 和 WHU-RS19 [64] 上的 zero-shot 结果。

指标. 对于光学数据集，遵循 GeoChat [20] 的方法，使用所有类别作为候选答案，以防止同义输出。对于红外和 SAR 数据集，所有类别均作为候选答案提供给视觉语言模型。

表 10: RSVQA-LR 数据集上的评估结果。

Model	Pre. Acc ↑	Comp. Acc ↑	Avg. Acc ↑
Specialist models			
EasyToHard (FT) [86]	90.66	87.49	89.08
Bi-Modal (FT) [87]	91.06	91.16	91.11
SHRNet (FT) [88]	91.03	90.48	90.76
VLMs			
MiniGPT-4 (ZS) [82]	43.86	57.55	50.71
Shikra (ZS) [29]	46.47	60.31	53.39
Qwen-VL (ZS) [36]	38.57	67.59	53.08
MiniGPT-v2 (ZS) [27]	49.85	63.09	56.47
InstructBLIP (ZS) [26]	48.83	65.92	57.38
mPLUG-Owl2 (ZS) [89]	74.04	63.69	68.87
LLaVA-1.5 (ZS) [90]	55.46	68.20	61.83
DeepSeek-VL2 (ZS) [40]	55.33	66.87	61.10
Qwen3-VL (ZS) [38]	66.53	77.49	72.01
Gemini 2.5 (ZS) [33]	67.99	72.77	70.38
GPT-4o (ZS) [34]	69.20	63.14	66.17
RSVLMs			
RSGPT (FT) [23]	91.17	**91.70**	91.44
Geochat (FT) [20]	91.09	90.33	90.71
LHRS-Bot (FT) [17]	89.07	88.51	88.79
H^2RSVLM (FT) [21]	89.58	89.79	89.69
RS-LLaVA (FT) [24]	92.80	91.33	**92.07**
SkyEyeGPT (FT) [18]	88.93	88.63	88.78
RingMo-Agent (FT)	**93.10**	87.50	90.30

表 11: RSVQA-HR 数据集上的 zero-shot 结果。

Model	Pre. Acc ↑	Comp. Acc ↑	Avg. Acc ↑
VLMs			
Qwen-VL (ZS) [36]	66.44	60.41	63.43
LLaVA-v1.5 [85]	69.83	67.29	68.56
MiniGPT-v2 [27]	40.79	50.91	45.85
RSVLMs			
EarthGPT [14]	62.77	79.53	71.15
Geochat [20]	58.45	83.19	70.82
H^2RSVLM [21]	65.00	83.70	74.35
SkySenseGPT [19]	69.14	**84.14**	76.64
RingMo-Agent	**75.24**	83.92	**79.58**

结果. 如 Table 12所示，RingMo-智能体在光学任务上表现出色，在 NWPU-RESISC45 数据集上达到了 93.96% 的准确率。在 zero-shot 设置的 UCMerced-LandUse 数据集上，我们取得了 86.52% 的性能，超越了其他 RSVLM，如 Table 13所示。这一提升归因于模型强大的泛化能力。

5.9 目标检测

数据集。 RingMo-智能体支持跨三种模态的目标检测：光学、SAR 和红外。SAR 结果在 SARDet-100k [59] 上报告，红外结果在我们的 IR-DET 数据集上报告。

指标。我们使用 mAP@50 报告每个类别的以及总体的检测性能。

结果. 如图 Table 16和 Table 15所示，RingMo-智能体在合成孔径雷达（SAR）和红外目标检测任务中显著优于现有模型。尽管采用了先进的通用视觉语言模型（VLM）作为基准，并在自然图像上展现出强大的检测能力，但在遥感特定模态数据上表现不佳。例如，Qwen3-VL [38] 常将 SAR 图像误解读为黑暗或灰色天空场景，反映出其对 SAR 成像特性的理解不足。在 IR-DET 数据集上，这些模型仅能部分识别车辆、卡车等

表 12: AID 和 NWPU-RESISC45 数据集上的评估结果。

Model	AID (Acc ↑)	NWPU-RESISC45 (Acc ↑)
Specialist models		
LSENet (FT) [91]	**94.41**	93.34
SeCo-ResNet-50 (FT) [92]	93.47	92.91
VLMs		
MiniGPT-4 (ZS) [82]	43.86	57.55
DeepSeek-VL2 (ZS) [40]	35.63	17.60
Qwen3-VL (ZS) [38]	70.71	71.01
Gemini 2.5 (ZS) [33]	37.97	68.58
GPT-4o (ZS) [34]	58.33	50.52
RSVLMs		
EarthGPT (FT) [14]	-	93.84
RingMo-Agent (FT)	92.43	**93.96**

表 13: 在 WHU-RS19 和 UCMerced-LandUse 数据集上的 zero-shot 结果。

Model	WHU-RS19 (Acc ↑)	UCMerced-LandUse (Acc ↑)
VLMs		
Qwen-VL [36]	83.51	62.90
MiniGPT-v2 [27]	62.08	4.76
LLaVA [85]	74.52	68.00
CLIP [93]	87.50	–
DeepSeek-VL2 [40]	69.05	32.00
Qwen3-VL [38]	82.39	77.81
Gemini 2.5 [33]	47.56	65.10
GPT-4o [34]	85.27	43.52
RSVLMs		
RemoteCLIP [49]	94.66	-
GeoChat [20]	86.47	84.43
RingMoGPT [22]	**97.71**	86.48
SkySenseGPT [19]	97.02	-
RingMo-Agent	95.28	**86.52**

表 14: SAR-CLA 和 IR-CLA 数据集上的评估结果。

Model	SAR-CLA	IR-CLA
	Acc ↑	Acc ↑
VLMs		
DeepSeek-VL2 (ZS) [40]	5.22	95.56
Qwen3-VL (ZS) [38]	29.38	98.21
Gemini 2.5 (ZS) [33]	37.89	97.55
GPT-4o (ZS) [34]	36.74	98.42
RSVLMs		
RingMo-Agent (FT)	**92.67**	**99.45**

常见物体，而在大多数类别上性能接近于零。这种性能下降主要源于自然 RGB 图像与非光学遥感数据（如 SAR 和红外图像）之间存在的严重模态偏移，其物理成像机制和视觉模式与视觉语言模型预训练阶段所见内容存在根本差异。

5.10 消融研究

为了评估 RingMo-Agent 中关键设计组件的有效性，我们从三个角度进行消融实验：(1) 两阶段训练范式的影响，(2) 模态特定嵌入层的作用，(3) 轨迹解码器的功能。

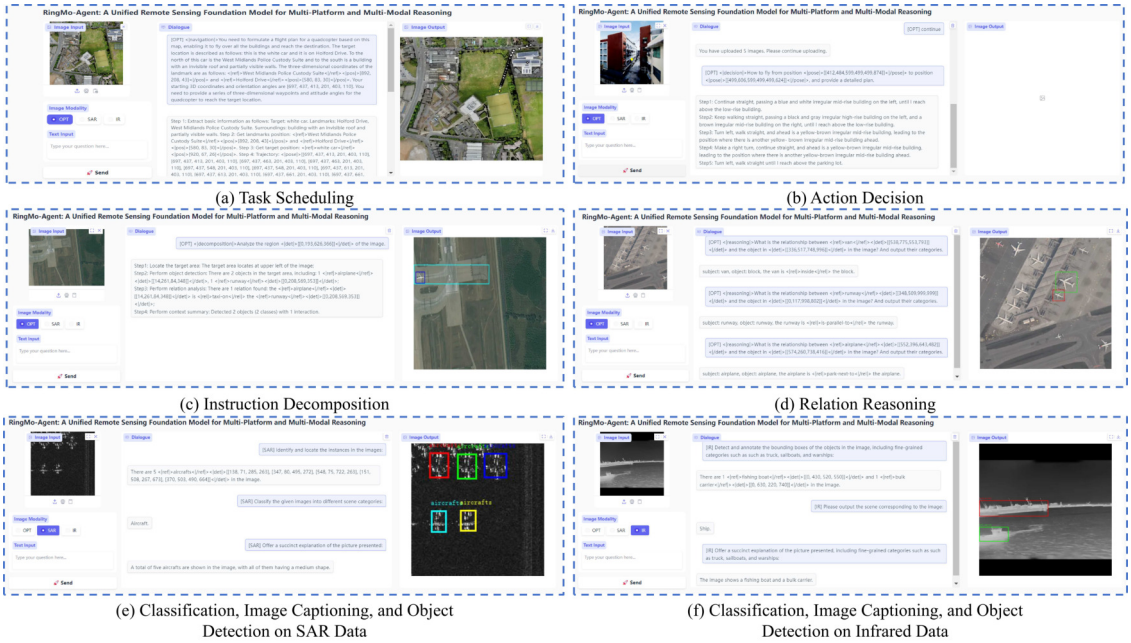

(a) Task Scheduling (b) Action Decision

(c) Instruction Decomposition (d) Relation Reasoning

(e) Classification, Image Captioning, and Object Detection on SAR Data (f) Classification, Image Captioning, and Object Detection on Infrared Data

图 5: RingMo 智能体针对用户关于图像内容的提问所呈现的视觉结果。

表 15: IR-DET 数据集上的评估结果。

Model	Fine-Grained Categories											Coarse-Grained Categories					mAP@50 ↑
	Bulk Carrier	Bus	Canoe	Container Ship	Fishing Boat	Liner	Nonmotor Vehicle	Other Vehicle	Sailboat	Truck	Warship	Bike	Cyclist	People	Ship	Vehicle	
VLMs																	
MiniGPT-v2 (ZS) [27]	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
DeepSeek-VL2 (ZS) [40]	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Kosmos-2 (ZS) [28]	0.00	8.75	0.00	0.00	0.00	0.00	0.00	0.00	3.96	1.78	0.00	0.00	0.00	1.23	2.13	7.76	1.60
shikra (ZS) [29]	0.00	1.81	0.00	0.00	0.00	0.00	0.31	0.00	0.91	0.52	0.00	0.00	0.00	0.95	0.28	0.73	0.34
Qwen3-VL (ZS) [38]	0.00	13.34	0.00	0.00	0.00	0.90	0.15	0.00	8.85	16.06	13.01	0.00	0.00	1.35	6.17	19.11	4.93
Gemini 2.5 (ZS) [33]	0.00	28.79	0.00	0.00	0.00	1.18	0.14	0.00	2.18	13.95	24.82	0.00	0.50	8.26	2.27	22.70	6.55
GPT-4o (ZS) [34]	0.00	0.25	0.00	0.00	0.00	0.00	0.00	0.00	0.02	0.02	0.00	0.00	0.00	0.00	0.00	0.03	0.02
RSVLMs																	
RingMo-Agent (FT)	**70.63**	**21.25**	**74.43**	**59.77**	**91.47**	**87.03**	**78.11**	**62.71**	**70.80**	**39.61**	**89.66**	**35.95**	**16.61**	**53.67**	**42.52**	**63.83**	**59.88**

表 16: SARDet-100k 数据集上的评估结果。

Model	Ship	Aircraft	Bridge	Harbor	Car	Tank	mAP@50 ↑
VLMs							
MiniGPT-v2 (ZS) [27]	0.00	0.00	0.00	0.00	0.00	0.00	0.00
DeepSeek-VL2 (ZS) [40]	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Kosmos-2 (ZS) [28]	0.27	0.17	0.00	0.00	0.04	0.00	0.08
shikra (ZS) [29]	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Qwen3-VL (ZS) [38]	0.89	0.09	0.00	0.00	0.33	0.00	0.22
Gemini 2.5 (ZS) [33]	1.46	0.14	0.00	0.00	0.00	0.00	0.27
GPT-4o (ZS) [34]	0.03	0.00	0.00	0.00	0.00	0.00	0.01
RSVLMs							
RingMo-Agent (FT)	**74.43**	**52.93**	**49.90**	**62.30**	**63.37**	**20.10**	**53.84**

两阶段训练。我们在大规模遥感图像-文本数据集上对 RingMo-Agent 进行预训练，以提升图像-文本生成能力。为评估其影响，我们将其与一个未经过预训练、从 DeepSeek-VL2 初始化的基准模型进行比较，使用相同的数据集和训练策略。如 Table 17 和 Table 18 所示，两阶段训练在推理和感知任务上均持续提升了性能。这一提升源于模型捕捉遥感特定特征（如分辨率、视角和光谱差异）的能力，从而增强了泛化能力。

模态特定嵌入层。我们对光学、SAR 和红外模态分别进行微调分离的嵌入层，训练和推理过程中由模态标签引导。仅更新嵌入层，而视觉编码器其余部分保持冻结。如 Table 19 所示，冻结这些层并移除模态特定设计会降低性能，凸显专用提取器的重要性。尽管结构完全相同，分离的嵌入能更好地捕捉模态特定特征，避免因强制异构数据通过共享滤波器而导致的特征退化。

表 17: 两阶段训练对推理任务影响的消融实验结果。

Model	Relation Reasoning		Instruction Decomposition	
	FIT-RS (F1-score ↑)	ReCon1M-REL (F1-score ↑)	ReCon1M-DEC (mAP@50 ↑)	ReCon1M-DEC (F1-score ↑)
RingMo-Agent (one stage)	72.82	87.11	16.72	20.32
RingMo-Agent (two stage)	**75.34**	**90.23**	**24.20**	**32.85**

表 18: 两阶段训练对感知任务影响的消融实验结果。

Model	Object Detection		Image Captioning			VQA
	SARDet-100k (mAP@50 ↑)	IR-DET (mAP@50 ↑)	UCM (BLEU-4 ↑)	SAR-CAP (BLEU-1 ↑)	IR-CAP (BLEU-1 ↑)	RSVQA-LR (Avg. Acc ↑)
RingMo-Agent (one stage)	50.12	51.56	76.12	50.12	49.16	89.96
RingMo-Agent (two stage)	**53.84**	**59.88**	**77.63**	**55.93**	**56.84**	**90.30**

表 19: 模态特异性嵌入层影响的消融实验结果，其中 MSEL 表示模态特异性嵌入层。

Model	MSEL	Object Detection		Image Captioning			Image Classification	
		SARDet-100k (mAP@50 ↑)	IR-DET (mAP@50 ↑)	UCM (BLEU-4 ↑)	SAR-CAP (BLEU-1 ↑)	IR-CAP (BLEU-1 ↑)	SAR-CLA (Acc ↑)	IR-CLA (Acc ↑)
RingMo-Agent	×	48.10	51.23	74.11	46.32	51.08	88.17	96.60
RingMo-Agent	✓	**53.84**	**59.88**	**77.63**	**55.93**	**56.84**	**92.67**	**99.45**

表 20: 轨迹解码器影响的消融实验结果。

Model	Trajectory Decoder	Validation Seen				Validation Unseen				Test Unseen			
		NE ↓	SR ↑	OSR ↑	SPL ↑	NE ↓	SR ↑	OSR ↑	SPL ↑	NE ↓	SR ↑	OSR ↑	SPL ↑
RingMo-Agent	×	196.4	2.65	14.23	2.16	220.1	1.94	12.36	1.91	187.9	1.57	13.16	1.22
RingMo-Agent	✓	**132.0**	**5.89**	**21.39**	**5.24**	**156.0**	**4.91**	**17.22**	**4.33**	**149.6**	**4.74**	**18.94**	**4.17**

轨迹解码器。为解决大模型在逐点生成轨迹时面临的损失不平衡和序列约束难以满足等问题，我们额外设计了一个专用于任务调度的轨迹解码器。在 Table 20中，我们还对比了不使用轨迹解码器的情况，此时模型通过逐个预测 token 来输出每个点的六维坐标。在 CityNav 数据集 [57] 上的实验结果表明，轨迹解码器有效提升了模型在已见和未见场景下的表现。

5.11 可视化

为了更清晰地理解模型行为，本文展示了代表性结果的可视化，如 Figure 5所示。这些包括任务调度（a)、动作决策（b)、指令分解（c)、关系推理（d)，以及对 SAR 和红外数据的分类、描述生成和检测（e, f)。此外，Figure 6提供了可视化示例以展示对话交互过程。

6 结论

在本工作中，我们提出了 RingMo-Agent，一种专为跨平台、多模态遥感（RS）数据设计的统一基础模型。该模型能够处理具有不同视角和传感特性的图像，并执行复杂的推理任务。该模型得益于以下几个关键支持：一个包含超过 300 万张图像-文本对的大规模数据集 RS-VL3M；构建分离的嵌入层以解决不同模态间的分布差异，并隔离特征抽取过程；以及引入基于 token 的高维隐状态解码机制，用于长时序空间任务，显著扩展了任务覆盖范围。我们预期未来的遥感智能体将进一步提升深层次逻辑推理能力，从而支持灾害响应等紧急场景中的损伤评估与决策制定等实际应用。

Examples

Image	Task	Question	Answer
	Image Captioning	[SAR] Offer a succinct explanation of the picture presented:	This image shows five aircrafts on a runway.
	Image Classification	[IR] What is the scene category of the given image:	Ship.
	Object Detection	[OPT] Detect and annotate the bounding boxes of the objects in the image:	There are 4 <|ref|>aircrafts<|/ref|><|det|>[[107, 149, 384, 533], [117, 544, 428, 922], [680, 213, 964, 604], [698, 615, 985, 989]]<|/det|> in the image.
	Visual Question Answer	[OPT] Question how can people improve their strength in this image? short answer:	Aerobic.
	Relation Reasoning	[OPT] <|reasoning|>What is the relationship between <|ref|>solar-panel<|/ref|><|det|>[[170,546,242,646]]<|/det|> and the object in <|det|>[[0,236,301,872]]<|/det|> in the image? And output their categories.	Subject: solar-panel, object: building, the solar-panel is <|rel|>power<|/rel|> the building.
	Instruction Decomposition	[OPT] <|decomposition|>Break down visual elements in region <|det|>[[343,641,586,739]]<|/det|>.	Step1: Locate the target area: The target area locates at lower area of the image; Step2: Perform object detection: There are 2 objects in the target area, including: 2 <|ref|>airplanes<|/ref|><|det|>[[365,651,446,732], [490,649,566,731]]<|/det|>; Step3: Perform relation analysis: There are 2 relations found: the <|ref|>airplane<|/ref|><|det|>[[490,649,566,731]]<|/det|> is <|rel|>park-next-to<|/rel|> the <|ref|>airplane<|/ref|><|det|>[[365,651,446,732]]<|/det|>, ...; Step4: Perform context summary: Detected 2 objects (1 class) with 2 interactions.
	Action Decision	[OPT] <|decision|> How to fly from position <|det|>[[719,749,439,499,499,874]]<|/det|> to position <|det|>[[352,470,439,499,499,998]]<|/det|>, and provide a detailed plan.	Step1: Go straight, passing a brown irregular mid-rise building on the right and a red irregular mid-rise building on the left, until I reach above the trees. Step2: Continue straight ahead towards a blue-brown irregular mid-rise building, reaching above a parking lot...
	Task Scheduling	[OPT] <|navigation|>You need to formulate a flight plan for a quadcopter based on this map, enabling it to fly over all the buildings and reach the destination. The target location is described as follows: The white car parked perpendicular to a bright blue car in the parking lot on the right side of the West Midlands Police Custody Suite on Holford Drive. The three-dimensional coordinates of the landmark are as follows: <|ref|>West Midlands Police Custody Suite<|/ref|><|pos|>[892, 208, 43]<|/pos|> and <|ref|>Holford Drive<|/ref|><|pos|>[580, 83, 30]<|/pos|>. Your starting 3D coordinates and orientation angles are [866, 944, 554, 226, 829, 242]. You need to provide a series of three-dimensional waypoints and attitude angles for the quadcopter to reach the target location.	Step 1: Extract basic information as follows: Target: white car. Landmarks: Holford Drive, West Midlands Police Custody Suite. Surroundings: bright blue car, parking lot. Step 2: Get landmarks position: <|ref|>West Midlands Police Custody Suite<|/ref|><|pos|>[892, 208, 43]<|/pos|> and <|ref|>Holford Drive<|/ref|><|pos|>[580, 83, 30]<|/pos|>. Step 3: Get target position: <|ref|>white car<|/ref|><|pos|>[798, 117, 22]<|/pos|>. Step 4: Trajectory: <|pose|>[[866, 944, 554, 226, 829, 242], ..., [801, 117, 27, 543, 821, 119]]<|/pose|>.

图 6: 为用户提供了可点击的任务示例，涵盖八个不同场景。

参考文献

[1] B. Lin, Y. Nie, Z. Wei, J. Chen, S. Ma, J. Han, H. Xu, X. Chang, and X. Liang, "Navcot: Boosting llm-based vision-and-language navigation via learning disentangled reasoning," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 47, no. 7, pp. 5945–5957, 2025.

[2] Z. Yu, X. Ouyang, Z. Shao, M. Wang, and J. Yu, "Prophet: Prompting large language models with complementary answer heuristics for knowledge-based visual question answering," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 47, no. 8, pp. 6797–6808, 2025.

[3] R. Xu, S. Yang, X. Wang, T. Wang, Y. Chen, J. Pang, and D. Lin, "Pointllm-v2: Empowering large language models to better understand point clouds," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pp. 1–15, 2025.

[4] D. Guo, D. Yang, H. Zhang, J. Song, R. Zhang, R. Xu, Q. Zhu, S. Ma, P. Wang, X. Bi *et al.*, "Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning," *arXiv preprint arXiv:2501.12948*, 2025.

[5] D. Dai, C. Deng, C. Zhao, R. Xu, H. Gao, D. Chen, J. Li, W. Zeng, X. Yu, Y. Wu *et al.*, "Deepseekmoe: Towards ultimate expert specialization in mixture-of-experts language models," *arXiv preprint arXiv:2401.06066*, 2024.

[6] A. Liu, B. Feng, B. Wang, B. Wang, B. Liu, C. Zhao, C. Dengr, C. Ruan, D. Dai, D. Guo *et al.*, "Deepseek-v2: A strong, economical, and efficient mixture-of-experts language model," *arXiv preprint arXiv:2405.04434*, 2024.

[7] A. Liu, B. Feng, B. Xue, B. Wang, B. Wu, C. Lu, C. Zhao, C. Deng, C. Zhang, C. Ruan *et al.*, "Deepseek-v3 technical report," *arXiv preprint arXiv:2412.19437*, 2024.

[8] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell *et al.*, "Language models are few-shot learners," *Advances in neural information processing systems*, vol. 33, pp. 1877–1901, 2020.

[9] J. Achiam, S. Adler, S. Agarwal, L. Ahmad, I. Akkaya, F. L. Aleman, D. Almeida, J. Altenschmidt, S. Altman, S. Anadkat *et al.*, "Gpt-4 technical report," *arXiv preprint arXiv:2303.08774*, 2023.

[10] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar *et al.*, "Llama: Open and efficient foundation language models," *arXiv preprint arXiv:2302.13971*, 2023.

[11] H. Touvron, L. Martin, K. Stone, P. Albert, A. Almahairi, Y. Babaei, N. Bashlykov, S. Batra, P. Bhargava, S. Bhosale *et al.*, "Llama 2: Open foundation and fine-tuned chat models," *arXiv preprint arXiv:2307.09288*, 2023.

[12] A. Grattafiori, A. Dubey, A. Jauhri, A. Pandey, A. Kadian, A. Al-Dahle, A. Letman, A. Mathur, A. Schelten, A. Vaughan *et al.*, "The llama 3 herd of models," *arXiv preprint arXiv:2407.21783*, 2024.

[13] X. Li, C. Wen, Y. Hu, Z. Yuan, and X. X. Zhu, "Vision-language models in remote sensing: Current progress and future trends," *IEEE Geoscience and Remote Sensing Magazine*, 2024.

[14] W. Zhang, M. Cai, T. Zhang, Y. Zhuang, and X. Mao, "Earthgpt: A universal multi-modal large language model for multi-sensor image comprehension in remote sensing domain," *IEEE Transactions on Geoscience and Remote Sensing*, 2024.

[15] W. Zhang, M. Cai, T. Zhang, G. Lei, Y. Zhuang, and X. Mao, "Popeye: A unified visual-language model for multi-source ship detection from remote sensing imagery," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2024.

[16] J. D. Silva, J. Magalhães, D. Tuia, and B. Martins, "Large language models for captioning and retrieving remote sensing images," *arXiv preprint arXiv:2402.06475*, 2024.

[17] D. Muhtar, Z. Li, F. Gu, X. Zhang, and P. Xiao, "Lhrs-bot: Empowering remote sensing with vgi-enhanced large multimodal language model," in *European Conference on Computer Vision*. Springer, 2024, pp. 440–457.

[18] Y. Zhan, Z. Xiong, and Y. Yuan, "Skyeyegpt: Unifying remote sensing vision-language tasks via instruction tuning with large language model," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 221, pp. 64–77, 2025.

[19] J. Luo, Z. Pang, Y. Zhang, T. Wang, L. Wang, B. Dang, J. Lao, J. Wang, J. Chen, Y. Tan *et al.*, "Skysensegpt: A fine-grained instruction tuning dataset and model for remote sensing vision-language understanding," *arXiv preprint arXiv:2406.10100*, 2024.

[20] K. Kuckreja, M. S. Danish, M. Naseer, A. Das, S. Khan, and F. S. Khan, "Geochat: Grounded large vision-language model for remote sensing," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 27 831–27 840.

[21] C. Pang, J. Wu, J. Li, Y. Liu, J. Sun, W. Li, X. Weng, S. Wang, L. Feng, G.-S. Xia *et al.*, "H2rsvlm: Towards helpful and honest remote sensing large vision language model," *CoRR*, 2024.

[22] P. Wang, H. Hu, B. Tong, Z. Zhang, F. Yao, Y. Feng, Z. Zhu, H. Chang, W. Diao, Q. Ye *et al.*, "Ringmogpt: A unified remote sensing foundation model for vision, language, and grounded tasks," *IEEE Transactions on Geoscience and Remote Sensing*, 2024.

[23] Y. Hu, J. Yuan, C. Wen, X. Lu, and X. Li, "Rsgpt: A remote sensing vision language model and benchmark," *arXiv preprint arXiv:2307.15266*, 2023.

[24] Y. Bazi, L. Bashmal, M. M. Al Rahhal, R. Ricci, and F. Melgani, "Rs-llava: A large vision-language model for joint captioning and question answering in remote sensing imagery," *Remote Sensing*, vol. 16, no. 9, p. 1477, 2024.

[25] J. Li, D. Li, S. Savarese, and S. Hoi, "Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models," in *International conference on machine learning*. PMLR, 2023, pp. 19 730–19 742.

[26] W. Dai, J. Li, D. Li, A. Tiong, J. Zhao, W. Wang, B. Li, P. N. Fung, and S. Hoi, "Instructblip: Towards general-purpose vision-language models with instruction tuning," *Advances in neural information processing systems*, vol. 36, pp. 49 250–49 267, 2023.

[27] J. Chen, D. Zhu, X. Shen, X. Li, Z. Liu, P. Zhang, R. Krishnamoorthi, V. Chandra, Y. Xiong, and M. Elhoseiny, "Minigpt-v2: large language model as a unified interface for vision-language multi-task learning," *arXiv preprint arXiv:2310.09478*, 2023.

[28] Z. Peng, W. Wang, L. Dong, Y. Hao, S. Huang, S. Ma, and F. Wei, "Kosmos-2: Grounding multimodal large language models to the world," *arXiv preprint arXiv:2306.14824*, 2023.

[29] K. Chen, Z. Zhang, W. Zeng, R. Zhang, F. Zhu, and R. Zhao, "Shikra: Unleashing multimodal llm's referential dialogue magic," *arXiv preprint arXiv:2306.15195*, 2023.

[30] X. Lai, Z. Tian, Y. Chen, Y. Li, Y. Yuan, S. Liu, and J. Jia, "Lisa: Reasoning segmentation via large language model," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 9579–9589.

[31] G. Team, R. Anil, S. Borgeaud, J.-B. Alayrac, J. Yu, R. Soricut, J. Schalkwyk, A. M. Dai, A. Hauth, K. Millican *et al.*, "Gemini: a family of highly capable multimodal models," *arXiv preprint arXiv:2312.11805*, 2023.

[32] G. Team, P. Georgiev, V. I. Lei, R. Burnell, L. Bai, A. Gulati, G. Tanzer, D. Vincent, Z. Pan, S. Wang *et al.*, "Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context," *arXiv preprint arXiv:2403.05530*, 2024.

[33] G. Comanici, E. Bieber, M. Schaekermann, I. Pasupat, N. Sachdeva, I. Dhillon, M. Blistein, O. Ram, D. Zhang, E. Rosen *et al.*, "Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities," *arXiv preprint arXiv:2507.06261*, 2025.

[34] A. Hurst, A. Lerer, A. P. Goucher, A. Perelman, A. Ramesh, A. Clark, A. Ostrow, A. Welihinda, A. Hayes, A. Radford *et al.*, "Gpt-4o system card," *arXiv preprint arXiv:2410.21276*, 2024.

[35] OpenAI, "Gpt-4o mini: advancing cost-efficient intelligence," Online, 2024, available: https://openai.com/zh-Hans-CN/index/gpt-4o-mini-advancing-cost-efficient-intelligence//.

[36] J. Bai, S. Bai, S. Yang, S. Wang, S. Tan, P. Wang, J. Lin, C. Zhou, and J. Zhou, "Qwen-vl: A versatile vision-language model for understanding, localization, text reading, and beyond," *arXiv preprint arXiv:2308.12966*, 2023.

[37] P. Wang, S. Bai, S. Tan, S. Wang, Z. Fan, J. Bai, K. Chen, X. Liu, J. Wang, W. Ge *et al.*, "Qwen2-vl: Enhancing vision-language model's perception of the world at any resolution," *arXiv preprint arXiv:2409.12191*, 2024.

[38] Y. C. Shuai Bai and R. C. et al., "Qwen3-vl technical report," *arXiv preprint arXiv:2511.21631*, 2025.

[39] L. Wang, H. Gao, C. Zhao, X. Sun, and D. Dai, "Auxiliary-loss-free load balancing strategy for mixture-of-experts," *arXiv preprint arXiv:2408.15664*, 2024.

[40] Z. Wu, X. Chen, Z. Pan, X. Liu, W. Liu, D. Dai, H. Gao, Y. Ma, C. Wu, B. Wang *et al.*, "Deepseek-vl2: Mixture-of-experts vision-language models for advanced multimodal understanding," *arXiv preprint arXiv:2412.10302*, 2024.

[41] L. Wang, C. Ma, X. Feng, Z. Zhang, H. Yang, J. Zhang, Z. Chen, J. Tang, X. Chen, Y. Lin *et al.*, "A survey on large language model based autonomous agents," *Frontiers of Computer Science*, vol. 18, no. 6, p. 186345, 2024.

[42] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, "Reflexion: Language agents with verbal reinforcement learning," *Advances in Neural Information Processing Systems*, vol. 36, pp. 8634–8652, 2023.

[43] Y. Shen, K. Song, X. Tan, D. Li, W. Lu, and Y. Zhuang, "Hugginggpt: Solving ai tasks with chatgpt and its friends in hugging face," *Advances in Neural Information Processing Systems*, vol. 36, pp. 38 154–38 180, 2023.

[44] T. Schick, J. Dwivedi-Yu, R. Dessì, R. Raileanu, M. Lomeli, E. Hambro, L. Zettlemoyer, N. Cancedda, and T. Scialom, "Toolformer: Language models can teach themselves to use tools," *Advances in Neural Information Processing Systems*, vol. 36, pp. 68 539–68 551, 2023.

[45] S. Hong, M. Zhuge, J. Chen, X. Zheng, Y. Cheng, J. Wang, C. Zhang, Z. Wang, S. K. S. Yau, Z. Lin *et al.*, "Metagpt: Meta programming for a multi-agent collaborative framework," in *The Twelfth International Conference on Learning Representations*, 2023.

[46] H. Hu, P. Wang, H. Bi, B. Tong, Z. Wang, W. Diao, H. Chang, Y. Feng, Z. Zhang, Y. Wang *et al.*, "Rs-vheat: Heat conduction guided efficient remote sensing foundation model," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2025, pp. 9876–9887.

[47] H. Bi, Y. Feng, B. Tong, M. Wang, H. Yu, Y. Mao, H. Chang, W. Diao, P. Wang, Y. Yu, H. Peng, Y. Zhang, K. Fu, and X. Sun, "Ringmoe: Mixture-of-modality-experts multi-modal foundation models for universal remote sensing image interpretation," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pp. 1–18, 2025.

[48] Y. Zhan, Z. Xiong, and Y. Yuan, "Rsvg: Exploring data and models for visual grounding on remote sensing data," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 61, pp. 1–13, 2023.

[49] F. Liu, D. Chen, Z. Guan, X. Zhou, J. Zhu, Q. Ye, L. Fu, and J. Zhou, "Remoteclip: A vision language foundation model for remote sensing," *IEEE Transactions on Geoscience and Remote Sensing*, 2024.

[50] F. Yao, Y. Yue, Y. Liu, X. Sun, and K. Fu, "Aeroverse: Uav-agent benchmark suite for simulating, pre-training, finetuning, and evaluating aerospace embodied world models," *arXiv preprint arXiv:2408.15511*, 2024.

[51] S. Lobry, D. Marcos, J. Murray, and D. Tuia, "Rsvqa: Visual question answering for remote sensing data," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 58, no. 12, pp. 8555–8566, 2020.

[52] G.-S. Xia, J. Hu, F. Hu, B. Shi, X. Bai, Y. Zhong, L. Zhang, and X. Lu, "Aid: A benchmark data set for performance evaluation of aerial scene classification," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 55, no. 7, pp. 3965–3981, 2017.

[53] K. Li, G. Wan, G. Cheng, L. Meng, and J. Han, "Object detection in optical remote sensing images: A survey and a new benchmark," *ISPRS journal of photogrammetry and remote sensing*, vol. 159, pp. 296–307, 2020.

[54] G.-S. Xia, X. Bai, J. Ding, Z. Zhu, S. Belongie, J. Luo, M. Datcu, M. Pelillo, and L. Zhang, "Dota: A large-scale dataset for object detection in aerial images," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 3974–3983.

[55] F. Wang, H. Wang, Z. Guo, D. Wang, Y. Wang, M. Chen, Q. Ma, L. Lan, W. Yang, J. Zhang *et al.*, "Xlrs-bench: Could your multimodal llms understand extremely large ultra-high-resolution remote sensing imagery?" in *Proceedings of the Computer Vision and Pattern Recognition Conference*, 2025, pp. 14 325–14 336.

[56] X. Li, J. Ding, and M. Elhoseiny, "Vrsbench: A versatile vision-language benchmark dataset for remote sensing image understanding," *Advances in Neural Information Processing Systems*, vol. 37, pp. 3229–3242, 2024.

[57] J. Lee, T. Miyanishi, S. Kurita, K. Sakamoto, D. Azuma, Y. Matsuo, and N. Inoue, "Citynav: A large-scale dataset for real-world aerial navigation," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2025, pp. 5912–5922.

[58] G. Cheng, J. Han, P. Zhou, and L. Guo, "Multi-class geospatial object detection and geographic image classification based on collection of part detectors," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 98, pp. 119–132, 2014.

[59] Y. Li, X. Li, W. Li, Q. Hou, L. Liu, M.-M. Cheng, and J. Yang, "Sardet-100k: Towards open-source benchmark and toolkit for large-scale sar object detection," *arXiv preprint arXiv:2403.06534*, 2024.

[60] B. Qu, X. Li, D. Tao, and X. Lu, "Deep semantic understanding of high resolution remote sensing image," in *2016 International conference on computer, information and telecommunication systems (Cits)*. IEEE, 2016, pp. 1–5.

[61] X. Lu, B. Wang, X. Zheng, and X. Li, "Exploring models and data for remote sensing image caption generation," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 56, no. 4, pp. 2183–2195, 2017.

[62] Q. Cheng, H. Huang, Y. Xu, Y. Zhou, H. Li, and Z. Wang, "Nwpu-captions dataset and mlca-net for remote sensing image captioning," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, pp. 1–19, 2022.

[63] G. Cheng, J. Han, and X. Lu, "Remote sensing image scene classification: Benchmark and state of the art," *Proceedings of the IEEE*, vol. 105, no. 10, pp. 1865–1883, 2017.

[64] G.-S. Xia, W. Yang, J. Delon, Y. Gousseau, H. Sun, and H. Maître, "Structural high-resolution satellite image indexing," in *ISPRS TC VII Symposium-100 Years ISPRS*, vol. 38, 2010, pp. 298–303.

[65] Y. Yang and S. Newsam, "Bag-of-visual-words and spatial extensions for land-use classification," in *Proceedings of the 18th SIGSPATIAL international conference on advances in geographic information systems*, 2010, pp. 270–279.

[66] X. Sun, Q. Yan, C. Deng, C. Liu, Y. Jiang, Z. Hou, W. Lu, F. Yao, X. Liu, L. Hao *et al.*, "Recon1m: A large-scale benchmark dataset for relation comprehension in remote sensing imagery," *arXiv preprint arXiv:2406.06028*, 2024.

[67] J. Suo, T. Wang, X. Zhang, H. Chen, W. Zhou, and W. Shi, "Hit-uav: A high-altitude infrared thermal dataset for unmanned aerial vehicle-based object detection," *Scientific Data*, vol. 10, no. 1, p. 227, 2023.

[68] Raytron Technology Co., Ltd., "Sea-shipping," Online, 2021, available: https://openai.raytrontek.com/apply/Sea_shipping.html/.

[69] ——, "Infrared-security," Online, 2021, available: https://openai.raytrontek.com/apply/Infrared_security.html/.

[70] ——, "Aerial-mancar," Online, 2021, available: http://openai.raytrontek.com/apply/Aerial_mancar.html/.

[71] ——, "Double-light-vehicle," Online, 2021, available: http://openai.raytrontek.com/apply/Double_light_vehicle.html/.

[72] Center for Optics Research and Engineering of Shandong University, "Oceanic-ship," Online, 2020, available: http://www.core.sdu.edu.cn/info/1133/2174.htm.

[73] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer, "Sigmoid loss for language image pre-training," in *Proceedings of the IEEE/CVF international conference on computer vision*, 2023, pp. 11 975–11 986.

[74] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen *et al.*, "Lora: Low-rank adaptation of large language models." *ICLR*, vol. 1, no. 2, p. 3, 2022.

[75] H. Li, X. Dou, C. Tao, Z. Wu, J. Chen, J. Peng, M. Deng, and L. Zhao, "Rsi-cb: A large-scale remote sensing image classification benchmark using crowdsourced data," *Sensors*, vol. 20, no. 6, p. 1594, 2020.

[76] Q. Zou, L. Ni, T. Zhang, and Q. Wang, "Deep learning based feature selection for remote sensing scene classification," *IEEE Geoscience and Remote Sensing Letters*, vol. 12, no. 11, pp. 2321–2325, 2015.

[77] P. Zhang, Y. Bai, D. Wang, B. Bai, and Y. Li, "Few-shot classification of aerial scene images via meta-learning," *Remote Sensing*, vol. 13, no. 1, p. 108, 2020.

[78] W. Zhou, S. Newsam, C. Li, and Z. Shao, "Patternnet: A benchmark dataset for performance evaluation of remote sensing image retrieval," *ISPRS journal of photogrammetry and remote sensing*, vol. 145, pp. 197–209, 2018.

[79] D. Hou, Z. Miao, H. Xing, and H. Wu, "Two novel benchmark datasets from arcgis and bing world imagery for remote sensing image retrieval," *International Journal of Remote Sensing*, vol. 42, no. 1, pp. 240–258, 2021.

[80] P. Anderson, Q. Wu, D. Teney, J. Bruce, M. Johnson, N. Sünderhauf, I. Reid, S. Gould, and A. Van Den Hengel, "Vision-and-language navigation: Interpreting visually-grounded navigation instructions in real environments," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 3674–3683.

[81] S. Liu, H. Zhang, Y. Qi, P. Wang, Y. Zhang, and Q. Wu, "Aerialvln: Vision-and-language navigation for uavs," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023, pp. 15 384–15 394.

[82] D. Zhu, J. Chen, X. Shen, X. Li, and M. Elhoseiny, "Minigpt-4: Enhancing vision-language understanding with advanced large language models," *arXiv preprint arXiv:2304.10592*, 2023.

[83] X. Lu, B. Wang, and X. Zheng, "Sound active attention framework for remote sensing image captioning," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 58, no. 3, pp. 1985–2000, 2019.

[84] G. Hoxha, G. Scuccato, and F. Melgani, "Improving image captioning systems with postprocessing strategies," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 61, pp. 1–13, 2023.

[85] H. Liu, C. Li, Q. Wu, and Y. J. Lee, "Visual instruction tuning," *Advances in neural information processing systems*, vol. 36, 2024.

[86] Z. Yuan, L. Mou, Q. Wang, and X. X. Zhu, "From easy to hard: Learning language-guided curriculum for visual question answering on remote sensing data," *IEEE transactions on geoscience and remote sensing*, vol. 60, pp. 1–11, 2022.

[87] Y. Bazi, M. M. Al Rahhal, M. L. Mekhalfi, M. A. Al Zuair, and F. Melgani, "Bi-modal transformer-based approach for visual question answering in remote sensing imagery," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, pp. 1–11, 2022.

[88] Z. Zhang, L. Jiao, L. Li, X. Liu, P. Chen, F. Liu, Y. Li, and Z. Guo, "A spatial hierarchical reasoning network for remote sensing visual question answering," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 61, pp. 1–15, 2023.

[89] Q. Ye, H. Xu, J. Ye, M. Yan, A. Hu, H. Liu, Q. Qian, J. Zhang, and F. Huang, "mplug-owl2: Revolutionizing multi-modal large language model with modality collaboration," in *Proceedings of the ieee/cvf conference on computer vision and pattern recognition*, 2024, pp. 13 040–13 051.

[90] H. Liu, C. Li, Y. Li, and Y. J. Lee, "Improved baselines with visual instruction tuning," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 26 296–26 306.

[91] Q. Bi, K. Qin, H. Zhang, and G.-S. Xia, "Local semantic enhanced convnet for aerial scene recognition," *IEEE Transactions on Image Processing*, vol. 30, pp. 6498–6511, 2021.

[92] O. Manas, A. Lacoste, X. Giró-i Nieto, D. Vazquez, and P. Rodriguez, "Seasonal contrast: Unsupervised pre-training from uncurated remote sensing data," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2021, pp. 9414–9423.

[93] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark *et al.*, "Learning transferable visual models from natural language supervision," in *International conference on machine learning*. PmLR, 2021, pp. 8748–8763.