https://hjfy.top/arxiv/2207.08051

SatMAE：用于时间序列与多光谱卫星影像的 Transformer 预训练

Yezhen Cong*
yzcong@stanford.edu

Samar Khanna*
samar.khanna@stanford.edu

Chenlin Meng

Patrick Liu **Erik Rozi** **Yutong He** **Marshall Burke** **David B. Lobell**

Stefano Ermon

Stanford University

Abstract

无监督预训练方法在大型视觉模型中已被证明能够提升下游监督任务的性能。针对卫星影像开发类似的预训练技术具有重大机遇，因为未标注数据极为丰富，且其固有的时序和多光谱结构为改进现有预训练策略提供了新途径。本文提出 SatMAE，一种基于掩码自编码器（MAE）的时序或多光谱卫星影像预训练框架。为了利用时序信息，我们在独立地对时间维度上的图像块进行掩码的同时，引入了时序嵌入。此外，我们还证明将多光谱数据以具有不同光谱位置编码的波段组形式进行编码是有效的。我们的方法在基准数据集上的监督学习性能（最高提升 ↑ 7%），以及在下游遥感任务中的迁移学习性能（包括土地覆盖分类，最高提升 ↑ 14%）和语义分割方面，均显著优于先前的最先进技术。代码和数据可在项目网站上获取：https://sustainlab-group.github.io/SatMAE/

1 引言

近年来，自监督学习技术已迅速成为在大规模自然图像数据集上预训练模型的常态 [1, 2, 3, 4, 5, 6, 7, 8]，并在图像分类 [3, 4, 9, 10]、图像分割 [3, 11]、表示学习 [12, 13, 14]、图像压缩 [12, 15]、图像重构 [1] 以及图像生成 [16] 等下游任务中展现出了强大的性能。与监督学习方法不同，自监督学习技术不需要人工标注，因此在未标记数据丰富但标注数据稀缺的情景（如遥感数据，例如卫星图像）中具有吸引力。尽管近年来已精心整理了多个大规模卫星图像数据集，包括全球功能图（fMoW）[17]、BigEarthNet [18]、xView [19]、SpaceNet [20]，但对这些数据集进行标注需要专业技能，且成本高于传统计算机视觉数据集。此外，对于贫困或作物产量预测 [21, 22, 23, 24, 25, 26, 27, 28, 29, 30] 等具有重大社会影响的任务，通常需要对卫星图像进行自动分析，而通过调查获取大量标注数据既不可行也成本过高。这表明针对卫星图像的自监督学习方法可能具有特别重要的价值。

然而，现有的自监督学习方法 [1, 2, 3, 4, 5, 6] 主要针对自然图像设计。与自然图像（如 ImageNet [31]）不同，卫星影像通常包含有意义的地理和时间信息，并且除了可见光（即自

*Equal contribution. Order determined via coin flip.

36th Conference on Neural Information Processing Systems (NeurIPS 2022).

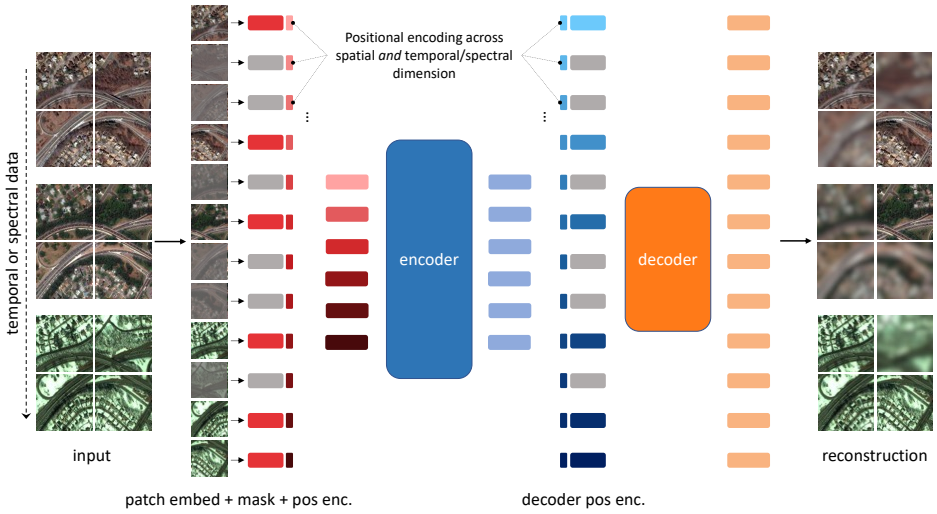

图 1: 通过在多光谱和时间图像上精心设计的掩码策略，以及时间与光谱位置编码，我们的 SatMAE 可作为遥感任务中强大的自监督学习视觉学习器。

然图像中典型的 RGB 通道）外，还可能包含多个表示传感器读数的光谱波段。根据数据源的不同，卫星影像的分辨率也可能存在显著差异 [32, 33]。尽管已存在针对卫星影像的自监督学习方法 [34, 35]，但这些方法无法同时为时序性和多光谱遥感数据学习通用表示。

为解决这一问题，我们提出 **SatMAE**，一种基于掩码自编码器（MAEs）[1] 的自监督学习框架，该框架能够自然地处理时序和多光谱输入数据。我们证明，在时序/光谱维度引入位置编码，并且在时序/光谱维度上独立地掩码补丁，有助于预训练，使模型能够学习到更有利于微调的数据表示。具体而言，我们的贡献包括：

1. 我们提出一种新方法，利用卫星图像中的时间或多光谱信息，以提升基于掩码自编码器的自监督预训练（见 4）。
2. 我们引入了 fMoW-Sentinel，这是一个与 fMoW 交叉引用的新型 Sentinel-2 数据集，可作为训练模型处理多光谱卫星影像的基准（见 5.1）。
3. 我们展示了预训练 Transformer [36] 在卫星图像上的有效性，在基准数据集以及下游遥感任务上均取得了显著优于之前最先进方法的性能（见 5）。

2 相关工作

SITS 的机器学习 深度学习已被广泛应用于许多卫星图像时序（SITS）监督学习任务中，例如作物类型制图 [29, 28, 37, 38]、产量预测 [39, 40]、经济理解 [41, 42, 43, 44]、降水预测 [45] 以及土地覆盖分类 [46, 47, 48, 27]。这些研究证实了将长短期记忆网络（LSTM）、自注意力机制和 Transformer 等架构适配到时序数据中的有效性。然而，除了特定任务外，这些方法通常难以直接应用于其他遥感数据集。

卫星图像的 SSL 自监督学习 [2, 3, 4, 5, 6] 已成为遥感领域中一种有前景的方法。例如，[34] 和 [35] 提出利用时间上对齐的影像进行对比自监督学习。尽管取得了令人瞩目的成果，这两种对比学习方法在很大程度上依赖于正样本对的质量，而正样本对的质量通常难以控制。[49] 将不同传感器通道组合以生成空间位置对齐的图像作为正样本对。[50, 51, 52] 将现成的

对比学习算法应用于卫星影像。[52] 利用图像修复和变换预测作为额外的预训练任务。[53] 利用地理知识辅助自监督学习，然而这些地理知识往往难以获取，因为需要标注。

掩码自编码器 MAE [1] 是一种近期强大的自监督学习方法。它不构建对比目标，而是提出将输入中被掩码的图像块进行重构作为预训练任务，并在很大程度上避免了设计特定数据增强的需求。受 MAE 在广泛视觉基准测试中表现出的顶尖性能 [1] 启发，许多后续工作将 MAE 扩展至不同数据模态。VideoMAE [54] 将视频管状掩码与重构作为视频分析的预训练任务。GMAE [55] 将 MAE 适配到图领域。MultiMAE [56] 支持多种模态的可选输入，并相应地引入其他训练目标以促进多模态学习。

然而，这些工作未能最优处理时间维度和多光谱输入。VideoMAE 要求时间维度上图像帧等间距分布，而卫星数据由于采样时间上的不规则性和不连续性，无法满足这一条件。

在本工作中，我们将时间与光谱信息融入掩码自编码器架构，提出一种针对卫星数据的新型自监督学习框架。

3 背景

掩码自编码器 Mae 是一种具有非对称编码和解码阶段的自编码器 [1]。它作用于图像 $I \in \mathbb{R}^{C\times H\times W}$ ，其中 H, W 为图像的高度和宽度，C 为通道数。输入图像 I 被调整为一系列不重叠的图像块序列 $S \in \mathbb{R}^{L\times P^2C}$ ，其中 P 为图像块的高度和宽度，$L = (H/P)\cdot(W/P)$ 为图像块的数量。每个图像块通过图像嵌入 $f_p : \mathbb{R}^{P^2C} \mapsto \mathbb{R}^D$ 转换为一个嵌入后的图像块 “token” 序列 $S' \in \mathbb{R}^{L\times D}$ 。将 L 个 token 中的一部分 p_m 进行掩码处理，仅将剩余的 $(1-p_m)L$ 个 “可见” 图像块 token 输入到编码器中，该编码器为带有位置嵌入的视觉 Transformer（ViT）[36]，以捕捉图像块在原图中的空间位置。解码器由一系列 Transformer 块组成，作用于全部 L 个 token（加入位置嵌入），其中 p_mL 个编码后的可见图像块被放置在原始序列位置，而 $(1-p_m)L$ 个被掩码的图像块则由可学习的掩码 token 表示。解码器输出重建图像 $\hat{I} \in \mathbb{R}^{C\times H\times W}$ ，并仅在被掩码的图像块上按像素计算均方误差（MSE）损失 [1]。

位置编码 位置编码使 Transformer 能够使其学习到的表示具有位置感知能力。在 MAE [1] 以及许多 Transformer [57, 58] 中，位置编码为：

$$\texttt{Encode}(k, 2i) = \sin\frac{k}{\Omega^{\frac{2i}{d}}},\ \texttt{Encode}(k, 2i+1) = \cos\frac{k}{\Omega^{\frac{2i}{d}}} \tag{1}$$

其中，k 为位置，i 为编码中特征维度的索引，d 为可能的位置数量，Ω 为一个大常数（通常设为 10000）。在 MAE 中，位置定义为沿 x 轴或 y 轴的补丁索引。因此，k 的取值范围为 0 到 H/P （或 W/P ）。最终的编码通过拼接 x 坐标和 y 坐标的编码生成。

4 方法

在本节中，我们使用时间（4.1）和多光谱（4.2）卫星图像描述 SatMAE。

4.1 时间序列 SatMAE

我们现在考虑输入张量 $I_T \in \mathbb{R}^{T\times C\times H\times W}$，其中 T 表示时间序列中的图像数量。在视频数据中，T 帧通常等距分布。然而，时间序列卫星影像很少在规则的时间间隔内获取。更常见的情况是，在不规则的时间点对某一特定区域拍摄多张快照或多个版本。这些卫星图像序列的长度和采样频率在多年间以及不同区域之间差异巨大。

直观地，可以将 I_T 重塑为 $I'_T \in \mathbb{R}^{TC\times H\times W}$ ，将图像的时间序列沿光谱（即通道）维度有效拼接，然后直接应用 MAE 机制。这种方法存在一些困难：(i) 该模型可能无法泛化到与预训练中使用的时序顺序不同的情况，因为它只能通过堆叠时间序列中图像的位置来理解顺序。(ii) 该模型无法推断时间序列中两张连续图像之间的时间间隔，当对某一位置的图像以不规则间隔采样时，这一时间间隔可能是变化的。(iii) 模型在深层中失去了对时间细粒度信息的访问，因为其唯一直接接触编码时间信息的方式仅通过初始的块嵌入 f_p (iv) 该模型不具备时间平移不变性（即模型需要分别学习在时间序列的两个不同片段中检测同一个事件）。

为应对这些挑战并避免丢失时间信息，我们将时间序列 I_T 重缩放为 $S_T \in \mathbb{R}^{L_T\times P_T P^2 C}$ ，其中 $L_T = L\cdot(T/P_T) = (H/P)\cdot(W/P)\cdot(T/P_T)$ ，P_T 为时间维度上的“块大小”，L 与 P 由 3 定义。先前使用 Transformer 处理视频数据的研究建议采用 $P_T = 2$ ，其中每个“块”是一个形状为 $2\times 16\times 16$ [54, 59, 60] 的立方体。由于我们的数据具有更短的时间序列长度 [17]，因此我们设定 $P_T = 1$ 使得 $L_T = L\cdot T$ 。为了能够在任意时间顺序的输入上操作，我们对时间序列中的每一帧图像重复使用相同的块嵌入 $f_p : \mathbb{R}^{P^2C} \mapsto \mathbb{R}^D$ ，从而得到一个嵌入后的 token 序列 $S'_T \in \mathbb{R}^{L_T\times D}$ 。

4.1.1 时间编码

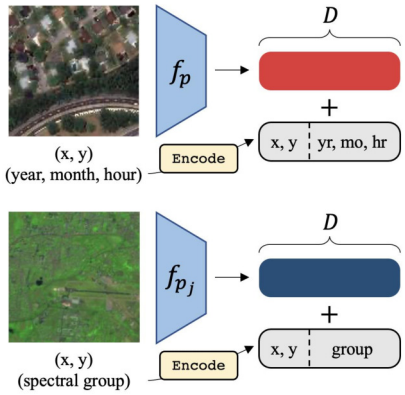

图 2: 上：使用共享的块嵌入 f_p 对每个时间块进行编码。下：对每个组 j 中的每个光谱块使用不同的块嵌入 f_{p_j} 进行编码。

对于 L_T 长度序列中的每个嵌入 token，我们需要确保模型保留其空间和时间位置的信息。如许多先验工作 [34, 35] 所示，卫星图像的时间戳对许多预训练或下游视觉任务非常有用。我们提出了一种与掩码自编码器架构兼容的时间编码方案，通过将时间维度处理方式类似于位置维度（见 3）。

卫星图像的时间戳表示为“年-月-日-时-分-秒”。与其将整个数值化时间戳输入特征编码器，我们提出仅保留有用的部分。直观上，日期、分钟和秒与区域的视觉外观无关，因此在时间编码中包含这些成分可能并无益处，甚至可能产生负面影响。相比之下，由于天气、地质和人类活动的影响，景观可能随多年演变。月份反映了季节和气候，小时则反映了光照和温度。

然后，时间编码被表述为：

$$t_{k,i} = \mathrm{CONCAT}[\texttt{Encode}(k_{\text{year}}, i), \texttt{Encode}(k_{\text{month}}, i), \texttt{Encode}(k_{\text{hour}}, i)] \tag{2}$$

并且最终的编码通过将时间编码连接到 3 中定义的位置编码生成，使得编码的总长度为 D。

4.1.2 掩码策略

在增加一个时间维度的情况下，对部分 L_T token 进行掩码需要格外小心。如图 3 所示，对卫星图像的时间序列进行掩码有多种方式。

一致掩码 每张图像都单独进行“分块”，但所有图像中的掩码区域保持一致（图 3a）。该方法在 VideoMAE [54] 中也得到了应用，适用于视频输入。

独立掩码 每张图像被单独“分块”，且被掩码的区域在每张图像之间可能不同。相反，会掩码全部分块 token 序列中的一小部分 p_m。另一种变体是独立地掩码每张图像的区域，但保持每张图像中被掩码区域的比例 p_m 固定。这两种变体在期望上是等价的。实际上，模型

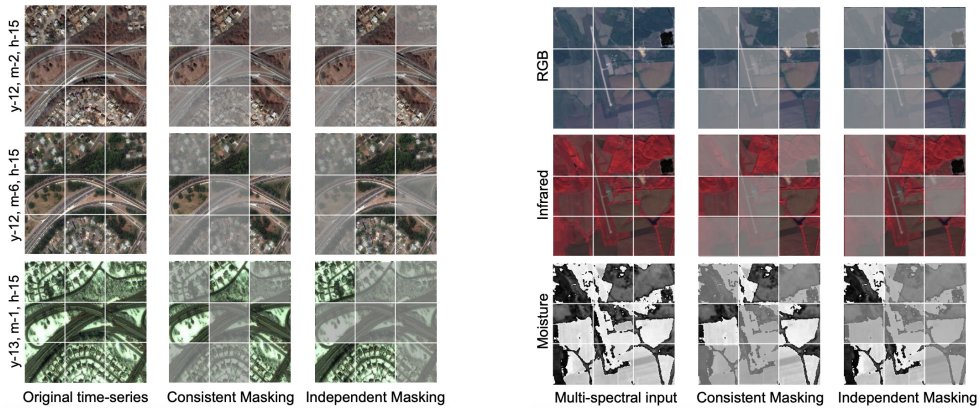

(a) 时间数据　　(b) 光谱数据

图 3: 3a **时间掩码**：对于时序图像，我们可以选择在时间上完全保持一个图像块可见或完全掩码（*一致性掩码*），或者独立地掩码所有图像块（*独立掩码*）。在两种情况下，都会掩码比例为 p_m 的图像块。这里，$T = 3$ ，最左侧一列根据时间戳特征对时间序列进行排序。例如，“y-12, m-12, h-15” 表示从最小年份（2002）起 12 年，零索引的第 2 个月，以及一天中的第 15 小时；即大约为 2014 年，3 月，15:00。3b **光谱掩码**：相同的掩码策略被应用于哨兵-2 图像中的 13 个光谱波段组。

可以查看某个区域在一张图像中被掩码但在其他图像中未被掩码时的未掩码值。这种情景对于视频数据可能带来更简单的任务，因为模型可以“作弊”，利用高帧率视频中的时间冗余 [54]。然而，我们认为这种“作弊”形式在时间序列卫星影像中可行性较低，因为季节变化和随时间推移的人类活动变化影响显著，且时间连续图像之间的时序间隔远大于视频数据（见图 3a）。

独立掩码 + 不一致裁剪　在数据预处理过程中，我们可以不一致地裁剪方阵区域作为输入，导致同一时间序列中的图像在空间上可能未对齐。这种策略有助于模型学习到更好的表示，因为它可能学会在空间和时间维度上对序列中的图像进行对齐。

4.2　多光谱 SatMAE

虽然 MAE 适用于图像 $I \in \mathbb{R}^{C \times H \times W}$ ，通常对 RGB 图像使用 $C = 3$ 。另一方面，卫星数据往往包含多个光谱波段。例如，Sentinel-2 影像包含 $C = 13$ 个波段，空间分辨率分别为 10 米、20 米和 60 米，每个波段对应不同的波长（参见 A.2.2）。以下我们将讨论并随后通过实验比较各种编码光谱信息的方法。

堆叠通道　将图像块序列 $S \in \mathbb{R}^{L \times P^2 C}$ 嵌入为令牌序列 $S' \in \mathbb{R}^{L \times D}$，从而直接处理多波段图像。我们称此方法为 **SatMAE+Stack**。

群组通道　简单地堆叠光谱信息存在局限性，尤其是单个卷积块嵌入可能不足以充分捕捉不同波长和空间分辨率下多个波段中存在的细粒度信息。我们希望模型在编码和解码过程中能够保留关于不同波段的信息。

为解决这一限制，我们提出对光谱波段的子集进行*分组*。给定 C 通道，我们形成 G 个组 $g_1, g_2, \ldots, g_G$ ，使得 $g_1 + g_2 + \cdots + g_G = C$ 。这类似于在通道维度上对图像 I 进行切片，生成图像 $I_1, \ldots, I_G$ ，其中 $I_j \in \mathbb{R}^{g_j \times H \times W}$ 。我们为每个组 j 使用一个分离的块嵌入 $f_{p_j} : \mathbb{R}^{P^2 g_j} \mapsto \mathbb{R}^D$ ，从而让模型能够最佳地表示每个可能不同的通道组作为 token 嵌入。因此，每个组 j 首先从 $I_j \in \mathbb{R}^{g_j \times H \times W}$ 调整大小到 $S_j \in \mathbb{R}^{L \times P^2 g_j}$ ，然后每个块使用 f_{p_j} 进行

嵌入，以生成嵌入 token 序列 $S'_j \in \mathbb{R}^{L\times D}$ 。这些序列 $S'_1, \ldots, S'_G$ 被连结以产生最终的 token 集合 $S' \in \mathbb{R}^{GL\times D}$ 。

光谱编码 由于 S' 中的 token 对应输入图像中的一个补丁位置 (m, n) 和一组通道 g_j，因此我们包含一组通道索引 k_g 的编码，类似于 4.1.1

$$g_{k_g,i} = \texttt{Encode}(k_g, i) \tag{3}$$

注意，这种编码仅依赖于用户自定义的通道分组，与 eq. (2) 不同，无需额外的图像元数据（如日期）。最终的编码是位置编码 $x_{k,i}$ 、$y_{k,i}$ 与光谱编码 $g_{k,i}$ 的拼接，使得总维度为 D（见 fig. 2）。该位置编码在输入编码器前被加到 S' 上。我们将通道分组与使用组编码相结合的设置记为 **SatMAE+Group**。

掩码策略 我们考虑 一致掩码（记为 **SatMAE+Group+CM**）和 独立掩码（**SatMAE+Group+IM**），如 section 4.1.2 所定义，并在 fig. 3b 中可视化。

5 实验

在本节中，我们首先介绍所考虑的数据集，包括一个用于下游任务评估的新多光谱遥感图像数据集 (5.1)。随后，我们展示在基准数据集 (5.2, 5.3, 5.4) 以及各类遥感迁移学习和下游任务 (5.5) 上的实验结果。所有实验中，我们与当前最先进的方法 ([34, 35]) 以及使用 SatMAE 的 ViT 主干网络从头开始的监督学习方法进行比较。综上所述，我们的方法在所考虑的所有任务中均表现出强劲性能，在监督学习基准测试中相较于先前最先进技术提升最高达 6%，在遥感迁移学习下游任务中提升最高达 14%。

5.1 预训练数据集

fMoW RGB 世界功能地图（fMoW）[17] 是一个全球高分辨率卫星图像时序数据集，任务为 62 个类别之间的分类。

fMoW 信标 我们基于 fMoW RGB 数据集创建了一个新数据集。我们在原始 fMoW 位置收集了哨兵-2 提供的所有 13 个频段（B1-12 和 B8A），时间部分与 fMoW 图像相同，部分额外增加，共计 712,874 张训练图像，84,939 张验证图像，以及 84,966 张测试图像。更多细节见 section A.1。

5.2 fMoW RGB（非时序）

Method	Backbone	Frozen/Finetune
Sup.*	ResNet50	-/69.05
Sup.†	ResNet50	-/69.07
GASSL [34]	ResNet50	68.32/71.55
Sup.*	ViT-Large	-/62.48
Sup.†	ViT-Large	-/75.70
Sup.‡	ViT-Large	-/76.91
SatMAE	ViT-Large	65.94/**77.84**

表 1: fMoW 分类任务上的 Top 1 准确率。**冻结**: 在预训练模型的冻结特征上进行线性分类。**微调**: 端到端地微调整个模型。* 表示从零开始训练，† 表示使用监督学习的 ImageNet 权重，‡ 表示使用 SSL MAE ImageNet 权重。

在本节中，我们在 fMoW 单图像分类任务上进行了实验。遵循 [34]，我们报告了线性探测和微调情景下的性能表现。表1显示，与之前使用对比动量编码方法的最先进自监督方法 [34, 3] 相比，我们的 SatMAE 在 top 1 分类准确率上提升了 6.29%。有趣的是，在没有 SatMAE 预训练的情况下，ViT-large 模型在经过 50 轮微调后收敛时仅达到 62.48% 的准确率，而使用 ResNet-50 模型从头训练则达到了 69.05%。这可能是因为 ViT[36] 骨干网络比 ResNet50[61] 更难从头开始微调，因此预训练模型的价值更高。

Method	Backbone	Top Acc. (1/5)
Sup.*	ResNet50	73.24/-
SeCo [35]	ResNet50	66.80/-
GASSL [34]	ResNet50	74.11/-
UTAE [48]	U-Net	61.59/86.45
Sup.*	ViT-Large	61.89/84.23
SatMAE+Stack	ViT-Large	75.85/88.68
MAE+Test Aug.	ViT-Large	78.90/93.31
MAE‖	ViT-Large	76.78/92.01
SatMAE	ViT-Large	**81.49/93.26**

表 2: 时序 fMoW RGB 数据集上的分类结果。* 表示从零开始微调。‖ 表示将输入图像复制 3 次，而不是使用时序序列作为输入。SatMAE+Stack 在此表示将图像序列沿通道维度堆叠。

Method	Backbone	Top Acc. (1/5)
Sup. Learning*	ResNet152	49.12/75.73
Sup. Learning‡	ResNet152	54.46/78.99
MoCo-v3	ViT-Base	50.45/76.37
MoCo-v3+Group	ViT-Base	51.33/75.68
SatMAE+Group*	ViT-Large	53.03/77.14
SatMAE+Group†	ViT-Large	51.61/77.26
SatMAE+Group‡	ViT-Large	47.57/72.26
SatMAE+Group§	ViT-Large	49.49/76.30
SatMAE+Stack	ViT-Large	57.37/81.63
SatMAE+Group+IM	ViT-Large	59.30/82.81
SatMAE+Group+IM	ViT-Large	**61.48/85.17**

表 3: fMoW Sentinel 验证集上的 Top 1 & Top 5 准确率。不同的初始化方式为：* 从零开始，† MAE ImageNet 权重，‡ 监督式 ImageNet 权重，§ SatMAE fMoW RGB 权重。其他行使用 fMoW Sentinel 进行预训练。最后一行包含了额外的数据增强 (5.4)。

Temp. Enc.	Indep. Mask.	Cons. Crop.	Test Aug.	Top 1 Acc.
	✓	✓		78.07
✓		✓		78.45
✓	✓			79.90
✓	✓	✓		79.69
✓	✓	✓	✓	**81.49**

表 4: 在时间 fMoW 分类任务上对时间 SatMAE 不同组件的消融实验。第一列为是否使用时间编码，第二列为是否使用独立掩码，第三列为是否一致裁剪，最后一列为是否应用测试时增强。

Back.	Group Strat.	Indp. Mask.	Spec. Enc.	Top 1 Acc.
Base	X	✓	✓	59.11
Large	X	✓		58.87
Large	X		✓	57.76
Large	H	✓	✓	57.78
Large	R	✓	✓	58.76
Large	X	✓	✓	**59.30**

表 5: 在 fMoW-Sentinel 上对光谱 SatMAE 的消融实验。第一列为使用 ViT-Base 或 ViT-Large。第二列为分组策略（见 5.4）。第三列为独立或一致的掩码。最后一列为是否使用光谱分组编码 3。

5.3 fMoW RGB（时间）

主要实验 我们在 fMoW RGB 的时序版本上进行图像序列分类，以评估我们的时序 SatMAE。时序 fMoW 包含长度为 3 的共位置图像序列。如 table 2 所示，SatMAE 在 top 1 分类准确率上相较于之前的最优状态提升了 4.48%，相较于非时序结果提升了 2.06%。我们还以 18% 的优势超越了 UTAE [48]，后者是当前 SITS 的最优模型。从第 5-8 行可以看出，这一提升并非源于更大的模型来处理数据序列。简单地将图像序列在通道维度上堆叠，其表现甚至劣于非时序的 SatMAE。再次强调，SatMAE 的预训练对于 ViT 超越 ResNet50 至关重要。训练细节见 section A.3.2。

消融研究 表 4 对时间 SatMAE 的各个组件进行了全面的消融研究。我们发现性能的提升主要归因于时间编码以及采用 独立掩码策略，而非 VideoMAE [54] 中建议的一致掩码策略。有趣的是，一致裁剪略微降低了性能，表明模型并不依赖于完全空间对齐的图像序列。此外，使用类似于 [34] 的测试时增强方法是有益的。关于掩码比例 p_m 和补丁大小 P 的进一步消融实验见 section A.4。

5.4 fMoW 哨兵（多光谱）

在本节中，我们在 fMoW-Sentinel 数据集的图像分类任务上对 SatMAE 进行预训练和微调。我们对 SatMAE+Stack 4.2 进行预训练，并研究了 SatMAE+Group+CM 4.1.2 和 SatMAE+Group+IM 4.1.2（见 4.2, 4.2）。随后，将完整模型在 fMoW-Sentinel 图像分类任务上进行微调。为了对比，我们还从头开始微调 ResNet-152 模型 [61]，以及从监督式 ImageNet 初始化状态出发进行微调。我们选择最大模型 ResNet-152，以便与 ViTs 进行更公平的比较。此外，我们还包含了 MoCo-v3 [62, 3]，这是一种流行的自监督学习方法。考虑到将 RGB 图像增强应用于卫星影像时存在的差异，我们实现了两种版本：(i) MoCo-v3：我们对 10 通道图像应用了所有相同的增强操作，除了随机灰度和太阳化之外，以生成两个视图。(ii) MoCo-v3+Group：我们按照 [2] 的建议将 10 个波段分为两组，并对每组应用增强操作，以生成一对两个 5 通道图像的正样本。

模型配置 由于并非全部 13 个哨兵-2 波段都有用，我们在实验中去除了空间分辨率分别为 60 米的 B1、B9 和 B10 波段。在剩下的 10 个波段中，我们将其分为三组：(i) RGB+NIR：B2、B3、B4、B8 (ii) 红边：B5、B6、B7、B8A (iii) SWIR：B11，B12. 我们选择这种分组方式，以确保每组的波段具有相同的空间分辨率和相似的波长（参见 A.2.2, A.6）。table 3 的最后一行包含了在微调过程中使用的额外数据增强方法，如 [1] 所述。有关预训练和微调的详细信息，请参见 A.3.3。

结果 我们在表 3 中展示了结果。我们的方法 SatMAE+Group+IM 达到了最高的准确率，优于从零开始的监督训练 (↑ 6.27%) 和 ImageNet 初始化的主干网络 (↑ 4.84%)。由于多光谱输入数据存在更大的分布偏移，ImageNet 初始化在 fMoW-RGB 中可能不如以往有效。此外，我们还注意到，在通道分组上的有效性优于仅在图像嵌入级别处理所有波段（即 SatMAE+Stack）。

消融研究 我们研究了在 table 5 中针对多光谱数据的 SatMAE 设计。对于分组策略，我们实现了交替波段分组，以检验基于波长和分辨率进行波段分组是否有益。5.4 中的 X 表示波段分组。H 表示将 10 个波段分为两个半区，{(2,3,4,5,6), (7,8,8A,11,12)}。R 表示随机划分为三个组 {(6,5,11,12), (8A,4,8,3), (7,2)}，分组大小与 X 相同。如图所示，波段分组的选择确实影响性能，带来了约 0.6% 的提升。此外，ViT-Base 表现强劲，表明性能提升的原因是 SatMAE 而非 ViT 的参数数量。有趣的是，独立掩码表现最佳，这促使模型“窥视”未掩码的波段分组，以重建被掩码波段分组中的同一区域。

我们还进行了进一步的实验，研究了预训练长度的影响（见 A.3.3），掩码比例 p_m 和补丁大小 P 的影响（见 A.5），以及 13 个哨兵-2 光谱波段的有用性（见 A.6）。

5.5 迁移学习实验

现在，我们在遥感数据集的下游任务上对预训练的 SatMAE 进行微调，包括土地覆盖分类 (5.5)、多标签分类 (5.5) 和建筑物分割 (5.5)。微调的详细信息见A.7、A.8、A.9、A.10。

土地覆盖分类 我们针对土地覆盖分类任务，在 NAIP 和 EuroSAT [63] 数据集上进行了迁移学习实验。NAIP 包含由美国农业部国家农业影像计划获取的 66 种土地覆盖类别的 RGB+CIR 图像，共分为 244,471 张训练图像和 55,529 张验证图像。EuroSAT 是一个小型数据集，包含基于 Sentinel-2 的 10 个类别共 27,000 幅 13 波段卫星图像。我们在 EuroSAT 上遵循 [35, 64] 的训练/验证划分方式。

Method	Backbone	Top 1 Acc.
Sup. (Scratch)	ResNet50	54.46
GASSL [34]	ResNet50	57.63
Sup. (Scratch)	ViT-Large	69.65
SatMAE	ViT-Large	**71.77**

表 6: NAIP 土地覆盖分类结果。

Method	Backbone	mIoU
Sup. (Scratch)	ResNet50	75.57
GASSL [34]	ResNet50	**78.51**
Sup. (Scratch)	ViT-Large	74.71
SatMAE	ViT-Large	78.07

表 7: SpaceNet v1 建筑分割结果。

Method	Backbone	Top 1 Acc.
Sup. (Scratch)	ResNet18	63.21
Sup. (IN init.)	ResNet18	86.44
GASSL [34]	ResNet18	89.51
SeCo [35]	ResNet18	93.14
SatMAE*	ViT-Large	95.74
SatMAE	ViT-Large	98.94
SatMAE+Group+IM	ViT-Large	**98.98**

表 8: EuroSAT 土地覆盖分类结果。* 表示我们仅使用数据的 RGB 通道。

Method	Backbone	mAP
Sup. (Scratch)	ResNet50	69.49
Sup. (IN init.)	ResNet50	80.04
GASSL [34]	ResNet50	80.20
SeCo [35]	ResNet50	**82.62**
Sup. (Scratch)	ViT-Large	80.07
SatMAE	ViT-Large	82.13

表 9: BigEarthNet 多标签分类结果。遵循 [35]，我们使用平均准确率（mAP）作为评估指标，并采用一组新的类标记。

表 6 和表 8 展示了我们的 SatMAE 相较于当前最先进方法的显著提升。尽管使用 ViT-Large 主干网络已取得良好结果，但使用 SAT-MAE 预训练权重进行初始化后，准确率进一步提升了 2%-3%。

多标签分类 我们还使用 BigEarthNet [18] 数据集进行多标签分类，该数据集包含总共 19 类的 13 波段 Sentinel-2 图像。训练集包含 354,196 张图像，验证集包含 118,065 张图像。遵循 [35]，我们使用训练集的 10% 子集。

表 9 显示，SatMAE 预训练相较于从零开始训练的模型提升了超过 2%，并达到了与当前最先进水平相当的结果。GASSL 和 SeCo 实际上是在更大的预训练数据集上进行训练的（100 万张哨兵-2 图像对比 71.3 万张），且使用了全部 13 个波段，而我们的 fMoW 哨兵数据则未达到此规模。因此，我们预计当使用更多数据和更长的训练时间对 SatMAE 进行预训练时，性能还将进一步提升。

建筑分割 在本节中，我们在 SpaceNet v1 数据集 [20] 的语义分割下游任务上评估 SatMAE。SpaceNet v1 数据集由 6940 张高分辨率卫星图像组成，这些图像带有建筑物的分割掩码，分为训练集和测试集，分别包含 5000 张和 1940 张图像。

table 7 中的结果表明，与 [34] 相比，我们的方法在从零开始的监督学习中获得了更大的性能提升。ViT 主干网络与 PSANet 的不兼容性可能解释了为何基准性能不如使用 ResNet50 主干网络时的表现。

5.6 SatMAE 重构质量的可视化

我们在 fig. 4 中展示了两种不同 SatMAE 掩码策略的重构质量可视化。SatMAE+IM 能够成功重构所有飞机，即使其数量随时间变化。相比之下，采用一致掩码的 SatMAE 在重构过程中遗漏了一些飞机。

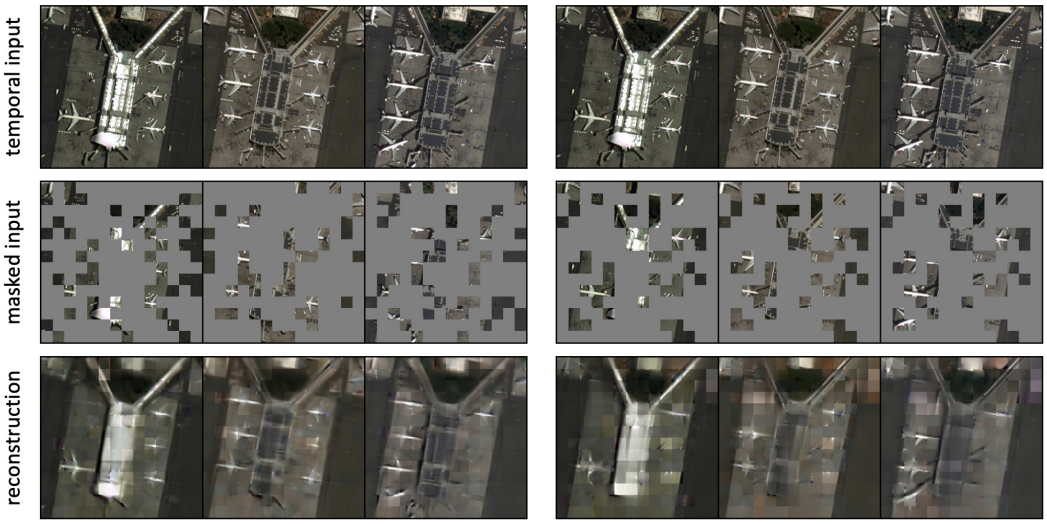

图 4: SatMAE+IM（左）与 SatMAE+CM（右）的重构质量。更多结果见 section C。

6 结论

本文提出了一种基于 MAE 架构 [1] 的新型自监督学习框架，专为遥感数据（卫星影像）设计。我们提出的创新掩码策略结合了联合位置、时间/光谱空间，以及时间与光谱编码，使我们的模型能够以时间和多光谱卫星影像作为输入，并学习到有用的表示。在预训练数据集及多个下游数据集上的实验表明，我们预训练的 SatMAE 模型具有显著效果，大幅超越了先前的最先进结果。

未来设计更高效的 Transformer 架构将非常有用。尽管 SatMAE 在时序和多光谱设置下的参数量与普通 ViT 相似，但 token 序列长度的增加可能会对计算资源造成压力。此外，探索适用于光谱和时序数据的最佳位置编码，以及通过基于神经网络的搜索方法或利用先验知识来确定最优的光谱波段组合，也值得研究。最后，深入研究使用 ViTs 进行目标检测和语义分割的更优架构，对于将 SatMAE 推广至更多下游任务至关重要。

更广泛的影响

对经济、社会和环境现象的精确测量是全球政策决策的关键输入，但许多结果的标签数据稀疏，导致这些决策往往缺乏及时或准确的数据支持。我们展示了预训练框架如何减轻许多使用卫星图像作为输入的下游任务对标签数据的依赖。我们希望我们的 SatMAE 方法能够缩小自然图像与更具挑战性的卫星图像在自监督学习性能之间的差距，并促使机器学习社区进一步关注自监督学习在卫星图像相关任务中的实用性。

从卫星图像中更有效地提取信息，对我们衡量和理解一系列对决策至关重要的社会、经济和环境现象具有深远影响。我们的方法进一步提升了现有稀疏标签数据在关键人类成果上的利用价值，有望实现针对贫困预测、基础设施发展和人口估算等关键下游任务的快速且准确的图像特征提取。此类信息可帮助政府做出更迅速、基于数据的决策，最终带来巨大的社会效益。

7 致谢

本研究部分得到了国家情报总监办公室（ODNI）、情报高级研究计划活动（IARPA）通过 2021-2011000004、HAI、NSF（#1651565）、AFOSR（FA95501910024）、ARO（W911NF-21-1-0125）以及斯隆奖学金的支持。本文中的观点和结论仅代表作者，不应被理解为必然代表 ODNI、IARPA 或美国政府的官方政策，无论明示或暗示。美国政府有权在不考虑其中任何版权标注的情况下，复制和分发用于政府目的的重印件。

参考文献

[1] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.

[2] Yonglong Tian, Dilip Krishnan, and Phillip Isola. Contrastive multiview coding. In *European conference on computer vision*, pages 776–794. Springer, 2020.

[3] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 9729–9738, 2020.

[4] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *International conference on machine learning*, pages 1597–1607. PMLR, 2020.

[5] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Guo, Mohammad Gheshlaghi Azar, et al. Bootstrap your own latent-a new approach to self-supervised learning. *Advances in Neural Information Processing Systems*, 33:21271–21284, 2020.

[6] Xinlei Chen and Kaiming He. Exploring simple siamese representation learning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 15750–15758, 2021.

[7] Ashish Jaiswal, Ashwin Ramesh Babu, Mohammad Zaki Zadeh, Debapriya Banerjee, and Fillia Makedon. A survey on contrastive self-supervised learning. *CoRR*, abs/2011.00362, 2020.

[8] Longlong Jing and Yingli Tian. Self-supervised visual feature learning with deep neural networks: A survey. *IEEE transactions on pattern analysis and machine intelligence*, 43(11):4037–4058, 2020.

[9] Ishan Misra and Laurens van der Maaten. Self-supervised learning of pretext-invariant representations. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 6707–6717, 2020.

[10] Mathilde Caron, Ishan Misra, Julien Mairal, Priya Goyal, Piotr Bojanowski, and Armand Joulin. Unsupervised learning of visual features by contrasting cluster assignments. *Advances in Neural Information Processing Systems*, 33:9912–9924, 2020.

[11] Yude Wang, Jie Zhang, Meina Kan, Shiguang Shan, and Xilin Chen. Self-supervised equivariant attention mechanism for weakly supervised semantic segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 12275–12284, 2020.

[12] Yann Dubois, Benjamin Bloem-Reddy, Karen Ullrich, and Chris J Maddison. Lossy compression for lossless prediction. *Advances in Neural Information Processing Systems*, 34, 2021.

[13] Alexander Kolesnikov, Xiaohua Zhai, and Lucas Beyer. Revisiting self-supervised visual representation learning. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 1920–1929, 2019.

[14] Zeyu Feng, Chang Xu, and Dacheng Tao. Self-supervised representation learning by rotation feature decoupling. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10364–10374, 2019.

[15] Soroush Abbasi Koohpayegani, Ajinkya Tejankar, and Hamed Pirsiavash. Compress: Self-supervised learning by compressing representations. *Advances in Neural Information Processing Systems*, 33:12980–12992, 2020.

[16] Abhishek Sinha, Jiaming Song, Chenlin Meng, and Stefano Ermon. D2c: Diffusion-decoding models for few-shot conditional generation. *Advances in Neural Information Processing Systems*, 34:12533–12548, 2021.

[17] Gordon Christie, Neil Fendley, James Wilson, and Ryan Mukherjee. Functional map of the world. In *CVPR*, 2018.

[18] Gencer Sumbul, Marcela Charfuelan, Begüm Demir, and Volker Markl. Bigearthnet: A large-scale benchmark archive for remote sensing image understanding. In *IGARSS 2019-2019 IEEE International Geoscience and Remote Sensing Symposium*, pages 5901–5904. IEEE, 2019.

[19] Darius Lam, Richard Kuzma, Kevin McGee, Samuel Dooley, Michael Laielli, Matthew Klaric, Yaroslav Bulatov, and Brendan McCord. xview: Objects in context in overhead imagery. *arXiv preprint arXiv:1802.07856*, 2018.

[20] Adam Van Etten, Dave Lindenbaum, and Todd M Bacastow. Spacenet: A remote sensing dataset and challenge series. *arXiv preprint arXiv:1807.01232*, 2018.

[21] Marshall Burke, Anne Driscoll, David B Lobell, and Stefano Ermon. Using satellite imagery to understand and promote sustainable development. *Science*, 371(6535):eabe8628, 2021.

[22] Kumar Ayush, Burak Uzkent, Kumar Tanmay, Marshall Burke, David Lobell, and Stefano Ermon. Efficient poverty mapping from high resolution remote sensing images. In *Proc. AAAI Conf. Artif. Intell*, volume 35, pages 12–20, 2021.

[23] Kumar Ayush, Burak Uzkent, Marshall Burke, David Lobell, and Stefano Ermon. Generating interpretable poverty maps using object detection in satellite images. *arXiv preprint arXiv:2002.01612*, 2020.

[24] Neal Jean, Marshall Burke, Michael Xie, W Matthew Davis, David B Lobell, and Stefano Ermon. Combining satellite imagery and machine learning to predict poverty. *Science*, 353(6301):790–794, 2016.

[25] Jiaxuan You, Xiaocheng Li, Melvin Low, David Lobell, and Stefano Ermon. Deep gaussian process for crop yield prediction based on remote sensing data. In *Thirty-First AAAI conference on artificial intelligence*, 2017.

[26] Anna X Wang, Caelin Tran, Nikhil Desai, David Lobell, and Stefano Ermon. Deep transfer learning for crop yield prediction with remote sensing data. In *Proceedings of the 1st ACM SIGCAS Conference on Computing and Sustainable Societies*, pages 1–5, 2018.

[27] Marc Rußwurm and Marco Körner. Self-attention for raw optical satellite time series classification. *ISPRS journal of photogrammetry and remote sensing*, 169:421–435, 2020.

[28] Jorge Andres Chamorro Martinez, Laura Elena Cué La Rosa, Raul Queiroz Feitosa, Ieda Del' Arco Sanches, and Patrick Nigri Happ. Fully convolutional recurrent networks for multidate crop recognition from multitemporal image sequences. *ISPRS Journal of Photogrammetry and Remote Sensing*, 171:188–201, 2021.

[29] Rose M Rustowicz, Robin Cheong, Lijing Wang, Stefano Ermon, Marshall Burke, and David Lobell. Semantic segmentation of crop type in africa: A novel dataset and analysis of deep learning methods. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 75–82, 2019.

[30] Christopher Yeh, Chenlin Meng, Sherrie Wang, Anne Driscoll, Erik Rozi, Patrick Liu, Jihyeon Lee, Marshall Burke, David B Lobell, and Stefano Ermon. Sustainbench: Benchmarks for monitoring the sustainable development goals with machine learning. *arXiv preprint arXiv:2111.04724*, 2021.

[31] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255, 2009.

[32] Yutong He, Dingjie Wang, Nicholas Lai, William Zhang, Chenlin Meng, Marshall Burke, David Lobell, and Stefano Ermon. Spatial-temporal super-resolution of satellite imagery via conditional pixel synthesis. *Advances in Neural Information Processing Systems*, 34:27903–27915, 2021.

[33] Yutong He, William Zhang, Chenlin Meng, Marshall Burke, David B Lobell, and Stefano Ermon. Tracking urbanization in developing regions with remote sensing spatial-temporal super-resolution. *arXiv preprint arXiv:2204.01736*, 2022.

[34] Kumar Ayush, Burak Uzkent, Chenlin Meng, Kumar Tanmay, Marshall Burke, David Lobell, and Stefano Ermon. Geography-aware self-supervised learning. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 10181–10190, 2021.

[35] Oscar Mañas, Alexandre Lacoste, Xavier Giro-i Nieto, David Vazquez, and Pau Rodriguez. Seasonal contrast: Unsupervised pre-training from uncurated remote sensing data. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 9414–9423, 2021.

[36] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. *ICLR*, 2021.

[37] Marc Rußwurm and Marco Körner. Convolutional lstms for cloud-robust segmentation of remote sensing imagery. *arXiv preprint arXiv:1811.02471*, 2018.

[38] Charlotte Pelletier, Geoffrey I Webb, and François Petitjean. Temporal convolutional neural network for the classification of satellite image time series. *Remote Sensing*, 11(5):523, 2019.

[39] Elisa Kamir, François Waldner, and Zvi Hochman. Estimating wheat yields in australia using climate records, satellite image time series and machine learning methods. *ISPRS Journal of Photogrammetry and Remote Sensing*, 160:124–135, 2020.

[40] Raí A Schwalbert, Telmo Amado, Geomar Corassa, Luan Pierre Pott, PV Vara Prasad, and Ignacio A Ciampitti. Satellite-based soybean yield forecast: Integrating machine learning and weather data for improving crop yield prediction in southern brazil. *Agricultural and Forest Meteorology*, 284:107886, 2020.

[41] Chenlin Meng, Enci Liu, Willie Neiswanger, Jiaming Song, Marshall Burke, David Lobell, and Stefano Ermon. Is-count: Large-scale object counting from satellite images with covariate-based importance sampling. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pages 12034–12042, 2022.

[42] Evan Sheehan, Chenlin Meng, Matthew Tan, Burak Uzkent, Neal Jean, Marshall Burke, David Lobell, and Stefano Ermon. Predicting economic development using geolocated wikipedia articles. In *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*, pages 2698–2706, 2019.

[43] Enci Liu, Chenlin Meng, Matthew Kolodner, Eun Jee Sung, Sihang Chen, Marshall Burke, David Lobell, and Stefano Ermon. Building coverage estimation with low-resolution remote sensing imagery. *arXiv preprint arXiv:2301.01449*, 2023.

[44] Burak Uzkent, Evan Sheehan, Chenlin Meng, Zhongyi Tang, Marshall Burke, David Lobell, and Stefano Ermon. Learning to interpret satellite images using wikipedia. In *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence*, 2019.

[45] Xingjian Shi, Zhourong Chen, Hao Wang, Dit-Yan Yeung, Wai-Kin Wong, and Wang-chun Woo. Convolutional lstm network: A machine learning approach for precipitation nowcasting. *Advances in neural information processing systems*, 28, 2015.

[46] Andrei Stoian, Vincent Poulain, Jordi Inglada, Victor Poughon, and Dawa Derksen. Land cover maps production with high resolution satellite image time series and convolutional neural networks: Adaptations and limits for operational systems. *Remote Sensing*, 11(17):1986, 2019.

[47] Xin Yang and CP Lo. Using a time series of satellite imagery to detect land use and land cover changes in the atlanta, georgia metropolitan area. *International Journal of Remote Sensing*, 23(9):1775–1798, 2002.

[48] Vivien Sainte Fare Garnot and Loic Landrieu. Panoptic segmentation of satellite image time series with convolutional temporal attention networks. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 4872–4881, 2021.

[49] Aidan M Swope, Xander H Rudelis, and Kyle T Story. Representation learning for remote sensing: An unsupervised sensor fusion approach. *arXiv preprint arXiv:2108.05094*, 2021.

[50] Vladan Stojnic and Vladimir Risojevic. Self-supervised learning of remote sensing scene representations using contrastive multiview coding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 1182–1191, 2021.

[51] Pallavi Jain, Bianca Schoen-Phelan, and Robert Ross. Multi-modal self-supervised representation learning for earth observation. In *2021 IEEE International Geoscience and Remote Sensing Symposium IGARSS*, pages 3241–3244. IEEE, 2021.

[52] Wenyuan Li, Hao Chen, and Zhenwei Shi. Semantic segmentation of remote sensing images with self-supervised multitask representation learning. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 14:6438–6450, 2021.

[53] Wenyuan Li, Keyan Chen, Hao Chen, and Zhenwei Shi. Geographical knowledge-driven representation learning for remote sensing images. *IEEE Transactions on Geoscience and Remote Sensing*, 2021.

[54] Zhan Tong, Yibing Song, Jue Wang, and Limin Wang. Videomae: Masked autoencoders are data-efficient learners for self-supervised video pre-training. *arXiv preprint arXiv:2203.12602*, 2022.

[55] Hongxu Chen, Sixiao Zhang, and Guandong Xu. Graph masked autoencoder. *arXiv preprint arXiv:2202.08391*, 2022.

[56] Roman Bachmann, David Mizrahi, Andrei Atanov, and Amir Zamir. Multimae: Multi-modal multi-task masked autoencoders. *arXiv preprint arXiv:2204.01678*, 2022.

[57] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.

[58] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In *International Conference on Machine Learning*, pages 10347–10357. PMLR, 2021.

[59] Anurag Arnab, Mostafa Dehghani, Georg Heigold, Chen Sun, Mario Lučić, and Cordelia Schmid. Vivit: A video vision transformer. In *International Conference on Computer Vision (ICCV)*, 2021.

[60] Ze Liu, Jia Ning, Yue Cao, Yixuan Wei, Zheng Zhang, Stephen Lin, and Han Hu. Video swin transformer. *arXiv preprint arXiv:2106.13230*, 2021.

[61] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.

[62] Xinlei Chen*, Saining Xie*, and Kaiming He. An empirical study of training self-supervised vision transformers. *arXiv preprint arXiv:2104.02057*, 2021.

[63] Patrick Helber, Benjamin Bischke, Andreas Dengel, and Damian Borth. Eurosat: A novel dataset and deep learning benchmark for land use and land cover classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 12(7):2217–2226, 2019.

[64] Maxim Neumann, Andre Susano Pinto, Xiaohua Zhai, and Neil Houlsby. In-domain representation learning for remote sensing. *arXiv preprint arXiv:1911.06721*, 2019.

[65] Hengshuang Zhao, Yi Zhang, Shu Liu, Jianping Shi, Chen Change Loy, Dahua Lin, and Jiaya Jia. Psanet: Point-wise spatial attention network for scene parsing. In *Proceedings of the European conference on computer vision (ECCV)*, pages 267–283, 2018.

[66] Alexandre Lacoste, Alexandra Luccioni, Victor Schmidt, and Thomas Dandres. Quantifying the carbon emissions of machine learning. *CoRR*, abs/1910.09700, 2019.

A 附录

A.1 数据集

fMoW RGB 世界功能地图（fMoW）[17] 是一个全球高分辨率卫星图像时序数据集，任务为在 62 种架构类别（如机场、船坞和动物园）之间进行分类。fMoW 提供了 RGB 图像以及包括位置、时间、太阳角度等在内的元数据。许可证详见此处 [2].

fMoW 提供了不同时间戳的共址图像，或称序列，其长度各不相同，约有 60% 的样本长度大于 2。读者可参考 fMoW 论文 [17] 以了解序列长度分布的统计信息。我们通过随机将每张图像与同一位置但不同时间戳的另外两张图像配对，构建了 fMoW 的时序版本（若可能）。对于给定的空间位置 loc ，我们将 T_{loc} 定义为数据集中存在的时序上不同的快照数量。

fMoW 信标 我们基于 fMoW RGB 数据集构建了一个新数据集。从哨兵-2（欧洲航天局）卫星获取地表反射率图像（美国地质调查局提供），这些图像是与 fMoW 图像相同位置的 90 天合成图像，以减少云层覆盖的影响。在每个 fMoW 数据点的位置，我们使用提供的地理坐标边界框收集哨兵-2 图像的时间序列。对于所有 fMoW 图像均早于哨兵-2 时间范围的位置，我们将其丢弃。否则，我们在哨兵-2 时间范围内，为每个 fMoW 图像收集一个以相同时间为中心的合成图像。由于许多 fMoW 图像出现在哨兵-2 之前，我们通过在 6 个月间隔内添加额外图像来扩充时间序列，这些时间段在 fMoW 数据集中没有对应图像。

我们收集了哨兵-2 提供的全部 13 个波段（B1-12 和 B8A），时间上与 fMoW 图像部分重合，同时增加了额外时间点，共计 712,874 张训练图像、84,939 张验证图像和 84,966 张测试图像。其中，155,446 张训练图像、22,602 张验证图像和 22,824 张测试图像与对应的 fMoW 图像在相同时间采集。每张图像的平均高度约为 45 像素，平均宽度约为 60 像素。

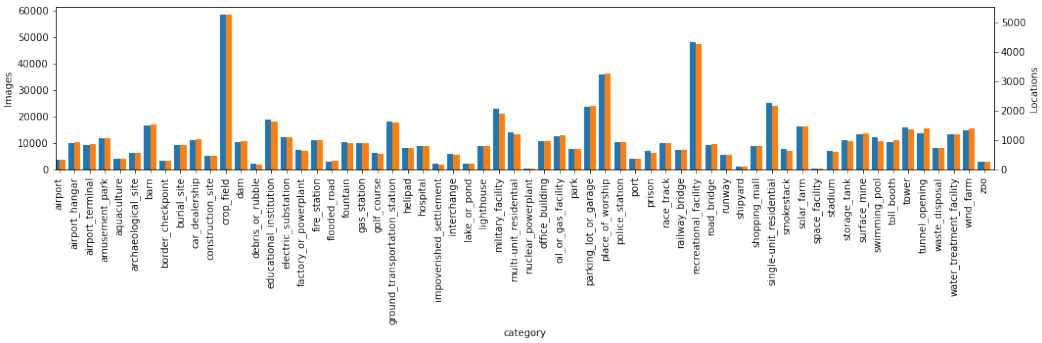

图 5: fMoW Sentinel 训练集上各类别图像与位置的分布情况。

A.2 fMoW 信标

我们提供使用哨兵-2 卫星采集的 fMoW-Sentinel 数据集的相关信息。[3].

[2] fMoW 许可证：`https://github.com/fMoW/dataset/raw/master/LICENSE`

[3] 哨兵-2 许可证：`https://scihub.copernicus.eu/twiki/pub/SciHubWebPortal/TermsConditions/Sentinel_Data_Terms_and_Conditions.pdf`

A.2.1 地理分布

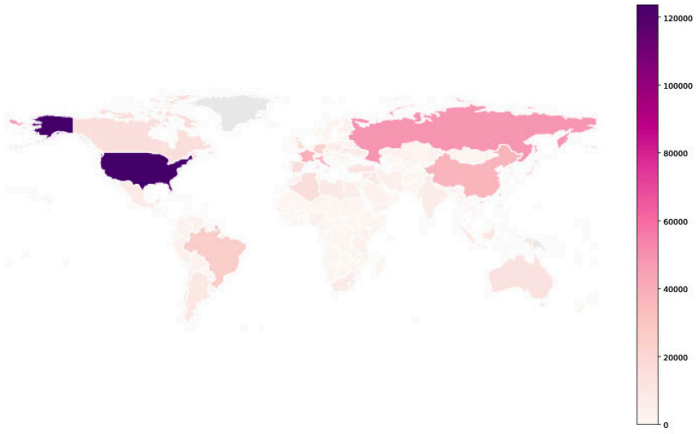

图 6: fMoW 哨兵影像按国家的地理分布

A.2.2 fMoW 侦测波段

Channel	Resolution	Central wavelength	Mean	Standard deviation
B1: Aerosols	60m	443nm	1370.192	633.152
B2: Blue	10m	490nm	1184.382	650.284
B3: Green	10m	560nm	1120.771	965.231
B4: Red	10m	665nm	1136.260	948.982
B5: Red Edge 1	20m	705nm	1263.739	1108.067
B6: Red Edge 2	20m	740nm	1645.403	1258.364
B7: Red Edge 3	20m	783nm	1846.870	1233.149
B8: NIR	10m	842nm	1762.595	1364.387
B8A: Red Edge 4	20m	865nm	1972.624	3545.66
B9: Water Vapor	60m	940nm	582.726	472.380
B10: Cirrus	60m	1375nm	14.771	14.311
B11: SWIR 1	20m	1610nm	1732.164	1310.370
B12: SWIR 2	20m	2190nm	1247.919	1087.602

表 10: 每个通道在 fMoW Sentinel 训练数据集中的像素值均值和标准差。注意，通道 B10 不包含地表底端的大气信息，且在 Google Earth Engine 上已不再可用。更多详细信息请参见 here。

A.3 训练细节

我们描述了在 fMoW RGB（非时序）(A.3.1)、fMoW RGB（时序）(A.3.2)、fMoW Sentinel (A.3.3)、NAIP (A.7)、EuroSAT (A.8)、BigEarthNet (A.9) 和 SpaceNet v1 (A.10) 上对我们的模型进行预训练和微调所使用的情景。

A.3.1 fMoW RGB（非时序）

SatMAE 预训练 我们使用 ViT-Large [36] 作为主干网络。模型配置与 [1] 相同，例如输入图像大小为 224 ，补丁大小为 $P = 16$ 。由于 fMoW 的原始图像大小差异较大，我们首

先将图像缩放，使较短边为 224 像素并保持长宽比，然后从缩放后的图像中随机裁剪出一个 224×224 区域。我们还根据整个数据集计算的均值和标准差对图像进行归一化处理。我们在 Google Cloud 上使用 8 块 NVIDIA V100 GPU 训练模型 800 轮次，学习率为 2.4×10^{-3} ，批量大小为 4096 。优化器和学习率调度器与 [1] 保持一致。

模型微调 我们在 ViT 头下方加载预训练权重，并以端到端的方式微调 ViT-Large 模型。在微调过程中，我们采用与 [1] 相同的学习率衰减和权重衰减策略。我们在预训练中应用相同的数据增强，并额外使用 Mixup 和 Cutmix 增强。我们使用 8 块 NVIDIA V100 GPU 训练模型 50 轮次，学习率为 2×10^{-3}，批量大小为 512。其他参数（包括 Mixup 系数）均与 [1] 保持一致。

A.3.2 fMoW RGB（时间）

数据集 我们以与非时序 fMoW 相同的方式遍历数据集，不同之处在于，对于每个图像样本，我们随机寻找两张具有不同时间戳的共位图像（如果可能的话），从而使每个样本变为长度为 3 的图像序列。如果缺乏足够具有不同时间戳的共位图像，我们就简单地复制原始图像。fMoW 数据集的训练/验证划分保证了共位图像属于同一划分，因此不存在数据泄露问题。

SatMAE 预训练 我们使用与上文相同的模型，尽管输入图像块的数量增加了三倍。为了引入时间编码，一个图像块空间位置的位置编码缩短为一个 $320 + 320 = 640$ 维向量，而时间编码是一个 384 维向量，其维度在年、月和小时之间均等分配。我们对掩码索引施加约束以实现不同的掩码策略。对于 *独立掩码* (4.1.2)，我们选择一种变体，即在序列中的每张图像中保持被掩码图像块的比例固定为 $p_m = 0.75$ 。对于一致裁剪选项，我们首先将图像序列调整为相同大小，然后对所有三张图像应用裁剪，而不是分别随机裁剪每张图像。我们使用 8 块 NVIDIA V100 GPU 训练模型 100 轮次，学习率为 6×10^{-4} ，批量大小为 1024 。

模型微调 我们使用 4 或 8 块 NVIDIA V100 GPU 对模型进行 50 轮次的训练，学习率为 5×10^{-4} ，批量大小为 128 。

测试时增强 与 [34] 中使用的测试时增强不同，我们对每个图像的 9 个随机图像序列样本的预测得分进行平均，作为最终的预测得分。为了与之前的实验保持一致，我们在整个验证集上计算分类准确率，而不是在具有唯一位置的子集上进行评估。这两个指标的结果非常接近。

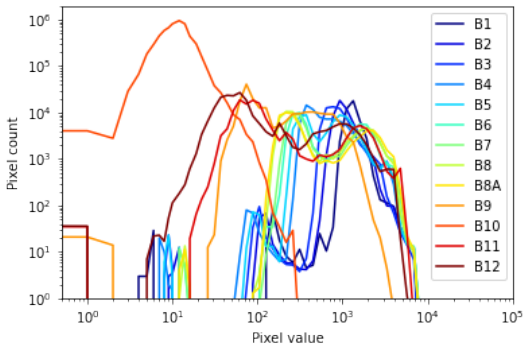

图 7: fMoW Sentinel 训练集各波段像素数量分布。

SeCo [35] 预训练与微调 我们使用 SeCo 官方仓库中的代码 [35]，以 ResNet 50 作为主干网络。在预训练阶段，我们使用 8 块 NVIDIA v100 GPU，批量大小为 128，并保持其他超参数和数据增强方式与 [35] 相同。我们对模型进行 50 轮次的预训练，观察到损失已收敛。在微调阶段，我们使用 4 块 NVIDIA v100 GPU，批量大小为 128，并同样保持其他超参数和数据增强方式与 [35] 相同。我们对模型进行 100 轮次的微调。

UTAE [48] 训练 我们使用 UTAE [48] 官方仓库中的代码，添加一个平均池化层，以将分割网络适配到分类任务。我们使用 8 块 NVIDIA v100 GPU，批量大小为 128，学习率为 5×10^{-4}，采用 AdamW 优化器且不使用权重衰减，经实验发现这是表现最佳的超参数组合。我们采用与 SatMAE 相同的数据增强策略。模型训练共进行 50 轮次。

A.3.3 fMoW 信标

我们选择 ViT-Large 骨干网络 [36] 并使用 $D = 1024$。图像块的空间位置的位置编码是一个 768 维向量，光谱组编码是一个 256 维向量。鉴于哨兵-2 影像的尺寸相对较小，我们将所有图像调整为 96×96 像素，并采用块大小 $P = 8$。这生成了 $L = (96/8)^2 = 144$ 个块，这些块被输入到 SatMAE+Stack。对于 SatMAE+Group，由于我们选取了 3 个通道组，因此有 $3L = 432$ 个块。我们曾尝试让每个通道单独作为一个组，但这导致内存占用过大，达到 $10L = 1440$ 个块，并且训练不稳定，经常出现 NaN 损失。因此，我们决定根据空间分辨率和波长相似度对波段进行分组（见 5.4）。我们在整个训练集上进行训练和微调。

SatMAE 预训练 我们使用 8 块 NVIDIA v100 GPU，有效批量大小为 4096，基础学习率为 10^{-4}，采用与 [1] 相同的预热和半周期余弦衰减调度策略。对于每张图像，我们使用标准归一化（详见 A.2.2 中的统计量），随机裁剪图像面积的 0.2 -1.0×，将其调整为 96×96 像素大小，并随机进行水平翻转。我们采用 $p_m = 0.75$ 的掩码比率，如 [1] 所发现的最优值。我们对每个模型进行 50 轮次的预训练。

MoCo 预训练 我们使用 8 张 NVIDIA v100 GPU，选择 ViT-Base 主干网络和有效的批量大小为 512，以确保模型能够放入内存。我们选择基础学习率为 10^{-4}，并采用与 [62] 相同的学习率预热和衰减策略。对于每张图像，我们使用标准归一化（详见 A.2.2 中的统计量），随机裁剪图像面积的 0.2-1.0 倍，将其调整为 96×96 像素大小，随机应用高斯模糊（$\sigma \in [0.1, 2]$），并随机进行水平翻转。我们对每个模型进行 50 轮次的预训练，并在后续所有实验中使用第 50 轮次的检查点。

模型微调 我们使用 8 块 NVIDIA v100 GPU，有效批量大小为 4096，基础学习率为 10^{-3}，采用预热和衰减调度策略。我们使用标准归一化，并将每张图像缩放至 96×96 像素。

SatMAE 进一步改进 在微调过程中（table 3 的最后一行），我们发现使用额外的数据增强方法（如 [1] 所示）后性能提升了约 2.18%。该配置与 SatMAE+Group+IM 相同，但有效批量大小为 1024，权重衰减为 0.05，丢弃路径（drop path）为 0.1，随机丢弃概率（reprob）为 0.25，mixup 为 0.8，cutmix 为 1.0。对于所有行，我们均进行 30 轮次的微调，但报告的是在验证集上达到的最佳 Top 1 准确率。

在 table 11 中，我们还报告了增加预训练的结果。与 50 轮次相比，将 SatMAE 训练 200 轮次，在使用上述配置微调 30 轮次后，最终的 top 1 准确率进一步提升。我们观察到，使用 ViT-Base 主干网络的较小模型，能够超越经过

Backbone	Pre-train epochs	Top 1 Acc.
ViT-B	200	62.65
ViT-L	50	61.48
ViT-L	200	**63.84**

表 11: 长时间预训练带来的改进。

更长时间预训练的使用 ViT-Large 主干网络的模型。我们推测，更长的预训练可能带来更大的收益。

A.4 掩码比率和图像块大小对 fMoW-RGB-时序的影响

在此，我们研究了掩码比率和块大小对 ViT-Large 模型在时序数据上的影响（采用独立掩码和一致裁剪，且不使用测试时增强）。

我们把掩码比率 p_m 从默认的 $p_m = 0.75$ 变为 0.6 和 0.9，同时将补丁大小 P 从默认的 $P = 16$ 变为 22 ，32 （table 12）。

p_m	P	Top 1 Acc.
0.6	16	72.80
0.9	16	74.78
0.75	32	69.31
0.75	22	72.08
0.75	16	**79.69**

表 12: on p_m and P on fMoW-RGB-temporal.

我们观察到，如预期所示，7.19% 在掩码比例较小时性能显著下降 [1],因为较低的掩码比例使模型更容易重建被遮挡的图像块，因为它可以访问更多的可见图像块。较高的掩码比例 0.9 可能会导致预训练任务变得困难，因为图像中剩余的可见图像块过少，可能需要更长的训练时间。因此，我们发现使用 $p_m = 0.75$ 大致是最优的。

我们还注意到，使用更大的图像块大小会导致性能下降，因为模型从图像中获取的细粒度空间信息减少。这与其他 MAE 研究结果一致 [1, 54]。然而，使用更大的图像块大小也更具计算效率，因此必须权衡准确率与计算资源之间的关系。

A.5 掩码比率和补丁大小对 fMoW-Sentinel 的影响

p_m	P	Top 1 Acc.
0.6	8	50.68
0.9	8	59.28
0.75	16	55.02
0.75	8	**59.30**

表 13: 在 fMoW-Sentinel 上对 p_m 和 P 的消融实验。

在本节中，我们研究了掩码比率 p_m 和补丁大小 P (table 13) 对 SatMAE 在多光谱数据上的影响。我们采用 ViT-Large 主干网络，并使用 SatMAE+Group+IM 情景，因为这是我们表现最佳的设计。

正如我们所预期的，较低的掩码比率会导致一个较弱的预训练任务，因为模型在可见块较多的情况下能够轻松重建图像，因此其表示作用较弱。有趣的是，$p_m = 0.9$ 并未导致性能出现大幅下降，与 [1] 不同。这表明对于具有独立掩码的多光谱数据，可以使用更高的掩码比率，因为在编码状态中产生的 token 较少，可能加快预训练过程。

我们发现，较大的块大小会导致性能下降。这是意料之中的，因为较大的块大小会向模型的深层提供较少的精细空间信息，可能会削弱其表达能力。如上所述，必须将准确率的损失与训练速度的提升进行权衡。未来的研究方向可以进一步探讨块大小逐步增加所带来的具体速度提升和准确率下降情况，以获得更深入的见解。

A.6 选择重要的多光谱波段

如5.4所述，哨兵-2 数据的所有 13 个波段可能并非都有效。在我们的实验中，我们去除了波段 B1、B9 和 B10。为了准确判断每个波段的有用性，需要使用除目标波段外的所有波段进行预训练，然后在不使用该波段的情况下微调模型，并测量验证集上的性能变化。然而，这种做法在计算资源方面开销过大。因此，我们使用 ViT Base 主干网络，在 fMoW Sentinel 的全部 13 个哨兵-2 波段上预训练了一个 SatMAE+Stack 模型，然后使用全部 13 个波段在

fMoW Sentinel 的图像分类任务上对模型进行微调。利用微调后的模型，我们进行了消融实验，通过将部分波段用其均值掩码，并测量验证集准确率的下降情况。由于模型训练时依赖于全部 13 个波段的信息，若掩码某些波段后准确率下降较小，表明这些波段对模型表现可能帮助不大。

Bands Masked	Top 1 Acc.	Top 5 Acc.
None	57.80	80.07
B1	45.83	69.46
B2, B3, B4	17.46	35.05
B5, B6, B7	13.25	35.33
B8, B8A	16.03	35.36
B9, B10	55.06	78.15
B11, B12	27.83	54.41

表 14: 一项消融实验，旨在确定在 fMoW Sentinel 的全部 13 个波段上预训练并微调的 SatMAE+Stack 模型中，哪一个波段的贡献最小。在评估过程中，对于每张图像，相关波段均用其在 table 10 中记录的均值进行掩码处理，然后直接输入到微调后的 SatMAE+Stack 模型中。

如 table 14所示，我们注意到在掩码 B9 和 B10 时准确率下降最小。当掩码 B1 时，准确率下降较大，但可能是由于模型在微调期间依赖了 B1 中可能不重要的信号所致。因此，我们在 section 5.4的实验中也移除了 B1。我们注意到 RGB 和其他多光谱波段对我们的模型非常重要。

A.7 NAIP 地表覆盖分类

我们使用与 fMoW RGB（非时序）微调实验 (A.3.1) 中相同的微调情景。

A.8 EuroSAT 土地覆盖分类

我们使用与 fMoW RGB(非时序)微调实验中相同的精确微调情景用于仅 RGB 输入 (A.3.1)。对于多光谱(13 波段)输入,我们也采用 fMoW-Sentinel 微调实验中的精确微调情景(A.3.3),但训练轮次更长（150 轮次)。模型收敛时间较长，很可能是因为 EuroSAT 数据集相比之下要小得多。许可证[4] 见脚注。

A.9 BigEarthNet 土地覆盖多标签分类

我们采用与 fMoW-Sentinel 微调实验中相同的精确微调情景 (A.3.3)。由于该任务是多标签分类而非单标签分类，我们将训练目标改为多标签软间隔损失。我们使用 [35] 中提供的平均精度均值作为评估指标。许可证 [5] 见脚注。

A.10 SpaceNet v1 建筑分割

我们使用 PSANet [65] 进行二值图像分割，并将主干网络替换为 ViT-Large。遵循 [34]，我们将 ViT 编码器的学习率设置为 1×10^{-3}，ViT 头和 PSA 模块的学习率设置为 1×10^{-2}。我们以批量大小 128 训练模型 100 轮次，采用动量为 0.9、权重衰减为 1×10^{-4} 的 SGD 优化器，并使用幂次学习率衰减调度器，其幂次为 0.9。同时遵循 [34]，我们将输入图像调整

[4]EuroSAT 许可证：`https://creativecommons.org/licenses/by/4.0/`

[5]BigEarthNet 许可证：`https://bigearth.net/downloads/documents/License.pdf`

大小并裁剪至 400×400 以进行公平比较。这表明我们的模型每张图像将处理更多的图像块（625 个）。我们使用 [1] 提供的位置编码插值算法来调整预训练权重。许可证[6] 见脚注。

[6]SpaceNet v1 许可证：`http://creativecommons.org/licenses/by-sa/4.0/`

B 社会影响

经济、社会和环境指标的测量对于全球政策制定至关重要。然而，这些测量经常不足，阻碍了决策过程。

与使用传统测量方法（如地面调查）不同，我们的方法利用了丰富、全球可获取且频繁更新的未标记卫星数据。我们的模型能够从遥感影像中捕捉对关键下游任务有益的表示，包括贫困预测、基础设施发展和人口估算。政府可以将此类信息有效应用于决策，从而带来显著的社会效益。

尽管卫星图像的使用可能被恶意演员滥用并导致数据滥用和隐私侵犯，但我们认为，基于公开可获取的卫星图像训练的模型的应用尊重了隐私，并避免暴露敏感信息。例如，从这些图像中难以提取出可辨认的个人身份信息。因此，我们认为所使用的图像并不直接构成隐私问题。

然而，我们注意到，如果训练数据存在偏差，SatMAE 学成的表示可能会受到相应影响。例如，若 SatMAE 在地理分布不平衡的数据上进行训练，模型可能会偏向某些区域，尤其是北美洲和欧洲地区（见 6）。因此，我们建议研究人员在将我们的 SatMAE 模型直接应用于地理分布与 fMoW RGB 和 fMoW Sentinel 不同的数据集时需保持警惕。

在代码发布时，我们还将明确允许的使用范围，并附上相应的许可协议。

B.1 碳足迹

我们将在下面简要分析训练该模型的碳足迹。

我们的实验主要在 Google Cloud Platform (GCP) 的 us-central1 区域进行，该区域的碳效率为 0.57 kg CO_2 eq. 每 kWh。对于在 fMoW RGB（时间）数据集上预训练并微调的模型，需要在 Tesla V100-SXM2-16GB（TDP 为 250W）硬件类型上累计 960 小时的计算量。总排放量估计为 136.8 kg CO_2 eq.，其中 100% 由云服务提供商直接抵消。估算使用了 [66] 中提出的机器学习影响计算器。对于在 fMoW Sentinel 数据集上预训练并微调的模型，总排放量估计为 109.44 kg CO_2 eq. 我们在 table 15 中列出了粗略估算的表格。

Experiment Setting	Dataset	GPU hours	Carbon Footprint (kg CO_2 eq.)
Pre-training	fMoW RGB temporal	768	109.44
Finetuning	fMoW RGB temporal	192	27.36
Pre-training	fMoW Sentinel	576	82.08
Finetuning	fMoW Sentinel	192	27.36
Finetuning	NAIP	30	4.27
Finetuning	EuroSAT	4	0.57
Finetuning	SpaceNet	50	7.12
Finetuning	BigEarthNet	16	2.28

表 15: 在这些数据集上对 SatMAE 进行预训练和微调的碳足迹估算。GPU 小时数是在 GCP 的 us-central1 区域使用 8 块 NVIDIA V100 GPU 测量的。

C 可视化

在本节中，我们包含了时间（C.1）和多光谱（C.2）情景下的可视化结果。

C.1 时间模型

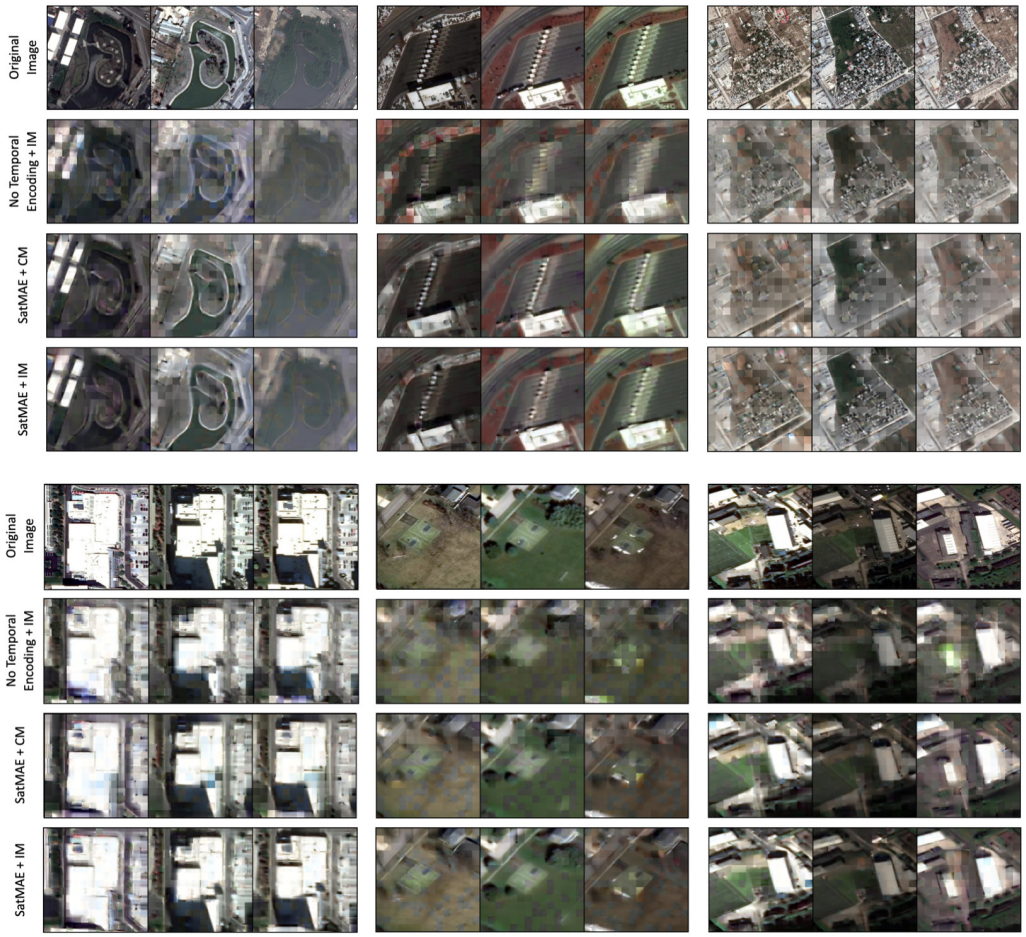

图 8: 更多来自 fMoW 时序数据集的图像序列重构质量的可视化示例，涵盖多种情景，包括不使用时序编码 +IM（独立掩码）、默认设置 +CM、默认设置 +IM。

如图 fig. 8所示，SatMAE+IM 实现了相对满意的重构质量。若不使用时间编码，所有三幅图像的图像块无法区分，我们观察到第二列的重构结果中混合了三幅图像。如前所述，采用独立掩码可使 SatMAE 利用其他时间块的信息来重构时序中的某一幅图像。我们的实验表明，这有助于 SatMAE 学习到更好的卫星影像表示。

C.2 谱模型

我们还可视化了不同多光谱设置下的图像修复质量，包括 SatMAE+Group+IM、SatMAE+Group+CM (4.2, 4.2)，以及 SatMAE+Stack (4.2) 在 fig. 9 和 fig. 10 中的情景。

我们可以清楚地看到，在 SatMAE+Group+IM 的条件下，重构质量相比 SatMAE+Group+CM 和 SatMAE+Stack 有明显提升。独立掩码导致了更清晰的重构结

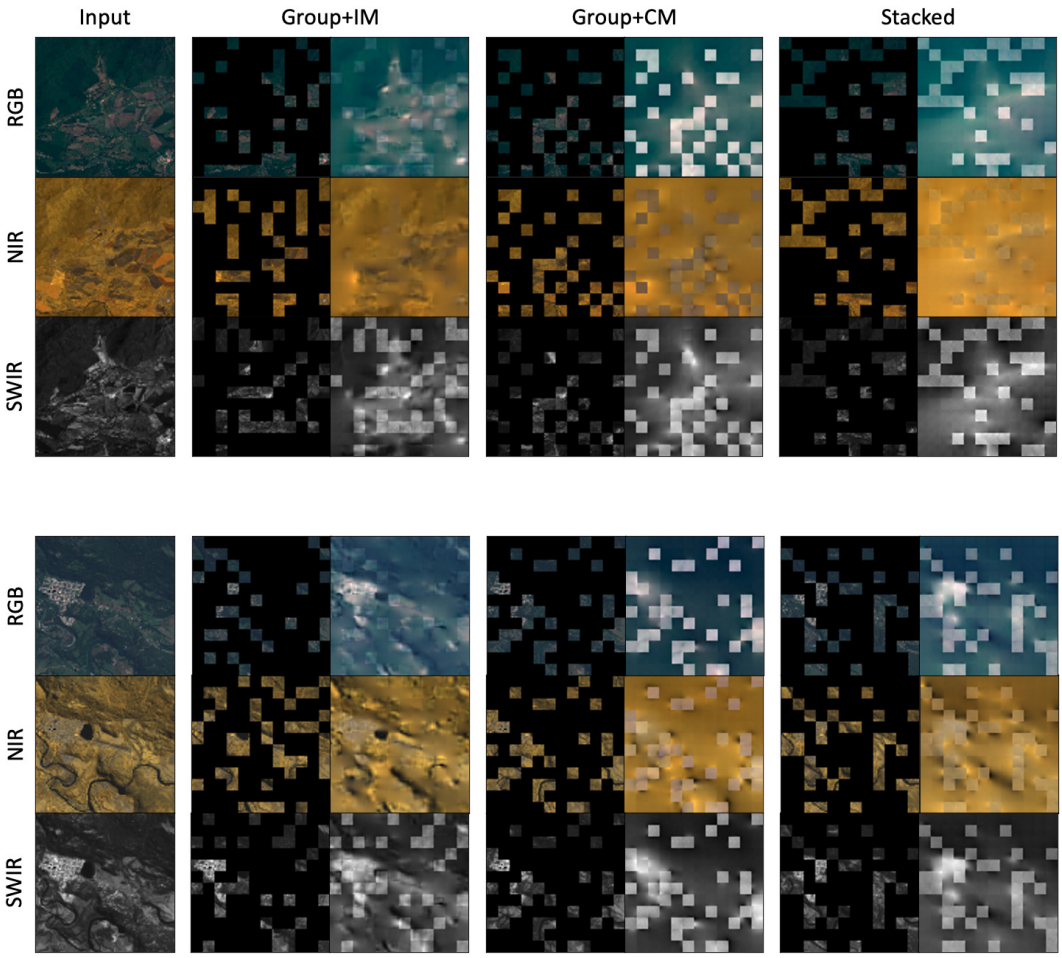

图 9: 不同情景下 SatMAE 的图像修复可视化。RGB 表示来自组 B2, B3, B4, B8 的波段 B4, B3, B2。NIR 表示来自组 B5, B6, B7, B8A 的波段 B7, B6, B5。SWIR 表示以灰度显示的波段 B11，来自组 B11, B12。对于每种方法，我们并排展示输入波段组的掩码部分与重构结果。需要注意的是，可见区域的重构效果不如掩码区域，因为对可见区域不计算损失。两半均代表机场的多光谱图像。

果，而一致掩码和通道堆叠的结果则要模糊得多。我们还注意到，该模型能够学习波段之间的相关性；在 fig. 9 的短波红外波段组的上半部分，尽管图像右下角被掩码，SatMAE+Group+IM 仍能基于其他波段组的信息重构出亮斑。

我们假设，通过更长的预训练，可以进一步提升重构质量和学成表示。

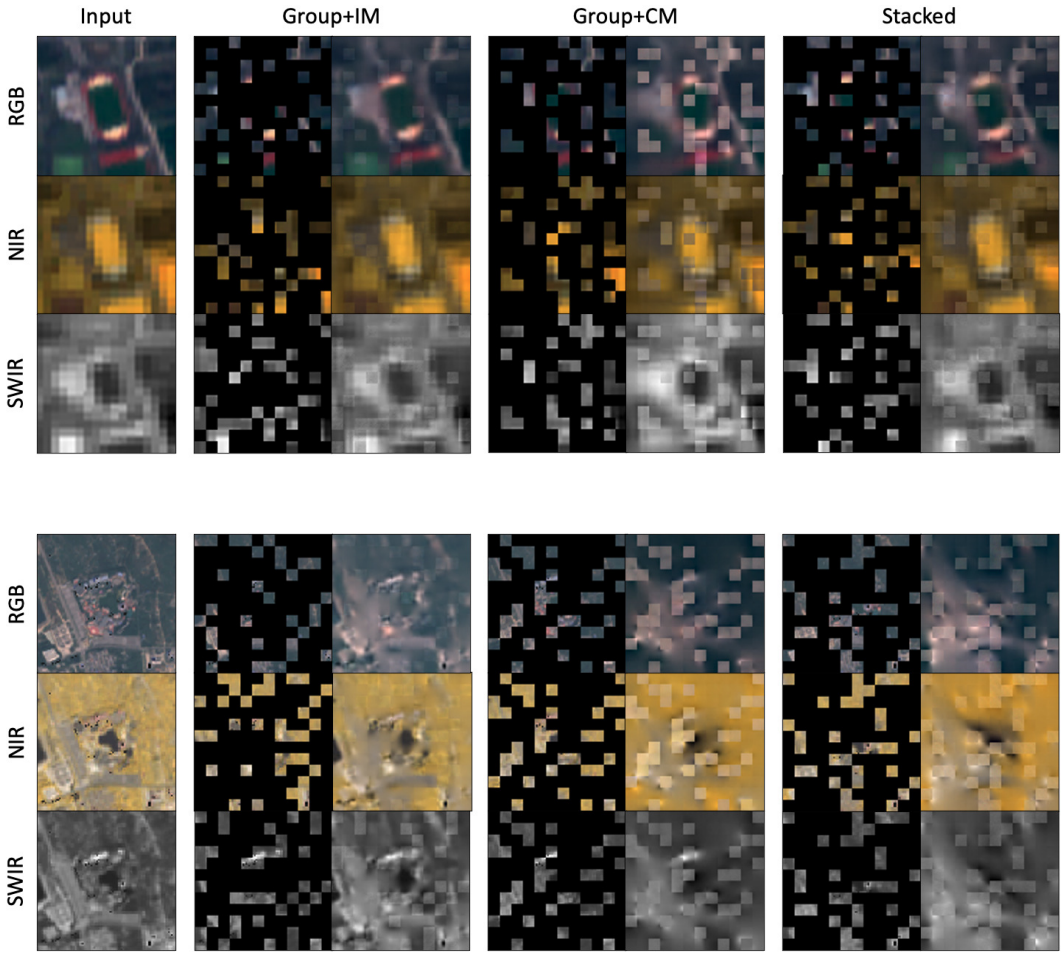

图 10: SatMAE 的更多内补可视化结果。有关波段组的详细信息，请参见 fig. 9。上半部分为一个休闲设施的多光谱图像，下半部分为一个游乐园的图像。