https://hjfy.top/arxiv/2301.08243

从图像中进行自监督学习，采用联合嵌入预测架构

Mahmoud Assran[1,2,3]* Quentin Duval[1] Ishan Misra[1] Piotr Bojanowski[1]
Pascal Vincent[1] Michael Rabbat[1,3] Yann LeCun[1,4] Nicolas Ballas[1]

[1]Meta AI (FAIR) [2]McGill University [3] Mila, Quebec AI Institute [4]New York University

Abstract

本文展示了一种无需依赖手工数据增强即可学习高度语义化图像表示的方法。我们提出了基于图像的联合嵌入预测架构 (I-JEPA)，这是一种用于图像自监督学习的非生成方法。I-JEPA 的核心思想很简单：从单一上下文块中预测同一图像内多个目标块的表示。引导 I-JEPA 生成语义表示的一个关键设计选择是掩码策略；具体而言，必须确保（a）采样具有足够大尺度（语义）的目标块，以及（b）使用信息量充足（空间分布）的上下文块。实验表明，当与视觉 Transformer 结合时，I-JEPA 展现出极高的可扩展性。例如，我们在 ImageNet 上使用 16 块 A100 GPU 训练 ViT-Huge/14，耗时不到 72 小时，便在从线性分类到物体计数及深度预测等一系列任务中实现了强劲的下游性能。

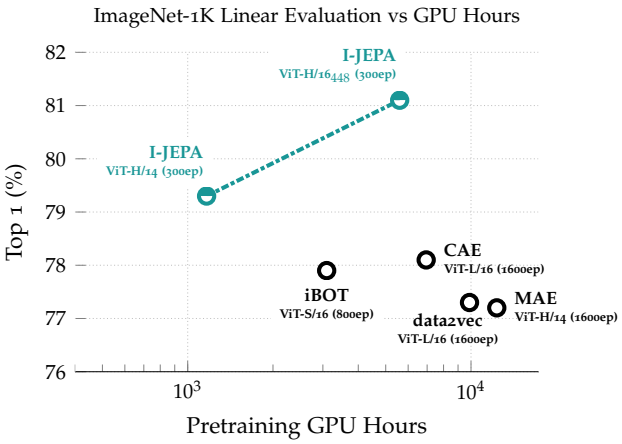

图 1. ImageNet **线性评估**。I-JEPA 方法在预训练期间不使用任何视图数据增强来学习语义图像表示。通过在表示空间中进行预测，I-JEPA 在比先前方法使用更少计算资源的同时，生成了语义表示。

1. 引言

在计算机视觉中，从图像中进行自监督学习的两类常见方法是基于不变性的方法 [1,4,10,17,18,24,35,37,74] 和生成式方法 [8,28,36,57]。

基于不变性的预训练方法优化编码器，使其为同一图像的两个或多个视图生成相似的嵌入 [15,20]，其中图像视图通常通过一组手工设计的数据增强技术构建，如随机缩放、裁剪和颜色抖动 [20]，以及其他方法 [35]。这些预训练方法能够生成具有高语义层次的表示 [4,18]，但它们也引入了强烈的偏差，这些偏差可能对某些下游任务甚至对不同数据分布的预训练任务有害 [2]。通常，如何将这些偏差泛化到需要不同抽象层次的任务上并不明确。例如，图像分类和实例分割并不需要相同的不变性 [11]。此外，将这些特定于图像的增强技术泛化到其他模态（如音频）也并非易事。

认知学习理论认为，生物系统中表示学习的驱动力是内部模型的适应，以预测感觉输入响应 [31,59]。这一理念是自监督生成方法的核心，这些方法会移除或破坏输入的一部分，并学习预测被破坏的内容 [9,36,57,67,68,71]。特别是，掩码-降噪方法通过从输入中重建随机掩码的块来学习表示，可以在像素或 token 级别进行。掩码预训练任务所需的先验知识比视图不变性方法少，并且容易泛化到图像模态之外 [8]。然而，生成的表示通常语义层次较低，在现成评估（例如，线性探测）和有限监督的语义分类任务的迁移设置中表现不如基于不变性的预训练 [4]。因此，需要更复杂的适

*massran@meta.com

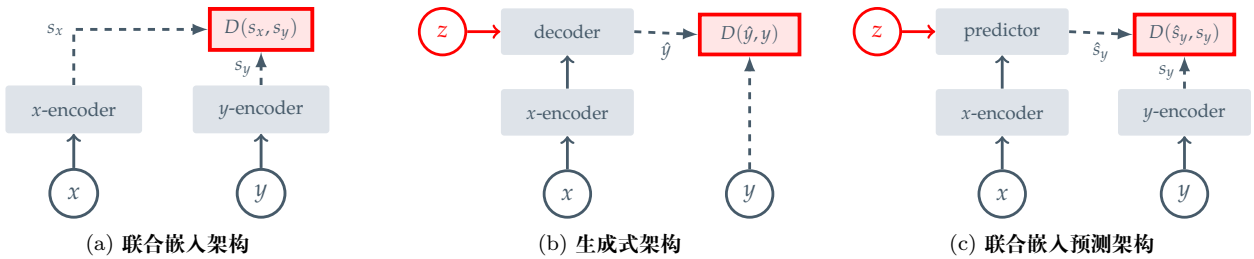

(a) **联合嵌入架构** (b) **生成式架构** (c) **联合嵌入预测架构**

图 2. 自监督学习的常见架构，系统学习捕捉其输入之间的关系。目标是为不兼容的输入分配高能量（较大的标量值），并为兼容的输入分配低能量（较小的标量值）。(a) 联合嵌入架构学习为兼容的输入输出相似的嵌入 x, y，并为不兼容的输入输出不同的嵌入。(b) 生成架构学习直接从兼容的信号 x 重构信号 y，使用一个解码器网络，该网络基于额外的（可能是潜在的）变量 z 来促进重构。(c) 联合嵌入预测架构学习从兼容的信号 x 预测信号 y 的嵌入，使用一个预测器网络，该网络基于额外的（可能是潜在的）变量 z 来促进预测。

应机制（例如，端到端微调）才能充分利用这些方法的优势。

在本工作中，我们探索了如何在不通过图像变换编码额外先验知识的情况下，提升自监督表示的语义水平。为此，我们引入了一种用于图像的联合嵌入预测架构 [48]（I-JEPA ）。该方法的示意图见图 3。I-JEPA 背后的思想是在抽象表示空间中预测缺失信息；例如，给定单个上下文块，预测同一图像中多个目标块的表示，其中目标表示由学成的目标编码器网络计算得出。

与在像素/token 空间中进行预测的生成方法相比，I-JEPA 利用抽象预测目标，潜在地消除了不必要的像素级细节，从而引导模型学习更具语义的特征。另一个指导 I-JEPA 生成语义表示的核心设计选择是提出的多块掩码策略。具体而言，我们展示了在图像中预测足够大的目标块的重要性，并使用信息丰富（空间分布）的上下文块。

通过广泛的实证评估，我们证明了：

- I-JEPA 无需使用手工设计的视图增强即可学习到强大的现成表示（参见图1）。I-JEPA 在 ImageNet-1K 线性探测、半监督 1% ImageNet-1K 以及语义迁移任务上，均优于 MAE [36] 等像素重构方法。
- I-JEPA 在语义任务上与视角不变的预训练方法具有竞争力，并在低层次视觉任务（如物体计数和深度预测）上实现了更好的性能（参见第 5 和 6 节）。通过使用一个更简单、归纳偏置更不严格的模型，I-JEPA 适用于更广泛的任务集。
- I-JEPA 同样具备可扩展性和高效性（第 7 节）。在 ImageNet 上预训练一个 ViT-H/14 所需的 GPU 时间少于 1200 小时，比使用 iBOT [79] 预训练的 ViT-S/16 快 2.5× 倍以上，比使用 MAE 预训练的 ViT-H/14 效率高出 10× 倍。在表示空间中进行预测显著减少了自监督预训练所需的总计算量。

2. 背景

自监督学习是一种表示学习方法，其中系统学习捕捉其输入之间的关系。此目标可以使用基于能量的模型（EBM）[49] 的框架来轻松描述，在该框架中，自监督目标是为不兼容的输入分配高能量，并为兼容的输入分配低能量。许多现有的生成和非生成方法的自监督学习确实可以在此框架中表示；参见图 2。

联合嵌入架构。 基于不变性的预训练可以在使用联合嵌入架构（JEA）的能量基模型（EBM）框架中进行，该架构学习为兼容的输入输出相似的嵌入，$\boldsymbol{x}, \boldsymbol{y}$，并为不兼容的输入输出不同的嵌入；参见图 2a。在基于图像的预训练背景下，兼容的 $\boldsymbol{x}, \boldsymbol{y}$ 对通常通过对同一输入图像随机应用手工设计的数据增强来构建 [20]。

JEA 的主要挑战在于表示崩溃，即能量景观平坦（即无论输入如何，编码器都产生恒定输出）。过去几年中，已经研究了几种方法来防止表示崩溃，例如对比损失，它明确地将负例的嵌入分开 [15, 24, 37]；非对比损失，它最小化嵌入间的信息冗余 [10, 74]；以及基于聚类的方法，它最大化平均嵌入的熵 [4, 5, 18]。此外，还有一些启发式方法，通过利用 x -编码器和 y -编码器之间的非对称架构设计来避免崩溃 [8, 24, 35]。

生成架构。 基于重构的自监督学习方法也可以在使用生成架构的 EBM 框架中进行；参见图 2b。生成架构通过学习直接从兼容信号 $\boldsymbol{x}$ 中重构信号 $\boldsymbol{y}$，利用一个解码器网络，该网络以额外的（可能是潜在的）变量 $\boldsymbol{z}$ 为条件，以促进重构。在基于图像的预训练背景下，计算机视觉中的一种常见方法是通过掩码 [9, 38] 生成兼容的 $\boldsymbol{x}, \boldsymbol{y}$ 对，其中 $\boldsymbol{x}$ 是图像 $\boldsymbol{y}$ 的副本，但部分图像块被掩码。条件变量 $\boldsymbol{z}$ 则对应一组（可能是可学习的）掩码和位置 token，它们向解码器指定要重构哪些图像块。只要 $\boldsymbol{z}$ 的信息容量相对于信号 $\boldsymbol{y}$ 较低，这些架构就不会出现表示崩溃的问题。

联合嵌入预测架构。 如图 2c所示，联合嵌入预测架构 [48] 在概念上与生成架构相似；然而，一个关键区别在于损失函数是在嵌入空间中应用，而非输入空间。JEPAs 通过学习从兼容信号 $\boldsymbol{x}$ 预测信号 $\boldsymbol{y}$ 的嵌入，利用一个预测器网络，该网络以额外（可能为潜在）变量 $\boldsymbol{z}$ 为条件来促进预测。我们提出的 I-JEPA 在图像背景下使用掩码提供了该架构的一个实例；参见图 3。

与联合嵌入架构相反，JEPAs 不寻求对一组手工设计的数据增强保持不变的表示，而是寻求在附加信息条件下彼此具有预测性的表示 $\boldsymbol{z}$ 。然而，与联合嵌入架构一样，表示崩溃也是 JEPAs 的一个关注点；我们利用 $\boldsymbol{x}$ -和 $\boldsymbol{y}$ -编码器之间的非对称架构来避免表示崩溃。

3. 方法

我们现在描述所提出的基于图像的联合嵌入预测架构（I-JEPA ），如图 3 所示。总体目标如下：给定一个上下文块，预测同一图像中各个目标块的表示。我们使用 Vision Transformer [29, 63]（ViT）架构作为上下文编码器、目标编码器和预测器。ViT 由一系列 Transformer 层组成，每层包括一个自注意力 [66] 操作，后接一个全连接的 MLP。我们的编码器/预测器架构让人联想到生成式掩码自编码器（MAE） [36] 方法。然而，一个关键区别在于 I-JEPA 方法是非生成式的，且预测是在表示空间中进行的。

目标。 我们首先描述如何在 I-JEPA 框架中生成目标：在 I-JEPA 中，目标对应于图像块的表示。给定输入图像 $\boldsymbol{y}$，我们将其转换为 N 个不重叠的补丁序列，并通

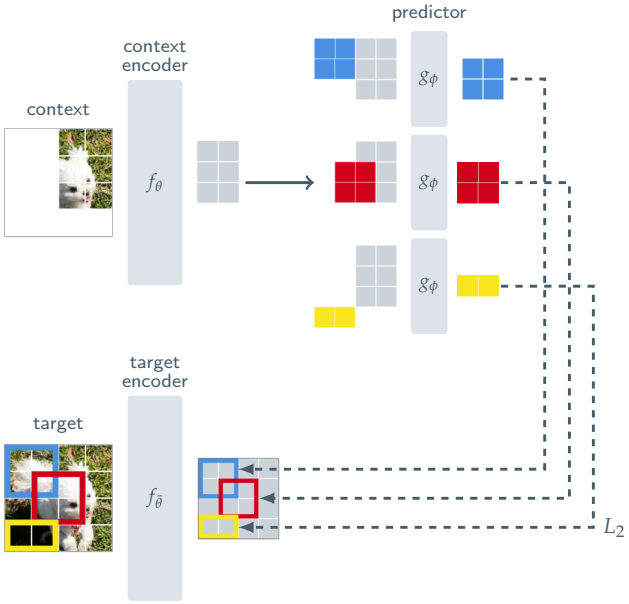

图 3. I-JEPA. 基于图像的联合嵌入预测架构使用单一上下文块来预测源自同一图像的各种目标块的表示。上下文编码器是一个视觉 Transformer（ViT），它仅处理可见的上下文补丁。预测器是一个窄的 ViT，它接收上下文编码器的输出，并在位置 token（以彩色显示）的条件下，预测特定位置目标块的表示。目标表示对应于目标编码器的输出，其权重通过上下文编码器权重的指数移动平均在每次迭代中更新。

图 4. 我们的上下文和目标掩码策略示例。给定一张图像，我们随机采样 4 个目标块，其尺度在值域 $(0.15, 0.2)$ 内，长宽比在值域 $(0.75, 1.5)$ 内。接着，我们随机采样一个上下文块，其尺度在值域 $(0.85, 1.0)$ 内，并移除任何重叠的目标块。在此策略下，目标块相对具有语义，而上下文块信息丰富且稀疏（便于处理）。

过目标编码器 $f_{\bar{\theta}}$ 进行处理，以获得相应的补丁级表示 $\boldsymbol{s}_y = \{\boldsymbol{s}_{y_1}, \ldots, \boldsymbol{s}_{y_N}\}$，其中 $\boldsymbol{s}_{y_k}$ 是与第 k^{th} 个补丁相关联的表示。为了获得损失函数的目标，我们从目标表示 $\boldsymbol{s}_y$ 中随机采样 M 个（可能重叠的）块。我们用 B_i 表示第 i^{th} 个块对应的掩码，用 $\boldsymbol{s}_y(i) = \{\boldsymbol{s}_{y_j}\}_{j \in B_i}$ 表示其补丁级表示。通常，我们将 M 设置为 4，并在值域 $(0.75, 1.5)$ 内随机采样块的长宽比，在值域 $(0.15, 0.2)$ 内随机采样块的尺度。请注意，目标块是通过对目标编码器的输出进行掩码获得的，而不是对输入进行掩码。这一区别对于确保高语义层次的目标表示至关重要；参见，例如，[8]。

背景. 召回率，I-JEPA 的目标是从单个上下文块预测目标块的表示。在 I-JEPA 中获取上下文时，我们首先从图像中以随机比例在值域 $(0.85, 1.0)$ 内采样一个块 $\boldsymbol{x}$，并保持单位宽高比。我们用 B_x 表示与上下文块 $\boldsymbol{x}$ 相关联的掩码。由于目标块是独立于上下文块采样的，可能存在显著的重叠。为了确保预测任务具有挑战性，我们从上下文块中移除任何重叠区域。图 4 展示了实践中各种上下文和目标块的示例。接下来，掩码后的上下文块 $\boldsymbol{x}$ 通过上下文编码器 f_θ 进行处理，以获得相应的补丁级表示 $\boldsymbol{s}_x = \{\boldsymbol{s}_{x_j}\}_{j \in B_x}$。

预测。 给定上下文编码器的输出 $\boldsymbol{s}_x$，我们希望预测 M 个目标块表示 $\boldsymbol{s}_y(1), \ldots, \boldsymbol{s}_y(M)$。为此，对于对应于目标掩码 B_i 的给定目标块 $\boldsymbol{s}_y(i)$，预测器 $g_\phi(\cdot, \cdot)$ 将上下文编码器的输出 $\boldsymbol{s}_x$ 和每个我们希望预测的补丁的掩码 token $\{\boldsymbol{m}_j\}_{j \in B_i}$ 作为输入，并输出补丁级别的预测 $\hat{\boldsymbol{s}}_y(i) = \{\hat{\boldsymbol{s}}_{y_j}\}_{j \in B_i} = g_\phi(\boldsymbol{s}_x, \{\boldsymbol{m}_j\}_{j \in B_i})$。这些掩码 token 由一个共享的可学习向量参数化，并添加了位置嵌入。由于我们希望为 M 个目标块进行预测，因此我们应用预测器 M 次，每次根据我们希望预测的目标块位置对应的掩码 token 进行条件化，并获得预测 $\hat{\boldsymbol{s}}_y(1), \ldots, \hat{\boldsymbol{s}}_y(M)$。

损失。 损失简单地是预测的补丁级表示 L_2 与目标补丁级表示 $\boldsymbol{s}_y(i)$ 之间的平均 $\hat{\boldsymbol{s}}_y(i)$ 距离；即，

$$\frac{1}{M} \sum_{i=1}^{M} D\left(\hat{\boldsymbol{s}}_y(i), \boldsymbol{s}_y(i)\right) = \frac{1}{M} \sum_{i=1}^{M} \sum_{j \in B_i} \|\hat{\boldsymbol{s}}_{y_j} - \boldsymbol{s}_{y_j}\|_2^2.$$

预测器 ϕ 和上下文编码器 θ 的参数通过基于梯度的最优化学习，而目标编码器 $\bar{\theta}$ 的参数则通过上下文编码器参数的指数移动平均更新。使用指数移动平均的目标编码器已被证明对于训练带有 Vision Transformers [18, 25, 79] 的 JEAs 至关重要，我们发现对于 I-JEPA 同样如此。

4. 相关工作

一系列长期的研究通过预测缺失或受损感官输入的值来探索视觉表示学习。降噪自编码器使用随机噪声作为输入损坏 [67]。上下文编码器根据其周围环境回归整个图像区域 [57]。其他工作将图像着色任务视为降噪任务 [46, 47, 77]。

图像降噪的理念最近在掩码图像建模 [9, 36, 71] 的背景下被重新审视，其中使用 Vision Transformer [29] 来重构缺失的输入块。关于掩码自编码器（MAE）[36] 的研究提出了一种高效的架构，仅需编码器处理可见的图像块。通过在像素空间中重构缺失块，MAE 在大型标注数据集上进行端到端微调时表现出色，并展现了良好的缩放特性。BEiT [9] 则在一个 token 化的空间中预测缺失块的值；具体而言，利用一个在包含 2.5 亿张图像的数据集上训练好的冻结离散 VAE 对图像块进行 token 化 [58]。然而，像素级预训练已被证明在微调时优于 BEiT [36]。另一项工作 SimMIM [71] 探索了基于经典梯度直方图 [27] 特征空间的重构目标，并展示出相较于像素空间重构的某些优势。与这些工作不同，我们的表示空间是在训练过程中通过联合嵌入预测架构学成的。我们的目标是学习语义表示，这些表示无需在下游任务上进行大量微调。

与我们的工作最为接近的是 data2vec [8] 和 Context Autoencoders [25]。data2vec 方法通过学习预测通过在线目标编码器计算出的缺失补丁的表示；通过避免手工设计的增强，该方法可以应用于多种模态，在视觉、文本和语音领域取得了有前景的结果。Context Autoencoders 使用编码器/解码器架构，通过重构损失和对齐约束的总和进行优化，这增强了表示空间中缺失补丁的可预测性。与这些方法相比，I-JEPA 在计算效率上展现出显著提升，并学习了更具语义的即用表示。与我们工作同时，data2vec-v2 [7] 探索了用于多种模态学习的高效架构。

我们还比较了 I-JEPA 与基于联合嵌入架构的各种方法；例如，DINO [18]、MSN [4] 和 iBOT [79]。这些方法在预训练期间依赖于手工设计的数据增强来学

Method	Arch.	Epochs	Top-1
Methods without view data augmentations			
data2vec [8]	ViT-L/16	1600	77.3
MAE [36]	ViT-B/16	1600	68.0
	ViT-L/16	1600	76.0
	ViT-H/14	1600	77.2
CAE [22]	ViT-B/16	1600	70.4
	ViT-L/16	1600	78.1
I-JEPA	ViT-B/16	600	72.9
	ViT-L/16	600	77.5
	ViT-H/14	300	79.3
	ViT-H/16_{448}	300	81.1
Methods using extra view data augmentations			
SimCLR v2 [21]	RN152 (2×)	800	79.1
DINO [18]	ViT-B/8	300	80.1
iBOT [79]	ViT-L/16	250	81.0

表 1. ImageNet。在 ImageNet-1k 上的线性评估（ViT-H/16_{448} 在 448×448 分辨率下进行预训练）。与其他在预训练期间不依赖手工视图数据增强的方法相比，I-JEPA 提高了线性探测性能。此外，I-JEPA 展示了良好的可扩展性——更大的 I-JEPA 模型在不需视图数据增强的情况下，匹配了视图不变性方法的性能。

Method	Arch.	Epochs	Top-1
Methods without view data augmentations			
data2vec [8]	ViT-L/16	1600	73.3
MAE [36]	ViT-L/16	1600	67.1
	ViT-H/14	1600	71.5
I-JEPA	ViT-L/16	600	69.4
	ViT-H/14	300	73.3
	ViT-H/16_{448}	300	77.3
Methods using extra view data augmentations			
iBOT [79]	ViT-B/16	400	69.7
DINO [18]	ViT-B/8	300	70.0
SimCLR v2 [35]	RN151 (2×)	800	70.2
BYOL [35]	RN200 (2×)	800	71.2
MSN [4]	ViT-B/4	300	75.7

表 2. ImageNet-1%。在仅使用 1% 可用标签的情况下，对 ImageNet-1K 进行半监督评估。根据每种方法的最佳表现，模型通过微调或线性探测进行适配。ViT-H/16_{448} 在分辨率 448×448 下进行预训练。I-JEPA 预训练优于 Mae，后者在预训练期间同样不依赖手工设计的数据增强。此外，I-JEPA 受益于规模。在分辨率 448 下训练的 ViT-H/16 超越了包括利用额外手工设计数据增强方法在内的先前方法。

习语义图像表示。MSN [4] 的工作在预训练中使用掩码作为额外的数据增强，而 iBOT 则将 data2vec 风格的补丁级重构损失与 DINO 的视图不变性损失相结合。这些方法的共同点是需要处理每个输入图像的多个用户生成视图，从而限制了可扩展性。相比之下，I-JEPA 仅需处理每个图像的单一视图。我们发现，使用 I-JEPA 训练的 ViT-Huge/14 所需的计算量少于使用 iBOT 训练的 ViT-Small/16。

5. 图像分类

为了证明 I-JEPA 在不依赖手工设计的数据增强的情况下学习到高级表示，我们使用线性探测和部分微调协议在各种图像分类任务上报告了结果。在本节中，我们考虑了在 ImageNet-1K 数据集 [60] 上预训练的自监督模型。预训练和评估的实现细节在附录 A 中描述。除非另有说明，所有 I-JEPA 模型均在 224×224 像素分辨率下进行训练。

ImageNet-1K. 表 1展示了在常见的 ImageNet-1K 线性评估基准上的性能表现。在自监督预训练之后，模型权重被冻结，并使用完整的 ImageNet-1K 训练集在其上训练一个线性分类器。与诸如掩码自编码器（MAE）[36]、上下文自编码器（CAE）[22] 和数据 2vec [8] 等流行方法相比，这些方法在预训练期间同样不依赖大量手工设计的数据增强，我们发现 I-JEPA 显著提升了线性探测性能，同时减少了计算开销（参见第 7节）。通过利用 I-JEPA 提升的效率，我们能够训练更大的模型，这些模型在仅使用一小部分计算资源的情况下，超越了最佳的 CAE 模型。I-JEPA 还受益于规模效应；特别是，在分辨率为 448×448 像素下训练的 ViT-H/16 模型，其性能与如 iBOT [79] 等视图不变方法相当，尽管避免了使用手工设计的数据增强。

Method	Arch.	CIFAR100	Places205	iNat18
Methods without view data augmentations				
data2vec [8]	ViT-L/16	81.6	54.6	28.1
MAE [36]	ViT-H/14	77.3	55.0	32.9
I-JEPA	ViT-H/14	87.5	58.4	47.6
Methods using extra view data augmentations				
DINO [18]	ViT-B/8	84.9	57.9	55.9
iBOT [79]	ViT-L/16	88.3	60.4	57.3

表 3. **图像分类的线性探针迁移**。在下游图像分类任务上进行线性评估。I-JEPA 显著优于之前不使用数据增强的方法（MAE 和 data2vec），并缩小了与基于手工数据增强的预训练方法在视图不变性方面的差距。

Method	Arch.	Clevr/Count	Clevr/Dist
Methods without view data augmentations			
data2vec [8]	ViT-L/16	85.3	71.3
MAE [36]	ViT-H/14	90.5	72.4
I-JEPA	ViT-H/14	86.7	72.4
Methods using extra data augmentations			
DINO [18]	ViT-B/8	86.6	53.4
iBOT [79]	ViT-L/16	85.7	62.8

表 4. **低层次任务的线性探针迁移**。在下游低层次任务上进行线性评估，包括物体计数（Clevr/Count）和深度预测（Clevr/Dist）。I-JEPA 方法在预训练过程中有效地捕捉了低层次图像特征，并在物体计数和深度预测等任务上优于基于视图不变性的方法。

低样本 ImageNet-1K。 表 2展示了在 1% ImageNet 基准上的性能表现。此处的思路是仅利用 ImageNet 标签的 1%（即每类大约 12 或 13 张图像）来调整预训练模型，以适应 ImageNet 分类任务。根据每种方法的最佳效果，模型通过微调或线性探测进行调整。在采用相似编码器架构的情况下，I-JEPA 在减少预训练轮次的同时，性能超越了 MAE。采用 ViT-H/14 架构的 I-JEPA ，其表现与使用 data2vec [8] 预训练的 ViT-L/16 相当，但计算资源消耗显著降低（见第 7节）。通过提高图像输入分辨率，I-JEPA 超越了包括 MSN [4]、DINO [17] 和 iBOT [79] 在内的先前方法，这些方法在预训练期间确实利用了额外的手工数据增强策略。

迁移学习。 表 3展示了使用线性探针在各种下游图像分类任务上的性能。I-JEPA 显著优于不使用数据增强的先前方法（MAE 和 data2vec），并缩小了与最佳基于视图不变性方法之间的差距，这些方法在预训练期间利用了手工制作的数据增强，甚至在 CIFAR100 和 Place205 上使用线性探针时超越了流行的 DINO [18]。

6. 本地预测任务

如第 5 节所示，I-JEPA 学习了语义图像表示，显著提升了如 MAE 和 data2vec 等先前方法在下游图像分类任务中的性能。此外，I-JEPA 受益于规模，能够缩小甚至超越基于视图不变性的方法，这些方法利用了额外的手工数据增强。在本节中，我们发现 I-JEPA 还学习了局部图像特征，并在低层次和稠密预测任务（如物体计数和深度预测）上超越了基于视图不变性的方法。

表 4展示了使用线性探针在各种低级任务上的性能。预训练后，编码器权重被冻结，并在其顶部训练一个线性模型，以在 Clevr 数据集 [43] 上进行物体计数和深度预测。与 DINO 和 iBOT 等视图不变性方法相比，I-JEPA 方法在预训练期间有效地捕捉了低级图像特征，并在物体计数（Clevr/Count）和（以较大优势）深度预测（Clevr/Dist）上表现更优。

7. 可扩展性

模型效率。 与之前的方法相比，I-JEPA 具有高度的可扩展性。图 5 展示了在 1% ImageNet-1K 上的半监督评估结果，作为 GPU 小时的函数。I-JEPA 需要的计算资源少于之前的方法，并且在不依赖手工设计的数据增强的情况下实现了强大的性能。与基于重构的方法（如 MAE）相比，后者直接使用像素作为目标，I-JEPA 通过在表示空间中计算目标引入了额外的开销（每次迭代大约慢 7%）。然而，由于 I-JEPA 在大约 5× 次更少的迭代中收敛，我们在实践中仍然看到了显著的计算节省。与基于视图不变性的方法（如 iBOT）相比，后者依赖手工设计的数据增强来创建和处理每张图像的多个视图，I-JEPA 的运行速度也显著更快。特别是，一个巨大的 I-JEPA 模型（ViT-H/14）需要的计算资源少于一个小的 iBOT 模型（ViT-S/16）。

Pretrain	Arch.	CIFAR100	Place205	INat18	Clevr/Count	Clevr/Dist
IN1k	ViT-H/14	87.5	58.4	47.6	86.7	72.4
IN22k	ViT-H/14	89.5	57.8	50.5	88.6	75.0
IN22k	ViT-G/16	89.5	59.1	55.3	86.7	73.0

表 5. **消融数据集和模型大小**。评估预训练数据集大小和模型大小对迁移任务的影响。I-JEPA 从更大更多样化的数据集中受益。当增加预训练数据集的大小（IN1k 对比 IN22k）时，我们观察到 ViT-H/14 模型的性能提升。通过在 ImageNet-22k 上训练更大的模型 ViT-G/16，我们在语义任务上进一步观察到性能提升。ViT-H/14 在 IN1k 上训练了 300 轮次，在 IN22k 上训练了相当于 900 轮 IN1k 的轮次。ViT-H/16 训练了相当于 600 轮 IN1k 的轮次。

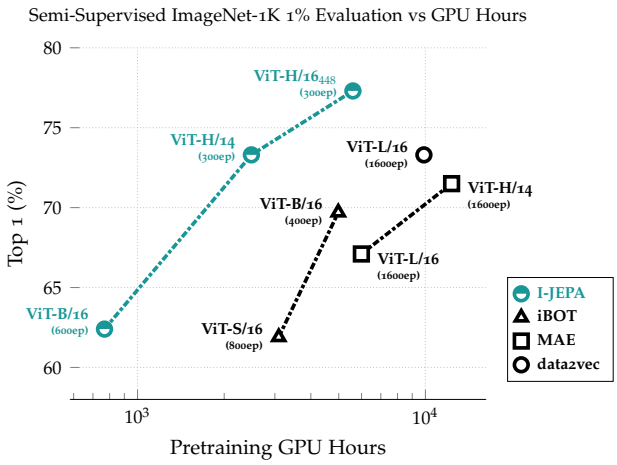

图 5. **缩放**。在 ImageNet-1K 1% 上进行半监督评估，作为预训练 GPU 小时的函数。I-JEPA 在达到强劲性能时所需的计算量少于以往方法。与 MAE 和 data2vec 相比，I-JEPA 通过需要更少的预训练轮次实现了显著的加速。与依赖手工数据增强的 iBOT 相比，一个大型的 I-JEPA 模型（ViT-H/14）所需的计算量少于其最小模型（ViT-S/16）。

缩放数据大小。 我们还发现 I-JEPA 通过使用更大的数据集进行预训练而受益。表 5展示了在增加预训练数据集大小（IN1K 与 IN22K）时，在语义和低层次任务上的迁移学习性能。当在更大、更多样化的数据集上进行预训练时，这些概念上不同的任务的迁移学习性能有所提升。

缩放模型大小。 表 5 还显示，在 IN22K 上进行预训练时，I-JEPA 从更大的模型大小中获益。与 ViT-H/14 模型相比，预训练 ViT-G/16 显著提高了在 Place205 和 INat18 等图像分类任务中的下游性能，但在低层次下游任务上并未提升性能——ViT-G/16 使用了更大的输入补丁，这可能对局部预测任务不利。

8. 预测器可视化

在 I-JEPA 中，预测器的作用是接收上下文编码器的输出，并基于位置掩码 token，预测由掩码 token 指定位置的目标块的表示。一个自然的问题是，基于位置掩码 token 的预测器是否在学习正确捕捉目标中的位置不确定性。为了定性研究这一问题，我们可视化了预测器的输出。我们采用以下可视化方法，以便研究社区能够独立复现我们的发现。预训练后，我们冻结上下文编码器和预测器的权重，并按照 RCDM 框架 [13] 训练一个解码器，将预测器输出的平均池化映射回像素空间。图 6展示了不同随机种子下的解码器输出。样本间共有的特性代表了包含在平均池化预测器表示中的信息。I-JEPA 预测器正确捕捉了位置不确定性，并生成了具有正确姿态的高层次对象部分（例如，鸟的背部和汽车的顶部）。

9. 消融

在表示空间中进行预测。 表 7 比较了在 1% ImageNet-1K 上使用线性探针时，在像素空间与表示空间中计算损失的低样本性能。我们推测，I-JEPA 的一个关键组成部分是损失完全在表示空间中计算，从而使目标编码器能够生成抽象的预测目标，其中无关的像素级细节被消除。从表 7 可以看出，在像素空间中进行预测会导致线性探针性能显著下降。

掩码策略。 表 6 比较了我们的多块掩码与其他掩码策略，例如栅格化掩码，其中图像被分割为四个大象限，目标是使用一个象限作为上下文来预测其他三个象限，以及传统上用于基于重构方法的块和随机掩码。在块掩码中，目标是一个单一的图像块，上下文是图像的补集。在随机掩码中，目标是一组随机补丁，上下文

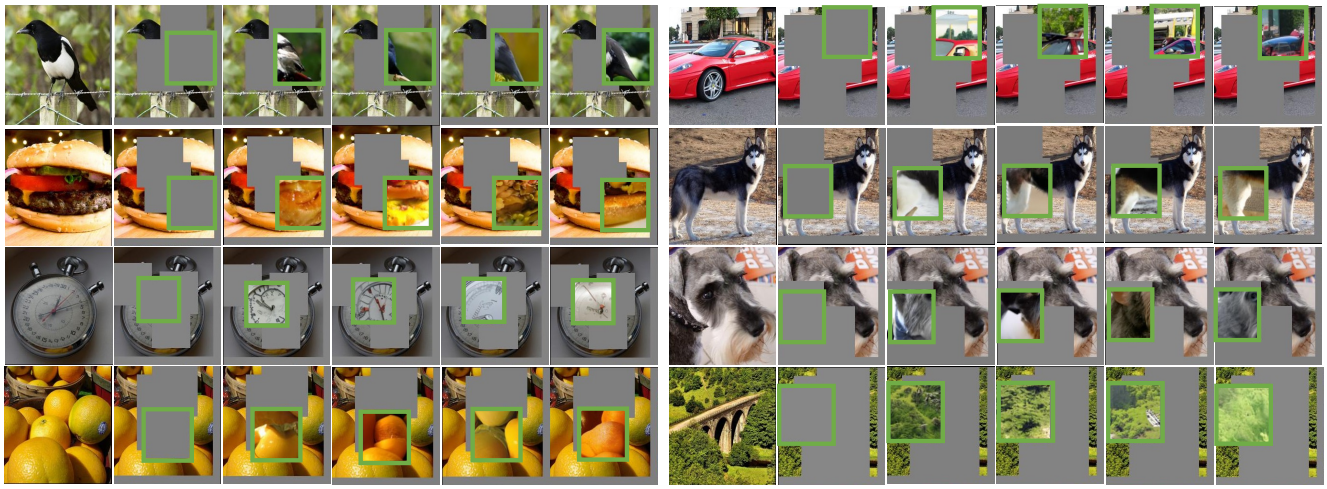

图 6. I-JEPA **预测器表示的可视化**。对于每张图像：第一列包含原始图像；第二列包含上下文图像，该图像由预训练的 I-JEPA ViT-H/14 编码器处理。后续列中的绿色边界框包含生成式模型的样本，该模型解码预训练的 I-JEPA 预测器的输出，并基于与绿色边界框位置对应的位置掩码 token 进行条件生成。样本间共有的特征表示 I-JEPA 预测中包含的信息。I-JEPA 预测器正确捕捉了位置不确定性，并生成了具有正确姿态的高层次物体部分（例如，鸟的背部和汽车的顶部）。样本间变化的特征表示表示中未包含的信息。在这种情况下，I-JEPA 预测器舍弃了精确的低层次细节以及背景信息。

	Targets		Context		
Mask	Type	Freq.	Type	Avg. Ratio*	Top-1
multi-block	Block(0.15, 0.2)	4	Block(0.85, 1.0) × Complement	0.25	54.2
rasterized	Quadrant	3	Complement	0.25	15.5
block	Block(0.6)	1	Complement	0.4	20.2
random	Random(0.6)	1	Complement	0.4	17.6

*Avg. Ratio is the average number of patches in the context block relative to the total number of patches in the image.

表 6. **消融掩码策略**。在 ViT-B/16 进行 300 轮次的预训练后，仅使用 ImageNet-1K 中 1% 的可用标签进行线性评估。比较了提出的多块掩码策略。在栅格化掩码中，图像被分割为四个大象限；一个象限用作上下文来预测其他三个象限。在块掩码中，目标是单个图像块，上下文是图像的补集。在随机掩码中，目标是一组随机图像补丁，上下文是图像的补集。提出的多块掩码策略有助于引导 I-JEPA 学习语义表示。

Targets	Arch.	Epochs	Top-1
Target-Encoder Output	ViT-L/16	500	66.9
Pixels	ViT-L/16	800	40.7

表 7. **消融目标**。在 ImageNet-1K 上仅使用 1% 的可用标签进行线性评估。当损失在像素空间而非表示空间应用时，I-JEPA 表示的语义水平显著下降，这凸显了目标编码器在预训练中的重要性。

是图像的补集。请注意，在所有考虑的策略中，上下文和目标块之间没有重叠。我们发现多块掩码有助于引导 I-JEPA 学习语义表示。关于多块掩码的额外消融实验可在附录 C中找到。

10. 结论

我们提出了 I-JEPA ，一种简单高效的方法，用于学习语义图像表示，而无需依赖手工制作的数据增强。我们展示了通过在表示空间中进行预测，I-JEPA 比像素重构方法收敛得更快，并且学习到更高语义层次的

表示。与基于视图不变性的方法相比，I-JEPA 为使用联合嵌入架构学习通用表示指明了一条路径，而无需依赖手工制作的视图增强。

参考文献

[1] Yuki Markus Asano, Christian Rupprecht, and Andrea Vedaldi. Self-labelling via simultaneous clustering and representation learning. Internatinoal Conference on Learning Representations, 2020. 1

[2] Mahmoud Assran, Randall Balestriero, Quentin Duval, Florian Bordes, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, and Nicolas Ballas. The hidden uniform cluster prior in self-supervised learning. International Conference on Learning Representations, 2023. 1, 14

[3] Mahmoud Assran, Nicolas Ballas, Lluis Castrejon, and Michael Rabbat. Supervision accelerates pre-training in contrastive semi-supervised learning of visual representations. NeurIPS Workshop on Self-Supervised Learning, 2020. 14

[4] Mahmoud Assran, Mathilde Caron, Ishan Misra, Piotr Bojanowski, Florian Bordes, Pascal Vincent, Armand Joulin, Michael Rabbat, and Nicolas Ballas. Masked siamese networks for label-efficient learning. European Conference on Computer Vision, 2022. 1, 2, 4, 5, 6, 13, 14, 17, 18

[5] Mahmoud Assran, Mathilde Caron, Ishan Misra, Piotr Bojanowski, Armand Joulin, Nicolas Ballas, and Michael Rabbat. Semi-supervised learning of visual features by non-parametrically predicting view assignments with support samples. IEEE/CVF International Conference on Computer Vision, 2021. 2, 14

[6] Philip Bachman, R Devon Hjelm, and William Buchwalter. Learning representations by maximizing mutual information across views. Advances in neural information processing systems, 32, 2019. 14

[7] Alexei Baevski, Arun Babu, Wei-Ning Hsu, and Michael Auli. Efficient self-supervised learning with contextualized target representations for vision, speech and language. arXiv preprint arXiv:2212.07525, 2022. 4

[8] Alexei Baevski, Wei-Ning Hsu, Qiantong Xu, Arun Babu, Jiatao Gu, and Michael Auli. Data2vec: A general framework for self-supervised learning in speech, vision and language. arXiv preprint arXiv:2202.03555, 2022. 1, 2, 4, 5, 6, 14

[9] Hangbo Bao, Li Dong, and Furu Wei. Beit: Bert pre-training of image transformers. arXiv preprint arXiv:2106.08254, 2021. 1, 3, 4, 14

[10] Adrien Bardes, Jean Ponce, and Yann LeCun. Vicreg: Variance-invariance-covariance regularization for self-supervised learning. arXiv preprint arXiv:2105.04906, 2021. 1, 2, 14

[11] Adrien Bardes, Jean Ponce, and Yann LeCun. Vicregl: Self-supervised learning of local visual features. arXiv preprint arXiv:2210.01571, 2022. 1, 14

[12] Florian Bordes, Randall Balestriero, Quentin Garrido, Adrien Bardes, and Pascal Vincent. Guillotine regularization: Improving deep networks generalization by removing their head. arXiv preprint arXiv:2206.13378, 2022. 14

[13] Florian Bordes, Randall Balestriero, and Pascal Vincent. High fidelity visualization of what your self-supervised representation knows about. Transactions on Machine Learning Research, 2022. 8, 17

[14] John Bridle, Anthony Heading, and David MacKay. Unsupervised classifiers, mutual information and'phantom targets. Advances in neural information processing systems, 4, 1991. 14

[15] Jane Bromley, James W Bentz, Léon Bottou, Isabelle Guyon, Yann LeCun, Cliff Moore, Eduard Säckinger, and Roopak Shah. Signature verification using a "siamese" time delay neural network. International Journal of Pattern Recognition and Artificial Intelligence, 7(04):669–688, 1993. 1, 2

[16] Zhaowei Cai, Avinash Ravichandran, Paolo Favaro, Manchen Wang, Davide Modolo, Rahul Bhotika, Zhuowen Tu, and Stefano Soatto. Semi-supervised vision transformers at scale. arXiv preprint arXiv:2208.05688, 2022. 14

[17] Mathilde Caron, Ishan Misra, Julien Mairal, Priya Goyal, Piotr Bojanowski, and Armand Joulin. Unsupervised learning of visual features by contrasting cluster assignments. arXiv preprint arXiv:2006.09882, 2020. 1, 6

[18] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision

transformers. arXiv preprint arXiv:2104.14294, 2021. 1, 2, 4, 5, 6, 13, 14

[19] Mark Chen, Alec Radford, Rewon Child, Jeffrey Wu, Heewoo Jun, David Luan, and Ilya Sutskever. Generative pretraining from pixels. In International Conference on Machine Learning, pages 1691–1703. PMLR, 2020. 14

[20] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. preprint arXiv:2002.05709, 2020. 1, 2, 14

[21] Ting Chen, Simon Kornblith, Kevin Swersky, Mohammad Norouzi, and Geoffrey Hinton. Big self-supervised models are strong semi-supervised learners. arXiv preprint arXiv:2006.10029, 2020. 5

[22] Xiaokang Chen, Mingyu Ding, Xiaodi Wang, Ying Xin, Shentong Mo, Yunhao Wang, Shumin Han, Ping Luo, Gang Zeng, and Jingdong Wang. Context autoencoder for self-supervised representation learning. arXiv preprint arXiv:2202.03026, 2022. 5

[23] Xinlei Chen, Haoqi Fan, Ross Girshick, and Kaiming He. Improved baselines with momentum contrastive learning. arXiv preprint arXiv:2003.04297, 2020. 13, 14

[24] Xinlei Chen and Kaiming He. Exploring simple siamese representation learning. arXiv preprint arXiv:2011.10566, 2020. 1, 2, 14

[25] Xinlei Chen, Saining Xie, and Kaiming He. An empirical study of training self-supervised vision transformers. arXiv preprint arXiv:2104.02057, 2021. 4

[26] Yubei Chen, Adrien Bardes, Zengyi Li, and Yann LeCun. Intra-instance vicreg: Bag of self-supervised image patch embedding. arXiv preprint arXiv:2206.08954, 2022. 14

[27] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In 2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05), volume 1, pages 886–893. Ieee, 2005. 4

[28] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805, 2018. 1

[29] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929, 2020. 3, 4, 13, 14

[30] Alaaeldin El-Nouby, Gautier Izacard, Hugo Touvron, Ivan Laptev, Hervé Jegou, and Edouard Grave. Are large-scale datasets necessary for self-supervised pre-training? arXiv preprint arXiv:2112.10740, 2021. 14

[31] Karl Friston. A theory of cortical responses. Philosophical transactions of the Royal Society B: Biological sciences, 360(1456):815–836, 2005. 1

[32] Spyros Gidaris, Andrei Bursuc, Nikos Komodakis, Patrick Pérez, and Matthieu Cord. Learning representations by predicting bags of visual words. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 6928–6938, 2020. 14

[33] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. Deep learning. MIT press, 2016. 14

[34] Priya Goyal, Quentin Duval, Jeremy Reizenstein, Matthew Leavitt, Min Xu, Benjamin Lefaudeux, Mannat Singh, Vinicius Reis, Mathilde Caron, Piotr Bojanowski, Armand Joulin, and Ishan Misra. Vissl. https://github.com/facebookresearch/vissl, 2021. 13

[35] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre H Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Daniel Guo, Mohammad Gheshlaghi Azar, et al. Bootstrap your own latent: A new approach to self-supervised learning. arXiv preprint arXiv:2006.07733, 2020. 1, 2, 5, 13, 14

[36] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022. 1, 2, 3, 4, 5, 6, 13, 14, 17

[37] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. arXiv preprint arXiv:1911.05722, 2019. 1, 2, 13, 14

[38] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 770–778, 2016. 3

[39] Olivier Henaff. Data-efficient image recognition with contrastive predictive coding. In International conference on machine learning, pages 4182–4192. PMLR, 2020. 14

[40] R Devon Hjelm, Alex Fedorov, Samuel Lavoie-Marchildon, Karan Grewal, Phil Bachman, Adam Trischler, and Yoshua Bengio. Learning deep representations by mutual information estimation and maximization. arXiv preprint arXiv:1808.06670, 2018. 14

[41] Weihua Hu, Takeru Miyato, Seiya Tokui, Eiichi Matsumoto, and Masashi Sugiyama. Learning discrete representations via information maximizing self-augmented training. In International conference on machine learning, pages 1558–1567. PMLR, 2017. 14

[42] Justin Johnson, Bharath Hariharan, Laurens Van Der Maaten, Li Fei-Fei, C Lawrence Zitnick, and Ross Girshick. Clevr: A diagnostic dataset for compositional language and elementary visual reasoning. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 2901–2910, 2017. 13

[43] Justin Johnson, Bharath Hariharan, Laurens van der Maaten, Li Fei-Fei, C Lawrence Zitnick, and Ross Girshick. Clevr: A diagnostic dataset for compositional language and elementary visual reasoning. In CVPR, 2017. 6

[44] Andreas Krause, Pietro Perona, and Ryan Gomes. Discriminative clustering by regularized information maximization. Advances in neural information processing systems, 23, 2010. 14

[45] Alex Krizhevsky, Geoffrey Hinton, et al. Learning multiple layers of features from tiny images. 2009. 13

[46] Gustav Larsson, Michael Maire, and Gregory Shakhnarovich. Learning representations for automatic colorization. 2016. 4

[47] Gustav Larsson, Michael Maire, and Gregory Shakhnarovich. Colorization as a proxy task for visual understanding. 2017. 4

[48] Yann LeCun. A path towards autonomous machine intelligence version 0.9. 2, 2022-06-27. 2022. 2, 3

[49] Yann LeCun, Sumit Chopra, Raia Hadsell, M Ranzato, and Fujie Huang. A tutorial on energy-based learning. Predicting structured data, 1(0), 2006. 2

[50] Ralph Linsker. Self-organization in a perceptual network. Computer, 21(3):105–117, 1988. 14

[51] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. arXiv preprint arXiv:1711.05101, 2017. 13

[52] Yi Ma, Doris Tsao, and Heung-Yeung Shum. On the principles of parsimony and self-consistency for the emergence of intelligence. Frontiers of Information Technology & Electronic Engineering, pages 1–26, 2022. 14

[53] Ishan Misra and Laurens van der Maaten. Self-supervised learning of pretext-invariant representations. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 6707–6717, 2020. 14

[54] Jovana Mitrovic, Brian McWilliams, Jacob Walker, Lars Buesing, and Charles Blundell. Representation learning via invariant causal mechanisms. International Conference on Learning Representations, 2021. 14

[55] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. Representation learning with contrastive predictive coding. arXiv preprint arXiv:1807.03748, 2018. 14

[56] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, et al. Pytorch: An imperative style, high-performance deep learning library. Advances in neural information processing systems, 32, 2019. 13

[57] Deepak Pathak, Philipp Krahenbuhl, Jeff Donahue, Trevor Darrell, and Alexei A Efros. Context encoders: Feature learning by inpainting. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 2536–2544, 2016. 1, 4

[58] Aditya Ramesh, Mikhail Pavlov, Gabriel Goh, Scott Gray, Chelsea Voss, Alec Radford, Mark Chen, and Ilya Sutskever. Zero-shot text-to-image generation. In International Conference on Machine Learning, pages 8821–8831. PMLR, 2021. 4

[59] Rajesh PN Rao and Dana H Ballard. Predictive coding in the visual cortex: a functional interpretation of some extra-classical receptive-field effects. Nature neuroscience, 2(1):79–87, 1999. 1

[60] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, Alexander C. Berg, and Li Fei-Fei. Imagenet large scale

visual recognition challenge. International Journal of Computer Vision, 115(3):211–252, 2015. 5, 13

[61] Antti Tarvainen and Harri Valpola. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results. arXiv preprint arXiv:1703.01780, 2017. 13

[62] Yuandong Tian, Xinlei Chen, and Surya Ganguli. Understanding self-supervised learning dynamics without contrastive pairs. In International Conference on Machine Learning, pages 10268–10278. PMLR, 2021. 14

[63] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In International Conference on Machine Learning, pages 10347–10357. PMLR, 2021. 3

[64] Michael Tschannen, Josip Djolonga, Paul K Rubenstein, Sylvain Gelly, and Mario Lucic. On mutual information maximization for representation learning. arXiv preprint arXiv:1907.13625, 2019. 14

[65] Grant Van Horn, Oisin Mac Aodha, Yang Song, Yin Cui, Chen Sun, Alex Shepard, Hartwig Adam, Pietro Perona, and Serge Belongie. The inaturalist species classification and detection dataset. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 8769–8778, 2018. 13

[66] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In Advances in neural information processing systems, pages 5998–6008, 2017. 3

[67] Pascal Vincent, Hugo Larochelle, Isabelle Lajoie, Yoshua Bengio, Pierre-Antoine Manzagol, and Léon Bottou. Stacked denoising autoencoders: Learning useful representations in a deep network with a local denoising criterion. Journal of machine learning research, 11(12), 2010. 1, 4, 14

[68] Chen Wei, Haoqi Fan, Saining Xie, Chao-Yuan Wu, Alan Yuille, and Christoph Feichtenhofer. Masked feature prediction for self-supervised visual pre-training. arXiv preprint arXiv:2112.09133, 2021. 1, 14

[69] Zhirong Wu, Yuanjun Xiong, Stella X Yu, and Dahua Lin. Unsupervised feature learning via non-parametric instance discrimination. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 3733–3742, 2018. 14

[70] Qizhe Xie, Zihang Dai, Eduard Hovy, Minh-Thang Luong, and Quoc V Le. Unsupervised data augmentation. arXiv preprint arXiv:1904.12848, 2019. 14

[71] Zhenda Xie, Zheng Zhang, Yue Cao, Yutong Lin, Jianmin Bao, Zhuliang Yao, Qi Dai, and Han Hu. Simmim: A simple framework for masked image modeling. arXiv preprint arXiv:2111.09886, 2021. 1, 4

[72] Yang You, Igor Gitman, and Boris Ginsburg. Large batch training of convolutional networks, 2017. 13

[73] Sangdoo Yun, Dongyoon Han, Seong Joon Oh, Sanghyuk Chun, Junsuk Choe, and Youngjoon Yoo. Cutmix: Regularization strategy to train strong classifiers with localizable features. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 6023–6032, 2019. 17

[74] Jure Zbontar, Li Jing, Ishan Misra, Yann LeCun, and Stéphane Deny. Barlow twins: Self-supervised learning via redundancy reduction. arXiv preprint arXiv:2103.03230, 2021. 1, 2, 14

[75] Xiaohua Zhai, Joan Puigcerver, Alexander Kolesnikov, Pierre Ruyssen, Carlos Riquelme, Mario Lucic, Josip Djolonga, Andre Susano Pinto, Maxim Neumann, Alexey Dosovitskiy, Lucas Beyer, Olivier Bachem, Michael Tschannen, Marcin Michalski, Olivier Bousquet, Sylvain Gelly, and Neil Houlsby. A large-scale study of representation learning with the visual task adaptation benchmark, 2019. 13

[76] Hongyi Zhang, Moustapha Cisse, Yann N Dauphin, and David Lopez-Paz. mixup: Beyond empirical risk minimization. Internatinoal Conference on Learning Representations, 2018. 17

[77] Richard Zhang, Phillip Isola, and Alexei A Efros. Colorful image colorization. 2016. 4

[78] Bolei Zhou, Agata Lapedriza, Jianxiong Xiao, Antonio Torralba, and Aude Oliva. Learning deep features for scene recognition using places database. Advances in neural information processing systems, 27, 2014. 13

[79] Jinghao Zhou, Chen Wei, Huiyu Wang, Wei Shen, Cihang Xie, Alan Yuille, and Tao Kong. Ibot: Image bert pre-training with online tokenizer. International Conference on Learning Representations, 2022. 2, 4, 5, 6, 13, 14

A. 实现细节

A.1. 预训练

架构。 对于 I-JEPA 的预训练，我们采用 Vision Transformer [29]（ViT）架构作为上下文编码器、目标编码器及预测器。其中，上下文编码器与目标编码器遵循标准 ViT 架构，而预测器则设计为轻量级（窄型）ViT 架构。具体而言，我们将预测器的嵌入维度固定为 384，同时保持其自注意力头的数量与主干上下文编码器一致。对于较小的 ViT-B/16 上下文编码器，预测器的深度设为 6；对于 ViT-L/16、ViT-H/16 及 ViT-H/14 上下文编码器，预测器深度设为 12；最后，ViT-G/16 采用深度为 16 的预测器。I-JEPA 在预训练过程中未使用 [cls] token。评估时，我们利用目标编码器并对其输出进行平均池化，以生成全局图像表示。

最优化. 我们使用 AdamW [51] 来优化上下文编码器和预测器的权重。默认的批量大小为 2048，学习率在前 15 轮预训练中从 10^{-4} 线性增加到 10^{-3}，之后按照余弦调度衰减至 10^{-6}。根据 [4,18]，权重衰减在整个预训练过程中从 0.04 线性增加到 0.4。目标编码器的权重在初始化时与上下文编码器的权重相同，之后通过指数移动平均进行更新 [4,18,23,35,37,61]。我们使用 0.996 的动量值，并在整个预训练过程中按照 [4,18] 将该值线性增加到 1.0。

掩码处理。 默认情况下，我们随机采样 4 个可能重叠的目标块掩码，其随机缩放比例在值域 $(015, 0.2)$ 内，宽高比在值域 $(0.75, 1.5)$ 内。我们采样 1 个上下文块掩码，其随机缩放比例在值域 $(0.85, 1.0)$ 内，且保持单元宽高比。随后，我们消除上下文块掩码中与任何 4 个目标块掩码重叠的区域。对于小批量中的每张图像，上下文块掩码和目标块掩码是独立采样的。为确保高效的批量处理，我们限制位于同一 GPU 上的所有上下文掩码的大小相同。同样，我们限制位于同一 GPU 上的所有目标掩码的大小相同。掩码采样器在 PyTorch [56] 中仅用几行代码高效实现，使用了一个批量整理函数，该函数在数据加载器进程中运行。简而言之，在每次迭代中，数据加载器返回一个小批量的图像以及每张图像的一组上下文和目标掩码，标识出需要保留的上下文和目标视图的补丁索引。

A.2. 下游任务

线性评估。 在评估如 iBOT [79]、DINO [18] 或 MAE [36] 等方法时，这些方法利用带有额外 [cls] token 的 Vision Transformers [29]，我们使用 VISSL [34] 的默认配置在 iNaturalist18 [65]、CIFAR100 [45]、Clevr/Count [42,75]、Clevr/Dist [42,75] 和 Places205 [78] 上评估所有模型。我们冻结编码器，并从以下表示中返回最佳数值：1) 最后一层的 [cls] token 表示，2) 最后 4 层 [cls] token 的拼接。对于每种表示，我们尝试两种不同的头部：1) 一个线性头部，或 2) 一个前接批量规范化的线性头部，并返回最佳数值。我们使用 VISSL [34] 的默认数据增强：随机调整大小裁剪和水平翻转，除了 Clevr/Count 和 Clevr/Dist，我们仅使用中心裁剪和水平翻转，因为随机裁剪会干扰计数物体和估计距离的能力，从而从场景中移除关键物体。对于 CIFAR100，我们将图像调整为 224×224 像素，以保持与预训练期间使用的 patch 数量相同。

由于我们的 I-JEPA 实现使用了不带 [cls] token 的 Vision Transformer 架构，我们调整了默认的 VISSL 评估方案，采用平均池化的 patch 表示而非 [cls] token。因此，我们报告了以下表示中的最佳线性评估结果：1) 最后一层的平均池化 patch 表示，2) 最后 4 层平均池化 patch 表示的拼接。除此之外，我们保持线性探测方案不变。

ImageNet **评估。** 为了在 ImageNet [60] 上评估 I-JEPA ，我们调整了 VISSL 的配方，使用平均池化表示而非 [cls] token。遵循 MAE [36]，我们采用 LARS [72] 优化器，批量大小为 16384，并训练线性探测器 50 轮次。我们采用分步衰减的学习率，每 15 轮次将其除以因子 10，并扫描了三种不同的参考学习率 $[0.01, 0.05, 0.001]$ 和两种权重衰减值 $[0.0005, 0.0]$。

低样本评估。 为了在 ImageNet-1% 低样本任务上评估我们的模型，我们采用了 MAE [36] 的微调协议。我们在 ImageNet-1% 上使用 AdamW 优化器和余弦学习率调度器对我们的 ViT-L/H 模型进行 50 轮次的微调。我们使用批量大小为 512，学习率层衰减为 0.75 和 0.1 标签平滑。我们使用与 MAE 中相同的默认随机增强数据增强方法。与 MAE 所做的微调不同，我们不使用混合、切割混合、随机擦除或丢弃路径。对于 I-JEPA ，我们对 ViT-L/16 使用学习率/权重衰减为 $3e^{-5}$ /$5e^{-2}$ ，对 ViT-H/14 使用 $3e^{-5}$ /$4e^{-1}$ ，对 ViT-H/16 使用 $3e^{-5}$ /$4e^{-1}$ $_{448}$ 。类似的微调策略在半监督学习背景下由 Semi-VIT 进行了探索 [16]。

B. 更广泛的相关工作

基于联合嵌入架构的视觉表示自监督学习是一个活跃的研究方向 [3,10,12,18,23,24,35,37,54,69,79]。这些方法训练一对编码器，使其对同一图像的两个或多个视图输出相似的嵌入。为了避免病态解，许多流行的联合嵌入方法采用显式正则化 [5,10,18,20] 或架构约束 [24,35]。基于架构约束的防止崩溃策略利用特定的网络设计选择来避免崩溃，例如，通过在联合嵌入的一个分支中停止梯度流动 [20]，在联合嵌入的一个分支中使用动量编码器 [35]，或使用非对称预测头 [8,20,35]。最近的工作 [62] 尝试在理论上理解（在某些简化情景下）带有架构约束的联合嵌入方法如何在没有显式正则化的情况下避免表示崩溃。

基于正则化的防止坍缩的方法在联合嵌入架构中试图最大化表示所占据空间的体积。这通常通过 InfoMax [52] 原理来激励。事实上，无监督表示学习中长期以来有一个信念，即所得的表示应该在最大程度上关于输入信息的同时，还满足某些简单性约束 [33,50]。前者目标通常被称为信息最大化原理（InfoMax），而后者有时被称为简约原理 [52]。这种表示学习方法已经提出了几十年（例如， [14]），其中，历史上通过鼓励学成的表示稀疏、低维或解耦来实施简单性约束，即表示向量的各个维度应该是统计独立的 [33]。现代方法通过自监督损失项来实施简单性约束和 InfoMax 正则化 [6,40,41,44,55,64]。一个例子是广泛的观点不变性惩罚 [53]，通常与独立性 [10,74] 或低维性约束结合使用，例如通过将表示投影到单位超球面 [20,35,37]。然而，尽管 InfoMax 原理被广泛使用，也存在许多批评，尤其是因为它不区分不同类型的信息（例如，噪声和语义） [2]。确实，我们希望模型捕捉的特征并不总是具有最高边缘熵（最大信息量）的特征。

与基于不变性的预训练的贡献正交，另一系列工作尝试通过人为掩码输入的部分内容并训练网络重建隐藏内容来学习表示 [67]。自回归模型，特别是降噪自编码器，从噪声视图中预测干净的视觉输入 [8,9,19,36,67]。通常，目标是在像素级别 [29,36,70] 或使用分词器在 patch token 级别预测缺失的输入 [9,68]。尽管这些工作展示了令人印象深刻的扩展性，但与联合嵌入方法相比，它们通常在较低层次的语义抽象上学习特征 [4]。

最近，一系列方法尝试将联合嵌入架构与基于重构的方法相结合 [30]，其中它们将不变性预训练损失与局部重构损失结合，如 iBOT 方法 [79] 所示。由于基于视图不变性的方法通常偏向于学习全局图像表示，从而限制了它们在其他计算机视觉任务中的适用性，因此添加局部损失项可以提高在其他流行计算机视觉任务上的性能 [11,26,32]。对比预测编码框架 [55] 也与这一关于局部损失项的工作密切相关。在图像的背景下 [39]，这里的想法是使用对比目标结合卷积网络来区分重叠图像块的表示。具体来说，目标是鼓励图像块的表示能够预测其正下方的图像块，同时推开其他视图的表示。与这项工作不同，提出的 I-JEPA 方法是非对比的，并不寻求区分图像块。相反，目标是从单个上下文块预测各种目标块的表示。这是通过联合嵌入预测架构实现的，使用一个预测器网络，该网络根据目标块在图像中的位置进行位置嵌入条件化。第 8节的定性实验表明，我们架构中的预测器网络能够正确执行这种局部到局部区域特征映射，并能够正确捕捉图像中的位置不确定性。

C. 额外的消融

本节遵循与第 9 节相同的实验协议。我们报告了在低样本 1% ImageNet-1K 基准上训练的、使用冻结骨干网络的线性探测结果。

Targets		Context	
Scale	Freq.	Scale	Top-1
(0.075, 0.2)	4	(0.85, 1.0)	19.2
(0.1, 0.2)	4	(0.85, 1.0)	39.2
(0.125, 0.2)	4	(0.85, 1.0)	42.4
(0.15, 0.2)	4	(0.85, 1.0)	54.2
(0.2, 0.25)	4	(0.85, 1.0)	38.9
(0.2, 0.3)	4	(0.85, 1.0)	33.6

表 8. **多块掩码目标块大小的消融实验**。在 1% ImageNet-1K 上进行线性评估（仅使用 1% 的可用标签）；在 ViT-B/16 的 300 轮次预训练过程中消融多块目标大小。预测更大的（语义）块可以提高低样本准确率，只要上下文信息足够丰富。

Targets		Context	
Scale	Freq.	Scale	Top-1
(0.15, 0.2)	4	(0.40, 1.0)	31.2
(0.15, 0.2)	4	(0.65, 1.0)	47.1
(0.15, 0.2)	4	(0.75, 1.0)	49.3
(0.15, 0.2)	4	(0.85, 1.0)	54.2

表 9. **多块掩码上下文大小的消融实验**。在 1% 的 ImageNet-1K 上进行线性评估（仅使用 1% 的可用标签）；在 ViT-B/16 的 300 轮次预训练期间消融多块目标大小。减少多块上下文大小会降低低样本性能。

Targets		Context	
Scale	Freq.	Scale	Top-1
(0.15, 0.2)	1	(0.85, 1.0)	9.0
(0.15, 0.2)	2	(0.85, 1.0)	22.0
(0.15, 0.2)	3	(0.85, 1.0)	48.5
(0.15, 0.2)	4	(0.85, 1.0)	54.2

表 10. **多块掩码目标数量的消融实验**。在 1% 的 ImageNet-1K 上进行线性评估（仅使用 1% 的可用标签）；在 ViT-B/16 的 300 轮次预训练过程中，消融多块目标数量。增加目标块的数量提高了低样本准确率。

多块掩码策略。 我们展示了对多块掩码策略的扩展消融实验，其中我们改变了目标块的尺度（表 8）、上下文尺度（表 9）以及目标块的数量（表 10）。我们使用 I-JEPA 在多种多块情景下训练了一个 ViT-B/16 模型，共进行 300 轮次，并在 1% ImageNet-1K 基准上通过线性探测比较了性能。简而言之，我们发现预测多个相对较大（语义）的目标块，并使用足够信息量（空间分布）的上下文块是至关重要的。

在目标编码器输出处应用掩码。 I-JEPA 中的一个重要设计选择是，目标块是通过对目标编码器的输出进行掩码获得的，而非输入。表 11 展示了这一设计选择在使用 I-JEPA 对 ViT-H/16 进行 300 轮次预训练时，对学成表示的语义层次的影响。当掩码应用于输入时，我们需为每个目标区域前向传播通过目标编码器一次。在预训练期间对目标编码器输出进行掩码，能生成更具语义的预测目标，并提升线性探测性能。

Target Masking	Arch.	Epochs	Top-1
Output	ViT-H/16	300	67.3
Input	ViT-H/16	300	56.1

表 11. **消融目标编码器输出的掩码效果**。在仅使用 1% 可用标签的情况下，对 ImageNet-1K 进行线性评估；消融在 ViT-H/16 的 300 轮次预训练期间对目标编码器输出进行掩码的效果。在预训练期间对目标编码器输出进行掩码显著提高了预训练表示的线性探测性能。

预测器深度。 我们在表 12中研究了预测器深度对下游少样本性能的影响。我们使用一个 6 层预测器网络或一个 12 层预测器网络对 ViT-L/16 进行了 500 轮次的预训练。与使用较浅预测器预训练的模型相比，使用更深预测器预训练的模型在下游少样本性能上显示出显著提升。

Predictor Depth	Arch.	Epochs	Top-1
6	ViT-L/16	500	64.0
12	ViT-L/16	500	66.9

表 12. **消融预测器深度**。在仅使用 1% 可用标签的情况下，在 ImageNet-1K 上进行线性评估；消融掩码预测器深度对预训练 500 轮次的 ViT-L/16 的影响。增加预测器深度显著提升了预训练表示的线性探针性能。

权重衰减。 在表 13中，我们评估了预训练期间权重衰减的影响。我们探讨了两种权重衰减策略：从 0.04 线性增加到 0.4，或使用固定的 0.05 权重衰减。在预训练期间使用较小的权重衰减在微调时提高了 ImageNet-1% 上的下游任务性能。然而，这也导致线性评估性能的下降。在主要论文中，我们采用了第一种权重衰减策略，因为它提高了线性评估下游任务的性能。

Weight Decay	Arch.	Epochs	ImageNet-1%	ImageNet Linear-Eval
$0.04 \rightarrow 0.4$	ViT-L/16	600	69.4	77.8
0.05	ViT-L/16	600	70.7	76.4

表 13. **消融预训练权重衰减**。我们比较了默认的预训练权重衰减策略，即权重衰减从 0.04 线性增加至 0.4，与使用固定权重衰减 0.05 的情况。在预训练期间使用较小的权重衰减可以提升在 ImageNet-1% 上的微调性能，但也会导致线性评估性能下降。

预测器宽度。 我们在表 14 中探讨了预测器宽度的影响。我们比较了使用 ViT-L 编码器和具有 386 通道的预测器的 I-JEPA 与使用具有 1024 通道的预测器的类似模型。需要注意的是，ViT-L 编码器具有 1024 通道。在预测器宽度中使用瓶颈提高了在 ImageNet 1% 上的下游性能。

Predictor Width	Arch.	Epochs	Top-1
384	ViT-L/16	600	70.7
1024	ViT-L/16	600	68.4

表 14. **消融预测器宽度**。我们在 ImageNet-1K 1% 上使用微调报告结果。我们比较了宽度为 384 或 1024 的两个预测器。注意 I-JEPA 编码器是一个具有 1024 通道的 ViT-L。在预测器中设置宽度瓶颈提升了下游性能。

D. 在完整 ImageNet 上进行微调

在本节中，我们报告了在完整 ImageNet 数据集上进行微调时在 I-JEPA 上的性能表现。我们重点关注 ViT-H/16_{448}，因为该架构在使用 MAE [36] 时达到了最先进的性能。

我们采用与 MAE 相似的微调协议。具体而言，我们使用 AdamW 优化器和余弦学习率调度对模型进行微调，共训练 50 轮次。基础学习率设为 10^{-4}，批量大小为 528。训练过程中，mixup [76] 设置为 0.8，cutmix [73] 设置为 1.0，路径丢弃概率为 0.25，权重衰减设为 0.04。此外，我们还采用了 0.75 的层衰减。最后，我们使用了与 MAE 相同的随机增强数据增强方法。

表 15 报告了微调结果。I-JEPA 实现了 87.1 的 top-1 准确率。尽管 I-JEPA 的训练轮次比 MAE 少 5.3 倍，但其性能与最佳 MAE 模型相差不到 1%。这一结果表明，I-JEPA 在完整 ImageNet 数据集上进行微调时具有竞争力。

Method	Arch.	Epochs	Top-1
MAE [36]	ViT-H/14_{448}	1600	87.8
I-JEPA	ViT-H/16_{448}	300	87.1

表 15. **在完整 ImageNet 数据集上的微调**。I-JEPA 取得了具有竞争力的性能。尽管 I-JEPA 的训练轮次比 MAE 少 5.3 倍，但 I-JEPA 的表现接近 MAE 方法。

E. RCDM 可视化

为了可视化预训练神经网络在像素空间中的表示，我们使用 RCDM 框架 [13]。该框架训练一个解码器网络 h_ω，该网络包含一个生成扩散模型，用于从图像的表示向量 $\boldsymbol{s}_x$ 和该图像的噪声版本 $\hat{\boldsymbol{x}} := \boldsymbol{x} + \epsilon$ 重建图像 $\boldsymbol{x}$，其中 ϵ 是一个加性噪声向量。具体来说，解码器的目标是最小化损失函数 $\|h_\omega(\hat{\boldsymbol{x}}, \boldsymbol{s}_x) - \epsilon\|$。我们使用默认超参数 [13] 对每个 RCDM 网络进行 300,000 次迭代训练。训练解码器后，可以将未见过的测试图像的表示向量 $\boldsymbol{s}_y$ 与各种随机噪声向量一起输入解码器，生成多个表示在像素级别的可视化，从而深入了解预训练网络表示中捕获的特征。样本之间共有的特性表示包含在表示中的信息，而样本之间变化的特性则表示未包含在表示中的信息。

在图 6中，可视化结果是通过将预测器在特定目标区域条件下的平均池化输出与各种随机噪声向量一起输入到解码器网络中获得的。在图 7和图 8中，可视化结果是通过将目标编码器的平均池化输出与各种随机噪声向量一起输入到解码器网络中获得的。

E.1. 编码器可视化

在图 7中，我们可视化了 ViT-H/14 目标编码器输出的平均池化 I-JEPA 表示。第一列包含原始图像，而后续列包含通过将图像的平均池化表示与各种随机噪声向量一起输入解码器获得的合成样本。图 7表明，I-JEPA 目标编码器能够正确捕捉关于物体及其姿态的高层信息，同时丢弃低层图像细节和背景信息。

图 8展示了类似的视觉化效果，但这次使用了 MSN [4] 预训练的 ViT-L/7 目标编码器来计算图像表示。MSN 方法通过联合嵌入架构训练上下文和目标编码器，以确保全局图像表示对各种手工设计的数据增强和缺失块具有不变性。虽然 MSN 预训练网络能够在第一列中捕捉到图像的高级语义信息，但它也在生成的样本中表现出更高的变异性，例如物体姿态、物体尺度和实例数量的变化。简而言之，MSN 预训练丢弃了图像中的大部分局部结构，这与 I-JEPA 形成鲜明对比，后者保留了输入图像中大量局部结构的信息。

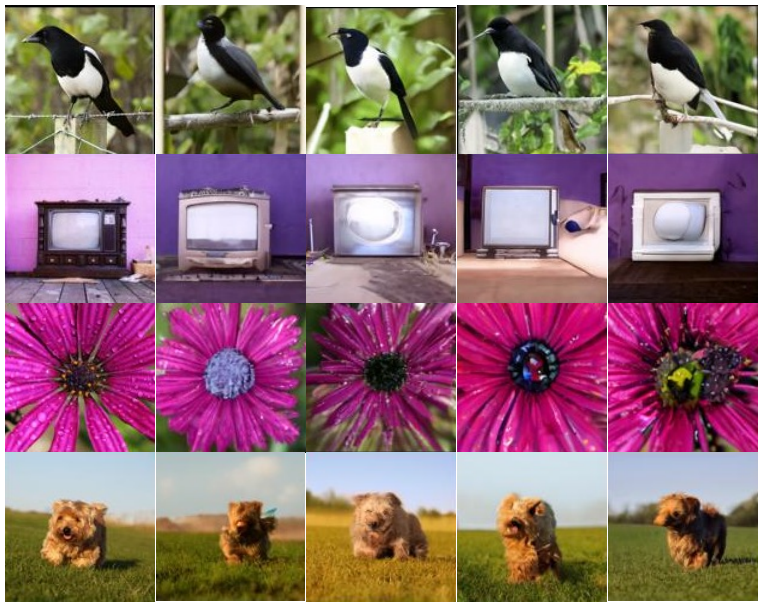

图 7. I-JEPA **目标编码器表示的可视化**。对于每张图像：第一列包含原始图像；后续列包含从生成式模型解码预训练 I-JEPA 目标编码器平均池化输出的样本。样本间共有的特性代表了 I-JEPA 表示中包含的信息。I-JEPA 能够正确捕捉关于物体及其姿态的高层次信息。样本间变化的特性代表了表示中未包含的信息。I-JEPA 编码器舍弃了精确的低层次细节以及背景信息。

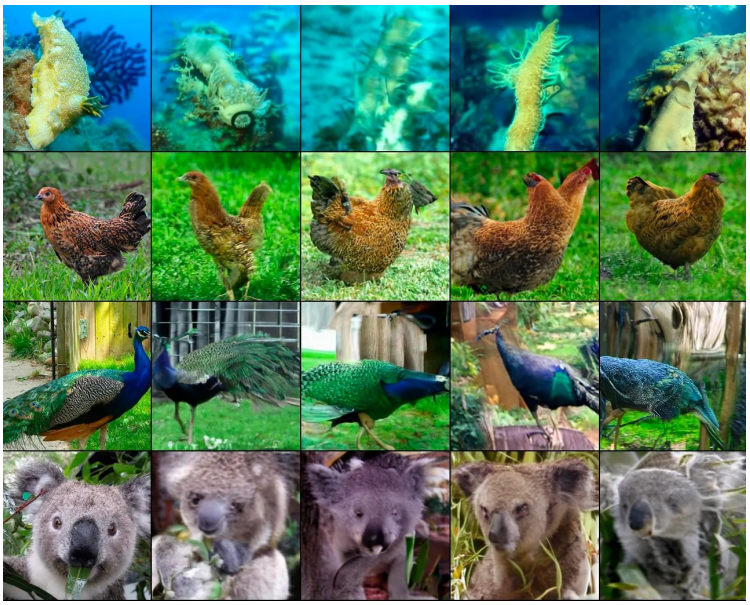

图 8. MSN **目标-编码器表示的可视化**。对于每张图像：第一列包含原始图像；后续列包含从冻结的 MSN 编码器 [4] 解码生成式模型的样本。样本间共有的特性表示包含在表示中的信息。样本间变化的特性表示 MSN 未捕捉到的信息。与 I-JEPA 相比，MSN 样本显示出更高的变异性。MSN 从输入中保留的信息较少，特别是丢弃了全局结构信息，如物体姿态甚至实例数量。