https://hjfy.top/arxiv/2111.09883

Swin Transformer V2：扩大容量与分辨率

Ze Liu* Han Hu*† Yutong Lin Zhuliang Yao Zhenda Xie Yixuan Wei Jia Ning
Yue Cao Zheng Zhang Li Dong Furu Wei Baining Guo
Microsoft Research Asia
{v-zeliu1,hanhu,t-yutonglin,t-zhuyao,t-zhxie,t-yixuanwei,v-jianing}@microsoft.com
{yuecao,zhez,lidong1,fuwei,bainguo}@microsoft.com

Abstract

大规模自然语言处理模型在语言任务上的性能显著提升，且尚未出现饱和迹象。它们还展现出类似人类的惊人 *few-shot* 能力。本文旨在探索计算机视觉中的大规模模型。我们解决了大规模视觉模型训练与应用中的三个主要问题：训练稳定性、预训练与微调之间的分辨率差距，以及对标注数据的需求饥渴。为此，本文提出了三种关键技术：*1*）结合残差后范数与余弦注意力的方法，以提升训练稳定性；*2*）一种对数间隔连续位置偏置方法，有效实现使用低分辨率图像预训练的模型向具有高分辨率输入的下游任务迁移；*3*）一种自监督预训练方法 *SimMIM*，以减少对大量标注图像的需求。通过这些技术，本文成功训练了一个参数量达 *30* 亿的 *Swin Transformer V2* 模型，这是迄今为止参数最密集的视觉模型，并使其能够支持最高达 *1,536*× *1,536* 分辨率的图像训练。该模型在 *4* 个代表性视觉任务上创造了新的性能记录，包括 *ImageNet-V2* 图像分类、*COCO* 目标检测、*ADE20K* 语义分割和 *Kinetics-400* 视频动作分类。此外，我们的训练效率远高于谷歌的十亿级视觉模型，仅需其 *1/40* 的标注数据和 *1/40* 的训练时间。代码已公开于 *https://github.com/microsoft/Swin-Transformer*。

*Equal. †Project lead. Ze, Yutong, Zhuliang, Zhenda, Yixuan, Jia are long-term interns at MSRA.

1. 引言

扩大语言模型的规模取得了巨大成功。它显著提升了模型在语言任务上的表现 [19,24,49,50,52,53]，且模型展现出与人类相似的惊人 few-shot 能力 [7]。自拥有 3.4 亿参数的 BERT 大模型 [19] 以来，语言模型在短短几年内参数规模迅速扩大了上千倍，达到 5300 亿稠密参数 [50] 和 1.6 万亿稀疏参数 [24]。这些大规模语言模型还被发现具备越来越强的 few-shot 能力，能够类比人类智能完成广泛的语言任务 [7]。

另一方面，视觉模型的缩放进展相对滞后。尽管长期以来人们已经认识到，更大的视觉模型在视觉任务上通常表现更好 [29,60]，但模型的绝对大小直到最近才达到约 10 亿到 20 亿参数 [17,27,39,56,80]。更重要的是，与大型语言模型不同，现有的大型视觉模型仅应用于图像分类任务 [17,56,80]。

为了成功训练大型通用视觉模型，我们需要解决几个关键问题。首先，我们对大型视觉模型的实验揭示了训练过程中的不稳定性问题。我们发现，在大型模型中，各层之间激活值幅度的差异显著增大。仔细分析原始架构后发现，这是由于残差单元的输出直接加回到主分支所致。结果是激活值逐层累积，导致深层的激活值幅度远大于浅层。为了解决这一问题，我们提出了一种新的规范化配置，称为 res-post-norm，即将每一残差单元开头的 LN 层移至末端，如图 1 所示。我们发现这种新配置在全网络各层中产生了更为平缓的激活值。此外，我们还提出使用缩放余弦注意力来替代之前的点积注意力。缩放余弦注意力使计算与块输入的幅度无关，注意力值更不容易落入极端情况。在我们的实

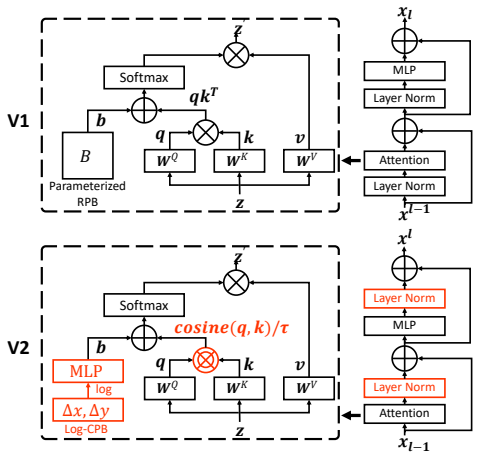

图 1. 为了更好地扩展模型容量和窗口分辨率，对原始的 Swin Transformer 架构（V1）进行了若干改进：1）采用 *res-post-norm* 替换之前的 *pre-norm* 配置；2）采用 *scaled cosine attention* 替换原始的 *dot product attention*；3）采用 *log-spaced continuous* 相对位置偏置方法替换之前的 *parameterized* 方法。改进 1）和 2）使得模型更容易扩展容量。改进 3）使得模型在不同窗口分辨率之间迁移更加高效。该改进后的架构命名为 Swin Transformer V2。

验中，所提出的两项技术不仅使训练过程更加稳定，而且尤其提升了大型模型的准确率。

其次，许多下游视觉任务（如目标检测和语义分割）需要高分辨率输入图像或较大的注意力窗口。低分辨率预训练与高分辨率微调之间的窗口大小差异可能非常大。当前普遍的做法是对位置偏置图进行双三次插值 [22, 46]。这种简单的方法略显随意，结果通常为次最优。我们提出了一种对数间隔的连续位置偏置（Log-CPB），通过在对数间隔的坐标输入上应用一个小型元网络，生成任意坐标值域下的偏置值。由于该元网络可处理任意坐标，预训练模型能够通过共享元网络的权重，在不同窗口尺寸间自由迁移。我们方法的关键设计在于将坐标变换到对数空间，使得即使目标窗口尺寸显著大于预训练时的尺寸，外推比例也能保持较低。

模型容量和分辨率的提升也导致现有视觉模型的 GPU 内存消耗急剧增加。为解决内存问题，我们引入了多项关键技术，包括零优化器 [54]、活性值检查点 [12] 以及一种新颖的顺序自注意力计算实现。借助这些技术，大型模型和高分辨率下的 GPU 内存消耗显著降低，同时对训练速度的影响微乎其微。

通过上述技术，我们成功训练了一个 30 亿参数的 Swin Transformer 模型，并有效将其迁移至分辨率高达 1,536× 1,536 的各种视觉任务中，使用了 Nvidia A100-40G GPU。在模型预训练过程中，我们还采用了自监督预训练方法，以减少对超大规模标注数据的依赖。相比之前实践（JFT-3B）中使用的标注数据量减少了 40×，这一 30 亿参数模型在广泛的视觉基准测试中达到了最先进的准确率。具体而言，在 ImageNet-V2 图像分类验证集 [55] 上获得了 84.0% 的 top-1 准确率，在 COCO 测试开发集的目标检测任务中取得了 63.1 / 54.4 的 box / mask AP，在 ADE20K 语义分割任务中达到了 59.9 mIoU，在 Kinetics-400 视频动作分类任务中获得了 86.8% 的 top-1 准确率，这些成绩分别比原始 Swin Transformers [46, 47] 的最佳结果高出 +NA%, +4.4/+3.3, +6.3 和 +1.9，并且超越了之前的最佳记录，分别提高了 +0.8% ([80]), +1.8/+1.4 ([74]), +1.5 ([4]) 和 +1.4% ([57])。

通过提升视觉模型的容量和分辨率，使其在通用视觉任务上表现出色，就像优秀的语言模型在通用自然语言处理任务上的表现一样，我们旨在激发更多相关研究，最终缩小视觉模型与语言模型之间的容量差距，促进两个领域的联合建模。

2. 相关工作

语言网络与缩放 Transformer 自从开创性工作 [65] 以来，已成为标准网络架构。对这一架构的缩放探索自此开始，并因有效的自监督学习方法（如掩码或自回归语言模型化 [19, 52]）的提出而加速推进，又因缩放法则的发现 [36] 而进一步得到鼓励。此后，语言模型的容量在短短几年内提升了超过 1000 倍，从 BERT-340M 发展到 Megatron-Turing-530B [7, 49, 50, 53] 和稀疏的 Switch-Transformer-1.6T [24]。随着容量的增加，各类语言基准的准确率显著提升，zero-shot 或 few-shot 性能也大幅改善 [7]，这构成了人类通用智能的基础。

视觉网络与缩放 CNNs have long been the standard 计算机视觉 networks [40, 41]. Since AlexNet [40], 架构 have become deeper and larger, which has greatly advanced various visual tasks and largely fueled the wave of 深度学习 in 计算机视觉, such as VGG [60], GoogleNet [62] and ResNet citehe2015resnet. In the

past two years, the CNN 架构 have been further scaled up to about 1 billion 参数 [27, 39], however, absolute performance may not be so encouraging, perhaps due to 归纳偏置 in the CNN 架构 limiting modeling power.

去年，Transformer 一个接一个地在各类代表性视觉基准上占据主导地位，包括 ImageNet-1K 图像级分类基准 [22]、COCO 区域级目标检测基准 [46]、ADE20K 像素级语义分割基准 [46, 83]、Kinetics-400 视频动作分类基准 [2] 等。自这些工作以来，大量视觉 Transformer 变体被提出，以在相对较小规模下提升准确率 [14, 21, 34, 42, 63, 68, 71, 75, 77, 78, 82]。仅有少数工作尝试将视觉 Transformer 进行大规模扩展 [17, 56, 80]。然而，它们依赖于包含分类标签的超大规模图像数据集，即 JFT-3B，且仅应用于图像分类问题。

跨窗口/内核分辨率传输 对于 CNN，先前的工作通常在预训练和微调过程中固定卷积核大小。全局视觉 Transformer，例如 ViT [22]，全局计算注意力，其等效注意力窗口大小与输入图像分辨率的增加成线性比例关系。对于局部视觉 Transformer 架构，例如 Swin Transformer [46]，窗口大小在微调过程中可以固定或改变。允许可变的窗口大小使用起来更为方便，以便能够整除可能变化的整个特征图，并调节感受野以获得更高的准确率。为处理预训练与微调之间可变的窗口大小，双三次插值是之前常见的做法 [22, 46]。本文提出一种对数间距连续位置偏置方法（Log-CPB），能够更平滑地将低分辨率下的预训练模型权重迁移至更高分辨率的窗口中。

关于偏差项的研究 在自然语言处理中，相对位置偏置方法被证明是有益的 [53]，相较于原始 Transformer 中使用的绝对位置嵌入 [65]。在计算机视觉中，相对位置偏置方法更为常用 [31, 46, 75]，可能是因为视觉信号的空间关系在视觉建模中起着更重要的作用。一种常见的做法是直接将偏置值作为模型权重进行学习。也有一些工作专门研究如何设置和学习偏置项 [38, 69]。

连续卷积及其变体 我们的 Log-CPB 方法还与早期关于连续卷积及其变体的工作 [30, 45, 58, 67] 相关，这些工作利用元网络处理不规则数据点。我们的 Log-CPB 方法受到这些研究的启发，同时解决了在视觉 Transformer 中跨任意窗口大小转移相对位置偏置的不同问题。我们还提出了对数间隔坐标，以缓解在大幅尺寸变化之间进行外推法时的困难。

3. Swin Transformer V2

3.1. Swin Transformer 简要回顾

Swin Transformer 是一种通用的计算机视觉主干网络，在各类细粒度识别任务中表现出色，例如区域级目标检测、像素级语义分割和图像级图像分类。Swin Transformer 的核心思想是将若干重要的视觉先验引入原始 Transformer 编码器中，包括层次性、局部性和平移不变性。这一设计结合了两方面的优势：基础 Transformer 单元具有强大的建模能力，而视觉先验则使其适用于多种视觉任务。

规范化配置 众所周知，规范化技术 [3, 35, 64, 70] 在稳定训练更深架构方面至关重要。原始的 Swin Transformer 继承了语言 Transformer [52] 和原始 ViT [22] 中常见的做法，采用预规范化配置，且未进行深入研究，如图 1 所示。在接下来的小节中，我们将考察这种默认的规范化配置[1].

相对位置偏差 是原始 Swin Transformer 中的一个关键组件，它在自注意力计算中引入了一个额外的参数化偏置项，用于编码几何关系：

$$\mathrm{Attention}(Q, K, V) = \mathrm{SoftMax}(QK^T/\sqrt{d} + B)V, \quad (1)$$

其中，$B \in \mathbb{R}^{M^2 \times M^2}$ 为每个头的相对位置偏置项；$Q, K, V \in \mathbb{R}^{M^2 \times d}$ 为 查询、键和 值矩阵；d 为 查询/键的维度，M^2 为窗口内的补丁数量。相对位置偏置编码了视觉元素之间的相对空间配置，在多种视觉任务中表现关键，尤其是在稠密识别任务（如目标检测）中。

在 Swin Transformer 中，每个轴上的相对位置范围为 $[-M+1, M-1]$，相对位置偏置被参数化为一个偏置矩阵 $\hat{B} \in \mathbb{R}^{(2M-1)\times(2M-1)}$，且 B 中的元素取自 $\hat{B}$。在跨不同窗口大小进行迁移时，预训练中学习到的相对位置偏置矩阵通过双三次插值用于初始化微调阶段不同大小的偏置矩阵。

[1]已经出现了一些替代的规范化配置，例如后规范化 [65] 和夹心规范化 [20]。后规范化会损害训练稳定性 [73]，而夹心规范化由于规范化层过多，牺牲了表示能力。

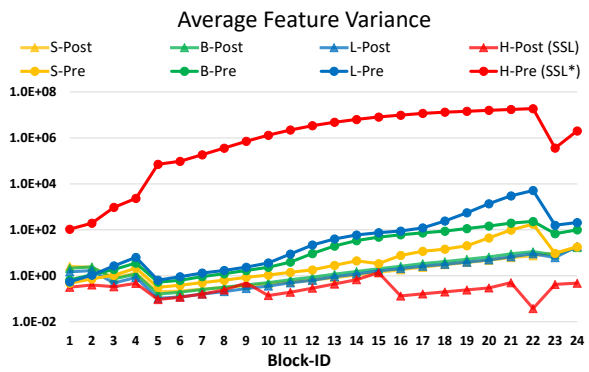

图 2. 不同模型大小的信号传播图 [6,76]。H-size 模型在自监督学习阶段进行训练，其他大小的模型则通过图像分类任务进行训练。* 表示我们在模型崩溃前使用了 40 轮的模型。

模型容量和窗口分辨率扩大的挑战 在扩大 Swin Transformer 的容量和窗口分辨率时，我们观察到两个问题。

- *在扩大模型容量时出现的不稳定性问题*。如图 2 所示，当我们将原始的 Swin Transformer 模型从小型扩展到大型时，深层的活性值急剧增加。各层中最高与最低振幅之间的差异已达到极端值 10^4 。当我们进一步将其扩展至巨大规模（6.58 亿参数）时，训练无法完成，如图 3 所示。

- *在跨窗口分辨率迁移模型时性能下降*. 如表 1 第一行所示，当直接通过双三次插值方法在更大的图像分辨率和窗口大小下测试预训练的 ImageNet-1K 模型 (256×256 图像，8×8 窗口大小) 的准确率时，准确率显著下降。这可能值得重新审视原始 Swin Transformer 中的相对位置偏置方法。

在以下小节中，我们介绍了应对这些问题的技术，包括*残差后规范化*和*缩放余弦注意力*以解决不稳定性问题，以及一种*对数间距的连续位置偏置*方法来解决跨窗口分辨率迁移的问题。

3.2. 扩大模型容量

如第 3.1 节所述，原始的 Swin Transformer（以及大多数视觉 Transformer）在每个块的开头采用层范数层，这一设计继承自原始 ViT。当我们扩大模型容量时，观察到深层中的活性值显著增加。事实上，在预规范化配置中，每个残差块的输出活性值会直接合并回主分支，导致主分支的幅值在深层不断增大。不同层之间幅值差异过大会导致训练不稳定。

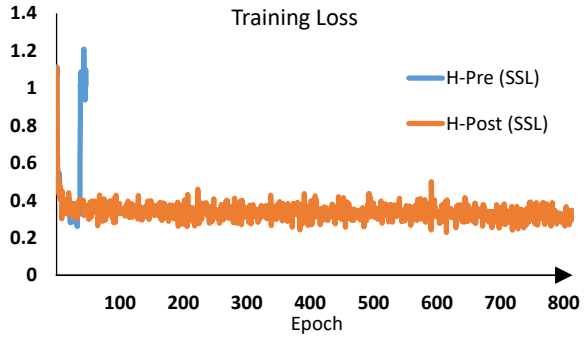

图 3. SwinV1-H 与 SwinV2-H 在训练 [72].

规范化后 为缓解此问题，我们提出采用一种*残差后规范化*方法，如图 1所示。在此方法中，每个残差块的输出在合并回主分支之前进行规范化，从而避免随着层数加深导致主分支幅值不断累积。如图 2所示，相较于原始的前规范化配置，该方法得到的活性值幅值要温和得多。

在我们最大的模型训练中，每 6 个 Transformer 块在主分支上增加一层层规范化层，以进一步稳定训练。

缩放余弦注意力 在原始的自注意力计算中，像素对之间的相似度项通过 *查询*和 *键*向量的点积来计算。我们发现，当此方法应用于大型视觉模型时，某些块和头的学得注意力图常常被少数像素对所主导，尤其是在 *res-post-norm* 配置下。为缓解这一问题，我们提出一种 *缩放余弦注意力*方法，通过缩放余弦函数计算像素对 i 和 j 的注意力 Logit：

$$\mathrm{Sim}(\mathbf{q}_i, \mathbf{k}_j) = \cos(\mathbf{q}_i, \mathbf{k}_j)/\tau + B_{ij}, \tag{2}$$

其中，B_{ij} 为像素 i 与 j 之间的相对位置偏置；τ 为可学习的标量，在不同注意力头和层之间不共享。τ 设置大于 0.01。余弦函数天然规范化，因此可以产生更温和的注意力值。

3.3. 缩放窗口分辨率

在本小节中，我们引入了一种对数间距的连续位置偏置方法，使得相对位置偏置能够平滑地跨窗口分辨率传递。

连续相对位置偏差 不是直接优化参数化的偏置，*连续位置偏置*方法在相对坐标上采用了一个小型元网络：

$$B(\Delta x, \Delta y) = \mathcal{G}(\Delta x, \Delta y), \tag{3}$$

method	ImageNet*	ImageNet†				COCO		ADE20k		
	W8, I256	W12, I384	W16, I512	W20, I640	W24, I768	W16	W32	W16	W20	W32
	top-1 acc	top-1 acc	top-1 acc	top-1 acc	top-1 acc	AP^{box}	AP^{box}	mIoU	mIoU	mIoU
Parameterized position bias [46]	81.7	79.4/82.7	77.2/83.0	73.2/83.2	68.7/83.2	50.8	50.9	45.5	45.8	44.5
Linear-Spaced CPB	81.7 (+0.0)	82.0/82.9 (+2.6/+0.2)	81.2/83.3 (+4.0/+0.3)	79.8/83.6 (+6.6/+0.4)	77.6/83.7 (+8.9/+0.5)	50.9 (+0.1)	51.7 (+0.8)	47.0 (+1.5)	47.4 (+1.6)	47.2 (+2.7)
Log-Spaced CPB	81.8 (+0.1)	82.4/83.2 (+3.0/+0.5)	81.7/83.8 (+4.5/+0.8)	80.4/84.0 (+7.2/+0.8)	79.1/84.2 (+10.4/+1.0)	51.1 (+0.3)	51.8 (+0.9)	47.0 (+1.5)	47.7 (+1.9)	47.8 (+3.3)

表 1. 使用 Swin-T 比较不同的位置偏置计算方法。* 表示从零开始训练的 ImageNet-1k 上的 top-1 准确率。* 列中的模型将用于在更大的图像/窗口分辨率下进行 ImageNet-1K 图像分类任务测试，标记为 † 。对于这些结果，我们报告了无微调/有微调的结果。这些模型也用于 COCO 目标检测和 ADE20K 语义分割任务的微调。

其中 $\mathcal{G}$ 是一个小型网络，例如默认情况下在中间使用 ReLU 活性值的两层 MLP。

元网络 $\mathcal{G}$ 为任意相对坐标生成偏置值，因此可以自然地迁移至窗口大小任意变化的微调任务中。在推理阶段，每个相对位置的偏置值可以预先计算并存储为模型参数，从而使推理过程与原始参数化偏置方法相同。

对数坐标 在跨大小差异较大的窗口进行转换时，需要对相对坐标值域的很大一部分进行外推。为缓解此问题，我们提出使用对数间隔坐标代替原有的线性间隔坐标：

$$\begin{aligned} \widehat{\Delta x} &= \operatorname{sign}(x) \cdot \log(1 + |\Delta x|), \\ \widehat{\Delta y} &= \operatorname{sign}(y) \cdot \log(1 + |\Delta y|), \end{aligned} \tag{4}$$

其中 Δx 、Δy 和 $\widehat{\Delta x}$ 、$\widehat{\Delta y}$ 分别为线性缩放坐标和对数间距坐标。

通过使用对数坐标，当我们将相对位置偏置从一个窗口分辨率外推到另一个时，所需的外推比例将远小于使用原始线性坐标的情况。以从预训练的 8×8 窗口大小转移到微调后的 16×16 窗口大小为例，使用原始线性坐标时，输入坐标的值域将从 $[-7, 7] \times [-7, 7]$ 到 $[-15, 15] \times [-15, 15]$ 。此时的外推比例为原始值域的 $\frac{8}{7} = 1.14\times$ 。而使用对数坐标时，输入坐标范围将从 $[-2.079, 2.079] \times [-2.079, 2.079]$ 到 $[-2.773, 2.773] \times [-2.773, 2.773]$ 。此时的外推比例为原始值域的 $0.33\times$ ，相比使用原始线性坐标时的外推比例约小了 4 倍。

表 1 比较了不同位置偏置计算方法的迁移性能。可以看出，对数间隔的 CPB（连续位置偏置）方法表现最佳，尤其是在迁移到更大的窗口大小时。

3.4. 自监督预训练

更大的模型对数据的需求更高。为解决数据饥渴问题，以往的大规模视觉模型通常依赖于海量的标签数据，例如 JFT-3B [17, 56, 80]。在本工作中，我们采用一种自监督预训练方法 SimMIM [72]，以减轻对标签数据的需求。通过该方法，我们仅使用 7000 万张标签图像（仅为 JFT-3B 的 1/40），便成功训练出一个拥有 30 亿参数的强大 Swin Transformer 模型，在 4 个代表性视觉基准上达到了当前最优（SOTA）性能。

3.5. 节省 GPU 内存的实现

另一个问题在于，当容量和分辨率都较大时，常规实现会导致 GPU 内存消耗过高而无法承受。为缓解内存问题，我们采用了以下实现方法：

- *零冗余优化器 (ZeRO)* [54]。在优化器的一般数据并行实现中，模型参数和优化状态会被广播到每个 GPU。这种实现方式对 GPU 内存消耗非常不友好，例如，当使用 AdamW 优化器和 fp32 权重/状态时，一个包含 30 亿参数的模型将消耗 48G GPU 内存。通过 ZeRO 优化器，模型参数和相应的优化状态将被分割并分布到多个 GPU 上，从而显著降低内存消耗。我们在实验中采用 DeepSpeed 框架，并使用 ZeRO 阶段-1 选项。该优化对训练速度影响极小。

- *活性值检查点技术* [12]. Transformer 层中的特征图同样会消耗大量 GPU 内存，当图像和窗口分辨率较高时，这可能会造成瓶颈。活性值检查点技术可以显著降低内存消耗，但训练速度会慢约 30%。

- *顺序自注意力计算*。为了在非常大的分辨率上训练大型模型，例如分辨率为 1,536× 1,536 的图像且窗口大小为 32× 32 时，即使采用上述两种最优化技术，常规的 A100 GPU（40GB 内存）仍然无法承受。我们发现，在这种情况下，自注意力模块构成了瓶颈。为了缓解这一问题，我们实现顺序自注意力计算，而非使用之前的批量计算方法。该最优化应用于前两个阶段的层中，对整体训练速度影响甚微。

通过这些实现，我们成功使用 Nvidia A100-40G GPU 训练了一个 3B 参数的模型，用于 COCO 目标检测（输入图像分辨率为 1,536× 1,536），以及 Kinetics-400 动作分类（输入分辨率为 $320 \times 320 \times 8$）。

3.6. 模型配置

我们为 Swin Transformer V2 的 4 种配置保持了原始 Swin Transformer 的阶段、块和通道设置。

- SwinV2-T：$C = 96$，#. 块 $= \{2, 2, 6, 2\}$
- SwinV2-S/B/L：C =96/128/192，#.block=$\{2, 2, 18, 2\}$

其中 C 为第一阶段的通道数。

我们进一步将 Swin Transformer V2 扩展至其巨大的规模和超大规模，参数量分别为 6.58 亿和 30 亿：

- SwinV2-H：$C = 352$，#. 块 $= \{2, 2, 18, 2\}$
- SwinV2-G：$C = 512$，#. 块 $= \{2, 2, 42, 4\}$

对于 SwinV2-H 和 SwinV2-G，我们在主分支每 6 层增加一层层规范化。为了节省实验时间，我们仅在大规模实验中使用 SwinV2-G。SwinV2-H 用于另一项关于自监督学习的并行研究 [72]。

4. 实验

4.1. 任务和数据集

我们在 ImageNet-1K 图像分类(V1 和 V2) [18,55]、COCO 目标检测 [44] 和 ADE20K 语义分割 [85] 上进行实验。对于 3B 模型的实验，我们还报告了在 Kinetics-400 视频动作识别上的准确率 [37]。

- *图像分类*。使用 ImageNet-1K V1 和 V2 验证集进行评估 [18, 55]。可选地，使用包含 1400 万张图像和 22000 个类别的 ImageNet-22K [18] 进行预训练。对于我们的最大模型 SwinV2-G 的预训练，使用了一个私有收集的 ImageNet-22K-ext 数据集，该数据集包含 7000 万张图像。对于此数据集，进行了去重处理 [51]，以排除与 ImageNet-1K V1 和 V2 验证集重叠的图像。
- *目标检测*。使用 COCO [44] 进行评估。在我们最大模型的实验中，我们在图像分类预训练阶段与 COCO 微调阶段之间，增加了一个额外的目标检测预训练阶段，使用的是 Object 365 v2 数据集 [59]。
- *语义分割*。使用 ADE20K [85]。
- *视频动作分类*。使用 Kinetics-400 (K400) [37] 进行评估。

预训练和微调的情景将在附录中详细说明。

4.2. 扩大实验

我们首先展示了在各种具有代表性的视觉基准上，将模型参数扩展到 30 亿并提升至高图像/窗口分辨率时的结果。

SwinV2-G 实验设置 我们采用较小的 192×192 图像分辨率进行预训练，以降低训练成本。我们采用两步预训练方法：首先，模型在 ImageNet-22K-ext 数据集上使用自监督方法 [72] 进行 20 轮次的预训练；其次，模型在此数据集上通过图像分类任务再进行 30 轮次的进一步预训练。详细的预训练和微调设置见附录。

在以下段落中，我们报告了 SwinV2-G 在代表性视觉基准上的准确率。需要注意的是，由于我们的主要目标是探索如何可行地扩大模型容量和窗口分辨率，以及视觉任务是否能从显著更大的模型容量中获益，因此在比较时并未特别对齐复杂度或预训练数据。

ImageNet-1K 图像分类结果 表 2 比较了 SwinV2-G 模型与此前最大/最佳视觉模型在 ImageNet-1K V1 和 V2 分类任务上的表现。SwinV2-G 是目前最大的稠密视觉模型，其在 ImageNet V2 基准测试中达到了

Method	param	pre-train images	pre-train length (#im)	pre-train im size	pre-train time	fine-tune im size	ImageNet-1K-V1 top-1 acc	ImaegNet-1K-V2 top-1 acc
SwinV1-B	88M	IN-22K-14M	1.3B	224^2	<30†	384^2	86.4	76.58
SwinV1-L	197M	IN-22K-14M	1.3B	224^2	<10†	384^2	87.3	77.46
ViT-G [80]	1.8B	JFT-3B	164B	224^2	>30k	518^2	90.45	83.33
V-MoE [56]	14.7B*	JFT-3B	-	224^2	16.8k	518^2	90.35	-
CoAtNet-7 [17]	2.44B	JFT-3B	-	224^2	20.1k	512^2	**90.88**	-
SwinV2-B	88M	IN-22K-14M	1.3B	192^2	<30†	384^2	87.1	78.08
SwinV2-L	197M	IN-22K-14M	1.3B	192^2	<20†	384^2	87.7	78.31
SwinV2-G	3.0B	IN-22K-ext-70M	3.5B	192^2	<0.5k†	640^2	90.17	**84.00**

表 2. 与先前最大的视觉模型在 ImageNet-1K V1 和 V2 分类上的对比。* 表示稀疏模型；“预训练时间” 列以 TPUv3 核心天数为单位，数值来自原始论文。† SwinV2-G 的该值根据训练迭代次数和浮点运算量估算得出。

Method	train I(W) size	test I(W) size	mini-val (AP) box	mini-val (AP) mask	test-dev (AP) box	test-dev (AP) mask
CopyPaste [25]	1280(-)	1280(-)	57.0	48.9	57.3	49.1
SwinV1-L [46]	800(7)	ms(7)	58.0	50.4	58.7	51.1
YOLOR [66]	1280(-)	1280(-)	-	-	57.3	-
CBNet [43]	1400(7)	ms(7)	59.6	51.8	60.1	52.3
DyHead [16]	1200(-)	ms(-)	60.3	-	60.6	-
SoftTeacher [74]	1280(12)	ms(12)	60.7	52.5	61.3	53.0
SwinV2-L (HTC++)	1536(32)	1100(32)	58.8	51.1	-	-
		1100 (48)	58.9	51.2	-	-
		ms (48)	60.2	52.1	60.8	52.7
SwinV2-G (HTC++)	1536(32)	1100(32)	61.7	53.3	-	-
		1100 (48)	61.9	53.4	-	-
		ms (48)	**62.5**	**53.7**	**63.1**	**54.4**

表 3. 与 COCO 目标检测和实例分割先前最佳结果的对比。I(W) 表示图像和窗口大小。ms 表示采用了多尺度测试。

Method	train I(W) size	test I(W) size	mIoU
SwinV1-L [46]	640(7)	640(7)	53.5*
Focal-L [75]	640(40)	640(40)	55.4*
CSwin-L [21]	640(40)	640(40)	55.7*
MaskFormer [13]	640(7)	640(7)	55.6*
FaPN [33]	640(7)	640(7)	56.7*
BEiT [4]	640(40)	640(40)	58.4*
SwinV2-L (UperNet)	640(40)	640(40)	55.9*
SwinV2-G (UperNet)	640(40)	640(40)	59.1
		896 (56)	59.3
		896 (56)	**59.9***

表 4. 与 ADE20K 语义分割先前最佳结果的比较。* 表示使用了多尺度测试。

Method	train I(W) size	test I(W) size	views	top-1
ViViT [2]	-(-)	-(-)	4×3	84.8
SwinV1-L [47]	$480(12)^2\times16(8)$	$480(12)^2\times16(8)$	10×5	84.9
TokenLearner [57]	$256(8)^2\times64(64)$	$256(8)^2\times64(64)$	4×3	85.4
Video-SwinV2-G	$320(20)^2\times8(8)$	$320(20)^2\times8(8)$	1×1	83.2
		$384(24)^2\times8(8)$	1×1	83.4
		$384(24)^2\times8(8)$	4×5	**86.8**

表 5. 与 Kinetics-400 视频动作分类先前最佳结果的对比。

84.0% 的 top-1 准确率，比之前最佳结果（83.3%）高出 +0.7%。我们在 ImageNet-1K V1 上的准确率略低（90.17% vs 90.88%）。性能差异可能源于数据集过拟合程度的不同 [55]。此外需要注意的是，我们的训练迭代次数远少于以往工作，且采用的图像分辨率更低，但仍取得了优异的表现。

我们还将 SwinV2-B 和 SwinV2-L 分别与原始的 SwinV1-B 和 SwinV1-L 进行比较，分别观察到 +0.8% 和 +0.4% 的提升。SwinV2-L 相较于 SwinV2-B 的提升幅度减小，可能意味着如果模型大小超过此范围，则需要更多的标注数据、更强的正则化或更先进的自监督学习方法。

COCO 目标检测结果 表 3 将 SwinV2-G 模型与 COCO 目标检测和实例分割任务上的先前最优结果进行了比较。该模型在 COCO test-dev 上取得了 63.1/54.4 的框/AP 最大值，比之前的最优结果（[74] 提出的 61.3/53.0）分别提高了 1.8/1.4。这表明扩大视

Backbone	res-post-norm	scaled cosine attention	ImageNet top-1 acc
Swin-T			81.5
	✓		81.6
	✓	✓	**81.7**
Swin-S			83.2
	✓		83.3
	✓	✓	**83.6**
Swin-B			83.6
	✓		83.8
	✓	✓	**84.1**
ViT-B			82.2
	✓	✓	**82.6**

表 6. 关于 res-post-norm 和余弦注意力的消融实验。

Backbone	pre-norm	sandwich [20]	post-norm [65]	our
Swin-S	83.2	82.6	83.3	**83.6**
Swin-B	83.6	-	83.6	**84.1**

表 7. 与其他归一化方法的比较。后归一化方法在默认学习率下发散，因此我们为此方法使用了默认学习率的 1/4。夹心结构的表现不如我们的方法，可能是因为它牺牲了表达能力。

觉模型规模对于稠密视觉识别任务（如目标检测）是有益的。我们的方法在测试时可采用不同的窗口大小以进一步获益，这可能归因于有效的对数间距 CPB 方法。

ADE20K 语义分割结果 表 4 将 SwinV2-G 模型与 ADE20K 语义分割基准上的先前最优结果进行了比较。该模型在 ADE20K 验证集上达到了 59.9 mIoU，比之前的最优结果（[4] 提出的 58.4）高出 1.5。这表明扩大视觉模型规模对像素级视觉识别任务是有益的。在测试时使用更大的窗口大小可额外带来 +0.2 的提升，这可能归因于有效的对数间隔 CPB 方法。

Kinetics-400 视频动作分类结果 表 5 将 SwinV2-G 模型与 Kinetics-400 动作分类基准上的先前最佳结果进行了比较。该模型达到了 86.8% 的 top-1 准确率，比之前的最佳数值 [57] 提高了 +1.4%。这表明扩大视觉模型规模同样有助于视频识别任务。在此场景下，测试时使用更大的窗口大小还可带来额外的 +0.2% 提升，可能归因于有效的对数间隔 CPB 方法。

4.3. 消融研究

关于 res-post-norm 和缩放余弦注意力的消融实验 表 6 展示了将所提出的 res-post-norm 和缩放余弦注意力方法应用于 Swin Transformer 时的性能消融实验。两种技术在所有微型、小型和基础大小的模型上均提升了准确率，总体提升分别为 +0.2%、+0.4% 和 +0.5%，表明这些技术对更大模型更具优势。同时，该方法也对 ViT 架构带来了提升（+0.4%）。如表 7 所示，所提出的规范化方法相较于其他一些规范化方法表现更优。

更重要的是，后范数（post-norm）与缩放余弦注意力的结合稳定了训练过程。如图 2所示，当模型规模较大（L）时，原始 Swin Transformer 深层的活性值几乎发生爆炸，而新版本模型的活性值行为则要温和得多。在超大规模模型上，使用原始 Swin Transformer 进行自监督预训练 [72] 会发生发散，而采用 Swin Transformer V2 模型则能顺利训练。

通过不同方法提升窗口分辨率 表 1 和 8 通过在预训练阶段将窗口分辨率从 256×256 缩放至下游视觉任务中的更大尺寸，对三种方法的性能进行了消融分析，这些下游任务分别为 ImageNet-1K 图像分类、COCO 目标检测和 ADE20K 语义分割。可以看出：1）不同方法在预训练阶段的准确率相近（81.7%-81.8%）；2）在迁移至下游任务时，两种连续位置偏置（CPB）方法的表现均持续优于 Swin Transformer V1 中使用的参数化位置偏置方法。相较于线性间距方法，对数间距版本表现略优；3）预训练与微调阶段分辨率变化越大，所提出的对数间距 CPB 方法带来的优势越明显。

在表 1 和 8 中，我们还报告了在未进行微调的情况下使用目标窗口分辨率的准确率（见 ImageNet-1K 实验中每列的第一个数值）。即使窗口大小从 8 扩大到 24（78.9% 对比 81.8%），识别准确率仍然保持不错，而原方法的 top-1 准确率则从 81.7% 显著下降至 68.7%。此外请注意，在未进行微调的情况下，使用预训练模型从未见过的窗口大小 12 甚至可以比原准确率高出 +0.4%。这表明我们可以通过测试时的窗口调整来提升准确率，这一点也在表 3、4 和 5 中得到了观察。

5. 结论

我们提出了将 Swin Transformer 扩展至 30 亿参数并支持高达 1,536× 1,536 分辨率图像训练的技术，

Backbone	L-CPB	ImageNet*	ImageNet†	
		W8, I256	W12, I384	W16, I512
SwinV2-S		83.7	81.8/84.5	79.4/84.9
	✓	83.7	84.1/84.8	82.9/85.4
SwinV2-B		84.1	82.9/85.0	81.0/85.3
	✓	84.2	84.5/85.1	83.8/85.6

表 8. 基于不同模型大小的 Log-CPB 消融实验。

包括 *res-post-norm* 和缩放余弦注意力，以使模型更容易扩展其容量，同时还采用了一种对数间隔的连续相对位置偏置方法，使模型在不同窗口分辨率间更有效地迁移。该改进架构被称为 Swin Transformer V2，通过提升容量和分辨率，它在 4 个代表性视觉基准上创造了新的记录。凭借这些优异的结果，我们希望激发更多相关研究，最终缩小视觉与语言模型之间的容量差距，并推动两个领域的联合建模。

致谢

我们感谢微软的许多同事提供的帮助，特别是 Eric Chang、Lidong Zhou、Jing Tao、Aaron Zhang、Edward Cui、Bin Xiao、Lu Yuan、Peng Cheng 和 Fan Yang 在 GPU 资源和数据集方面提供的宝贵讨论与支持。

A1. 消融实验情景

本节描述了消融实验的设置，包括 SwinV2-T、SwinV2-S 和 SwinV2-B 模型，以及 ImageNet-1K 图像分类、COCO 目标检测和 ADE 语义分割任务。

A1.1. ImageNet-1K 预训练

所有消融实验均采用 ImageNet-1K 图像分类任务进行预训练。我们采用输入图像大小（窗口大小）为 256× 256 (8× 8)[2]. 在 [46] 的基础上，我们使用 AdamW [48] 优化器进行 300 轮次训练，采用余弦衰减学习率调度器，并包含 20 轮次的线性预热。批量大小为 1024，初始学习率为 1×10^{-3}，权重衰减为 0.05，梯度裁剪的最大范数为 5.0。增强和正则化策略包括 RandAugment [15]、Mixup [81]、Cutmix [79]、随机擦除 [84] 和随机深度 [32]。对于更大的模型，采用递增的随机深度增强程度，即分别为 tiny、small 和 base 模型设置 0.2, 0.3, 0.5。

[2]我们的大多数实验都将窗口大小设为偶数，以确保窗口移动的偏移量能被窗口大小整除。然而，窗口大小为奇数时也同样表现良好，正如原始的 Swin Transformer (7×7) 所示。

A1.2. 在各种任务上的微调

ImageNet-1K 图像分类 对于 ImageNet-1K 图像分类实验，如果输入图像的分辨率大于预训练步骤中的分辨率，则我们进行微调步骤。微调持续 30 轮次，使用 AdamW [48] 优化器，初始学习率为 4×10^{-5} 的余弦衰减学习率调度器，权重衰减为 1×10^{-8} ，并采用与第一阶段相同的数据增强和正则化方法。

COCO 目标检测 我们使用在 mmdetection [11] 中实现的级联掩码 R-CNN [8, 28] 作为目标检测框架。在训练中，采用多尺度增强 [9, 61]，较短边大小在 480 到 800 之间，较长边大小为 1333。窗口大小设置为 16× 16。使用 AdamW [48] 优化器，初始学习率为 1×10^{-4} ，权重衰减为 0.05，批量大小为 16，采用 3× 调度策略。

ADE20K 语义分割 我们采用图像大小（窗口大小）为 512× 512(16× 16)。在训练中，我们使用 AdamW [48] 优化器，初始学习率为 4×10^{-5} ，权重衰减为 0.05，学习率调度器采用线性学习率衰减，并进行 1,500 次迭代的线性预热。模型以批量大小 16 训练 160K 次迭代。我们遵循 mmsegmentation 代码库，采用随机水平翻转、随机缩放（缩放比例范围 [0.5, 2.0]）以及随机光度畸变的数据增强方法。所有模型均应用随机深度，其比例为 0.3 。所有实验均采用逐层学习率衰减 [4]，衰减率为 0.95。

A2. 系统级对比的实验情景

A2.1. SwinV2-B 和 SwinV2-L 情景

表 2、3 和 4 包含了 SwinV2-B 和 SwinV2-L 的结果。在这些实验中，我们首先进行 ImageNet-22K 预训练，然后在各个下游识别任务上微调预训练模型。

ImageNet-22K 预训练 两个模型均采用输入图像大小（窗口大小）为 192× 192（12× 12）。我们使用 AdamW 优化器 [48] 进行 90 轮次训练，采用余弦学习率调度器，并配合 5 轮次的线性预热。批量大小为 4096，初始学习率为 0.001，权重衰减为 0.1，梯度

裁剪的最大范数为 5.0。数据增强和正则化策略包括 RandAugment [15]、Mixup [81]、Cutmix [79]、随机擦除 [84] 和随机深度 [32]，其比例为 0.2。

ImageNet-1K 图像分类 我们考虑输入图像大小为 256× 256 和 384× 384。训练轮次设置为 30 轮，批量大小为 1024，采用余弦衰减学习率调度器，初始学习率为 4×10^{-5} ，权重衰减为 1×10^{-8} 。ImageNet-1K 分类权重也从 ImageNet-22K 模型中的对应权重初始化。

COCO 目标检测 我们采用 HTC++ [10, 46] 进行实验。在数据预处理中，使用 Instaboost [23]，采用多尺度训练 [26]，输入图像大小为 1536× 1536，窗口大小为 32× 32，随机缩放范围在 $[0.1, 2.0]$ 之间。使用 AdamW 优化器 [48]，初始学习率设为 4×10^{-4}，批量大小为 64，权重衰减为 0.05，并采用 3× 调度器。主干网络的学习率设置为头部学习率的 0.1×。在推理阶段，使用 soft-NMS [5]。报告了单尺度和多尺度测试结果。

ADE20K 语义分割 输入图像大小（窗口大小）设置为 640× 640（40× 40）。我们采用 AdamW [48] 优化器，初始学习率为 6×10^{-5} ，权重衰减为 0.05，使用线性衰减学习率调度器，并进行 375 次迭代的线性预热。模型以批量大小 64 训练 40K 次迭代。我们遵循 mmsegmentation 的默认数据增强设置，包括随机水平翻转、随机缩放（缩放比例值域为 $[0.5, 2.0]$ ）以及随机摄影畸变。应用了随机深度，比例为 0.3 。

A2.2. SwinV2-G 情景

第一阶段自监督预训练 模型首先在 ImageNet-22K-ext 数据集（7000 万张图像）上采用自监督学习方法 [1] 进行预训练，共进行 20 轮次。为降低实验开销，我们采用较小的图像大小 192× 192。使用 AdamW [48] 优化器进行训练，学习率调度采用余弦衰减策略，并设置 30000 步的线性预热。批量大小为 9216，初始学习率为 1.4×10^{-3} ，权重衰减为 0.1，梯度裁剪的最大范数为 100.0。采用轻量级数据增强策略：随机缩放裁剪，缩放值域为 [0.67, 1]，长宽比值域为 [3/4, 4/3]，随后进行随机翻转和颜色规范化步骤。

第二阶段监督预训练 模型在 ImageNet-22K-ext 数据集的类标记上进一步进行预训练。我们使用 AdamW [48] 优化器进行 30 轮次训练，采用余弦衰减学习率调度器，并设置 20000 步的线性预热。批量大小为 9216，初始学习率为 1.4×10^{-3}，逐层学习率衰减系数为 0.87，权重衰减为 0.1，并采用最大范数为 100.0 的梯度裁剪。增强和正则化策略包括 RandAugment [15]、随机擦除 [84] 以及 0.3 的随机深度 [32] 比例。

在 ImageNet-1K 图像分类上的微调 我们采用 640× 640 的输入图像大小进行实验。使用 AdamW [48] 优化器进行 10 轮次训练，采用余弦衰减的学习率调度器，并设置 2 轮次的线性预热。批量大小为 576，初始学习率为 2.1×10^{-5}，权重衰减为 0.1，梯度裁剪的最大范数为 100.0。数据增强和正则化策略包括 RandAugment [15]、随机擦除 [84] 以及 0.5 的随机深度 [32] 比例。

在评估中，我们在 ImageNet-1K V1 和 V2 上测试了 top-1 准确率。

在 COCO 目标检测上进行微调 我们首先使用 Objects-365 V2 数据集进行中间微调。在此阶段，我们移除 HTC++ 框架 [10, 46] 中的掩码分支，因为该数据集中没有掩码标注。输入图像分辨率和窗口大小分别设置为 $[800, 1024]$ 和 32×32。在训练过程中，采用 AdamW [48] 优化器，初始学习率为 1.2×10^{-3}，权重衰减为 0.05，批量大小为 96，训练步数设定为 67,500 步。

然后我们在 COCO 数据集上对 HTC++ 模型进行微调，掩码分支随机初始化，其他模型权重从 Objects-365-V2 预训练模型加载。在此训练阶段，输入图像分辨率为 1536× 1536，多尺度比例为 $[0.1, 2.0]$ 。窗口大小设置为 32× 32。采用 AdamW [48] 优化器，初始学习率为 6×10^{-4} ，权重衰减为 0.05，批量大小为 96，共训练 45,000 步。

在测试中，使用了 Soft-NMS [5]。考虑了 32×32 和 48×48 的两种窗口大小。

在 ADE20K 语义分割上的微调 输入图像大小（窗口大小）设置为 640× 640 (40× 40)。采用 AdamW 优化器 [48]，初始学习率为 4×10^{-5}，权重衰减为 0.05，线性衰减学习率调度器，共 80K 迭代，批量大小为 32，

线性预热迭代次数为 750。对于数据增强，我们遵循 mmsegmentation 的默认设置，包括随机水平翻转、随机缩放（缩放比例值域为 $[0.5, 2.0]$）以及随机光照畸变。随机深度比设置为 0.4。

在 Kinetics-400 视频动作识别上的微调 采用两阶段微调过程。在第一阶段，输入分辨率为 256× 256× 8，窗口大小为 16× 16× 8。我们使用 AdamW 优化器进行 20 轮次训练，采用余弦衰减学习率调度器，并设置 2.5 轮次的线性预热。其他训练超参数为：批量大小 80，初始学习率为 3.6×10^{-4} ，权重衰减为 0.1。

在第二阶段，我们进一步微调模型，使用更大的输入视频分辨率 320× 320× 8 和 20× 20× 8 的窗口大小。我们采用 AdamW 优化器进行 5 轮次训练，学习率调度器使用余弦衰减，并设置 1 轮次的线性预热。批量大小设为 64，初始学习率为 5×10^{-5}，权重衰减为 0.1。

A3. 不同方法所学习到的相对位置偏差

图 4 展示了不同偏置计算方法所学习到的相对位置偏置矩阵（$\hat{B} \in \mathbb{R}^{(2M-1)\times(2M-1)}$ ），采用的是 SwinV2-T 模型。可视化的是第一块中 3 个注意力头的偏置矩阵。左侧展示了使用输入图像大小为 256× 256 和窗口大小为 8×8 时学习到的偏置矩阵。右侧展示了在更大的输入图像分辨率 512× 512 和更大的窗口大小 16× 16 下进行微调后的偏置矩阵。结果表明，两种 CPB（连续位置偏置）方法学习到的偏置矩阵比 P-RPE（参数化相对位置偏置）方法更加平滑。图 5 展示了该模型最后一块的更多示例。

参考文献

[1] Anonymous. Simmim: A simple framework for masked image modeling. In *CVPR submission*, 2022. 10

[2] Anurag Arnab, Mostafa Dehghani, Georg Heigold, Chen Sun, Mario Lučić, and Cordelia Schmid. Vivit: A video vision transformer, 2021. 3, 7

[3] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E. Hinton. Layer normalization, 2016. 3

[4] Hangbo Bao, Li Dong, and Furu Wei. Beit: Bert pre-training of image transformers, 2021. 2, 7, 8, 9

[5] Navaneeth Bodla, Bharat Singh, Rama Chellappa, and Larry S. Davis. Soft-nms – improving object detection with one line of code. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, Oct 2017. 10

[6] Andrew Brock, Soham De, and Samuel L Smith. Characterizing signal propagation to close the performance gap in unnormalized resnets. *arXiv preprint arXiv:2101.08692*, 2021. 4

[7] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners, 2020. 1, 2

[8] Zhaowei Cai and Nuno Vasconcelos. Cascade r-cnn: Delving into high quality object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 6154–6162, 2018. 9

[9] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In *European Conference on Computer Vision*, pages 213–229. Springer, 2020. 9

[10] Kai Chen, Jiangmiao Pang, Jiaqi Wang, Yu Xiong, Xiaoxiao Li, Shuyang Sun, Wansen Feng, Ziwei Liu, Jianping Shi, Wanli Ouyang, et al. Hybrid task cascade for instance segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 4974–4983, 2019. 10

[11] Kai Chen, Jiaqi Wang, Jiangmiao Pang, Yuhang Cao, Yu Xiong, Xiaoxiao Li, Shuyang Sun, Wansen Feng, Ziwei Liu, Jiarui Xu, et al. Mmdetection: Open mmlab detection toolbox and benchmark. *arXiv preprint arXiv:1906.07155*, 2019. 9

[12] Tianqi Chen, Bing Xu, Chiyuan Zhang, and Carlos Guestrin. Training deep nets with sublinear memory cost, 2016. 2, 5

[13] Bowen Cheng, Alexander G. Schwing, and Alexander Kirillov. Per-pixel classification is not all you need for semantic segmentation. *arXiv*, 2021. 7

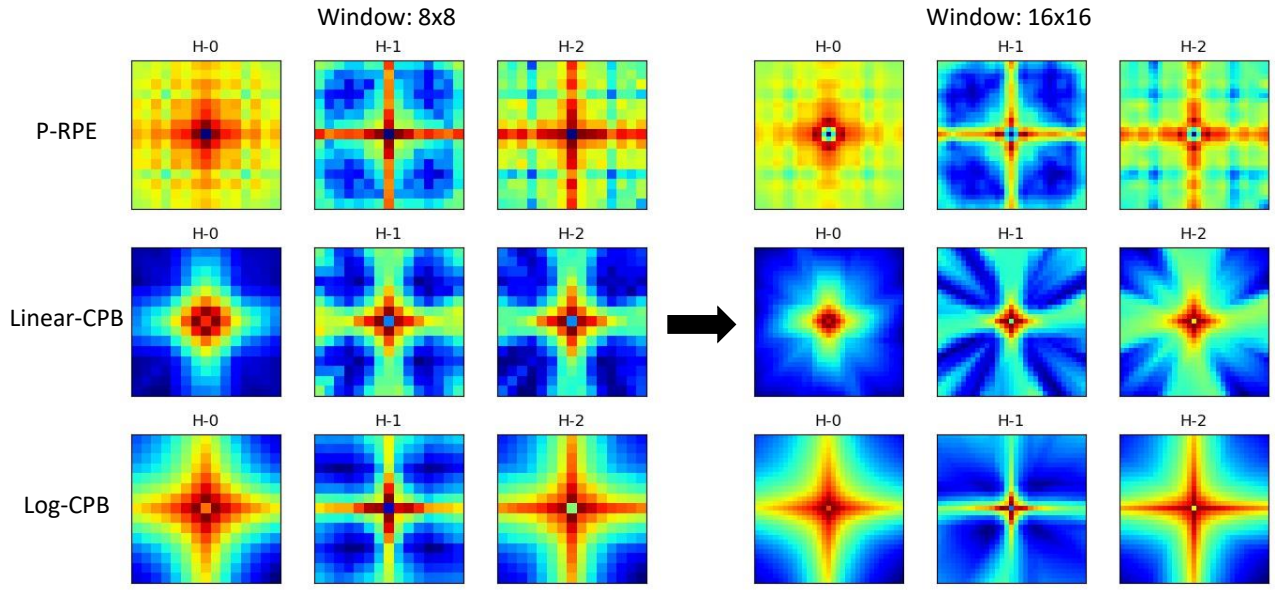

图 4. 不同方法学习到的相对位置偏置矩阵的可视化结果，采用 SwinV2-T 模型及第一块中的 3 个头。左图：在 256× 256 图像和 8× 8 窗口上进行预训练得到的偏置矩阵；右图：使用 512× 512 图像大小和 16× 16 窗口大小进行微调后的偏置矩阵。H-x 表示第 x 个头。

[14] Xiangxiang Chu, Zhi Tian, Yuqing Wang, Bo Zhang, Haibing Ren, Xiaolin Wei, Huaxia Xia, and Chunhua Shen. Twins: Revisiting the design of spatial attention in vision transformers, 2021. 3

[15] Ekin D Cubuk, Barret Zoph, Jonathon Shlens, and Quoc V Le. Randaugment: Practical automated data augmentation with a reduced search space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 702–703, 2020. 9, 10

[16] Xiyang Dai, Yinpeng Chen, Bin Xiao, Dongdong Chen, Mengchen Liu, Lu Yuan, and Lei Zhang. Dynamic head: Unifying object detection heads with attentions, 2021. 7

[17] Zihang Dai, Hanxiao Liu, Quoc V. Le, and Mingxing Tan. Coatnet: Marrying convolution and attention for all data sizes, 2021. 1, 3, 5, 7

[18] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE conference on computer vision and pattern recognition*, pages 248–255. Ieee, 2009. 6

[19] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018. 1, 2

[20] Ming Ding, Zhuoyi Yang, Wenyi Hong, Wendi Zheng, Chang Zhou, Da Yin, Junyang Lin, Xu Zou, Zhou Shao, Hongxia Yang, and Jie Tang. Cogview: Mastering text-to-image generation via transformers. *arXiv preprint arXiv:2105.13290*, 2021. 3, 8

[21] Xiaoyi Dong, Jianmin Bao, Dongdong Chen, Weiming Zhang, Nenghai Yu, Lu Yuan, Dong Chen, and Baining Guo. Cswin transformer: A general vision transformer backbone with cross-shaped windows, 2021. 3, 7

[22] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021. 2, 3

[23] Hao-Shu Fang, Jianhua Sun, Runzhong Wang, Minghao Gou, Yong-Lu Li, and Cewu Lu. Instaboost: Boosting instance segmentation via probability map guided copy-pasting. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages

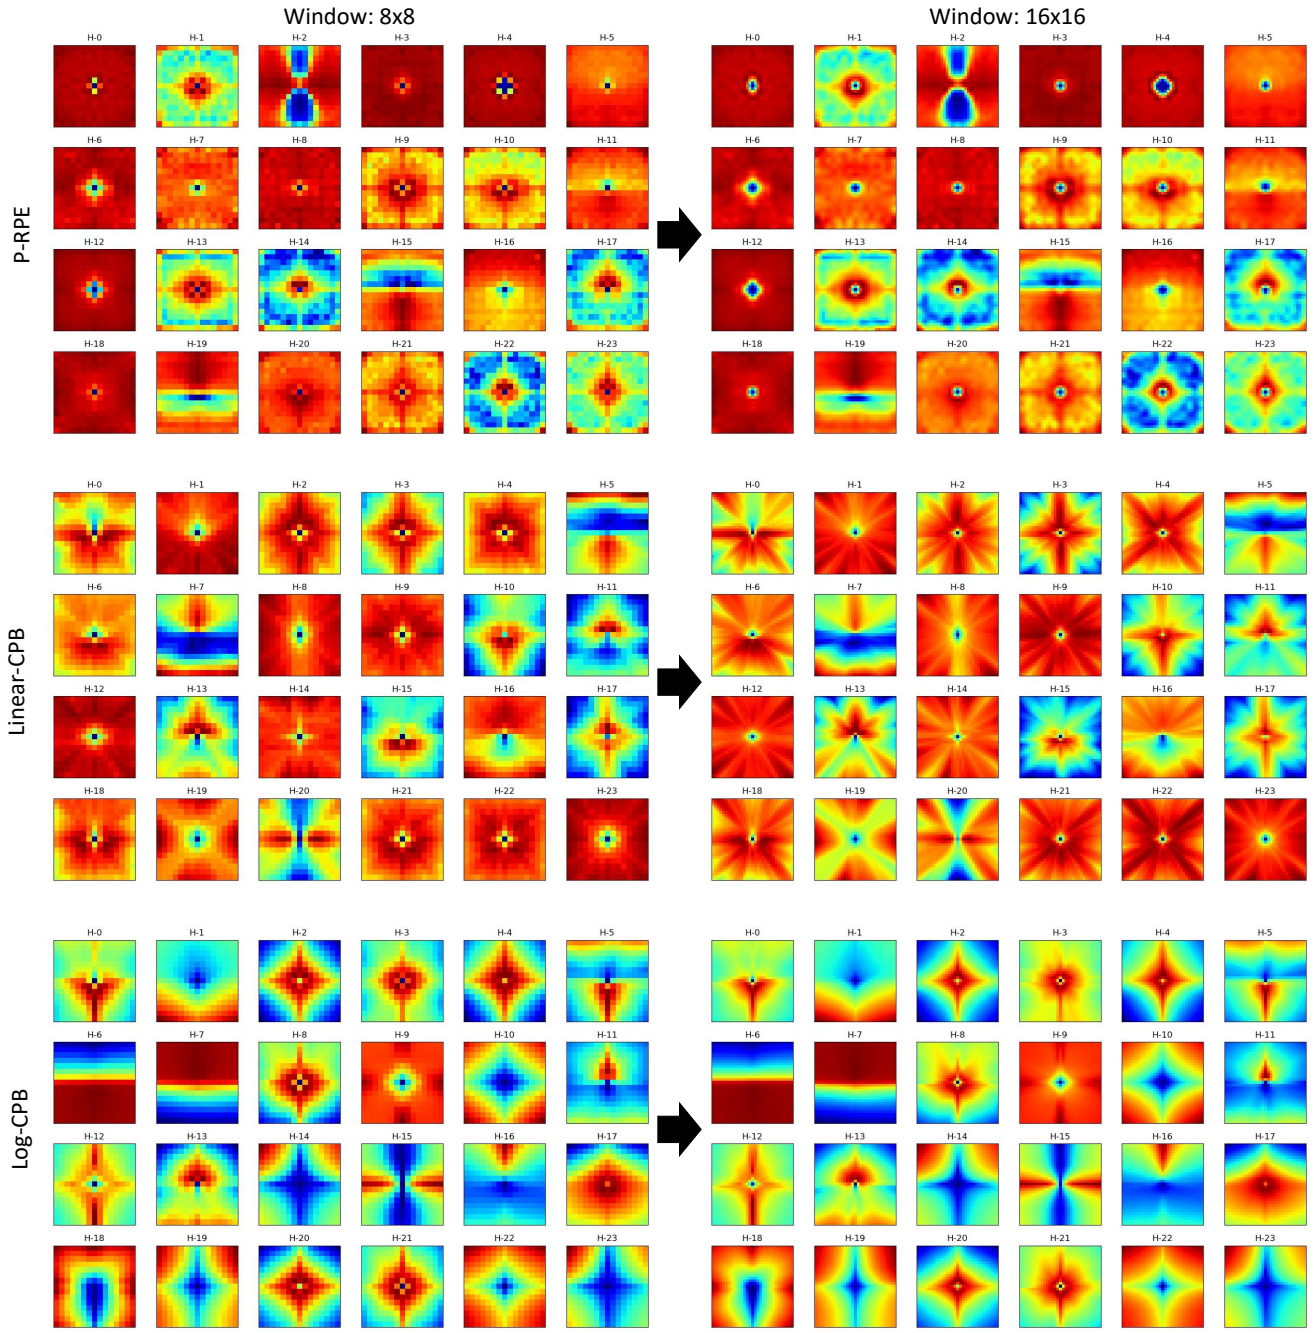

图 5. 不同方法学习到的相对位置偏置矩阵的可视化结果，采用 SwinV2-T 模型和最后一块中的 24 个头。左图：在 256× 256 图像和 8× 8 窗口上进行预训练得到的偏置矩阵；右图：使用 512× 512 图像大小和 16× 16 窗口大小进行微调后的偏置矩阵。H-x 表示第 x 个头。

682–691, 2019. 10

[24] William Fedus, Barret Zoph, and Noam Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity, 2021. 1, 2

[25] Golnaz Ghiasi, Yin Cui, Aravind Srinivas, Rui Qian, Tsung-Yi Lin, Ekin D Cubuk, Quoc V Le, and Barret Zoph. Simple copy-paste is a strong data augmentation method for instance segmentation. *arXiv preprint*

arXiv:2012.07177, 2020. 7

[26] Golnaz Ghiasi, Tsung-Yi Lin, and Quoc V Le. Nas-fpn: Learning scalable feature pyramid architecture for object detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7036–7045, 2019. 10

[27] Priya Goyal, Mathilde Caron, Benjamin Lefaudeux, Min Xu, Pengchao Wang, Vivek Pai, Mannat Singh, Vitaliy Liptchinsky, Ishan Misra, Armand Joulin, and Piotr Bojanowski. Self-supervised pretraining of visual features in the wild, 2021. 1, 3

[28] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask r-cnn. In *Proceedings of the IEEE international conference on computer vision*, pages 2961–2969, 2017. 9

[29] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016. 1

[30] Han Hu, Jiayuan Gu, Zheng Zhang, Jifeng Dai, and Yichen Wei. Relation networks for object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3588–3597, 2018. 3

[31] Han Hu, Zheng Zhang, Zhenda Xie, and Stephen Lin. Local relation networks for image recognition. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 3464–3473, October 2019. 3

[32] Gao Huang, Yu Sun, Zhuang Liu, Daniel Sedra, and Kilian Q Weinberger. Deep networks with stochastic depth. In *European conference on computer vision*, pages 646–661. Springer, 2016. 9, 10

[33] Shihua Huang, Zhichao Lu, Ran Cheng, and Cheng He. Fapn: Feature-aligned pyramid network for dense image prediction, 2021. 7

[34] Zilong Huang, Youcheng Ben, Guozhong Luo, Pei Cheng, Gang Yu, and Bin Fu. Shuffle transformer: Rethinking spatial shuffle for vision transformer, 2021. 3

[35] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift, 2015. 3

[36] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B. Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models, 2020. 2

[37] Will Kay, Joao Carreira, Karen Simonyan, Brian Zhang, Chloe Hillier, Sudheendra Vijayanarasimhan, Fabio Viola, Tim Green, Trevor Back, Paul Natsev, et al. The kinetics human action video dataset. *arXiv preprint arXiv:1705.06950*, 2017. 6

[38] Guolin Ke, Di He, and Tie-Yan Liu. Rethinking positional encoding in language pre-training, 2021. 3

[39] Alexander Kolesnikov, Lucas Beyer, Xiaohua Zhai, Joan Puigcerver, Jessica Yung, Sylvain Gelly, and Neil Houlsby. Big transfer (bit): General visual representation learning. *arXiv preprint arXiv:1912.11370*, 6(2):8, 2019. 1, 3

[40] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in neural information processing systems*, pages 1097–1105, 2012. 2

[41] Yann LeCun, Léon Bottou, Yoshua Bengio, Patrick Haffner, et al. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998. 2

[42] Yawei Li, Kai Zhang, Jiezhang Cao, Radu Timofte, and Luc Van Gool. Localvit: Bringing locality to vision transformers, 2021. 3

[43] Tingting Liang, Xiaojie Chu, Yudong Liu, Yongtao Wang, Zhi Tang, Wei Chu, Jingdong Chen, and Haibin Ling. Cbnetv2: A composite backbone network architecture for object detection, 2021. 7

[44] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C Lawrence Zitnick. Microsoft coco: Common objects in context. In *European conference on computer vision*, pages 740–755. Springer, 2014. 6

[45] Ze Liu, Han Hu, Yue Cao, Zheng Zhang, and Xin Tong. A closer look at local aggregation operators in point cloud analysis, 2020. 3

[46] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows, 2021. 2, 3, 5, 7, 9, 10

[47] Ze Liu, Jia Ning, Yue Cao, Yixuan Wei, Zheng Zhang, Stephen Lin, and Han Hu. Video swin transformer, 2021. 2, 7

[48] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019. 9, 10

[49] Microsoft. Turing-nlg: A 17-billion-parameter language model by microsoft, 2020. 1, 2

[50] Microsoft. Using deepspeed and megatron to train megatron-turing nlg 530b, the world' s largest and most powerful generative language model, 2021. 1, 2

[51] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision, 2021. 6

[52] Alec Radford, Jeff Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. 2019. 1, 2, 3

[53] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020. 1, 2, 3

[54] Samyam Rajbhandari, Jeff Rasley, Olatunji Ruwase, and Yuxiong He. Zero: Memory optimizations toward training trillion parameter models, 2020. 2, 5

[55] Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt, and Vaishaal Shankar. Do imagenet classifiers generalize to imagenet?, 2019. 2, 6, 7

[56] Carlos Riquelme, Joan Puigcerver, Basil Mustafa, Maxim Neumann, Rodolphe Jenatton, André Susano Pinto, Daniel Keysers, and Neil Houlsby. Scaling vision with sparse mixture of experts, 2021. 1, 3, 5, 7

[57] Michael S. Ryoo, AJ Piergiovanni, Anurag Arnab, Mostafa Dehghani, and Anelia Angelova. Tokenlearner: What can 8 learned tokens do for images and videos?, 2021. 2, 7, 8

[58] Kristof T Schütt, Pieter-Jan Kindermans, Huziel E Sauceda, Stefan Chmiela, Alexandre Tkatchenko, and Klaus-Robert Müller. Schnet: A continuous-filter convolutional neural network for modeling quantum interactions. *arXiv preprint arXiv:1706.08566*, 2017. 3

[59] Shuai Shao, Zeming Li, Tianyuan Zhang, Chao Peng, Gang Yu, Xiangyu Zhang, Jing Li, and Jian Sun. Objects365: A large-scale, high-quality dataset for object detection. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, October 2019. 6

[60] K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations*, May 2015. 1, 2

[61] Peize Sun, Rufeng Zhang, Yi Jiang, Tao Kong, Chenfeng Xu, Wei Zhan, Masayoshi Tomizuka, Lei Li, Zehuan Yuan, Changhu Wang, et al. Sparse r-cnn: End-to-end object detection with learnable proposals. *arXiv preprint arXiv:2011.12450*, 2020. 9

[62] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 1–9, 2015. 2

[63] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. *arXiv preprint arXiv:2012.12877*, 2020. 3

[64] Dmitry Ulyanov, Andrea Vedaldi, and Victor Lempitsky. Instance normalization: The missing ingredient for fast stylization, 2017. 3

[65] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, pages 5998–6008, 2017. 2, 3, 8

[66] Chien-Yao Wang, I-Hau Yeh, and Hong-Yuan Mark Liao. You only learn one representation: Unified network for multiple tasks, 2021. 7

[67] Shenlong Wang, Simon Suo, Wei-Chiu Ma, Andrei Pokrovsky, and Raquel Urtasun. Deep parametric continuous convolutional neural networks. *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, Jun 2018. 3

[68] Wenhai Wang, Enze Xie, Xiang Li, Deng-Ping Fan, Kaitao Song, Ding Liang, Tong Lu, Ping Luo, and Ling Shao. Pyramid vision transformer: A versatile

backbone for dense prediction without convolutions, 2021. 3

[69] Kan Wu, Houwen Peng, Minghao Chen, Jianlong Fu, and Hongyang Chao. Rethinking and improving relative position encoding for vision transformer, 2021. 3

[70] Yuxin Wu and Kaiming He. Group normalization. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 3–19, 2018. 3

[71] Tete Xiao, Mannat Singh, Eric Mintun, Trevor Darrell, Piotr Dollár, and Ross Girshick. Early convolutions help transformers see better. *arXiv preprint arXiv:2106.14881*, 2021. 3

[72] Zhenda Xie, Zheng Zhang, Yue Cao, Yutong Lin, Jianmin Bao, Zhuliang Yao, Qi Dai, and Han Hu. Simmim: A simple framework for masked image modeling. In *Tech report*, 2022. 4, 5, 6, 8

[73] Ruibin Xiong, Yunchang Yang, Di He, Kai Zheng, Shuxin Zheng, Chen Xing, Huishuai Zhang, Yanyan Lan, Liwei Wang, and Tie-Yan Liu. On layer normalization in the transformer architecture. 2020. 3

[74] Mengde Xu, Zheng Zhang, Han Hu, Jianfeng Wang, Lijuan Wang, Fangyun Wei, Xiang Bai, and Zicheng Liu. End-to-end semi-supervised object detection with soft teacher, 2021. 2, 7

[75] Jianwei Yang, Chunyuan Li, Pengchuan Zhang, Xiyang Dai, Bin Xiao, Lu Yuan, and Jianfeng Gao. Focal self-attention for local-global interactions in vision transformers, 2021. 3, 7

[76] Zhuliang Yao, Yue Cao, Yutong Lin, Ze Liu, Zheng Zhang, and Han Hu. Leveraging batch normalization for vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 413–422, 2021. 4

[77] Li Yuan, Yunpeng Chen, Tao Wang, Weihao Yu, Yujun Shi, Zihang Jiang, Francis EH Tay, Jiashi Feng, and Shuicheng Yan. Tokens-to-token vit: Training vision transformers from scratch on imagenet, 2021. 3

[78] Li Yuan, Qibin Hou, Zihang Jiang, Jiashi Feng, and Shuicheng Yan. Volo: Vision outlooker for visual recognition. *arXiv preprint arXiv:2106.13112*, 2021. 3

[79] Sangdoo Yun, Dongyoon Han, Seong Joon Oh, Sanghyuk Chun, Junsuk Choe, and Youngjoon Yoo. Cutmix: Regularization strategy to train strong classifiers with localizable features. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 6023–6032, 2019. 9, 10

[80] Xiaohua Zhai, Alexander Kolesnikov, Neil Houlsby, and Lucas Beyer. Scaling vision transformers, 2021. 1, 2, 3, 5, 7

[81] Hongyi Zhang, Moustapha Cisse, Yann N Dauphin, and David Lopez-Paz. mixup: Beyond empirical risk minimization. *arXiv preprint arXiv:1710.09412*, 2017. 9, 10

[82] Pengchuan Zhang, Xiyang Dai, Jianwei Yang, Bin Xiao, Lu Yuan, Lei Zhang, and Jianfeng Gao. Multi-scale vision longformer: A new vision transformer for high-resolution image encoding, 2021. 3

[83] Sixiao Zheng, Jiachen Lu, Hengshuang Zhao, Xiatian Zhu, Zekun Luo, Yabiao Wang, Yanwei Fu, Jianfeng Feng, Tao Xiang, Philip HS Torr, et al. Rethinking semantic segmentation from a sequence-to-sequence perspective with transformers. *arXiv preprint arXiv:2012.15840*, 2020. 3

[84] Zhun Zhong, Liang Zheng, Guoliang Kang, Shaozi Li, and Yi Yang. Random erasing data augmentation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, pages 13001–13008, 2020. 9, 10

[85] Bolei Zhou, Hang Zhao, Xavier Puig, Tete Xiao, Sanja Fidler, Adela Barriuso, and Antonio Torralba. Semantic understanding of scenes through the ade20k dataset. *International Journal on Computer Vision*, 2018. 6