https://hjfy.top/arxiv/2103.14030

Swin Transformer：使用移位窗口的分层视觉 Transformer

Ze Liu[†*] Yutong Lin[†*] Yue Cao[*] Han Hu[*‡] Yixuan Wei[†]
Zheng Zhang Stephen Lin Baining Guo
Microsoft Research Asia
{v-zeliu1,v-yutlin,yuecao,hanhu,v-yixwe,zhez,stevelin,bainguo}@microsoft.com

Abstract

本文提出了一种新的视觉 Transformer，称为 Swin Transformer，它能够作为计算机视觉的通用主干。从语言领域适应到视觉领域的 Transformer 面临挑战，这些挑战源于两个领域之间的差异，例如视觉实体在尺度上的巨大变化以及图像中像素的高分辨率与文本中单词相比。为了解决这些差异，我们提出了一种分层 Transformer，其表示是通过 Shifted window 计算的。shifted 窗口方案通过将自注意力计算限制在非重叠的局部窗口内来提高效率，同时也允许跨窗口连接。这种分层架构具有在各种尺度上建模的灵活性，并且其计算复杂度与图像大小呈线性关系。Swin Transformer 的这些特性使其适用于广泛的视觉任务，包括图像分类（ImageNet-1K 上的 87.3 top-1 准确率）和密集预测任务，如对象检测（COCO test-dev 上的 58.7 box AP 和 51.1 mask AP）和语义分割（ADE20K val 上的 53.5 mIoU）。其性能在 COCO 上比前一个最先进的方法高出 2.7 box AP 和 2.6 mask AP，在 ADE20K 上高出 3.2 mIoU，展示了基于 Transformer 的模型作为视觉主干的潜力。分层设计和 shifted 窗口方法也证明对所有 MLP 架构有益。代码和模型可在 https://github.com/microsoft/Swin-Transformer公开获取。

1. 引言

计算机视觉中的建模长期以来一直由卷积神经网络（CNNs）主导。从 AlexNet [39]在 ImageNet 图像分类挑战中革命性的表现开始，CNN 架构通过更大的规模 [30, 76]、更广泛的连接 [34]和更复杂的卷积形式 [70, 18, 84]不断发展，变得越来越强大。随着 CNN 作为各种视觉任务的主干网络，这些架构上的进步带来了性能的提升，从而整体上推动了整个领域的发展。

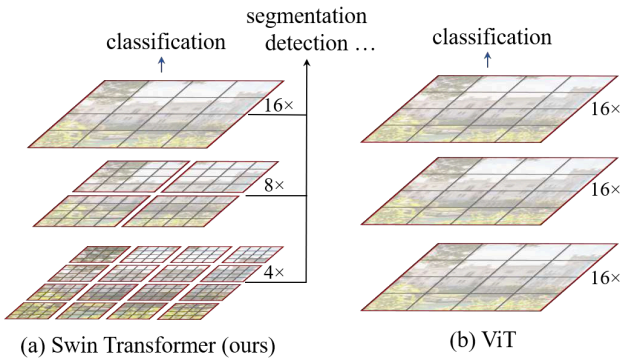

图 1. (a) 所提出的 Swin Transformer 通过在更深的层中合并图像块（灰色显示）来构建分层特征图，并且由于仅在每个局部窗口内（红色显示）计算自注意力，其计算复杂度与输入图像大小呈线性关系。因此，它可以作为图像分类和密集识别任务的通用主干网络。(b) 相比之下，先前的视觉 Transformer [20]生成单一低分辨率的特征图，并且由于全局计算自注意力，其计算复杂度与输入图像大小呈二次方关系。

另一方面，自然语言处理（NLP）中网络结构的演化走了一条不同的路径，如今流行的架构反而是 Transformer [64]。专为序列建模和转换任务设计的 Transformer 因其使用注意力机制来建模数据中的长距离依赖关系而闻名。它在语言领域的巨大成功促使研究人员探索其在计算机视觉领域的适应性，在那里它最近在某些任务上展示了有希望的结果，特别是图像分类 [20]和联合视觉-语言建模 [47]。

在本文中，我们寻求扩展 Transformer 的应用范

*等贡献。†MSRA 实习生。‡ 联系人。

围，使其能够作为计算机视觉中的通用主干网络，就像它在自然语言处理（NLP）中所做的那样，并且像卷积神经网络（CNNs）在视觉领域中所做的一样。我们观察到，将其在语言领域的高性能转移到视觉领域面临的重大挑战可以通过两种模态之间的差异来解释。其中一个差异涉及规模。与语言 Transformer 中用作基本处理单元的词元不同，视觉元素在规模上可以有很大差异，这在目标检测等任务中引起了关注 [42, 53, 54]。在现有的基于 Transformer 的模型 [64, 20]中，词元的规模都是固定的，这一特性不适合这些视觉应用。另一个差异是图像中像素的分辨率远高于文本段落中的单词。有许多视觉任务，例如语义分割，需要在像素级别进行密集预测，这对于高分辨率图像上的 Transformer 来说是不可处理的，因为其自注意力的计算复杂度相对于图像大小是二次的。为了解决这些问题，我们提出了一种通用的 Transformer 主干网络，称为 Swin Transformer，它构建了分层特征图，并具有线性计算复杂度相对于图像大小。如图 1(a) 所示，Swin Transformer 通过从小尺寸块（灰色轮廓）开始，并在更深的 Transformer 层中逐渐合并相邻块来构建分层表示。通过这些分层特征图，Swin Transformer 模型可以方便地利用高级技术进行密集预测，例如特征金字塔网络（FPN） [42]或 U-Net [51]。线性计算复杂度是通过在划分图像的非重叠窗口内局部计算自注意力实现的（红色轮廓）。每个窗口中的块数量固定，因此复杂度变为线性于图像大小。这些优点使 Swin Transformer 适合作为各种视觉任务的通用主干网络，与以前基于 Transformer 的架构 [20]形成对比，后者生成单一分辨率的特征图并具有二次复杂度。

Swin Transformer 的一个关键设计元素是其在连续的自注意力层之间对窗口划分进行平移，如图 2所示。这种平移窗口连接了前一层的窗口，提供了它们之间的联系，显著增强了建模能力（见表 4）。从实际延迟的角度来看，这一策略也非常高效：在一个窗口内的所有查询补丁共享相同的键集。[1]，这有助于硬件中的内存访问。相比之下，早期基于滑动窗口的自注意力方法由于不同的查询像素有不同的键集，在通用硬件上存在低延迟问题 [33, 50]。[2]. 我们的实验表明，所提出

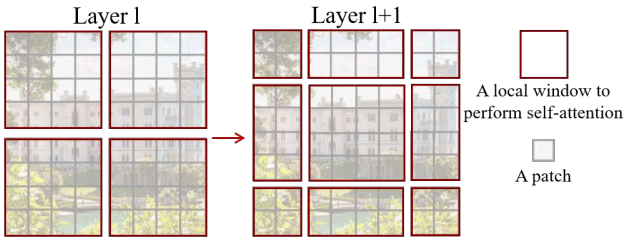

图 2. 一个关于所提出的 Swin Transformer 架构中计算自注意力的移位窗口方法的示意图。在第 l 层（左图），采用常规的窗口划分方案，在每个窗口内计算自注意力。在下一层次 $l+1$（右图），窗口划分发生了偏移，形成了新的窗口。在新窗口中的自注意力计算跨越了第 l 层中先前窗口的边界，从而在它们之间建立了联系。

的移位窗口方法比滑动窗口方法具有更低的延迟，但在建模能力上相似（参见表 5 和 6）。移位窗口方法也证明对全 MLP 架构有益 [61]。

提出的 Swin Transformer 在图像分类、目标检测和语义分割等识别任务上表现出色。它在三项任务中具有相似延迟的情况下，显著优于 ViT/DeiT [20, 63]和 ResNe(X)t 模型 [30, 70]。其在 COCO 测试开发集上的 58.7 箱 AP 和 51.1 掩码 AP 分别超过了前人工作的最佳结果 +2.7 箱 AP（Copy-paste [26]不使用外部数据）和 +2.6 掩码 AP（DetectoRS [46]）。在 ADE20K 语义分割任务中，它在验证集上获得了 53.5 mIoU，比之前的最优结果（SETR [81]）提高了 +3.2 mIoU。此外，在 ImageNet-1K 图像分类任务中，它达到了 87.3% 的 top-1 准确率。

我们相信，计算机视觉和自然语言处理领域的统一架构将使这两个领域都受益，因为它将促进视觉和文本信号的联合建模，并且可以从两个领域共享更多的建模知识。我们希望，Swin Transformer 在各种视觉问题上表现出的强大性能能让社区中的这种信念更加坚定，并鼓励视觉和语言信号的统一建模。

2. 相关工作

CNN 及其变体 CNNs 作为计算机视觉中的标准网络模型。尽管 CNN 已经存在了几十年 [40]，但直到 AlexNet [39]的引入，CNN 才开始流行并成为主流。从那时起，更深、更有效的卷积神经架构被提出，以进一步推动计算机视觉中的深度学习浪潮，例如

[1]查询和键是自注意力层中的投影向量。

[2]虽然在通用硬件上实现基于滑动窗口的卷积层有高效的方法，但由于其在特征图上具有共享的权重，基于滑动窗口的自注意力层在实际中很难进行高效的内存访问。

VGG [52]、GoogleNet [57]、ResNet [30]、DenseNet [34]、HRNet [65]和 EfficientNet [58]。除了这些架构上的进步，还有很多工作致力于改进单个卷积层，例如深度可分离卷积 [70]和可变形卷积 [18, 84]。尽管 CNN 及其变体仍然是计算机视觉应用的主要骨干架构，但我们强调了 Transformer 类架构在视觉和语言统一建模方面的强大潜力。我们的工作在几个基本的视觉识别任务上取得了强大的性能，并希望它能促成建模方向的转变。

基于自注意力的骨干架构 受自注意力层和 Transformer 架构在 NLP 领域的成功启发，一些工作采用自注意力层来替换流行的 ResNet [33, 50, 80]中的一些或全部空间卷积层。在这些工作中，自注意力在一个像素的局部窗口内计算以加速优化 [33]，并且它们比对应的 ResNet 架构实现了稍好的准确率/FLOPs 权衡。然而，其高昂的内存访问成本导致它们的实际延迟明显大于卷积网络 [33]。与使用滑动窗口不同，我们提出在连续的层之间移动窗口，这允许在通用硬件上实现更高效的实施。

自注意力/Transformers **以补充** CNN 另一种方法是用自注意力层或 Transformer 增强标准的 CNN 架构。自注意力层可以通过提供对远距离依赖关系或异质交互进行编码的能力来补充骨干网络 [67, 7, 3, 71, 23, 74, 55] 或头部网络 [32, 27]。最近，Transformer 的编码器-解码器设计已被应用于目标检测和实例分割任务 [8, 13, 85, 56]。我们的工作探索了 Transformer 在基本视觉特征提取中的适应性，并且与这些工作互补。

基于 Transformer 的视觉主干网络 与我们的工作最相关的当属 Vision Transformer (ViT) [20]及其后续研究 [63, 72, 15, 28, 66]。ViT 的开创性工作直接将 Transformer 架构应用于非重叠的中等尺寸图像块以进行图像分类。相比卷积网络，ViT 在图像分类上的速度-准确率权衡令人印象深刻。尽管 ViT 在大规模训练数据集（如 JFT-300M）下表现良好，但 DeiT [63]引入了几种训练策略，使 ViT 也能使用较小的 ImageNet-1K 数据集取得效果。ViT 在图像分类上的结果令人鼓舞，但由于其低分辨率特征图以及复杂度随图像大小呈二次增长，因此其架构不适合用作密集视觉任务或输入图像分辨率较高的通用骨干网络。有几项工作通过直接上采样或反卷积将 ViT 模型应用于目标检测和语义分割等密集视觉任务，但性能相对较低 [2, 81]。与我们工作同时进行的研究包括一些对 ViT 架构进行修改的工作 [72, 15, 28]，以提高图像分类性能。经验表明，即使我们的工作重点在于通用性能而非专门针对分类，我们的 Swin Transformer 架构在图像分类上的速度-准确率权衡仍优于这些方法中的大多数。另一项与我们工作同时进行的研究 [66] 探索了类似的思想，在 Transformer 上构建多分辨率特征图。其复杂度仍然与图像大小呈二次关系，而我们的复杂度是线性的，并且也是局部操作的，这已被证明在建模视觉信号中的高相关性方面有益 [36, 25, 41]。我们的方法既高效又有效，在 COCO 目标检测和 ADE20K 语义分割上均达到了最先进的准确率。

3. 方法

3.1. 总体架构

一个 Swin Transformer 架构的概述如图 3所示，其中展示了 tiny 版本（Swin-T）。它首先通过一个 patch 分割模块将输入的 RGB 图像分割成不重叠的小块，就像 ViT 一样。每个 patch 被视为一个“词元”，其特征被设置为原始像素 RGB 值的拼接。在我们的实现中，我们使用了 4×4 的 patch 大小，因此每个 patch 的特征维度是 $4 \times 4 \times 3 = 48$。然后在一个线性的嵌入层上应用这个原始值特征，将其投影到任意维度（表示为 C）。

几个带有修改的自注意力计算的 Transformer 块（Swin Transformer 块）应用于这些 patch 词元。Transformer 块保持词元数量不变（$\frac{H}{4} \times \frac{W}{4}$），与线性嵌入一起被称为“Stage 1”。

为了生成分层表示，随着网络变深，通过补丁合并层减少了词元的数量。第一个补丁合并层将每组 2×2 个相邻补丁的特征进行连结，并对 $4C$ -维连结后的特征应用一个线性层。这将词元数量按 $2 \times 2 = 4$ 倍减少（2× 分辨率下采样），输出维度设置为 $2C$ 。随后应用 Swin Transformer 块进行特征变换，分辨率保持为 $\frac{H}{8} \times \frac{W}{8}$ 。这个补丁合并和特征变换的第一块被标记为“Stage 2”。该过程重复两次，分别作为“Stage 3”和“Stage 4”，输出分辨率为 $\frac{H}{16} \times \frac{W}{16}$ 和 $\frac{H}{32} \times \frac{W}{32}$ 。这些阶

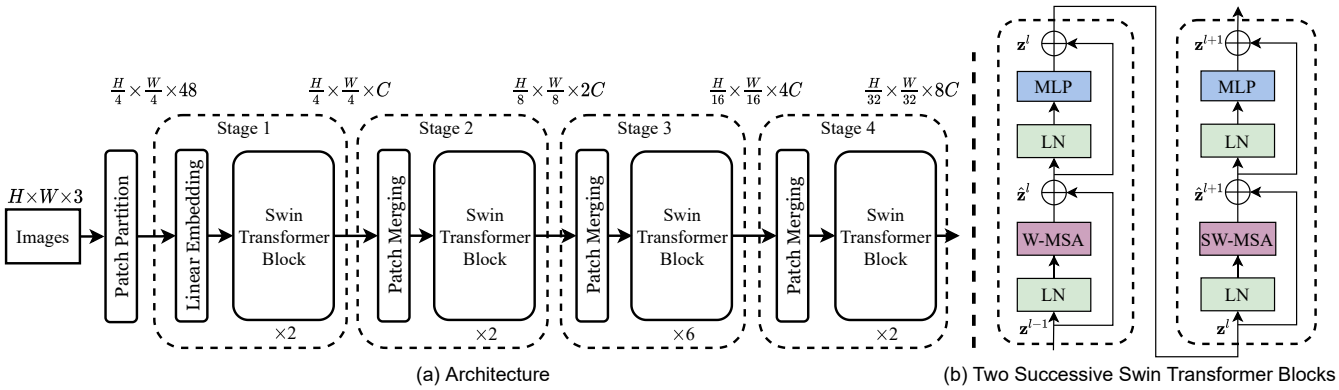

图 3. (a) Swin Transformer（Swin-T）的架构；(b) 两个连续的 Swin Transformer 块（符号见 Eq. (3)）。W-MSA 和 SW-MSA 分别是具有常规和移位窗口配置的多头自注意力模块。

段共同生成了分层表示，具有与典型卷积网络相同的特征图分辨率，例如 VGG [52] 和 ResNet [30]。因此，所提出的架构可以方便地替换现有视觉任务方法中的骨干网络。

Swin Transformer 块 Swin Transformer 通过用基于移位窗口的模块（详见第 3.2节）替换 Transformer 块中的标准多头自注意力（MSA）模块，其余层保持不变构建而成。如图 3(b) 所示，一个 Swin Transformer 块由基于移位窗口的 MSA 模块组成，后面跟着一个带有 GELU 非线性的 2 层 MLP。每个 MSA 模块和 MLP 之前都应用了一个 LayerNorm（LN）层，并且在每个模块之后应用了残差连接。

3.2. 基于滑动窗口的自注意力

标准 Transformer 架构 [64] 及其用于图像分类的适应版本 [20] 都执行全局自注意力，其中计算一个词元与其他所有词元之间的关系。全局计算相对于词元数量具有二次复杂度，这使得它不适合许多需要大量词元进行稠密预测或表示高分辨率图像的视觉问题。

非重叠窗口中的自注意力 为了高效的建模，我们建议在局部窗口内计算自注意力。这些窗口被排列为以非重叠的方式均匀划分图像。假设每个窗口包含 $M\times M$ 个补丁，全局 MSA 模块和基于窗口的模块在一个包含 $h\times w$ 个补丁的图像上的计算复杂度分别为[3]:

$$\Omega(\text{MSA}) = 4hwC^2 + 2(hw)^2C, \tag{1}$$

$$\Omega(\text{W-MSA}) = 4hwC^2 + 2M^2hwC, \tag{2}$$

其中前者与补丁编号 hw 二次相关，后者在固定 M 时是线性的（默认设置为 7 ）。全局自注意力计算对于较大的 hw 通常是负担不起的，而基于窗口的自注意力是可扩展的。

连续块中的移位窗口划分 基于窗口的自注意力模块在窗口之间缺乏连接，这限制了其建模能力。为了在保持非重叠窗口高效计算的同时引入跨窗口连接，我们提出了一种移位窗口划分方法，在连续的 Swin Transformer 块中交替使用两种划分配置。

如图 2 所示，第一模块采用从左上角像素开始的常规窗口划分策略，8×8 特征图被均匀划分为 2×2 个大小为 4×4 ($M=4$) 的窗口。然后，下一模块采用的窗口配置相对于前一层的窗口配置进行了位移，窗口从规则划分的窗口位置向右和向下偏移了 $(\lfloor\frac{M}{2}\rfloor, \lfloor\frac{M}{2}\rfloor)$ 像素。

通过移位窗口划分方法，连续的 Swin Transformer 块的计算为

$$\begin{aligned}
\hat{\mathrm{z}}^l &= \text{W-MSA}\left(\text{LN}\left(\mathrm{z}^{l-1}\right)\right) + \mathrm{z}^{l-1}, \\
\mathrm{z}^l &= \text{MLP}\left(\text{LN}\left(\hat{\mathrm{z}}^l\right)\right) + \hat{\mathrm{z}}^l, \\
\hat{\mathrm{z}}^{l+1} &= \text{SW-MSA}\left(\text{LN}\left(\mathrm{z}^l\right)\right) + \mathrm{z}^l, \\
\mathrm{z}^{l+1} &= \text{MLP}\left(\text{LN}\left(\hat{\mathrm{z}}^{l+1}\right)\right) + \hat{\mathrm{z}}^{l+1},
\end{aligned} \tag{3}$$

[3]在确定复杂性时，我们省略了 SoftMax 计算。

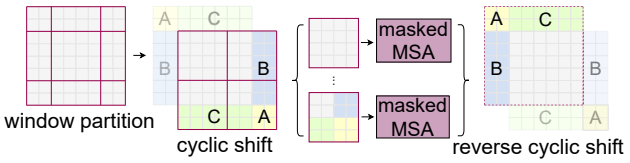

图 4. 在移位窗口划分中高效计算批量自注意力的方法示意图。

其中 $\hat{z}^l$ 和 z^l 分别表示（S）W-MSA 模块和 MLP 模块的输出特征，对应于块 l；W-MSA 和 SW-MSA 分别表示基于窗口的多头自注意力，使用常规和移位窗口划分配置。

移位窗口划分方法在前一层引入了相邻非重叠窗口之间的连接，并被发现对图像分类、对象检测和语义分割有效，如表 4 所示。

高效批量计算的偏移配置 偏移划分的问题在于它将导致更多的窗口，在偏移配置中从 $\lceil \frac{h}{M} \rceil \times \lceil \frac{w}{M} \rceil$ 到 $(\lceil \frac{h}{M} \rceil + 1) \times (\lceil \frac{w}{M} \rceil + 1)$，并且一些窗口将小于 $M \times M$。[4]. 一个天真的解决方案是在较小的窗口大小上填充到 $M \times M$ 并在计算注意力时屏蔽填充值。当规则划分中的窗口数量较少时，例如 2×2 ，这种天真方法的计算开销相当大（$2 \times 2 \rightarrow 3 \times 3$ ，是原来的 2.25 倍）。在这里，我们通过向左上角循环移位提出了一种更高效的批量计算方法，如图 4 所示。经过此移位后，一个批量窗口可能由几个在特征图中不相邻的子窗口组成，因此采用屏蔽机制来限制自注意力计算在每个子窗口内部进行。通过循环移位，批量窗口的数量与常规窗口划分相同，因此同样高效。该方法的低延迟见表 5。

相对位置偏置 在计算自注意力时，我们通过在每个头计算相似度时加入相对位置偏置 [49, 1, 32, 33]$B \in \mathbb{R}^{M^2 \times M^2}$ 来遵循 [49, 1, 32, 33]：

$$\text{Attention}(Q, K, V) = \text{SoftMax}(QK^T/\sqrt{d} + B)V, \quad (4)$$

其中 $Q, K, V \in \mathbb{R}^{M^2 \times d}$ 是 查询、键和 值矩阵；d 是 查询/键维度，M^2 是窗口中的补丁数量。由于沿每个轴的相对位置在范围 $[-M+1, M-1]$ 内，我们参数化了一个较小尺寸的偏置矩阵 $\hat{B} \in \mathbb{R}^{(2M-1) \times (2M-1)}$ ，B 中的值来自 $\hat{B}$ 。

[4]为了使窗口大小 (M, M) 可以被 (h, w) 的特征图大小整除，如果需要的话，在特征图的右下角使用填充。

我们观察到，与没有这个偏置项或使用绝对位置嵌入的对应方法相比，有显著的改进，如表 4 所示。进一步像 [20] 中那样在输入中添加绝对位置嵌入会略微降低性能，因此在我们的实现中未采用这种方法。

在预训练中学到的相对位置偏差也可以通过双三次插值 [20, 63] 初始化模型以不同的窗口大小进行微调。

3.3. 架构变体

我们构建了我们的基础模型，称为 Swin-B，其模型大小和计算复杂度与 ViT-B/DeiT-B 相似。我们还引入了 Swin-T、Swin-S 和 Swin-L，它们的模型大小和计算复杂度分别约为 0.25×、0.5× 和 2×。注意，Swin-T 和 Swin-S 的复杂度分别与 ResNet-50（DeiT-S）和 ResNet-101 相似。窗口大小默认设置为 $M = 7$。每个头的查询维度为 $d = 32$，每个多层感知机的扩展层为 $\alpha = 4$，适用于所有实验。这些模型变体的架构超参数如下：

- Swin-T: $C = 96$ ，层数量 $= \{2, 2, 6, 2\}$
- Swin-S: $C = 96$ ，层的数量 $=\{2, 2, 18, 2\}$
- Swin-B: $C = 128$ ，层的数量 $=\{2, 2, 18, 2\}$
- Swin-L: $C = 192$ ，层的数量 $=\{2, 2, 18, 2\}$

其中 C 是第一阶段隐藏层的通道数。表 1 列出了用于 ImageNet 图像分类的模型变体的模型大小、理论计算复杂度（FLOPs）和吞吐量。

4. 实验

我们在 ImageNet-1K 图像分类 [19]、COCO 目标检测 [43] 和 ADE20K 语义分割 [83] 上进行实验。在下面的内容中，我们首先将提出的 Swin Transformer 架构与这三个任务上的先前最佳方法进行比较。然后，我们分析 Swin Transformer 的重要设计元素。

4.1. ImageNet-1K 上的图像分类

情景 对于图像分类，我们在 ImageNet-1K [19]上评估所提出的 Swin Transformer，ImageNet-1K 包含来自 1,000 个类别的 1.28M 训练图像和 50K 验证图像。报告单裁剪的 top-1 准确率。我们考虑两种训练情景：

- 常规 ImageNet-1K 训练. 此情景主要遵循 [63]。我们使用 AdamW [37]优化器进行 300 轮次训练，采用余弦衰减学习率调度器，并进行 20 轮次的线性预热。批量大小为 1024，初始学习率为 0.001，权重衰减为 0.05。我们在训练中包含 [63]中的大多数增强和正则化策略，但不包括重复增强 [31]和 EMA [45]，因为它们未提升性能。请注意，这与 [63]相反，在 ViT 的训练中重复增强至关重要以稳定训练。

- 在 ImageNet-22K 上预训练并在 ImageNet-1K 上微调。我们还在更大的 ImageNet-22K 数据集上进行预训练，该数据集包含 1420 万张图像和 22K 个类别。我们使用 AdamW 优化器进行 90 轮次的训练，采用线性衰减的学习率调度程序，并在前 5 个轮次中使用线性热身。批量大小为 4096，初始学习率为 0.001，权重衰减为 0.01。在 ImageNet-1K 微调中，我们以批量大小 1024、恒定学习率 10^{-5} 和权重衰减 10^{-8} 训练模型 30 轮次。

使用常规 ImageNet-1K 训练的结果 表 1(a) 展示了与其他骨干网络的比较，包括基于 Transformer 和基于 ConvNet 的，使用常规 ImageNet-1K 训练。

相比之前最先进的基于 Transformer 的架构，即 DeiT [63]，Swin Transformer 在相似复杂度下明显超越对应的 DeiT 架构：使用 224^2 输入时，Swin-T (81.3%) 比 DeiT-S (79.8%) 高出 +1.5%；使用 224^2 /384^2 输入时，Swin-B (83.3%/84.5%) 分别比 DeiT-B (81.8%/83.1%) 高出 +1.5%/1.4%。

与最先进的 ConvNets 相比，即 RegNet [48]和 EfficientNet [58]，Swin Transformer 在速度-准确率权衡上略胜一筹。需要注意的是，尽管 RegNet [48]和 EfficientNet [58]是通过全面的架构搜索获得的，提出的 Swin Transformer 是从标准 Transformer 改编而来的，并且具有进一步改进的强大潜力。

使用 ImageNet-22K 预训练的结果 我们还在 ImageNet-22K 上对更大容量的 Swin-B 和 Swin-L 进行了预训练。在 ImageNet-1K 图像分类任务上微调后的结果如表 1(b) 所示。对于 Swin-B，ImageNet-22K 的预训练相比从头开始在 ImageNet-1K 上训练带来了 1.8%～ 1.9% 的提升。与之前 ImageNet-22K 预训练的最佳结果相比，我们的模型在速度-准确率权衡方面取得了显著更好的表现：Swin-B 获得了 86.4% 的 top-1 准确率，比具有相似推理吞吐量 (84.7 vs. 85.9 张/秒) 的 ViT 高 2.4%，且 FLOPs 略低 (47.0G vs. 55.4G)。更大的 Swin-L 模型达到了 87.3% 的 top-1 准确率，比 Swin-B 模型高 0.9%。

(a) Regular ImageNet-1K trained models

method	image size	#param.	FLOPs	throughput (image / s)	ImageNet top-1 acc.
RegNetY-4G [48]	224^2	21M	4.0G	1156.7	80.0
RegNetY-8G [48]	224^2	39M	8.0G	591.6	81.7
RegNetY-16G [48]	224^2	84M	16.0G	334.7	82.9
EffNet-B3 [58]	300^2	12M	1.8G	732.1	81.6
EffNet-B4 [58]	380^2	19M	4.2G	349.4	82.9
EffNet-B5 [58]	456^2	30M	9.9G	169.1	83.6
EffNet-B6 [58]	528^2	43M	19.0G	96.9	84.0
EffNet-B7 [58]	600^2	66M	37.0G	55.1	84.3
ViT-B/16 [20]	384^2	86M	55.4G	85.9	77.9
ViT-L/16 [20]	384^2	307M	190.7G	27.3	76.5
DeiT-S [63]	224^2	22M	4.6G	940.4	79.8
DeiT-B [63]	224^2	86M	17.5G	292.3	81.8
DeiT-B [63]	384^2	86M	55.4G	85.9	83.1
Swin-T	224^2	29M	4.5G	755.2	81.3
Swin-S	224^2	50M	8.7G	436.9	83.0
Swin-B	224^2	88M	15.4G	278.1	83.5
Swin-B	384^2	88M	47.0G	84.7	84.5

(b) ImageNet-22K pre-trained models

method	image size	#param.	FLOPs	throughput (image / s)	ImageNet top-1 acc.
R-101x3 [38]	384^2	388M	204.6G	-	84.4
R-152x4 [38]	480^2	937M	840.5G	-	85.4
ViT-B/16 [20]	384^2	86M	55.4G	85.9	84.0
ViT-L/16 [20]	384^2	307M	190.7G	27.3	85.2
Swin-B	224^2	88M	15.4G	278.1	85.2
Swin-B	384^2	88M	47.0G	84.7	86.4
Swin-L	384^2	197M	103.9G	42.1	87.3

表 1. 在 ImageNet-1K 分类上的不同 backbone 的比较。吞吐量使用 [68] 的 GitHub 仓库和 V100 GPU 进行测量，遵循 [63]。

4.2. COCO 上的目标检测

情景 在 COCO 2017 数据集上进行目标检测和实例分割实验，该数据集包含 11.8 万张训练图像、5000 张

验证图像和 2 万张测试开发图像。使用验证集进行消融实验，并在测试开发集上进行系统级比较。对于消融实验，我们考虑四种典型的目标检测框架：Cascade Mask R-CNN [29, 6]、ATSS [79]、RepPoints v2 [12]和 Sparse RCNN [56]（在 mmdetection [10]中）。对于这四种框架，我们采用相同的设置：多尺度训练 [8, 56]（调整输入大小，使较短边在 480 到 800 之间，较长边最多为 1333）、AdamW [44]优化器（初始学习率为 0.0001，权重衰减为 0.05，批量大小为 16）和 3x 训练计划（36 轮次）。对于系统级比较，我们采用改进的 HTC [9]（记为 HTC++），并结合 instaboost [22]、更强的多尺度训练 [7]、6x 训练计划（72 轮次）、soft-NMS [5]以及使用 ImageNet - 22K 预训练模型进行初始化。

我们将我们的 Swin Transformer 与标准 ConvNets（即 ResNe(X)t）和之前的 Transformer 网络（例如 DeiT）进行比较。通过仅改变主干网络，而其他设置保持不变来进行这些比较。请注意，由于 Swin Transformer 和 ResNe(X)t 具有分层特征图，因此它们可以直接应用于上述所有框架，而 DeiT 只生成单一分辨率的特征图，不能直接应用。为了公平比较，我们按照 [81]使用反卷积层为 DeiT 构建分层特征图。

与 ResNe(X)t 的比较 表 2(a) 列出了 Swin-T 和 ResNet-50 在四种目标检测框架上的结果。我们的 Swin-T 架构在 ResNet-50 的基础上带来了 +3.4∼ 4.2 的 box AP 一致提升，但模型大小、FLOPs 和延迟略大。

表 2(b) 比较了在不同模型容量下使用 Cascade Mask R-CNN 的 Swin Transformer 和 ResNe(X)t。Swin Transformer 达到了较高的检测准确率，box AP 为 51.9，mask AP 为 45.0，相比具有相似模型大小、FLOPs 和延迟的 ResNeXt101-64x4d，分别提高了 +3.6 box AP 和 +3.3 mask AP。在更高的基准上，即使用改进的 HTC 框架时，box AP 为 52.3，mask AP 为 46.0，Swin Transformer 的增益仍然显著，分别为 +4.1 box AP 和 +3.1 mask AP（见表 2(c)）。关于推理速度，在 ResNe(X)t 中构建了高度优化的 Cudnn 函数，而我们的架构是用内置的 PyTorch 函数实现的，这些函数并非全部都经过了良好的优化。彻底的内核优化超出了本文的研究范围。

(a) Various frameworks

Method	Backbone	AP^{box}	AP^{box}_{50}	AP^{box}_{75}	#param.	FLOPs	FPS
Cascade Mask R-CNN	R-50	46.3	64.3	50.5	82M	739G	18.0
	Swin-T	50.5	69.3	54.9	86M	745G	15.3
ATSS	R-50	43.5	61.9	47.0	32M	205G	28.3
	Swin-T	47.2	66.5	51.3	36M	215G	22.3
RepPointsV2	R-50	46.5	64.6	50.3	42M	274G	13.6
	Swin-T	50.0	68.5	54.2	45M	283G	12.0
Sparse R-CNN	R-50	44.5	63.4	48.2	106M	166G	21.0
	Swin-T	47.9	67.3	52.3	110M	172G	18.4

(b) Various backbones w. Cascade Mask R-CNN

	AP^{box}	AP^{box}_{50}	AP^{box}_{75}	AP^{mask}	AP^{mask}_{50}	AP^{mask}_{75}	param	FLOPs	FPS
DeiT-S†	48.0	67.2	51.7	41.4	64.2	44.3	80M	889G	10.4
R50	46.3	64.3	50.5	40.1	61.7	43.4	82M	739G	18.0
Swin-T	50.5	69.3	54.9	43.7	66.6	47.1	86M	745G	15.3
X101-32	48.1	66.5	52.4	41.6	63.9	45.2	101M	819G	12.8
Swin-S	51.8	70.4	56.3	44.7	67.9	48.5	107M	838G	12.0
X101-64	48.3	66.4	52.3	41.7	64.0	45.1	140M	972G	10.4
Swin-B	51.9	70.9	56.5	45.0	68.4	48.7	145M	982G	11.6

(c) System-level Comparison

Method	mini-val		test-dev		#param.	FLOPs
	AP^{box}	AP^{mask}	AP^{box}	AP^{mask}		
RepPointsV2* [12]	-	-	52.1	-	-	-
GCNet* [7]	51.8	44.7	52.3	45.4	-	1041G
RelationNet++* [13]	-	-	52.7	-	-	-
SpineNet-190 [21]	52.6	-	52.8	-	164M	1885G
ResNeSt-200* [78]	52.5	-	53.3	47.1	-	-
EfficientDet-D7 [59]	54.4	-	55.1	-	77M	410G
DetectoRS* [46]	-	-	55.7	48.5	-	-
YOLOv4 P7* [4]	-	-	55.8	-	-	-
Copy-paste [26]	55.9	47.2	56.0	47.4	185M	1440G
X101-64 (HTC++)	52.3	46.0	-	-	155M	1033G
Swin-B (HTC++)	56.4	49.1	-	-	160M	1043G
Swin-L (HTC++)	57.1	49.5	57.7	50.2	284M	1470G
Swin-L (HTC++)*	58.0	50.4	58.7	51.1	284M	-

表 2. COCO 数据集上的目标检测和实例分割结果。† 表示使用了额外的反卷积层来生成分层特征图。* 表示多尺度测试。

与 DeiT 的比较 表格 2(b) 展示了使用级联掩码 R-CNN 框架的 DeiT-S 的表现。Swin-T 的结果比 DeiT-S 在箱体 AP 上高出 +2.5，掩码 AP 上高出 +2.3，同时具有相似的模型大小（86M 对 80M）和显著更高的推理速度（15.3 FPS 对 10.4 FPS）。DeiT 较低的推理速

ADE20K Method	Backbone	val mIoU	test score	#param.	FLOPs	FPS
DANet [23]	ResNet-101	45.2	-	69M	1119G	15.2
DLab.v3+ [11]	ResNet-101	44.1	-	63M	1021G	16.0
ACNet [24]	ResNet-101	45.9	38.5	-		
DNL [71]	ResNet-101	46.0	56.2	69M	1249G	14.8
OCRNet [73]	ResNet-101	45.3	56.0	56M	923G	19.3
UperNet [69]	ResNet-101	44.9	-	86M	1029G	20.1
OCRNet [73]	HRNet-w48	45.7	-	71M	664G	12.5
DLab.v3+ [11]	ResNeSt-101	46.9	55.1	66M	1051G	11.9
DLab.v3+ [11]	ResNeSt-200	48.4	-	88M	1381G	8.1
SETR [81]	T-Large‡	50.3	61.7	308M	-	-
UperNet	DeiT-S†	44.0	-	52M	1099G	16.2
UperNet	Swin-T	46.1	-	60M	945G	18.5
UperNet	Swin-S	49.3	-	81M	1038G	15.2
UperNet	Swin-B‡	51.6	-	121M	1841G	8.7
UperNet	Swin-L‡	53.5	62.8	234M	3230G	6.2

表 3. 语义分割在 ADE20K 验证集和测试集上的结果。† 表示使用额外的反卷积层来生成分层特征图。‡ 表示该模型在 ImageNet-22K 上进行了预训练。

	ImageNet top-1	ImageNet top-5	COCO AP^{box}	COCO AP^{mask}	ADE20k mIoU
w/o shifting	80.2	95.1	47.7	41.5	43.3
shifted windows	81.3	95.6	50.5	43.7	46.1
no pos.	80.1	94.9	49.2	42.6	43.8
abs. pos.	80.5	95.2	49.0	42.4	43.2
abs.+rel. pos.	81.3	95.6	50.2	43.4	44.0
rel. pos. w/o app.	79.3	94.7	48.2	41.9	44.1
rel. pos.	81.3	95.6	50.5	43.7	46.1

表 4. 消融研究关于 shifted windows 方法和三种基准上的不同位置嵌入方法，使用 Swin-T 架构。无 shift：所有自注意力模块采用常规窗口划分，没有 shift；abs.pos.：ViT 的绝对位置嵌入项；rel.pos.：默认设置外加相对位置偏置项（见 Eq. (4)）；app.：Eq. (4) 中的第一个缩放点积项。

度主要是由于其对输入图像大小的二次复杂度依赖。

与先前最先进的模型比较 表 2(c) 将我们最佳结果与先前最先进的模型的结果进行了比较。我们的最佳模型在 COCO test-dev 上达到了 58.7 的 box AP 和 51.1 的 mask AP，超过了先前的最佳结果 +2.7 的 box AP（Copy-paste [26]不使用外部数据）和 +2.6 的 mask AP（DetectoRS [46]）。

4.3. ADE20K 数据集上的语义分割

情景 ADE20K [83] 是一个广泛使用的语义分割数据集，涵盖了 150 个语义类别。它总共有 25K 张图像，其中 20K 用于训练，2K 用于验证，另外 3K 用于测试。我们利用 mmseg [16] 中的 UperNet [69] 作为我们的基础框架，因为它具有很高的效率。更多细节见附录。

结果 表 3 列出了不同方法/主干组合的 mIoU、模型大小（# 参数）、FLOPs 和 FPS。从这些结果可以看出，Swin-S 比 DeiT-S 在相似的计算代价下高出 +5.3 mIoU（49.3 对 44.0）。它也比 ResNet-101 高 +4.4 mIoU，比 ResNeSt-101 [78]高 +2.4 mIoU。我们的 Swin-L 模型使用 ImageNet-22K 进行预训练，在验证集上达到了 53.5 mIoU，超过了之前的最佳模型 +3.2 mIoU（SETR [81]为 50.3 mIoU，其模型大小更大）。

4.4. 消融研究

在本节中，我们通过使用 ImageNet-1K 图像分类、COCO 目标检测的级联 Mask R-CNN 以及 ADE20K 语义分割的 UperNet 来研究所提出的 Swin Transformer 中的重要设计元素。

Shifted windows 表 4 中报告了对三种任务的 shifted window 方法的消融研究。在每个阶段，使用 shifted window 划分的 Swin-T 在 ImageNet-1K 上比基于单一窗口划分的模型高出 1.1% 的 top-1 准确率，在 COCO 上高出 2.8 box AP/2.2 mask AP，在 ADE20K 上高出 2.8 mIoU。这些结果表明使用 shifted windows 在前几层中建立窗口之间的连接的有效性。如表 5 所示，shifted window 的延迟开销也很小。

相对位置偏置 表 4 显示了不同位置嵌入方法的比较。带有相对位置偏置的 Swin-T 在 ImageNet-1K 上 top-1 准确率提高了 +1.2%/+0.8%，在 COCO 数据集上 box AP 提高了 +1.3/+1.5，mask AP 提高了 +1.1/+1.3，在 ADE20K 上 mIoU 提高了 +2.3/+2.9，相对于没有位置编码和使用绝对位置嵌入的情况，表明了相对位置偏置的有效性。同时请注意，虽然包含绝对位置嵌入可以提高图像分类的准确性（+0.4%），但它会损害目标检测和语义分割（在 COCO 上 box/mask AP 降低

method	MSA in a stage (ms)				Arch. (FPS)		
	S1	S2	S3	S4	T	S	B
sliding window (naive)	122.5	38.3	12.1	7.6	183	109	77
sliding window (kernel)	7.6	4.7	2.7	1.8	488	283	187
Performer [14]	4.8	2.8	1.8	1.5	638	370	241
window (w/o shifting)	2.8	1.7	1.2	0.9	770	444	280
shifted window (padding)	3.3	2.3	1.9	2.2	670	371	236
shifted window (cyclic)	3.0	1.9	1.3	1.0	755	437	278

表 5. 在 V100 GPU 上不同自注意力计算方法和实现的实际速度。

了-0.2，在 ADE20K 上 mIoU 降低了-0.6）。

虽然最近的 ViT/DeiT 模型在图像分类中放弃了平移不变性，尽管早已证明其对视觉建模至关重要，但我们发现，鼓励某种平移不变性的归纳偏置对于通用视觉建模仍然更可取，特别是在目标检测和语义分割等稠密预测任务中。

不同的自注意力方法 表格 5 比较了不同自注意力计算方法和实现的实际速度。我们的循环实现比简单的填充在更深的阶段更具硬件效率。总体而言，它分别在 Swin-T、Swin-S 和 Swin-B 上带来了 13%、18% 和 18% 的加速。

所提出的*移位窗口*方法构建的自注意力模块分别比*滑动窗口*在四个网络阶段的朴素/核实现效率高 40.8× /2.5× ，20.2× /2.5× ，9.3× /2.1× ，和 7.6× /1.8× 。总体而言，基于*移位窗口*的 Swin Transformer 架构分别比基于*滑动窗口*的 Swin-T、Swin-S 和 Swin-B 变体快 4.1/1.5、4.0/1.5 和 3.6/1.5 倍。表 6 比较了它们在三个任务上的准确率，表明它们在视觉建模方面具有相似的准确性。

与 Performer [14]相比，Performer 是一种最快的 Transformer 架构（见 [60]），所提出的基于“移位窗口”的自注意力计算以及整体 Swin Transformer 架构略快（见表 5），同时在 ImageNet-1K 上使用 Swin-T 实现了比 Performer 高 +2.3% 的 top-1 准确率（见表 6）。

5. 结论

本文介绍了 Swin Transformer，这是一种新的视觉 Transformer，它生成分层特征表示，并且其计算复杂度与输入图像大小呈线性关系。Swin Transformer 在 COCO 目标检测和 ADE20K 语义分割上达到了最先进的性能，显著超过了之前的最佳方法。我们希望 Swin Transformer 在各种视觉问题上的强大性能将鼓励视觉和语言信号的统一建模。

	Backbone	ImageNet		COCO		ADE20k
		top-1	top-5	AP^{box}	AP^{mask}	mIoU
sliding window	Swin-T	81.4	95.6	50.2	43.5	45.8
Performer [14]	Swin-T	79.0	94.2	-	-	-
shifted window	Swin-T	81.3	95.6	50.5	43.7	46.1

表 6. 在三个基准上使用不同方法进行自注意力计算的 Swin Transformer 的准确率。

作为 Swin Transformer 的关键组成部分，基于*移位窗口*的自注意力在视觉问题上被证明是有效且高效的，我们期待进一步研究其在自然语言处理中的应用。

致谢

我们要感谢微软公司的许多同事提供的帮助，尤其是李栋和韦福如的有益讨论；以及肖斌、袁路和张磊在数据集方面提供的帮助。

A1. 详细架构

详细的架构规格显示在表 7 中，其中假设所有架构的输入图像大小为 224× 224。“Concat $n \times n$ ”表示在图像块中连接 $n \times n$ 临近的特征。此操作通过 n 的比率对特征图进行下采样。“96-d” 表示输出维度为 96 的线性层。“win. sz. 7×7 ”表示窗口大小为 7×7 的多头自注意力模块。

A2. 详细实验情景

A2.1. ImageNet-1K 上的图像分类

图像分类通过在最后一阶段的输出特征图上应用全局平均池化层来实现，然后接一个线性分类器。我们发现这种方法与使用额外的 class 词元（如 ViT [20]和 DeiT [63]中所用）一样准确。在评估时，报告单个裁剪的 top-1 准确率。

常规 ImageNet-1K 训练 训练设置大多遵循 [63]。对于所有模型变体，我们采用默认输入图像分辨率为 224^2。对于其他分辨率如 384^2，我们对在 224^2 分辨率下训练的模型进行微调，而不是从头开始训练，以减少 GPU 消耗。

	downsp. rate (output size)	Swin-T	Swin-S	Swin-B	Swin-L
stage 1	4× (56×56)	concat 4×4, 96-d, LN	concat 4×4, 96-d, LN	concat 4×4, 128-d, LN	concat 4×4, 192-d, LN
		[win. sz. 7×7, dim 96, head 3] × 2	[win. sz. 7×7, dim 96, head 3] × 2	[win. sz. 7×7, dim 128, head 4] × 2	[win. sz. 7×7, dim 192, head 6] × 2
stage 2	8× (28×28)	concat 2×2, 192-d , LN	concat 2×2, 192-d , LN	concat 2×2, 256-d , LN	concat 2×2, 384-d , LN
		[win. sz. 7×7, dim 192, head 6] × 2	[win. sz. 7×7, dim 192, head 6] × 2	[win. sz. 7×7, dim 256, head 8] × 2	[win. sz. 7×7, dim 384, head 12] × 2
stage 3	16× (14×14)	concat 2×2, 384-d , LN	concat 2×2, 384-d , LN	concat 2×2, 512-d , LN	concat 2×2, 768-d , LN
		[win. sz. 7×7, dim 384, head 12] × 6	[win. sz. 7×7, dim 384, head 12] × 18	[win. sz. 7×7, dim 512, head 16] × 18	[win. sz. 7×7, dim 768, head 24] × 18
stage 4	32× (7×7)	concat 2×2, 768-d , LN	concat 2×2, 768-d , LN	concat 2×2, 1024-d , LN	concat 2×2, 1536-d , LN
		[win. sz. 7×7, dim 768, head 24] × 2	[win. sz. 7×7, dim 768, head 24] × 2	[win. sz. 7×7, dim 1024, head 32] × 2	[win. sz. 7×7, dim 1536, head 48] × 2

表 7. 详细的架构规范。

当使用 224^2 输入从头开始训练时，我们采用 AdamW [37]优化器进行 300 个轮次的训练，使用带有 20 个轮次线性热身的余弦衰减学习率调度器。使用 1024 的批量大小、0.001 的初始学习率、0.05 的权重衰减以及最大范数为 1 的梯度裁剪。我们在训练中纳入了 [63]的大部分增强和正则化策略，包括随机增强（RandAugment）[17]、混合增强（Mixup）[77]、切块混合增强（Cutmix）[75]、随机擦除（random erasing）[82]和随机深度（stochastic depth）[35]，但不包括重复增强（repeated augmentation）[31]和指数移动平均（Exponential Moving Average，EMA）[45]，因为它们不会提高性能。请注意，这与 [63]相反，在 [63]中重复增强对于稳定 ViT 的训练至关重要。对于更大的模型，即分别针对 Swin-T、Swin-S 和 Swin-B 0.2, 0.3, 0.5，采用了逐渐增加程度的随机深度增强。

对于输入分辨率更大时的微调，我们使用 adamW [37] 优化器进行 30 轮次训练，学习率为常数 10^{-5} ，权重衰减为 10^{-8} ，并且与第一阶段相同的数据增强和正则化方法，但将随机深度比率设置为 0.1。

ImageNet-22K **预训练** 我们还在更大的 ImageNet-22K 数据集上进行预训练，该数据集包含 1420 万张图像和 22K 类别。训练分两个阶段进行。对于第一阶段的 224^2 输入，我们使用 AdamW 优化器进行 90 轮训练，采用线性衰减学习率调度程序，并在前 5 轮中使用线性热身。批量大小为 4096，初始学习率为 0.001，权重衰减为 0.01。在第二阶段的 ImageNet-1K 微调（224^2 /384^2 输入）中，我们将模型训练 30 轮，批量大小为 1024，恒定学习率为 10^{-5} ，权重衰减为 10^{-8} 。

A2.2. COCO 上的目标检测

在消融实验中，我们考虑四种典型的目标检测框架：级联掩码 R-CNN [29, 6]、ATSS [79]、RepPoints v2 [12] 和稀疏 RCNN [56]，这些框架均来自 mmdetection [10]。对于这四种框架，我们采用相同的情景设置：多尺度训练 [8, 56]（调整输入大小，使较短边在 480 到 800 之间，较长边最多为 1333），AdamW [44] 优化器（初始学习率为 0.0001，权重衰减为 0.05，批量大小为 16），以及 3x 训练计划（36 轮次训练，在第 27 和 33 轮次时学习率衰减 10×）。

对于系统级比较，我们采用了一种改进的 HTC [9]（记为 HTC++），它带有 instaboost [22]、更强的多尺度训练 [7]（调整输入使得较短边在 400 到 1400 之间且较长边不超过 1600）、6x 计划（72 轮次，学习率在第 63 和 69 轮次通过因子 0.1 进行学习率衰减）、soft-NMS [5]，并在最后一阶段输出后添加了一个全局自注意力层，以及使用 ImageNet-22K 预训练模型作为初始化。我们对所有 Swin Transformer 模型采用了深度率为 0.2 的随机深度。

	Swin-T		Swin-S		Swin-B	
input size	top-1 acc	throughput (image / s)	top-1 acc	throughput (image / s)	top-1 acc	throughput (image / s)
224^2	81.3	755.2	83.0	436.9	83.3	278.1
256^2	81.6	580.9	83.4	336.7	83.7	208.1
320^2	82.1	342.0	83.7	198.2	84.0	132.0
384^2	82.2	219.5	83.9	127.6	84.5	84.7

表 8. 在 ImageNet-1K 分类中使用不同输入图像大小的 Swin Transformer。

Backbone	Optimizer	AP^{box}	AP^{box}_{50}	AP^{box}_{75}	AP^{mask}	AP^{mask}_{50}	AP^{mask}_{75}
R50	SGD	45.0	62.9	48.8	38.5	59.9	41.4
	AdamW	46.3	64.3	50.5	40.1	61.7	43.4
X101-32x4d	SGD	47.8	65.9	51.9	40.4	62.9	43.5
	AdamW	48.1	66.5	52.4	41.6	63.9	45.2
X101-64x4d	SGD	48.8	66.9	53.0	41.4	63.9	44.7
	AdamW	48.3	66.4	52.3	41.7	64.0	45.1

表 9. 在 COCO 目标检测任务中，使用 Cascade Mask R-CNN 框架，比较 SGD 和 AdamW 优化器在 ResNe(X)t 主干网络上的性能。

A2.3. ADE20K 数据集上的语义分割

ADE20K [83] 是一个广泛使用的语义分割数据集，涵盖 150 个语义类别。它总共有 25K 张图像，其中 20K 用于训练，2K 用于验证，另外 3K 用于测试。我们利用 mmsegmentation [16] 中的 UperNet [69] 作为我们的基础框架，因为它具有高效率。

在训练过程中，我们采用 AdamW [44] 优化器，初始学习率为 6×10^{-5} ，权重衰减为 0.01，使用线性学习率衰减调度器，并进行 1500 次迭代的线性预热。模型在 8 块 GPU 上进行训练，每块 GPU 处理 2 张图像，共进行 160K 次迭代。对于数据增强，我们采用 mmsegmentation 中的默认情景，包括随机水平翻转、在比例值域 [0.5, 2.0] 内随机缩放以及随机光度失真。所有 Swin Transformer 模型都应用比率为 0.2 的随机深度变换。Swin - T、Swin - S 在与之前方法相同的标准情景下进行训练，输入尺寸为 512× 512。带有 ‡ 的 Swin - B 和 Swin - L 表明这两个模型在 ImageNet - 22K 上进行了预训练，并以 640× 640 的输入尺寸进行训练。

在推理阶段，采用多尺度测试，使用的分辨率为训练时分辨率的 [0.5, 0.75, 1.0, 1.25, 1.5, 1.75]× 。在报告测试得分时，按照常见做法，训练图像和验证图像都用于训练 [71] 。

A3. 更多实验

A3.1. 不同输入大小的图像分类

表格 8 列出了具有不同输入图像大小的 Swin Transformer 的性能，从 224^2 到 384^2 。总体而言，较大的输入分辨率可以带来更好的 top-1 准确率，但推理速度较慢。

A3.2. 在 COCO 数据集上使用不同的 ResNe(X)t 优化器

表 9 比较了在 COCO 目标检测任务中 ResNe(X)t 主干网络的 AdamW 和 SGD 优化器。本次比较使用了级联掩码 R-CNN 框架。虽然 SGD 是级联掩码 R-CNN 框架的默认优化器，但我们通常观察到用 AdamW 优化器替换后准确率有所提高，尤其是在较小的主干网络上。因此，在与提出的 Swin Transformer 架构进行比较时，我们为 ResNe(X)t 主干网络使用 AdamW 优化器。

A3.3. Swin MLP-Mixer

我们将所提出的分层设计和移位窗口方法应用于 MLP-Mixer 架构 [61]，称为 Swin-Mixer。表 10显示了 Swin-Mixer 与原始的 MLP-Mixer 架构 MLP-Mixer [61]和后续方法 ResMLP [61]的性能对比。Swin-Mixer 在稍微更小的计算预算（10.4G vs. 12.7G）下显著优于 MLP-Mixer（81.3% vs. 76.4%）。它在速度-准确率权衡上也比 ResMLP [62]表现更好。这些结果表明所提出的分层设计和移位窗口方法具有通用性。

参考文献

[1] Hangbo Bao, Li Dong, Furu Wei, Wenhui Wang, Nan Yang, Xiaodong Liu, Yu Wang, Jianfeng Gao, Songhao Piao, Ming Zhou, et al. Unilmv2: Pseudo-masked language models for unified language model pre-training. In International Conference on Machine Learning, pages 642–652. PMLR, 2020. 5

[2] Josh Beal, Eric Kim, Eric Tzeng, Dong Huk Park, Andrew Zhai, and Dmitry Kislyuk. Toward

method	image size	#param.	FLOPs	throughput (image / s)	ImageNet top-1 acc.
MLP-Mixer-B/16 [61]	224^2	59M	12.7G	-	76.4 [9]
ResMLP-S24 [62]	224^2	30M	6.0G	715	79.4
ResMLP-B24 [62]	224^2	116M	23.0G	231	81.0
Swin-T/D24 (Transformer)	256^2	28M	5.9G	563	81.6
Swin-Mixer-T/D24	256^2	20M	4.0G	807	79.4
Swin-Mixer-T/D12	256^2	21M	4.0G	792	79.6
Swin-Mixer-T/D6	256^2	23M	4.0G	766	79.7
Swin-Mixer-B/D24 (no shift)	224^2	61M	10.4G	409	80.3
Swin-Mixer-B/D24	224^2	61M	10.4G	409	81.3

表 10. Swin MLP-Mixer 在 ImageNet-1K 分类上的性能。*D* 表示每个头的通道数。吞吐量使用 [68] 的 GitHub 仓库和 V100 GPU 进行测量，遵循 [63]。

transformer-based object detection. arXiv preprint arXiv:2012.09958, 2020. 3

[3] Irwan Bello, Barret Zoph, Ashish Vaswani, Jonathon Shlens, and Quoc V. Le. Attention augmented convolutional networks, 2020. 3

[4] Alexey Bochkovskiy, Chien-Yao Wang, and Hong-Yuan Mark Liao. Yolov4: Optimal speed and accuracy of object detection. arXiv preprint arXiv:2004.10934, 2020. 7

[5] Navaneeth Bodla, Bharat Singh, Rama Chellappa, and Larry S. Davis. Soft-nms – improving object detection with one line of code. In Proceedings of the IEEE International Conference on Computer Vision (ICCV), Oct 2017. 7, 10

[6] Zhaowei Cai and Nuno Vasconcelos. Cascade r-cnn: Delving into high quality object detection. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 6154–6162, 2018. 6, 10

[7] Yue Cao, Jiarui Xu, Stephen Lin, Fangyun Wei, and Han Hu. Gcnet: Non-local networks meet squeeze-excitation networks and beyond. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops, Oct 2019. 3, 7, 10

[8] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In European Conference on Computer Vision, pages 213–229. Springer, 2020. 3, 6, 10

Kai Chen, Jiangmiao Pang, Jiaqi Wang, Yu Xiong, Xiaoxiao Li, Shuyang Sun, Wansen Feng, Ziwei Liu, Jianping Shi, Wanli Ouyang, et al. Hybrid task cascade for instance segmentation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 4974–4983, 2019. 7, 10

[10] Kai Chen, Jiaqi Wang, Jiangmiao Pang, Yuhang Cao, Yu Xiong, Xiaoxiao Li, Shuyang Sun, Wansen Feng, Ziwei Liu, Jiarui Xu, et al. Mmdetection: Open mmlab detection toolbox and benchmark. arXiv preprint arXiv:1906.07155, 2019. 6, 10

[11] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam. Encoder-decoder with atrous separable convolution for semantic image segmentation. In Proceedings of the European conference on computer vision (ECCV), pages 801–818, 2018. 8

[12] Yihong Chen, Zheng Zhang, Yue Cao, Liwei Wang, Stephen Lin, and Han Hu. Reppoints v2: Verification meets regression for object detection. In NeurIPS, 2020. 6, 7, 10

[13] Cheng Chi, Fangyun Wei, and Han Hu. Relationnet++: Bridging visual representations for object detection via transformer decoder. In NeurIPS, 2020. 3, 7

[14] Krzysztof Marcin Choromanski, Valerii Likhosherstov, David Dohan, Xingyou Song, Andreea Gane, Tamas Sarlos, Peter Hawkins, Jared Quincy Davis, Afroz Mohiuddin, Lukasz Kaiser, David Benjamin Belanger, Lucy J Colwell, and Adrian Weller. Rethinking attention with performers. In International Conference on Learning Representations, 2021. 9

[15] Xiangxiang Chu, Bo Zhang, Zhi Tian, Xiaolin Wei, and Huaxia Xia. Do we really need explicit position encodings for vision transformers? arXiv preprint arXiv:2102.10882, 2021. 3

[16] MMSegmentation Contributors. MMSegmentation: Openmmlab semantic segmentation toolbox and benchmark. https://github.com/open-mmlab/mmsegmentation, 2020. 8, 10

[17] Ekin D Cubuk, Barret Zoph, Jonathon Shlens, and Quoc V Le. Randaugment: Practical automated data

augmentation with a reduced search space. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, pages 702–703, 2020. 9

[18] Jifeng Dai, Haozhi Qi, Yuwen Xiong, Yi Li, Guodong Zhang, Han Hu, and Yichen Wei. Deformable convolutional networks. In Proceedings of the IEEE International Conference on Computer Vision, pages 764–773, 2017. 1, 3

[19] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In 2009 IEEE conference on computer vision and pattern recognition, pages 248–255. Ieee, 2009. 5

[20] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In International Conference on Learning Representations, 2021. 1, 2, 3, 4, 5, 6, 9

[21] Xianzhi Du, Tsung-Yi Lin, Pengchong Jin, Golnaz Ghiasi, Mingxing Tan, Yin Cui, Quoc V Le, and Xiaodan Song. Spinenet: Learning scale-permuted backbone for recognition and localization. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 11592–11601, 2020. 7

[22] Hao-Shu Fang, Jianhua Sun, Runzhong Wang, Minghao Gou, Yong-Lu Li, and Cewu Lu. Instaboost: Boosting instance segmentation via probability map guided copy-pasting. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 682–691, 2019. 7, 10

[23] Jun Fu, Jing Liu, Haijie Tian, Yong Li, Yongjun Bao, Zhiwei Fang, and Hanqing Lu. Dual attention network for scene segmentation. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 3146–3154, 2019. 3, 8

[24] Jun Fu, Jing Liu, Yuhang Wang, Yong Li, Yongjun Bao, Jinhui Tang, and Hanqing Lu. Adaptive context network for scene parsing. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 6748–6757, 2019. 8

[25] Kunihiko Fukushima. Cognitron: A self-organizing multilayered neural network. Biological cybernetics, 20(3):121–136, 1975. 3

[26] Golnaz Ghiasi, Yin Cui, Aravind Srinivas, Rui Qian, Tsung-Yi Lin, Ekin D Cubuk, Quoc V Le, and Barret Zoph. Simple copy-paste is a strong data augmentation method for instance segmentation. arXiv preprint arXiv:2012.07177, 2020. 2, 7

[27] Jiayuan Gu, Han Hu, Liwei Wang, Yichen Wei, and Jifeng Dai. Learning region features for object detection. In Proceedings of the European Conference on Computer Vision (ECCV), 2018. 3

[28] Kai Han, An Xiao, Enhua Wu, Jianyuan Guo, Chunjing Xu, and Yunhe Wang. Transformer in transformer. arXiv preprint arXiv:2103.00112, 2021. 3

[29] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask r-cnn. In Proceedings of the IEEE international conference on computer vision, pages 2961–2969, 2017. 6, 10

[30] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 770–778, 2016. 1, 2, 3, 4

[31] Elad Hoffer, Tal Ben-Nun, Itay Hubara, Niv Giladi, Torsten Hoefler, and Daniel Soudry. Augment your batch: Improving generalization through instance repetition. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 8129–8138, 2020. 5, 10

[32] Han Hu, Jiayuan Gu, Zheng Zhang, Jifeng Dai, and Yichen Wei. Relation networks for object detection. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 3588–3597, 2018. 3, 5

[33] Han Hu, Zheng Zhang, Zhenda Xie, and Stephen Lin. Local relation networks for image recognition. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pages 3464–3473, October 2019. 2, 3, 5

[34] Gao Huang, Zhuang Liu, Laurens Van Der Maaten, and Kilian Q Weinberger. Densely connected convolutional networks. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 4700–4708, 2017. 1, 3

[35] Gao Huang, Yu Sun, Zhuang Liu, Daniel Sedra, and Kilian Q Weinberger. Deep networks with stochastic depth. In European conference on computer vision, pages 646–661. Springer, 2016. 9

[36] David H Hubel and Torsten N Wiesel. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex. The Journal of physiology, 160(1):106–154, 1962. 3

[37] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980, 2014. 5, 9, 10

[38] Alexander Kolesnikov, Lucas Beyer, Xiaohua Zhai, Joan Puigcerver, Jessica Yung, Sylvain Gelly, and Neil Houlsby. Big transfer (bit): General visual representation learning. arXiv preprint arXiv:1912.11370, 6(2):8, 2019. 6

[39] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In Advances in neural information processing systems, pages 1097–1105, 2012. 1, 2

[40] Yann LeCun, Léon Bottou, Yoshua Bengio, Patrick Haffner, et al. Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11):2278–2324, 1998. 2

[41] Yann LeCun, Patrick Haffner, Léon Bottou, and Yoshua Bengio. Object recognition with gradient-based learning. In Shape, contour and grouping in computer vision, pages 319–345. Springer, 1999. 3

[42] Tsung-Yi Lin, Piotr Dollar, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection. In The IEEE Conference on Computer Vision and Pattern Recognition (CVPR), July 2017. 2

[43] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C Lawrence Zitnick. Microsoft coco: Common objects in context. In European conference on computer vision, pages 740–755. Springer, 2014. 5

[44] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In International Conference on Learning Representations, 2019. 6, 10

[45] Boris T Polyak and Anatoli B Juditsky. Acceleration of stochastic approximation by averaging. SIAM journal on control and optimization, 30(4):838–855, 1992. 5, 10

[46] Siyuan Qiao, Liang-Chieh Chen, and Alan Yuille. Detectors: Detecting objects with recursive feature pyramid and switchable atrous convolution. arXiv preprint arXiv:2006.02334, 2020. 2, 7

[47] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision, 2021. 1

[48] Ilija Radosavovic, Raj Prateek Kosaraju, Ross Girshick, Kaiming He, and Piotr Dollár. Designing network design spaces. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 10428–10436, 2020. 6

[49] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. Journal of Machine Learning Research, 21(140):1–67, 2020. 5

[50] Prajit Ramachandran, Niki Parmar, Ashish Vaswani, Irwan Bello, Anselm Levskaya, and Jon Shlens. Standalone self-attention in vision models. In Advances in Neural Information Processing Systems, volume 32. Curran Associates, Inc., 2019. 2, 3

[51] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In International Conference on Medical image computing and computer-assisted intervention, pages 234–241. Springer, 2015. 2

[52] K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. In International Conference on Learning Representations, May 2015. 2, 4

[53] Bharat Singh and Larry S Davis. An analysis of scale invariance in object detection snip. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 3578–3587, 2018. 2

[54] Bharat Singh, Mahyar Najibi, and Larry S Davis. Sniper: Efficient multi-scale training. In Advances in Neural Information Processing Systems, volume 31. Curran Associates, Inc., 2018. 2

[55] Aravind Srinivas, Tsung-Yi Lin, Niki Parmar, Jonathon Shlens, Pieter Abbeel, and Ashish Vaswani.

Bottleneck transformers for visual recognition. arXiv preprint arXiv:2101.11605, 2021. 3

[56] Peize Sun, Rufeng Zhang, Yi Jiang, Tao Kong, Chenfeng Xu, Wei Zhan, Masayoshi Tomizuka, Lei Li, Zehuan Yuan, Changhu Wang, et al. Sparse r-cnn: End-to-end object detection with learnable proposals. arXiv preprint arXiv:2011.12450, 2020. 3, 6, 10

[57] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 1–9, 2015. 3

[58] Mingxing Tan and Quoc Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In International Conference on Machine Learning, pages 6105–6114. PMLR, 2019. 3, 6

[59] Mingxing Tan, Ruoming Pang, and Quoc V Le. Efficientdet: Scalable and efficient object detection. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 10781–10790, 2020. 7

[60] Yi Tay, Mostafa Dehghani, Samira Abnar, Yikang Shen, Dara Bahri, Philip Pham, Jinfeng Rao, Liu Yang, Sebastian Ruder, and Donald Metzler. Long range arena : A benchmark for efficient transformers. In International Conference on Learning Representations, 2021. 9

[61] Ilya Tolstikhin, Neil Houlsby, Alexander Kolesnikov, Lucas Beyer, Xiaohua Zhai, Thomas Unterthiner, Jessica Yung, Andreas Steiner, Daniel Keysers, Jakob Uszkoreit, Mario Lucic, and Alexey Dosovitskiy. Mlp-mixer: An all-mlp architecture for vision, 2021. 2, 11

[62] Hugo Touvron, Piotr Bojanowski, Mathilde Caron, Matthieu Cord, Alaaeldin El-Nouby, Edouard Grave, Gautier Izacard, Armand Joulin, Gabriel Synnaeve, Jakob Verbeek, and Hervé Jégou. Resmlp: Feedforward networks for image classification with data-efficient training, 2021. 11

[63] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. arXiv preprint arXiv:2012.12877, 2020. 2, 3, 5, 6, 9, 10, 11

[64] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In Advances in Neural Information Processing Systems, pages 5998–6008, 2017. 1, 2, 4

[65] Jingdong Wang, Ke Sun, Tianheng Cheng, Borui Jiang, Chaorui Deng, Yang Zhao, Dong Liu, Yadong Mu, Mingkui Tan, Xinggang Wang, et al. Deep high-resolution representation learning for visual recognition. IEEE transactions on pattern analysis and machine intelligence, 2020. 3

[66] Wenhai Wang, Enze Xie, Xiang Li, Deng-Ping Fan, Kaitao Song, Ding Liang, Tong Lu, Ping Luo, and Ling Shao. Pyramid vision transformer: A versatile backbone for dense prediction without convolutions. arXiv preprint arXiv:2102.12122, 2021. 3

[67] Xiaolong Wang, Ross Girshick, Abhinav Gupta, and Kaiming He. Non-local neural networks. In IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2018, 2018. 3

[68] Ross Wightman. Pytorch image models. https://github.com/rwightman/pytorch-image-models, 2019. 6, 11

[69] Tete Xiao, Yingcheng Liu, Bolei Zhou, Yuning Jiang, and Jian Sun. Unified perceptual parsing for scene understanding. In Proceedings of the European Conference on Computer Vision (ECCV), pages 418–434, 2018. 8, 10

[70] Saining Xie, Ross Girshick, Piotr Dollár, Zhuowen Tu, and Kaiming He. Aggregated residual transformations for deep neural networks. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 1492–1500, 2017. 1, 2, 3

[71] Minghao Yin, Zhuliang Yao, Yue Cao, Xiu Li, Zheng Zhang, Stephen Lin, and Han Hu. Disentangled non-local neural networks. In Proceedings of the European conference on computer vision (ECCV), 2020. 3, 8, 11

[72] Li Yuan, Yunpeng Chen, Tao Wang, Weihao Yu, Yujun Shi, Francis EH Tay, Jiashi Feng, and Shuicheng Yan. Tokens-to-token vit: Training vision transformers from scratch on imagenet. arXiv preprint arXiv:2101.11986, 2021. 3

[73] Yuhui Yuan, Xilin Chen, and Jingdong Wang. Object-contextual representations for semantic segmenta-

tion. In 16th European Conference Computer Vision (ECCV 2020), August 2020. 8

[74] Yuhui Yuan and Jingdong Wang. Ocnet: Object context network for scene parsing. arXiv preprint arXiv:1809.00916, 2018. 3

[75] Sangdoo Yun, Dongyoon Han, Seong Joon Oh, Sanghyuk Chun, Junsuk Choe, and Youngjoon Yoo. Cutmix: Regularization strategy to train strong classifiers with localizable features. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 6023–6032, 2019. 9

[76] Sergey Zagoruyko and Nikos Komodakis. Wide residual networks. In BMVC, 2016. 1

[77] Hongyi Zhang, Moustapha Cisse, Yann N Dauphin, and David Lopez-Paz. mixup: Beyond empirical risk minimization. arXiv preprint arXiv:1710.09412, 2017. 9

[78] Hang Zhang, Chongruo Wu, Zhongyue Zhang, Yi Zhu, Zhi Zhang, Haibin Lin, Yue Sun, Tong He, Jonas Mueller, R Manmatha, et al. Resnest: Split-attention networks. arXiv preprint arXiv:2004.08955, 2020. 7, 8

[79] Shifeng Zhang, Cheng Chi, Yongqiang Yao, Zhen Lei, and Stan Z Li. Bridging the gap between anchor-based and anchor-free detection via adaptive training sample selection. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 9759–9768, 2020. 6, 10

[80] Hengshuang Zhao, Jiaya Jia, and Vladlen Koltun. Exploring self-attention for image recognition. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 10076–10085, 2020. 3

[81] Sixiao Zheng, Jiachen Lu, Hengshuang Zhao, Xiatian Zhu, Zekun Luo, Yabiao Wang, Yanwei Fu, Jianfeng Feng, Tao Xiang, Philip HS Torr, et al. Rethinking semantic segmentation from a sequence-to-sequence perspective with transformers. arXiv preprint arXiv:2012.15840, 2020. 2, 3, 7, 8

[82] Zhun Zhong, Liang Zheng, Guoliang Kang, Shaozi Li, and Yi Yang. Random erasing data augmentation. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 34, pages 13001–13008, 2020. 9

[83] Bolei Zhou, Hang Zhao, Xavier Puig, Tete Xiao, Sanja Fidler, Adela Barriuso, and Antonio Torralba. Semantic understanding of scenes through the ade20k dataset. International Journal on Computer Vision, 2018. 5, 8, 10

[84] Xizhou Zhu, Han Hu, Stephen Lin, and Jifeng Dai. Deformable convnets v2: More deformable, better results. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 9308–9316, 2019. 1, 3

[85] Xizhou Zhu, Weijie Su, Lewei Lu, Bin Li, Xiaogang Wang, and Jifeng Dai. Deformable {detr}: Deformable transformers for end-to-end object detection. In International Conference on Learning Representations, 2021. 3