https://hjfy.top/arxiv/2506.06281

TerraFM：一种可扩展的基础模型，用于统一多传感器地球观测

Muhammad Sohail Danish[1] **Muhammad Akhtar Munir**[1] **Syed Roshaan Ali Shah**[2]
Muhammad Haris Khan[1] **Rao Muhammad Anwer**[1,3] **Jorma Laaksonen**[3]
Fahad Shahbaz Khan[1,4] **Salman Khan**[1,5]
[1]Mohamed bin Zayed University of Artificial Intelligence [2]University College London
[3]Aalto University [4]Linköping University, Sweden [5]Australian National University

Abstract

现代地球观测（EO）越来越多地利用深度学习来挖掘来自不同传感器和区域的卫星影像在规模与多样性方面的潜力。尽管近期的基础模型已在多种 EO 任务中展现出令人瞩目的泛化能力，但许多模型仍受限于其训练数据的规模、地理覆盖范围以及光谱多样性，而这些因子对于学习具有全球可迁移性的表示至关重要。在本工作中，我们提出了 **TerraFM**，一种可扩展的自监督学习模型，该模型利用全球分布的哨兵-1 和哨兵-2 影像，结合大尺度空间块及面向土地覆盖的采样策略，以增强空间与语义覆盖。通过将感知模态视为自监督方法中的自然增强手段，我们采用模态特定的图像块嵌入和自适应交叉注意力融合，统一雷达与光学输入。我们的训练策略整合了局部-全局对比学习，并引入了一种双中心机制，结合类别频率感知的正则化，以应对土地覆盖中的长尾分布问题。TerraFM 在分类与分割任务上均表现出强大的泛化能力，在 GEO-Bench 与 Copernicus-Bench 上超越了先前的模型。我们的代码与预训练模型已公开发布于 https://github.com/mbzuai-oryx/TerraFM。

1 引言

EO 提供了对地球表面的系统性测量，支持一系列关键应用，如土地利用监测 [31]、作物评估 [20, 17]、城市发展 [37] 以及灾害响应 [15, 24, 21]。这些能力得益于日益壮大的地球观测卫星舰队，尤其是哨兵系列任务，它们在全球范围内提供多模态、多时相的数据 [27, 7]。深度学习的兴起，特别是深度神经网络（DNNs），从根本上重塑了 EO 数据的处理与解读方式 [32, 25, 28]。现代 DNNs 能够从原始影像中自动提取空间和语义模式，推动下游任务如场景分类、目标检测和语义分割的发展 [1, 29, 16, 28, 10]。这些模型通过直接从数据中学习可泛化的表示，为传统手工设计的流水线提供了可扩展且自适应的替代方案 [12]。随着 EO 数据集在规模、多样性及复杂性上的持续增长，DNNs 已成为构建高容量模型的基础，使模型能够在地理区域、模态和任务之间实现泛化 [25, 1, 29]。

遥感数据本质上是多模态的，包含光学、SAR 以及多光谱影像等多种传感器类型。传统的地球观测流水线通常专注于单模态输入，通常是高分辨率光学影像，这限制了模型在不同感知条件下的泛化能力。相比之下，多模态和多光谱数据源（如哨兵-1 SAR 和哨兵-2

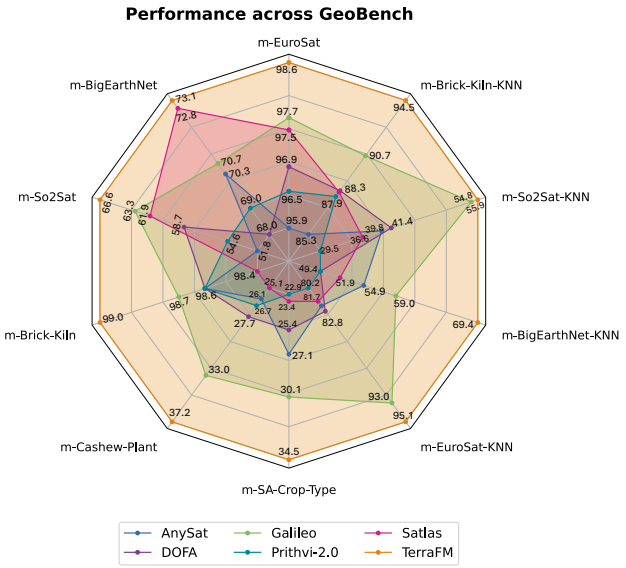

图 1: 不同遥感基准任务中基于监督和 kNN 评估协议的性能比较。具体而言，监督微调评估学成基础表示与冻结编码器结合 kNN 头的泛化能力。展示了五种近期的地球观测基础模型（AnySat [1]，DOFA [36]，Galileo [28]，Prithvi-2.0 [25]，Satlas [2]）的表现，与我们提出的 TerraFM 进行对比。TerraFM 在多种模态和评估情景下均持续优于现有模型，展现出强大的泛化能力。

Level-1C/Level-2A 光学波段）能够捕捉互补的结构与光谱信息，从而实现更丰富的场景理解 [13, 10]。拥抱这种多样性的基础模型已在任务和地理区域之间展现出更优的可迁移性 [28, 12]。然而，地球观测数据中地面采样距离（GSD）的变化使得瓦片大小成为一个关键因子；较小的瓦片能捕捉局部细节，但可能过拟合于纹理，而较大的瓦片则提供更广泛的语义上下文，但需要具备尺度鲁棒性的架构 [22]。近期的研究如 AnySat 和 msGFM [13, 1] 表明，尺度不变建模与混合分辨率预训练能够生成更稳健且更具泛化能力的表示。至关重要的是，跨地理区域和分辨率的大规模采样使地球观测基础模型能够学习跨越传感器和全球条件的不变特征。

随着地球观测基础模型不断扩大以适应多样化的传感器输入和分辨率，两种主流的预训练范式已经出现：掩码自编码器（MAE）和对比学习。尽管 MAE 专注于重建空间结构，但其对以 RGB 为中心的 ViTs 的依赖限制了其在具有不同光谱维度的多光谱或 SAR 输入中的适应性 [18, 25]。相比之下，诸如 DINO [4, 19] 及其在遥感领域的适应方法 [28, 10, 29] 等对比方法通过学生-教师蒸馏对齐全局与局部视图，实现了模态无关的训练。然而，地球观测数据集广阔的空域覆盖带来了新的挑战：卫星影像的大部分区域语义稀疏或信息量低，而简单的采样方式可能导致表示偏差。因此，需要智能采样策略，优先选择语义多样化的区域，并基于土地覆盖先验进行引导，以实现均衡且高效的表示学习。

为解决标准 ViTs 在遥感应用中的诸多局限性，尤其是其以 RGB 为中心的设计、缺乏模态感知能力以及单峰值自监督学习的问题，我们提出了一种面向遥感的统一基础模型——**TerraFM**。首先，我们提出了一个模态特定的块嵌入模块，该模块用针对多光谱和合成孔径雷达（SAR）数据设计的模态感知嵌入替代标准 ViTs 中的共享投影。这使得模型能够灵活处理传感器特有的光谱特性，同时保持空间结构的一致性。为增强尺度不变性和跨视角一致性，我们在自监督教师-学生框架内采用多裁剪学习策略，通过全局-局部对齐促进鲁棒的表示学习。此外，我们将不同对齐的模态（S1-SAR、S2-L1C、S2-L2A）视为同一场景的互补视图，并引入一个交叉注意力融合模块，利用可学习的空间查询动态聚合各模态特定的 token。这使模型能够在每个空间位置上选择性地强调不同传感器的贡献。最后，为缓解地球观测（EO）数据中常见的长尾地表覆盖分布问题，我们在蒸馏过程中引入了双中心化机制。该机制利用来自 WorldCover [38] 的类别统计量计算具有频率感知能力的中心，从而在不依赖监督目标的情况下提升主导与稀有语义类别之间的平衡性。我们的主要贡献如下。

表 1: 不同模态、规模和基准下近期遥感基础模型的比较。**TerraFM** 独特地结合了大瓦片尺寸（534）、基于 WorldCover 的元数据以及全球尺度训练（1870 万样本），并在 GEO-Bench 和 Copernicus-Bench 上进行评估。

Model	**Modalities**	**Scale**	**Resolution**	**TileSize**	**Metadata**	**Benchmarks**	**Pixels (~T)**
SatMAE++	S2, RGB	∼1.2 M	10–60 m	224, 96	No	6 DS	0.12
Galileo	S1, S2, NDVI, ESA WC etc	∼3–10.9 M	10 m	96 (flex)	Yes	GEO + 5 DS	1.58
CROMA	S1, S2	∼1 M	10 m	96, 120	No	7 DS	0.98
SoftCon	S1, S2	∼0.78 M	10 m	224	Yes	4 GEO + 7 DS	0.76
AnySat	Aerial, S1/S2, MODIS, etc.	11.1 M	0.2–250 m	10–240	No	11 DS	0.17
Prithvi-2	S2, HLS	4.2 M	30 m	224	Yes	GEO + 9 SME	5.06
DOFA	S1, S2, EnMAP, etc.	∼8 M	1–30 m	512, 128	Yes	GEO + 2 DS	6.74
Panopticon	S1, S2, WV2/3, NAIP	∼2.6 M	0.3–100 m	96, 224	Yes	GEO + 10 DS	2.34
MMEarth	S1, S2, DEM, etc.	∼7.2 M	0.3–100 m	128	Yes	5 GEO	0.51
msGFM	RGB, S2, SAR, DSM	∼2 M	0.1–30 m	192	No	5 DS	0.44
Copernicus-FM	S1–S5P, DEM	18.7 M	10 m–1 km	Mixed	Yes	Cop-Bench	5.12
TerraFM (Ours)	S1, S2 L1C/L2A	18.7 M	10–60 m	534	Yes	GEO + Cop-Bench	**23.32**

贡献：(1) 提出了一种模态特定的块嵌入机制，以在具有不同光谱维度的异构遥感模态间泛化视觉变换器（ViTs）。**(2)** 将传感器模态视为自然增强，并引入一种交叉注意力融合块，将多模态输入统一在共享编码器中。**(3)** 为应对长尾的土地利用/土地覆盖（LULC）分布，采用一种双中心化策略，利用与类别频率相关的统计量来正则化表示学习。**(4)** 在 *GEO-Bench* 和 *Copernicus-Bench* 上的大量实验表明，使用全球分布数据，在多个下游任务中均取得了领先性能（图 1）。

2 相关工作

自监督预训练： MAEs [14] 已成为遥感领域自监督预训练的流行选择，通过使用 ViT [6] 重构被掩码的图像区域。诸如 Scale-MAE [22] 和 MC-MAE [11] 的变体通过感知尺度的编码和卷积 tokenizer 增强了跨空间尺度的鲁棒性。然而，MAEs 在扩展到多传感器地球观测数据时面临挑战，因其以 RGB 为中心的 tokenization 与重构目标限制了对具有不同通道结构的多光谱和 SAR 模态的泛化能力 [35, 18]。

与平均绝对误差（MAE）不同，自监督对比学习通过比较语义上相似和不相似的视图来关注学习判别性表示。遥感方法 [26, 10, 29] 利用空间和光谱增强来生成多样但一致的视图。CROMA [10] 结合了对比损失和掩码自编码损失，而跨尺度 MAE [26] 将生成式目标与对比目标相结合，以实现多尺度学习。如 DINO [4, 19] 的学生-教师框架通过指数移动平均更新的教师模型来扩展对比学习，并通过中心化实现全局-局部视图对齐，以防止表示坍缩。这些策略非常适合地球观测（EO），其中多模态影像可作为自然增强手段，从而实现可扩展的无标签训练和广泛的泛化能力。

遥感基础模型： 遥感基础模型（FMs）的最新进展在架构类型、模态、训练规模、影像块分辨率以及元数据使用方面实现了自监督学习的扩展（表 1）。多模态融合是近期基础模型如 [12, 32, 29, 1, 28, 13] 的核心。SkySense [12] 将对比学习应用于时序-多模态数据，但需要大规模计算资源。CopernicusFM [32] 通过元数据感知网络融合哨兵系列模态，但在处理异构输入时面临缩放问题。Panopticon [29] 和 AnySat [1] 通过对比学习对齐跨模态视图，而

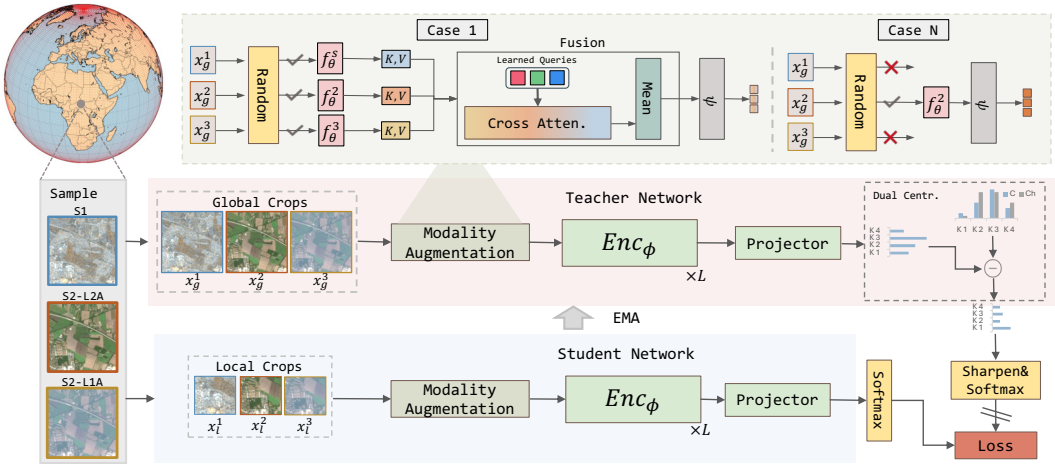

图 2: **TerraFM** 的整体架构。它将学生-教师对比框架与模态增强结合，采用交叉注意力融合，并引入一种新的双中心正则化。**TerraFM** 基于 ViT 骨干网络，使用 1870 万张全球分布的样本进行预训练，并利用大尺寸图像块输入以编码更广泛的空域上下文。为便于说明，选取了 S2-L2A 和 S2-L1C 的 RGB 通道，而 S1 则通过伪彩色 RGB 合成进行可视化。

Galileo [28] 使用共享嵌入实现 SAR 与多光谱数据的融合。Fus-MAE [5] 采用基于注意力机制的融合方法，但未使用对比损失，限制了泛化能力。

Prithvi-2 [25] 仅限于单模态光学数据，并具有时空建模能力。DOFA [36]、msGFM [13] 和 AnySat [1] 通过混合瓦片大小或尺度自适应设计来应对分辨率变化问题。我们的 534px 瓦片比之前的遥感图像模型（RSFMs）捕获了更广泛的时空上下文。尽管 CopernicusFM [32] 和 DOFA [36] 融入了元数据，我们则利用土地覆盖（LULC）先验实现语义感知的学习。CopernicusFM 与我们的模型均在 1870 万样本上进行训练，但我们的模型在预训练阶段使用了超过 23T 像素，是 Copernicus-Pretrain [32] 所用 5.1T 像素的 4 倍以上缩放。

3 TerraFM：一种可扩展的多传感器基础模型

与以往的遥感基础模型不同，我们的方法集成了学生-教师对比学习框架与双重中心化（以平衡长尾类别）、模态作为增强（以学习跨模态不变性）以及交叉注意力融合（以聚合多传感器上下文），如图 2所示。基于 ViT 骨干网络，并在 1870 万全球分布的样本上使用 534×534 个瓦片进行训练，**TerraFM** 能够捕捉更广泛的空间上下文，并在多种传感模态和地理区域间有效泛化，在多样化的下游基准测试中取得了优异表现。

3.1 架构

我们使用在全球范围内分布的遥感影像，并将其组织在空间网格上，将地球表面划分为固定大小的瓦片 [9]（例如 5.34 km × 5.34 km）。每个空间单元，记为 s，代表一个这样的网格单元。对于每个样本，我们观测一组配准的地球观测模态：

$$\mathcal{M} = \{\text{S1, S2-L1C, S2-L2A}\},$$

其中 **S1** 对应哨兵-1 SAR（合成孔径雷达），**S2-L1C** 和 **S2-L2A** 分别代表哨兵-2 光学影像的两个处理级别：Level-1C（大气顶反射率）和 Level-2A（地表反射率）。每个模态 $m \in \mathcal{M}$ 提供一个多通道图像 $\boldsymbol{x}^m \in \mathbb{R}^{H\times W\times C_m}$ ，其中 H 和 W 表示空间维度，C_m 是模态 m 的光谱通道数。例如，哨兵-1 包含两个通道（VV 和 VH 极化），因此 $C_{\text{S1}} = 2$ ，而哨兵-2 模态

根据处理级别和分辨率最多包含 13 个光谱波段。这些模态被视为同一位置的互补视图，作为自然的数据增强，支持我们的训练策略，并促进学习模态不变表示。

为了提供语义基础，每个样本 s 被分配一个高层次的土地利用和土地覆盖（LULC）类别 $y^{(s)} \in \{1, \ldots, Y\}$ ，该类别源自 ESA WorldCover 产品。这些类别反映了全球尺度上的粗粒度语义类别，并用于计算考虑类别频率的统计量，以实现平衡的表示学习。

视觉 Transformer 模型:

ViTs 通过将图像视为一系列补丁 token 而非稠密的像素网格，将 Transformer 架构应用于视觉数据。一个典型的 ViT 包含两个主要组件：补丁嵌入模块和 Transformer 编码器。给定输入图像 $\boldsymbol{x} \in \mathbb{R}^{H \times W \times C}$，**补丁嵌入**层 f_θ 将图像划分为 N 个大小为 $P \times P$ 的非重叠补丁，并将每个补丁投影到一个 d 维嵌入空间中：

$$\{\boldsymbol{z}_i\}_{i=1}^{N} = f_\theta(\boldsymbol{x}), \qquad \boldsymbol{z}_i \in \mathbb{R}^d.$$

此投影通常通过卷积层实现，其卷积核大小和步幅均等于图像块大小 P ，由权重 $\mathbf{W}_\theta \in \mathbb{R}^{d \times C \times P \times P}$ 参数化。为编码空间信息，Transformer 编码器为每个图像块 token $\boldsymbol{z}_i$ 增加一个位置向量。添加一个可学习的类别 token $\boldsymbol{z}_{\text{cls}}$ 到序列中，从而得到完整的输入：

$$\boldsymbol{Z} = \left[\, \boldsymbol{z}_{\text{cls}};\ \{\boldsymbol{z}_i + \text{pos}_i\}_{i=1}^{N} \,\right].$$

token 序列 $\boldsymbol{Z}$ 由一系列 L Transformer 层处理，记为 Enc_ϕ。对于分类任务，仅将最终的类别 token $\hat{\boldsymbol{z}}_{\text{cls}}$ 传递给预测头。

模态特定的 Patch 嵌入:

Vision Transformers 中的标准补丁嵌入层通常通过在所有输入上使用共享的卷积投影来实现，这使其不适用于多模态遥感数据。

为了更好地处理这种异质性，我们采用一种模态特定的图像块嵌入策略。对于每种模态 $m \in \mathcal{M}$，我们定义一个嵌入函数 f_θ^m，将输入图像 $\boldsymbol{x}^m \in \mathbb{R}^{H \times W \times C_m}$ 映射为一组图像块 token $\boldsymbol{Z}^m \in \mathbb{R}^{N_m \times D}$，其中 C_m 为通道数，N_m 为图像块数量。每个 f_θ^m 通过独立参数化以适应模态特有的动态变化。我们将每个模态与一个可学习的嵌入向量 $\boldsymbol{e}^m \in \mathbb{R}^D$ 相关联。该向量通过广播机制加到该模态的每个 token 上：

$$\tilde{\boldsymbol{Z}}^m = \boldsymbol{Z}^m + \mathbf{1}_{N_m} \cdot (\boldsymbol{e}^m)^\top,$$

其中 $\mathbf{1}_{N_m} \in \mathbb{R}^{N_m \times 1}$ 是一个全 1 向量。这使得模型能够在保留局部空间和光谱特征的同时区分不同模态。最后，为了在 Transformer 编码器中实现共享处理，将增强的 token $\tilde{\boldsymbol{Z}}^m$ 通过一个共享投影 $\psi : \mathbb{R}^D \to \mathbb{R}^d$ 线性映射到维度为 d 的公共潜在空间中：

$$\boldsymbol{Z}^{(m)} = \psi(\tilde{\boldsymbol{Z}}^m) \in \mathbb{R}^{N_m \times d}.$$

此操作将所有模态特定的 token 序列对齐到统一的表示空间中，使编码器能够联合处理它们。

模态增强与交叉注意力融合: 单个位置的遥感观测通常使用多个传感器获取，每个传感器提供独特的光谱或辐射视角。我们不将这些模态视为独立输入，而是将其解释为同一场景的互补视图。这使得我们能够利用模态多样性作为一种自然增强方式，使模型学习到传感器不变的表示。在我们的设置中，来自 Major-TOM 数据集 [9] 的每个空间样本 s 均通过一组固定的模态进行观测。在预训练过程中，我们通过随机选择（阈值 $= 0.5$）独立地将模态分配给学生网络和教师网络，以确保跨模态监督。例如，教师网络可能观察来自 Sentinel-1 的全局作物图像，而学生网络则接收来自 Sentinel-2 L2A 的局部视图。这种模态增强策略促使模

型在不同传感器间对齐特征，从而提升对传感器特异性伪影的鲁棒性。我们根据所选模态的数量考虑两种情况：

1）单模态视图：若仅选择一种模态，输入将通过对应的模态特定的补丁嵌入层，随后进入共享的 Transformer 编码器。此过程遵循标准的 ViT 流水线，但使用模态感知的嵌入来处理光谱通道差异。

2）通过交叉注意力实现多模态融合：当选择多种模态时，我们激活基于交叉注意力的模态融合模块。对于每种选定的模态 $m \in \mathcal{M}$ ，我们获得一个补丁 token 序列 $\boldsymbol{Z}^{(m)} \in \mathbb{R}^{N \times D}$ ，其中 N 表示空间位置的数量。这些序列被堆叠成一个张量 $\boldsymbol{Z}_{\text{all}} \in \mathbb{R}^{N \times M \times D}$ ，以对齐各模态之间的空间位置。

对于每个位置 $n = 1, \ldots, N$ ，我们定义共享的可学习查询 $\boldsymbol{q} \in \mathbb{R}^{N_q \times D}$ ，其关注特定模态的键 $\boldsymbol{K}_n \in \mathbb{R}^{M \times D}$ 和值 $\boldsymbol{V}_n \in \mathbb{R}^{M \times D}$ ，从而生成 N_q 个中间输出：

$$\boldsymbol{z}'_n = \texttt{MultiHeadAttention}(\boldsymbol{q}, \boldsymbol{K}_n, \boldsymbol{V}_n) \in \mathbb{R}^{N_q \times D}.$$

为了聚合它们，我们使用 Softmax 规范化的注意力得分计算一个学成的加权平均值：

$$\boldsymbol{w} = \texttt{Softmax}(\boldsymbol{z}'_n \cdot \boldsymbol{p}_r), \quad \boldsymbol{z}_n^{\text{fused}} = \sum_{j=1}^{N_q} w_j \boldsymbol{z}'_n[j],$$

其中，$\boldsymbol{p}_r \in \mathbb{R}^{D \times 1}$ 是用于对查询输出进行打分的可学习投影。这生成了一个融合的 token $\boldsymbol{z}_n^{\text{fused}} \in \mathbb{R}^D$。随后，最终序列 $\boldsymbol{Z}_{\text{fused}} \in \mathbb{R}^{N \times D}$ 被传递到共享编码器。这种交叉注意力融合使得模型能够在每个空间位置动态地权衡不同模态的贡献，从而在保持空间一致性的同时捕捉多样化信息。

3.2 预训练

我们的预训练策略基于 DINO 框架，该框架执行自监督学习。它采用教师-学生架构，其中两个网络共享相同的 ViT 主干和轻量级的三层投影头。令 g_{θ_s} 和 g_{θ_t} 分别表示学生网络和教师网络。当学生网络通过基于梯度的最优化进行训练时，教师网络则通过学生权重的指数移动平均（EMA）进行更新：

$$\theta_t \leftarrow \lambda_e \, \theta_t + (1 - \lambda_e) \, \theta_s, \quad \lambda_e = 1 - (1 - \lambda_0) \frac{1 + \cos(\pi e / E)}{2}, \tag{1}$$

其中 e 表示当前轮次，E 表示训练的总轮次数，$\lambda_0 \in [0.996, 1)$ 表示初始动量系数。余弦调度逐渐增大 λ_e，随着训练的进行稳定教师模型的更新。该 EMA 机制使教师模型能够作为过去学生模型状态的时间平滑集成，从而生成更稳定且一致的目标。图 2 展示了 TerraFM 预训练的整体流程。

多裁剪学习：为了实现尺度不变和跨视图表示学习，我们采用了 DINO 中使用的多裁剪策略 [4]. 对于每个输入样本，我们生成两个高分辨率全局裁剪 $\{\boldsymbol{x}_g^1, \boldsymbol{x}_g^2\} \subset \mathcal{X}_g$ 和 J 低分辨率局部裁剪 $\{\boldsymbol{x}_\ell^j\}_{j=1}^J \subset \mathcal{X}_\ell$. 教师网络仅处理全局裁剪，而学生网络接收全局和局部视图。每个网络产生一个 K -维输出，该输出经过温度缩放并通过 Softmax 函数规范化：

$$Q_s(\boldsymbol{x})^{(i)} = \frac{\exp(g_{\theta_s}(\boldsymbol{x})^{(i)} / \tau_s)}{\sum_{k=1}^K \exp(g_{\theta_s}(\boldsymbol{x})^{(k)} / \tau_s)}, \quad Q_t(\boldsymbol{x})^{(i)} = \frac{\exp((g_{\theta_t}(\boldsymbol{x})^{(i)} - c^{(i)}) / \tau_t)}{\sum_{k=1}^K \exp((g_{\theta_t}(\boldsymbol{x})^{(k)} - c^{(k)}) / \tau_t)},$$

其中 τ_s 和 τ_t 是控制输出锐度的温度参数，c 是表示教师模型 Logit 的移动平均的中心项，用于稳定训练并避免表示崩溃。中心项通过教师输出的指数移动平均进行更新：

$$c \leftarrow \beta c + (1 - \beta) \cdot \frac{1}{B} \sum_{i=1}^{B} g_{\theta_t}(x_i),$$

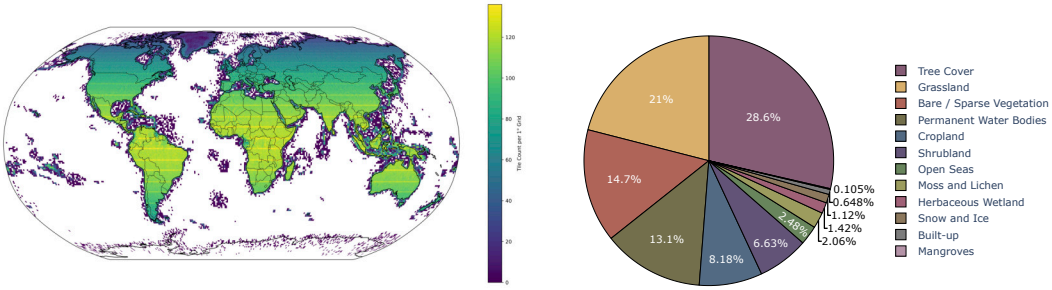

图 3: 左图： Major-TOM 训练子集的全局空间分布。每个方阵表示一个 $1^\circ \times 1^\circ$ 单元，颜色根据其包含的 10.68 km × 10.68 km 瓦片数量进行区分。右图：相同训练瓦片上的土地利用/土地覆盖（LULC）构成。由于数据分布倾斜，一些语义上重要的类别（如建筑用地、红树林、冰）仍呈现代表性不足。

其中 $\beta \in [0.9, 0.999]$ 控制动量，B 为批量大小。整体损失鼓励教师模型与学生模型在所有不同视图组合之间的预测保持一致：

$$\sum_{\boldsymbol{x} \in \mathcal{X}_g} \sum_{\boldsymbol{x}' \in \mathcal{X}; \boldsymbol{x}' \neq \boldsymbol{x}} \mathcal{L}_{\mathrm{CE}} \left(Q_t(\boldsymbol{x}), Q_s(\boldsymbol{x}') \right),$$

其中 $\mathcal{X} = \mathcal{X}_g \cup \mathcal{X}_\ell$ 和 $\mathcal{L}_{\mathrm{CE}}(\cdot, \cdot)$ 表示交叉熵损失。这种损失形式要求学生模型在所有视图中产生一致的表示。

长尾分布的双中心机制： 遥感数据集中的地表覆盖类别（LULC）通常呈现长尾分布，例如森林等常见类别占主导地位，而城市或裸土等类别则代表性不足，如图 3所示。即使经过下采样后，这种不平衡仍然存在，并对表示学习构成挑战。标准的自监督方法（如 DINO [4]）通过引入单一全局中心项来稳定训练并避免表示崩溃，但它们并未考虑数据中的语义不平衡问题。为了解决这一问题，我们提出了一种双中心机制，结合全局统计量与类别频率感知的正则化。除了标准的全局中心向量 c 外，我们还引入了一个辅助中心 c_h ，该中心基于高频率 LULC 类别（如树冠、草地和开阔海域）的样本子集计算得出，其依据是数据集层面的统计量。给定一批教师模型的 Logit $g_{\theta_t}(x)$ ，用于训练的调整后的 Logit 计算如下：

$$\hat{g}(\boldsymbol{x}) = g_{\theta_t}(\boldsymbol{x}) - \alpha \cdot c - (1 - \alpha) \cdot c_h,$$

其中，向量 $\alpha \in [0, 1]$ 平衡了全局中心与频率感知中心的贡献。向量 c_h 通过仅使用每个批量中的频繁类样本进行指数移动平均来更新。这种双中心机制实现了两个关键目的：**(i)** 保留了如 DINO 中全局中心化所带来的稳定性优势，以及 **(ii)** 引入了一种软重平衡偏差，以抵消特征空间中主导类别过度代表的问题。在消融实验（表 5）中，这一调整带来了更均衡的表示学习，并显著提升了下游任务性能，尤其是在代表性不足的土地利用/土地覆盖（LULC）类别上表现更为突出。

4 预训练数据采样

我们采用 Major-TOM 数据集 [9] 作为预训练的主要地球观测（EO）数据源。该数据集包含 224 万个全球分布的网格单元，每个单元大小约为 10.68 km × 10.68 km ($\approx$ 114 km^2)，并提供来自 Sentinel-2 Level-1C、Sentinel-2 Level-2A 和 Sentinel-1 RTC 的三模态、同配准影像。Major-TOM 是少数几个在全局尺度上提供稠密多模态覆盖的公开数据集之一。然而，其超过三分之一的样本位于 10 km 陆地缓冲区之外，通常属于“开阔海洋”类别 [38]，这限制了它们在以陆地为中心的任务中的相关性。受 [23] 中见解的启发，该研究强调语义丰富

样本的重要性，以及 [33] 中指出的结构先验的实用性，我们采用了系统性的筛选策略。具体而言，我们移除了 98% 的海洋分类瓦片（保留 2% 以维持海洋表示），并基于全球土地覆盖 [38]、气候区 [3] 和 ESRI 世界区域 [8] 的分布先验对陆地区域子集进行采样。该方法聚焦于具有生态多样性的有意义陆地区域。图 3 展示了瓦片的全球覆盖情况。

在预训练过程中，我们整理了一个过滤后的子集，包含超过 150 万个网格单元，这些单元在所有三种模态（S1、S2-L1C 和 S2-L2A）中具有一致的覆盖。（需要突出显示磁盘空间使用情况，存储 150 万个样本（uint16 格式）大约需要 76TB。）每个 10.68 km $\times$ 10.68 km 的网格单元被划分为四个不重叠的瓦片，每个瓦片为 534×534 像素，每种模态由此产生超过 600 万个瓦片。总计，这产生了 1870 万个特定模态的训练瓦片。在训练期间，模态被随机采样，并被视为自然增强，以促进传感器不变表示学习。为了减轻空间采样偏差并支持语义感知学习，我们利用 ESRI World Regions 数据集 [8] 为每个网格单元添加了元数据。

5 实验与结果

5.1 预训练实现细节

我们使用 16×16 的 patch 分辨率和输入大小 224×224 对 TerraFM 进行预训练。训练数据集包含约 1.53 百万个多模态样本，我们定义一个虚拟轮次为 30 万样本，以确保频繁的参数更新并提升内存效率。TerraFM-B 训练 150 轮，TerraFM-L 训练 200 轮，前 30 轮采用线性预热。模型在 64 个 GPU 上训练，TerraFM-B 的批量大小为 1024，训练时间为 92 小时；而 TerraFM-L 的批量大小为 2048，训练时间为 183 小时。学习率随批量大小线性缩放，初始值设为 $\text{lr} = 0.0001 \times \text{batch_size}/256$。遵循 DINO 风格的预训练，我们在投影头中禁用批量规范化，并在最初的 3 轮冻结学生网络的最后一层以稳定早期训练。遵循 DINO [4]，我们使用两个全局裁剪，尺度从 $[0.25, 1.0]$ 中采样，以及六个局部裁剪，从 $[0.05, 0.25]$ 中采样。输出维度设置为 $K = 65{,}536$，教师网络温度调度在前 50 轮内从 0.04 线性增加到 0.06。教师网络动量参数遵循余弦调度，起始值为 0.996。应用 0.1 的丢弃路径率来正则化训练。预训练期间我们设置 $N_q = 5$ 和 $\alpha = 0.8$。

5.2 评估实施细节

线性探针评估：为了评估学成表示的质量，我们遵循 DINOv2[19] 的线性探针协议，并对三个关键超参数进行轻量级网格搜索：(i) 学习率，(ii) 从多少个 Transformer 层中提取特征，以及 (iii) 是否仅使用 [CLS] token，或将其与平均池化的 patch token 连结。我们使用随机梯度下降（SGD）训练线性分类器共 50 轮次。训练数据通过随机缩放裁剪进行数据增强。具体而言，我们在集合 $\{10^{-5}, 2\times10^{-5}, 5\times10^{-5}, 10^{-4}, 2\times10^{-4}, 5\times10^{-4}, 10^{-3}, 2\times10^{-3}, 5\times10^{-3}, 10^{-2}, 2\times10^{-2}, 5\times10^{-2}, 1\}$ 上扫描学习率。重要的是，该搜索在计算上非常高效：每个图像的冻结主干特征仅需一次前向传播即可计算完成，并可在所有配置间重复使用，因为每个线性头仅需简单的前向传播。对于每种配置，我们在验证集上评估分类器，并报告最佳验证配置所达到的测试准确率。

UperNet 探针评估：对于 UperNet [34] 探针评估，我们冻结预训练主干并附加 `UPerNet` 解码器头部。具体而言，我们使用 `Feature2Pyramid` 模块作为颈部，随后是 `UPerNet` 解码器和一个辅助的 `FCNHead`。我们仅使用 AdamW 优化器训练分割头部共 50 轮次，不进行学习率预热。我们在基础学习率 $\{10^{-1}, 10^{-2}, 10^{-3}, 10^{-4}, 10^{-5}, 10^{-6}\}$. 和批量大小集合 $\{16, 32, 64\}$. 上进行网格搜索。

表 2: 我们使用 k-近邻法（kNN）评估图像分类，并报告所有单标签任务的 Top-1 准确率。对于多标签 BigEarthNet 基准，我们报告 F1 得分。除 Copernicus-FM 和 TerraFM 外的结果直接取自 [28]。

		m-EuroSat Training %		m-BigEarthNet Training %		m-So2Sat Training %		m-Brick-Kiln Training %	
Model	Backbone	100%	1%	100%	1%	100%	1%	100%	1%
SatMAE	ViT-Base	84.1	34.8	50.6	29.0	36.0	23.1	86.1	73.5
SatMAE++	ViT-Large	82.7	48.5	50.8	31.6	34.7	23.4	89.6	76.7
CROMA	ViT-Base	85.6	51.3	58.8	44.7	48.8	33.8	92.6	85.1
SoftCon	ViT-Small	89.8	27.2	64.7	43.3	51.1	31.4	89.2	77.8
DOFA	ViT-Base	82.8	49.6	49.4	29.9	41.4	29.4	88.3	78.3
Satlas	Swin-Tiny	81.7	35.8	51.9	29.6	36.6	27.1	88.2	73.0
MMEarth	CNN-atto	81.7	30.0	58.3	39.6	39.8	25.1	89.4	79.7
DeCUR	ViT-Small	89.0	46.6	63.8	49.6	45.8	30.9	83.7	74.2
AnySat	ViT-Base	82.2	47.1	54.9	33.7	39.8	29.0	85.3	72.0
Galileo	ViT-Base	93.0	56.6	59.0	36.5	54.8	**43.2**	90.7	78.0
Prithvi-2.0	ViT-Large	80.2	48.0	49.4	28.8	29.5	26.1	87.9	80.6
Copernicus-FM	ViT-Base	76.0	47.4	53.8	33.3	38.4	23.3	93.0	83.2
TerraFM	ViT-Base	94.2	59.3	68.7	49.4	55.1	41.6	**94.5**	**85.6**
	ViT-Large	**95.1**	**62.1**	**69.4**	**50.6**	**55.9**	41.1	93.0	82.2

k-最近邻评估： 为了在无需任何微调的情况下评估学成表示的质量，我们在冻结特征上应用非参数分类，使用 k -最近邻（k-NN）分类器。除了在验证性能上扫描 $k \in 3, 5, 7, 10, 15, 20, 30, 50, 100$ 之外，我们采用与线性探针相同的层选择策略，即评估最后 4 个 Transformer 层的特征。该协议无需额外训练或数据增强，因此成为预训练模型中原始特征质量的一个轻量且可靠的指标。

微调评估： 对于全模型微调，我们解冻主干并与特定任务的头部联合优化。我们在学习率集合和批量大小上进行网格搜索。为稳定训练，我们将主干的学习率设为头部参数所用主学习率的一半。一旦根据验证性能选定最佳配置后，我们将在测试集上评估微调后的模型。

5.3 评估下游任务

基准： 我们在两个全面的遥感基准数据集上评估我们的模型：**GEO-Bench** 和 **Copernicus-Bench**，这两个基准均包含跨越多个领域和模态的多样化下游任务。更多细节见补充材料。

讨论： 我们报告了在四个标准 GEO-Bench 分类任务上的 KNN 分类准确率，以评估无训练情景下学成表示的质量。如 Tab. 2所示，TerraFM 在三个数据集上取得最高性能，超越了特定模态和多模态基础模型。值得注意的是，我们的模型在 m-EuroSAT 上达到 95.1%，在 m-Brick-Kiln 上达到 94.5%，突出了学成表示在标准场景分类任务中的有效性。在 m-So2Sat 和 m-BigEarthNet 等其他具有挑战性的任务中，我们的模型取得领先性能（分别为 55.9% 和 69.4%），超越了 Galileo [28]，尽管 So2Sat 的通道数少于预训练时使用的通道数，这突出了模型对缺失模态信息的鲁棒性。与 CROMA [10] 和 DeCUR [30] 相比，我们的增益表明对比对齐与跨模态融合相结合增强了类别可分离性。不同难度任务的结果表明，我们的模型学习到了鲁棒且可迁移的表示，在不同情景下泛化能力良好。

此外，在 GEO-Bench 上，对于分类任务（微调），TerraFM 在 m-BigEarthNet（73.1%）和 m-EuroSat（98.6%）上实现了提升，并在 m-So2Sat 上表现最佳（66.6%）。对于分割任务（线性探测），我们的 TerraFM-L 在 m-SA-Crop-Type（34.5% mIoU）和 m-Cashew-Plant（37.2% mIoU）上显著优于现有模型。表 4显示，TerraFM-B 超越了如 SatMAE++ 和 DOFA 中使用的 ViT-Large 等更大规模的模型。

在 Copernicus-Bench [32] 评估中，我们的模型在各项任务和模态上始终优于现有的基础模型（表 3）。TerraFM 与现有方法在 Copernicus-Bench 上的全面对比，采用的指标包括 OA（总体准确率）、mAP（平均精确率均值）和 mIoU（交并比均值）。值得注意的是，TerraFM 在大多数任务和指标上均取得了最高得分。具体而言，其在 EuroSAT-S2 上实现了 99.1% 的 OA，BigEarthNet-S2 上实现了 84.4% 的 mAP，Cloud-S2 上实现了 67.9% 的 mIoU。

表 3: 在 Copernicus-Bench 上与现有监督学习和自监督学习方法的比较。评估指标包括分类任务的总体准确率（OA）、多标签分类任务的平均精度均值（mAP），以及分割任务的平均交并比（mIoU）。

	Metric	**Supervised**	**Random**	**SoftCon**	**CROMA**	**DOFA**	**Copernicus-FM**	**TerraFM**
Backbone	–	ViT-B/16	ViT-B/16	ViT-B/14	ViT-B/8	ViT-B/16	ViT-B/16	ViT-B/16
Cloud-S2	mIoU	59.4	60.4	66.9	65.0	65.0	66.7	**67.9**
EuroSAT-S1	OA	81.5	75.4	83.6	83.9	81.7	87.2	**87.8**
EuroSAT-S2	OA	97.6	92.5	96.7	97.0	97.2	97.9	**99.1**
BigEarthNet-S1	mAP	70.6	63.8	**78.7**	70.8	70.5	77.9	76.9
BigEarthNet-S2	mAP	80.1	71.6	83.6	76.4	75.5	79.0	**84.4**
DFC2020-S1	mIoU	50.8	45.4	52.8	52.7	49.7	52.4	**55.4**
DFC2020-S2	mIoU	66.2	62.3	64.1	**66.5**	61.8	64.5	63.8
LCZ-S2	OA	85.3	77.4	83.6	84.1	83.0	84.4	**87.0**

表 4: 在 GEO-Bench 上的性能比较显示，TerraFM 在分类（Top-1 准确率）、分割（mIoU）以及 F1 得分（针对 m-BigEarthNet）方面均取得了最先进的结果，优于以往的视觉模型。

		Classification				**Segmentation**	
Method	Backbone	m-EuroSat	m-BigEarthNet	m-So2Sat	m-Brick-Kiln	m-Cashew-Plant	m-SA-Crop-Type
SatMAE	ViT-Large	96.6	68.3	57.2	98.4	30.8	24.8
SatMAE++	ViT-Large	96.5	67.9	56.0	98.6	29.6	25.7
CROMA	ViT-Large	96.6	71.9	60.6	98.7	31.8	32.0
SoftCon	ViT-Base	97.5	70.3	61.7	98.7	29.6	30.8
DOFA	ViT-Large	96.9	68.0	58.7	98.6	27.7	25.4
Satlas	Swin-Base	97.5	72.8	61.9	98.4	25.1	23.4
MMEarth	CNN-atto	95.7	70.0	57.2	98.9	24.2	22.2
DeCUR	ViT-Small	97.9	70.9	61.7	98.7	26.2	21.5
Prithvi 2.0	ViT-Large	96.5	69.0	54.6	98.6	26.7	22.9
AnySat	ViT-Base	95.9	70.3	51.8	98.6	26.1	27.1
Galileo	ViT-Base	97.7	70.7	63.3	98.7	33.0	30.1
TerraFM	ViT-Base	98.1	72.6	64.9	98.7	34.1	33.0
	ViT-Large	**98.6**	**73.1**	**66.6**	**99.0**	**37.2**	**34.5**

5.4 消融与分析

组件影响： 表 5 展示了我们框架中每个组件的增量收益。我们在完整的训练数据集的一个包含 20 万样本的子集上，对 TerraFM-B 进行了 150 轮次的训练。模型在训练数据的一个

子集上进行训练，报告了每个数据集上的 KNN 分类准确率。为了衡量分割任务的性能，我们在 GeoBench 中的 m-Cashew-Plantation 数据集上使用 uppernet 探测。引入模态作为增强手段，在 m-EuroSat 上提升了 +4.5，在 m-BigEarthNet 上提升了 +3.01。融合机制在 m-Cashew-Plantation 上带来了显著提升，提高了 +11.82；而双中心化进一步优化了性能：在 m-BigEarthNet 上提升了 +3.44，在 m-EuroSat 上提升了 +7.2，在 m-Cashew-Plantation 上提升了 +14.0。

表 5: 组件消融实验：SS = 自监督对比学习，MAug = 模态增强，Fus = 融合，DC = 双中心化。BEN = m-BigEarthNet，ES = m-EuroSat，CP = m-Cashew-Plant。

SS	MAug	Fus	DC	BEN	ES	CP
✓	–	–	–	54.62	83.20	50.58
✓	✓	–	–	57.63	87.70	59.17
✓	✓	✓	–	57.74	88.50	62.40
✓	✓	✓	✓	58.06	90.40	64.58

双中心化动机与可视化：此处，我们讨论双中心化对类别级预测行为和表示多样性的影响。图 4 显示，采用双中心化的模型在大多数类别上表现出更高的 Softmax 熵，表明其预测更加校准，尤其对“红树林”等稀有类别具有显著优势。图 5 表明，双中心化显著增加了原型多样性，即激活的前 5 个特征中不同特征的数量，尤其在尾部类别上表现明显。这说明模型避免了坍缩到常见类原型，从而学习到更具多样性和语义丰富性的表示。这些结果为双中心化作为缓解表示学习中类别不平衡效应的有效策略提供了依据。

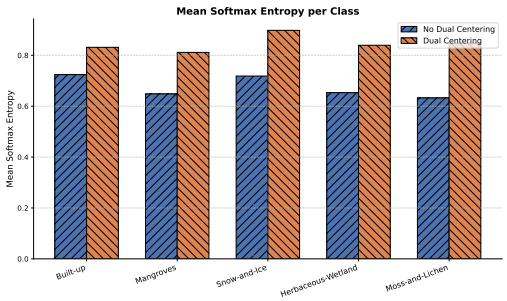

图 4: 每个土地利用/土地覆盖类别在 5000 个均匀采样的训练样本上的平均熵。在计算熵之前，使用固定的随机高斯矩阵将 Logit (K=65,536) 投影到低维空间。基准模型（无双中心化）对于大多数类别表现出较低的熵，显示出对频繁类别原型的过度自信预测，存在有偏性。相比之下，我们的双中心化模型产生了更高的熵，表明高频率原型的主导作用减弱，尤其对于稀有类别（“红树林”、“草本湿地”）。

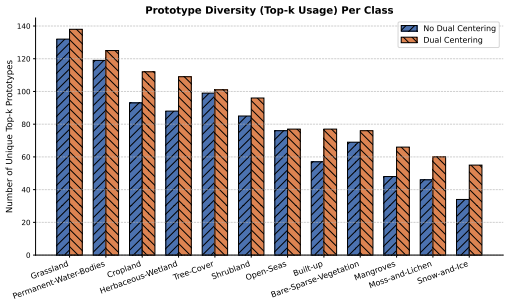

图 5: 原型多样性通过在 5000 个均匀采样的训练样本中激活的唯一前 5 名原型数量进行度量。双中心化方法在“红树林”、“草本湿地”和“建筑用地”等尾部类别中表现出更高的原型多样性，表明具有更丰富的表示学习。基准方法（无双中心化）倾向于重复使用较少的原型子集，尤其是在稀有类别中，反映出对高频类别主导特征的过度依赖。

MACs-性能权衡：我们使用乘累加操作（MACs）作为推理成本的衡量标准，评估了多种遥感基础模型的计算效率权衡。如图 6所示，TerraFM 在 m-EuroSat 上的准确率最高，同时相比其他大规模模型，其 MACs 显著更低。这突显了我们融合设计和预训练策略的高效性，表明在无需过度计算开销的情况下也能实现优异性能。MACs 较高的模型并不总是能带来更好的准确率，这凸显了高效且具有表现力的架构对于可扩展地球观测应用的重要性。

图 6: 模型在 m-EuroSat 数据集上的准确率与效率对比。每个点表示一个主干网络的 k-NN 分类准确率（纵轴）与其推理时的乘加操作数（单位：十亿，对数坐标，横轴）。标记的形状和颜色编码了主干网络的大小，具体含义见插图中的图例。此处报告了两种 TerraFM 变体（Base、Large），它们在保持相对于轻量级和重型基准适中计算成本的同时，实现了最高的准确率。

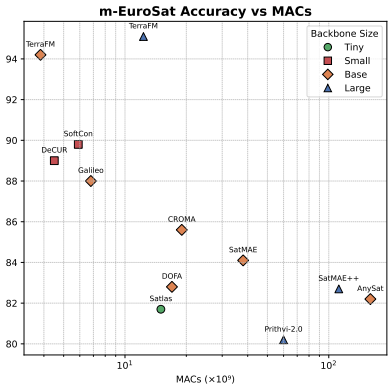

6 结论

在本工作中，我们提出了 TerraFM，这是一种专为多传感器遥感（EO）设计的统一且可扩展的基础模型（FM）。鉴于 EO 数据的独特性，我们的方法特别关注传感器异质性、尺度不变性以及类别频率不平衡问题，这些因素对于构建可泛化的 EO 基础模型至关重要。我们的预训练方法利用对比学习，从大规模哨兵-1 和哨兵-2 数据中获取具有地理和光谱感知能力的表示。具体而言，我们融合了模态特定的图像块嵌入、自适应交叉注意力融合机制以及双中心对比学习目标，以丰富异构遥感数据的表示。在 GEO-Bench 和 Copernicus-Bench 上的广泛评估表明，TerraFM 在分类和分割任务上均持续优于当前最先进的自监督 ViT 模型。

参考文献

[1] Astruc, G., N. Gonthier, C. Mallet, and L. Landrieu (2024). Anysat: An earth observation model for any resolutions, scales, and modalities. *arXiv preprint arXiv:2412.14123*.

[2] Bastani, F., P. Wolters, R. Gupta, J. Ferdinando, and A. Kembhavi (2023). Satlaspretrain: A large-scale dataset for remote sensing image understanding.

[3] Beck, H. E., N. E. Zimmermann, T. R. McVicar, N. Vergopolan, A. Berg, and E. F. Wood (2018). Present and future köppen-geiger climate classification maps at 1-km resolution. *Scientific data 5*(1), 1–12.

[4] Caron, M., H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, and A. Joulin (2021). Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 9650–9660.

[5] Chan-To-Hing, H. and B. Veeravalli (2024). Fus-mae: A cross-attention-based data fusion approach for masked autoencoders in remote sensing. In *IGARSS 2024-2024 IEEE International Geoscience and Remote Sensing Symposium*, pp. 6953–6958. IEEE.

[6] Dosovitskiy, A., L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby (2021). An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*.

[7] Drusch, M., U. Del Bello, S. Carlier, O. Colin, V. Fernandez, F. Gascon, B. Hoersch, C. Isola, P. Laberinti, P. Martimort, et al. (2012). Sentinel-2: Esa's optical high-resolution mission for gmes operational services. *Remote sensing of Environment 120*, 25–36.

[8] Esri, Global Mapping International, and U.S. Central Intelligence Agency (2025). World Regions. `https://www.arcgis.com/home/item.html?id=84dbc97915244e35808e87a881133d09`. Layer package representing boundaries for 25 commonly recognized world regions. Updated April 29, 2025. Accessed April 30, 2025.

[9] Francis, A. and M. Czerkawski (2024). Major tom: Expandable datasets for earth observation. In *IGARSS 2024-2024 IEEE International Geoscience and Remote Sensing Symposium*, pp. 2935–2940. IEEE.

[10] Fuller, A., K. Millard, and J. Green (2023). Croma: Remote sensing representations with contrastive radar-optical masked autoencoders. *Advances in Neural Information Processing Systems 36*, 5506–5538.

[11] Gao, P., T. Ma, H. Li, Z. Lin, J. Dai, and Y. Qiao (2022). MCMAE: Masked convolution meets masked autoencoders. In A. H. Oh, A. Agarwal, D. Belgrave, and K. Cho (Eds.), *Advances in Neural Information Processing Systems*.

[12] Guo, X., J. Lao, B. Dang, Y. Zhang, L. Yu, L. Ru, L. Zhong, Z. Huang, K. Wu, D. Hu, et al. (2024). Skysense: A multi-modal remote sensing foundation model towards universal interpretation for earth observation imagery. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 27672–27683.

[13] Han, B., S. Zhang, X. Shi, and M. Reichstein (2024). Bridging remote sensors with multisensor geospatial foundation models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 27852–27862.

[14] He, K., X. Chen, S. Xie, Y. Li, P. Dollár, and R. Girshick (2022). Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 16000–16009.

[15] Huot, F., R. L. Hu, N. Goyal, T. Sankar, M. Ihme, and Y.-F. Chen (2022). Next day wildfire spread: A machine learning dataset to predict wildfire spreading from remote-sensing data. *IEEE Transactions on Geoscience and Remote Sensing 60*, 1–13.

[16] Kuckreja, K., M. S. Danish, M. Naseer, A. Das, S. Khan, and F. S. Khan (2024). Geochat: Grounded large vision-language model for remote sensing. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 27831–27840.

[17] Kussul, N., M. Lavreniuk, S. Skakun, and A. Shelestov (2017). Deep learning classification of land cover and crop types using remote sensing data. *IEEE Geoscience and Remote Sensing Letters 14*(5), 778–782.

[18] Li, X., D. Hong, and J. Chanussot (2024). S2mae: A spatial-spectral pretraining foundation model for spectral remote sensing data. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 24088–24097.

[19] Oquab, M., T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby, et al. (2023). Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*.

[20] Prodhan, F. A., J. Zhang, F. Yao, L. Shi, T. P. Pangali Sharma, D. Zhang, D. Cao, M. Zheng, N. Ahmed, and H. P. Mohana (2021). Deep learning for monitoring agricultural drought in south asia using remote sensing data. *Remote sensing 13*(9), 1715.

[21] Rahnemoonfar, M., T. Chowdhury, A. Sarkar, D. Varshney, M. Yari, and R. R. Murphy (2021). Floodnet: A high resolution aerial imagery dataset for post flood scene understanding. *IEEE Access 9*, 89644–89654.

[22] Reed, C. J., R. Gupta, S. Li, S. Brockman, C. Funk, B. Clipp, K. Keutzer, S. Candido, M. Uyttendaele, and T. Darrell (2023). Scale-mae: A scale-aware masked autoencoder for multiscale geospatial representation learning. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 4088–4099.

[23] Roscher, R., M. Russwurm, C. Gevaert, M. Kampffmeyer, J. A. Dos Santos, M. Vakalopoulou, R. Hänsch, S. Hansen, K. Nogueira, J. Prexl, et al. (2024). Better, not just more: Data-centric machine learning for earth observation. *IEEE Geoscience and Remote Sensing Magazine*.

[24] Sarkar, A., T. Chowdhury, R. R. Murphy, A. Gangopadhyay, and M. Rahnemoonfar (2023). Sam-vqa: Supervised attention-based visual question answering model for post-disaster damage assessment on remote sensing imagery. *IEEE Transactions on Geoscience and Remote Sensing 61*, 1–16.

[25] Szwarcman, D., S. Roy, P. Fraccaro, Þ. E. Gíslason, B. Blumenstiel, R. Ghosal, P. H. de Oliveira, J. L. d. S. Almeida, R. Sedona, Y. Kang, et al. (2024). Prithvi-eo-2.0: A versatile multi-temporal foundation model for earth observation applications. *arXiv preprint arXiv:2412.02732*.

[26] Tang, M., A. Cozma, K. Georgiou, and H. Qi (2023). Cross-scale mae: A tale of multiscale exploitation in remote sensing. *Advances in Neural Information Processing Systems 36*, 20054–20066.

[27] Torres, R., P. Snoeij, D. Geudtner, D. Bibby, M. Davidson, E. Attema, P. Potin, B. Rommen, N. Floury, M. Brown, et al. (2012). Gmes sentinel-1 mission. *Remote sensing of environment 120*, 9–24.

[28] Tseng, G., A. Fuller, M. Reil, H. Herzog, P. Beukema, F. Bastani, J. R. Green, E. Shelhamer, H. Kerner, and D. Rolnick (2025). Galileo: Learning global and local features in pretrained remote sensing models. *arXiv preprint arXiv:2502.09356*.

[29] Waldmann, L., A. Shah, Y. Wang, N. Lehmann, A. J. Stewart, Z. Xiong, X. X. Zhu, S. Bauer, and J. Chuang (2025). Panopticon: Advancing any-sensor foundation models for earth observation. *arXiv preprint arXiv:2503.10845*.

[30] Wang, Y., C. M. Albrecht, N. A. A. Braham, C. Liu, Z. Xiong, and X. X. Zhu (2024). Decoupling common and unique representations for multimodal self-supervised learning. In *European Conference on Computer Vision*, pp. 286–303. Springer.

[31] Wang, Y., Y. Sun, X. Cao, Y. Wang, W. Zhang, and X. Cheng (2023). A review of regional and global scale land use/land cover (lulc) mapping products generated from satellite remote sensing. *ISPRS Journal of Photogrammetry and Remote Sensing 206*, 311–334.

[32] Wang, Y., Z. Xiong, C. Liu, A. J. Stewart, T. Dujardin, N. I. Bountos, A. Zavras, F. Gerken, I. Papoutsis, L. Leal-Taixé, et al. (2025). Towards a unified copernicus foundation model for earth vision. *arXiv preprint arXiv:2503.11849*.

[33] Wang, Z., R. Prabha, T. Huang, J. Wu, and R. Rajagopal (2024). Skyscript: A large and semantically diverse vision-language dataset for remote sensing. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Volume 38, pp. 5805–5813.

[34] Xiao, T., Y. Liu, B. Zhou, Y. Jiang, and J. Sun (2018). Unified perceptual parsing for scene understanding. In *European Conference on Computer Vision*. Springer.

[35] Xie, Z., Z. Zhang, Y. Cao, Y. Lin, Y. Wei, Q. Dai, and H. Hu (2023). On data scaling in masked image modeling. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 10365–10374.

[36] Xiong, Z., Y. Wang, F. Zhang, A. J. Stewart, J. Hanna, D. Borth, I. Papoutsis, B. Le Saux, G. Camps-Valls, and X. X. Zhu (2024). Neural plasticity-inspired foundation model for observing the earth crossing modalities. *arXiv e-prints*, arXiv–2403.

[37] Yu, D. and C. Fang (2023). Urban remote sensing with spatial big data: A review and renewed perspective of urban studies in recent decades. *Remote Sensing 15*(5), 1307.

[38] Zanaga, D., R. Van De Kerchove, D. Daems, W. De Keersmaecker, C. Brockmann, G. Kirches, J. Wevers, O. Cartus, M. Santoro, S. Fritz, et al. (2022). Esa worldcover 10 m 2021 v200.

补充材料

本补充材料提供了与主论文相辅相成的额外实验、分析和可视化内容。其中包括我们多模态融合策略（S1）的详细描述和实验，以及定性图像（S2）。我们还报告了与可比方法的 GPU 小时数对比（S3），并使用全球地图可视化了我们数据集的土地覆盖分布（S4）。

S1　多模态融合策略：

我们研究了多种多模态融合策略，并在两个基准数据集 m-BigEarthNet 和 m-EuroSat 上报告结果，如表 A1 所示。作为基准，我们评估仅使用 Sentinel-2 L2A 输入的标准 DINO 训练（*DINO (S2-L2A)*），该方法学习单峰值表示。

为了实现显式的模态感知学习，我们采用 *Multi-Student-Teacher* 方法，每个模态都有自己的学生和教师网络，并在学生输出之间加入对齐损失以强制跨模态一致性。这在两个数据集上均带来了稳定提升。我们还测试了一种更具表达力的融合方法，*CrossAttn (Q = 196) Global*，其中 196 个学成查询（标准用于 224×224 图像输入）在补丁嵌入后立即全局关注多模态 token。然而，该方法表现不佳，可能由于参数过多且缺乏空间对齐的归纳偏置。

图 A1 直观总结了表 A1 中评估的关键融合策略，包括 (a) Multi-Student-Teacher、(b) 单峰值 DINO 和 (c) CrossAttn (Q = 196) Global，突出显示其架构差异和融合机制。我们提出的方法 *TerraFM-B (Q = 1)* 将一种模态视为增强，并使用每个位置一个学成的空间查询进行融合。这种轻量级注意力机制在非集成方法中取得了最佳性能。为进一步分析架构选择，我们测试了一个变体 *TerraFM-B (ViT PatchEmb)*，其中卷积补丁嵌入被 ViT-S 主干替换，仅用于提取 token。尽管具有竞争力，但此设置因模型复杂度增加和潜在过拟合而略微降低了性能。最后，我们的完整模型 *TerraFM-B (Q = 5)* 使用多个学成空间查询以实现更丰富的模态间融合。它实现了最佳整体性能，验证了我们融合设计的可扩展性和有效性。

表 A1：基于 k-NN 评估的多模态融合策略消融实验。TerraFM-B 采用多个空间查询（Q = 5）时表现最佳。

	m-BigEarthNet	m-EuroSat
DINO (S2-L2A)	54.6	83.2
Multi-Student-Teacher	55.8	87.8
CrossAttn (Q = 196) Global	52.0	77.1
TerraFM-B (Q = 1)	57.2	89.2
TerraFM-B (ViT PatchEmb)	56.9	87.2
TerraFM-B (Q = 5)	**58.1**	**90.4**

S2　定性：

图 A2 展示了云和云影分割任务的定性结果。TerraFM 准确勾勒出云和云影区域，在不同场景下有效区分视觉上相似的模式，同时保持空间一致性。这些结果展示了模型在多样且具有挑战性的大气条件下的强大泛化能力。

S3　滑坡检测

我们在 Landslide4Sense（L4S）基准上评估滑坡分割性能，该基准利用多源卫星数据（包括 Sentinel-2 波段、DEM 和坡度信息）为多样化的山地区域提供滑坡与非滑坡区域的分割标签。我们的方法 TerraFM 表现出色，平均交并比（mean IoU）达到 70.8，滑坡交并比

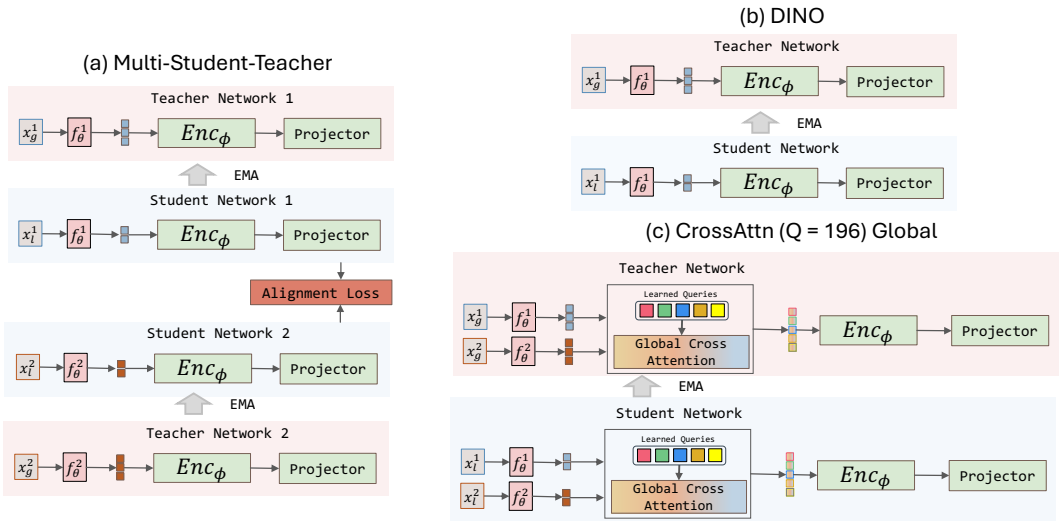

图 A1: 不同融合策略的架构概览：(a) 带对齐损失的多学生-教师模型，(b) 单峰值 DINO 基准模型，(c) CrossAttn（Q = 196）与全局学成查询。

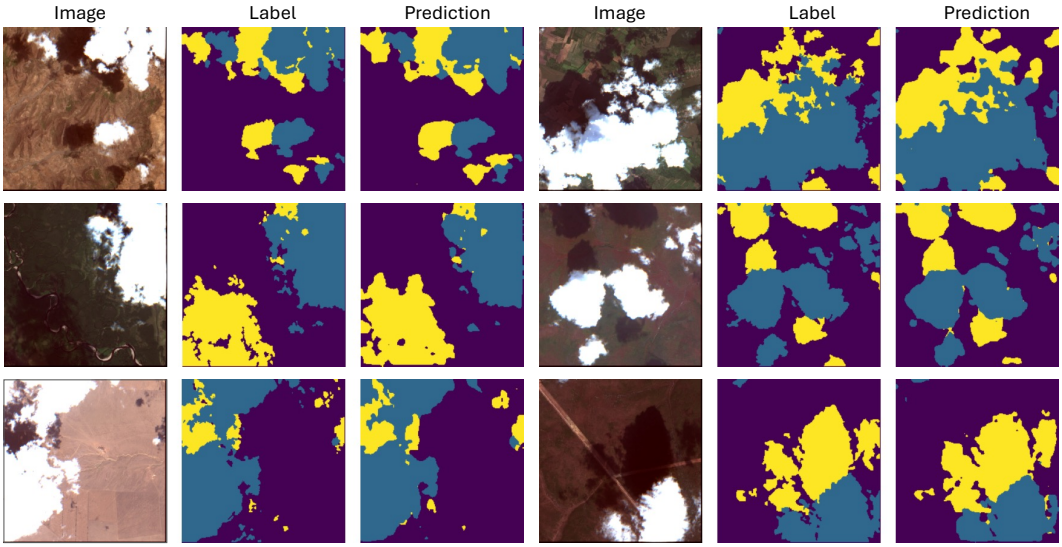

图 A2: 云和云阴影分割的定性结果。每个三元组显示输入图像（左侧）、真实值掩码（中间）和 TerraFM 预测（右侧）。

（landslide IoU）为 43.1，优于 Prithvi-EO-2.0 基准（表 A2）。TerraFM 与 Prithvi-EO-2.0 均采用焦点损失（focal loss）进行训练，批量大小（batch size）为 16，使用 Adam 优化器，学习率（learning rate）为 1×10^{-4}。

图 A3展示了 TerraFM 的定性结果，显示了预测的滑坡掩码（mask）与真实值（ground truth）的对比。

表 A2: Landslide4Sense 测试集上的滑坡检测性能。尽管参数量显著更小（TerraFM 为 120M，而 Prithvi-EO-2.0 为 300M），TerraFM 在整体分割性能上仍更高，尤其是在滑坡区域的表现更为突出。

	mIoU	IoU (Landslide)
Prithvi-EO-2.0 (300M)	65.0	31.5
TerraFM (120M)	**70.8**	**43.1**

S3 GPU 时长对比：

与 Prithvi-2.0 相比，后者使用最多 80 块 GPU 训练 ViT-L（300M）模型达 400 轮次，消耗约 21,000 GPU 小时 [25]，我们的 TerraFM（300M）在显著更少的资源下达到了相当的规模。具体而言，TerraFM 在 64 块 GPU 上训练 200 轮次，总计约 12,000 GPU 小时。

S4 土地覆盖分布：

图 A4 展示了我们预训练数据的全局空间覆盖情况。所选样本涵盖了多种生态系统，全面覆盖了城市、植被、海洋和干旱区域，保持了平衡的分布。插图展示了精细的地面覆盖变化，确保了训练瓦片间语义信息的丰富性。这种多样化的地理基础在提升 TerraFM 在不同区域和任务间的泛化能力方面起到了关键作用。

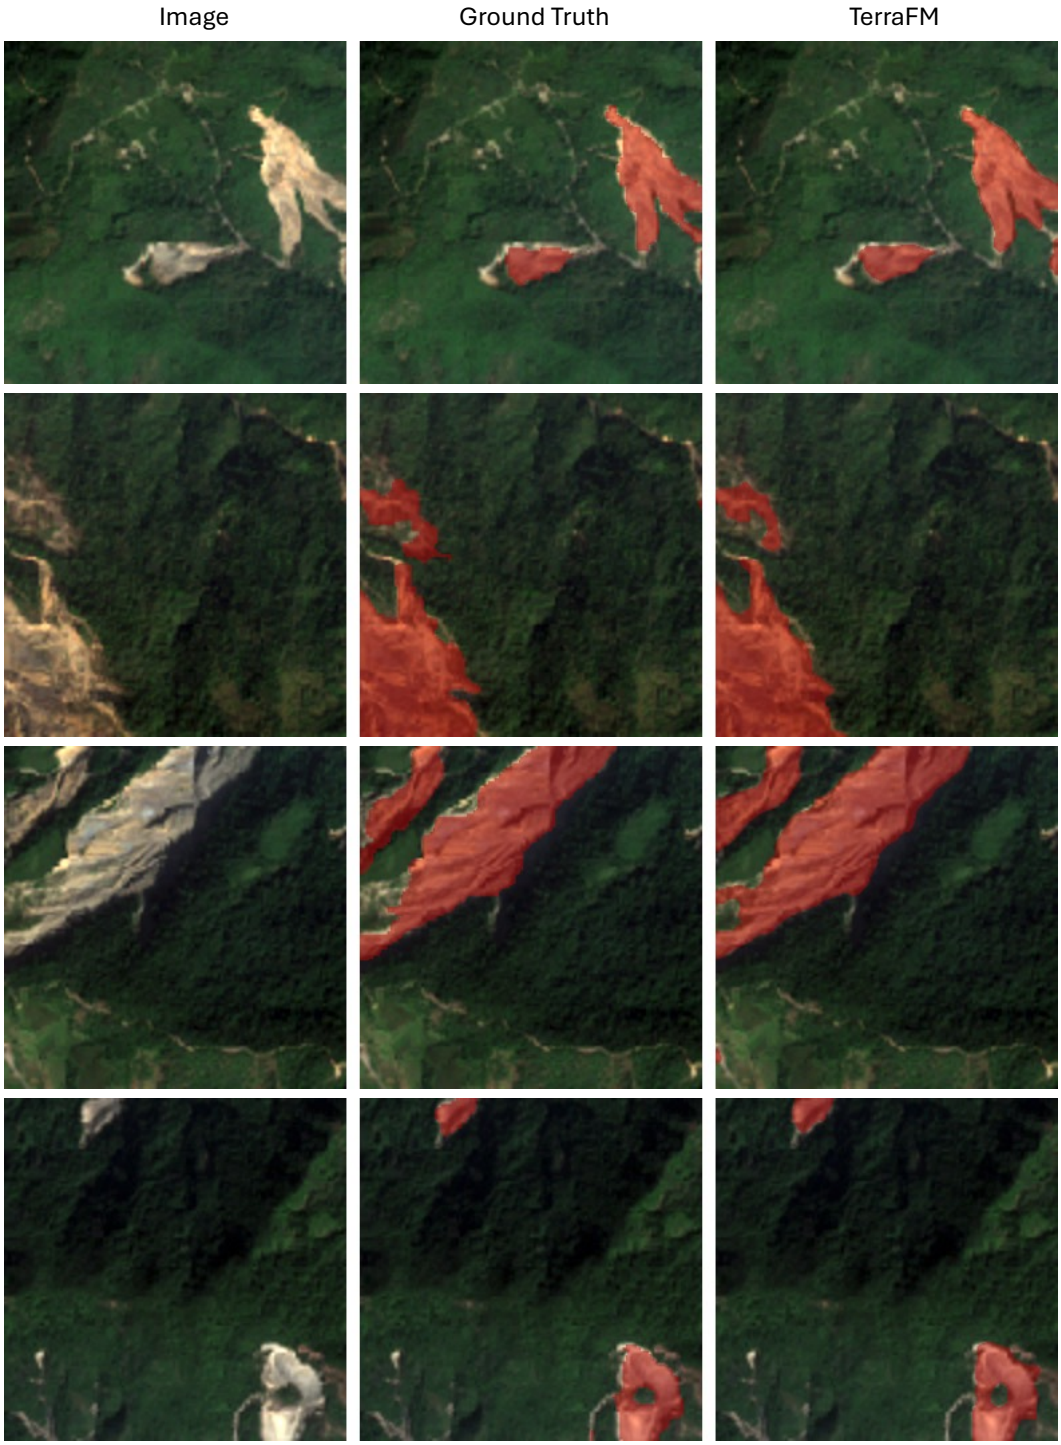

图 A3: 滑坡分割的定性结果。每个三元组显示输入图像（左）、真实值掩码（中）和 TerraFM 预测结果（右）。

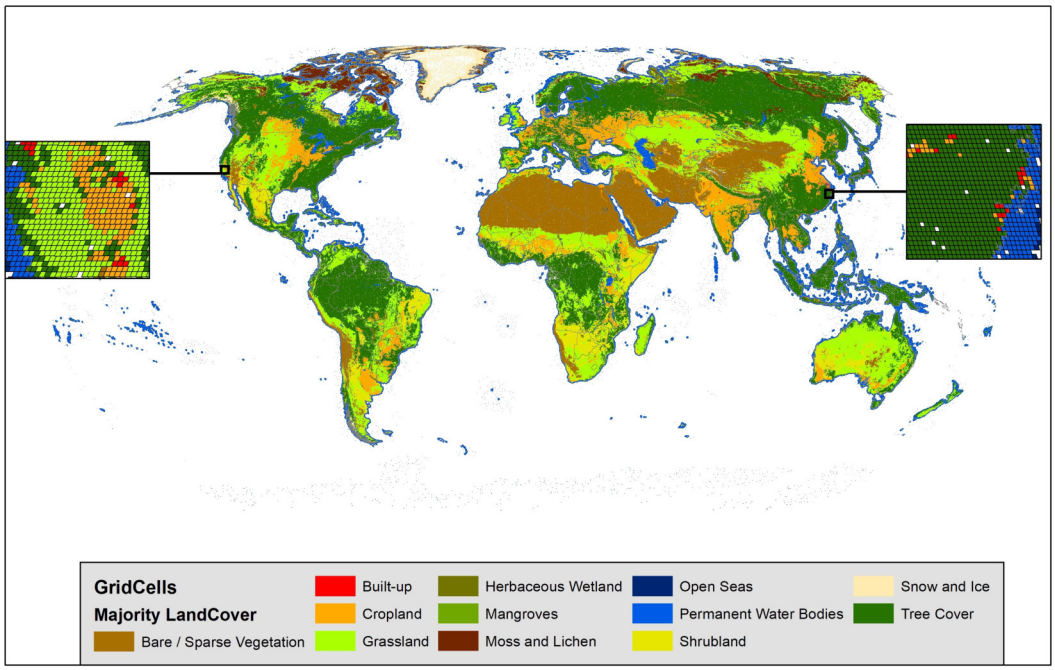

图 A4: 基于 ESA WorldCover 标签的样本训练图块全球分布，按主要地表覆盖类别划分。插图展示了图块级别的多样性细节，突出显示了建成区、植被和水体类别的覆盖情况。